





NGUYỄN VĂN TUẤN

Phân tích DỮ LIỆU với




NHÀ XUẤT BẢN TỔNG HỢP THÀNH PHỐ HỒ CHÍ MINH



Tác giả Nguyễn Văn Tuấn là một nhà nghiên cứu cao cấp (Principal Fellow) và đứng đầu một laboratory chuyên nghiên cứu về di truyền và dịch tễ học loãng xương của Viện Nghiên cứu Y khoa Garvan (Australia). Ông còn là Giáo sư Y khoa của Đại học New South Wales (Australia). Mới đây, tác giả được bổ nhiệm chức danh Giáo sư xuất sắc (Distinguished Professor) của Đại học Công nghệ Sydney (Australia). Ông là một nhà nghiên cứu nổi tiếng trên thế giới về loãng xương và một trong những kết quả nghiên cứu của ông được phát triển thành một mô hình tiên lượng gãy xương “Garvan Fracture Risk Calculator” (www.fractureriskcalculator.com) được các bác sĩ khắp thế giới sử dụng trong lâm sàng. Ở Việt Nam, tác giả là Giám đốc Chương trình nghiên cứu về cơ và xương tại Trường Đại học Tôn Đức Thắng (bmr.tdt.edu.vn) và là giáo sư thỉnh giảng của Trường Đại học Nguyễn Tất Thành, Thành phố Hồ Chí Minh.

PHÂN TÍCH DỮ LIỆU VỚI



BIỂU GHI BIÊN MỤC TRƯỚC XUẤT BẢN ĐƯỢC THỰC HIỆN BỞI THƯ VIỆN KHTH TP.HCM

Nguyễn Văn Tuấn

Phân tích dữ liệu với R / Nguyễn Văn Tuấn. - T.P. Hồ Chí Minh : Nxb. Tổng hợp T.P. Hồ Chí Minh, 2014.

520 tr. ; 25 cm.

ISBN 978-604-58-2831-1

1. Cơ sở dữ liệu -- Phương pháp thống kê. 2. Xử lý dữ liệu -- Phương pháp thống kê.


1. Databases -- Stastical methods. 2. Data processing -- Stastical methods.

025.0400727 -- ddc 23

N573-T88

NGUYỄN VĂN TUẤN

PHÂN TÍCH DỮ LIỆU VỚI



NHÀ XUẤT BẢN TỔNG HỢP THÀNH PHỐ HỒ CHÍ MINH

LỜI NÓI ĐẦU

Thống kê là một bộ môn khoa học về dữ liệu. Dữ liệu có thể được thu thập từ những nghiên cứu khoa học, nhưng cũng có thể bắt nguồn từ những “thí nghiệm tự nhiên” trong xã hội và đời sống hàng ngày. Khoa học thống kê (statistical science) và những phương pháp thống kê giúp chúng ta chuyển hoá *dữ liệu thô* thành *thông tin*, và với kiến thức chuyên ngành, biến thông tin thành *tri thức*. Do đó, khoa học thống kê đóng một vai trò không thể thiếu được trong việc hoán chuyển dữ liệu thành thông tin và tri thức.

Trái với quan điểm của nhiều người xem thống kê là một công cụ, trong thực tế, các phương pháp phân tích dù dựa vào nền tảng của toán học và xác suất, nhưng đó chỉ là phần “kỹ thuật”, phần quan trọng hơn là thiết kế nghiên cứu và diễn giải ý nghĩa dữ liệu. Người làm thống kê, do đó, không chỉ là người đơn thuần làm phân tích dữ liệu, mà phải là một nhà khoa học, một nhà suy nghĩ (thinker) về nghiên cứu khoa học. Chính vì thế, mà khoa học thống kê đóng một vai trò cực kì quan trọng, một vai trò không thể thiếu được trong các công trình nghiên cứu khoa học, nhất là khoa học thực nghiệm. Có thể nói rằng ngày nay, nếu không có thống kê thì các thử nghiệm gen với triệu triệu số liệu chỉ là những con số vô hồn, vô nghĩa.

Một công trình nghiên cứu khoa học, cho dù có tốn kém và quan trọng cỡ nào, nếu không được phân tích đúng phương pháp sẽ không có ý nghĩa khoa học gì cả. Chính vì thế mà ngày nay, chỉ cần nhìn qua tất cả các tập san nghiên cứu khoa học trên thế giới, hầu như bất cứ bài báo y học nào cũng có phần “Statistical Analysis” (Phân tích thống kê), nơi mà tác giả phải mô tả cẩn thận phương pháp phân tích, tính toán như thế nào, và giải thích ngắn gọn tại sao sử dụng những phương pháp đó để hàm ý “bảo vệ” hay tăng trọng lượng khoa học cho những phát biểu trong bài báo. Các tập san y học có uy tín càng cao yêu cầu về phân tích thống kê càng nặng.

Một trong những phát triển quan trọng nhất trong khoa học thống kê là ứng dụng máy tính cho phân tích và tính toán thống kê. Có thể nói không ngoa rằng không có máy tính, khoa học thống kê vẫn chỉ là một khoa học buồn tẻ khô khan, với những công thức rắc rối mà thiếu tính ứng dụng vào thực tế. Máy tính đã giúp khoa học thống kê làm một cuộc cách mạng lớn nhất trong lịch sử của bộ môn: đó là đưa khoa học thống kê vào thực tế, giải quyết các vấn đề gai góc nhất và góp phần làm phát triển khoa học thực nghiệm. Ngày nay, với một máy tính cá nhân, bất cứ ai cũng có thể thực hiện những phân tích thống kê phức tạp trong vòng vài giây mà trước đây phải tốn hàng tháng trời mới hoàn tất.

Nhưng nếu máy tính mà không có phần mềm thì máy tính cũng chỉ là một đồng sắt hay silicon “vô hồn” và vô dụng. Một phần mềm đã, đang và sẽ làm cách mạng thống kê là R. Phần mềm này được một số nhà nghiên cứu thống kê và khoa học trên thế giới phát triển và hoàn thiện trong khoảng 20 năm qua để sử dụng cho việc học tập, giảng dạy và nghiên cứu. Cuốn sách này sẽ giới thiệu bạn đọc cách sử dụng R cho phân tích thống kê và đồ thị.

R là một ngôn ngữ thống kê học, nhưng cũng có thể xem là một phần mềm có thể sử dụng cho các phân tích thống kê. Trong khoảng một thập niên qua, R đã trở nên cực kì phổ biến trong các trường đại học trên thế giới, và được dùng như là một phương tiện cho giảng dạy về thống kê học. Vì R hoàn toàn miễn phí nhưng có năng lực phân tích dữ liệu cao hơn các phần mềm thương mại (như SPSS, SAS, Stata, v.v.) nên các chuyên gia dự đoán rằng R sẽ trở thành một nhu liệu thống kê học phổ biến nhất trong tương lai gần. Do đó, chúng ta cần phải học và “làm quen” với R qua sử dụng nhu liệu này trong các phân tích dữ liệu.

Trái với cảm nhận thông thường, miễn phí không có nghĩa là chất lượng kém. Thật vậy, chẳng những hoàn toàn miễn phí, R còn có khả năng làm *tất cả* (xin nói lại: *tất cả*), thậm chí còn hơn cả, những phân tích mà các phần mềm thương mại làm. Có những phương pháp phân tích các phần mềm thương mại không thể thực hiện được, nhưng R có thể thực hiện một cách dễ dàng. Ngày nay, tất cả các phương pháp phân tích mới đều được triển khai qua R trước khi đưa vào các phần mềm khác. R có thể tải xuống máy tính cá nhân của bất cứ cá nhân nào, bất cứ lúc nào, và bất cứ ở đâu trên thế giới. Chỉ vài

phút cài đặt là R có thể đưa vào sử dụng. Chính vì thế mà đại đa số các đại học nước ngoài càng ngày càng chuyển sang sử dụng R cho học tập, nghiên cứu và giảng dạy. Trong xu hướng đó, cuốn sách này có một mục tiêu khiêm tốn là giới thiệu đến bạn đọc trong nước để kịp thời cập nhật hóa những phát triển về tính toán và phân tích thống kê trên thế giới.

Cuốn sách này được soạn chủ yếu cho sinh viên đại học và các nhà nghiên cứu khoa học, những người cần một phần mềm để học thống kê, để phân tích số liệu, hay vẽ đồ thị từ số liệu khoa học. Cuốn sách này không phải là sách giáo khoa về lý thuyết thống kê, hay nhằm chỉ bạn đọc cách làm phân tích thống kê, nhưng sẽ giúp bạn đọc làm phân tích thống kê hữu hiệu hơn và hào hứng hơn. Mục đích chính của tôi là cung cấp cho bạn đọc những kiến thức cơ bản về thống kê, và cách ứng dụng R cho giải quyết vấn đề, và qua đó làm nền tảng để bạn đọc tìm hiểu hay phát triển thêm R.

Tôi cho rằng, cũng như bất cứ ngành nghề nào, cách học phân tích thống kê hay nhất là tự mình làm phân tích. Vì thế, sách này được viết với rất nhiều ví dụ và dữ liệu thực. Bạn đọc có thể vừa đọc sách, vừa làm theo những chỉ dẫn trong sách (bằng cách gõ các lệnh vào máy tính) và sẽ thấy hào hứng hơn. Nếu bạn đọc đã có sẵn một dữ liệu nghiên cứu của chính mình thì việc học tập sẽ hữu hiệu hơn bằng cách ứng dụng ngay những phép tính trong sách. Đối với sinh viên, nếu chưa có số liệu sẵn, các bạn có thể dùng các phương pháp mô phỏng (simulation) để hiểu thống kê hơn. Trong sách có một số dữ liệu dùng cho phân tích. Các dữ liệu này đã được đưa lên mạng và có trong trang web www.statistics.vn/data. Bạn đọc có thể tải dữ liệu về máy tính cá nhân và tự thực hành. Bạn đọc cũng có thể thực hành các hàm R trong máy tính cá nhân mà không cần tải dữ liệu về máy.

Khoa học thống kê ở nước ta tương đối còn mới, cho nên một số thuật ngữ chưa được diễn dịch một cách thống nhất và hoàn chỉnh. Vì thế, bạn đọc sẽ thấy đâu đó trong sách một vài thuật ngữ “lạ”, và trong trường hợp này, tôi cố gắng kèm theo thuật ngữ gốc tiếng Anh để bạn đọc tham khảo. Ngoài ra, trong phần cuối của sách, tôi có liệt kê các thuật ngữ Anh - Việt đã được đề cập đến trong sách.

Tôi chân thành cảm ơn Tiến sĩ Nguyễn Đình Nguyên và Kiến trúc sư Nguyễn Nhất Hùng đã thiết kế và có ý tưởng thiết kế cho trang bìa của cuốn sách.

Tôi hi vọng bạn đọc sẽ tìm thấy trong sách một vài thông tin bổ ích, một vài kĩ thuật hay phép tính có ích cho việc học tập, giảng dạy và nghiên cứu của mình. Nhưng có lẽ, chẳng có cuốn sách nào hoàn thiện hay không có thiếu sót; do đó, nếu bạn đọc phát hiện một sai sót trong sách, xin báo cho tôi biết. Thành thật cảm ơn các bạn đọc trước. Bây giờ, tôi mời bạn đọc cùng đi với tôi một “hành trình thống kê” ngắn với R.

Sydney, ngày 30/7/2014
(Những ngày dưỡng bệnh)

Nguyễn Văn Tuấn

01 Giới thiệu ngôn ngữ R

1.1 R là gì?

Nói một cách ngắn gọn, R là một phần mềm sử dụng cho phân tích thống kê và đồ thị. Thật ra, về bản chất, R là ngôn ngữ máy tính đa năng, có thể sử dụng cho nhiều mục tiêu khác nhau, từ tính toán đơn giản, toán học giải trí (recreational mathematics), tính toán ma trận (matrix), đến các phân tích thống kê phức tạp. Vì là một ngôn ngữ, cho nên người ta có thể sử dụng R để phát triển thành các phần mềm chuyên môn cho một vấn đề tính toán cá biệt.

Hai người sáng tạo ra R là hai nhà thống kê học tên là Ross Ihaka và Robert Gentleman. Kể từ khi R ra đời, rất nhiều nhà nghiên cứu thống kê và toán học trên thế giới ủng hộ và tham gia vào việc phát triển R. Chủ trương của những người sáng tạo ra R là theo định hướng mở rộng (Open Access). Cũng một phần vì chủ trương này mà R hoàn toàn miễn phí. Bất cứ ai ở bất cứ nơi nào trên thế giới đều có thể truy nhập và tải toàn bộ mã nguồn của R về máy tính của mình để sử dụng. Cho đến nay, chỉ qua chưa đầy 5 năm phát triển, nhưng có nhiều nhà thống kê học, toán học, nghiên cứu trong mọi lĩnh vực đã chuyển sang sử dụng R để phân tích dữ liệu khoa học. Trên toàn cầu, đã có một mạng lưới gần một triệu người sử dụng R, và con số này đang tăng theo cấp số nhân. Có thể nói trong vòng 10 năm nữa, chúng ta sẽ không cần đến các phần mềm thống kê đắt tiền như SAS, SPSS hay Stata (các phần mềm này giá có thể lên đến 100.000 USD một năm) để phân tích thống kê nữa, vì tất cả các phân tích đó có thể tiến hành bằng R.

Vì thế, những ai làm nghiên cứu khoa học cần nên học cách sử dụng R cho phân tích thống kê và đồ thị. Chương này sẽ hướng dẫn bạn đọc cách sử dụng R.

1.2 Tải R xuống và cài đặt vào máy tính

Để sử dụng R, việc đầu tiên là chúng ta phải cài đặt R trong máy tính của mình. Để làm việc này, ta phải truy nhập vào mạng và vào website có tên là “Comprehensive R Archive Network” (CRAN) sau đây:

<http://cran.R-project.org>.

Tài liệu cần tải về, tùy theo phiên bản, nhưng thường có tên bắt đầu bằng mẫu tự R và số phiên bản (version). Chẳng hạn như phiên bản mà tác giả sử dụng vào cuối năm 2005 là 2.2.1, nên tên của tài liệu cần tải là:

`R-2.2.1-win32.zip`

Tài liệu này khoảng 26 MB, và địa chỉ cụ thể để tải là:

<http://cran.r-project.org/bin/windows/base/R-2.2.1-win32.exe>

Tại website này, chúng ta có thể tìm thấy rất nhiều tài liệu chỉ dẫn cách sử dụng R, đủ trình độ, từ sơ đẳng đến cao cấp. Nếu chưa quen với tiếng Anh, tài liệu này có thể cung cấp những thông tin cần thiết để sử dụng mà không cần phải đọc các tài liệu khác.

Khi đã tải R xuống máy tính, bước kế tiếp là cài đặt (set-up) vào máy tính. Để làm việc này, chúng ta chỉ đơn giản nhấn chuột vào tài liệu trên và làm theo hướng dẫn cách cài đặt trên màn hình.

1.3 Package cho các phân tích đặc biệt


R cung cấp cho chúng ta một “ngôn ngữ” máy tính và một số *function* để làm các phân tích căn bản và đơn giản. Nếu muốn làm những phân tích phức tạp hơn, chúng ta cần phải tải về máy tính một số *package* khác. Package là một phần mềm nhỏ được các nhà thống kê phát triển để giải quyết một vấn đề cụ thể, và có thể chạy trong hệ thống R. Chẳng hạn như để phân tích hồi qui tuyến tính, R có function **lm** để sử dụng cho mục đích này, nhưng để làm các phân tích sâu hơn và phức tạp hơn, chúng ta cần đến các package như **lme4**. Các package này cần phải được tải về máy tính và cài đặt.

Địa chỉ để tải các package vẫn là: <http://cran.r-project.org>, rồi bấm vào phần “Packages” xuất hiện bên trái của mục lục trang web. Một số package cần tải về máy tính để sử dụng cho các ví dụ trong sách này là:

TÊN PACKAGE	CHỨC NĂNG
lattice	Dùng để vẽ đồ thị và làm cho đồ thị đẹp hơn
Hmisc	Một số phương pháp mô hình dữ liệu của F. Harrell
rms	Package kèm theo cuốn sách về xây dựng mô hình tiên lượng của F. Harrell
Epi	Dùng cho các phân tích dịch tễ học
epitools	Một package khác chuyên cho các phân tích dịch tễ học
foreign	Dùng để nhập dữ liệu từ các phần mềm khác như SPSS, Stata, SAS, v.v...
Rmeta, metafor	Dùng cho phân tích tổng hợp (meta-analysis)
survival	Chuyên dùng cho phân tích theo mô hình Cox (Cox's proportional hazard model)
Zelig	Package dùng cho các phân tích thống kê trong lĩnh vực xã hội học
genetics	Package dùng cho phân tích số liệu di truyền học
BMA	Bayesian Model Average
ggplot2	Package dùng cho biểu đồ
psych	Package đa năng nhưng có nhiều chức năng cho phân tích tâm lí học.

1.4 Khởi động và ngưng chạy R

Sau khi hoàn tất việc cài đặt, một *icon* sẽ xuất hiện trên *desktop* của máy tính. Đến đây thì chúng ta đã sẵn sàng sử dụng R. Có thể nhấp chuột vào icon này và chúng ta sẽ có một cửa sổ như sau:



R thường được sử dụng dưới dạng “*command line*”, có nghĩa là chúng ta phải trực tiếp gõ lệnh vào cái *prompt* màu đỏ trên. Các lệnh phải tuân thủ nghiêm ngặt theo “văn phạm” và ngôn ngữ của R. Có thể nói toàn bộ bài viết này là nhằm hướng dẫn bạn đọc hiểu và viết theo ngôn ngữ của R. Một trong những văn phạm này là R phân biệt giữa `Library` và `library`. Nói cách khác, R phân biệt lệnh viết bằng chữ hoa hay chữ thường. Một văn phạm khác nữa là khi có hai chữ rời nhau, R thường dùng dấu chấm để thay vào khoảng trống, chẳng hạn như `data.frame`, `t.test`, `read.table`, v.v... Điều này rất quan trọng, nếu không để ý sẽ làm mất thì giờ của người sử dụng.

Nếu lệnh gõ ra đúng “văn phạm” thì R sẽ cho chúng ta một cái *prompt* khác hay cho ra kết quả nào đó (tùy theo lệnh); nếu lệnh không đúng văn phạm thì R sẽ cho ra một thông báo ngắn là không đúng hay không hiểu. Ví dụ, nếu chúng ta gõ:

```
> x <- rnorm(20)
```

thì R sẽ hiểu và làm theo lệnh đó, rồi cho chúng ta một *prompt* khác:

```
>
```

Nhưng nếu chúng ta gõ:

```
> R is great
```

R sẽ không “đồng ý” với lệnh này, vì ngôn ngữ này không có trong thư viện của R, một thông báo sau đây sẽ xuất hiện:

```
Error: syntax error
```

```
>
```

Khi muốn rời khỏi R, chúng ta có thể đơn giản nhấn nút chéo (x) bên góc trái của cửa sổ, hay gõ lệnh `q()`.

1.5 “Văn phạm” ngôn ngữ R

“Văn phạm” chung của R là một lệnh (*command*) hay *function* (thỉnh thoảng để cập đến là “hàm”). Mà đã là hàm thì phải có thông số; cho nên theo sau hàm là những thông số mà chúng ta phải cung cấp. Chẳng hạn như:

```
> reg <- lm(y ~ x)
```

thì `reg` là một object, còn `lm` là một hàm, và $y \sim x$ là thông số của hàm. Hay:

```
> setwd("c:/works/stats")
```

thì `setwd` là một hàm, còn “`c:/works/stats`” là thông số của hàm.

Để biết một hàm cần có những thông số nào, chúng ta dùng lệnh `args(x)`, (`args` viết tắt chữ arguments) mà trong đó `x` là một hàm chúng ta cần biết:

```
> args(lm)
```

```
function (formula, data, subset, weights, na.action,
method = "qr", model = TRUE, x = FALSE, y = FALSE, qr =
TRUE, singular.ok = TRUE, contrasts = NULL, offset, ...)
NULL
```

R là một ngôn ngữ “đối tượng” (object oriented language). Điều này có nghĩa là các dữ liệu trong R được chứa trong object. Định hướng này cũng có vài ảnh hưởng đến cách viết của R. Chẳng hạn như thay vì viết $x = 5$ như thông thường chúng ta vẫn viết, thì R yêu cầu viết là $x == 5$.

Đối với R, $x = 5$ tương đương với $x <- 5$. Cách viết sau (dùng kí hiệu $<-$) được khuyến khích hơn là cách viết trước ($=$). Chẳng hạn như:

```
> x <- rnorm(10)
```

có nghĩa là mô phỏng 10 số liệu và chứa trong object `x`. Chúng ta cũng có thể viết `x = rnorm(10)`.

Một số kí hiệu hay dùng trong R là:

<code>x == 5</code>	<code>x</code> bằng 5
<code>x != 5</code>	<code>x</code> không bằng 5
<code>y < x</code>	<code>y</code> nhỏ hơn <code>x</code>
<code>x > y</code>	<code>x</code> lớn hơn <code>y</code>
<code>z <= 7</code>	<code>z</code> nhỏ hơn hoặc bằng 7
<code>p >= 1</code>	<code>p</code> lớn hơn hoặc bằng 1
<code>is.na(x)</code>	Có phải <code>x</code> là biến số trống (missing value)
<code>A & B</code>	<code>A</code> và <code>B</code> (AND)
<code>A B</code>	<code>A</code> hoặc <code>B</code> (OR)
<code>!</code>	Không là (NOT)

Với R, tất cả các câu chữ hay lệnh sau kí hiệu # đều không có hiệu ứng, vì # là kí hiệu dành cho người sử dụng thêm vào các ghi chú, ví dụ:

```
> # lệnh sau đây sẽ mô phỏng 10 giá trị normal
> x <- rnorm(10)
```

1.6 Cách đặt tên trong R

Đặt tên một đối tượng (object) hay một biến số (variable) trong R khá linh hoạt, vì R không có nhiều giới hạn như các phần mềm khác. Tên một object phải được viết liền nhau (tức không được cách rời bằng một khoảng trống). Chẳng hạn như R chấp nhận `myobject` nhưng không chấp nhận `my object`.

```
> myobject <- rnorm(10)
> my object <- rnorm(10)
Error: syntax error in "my object"
```

Nhưng đôi khi tên `myobject` khó đọc, cho nên chúng ta nên tách rời bằng "." như `my.object`.

```
> my.object <- rnorm(10)
```

Một điều quan trọng cần lưu ý là R phân biệt mẫu tự viết hoa và viết thường. Cho nên `My.object` khác với `my.object`. Ví dụ:

```
> My.object.u <- 15
> my.object.L <- 5
> My.object.u + my.object.L
[1] 20
```

Một vài điều cần lưu ý khi đặt tên trong R là:

- Không nên đặt tên một biến số hay variable bằng kí hiệu "_" (underscore) như `my_object` hay `my-object`.
- Không nên đặt tên một object giống như một biến số trong một dữ liệu. Ví dụ, nếu chúng ta có một `data.frame` (dữ liệu hay dataset) với biến số `age` trong đó, thì không nên có một object trùng tên `age`, tức là không nên viết: `age <- age`. Tuy nhiên, nếu `data.frame` tên là `data` thì chúng ta có thể đề cập đến biến số `age` với một kí tự \$ như sau: `data$age`. (Tức là biến số `age` trong `data.frame data`), và trong trường hợp đó, `age <- data$age` có thể chấp nhận được.


1.7 Hỗ trợ trong R

Ngoài lệnh `args()` R còn cung cấp lệnh `help()` để người sử dụng có thể hiểu “văn phạm” của từng hàm. Chẳng hạn như muốn biết hàm `lm` có những thông số (arguments) nào, chúng ta chỉ đơn giản lệnh:

```
> help(lm)
hay
> ?lm
```

Một cửa sổ sẽ hiện ra bên phải của màn hình chỉ rõ cách sử dụng ra sao và thậm chí có cả ví dụ. Bạn đọc có thể đơn giản copy và dán ví dụ vào R để xem cách vận hành.

Trước khi sử dụng R, ngoài sách này, nếu cần, bạn đọc có thể đọc qua phần chỉ dẫn có sẵn trong R bằng cách chọn mục `help` và sau đó chọn `Html help` như hình dưới đây để biết thêm chi tiết. Bạn đọc cũng có thể copy và dán các lệnh trong mục này vào R để xem cho biết cách vận hành của R.



Thay vì chọn mục trên, bạn đọc cũng có thể đơn giản lệnh:

```
> help.start()
```

và một cửa sổ sẽ xuất hiện chỉ dẫn toàn bộ hệ thống R.

Hàm `apropos` cũng rất có ích vì nó cung cấp cho chúng ta tất cả các hàm trong R bắt đầu bằng kí tự mà chúng ta muốn tìm. Chẳng hạn như chúng ta muốn biết hàm nào trong R có kí tự "lm" thì chỉ đơn giản lệnh:

```
> apropos("lm").
```

Và R sẽ báo cáo các hàm với kí tự lm như sau có sẵn trong R:

```
[1] ".__C__anova.glm"      ".__C__anova.glm.null" ".__C__glm"
[4] ".__C__glm.null"      ".__C__lm"              ".__C__mlm"
[7] "anova.glm"           "anova.glm.list"        "anova.lm"
[10] "anova.lm.list"       "anova.mlm"             "anova.list.lm"
[13] "contr.helmert"        "glm"                   "glm.control"
[16] "glm.fit"             "glm.fit.null"          "hatvalues.lm"
[19] "KalmanForecast"      "KalmanLike"            "KalmanRun"
[22] "KalmanSmooth"        "lm"                    "lm.fit"
[25] "lm.fit.null"         "lm.influence"          "lm.wfit"
[28] "lm.wfit.null"        "model.frame.glm"       "model.frame.lm"
[31] "model.matrix.lm"     "nlm"                   "nlminb"
[34] "plot.lm"             "plot.mlm"              "predict.glm"
[37] "predict.lm"          "predict.mlm"           "print.glm"
[40] "print.lm"            "residuals.glm"         "residuals.lm"
[43] "rstandard.glm"       "rstandard.lm"          "rstudent.glm"
[46] "rstudent.lm"         "summary.glm"           "summary.lm"
[49] "summary.mlm"         "kappa.lm"
```

1.8 Môi trường vận hành

Dữ liệu phải được chứa trong một khu vực (directory) của máy tính. Trước khi sử dụng R, có lẽ cách hay nhất là tạo ra một directory để chứa dữ liệu, chẳng hạn như `c:\works\stats`. Để R biết dữ liệu nằm ở đâu, chúng ta sử dụng lệnh `setwd` (set working directory) như sau:

```
> setwd("c:/works/stats")
```

Lệnh trên báo cho R biết là dữ liệu sẽ chứa trong directory có tên là c:\works\stats. Chú ý rằng, R dùng forward slash “/” chứ không phải backward slash “\” như trong hệ thống Windows.

Chú ý rằng R có khả năng đọc dữ liệu trực tiếp từ mạng (từ các website). Do đó, chúng ta cũng có thể dùng lệnh setwd để báo cho R biết rằng chúng ta làm việc trực tiếp trên mạng như trong lệnh sau đây:

```
> setwd("http://www.r.ykhoanet.com/")
```

Để biết hiện nay, R đang “làm việc” ở directory nào, chúng ta chỉ cần lệnh:

```
> getwd()
```

```
[1] "C:/Program Files/R/R-2.2.1"
```

Cái prompt mặc định của R là “>”. Nhưng nếu chúng ta muốn có một prompt khác theo cá tính cá nhân, chúng ta có thể thay thế:

```
> options(prompt="R>_")
```

```
R>
```

Hay:

```
> options(prompt="Tuan>_")
```

```
Tuan>
```

Màn ảnh R mặc định là 80 kí tự (characters), nhưng nếu chúng ta muốn màn ảnh rộng hơn, thì chỉ cần ra lệnh:

```
> options(width=100)
```

Hay muốn R trình bày các số liệu ở dạng 3 số thập phân:

```
> options(scipen=3)
```

Các lựa chọn và thay đổi này có thể dùng lệnh options(). Để biết các thông số hiện tại của R là gì, chúng ta chỉ cần lệnh:

```
> options()
```

Tìm hiểu ngày tháng:

```
> Sys.Date()
```

```
[1] "2006-03-31"
```

Nếu bạn đọc cần thêm thông tin, một số tài liệu trên mạng (viết bằng tiếng Anh) cũng rất có ích. Các tài liệu này có thể tải xuống máy miễn phí:

R for beginners (của Emmanuel Paradis):

http://cran.r-project.org/doc/contrib/rdebuts_en.pdf

Using R for data analysis and graphics (của John Maindonald):

<http://cran.r-project.org/doc/contrib/usingR.pdf>

Ngoài ra, tác giả cũng có một tài liệu bằng tiếng Việt (dài 118 trang) tóm lược các lệnh hay sử dụng trong R tại website:

http://cran.r-project.org/doc/contrib/Intro_to_R_Vietnamese.pdf

02

Nhập dữ liệu

Muốn làm phân tích dữ liệu bằng R, chúng ta phải có sẵn dữ liệu ở dạng mà R có thể hiểu được để xử lí. Dữ liệu mà R hiểu được phải là dữ liệu trong một `data.frame`. Có nhiều cách để nhập số liệu vào một `data.frame` trong R, từ nhập trực tiếp đến nhập từ các nguồn khác nhau. Sau đây là một số cách thông dụng nhất:

- Nhập dữ liệu trực tiếp
- Nhập dữ liệu trong frame
- Đọc dữ liệu từ các phần mềm khác như Excel

2.1 Nhập số liệu trực tiếp: `c()`

Ví dụ 1: chúng ta có số liệu về độ tuổi và insulin cho 10 bệnh nhân như sau, và muốn nhập vào R.

50	16.5
62	10.8
60	32.3
40	19.3
48	14.2
47	11.3
57	15.5
70	15.8
48	16.2
67	11.2

Chúng ta có thể sử dụng function có tên `c` như sau:

```
> age = c(50, 62, 60, 40, 48, 47, 57, 70, 48, 67)
> insulin = c(16.5, 10.8, 32.3, 19.3, 14.2, 11.3, 15.5,
              15.8, 16.2, 11.2)
```

Lệnh thứ nhất cho R biết rằng chúng ta muốn tạo ra một cột dữ liệu (sẽ gọi là *biến số*, tức *variable*) có tên là `age`, và lệnh thứ hai là tạo ra một cột khác có tên là `insulin`. Tất nhiên, chúng ta có thể lấy một tên khác mà mình thích.

Chúng ta dùng function `c` (viết tắt của chữ *concatenation* - có nghĩa là “móc nối vào nhau”) để nhập dữ liệu. Chú ý rằng mỗi số liệu cho mỗi bệnh nhân được cách nhau bằng một dấu phẩy.

Kí hiệu `insulin <-` (cũng có thể viết là `insulin =`) có nghĩa là các số liệu theo sau sẽ nằm trong biến số `insulin`. Chúng ta sẽ gặp kí hiệu này rất nhiều lần trong khi sử dụng R.

R là một ngôn ngữ cấu trúc theo dạng đối tượng (thuật ngữ chuyên môn là “object-oriented language”), vì mỗi cột số liệu hay mỗi một `data.frame` là một đối tượng (object) đối với R. Vì thế, `age` và `insulin` là hai đối tượng riêng lẻ. Bây giờ, chúng ta cần phải nhập hai đối tượng này thành một `data.frame` để R có thể xử lí sau này. Để làm việc này chúng ta cần đến function `data.frame`:

```
> tuan = data.frame(age, insulin)
```

Trong lệnh này, chúng ta muốn cho R biết rằng nhập hai cột (hay hai đối tượng) `age` và `insulin` vào một đối tượng có tên là `tuan`.

Đến đây thì chúng ta đã có một đối tượng hoàn chỉnh để tiến hành phân tích thống kê. Để kiểm tra xem trong `tuan` có gì, chúng ta chỉ cần đơn giản gõ:

```
> tuan
```

Và R sẽ báo cáo:

	age	insulin
1	50	16.5
2	62	10.8
3	60	32.3
4	40	19.3
5	48	14.2
6	47	11.3
7	57	15.5
8	70	15.8
9	48	16.2
10	67	11.2

Nếu chúng ta muốn lưu lại các số liệu này trong một file theo dạng R, chúng ta cần dùng lệnh save. Giả dụ như chúng ta muốn lưu số liệu trong directory có tên là “c:\works\stats”, chúng ta cần gõ như sau:

```
> setwd("c:/works/stats")  
> save(tuan, file="tuan.rda")
```

Lệnh đầu tiên (setwd – chữ wd có nghĩa là working directory) cho R biết rằng chúng ta muốn lưu các số liệu trong directory có tên là “c:\works\stats”. Lưu ý rằng thông thường hệ thống Windows dùng dấu backward slash “\”, nhưng trong R chúng ta dùng dấu forward slash “/”.


Lệnh thứ hai (save) cho R biết rằng các số liệu trong đối tượng tuan sẽ lưu trong file có tên là “tuan.rda”. Sau khi gõ xong hai lệnh trên, một file có tên tuan.rda sẽ có mặt trong directory đó.

2.2 Nhập số liệu trực tiếp: edit(data.frame())

Ví dụ 1 (tiếp tục): chúng ta có thể nhập số liệu về độ tuổi và insulin cho 10 bệnh nhân bằng một function rất có ích, đó là: edit(data.frame()). Với function này, R sẽ cung cấp cho chúng ta một cửa sổ mới với một dãy cột và dòng giống như Excel, và chúng ta có thể nhập số liệu trong bảng đó. Ví dụ:

```
> ins = edit(data.frame())
```

Chúng ta sẽ có một window như sau:



Ở đây, R không biết chúng ta có biến số nào, cho nên R liệt kê các biến số `var1`, `var2`, v.v... Nhấp chuột vào cột `var1` và thay đổi bằng cách gõ vào đó `age`. Nhấp chuột vào cột `var2` và thay đổi bằng cách gõ vào đó `insulin`. Sau đó gõ số liệu cho từng cột. Sau khi xong, bấm nút chéo X ở góc phải của spreadsheet, chúng ta sẽ có một `data.frame` tên `ins` với hai biến số `age` và `insulin`.

2.3 Nhập số liệu từ một *text file*: `read.table`

Ví dụ 2: Chúng ta thu thập số liệu về độ tuổi và cholesterol từ một nghiên cứu ở 50 bệnh nhân mắc bệnh cao huyết áp. Các số liệu này được lưu trong một text file có tên là `chol.txt` tại directory `c:\works\stats`. Số liệu này như sau: cột 1 là mã số của bệnh nhân, cột 2 là giới tính, cột 3 là body mass index (`bmi`), cột 4 là HDL cholesterol (viết tắt là `hdl`), kế đến là LDL cholesterol, total cholesterol (`tc`) và triglycerides (`tg`).

id	sex	age	bmi	hdl	ldl	tc	tg
1	Nam	57	17	5.000	2.0	4.0	1.1
2	Nu	64	18	4.380	3.0	3.5	2.1
3	Nu	60	18	3.360	3.0	4.7	0.8
4	Nam	65	18	5.920	4.0	7.7	1.1
5	Nam	47	18	6.250	2.1	5.0	2.1
6	Nu	65	18	4.150	3.0	4.2	1.5
7	Nam	76	19	0.737	3.0	5.9	2.6
8	Nam	61	19	7.170	3.0	6.1	1.5
9	Nam	59	19	6.942	3.0	5.9	5.4
10	Nu	57	19	5.000	2.0	4.0	1.9
...							
44	Nam	45	24	5.450	2.8	6.0	2.6
45	Nam	63	24	5.000	3.0	4.0	1.8
46	Nu	52	24	3.360	2.0	3.7	1.2
47	Nam	64	24	7.170	1.0	6.1	1.9
48	Nam	45	24	7.880	4.0	6.7	3.3
49	Nu	64	25	7.360	4.6	8.1	4.0
50	Nu	62	25	7.750	4.0	6.2	2.5

Chúng ta muốn nhập các dữ liệu này vào R để tiện việc phân tích sau này. Chúng ta sẽ sử dụng lệnh `read.table` như sau:

```
> setwd("c:/works/stats")
> chol = read.table("chol.txt", header=TRUE)
```

Lệnh thứ nhất chúng ta muốn đảm bảo R truy nhập đúng directory mà số liệu đang được lưu giữ. Lệnh thứ hai yêu cầu R nhập số liệu từ file có tên là "chol.txt" (trong directory c:\works\stats) và cho vào đối tượng chol. Trong lệnh này, header=TRUE có nghĩa là yêu cầu R đọc dòng đầu tiên trong file đó như là tên của từng cột dữ kiện.

Chúng ta có thể kiểm tra xem R đã đọc hết các dữ liệu hay chưa bằng cách ra lệnh:

```
> chol
hay
> names(chol)
```

R sẽ cho biết có các cột như sau trong dữ liệu (name là lệnh hỏi trong dữ liệu có những cột nào và tên gì):

```
[1] "id" "sex" "age" "bmi" "hdl" "ldl" "tc" "tg"
```

Bây giờ chúng ta có thể lưu dữ liệu dưới dạng R để xử lí sau này bằng cách ra lệnh:

```
> save(chol, file="chol.rda")
```

2.4 Nhập số liệu từ Excel: read.csv

Để nhập số liệu từ phần mềm Excel, chúng ta cần tiến hành 2 bước:

- Bước 1: Dùng lệnh "Save as" trong Excel và lưu số liệu dưới dạng "csv";
- Bước 2: Dùng R (lệnh read.csv) để nhập dữ liệu dạng csv.


Ví dụ 3: Một dữ liệu gồm các cột sau đây đang được lưu trong Excel, và chúng ta muốn chuyển vào R để phân tích. Dữ liệu này có tên là excel.xls.

ID	Age	Sex	Ethnicity	IGFI	IGFBP3	ALS	PINP	ICTP	P3NP
1	18	1	1	148.27	5.14	316.00	61.84	5.81	4.21
2	28	1	1	114.50	5.23	296.42	98.64	4.96	5.33
3	20	1	1	109.82	4.33	269.82	93.26	7.74	4.56
4	21	1	1	112.13	4.38	247.96	101.59	6.66	4.61
5	28	1	1	102.86	4.04	240.04	58.77	4.62	4.95
6	23	1	4	129.59	4.16	266.95	48.93	5.32	3.82
7	20	1	1	142.50	3.85	300.86	135.62	8.78	6.75
8	20	1	1	118.69	3.44	277.46	79.51	7.19	5.11
9	20	1	1	197.69	4.12	335.23	57.25	6.21	4.44
10	20	1	1	163.69	3.96	306.83	74.03	4.95	4.84

11	22	1	1	144.81	3.63	295.46	68.26	4.54	3.70
12	27	0	2	141.60	3.48	231.20	56.78	4.47	4.07
13	26	1	1	161.80	4.10	244.80	75.75	6.27	5.26
14	33	1	1	89.20	2.82	177.20	48.57	3.58	3.68
15	34	1	3	161.80	3.80	243.60	50.68	3.52	3.35
16	32	1	1	148.50	3.72	234.80	83.98	4.85	3.80
17	28	1	1	157.70	3.98	224.80	60.42	4.89	4.09
18	18	0	2	222.90	3.98	281.40	74.17	6.43	5.84
19	26	0	2	186.70	4.64	340.80	38.05	5.12	5.77
20	27	1	2	167.56	3.56	321.12	30.18	4.78	6.12

Việc đầu tiên chúng ta cần làm, như đã nói ở trên, là vào Excel để lưu dữ liệu dưới dạng csv:

- Vào Excel, chọn File → Save as
- Chọn Save as type "CSV (Comma delimited)"



Sau khi xong, chúng ta sẽ có một file với tên “excel.csv” trong directory “c:\works\stats”.

Việc thứ hai là vào R và ra những lệnh sau đây:

```
> setwd("c:/works/stats")
> gh = read.csv ("excel.csv", header=TRUE)]
```

Lệnh thứ hai read.csv yêu cầu R đọc số liệu từ “excel.csv”, dùng dòng thứ nhất là tên cột, và lưu các số liệu này trong một object có tên là gh.

Bây giờ chúng ta có thể lưu gh dưới dạng R để xử lí sau này bằng lệnh sau đây:

```
> save(gh, file="gh.rda")
```

2.5 Nhập số liệu từ một SPSS: read.spss

Phần mềm thống kê SPSS lưu dữ liệu dưới dạng "sav". Chẳng hạn như nếu chúng ta đã có một dữ liệu có tên là testo.sav trong directory c:\works\stats, và muốn chuyển dữ liệu này sang dạng R có thể hiểu được, chúng ta cần sử dụng lệnh read.spss trong package có tên là foreign. Các lệnh sau đây sẽ hoàn tất dễ dàng việc này:

Việc đầu tiên chúng ta cho truy nhập foreign bằng lệnh library:

```
> library(foreign)
```

Việc thứ hai là lệnh read.spss:

```
> setwd("c:/works/stats")
```

```
> testo = read.spss("testo.sav", to.data.frame=TRUE)
```

Lệnh thứ hai read.spss yêu cầu R đọc số liệu từ "testo.sav", và cho vào một data.frame có tên là testo.

Bây giờ chúng ta có thể lưu testo dưới dạng R để xử lí sau này bằng lệnh sau đây:

```
> save(testo, file="testo.rda")
```

2.6 Thông tin cơ bản về dữ liệu

Giả dụ như chúng ta đã nhập số liệu vào một data.frame có tên là chol như trong ví dụ 1. Để tìm hiểu xem trong dữ liệu này có gì, chúng ta có thể nhập vào R như sau:

- Dẫn cho R biết chúng ta muốn xử lí chol bằng cách dùng lệnh attach(arg) với arg là tên của dữ liệu.

```
> attach(chol)
```

- Chúng ta có thể kiểm tra xem chol có phải là một data.frame không bằng lệnh is.data.frame(arg) với arg là tên của dữ liệu. Ví dụ:

```
> is.data.frame(chol)
```

```
[1] TRUE
```

R cho biết chol quả là một data.frame.

- Có bao nhiêu cột (hay *variable* = *biến số*) và dòng số liệu (observations) trong dữ liệu này? Chúng ta dùng lệnh `dim(arg)` với `arg` là tên của dữ liệu. (`dim` viết tắt chữ *dimension*). Ví dụ (kết quả của R trình bày ngay sau khi chúng ta gõ lệnh):

```
> dim(chol)
```

```
[1] 50  8
```

- Như vậy, chúng ta có 50 dòng và 8 cột (hay biến số). Vậy những biến số này tên gì? Chúng ta dùng lệnh `names(arg)` với `arg` là tên của dữ liệu. Ví dụ:

```
> names(chol)
```

```
[1] "id"  "sex" "age" "bmi" "hdl" "ldl" "tc"  "tg"
```

- Trong biến số `sex`, chúng ta có bao nhiêu nam và nữ? Để trả lời câu hỏi này, chúng ta có thể dùng lệnh `table(arg)` với `arg` là tên của biến số. Ví dụ:

```
> table(sex)
```


```
sex
```

```
nam Nam  Nu
```

```
1   21  28
```

Kết quả cho thấy dữ liệu này có 1 “nam”, 21 “Nam” và 28 “Nu”. Chú ý R phân biệt giữa “nam” và “Nam” nên xem đây là hai nhóm khác nhau!

Trên đây là vài cách nhập dữ liệu vào R. Trong thực tế, R có thể đọc dữ liệu từ rất nhiều phần mềm thông dụng, kể cả các phần mềm thống kê như SPSS (mà chúng ta đã xem qua), SAS, STATA, v.v... Nhưng để đọc dữ liệu từ các phần mềm này, bạn đọc cần phải tải package `foreign` về máy và cài đặt vào R. Package `foreign` có thể tải từ website chính thức của R.



03

Biên tập dữ liệu

Biên tập số liệu ở đây không có nghĩa là thay đổi số liệu gốc (vì đó là một tội lớn, một sự gian dối trong khoa học không thể chấp nhận được), mà chỉ có nghĩa tổ chức số liệu sao cho R có thể phân tích một cách hữu hiệu. Nhiều khi trong phân tích thống kê, chúng ta cần phải tập trung số liệu thành một nhóm, hay tách rời thành từng nhóm, hay thay thế từ kí tự (characters) sang số (numeric) cho tiện việc tính toán. Chương này sẽ bàn qua một số lệnh căn bản cho việc biên tập số liệu.

Chúng ta sẽ quay lại với dữ liệu `chol` trong ví dụ 1. Để tiện việc theo dõi và hiểu “câu chuyện”, xin nhắc lại rằng chúng ta đã nhập số liệu vào trong một dữ liệu R có tên là `chol` từ một text file có tên là `chol.txt`:

```
> setwd("c:/works/stats")
> chol = read.table("chol.txt", header=TRUE)
> attach(chol)
```

3.1 Kiểm tra số liệu trống không (missing value)

Trong nghiên cứu, vì nhiều lí do số liệu không thể thu thập được cho tất cả đối tượng, hay không thể đo lường tất cả biến số cho một đối tượng. Trong trường hợp đó, số liệu trống được xem là “missing value” (tạm dịch là số liệu trống không). R xem các số liệu trống không là `NA`. Có một số kiểm định thống kê đòi hỏi các số liệu trống không phải được loại ra (vì không thể tính toán được) trước khi phân tích. R có một lệnh rất có ích cho việc này: `na.omit`, và cách sử dụng như sau:

```
> chol.new = na.omit(chol)
```

Trong lệnh trên, chúng ta yêu cầu R loại bỏ các số liệu trống không trong `data.frame chol` và đưa các số liệu không trống vào `data.frame` mới tên là `chol.new`. Chú ý lệnh trên chỉ là ví dụ, vì trong dữ liệu `chol` không có số liệu trống không.

3.2 Tách rời dữ liệu: `subset`

Nếu chúng ta vì một lí do nào đó, chỉ muốn phân tích riêng cho nam giới, chúng ta có thể tách `chol` ra thành hai `data.frame`, tạm gọi là `nam` và `nu`. Để làm chuyện này, chúng ta dùng lệnh `subset(data, cond)`, trong đó `data` là `data.frame` mà chúng ta muốn tách rời, và `cond` là điều kiện. Ví dụ:

```
> nam = subset(chol, sex=="Nam")
> nu = subset(chol, sex=="Nu")
```

Sau khi ra hai lệnh này, chúng ta đã có 2 dữ liệu (hai `data.frame`) mới tên là `nam` và `nu`. Chú ý điều kiện `sex == "Nam"` và `sex == "Nu"` chúng ta dùng `==` thay vì `=` để chỉ điều kiện chính xác.

Tất nhiên, chúng ta cũng có thể tách dữ liệu thành nhiều `data.frame` khác nhau với những điều kiện dựa vào các biến số khác. Chẳng hạn như lệnh sau đây tạo ra một `data.frame` mới tên là `old` với những bệnh nhân trên 60 tuổi:

```
> old = subset(chol, age>=60)
> dim(old)
[1] 25 8
```

Hay một `data.frame` mới với những bệnh nhân trên 60 tuổi và nam giới:

```
> n60 <- subset(chol, age>=60 & sex=="Nam")
> dim(n60)
[1] 9 8
```

3.3 Chiết số liệu từ một `data.frame`

Trong `chol` có 8 biến số. Chúng ta có thể chiết dữ liệu `chol` và chỉ giữ lại những biến số cần thiết như mã số (`id`), độ tuổi (`age`) và total cholesterol (`tc`). Để ý từ lệnh `names(chol)` rằng biến số `id` là cột số 1, `age` là cột số 3, và biến số `tc` là cột số 7. Chúng ta có thể dùng lệnh sau đây:

```
> data2 = chol[, c(1,3,7)]
```

Ở đây, chúng ta lệnh cho R biết rằng chúng ta muốn chọn cột số 1, 3 và 7, và đưa tất cả số liệu của hai cột này vào `data.frame` mới có tên là `data2`. Chú ý chúng ta sử dụng ngoặc kép `[]` chứ không phải ngoặc kép vòng `()`, vì `chol` không phải là một function. Dấu phẩy phía trước `c`, có nghĩa là chúng ta chọn tất cả các dòng số liệu trong `data.frame chol`.

Nhưng nếu chúng ta chỉ muốn chọn 10 dòng số liệu đầu tiên, thì lệnh sẽ là:

```
> data3 = chol[1:10, c(1,3,7)]
```

```
> print(data3)
```

	id	sex	tc
1	1	Nam	4.0
2	2	Nu	3.5
3	3	Nu	4.7
4	4	Nam	7.7
5	5	Nam	5.0
6	6	Nu	4.2
7	7	Nam	5.9
8	8	Nam	6.1
9	9	Nam	5.9
10	10	Nu	4.0

Chú ý lệnh `print(arg)` đơn giản liệt kê tất cả số liệu trong `data.frame` `arg`. Thật ra, chúng ta chỉ cần đơn giản gõ `data3`, kết quả cũng giống y như `print(data3)`.

3.4 Nhập hai `data.frame` thành một: `merge`

Giả dụ như chúng ta có dữ liệu chứa trong hai `data.frame`. Dữ liệu thứ nhất tên là `d1` gồm 3 cột: `id`, `sex`, `tc` như sau:

id	sex	tc
1	Nam	4.0
2	Nu	3.5
3	Nu	4.7
4	Nam	7.7
5	Nam	5.0
6	Nu	4.2
7	Nam	5.9
8	Nam	6.1
9	Nam	5.9
10	Nu	4.0

Dữ liệu thứ hai tên là `d2` gồm 3 cột: `id`, `sex`, `tg` như sau:

id	sex	tg
1	Nam	1.1
2	Nu	2.1
3	Nu	0.8
4	Nam	1.1
5	Nam	2.1

6	Nu	1.5
7	Nam	2.6
8	Nam	1.5
9	Nam	5.4
10	Nu	1.9
11	Nu	1.7

Hai dữ liệu này có chung hai biến số `id` và `sex`. Nhưng dữ liệu `d1` có 10 dòng, còn dữ liệu `d2` có 11 dòng. Chúng ta có thể nhập hai dữ liệu thành một `data.frame` bằng cách dùng lệnh `merge` như sau:

```
> d = merge(d1, d2, by="id", all=TRUE)
```

```
> d
```

	id	sex.x	tc	sex.y	tg
1	1	Nam	4.0	Nam	1.1
2	2	Nu	3.5	Nu	2.1
3	3	Nu	4.7	Nu	0.8
4	4	Nam	7.7	Nam	1.1
5	5	Nam	5.0	Nam	2.1
6	6	Nu	4.2	Nu	1.5
7	7	Nam	5.9	Nam	2.6
8	8	Nam	6.1	Nam	1.5
9	9	Nam	5.9	Nam	5.4
10	10	Nu	4.0	Nu	1.9
11	11	<NA>	NA	Nu	1.7

Trong lệnh `merge`, chúng ta yêu cầu R nhập 2 dữ liệu `d1` và `d2` thành một và đưa vào `data.frame` mới tên là `d`, và dùng biến số `id` làm chuẩn. Chúng ta để ý thấy bệnh nhân số 11 không có số liệu cho `tc`, cho nên R cho là `NA` (một dạng “not available”).

3.5 Mã hóa số liệu (data coding)

Trong việc xử lý số liệu dịch tễ học, nhiều khi chúng ta cần phải biến đổi số liệu từ biến liên tục sang biến mang tính cách phân loại. Chẳng hạn như trong chẩn đoán loãng xương, những phụ nữ có chỉ số `T` của mật độ chất khoáng trong xương (bone mineral density hay `BMD`) bằng hay thấp hơn `-2.5` được xem là “loãng xương”, những ai có `BMD` giữa `-2.5` và `-1.0` là “xốp xương” (osteopenia), và trên `-1.0` là “bình thường”. Ví dụ, chúng ta có số liệu `BMD` từ 10 bệnh nhân như sau:

```
-0.92, 0.21, 0.17, -3.21, -1.80, -2.60, -2.00, 1.71,
2.12, -2.11
```

Để nhập các số liệu này vào R chúng ta có thể sử dụng *function* `c` như sau:

```
bmd = c(-0.92, 0.21, 0.17, -3.21, -1.80, -2.60,  
        -2.00, 1.71, 2.12, -2.11)
```

Để phân loại 3 nhóm loãng xương, xốp xương, và bình thường, chúng ta có thể dùng mã số 1, 2 và 3. Nói cách khác, chúng ta muốn tạo nên một biến số khác (hãy gọi là `diagnosis`) gồm 3 giá trị trên dựa vào giá trị của `bmd`. Để làm việc này, chúng ta sử dụng lệnh:

```
# tạm thời cho biến số diagnosis bằng bmd  
> diagnosis = bmd  
  
# biến đổi bmd thành diagnosis  
  
> diagnosis[bmd <= -2.5] <- 1  
> diagnosis[bmd > -2.5 & bmd <= 1.0] <- 2  
> diagnosis[bmd > -1.0] <- 3  
  
# tạo thành một data.frame  
> data = data.frame(bmd, diagnosis)  
  
# liệt kê để kiểm tra xem lệnh có hiệu quả không  
> data  
      bmd diagnosis  
1 -0.92          3  
2  0.21          3  
3  0.17          3  
4 -3.21          1  
5 -1.80          2  
6 -2.60          1  
7 -2.00          2  
8  1.71          3  
9  2.12          3  
10 -2.11         2
```

3.5.1 Biến đổi số liệu bằng cách dùng *replace*

Một cách biến đổi số liệu khác là dùng *replace*, nhưng cách này tương đối phức tạp hơn. Tiếp tục ví dụ trên, chúng ta biến đổi từ *bmd* sang *diagnosis* như sau:

```
> diagnosis = bmd
> diagnosis = replace(diagnosis, bmd <= -2.5, 1)
> diagnosis = replace(diagnosis, bmd > -2.5 & bmd <= 1.0, 2)
> diagnosis = replace(diagnosis, bmd > 1.0, 3)
```

3.5.2 Biến đổi thành yếu tố (*factor*)

Trong phân tích thống kê, chúng ta phân biệt một biến số mang tính *yếu tố* (*factor*) và biến số liên tục bình thường. Biến số yếu tố không thể dùng để tính toán như cộng trừ nhân chia, nhưng biến số số học có thể sử dụng để tính toán. Chẳng hạn như trong ví dụ *bmd* và *diagnosis* trên, *diagnosis* là yếu tố vì giá trị trung bình giữa 1 và 2 chẳng có ý nghĩa thực tế gì cả; còn *bmd* là biến số số học.

Nhưng hiện nay, *diagnosis* được xem là một biến số số học. Để biến thành biến số yếu tố, chúng ta cần sử dụng *function* *factor* như sau:

```
> diag = factor(diagnosis)
> diag
[1] 3 3 3 1 2 1 2 3 3 2
Levels: 1 2 3
```

Chú ý R bây giờ thông báo cho chúng ta biết *diag* có 3 bậc: 1, 2 và 3. Nếu chúng ta yêu cầu R tính số trung bình của *diag*, R sẽ không làm theo yêu cầu này, vì đó không phải là một biến số số học:

```
> mean(diag)
[1] NA
Warning message:
argument is not numeric or logical: returning NA in:
mean.default(diag)
```

Dĩ nhiên, chúng ta có thể tính giá trị trung bình của *diagnosis*:

```
> mean(diagnosis)
[1] 2.3
```

Nhưng kết quả 2.3 này không có ý nghĩa gì trong thực tế cả.

3.6 Chia nhóm bằng *cut*

Với một biến liên tục, chúng ta có thể chia thành nhiều nhóm bằng hàm *cut*. Ví dụ, chúng ta có biến *age* như sau:

```
> age = c(17,19,22,43,14,8,12,19,20,51,8,12,27,31,44)
```

Độ tuổi thấp nhất là 8 và cao nhất là 51. Nếu chúng ta muốn chia thành 2 nhóm tuổi:

```
> cut(age, 2)
```

```
[1] (7.96,29.5] (7.96,29.5] (7.96,29.5] (29.5,51]
(7.96,29.5] (7.96,29.5] (7.96,29.5] (7.96,29.5]
```

```
[9] (7.96,29.5] (29.5,51] (7.96,29.5] (7.96,29.5]
(7.96,29.5] (29.5,51] (29.5,51]
```

```
Levels: (7.96,29.5] (29.5,51]
```

cut chia biến *age* thành 2 nhóm: nhóm 1 tuổi từ 7.96 đến 29.5; nhóm 2 từ 29.5 đến 51. Chúng ta có thể đếm số đối tượng trong từng nhóm tuổi bằng hàm *table* như sau:

```
> table(cut(age, 2))
```

```
(7.96,29.5] (29.5,51]
      11         4
```

Trong lệnh sau đây, chúng ta chia biến độ tuổi thành 3 nhóm và đặt tên ba nhóm là “low”, “medium” và “high”:

```
> ageg = cut(age, 3, labels=c("low", "medium", "high"))
```

```
[1] low    low    low    high   low    low    low    low
low    high   low    low    medium medium
```

```
[15] high
```

```
Levels: low medium high
```

```
> ageg = cut(age, 3, labels=c("low", "medium", "high"))
```

```
> table(ageg)
```

```
ageg
    low medium   high
    10      2      3
```

Tất nhiên, chúng ta cũng có thể chia age thành 4 nhóm (quartiles) bằng cách cho những thông số 0, 0.25, 0.50 và 0.75 như sau:

```
cut(age,
     breaks=quantiles(age, c(0, 0.25, 0.50, 0.75, 1)),
     labels=c("q1", "q2", "q3", "q4"),
     include.lowest=TRUE)
```

3.7 Tập hợp số liệu bằng cut2 (Hmisc)

Hàm cut trên chia biến số theo giá trị của biến, chứ không dựa vào số mẫu, cho nên số lượng mẫu trong từng nhóm không bằng nhau. Tuy nhiên, trong phân tích thống kê, có khi chúng ta cần phải phân chia một biến số liên tục thành nhiều nhóm dựa vào phân phối của biến số nhưng số mẫu bằng hay tương đương nhau. Chẳng hạn như đối với biến số bmd chúng ta có thể “cắt” dãy số thành 3 nhóm với số mẫu tương đương nhau bằng cách dùng function cut2 (trong package Hmisc) như sau:

```
# nhập package Hmisc để có thể dùng function cut2

> library(Hmisc)

> bmd = c(-0.92, 0.21, 0.17, -3.21, -1.80, -2.60,
          -2.00, 1.71, 2.12, -2.11)

# chia biến số bmd thành 2 nhóm và để trong đối tượng group

> group = cut2(bmd, g=2)

> table(group)
group
[-3.21, -0.92)  [-0.92, 2.12]
              5              5
```

Như thấy qua ví dụ trên, g=2 có nghĩa là chia thành 2 nhóm (g = group). R tự động chia thành nhóm 1 gồm giá trị bmd từ -3.21 đến -0.92, và nhóm 2 từ -0.92 đến 2.12. Mỗi nhóm gồm có 5 số.

Tất nhiên, chúng ta cũng có thể chia thành 3 nhóm bằng lệnh:

```
> group = cut2(bmd, g=3)
```

Và với lệnh table chúng ta sẽ biết có 3 nhóm, nhóm 1 gồm 4 số, nhóm 2 và 3 mỗi nhóm có 3 số:

```
> table(group)
group
[-3.21, -1.80)  [-1.80, 0.21)  [ 0.21, 2.12]
              4              3              3
```

04

Dùng R cho các phép tính đơn giản và ma trận

Một trong những lợi thế của R là có thể sử dụng như một máy tính cầm tay. Thật ra, hơn thế nữa, R có thể sử dụng cho các phép tính ma trận và lập chương. Chương này chỉ trình bày một số phép tính đơn giản mà học sinh hay sinh viên có thể sử dụng lập tức trong khi đọc những dòng chữ này.

4.1 Tính toán đơn giản

Cộng hai số hay nhiều số với nhau: <code>> 15+2997</code> <code>[1] 3012</code>	Cộng và trừ: <code>> 15+2997-9768</code> <code>[1] -6756</code>
Nhân và chia <code>> -27*12/21</code> <code>[1] -15.42857</code>	Số lũy thừa: $(25 - 5)^3$ <code>> (25 - 5)^3</code> <code>[1] 8000</code>
Căn số bậc hai: $\sqrt{10}$ <code>> sqrt(10)</code> <code>[1] 3.162278</code>	Số pi (π) <code>> pi</code> <code>[1] 3.141593</code> <code>> 2+3*pi</code> <code>[1] 11.42478</code>
Logarit: $\log_e$ <code>> log(10)</code> <code>[1] 2.302585</code>	Logarit: $\log_{10}$ <code>> log10(100)</code> <code>[1] 2</code>
Số mũ: $e^{2.7689}$ <code>> exp(2.7689)</code> <code>[1] 15.94109</code> <code>> log10(2+3*pi)</code> <code>[1] 1.057848</code>	Hàm số lượng giác <code>> cos(pi)</code> <code>[1] -1</code>

Vector <pre>> x <- c(2,3,1,5,4,6,7,6,8) > x [1] 2 3 1 5 4 6 7 6 8 > sum(x) [1] 42 > x*2 [1] 4 6 2 10 8 12 14 12 16</pre>	<pre>> exp(x/10) [1] 1.221403 1.349859 1.105171 1.648721 1.491825 1.822119 2.013753 1.822119 [9] 2.225541 > exp(cos(x/10)) [1] 2.664634 2.599545 2.704736 2.405079 2.511954 2.282647 2.148655 2.282647 [9] 2.007132</pre>
Tính tổng bình phương (sum of squares): $1^2 + 2^2 + 3^2 + 4^2 + 5^2 = ?$ <pre>> x <- c(1,2,3,4,5) > sum(x^2) [1] 55</pre>	Tính tổng bình phương điều chỉnh (adjusted sum of squares): $\sum_{i=1}^n (x_i - \bar{x})^2 = ?$ <pre>> x <- c(1,2,3,4,5) > sum((x-mean(x))^2) [1] 10</pre> Trong công thức trên mean(x) là số trung bình của vector x.
Tính sai số bình phương (mean square): $\sum_{i=1}^n (x_i - \bar{x})^2 / n = ?$ <pre>> x <- c(1,2,3,4,5) > sum((x-mean(x))^2)/length(x) [1] 2</pre> Trong công thức trên, length(x) có nghĩa là tổng số phần tử (elements) trong vector x.	Tính phương sai (variance) và độ lệch chuẩn (standard deviation): Phương sai: $s^2 = \sum_{i=1}^n (x_i - \bar{x})^2 / (n-1) = ?$ <pre>> x <- c(1,2,3,4,5) > var(x) [1] 2.5</pre> Độ lệch chuẩn: $\sqrt{s^2} :$ <pre>> sd(x) [1] 1.581139</pre>

4.2 Số liệu về ngày tháng

Trong phân tích thống kê, các số liệu ngày tháng có khi là một vấn đề nan giải, vì có rất nhiều cách để mô tả các dữ liệu này. Chẳng hạn như 01/02/2003, có khi người ta viết 1/2/2003, 01/02/03, 01FEB2003, 2003-02-01, v.v... Thật ra, có một qui luật chuẩn để viết số liệu ngày tháng là tiêu chuẩn ISO 8601 (nhưng rất ít ai tuân theo!) Theo qui luật này, chúng ta viết:

2003-02-01

Lí do đằng sau cách viết này là chúng ta viết số với đơn vị lớn nhất trước, rồi dần dần đến đơn vị nhỏ nhất. Chẳng hạn như với số “123” thì chúng ta biết ngay rằng “một trăm hai mươi ba”: bắt đầu là hàng trăm, rồi đến hàng chục, v.v... Và đó cũng là cách viết ngày tháng chuẩn của R.

```
> date1 <- as.Date("01/02/06", format="%d/%m/%y")
> date2 <- as.Date("06/03/01", format="%y/%m/%d")
```

Chú ý chúng ta nhập hai số liệu khác nhau về thứ tự ngày tháng năm, nhưng chúng ta cũng cho biết cụ thể cách đọc bằng %d (ngày), %m (tháng), và %y (năm). Chúng ta có thể tính số ngày giữa hai thời điểm:

```
> days <- date2-date1
> days
Time difference of 28 days
```

Chúng ta cũng có thể tạo một dãy số liệu ngày tháng như sau:

```
> seq(as.Date("2005-01-01"), as.Date("2005-12-31"),
by="month")
```

```
[1] "2005-01-01" "2005-02-01" "2005-03-01" "2005-04-01"
"2005-05-01"
```

```
[6] "2005-06-01" "2005-07-01" "2005-08-01" "2005-09-01"
"2005-10-01"
```

```
[11] "2005-11-01" "2005-12-01"
```

```
> seq(as.Date("2005-01-01"), as.Date("2005-12-31"),
by="2 weeks")
```

```
[1] "2005-01-01" "2005-01-15" "2005-01-29" "2005-02-12"
"2005-02-26"
```

```
[6] "2005-03-12" "2005-03-26" "2005-04-09" "2005-04-23"
"2005-05-07"
```

```
[11] "2005-05-21" "2005-06-04" "2005-06-18" "2005-07-02"
"2005-07-16"
```

```
[16] "2005-07-30" "2005-08-13" "2005-08-27" "2005-09-10"
"2005-09-24"
```

```
[21] "2005-10-08" "2005-10-22" "2005-11-05" "2005-11-19"
"2005-12-03"
```

```
[26] "2005-12-17" "2005-12-31"
```


4.3 Tạo dãy số bằng hàm seq, rep và gl

R còn có công dụng tạo ra những dãy số rất tiện cho việc mô phỏng và thiết kế thí nghiệm. Những hàm thông thường cho dãy số là `seq` (sequence), `rep` (repetition) và `gl` (generating levels):

Áp dụng seq

- Tạo ra một vector số từ 1 đến 12:

```
> x <- (1:12)
> x
[1] 1 2 3 4 5 6 7 8 9 10 11 12

> seq(12)
[1] 1 2 3 4 5 6 7 8 9 10 11 12
```

- Tạo ra một vector số từ 12 đến 5:

```
> x <- (12:5)
> x
[1] 12 11 10 9 8 7 6 5

> seq(12,7)
[1] 12 11 10 9 8 7
```

Công thức chung của hàm `seq` là `seq(from, to, by= )` hay `seq(from, to, length.out= )`. Cách sử dụng sẽ được minh hoạ bằng các ví dụ sau đây:

- Tạo ra một vector số từ 4 đến 6 với khoảng cách bằng 0.25:

```
> seq(4, 6, 0.25)
[1] 4.00 4.25 4.50 4.75 5.00 5.25 5.50 5.75 6.00
```

- Tạo ra một vector 10 số, với số nhỏ nhất là 2 và số lớn nhất là 15

```
> seq(length=10, from=2, to=15)
[1] 2.000000 3.444444 4.888889 6.333333 7.777778
9.222222 10.666667 12.111111 13.555556 15.000000
```

Áp dụng rep

Công thức của hàm `rep` là `rep(x, times, ...)`, trong đó, `x` là một biến số và `times` là số lần lặp lại. Ví dụ:

- Tạo ra số 10, 3 lần:

```
> rep(10, 3)
[1] 10 10 10
```

- Tạo ra số 1 đến 4, 3 lần:

```
> rep(c(1:4), 3)
[1] 1 2 3 4 1 2 3 4 1 2 3 4
```

- Tạo ra số 1.2, 2.7, 4.8, 5 lần:

```
> rep(c(1.2, 2.7, 4.8), 5)
[1] 1.2 2.7 4.8 1.2 2.7 4.8 1.2 2.7 4.8 1.2 2.7 4.8
1.2 2.7 4.8
```

Áp dụng gl

gl được áp dụng để tạo ra một biến thứ bậc (categorical variable), tức biến không để tính toán, mà là đếm. Công thức chung của hàm gl là `gl(n, k, length = n*k, labels = 1:n, ordered = FALSE)` và cách sử dụng sẽ được minh họa bằng vài ví dụ sau đây:

- Tạo ra biến gồm bậc 1 và 2; mỗi bậc được lặp lại 8 lần:

```
> gl(2, 8)
[1] 1 1 1 1 1 1 1 1 2 2 2 2 2 2 2 2
Levels: 1 2
```

Hay một biến gồm bậc 1, 2 và 3; mỗi bậc được lặp lại 5 lần:

```
> gl(3, 5)
[1] 1 1 1 1 1 2 2 2 2 2 3 3 3 3 3
Levels: 1 2 3
```

- Tạo ra biến gồm bậc 1 và 2; mỗi bậc được lặp lại 10 lần (do đó length=20):

```
> gl(2, 10, length=20)
[1] 1 1 1 1 1 1 1 1 1 1 2 2 2 2 2 2 2 2 2 2
Levels: 1 2
```

Hay:

```
> gl(2, 2, length=20)
[1] 1 1 2 2 1 1 2 2 1 1 2 2 1 1 2 2 1 1 2 2
Levels: 1 2
```

- Cho thêm kí hiệu:

```
> gl(2, 5, label=c("C", "T"))
[1] C C C C C T T T T T
Levels: C T
```

- Tạo một biến gồm 4 bậc 1, 2, 3, 4. Mỗi bậc lặp lại 2 lần.

```
> rep(1:4, c(2,2,2,2))
[1] 1 1 2 2 3 3 4 4
```

Cũng tương đương với:

```
> rep(1:4, each = 2)
[1] 1 1 2 2 3 3 4 4
```

- Với ngày giờ tháng:

```
> x <- .leap.seconds[1:3]

> rep(x, 2)
[1] "1972-06-30 17:00:00 Pacific Standard Time"
    "1972-12-31 16:00:00 Pacific Standard Time"

[3] "1973-12-31 16:00:00 Pacific Standard Time"
    "1972-06-30 17:00:00 Pacific Standard Time"

[5] "1972-12-31 16:00:00 Pacific Standard Time"
    "1973-12-31 16:00:00 Pacific Standard Time"

> rep(as.POSIXlt(x), rep(2, 3))

[1] "1972-06-30 17:00:00 Pacific Standard Time"
    "1972-06-30 17:00:00 Pacific Standard Time"

[3] "1972-12-31 16:00:00 Pacific Standard Time"
    "1972-12-31 16:00:00 Pacific Standard Time"

[5] "1973-12-31 16:00:00 Pacific Standard Time"
    "1973-12-31 16:00:00 Pacific Standard Time"
```

4.4 Sử dụng R cho các phép tính ma trận

Như chúng ta biết ma trận (matrix), nói đơn giản, gồm có dòng (row) và cột (column). Khi viết $A[m, n]$, chúng ta hiểu rằng ma trận A có m dòng và n cột. Trong R, chúng ta cũng có thể thể hiện như thế. Ví dụ: chúng ta muốn tạo một ma trận vuông A gồm 3 dòng và 3 cột, với các phần tử (element) 1, 2, 3, 4, 5, 6, 7, 8, 9, chúng ta viết:

$$A = \begin{pmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \end{pmatrix}$$

Và với R:

```
> y <- c(1,2,3,4,5,6,7,8,9)
> A <- matrix(y, nrow=3)
> A
```

```
      [,1] [,2] [,3]
[1,]     1     4     7
[2,]     2     5     8
[3,]     3     6     9
```

Nhưng nếu chúng ta lệnh:

```
> A <- matrix(y, nrow=3, byrow=TRUE)
> A
```

Thì kết quả sẽ là:

```
      [,1] [,2] [,3]
[1,]     1     2     3
[2,]     4     5     6
[3,]     7     8     9
```

Tức là một **ma trận chuyển vị (transposed matrix)**. Một cách khác để tạo một ma trận hoán vị là dùng `t()`. Ví dụ:

```
> y <- c(1,2,3,4,5,6,7,8,9)
> A <- matrix(y, nrow=3)
> A
```

```
      [,1] [,2] [,3]
[1,]     1     4     7
[2,]     2     5     8
[3,]     3     6     9
```

và $B = A'$ có thể diễn tả bằng R như sau:

```
> B <- t(A)
> B
```

```
      [,1] [,2] [,3]
[1,]     1     2     3
[2,]     4     5     6
[3,]     7     8     9
```

Ma trận vô hướng (scalar matrix) là một ma trận vuông (tức số dòng bằng số cột), và tất cả các phần tử ngoài đường chéo (off-diagonal elements) là 0, và phần tử đường chéo là 1. Chúng ta có thể tạo một ma trận như thế bằng R như sau:

```

> # tạo ra một ma trận 3 x 3 với tất cả phần tử là 0.
> A <- matrix(0, 3, 3)

> # cho các phần tử đường chéo bằng 1
> diag(A) <- 1
> diag(A)
[1] 1 1 1

> # bây giờ ma trận A sẽ là:
> A
      [,1] [,2] [,3]
[1,]    1    0    0
[2,]    0    1    0
[3,]    0    0    1

```

4.4.1 Chiết phần tử từ ma trận

```

> y <- c(1,2,3,4,5,6,7,8,9)
> A <- matrix(y, nrow=3)
> A
      [,1] [,2] [,3]
[1,]    1    4    7
[2,]    2    5    8
[3,]    3    6    9

> # cột 1 của ma trận A
> A[,1]
[1] 1 4 7

> # cột 3 của ma trận A
> A[,3]
[1] 7 8 9

> # dòng 1 của ma trận A
> A[1,]
[1] 1 2 3

> # dòng 2, cột 3 của ma trận A
> A[2,3]
[1] 6

> # tất cả các dòng của ma trận A, ngoại trừ dòng 2
> A[-2,]
      [,1] [,2] [,3]
[1,]    1    4    7
[2,]    3    6    9

```

```

> # tất cả các cột của ma trận A, ngoại trừ cột 1
> A[,-1]
      [,1] [,2]
[1,]     4     7
[2,]     5     8
[3,]     6     9
> # xem phần tử nào cao hơn 3.
> A>3
      [,1] [,2] [,3]
[1,] FALSE TRUE TRUE
[2,] FALSE TRUE TRUE
[3,] FALSE TRUE TRUE

```

4.4.2 Tính toán với ma trận

Cộng và trừ hai ma trận. Cho hai ma trận A và B như sau:

```

> A <- matrix(1:12, 3, 4)
> A
      [,1] [,2] [,3] [,4]
[1,]     1     4     7    10
[2,]     2     5     8    11
[3,]     3     6     9    12
> B <- matrix(-1:-12, 3, 4)
> B
      [,1] [,2] [,3] [,4]
[1,]    -1    -4    -7   -10
[2,]    -2    -5    -8   -11
[3,]    -3    -6    -9   -12

```

Chúng ta có thể cộng A+B:

```

> C <- A+B
> C
      [,1] [,2] [,3] [,4]
[1,]     0     0     0     0
[2,]     0     0     0     0
[3,]     0     0     0     0

```

Hay A-B:

```

> D <- A-B
> D
      [,1] [,2] [,3] [,4]
[1,]     2     8    14    20
[2,]     4    10    16    22
[3,]     6    12    18    24

```

Nhân hai ma trận. Cho hai ma trận:

$$A = \begin{pmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \end{pmatrix} \quad \text{và} \quad B = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{pmatrix}$$

Chúng ta muốn tính AB , và có thể triển khai bằng R bằng cách sử dụng `%*%` như sau:

```
> y <- c(1,2,3,4,5,6,7,8,9)
> A <- matrix(y, nrow=3)
> B <- t(A)
> AB <- A%*%B
> AB
```

```
      [,1] [,2] [,3]
[1,]    66    78    90
[2,]    78    93   108
[3,]    90   108   126
```

Hay tính BA , và có thể triển khai bằng R bằng cách sử dụng `%*%` như sau:

```
> BA <- B%*%A
> BA
```

```
      [,1] [,2] [,3]
[1,]    14    32    50
[2,]    32    77   122
[3,]    50   122   194
```

Nghịch đảo ma trận và giải hệ phương trình. Ví dụ chúng ta có hệ phương trình sau đây:

$$\begin{aligned} 3x_1 + 4x_2 &= 4 \\ x_1 + 6x_2 &= 2 \end{aligned}$$

Hệ phương trình này có thể viết bằng kí hiệu ma trận: $AX = Y$, trong đó:

$$A = \begin{pmatrix} 3 & 4 \\ 1 & 6 \end{pmatrix}, \quad X = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \quad \text{và} \quad Y = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$$

Nghiệm của hệ phương trình này là: $X = A^{-1}Y$, hay trong R:

```
> A <- matrix(c(3,1,4,6), nrow=2)
> Y <- matrix(c(4,2), nrow=2)
> X <- solve(A)%*%Y
> X
```

```

      [,1]
[1,] 1.1428571
[2,] 0.1428571

```

Chúng ta có thể kiểm tra:

```

> 3*X[1,1]+4*X[2,1]
[1] 4

```

Trị số eigen cũng có thể tính toán bằng function eigen như sau:

```

> eigen(A)
$values
[1] 7 2

```

```

$vectors

```

```

      [,1]      [,2]
[1,] -0.7071068 -0.9701425
[2,] -0.7071068  0.2425356

```

Định thức (determinant). Làm sao chúng ta xác định một ma trận có thể đảo nghịch hay không? Ma trận mà định thức bằng 0 là **ma trận suy biến (singular matrix)** và không thể đảo nghịch. Để kiểm tra định thức, R dùng lệnh `det()`:

```

> E <- matrix((1:9), 3, 3)
> E
      [,1] [,2] [,3]
[1,]    1    4    7
[2,]    2    5    8
[3,]    3    6    9

```

```

> det(E)
[1] 0

```

Nhưng ma trận F sau đây thì có thể đảo nghịch:

```

> F <- matrix((1:9)^2, 3, 3)
> F
      [,1] [,2] [,3]
[1,]    1   16   49
[2,]    4   25   64
[3,]    9   36   81
> det(F)
[1] -216

```


Và nghịch đảo của ma trận F (F^{-1}) có thể tính bằng function `solve()` như sau:

```
> solve(F)
      [,1]      [,2]      [,3]
[1,]  1.291667 -2.166667  0.9305556
[2,] -1.166667  1.666667 -0.6111111
[3,]  0.375000 -0.500000  0.1805556
```

Ngoài những phép tính đơn giản này, R còn có thể sử dụng cho các phép tính phức tạp khác. Một lợi thế đáng kể của R là phần mềm cung cấp cho người sử dụng tự do tạo ra những phép tính phù hợp cho từng vấn đề cụ thể. Trong vài chương sau, chúng ta sẽ quay lại vấn đề này chi tiết hơn.

R có một package `Matrix` chuyên thiết kế cho tính toán ma trận. Bạn đọc có thể tải package xuống, cài vào máy, và sử dụng, nếu cần. Địa chỉ để tải là:

http://cran.au.r-project.org/bin/windows/contrib/r-release/Matrix_0.995-8.zip

cùng với tài liệu chỉ dẫn cách sử dụng (dài khoảng 80 trang):

<http://cran.au.r-project.org/doc/packages/Matrix.pdf>

05

Tính toán xác suất và mô phỏng (simulation)

Xác suất là nền tảng của phân tích thống kê. Tất cả các phương pháp phân tích số liệu và suy luận thống kê đều dựa vào lý thuyết xác suất. Lý thuyết xác suất quan tâm đến việc mô tả và thể hiện qui luật phân phối của một biến số ngẫu nhiên. “Mô tả” ở đây trong thực tế cũng có nghĩa đơn giản là đếm những trường hợp hay khả năng xảy ra của một hay nhiều biến. Chẳng hạn như khi chúng ta chọn ngẫu nhiên 2 đối tượng, và nếu 2 đối tượng này có thể được phân loại bằng hai đặc tính như giới tính và sở thích, thì vấn đề đặt ra là có bao nhiêu tất cả “phối hợp” giữa hai đặc tính này. Hay đối với một biến số liên tục như huyết áp, mô tả có nghĩa là tính toán các chỉ số thống kê của biến như trị số trung bình, trung vị, phương sai, độ lệch chuẩn, v.v... Từ những chỉ số mô tả, lý thuyết xác suất cung cấp cho chúng ta những mô hình để thiết lập các hàm phân phối cho các biến số đó. Chương này sẽ bàn qua hai lĩnh vực chính là phép đếm và các hàm phân phối.

5.1 Các phép đếm

5.1.1 Phép hoán vị (permutation)

Theo định nghĩa, hoán vị n phần tử là cách sắp xếp n phần tử theo một thứ tự định sẵn. Định nghĩa này khá khó hiểu, ví dụ cụ thể sau sẽ làm rõ định nghĩa hơn. Hãy tưởng tượng một trung tâm cấp cứu có 3 bác sĩ (x , y và z), và có 3 bệnh nhân (a , b và c) đang ngồi chờ được khám bệnh. Cả ba bác sĩ đều có thể khám bất cứ bệnh nhân a , b hay c . Câu hỏi đặt ra là có bao nhiêu cách sắp xếp bác sĩ - bệnh nhân? Để trả lời câu hỏi này, chúng ta xem xét vài trường hợp sau đây:

- Bác sĩ x có 3 lựa chọn: khám bệnh nhân a , b hoặc c ;
- Khi bác sĩ x đã chọn một bệnh nhân rồi, thì bác sĩ y có hai lựa chọn còn lại;

- Và sau cùng, khi 2 bác sĩ kia đã chọn, bác sĩ z chỉ còn 1 lựa chọn.
- Tổng cộng, chúng ta có 6 lựa chọn.

Một ví dụ khác, trong một buổi tiệc gồm 6 bạn, hỏi có bao nhiêu cách sắp xếp cách ngồi trong một bàn với 6 ghế? Qua cách lí giải của ví dụ trên, đáp số là: $6.5.4.3.2.1 = 720$ cách. (Chú ý dấu “ $\cdot$ ” có nghĩa là dấu nhân hay tích số). Và đây chính là phép đếm *hoán vị*.

Chúng ta biết rằng $3! = 3.2.1 = 6$, và $0! = 1$. Nói chung, công thức tính hoán vị cho một số n là: $n! = n(n-1)(n-2)(n-3) \times \dots \times 1$. Trong R cách tính này rất đơn giản với lệnh `prod()` như sau:

- Tìm $3!$

```
> prod(3:1)
[1] 6
```
- Tìm $10!$

```
> prod(10:1)
[1] 3628800
```
- Tìm $10.9.8.7.6.5.4$

```
> prod(10:4)
[1] 604800
```
- Tìm $(10.9.8.7.6.5.4) / (40.39.38.37.36)$

```
> prod(10:4) / prod(40:36)
[1] 0.007659481
```

5.1.2 Tổ hợp (combination)

Tổ hợp n phần tử chọn k là mọi tập hợp con gồm k phần tử của tập hợp n phần tử. Ví dụ cụ thể sau sẽ giúp cho chúng ta hiểu rõ vấn đề này: Cho 3 người (hãy cho là A, B, và C) ứng viên vào 2 chức chủ tịch và phó chủ tịch, hỏi: có bao nhiêu cách để chọn 2 chức này trong số 3 người đó. Chúng ta có thể tưởng tượng có 2 ghế mà phải chọn 3 người:

CÁCH CHỌN	CHỦ TỊCH	PHÓ CHỦ TỊCH
1	A	B
2	B	A
3	A	C
4	C	A
5	B	C
6	C	B

Như vậy có 6 cách chọn. Nhưng chú ý rằng cách chọn 1 và 2 trong thực tế chỉ là 1 cặp, và chúng ta chỉ có thể đếm là 1 (chứ không là 2 được). Tương tự, 3 và 4, 5 và 6 cũng chỉ có thể đếm là 1 cặp. Tổng cộng, chúng ta có 3 cách chọn 3 người cho 2 chức vụ. Đáp số này được gọi là tổ hợp.

Thật ra tổng số lần chọn có thể tính bằng công thức sau đây:

$$\binom{3}{2} = \frac{3!}{2!(3-2)!} = \frac{6}{2} = 3 \text{ lần.}$$

Nói chung, số lần chọn k người từ n người là:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

Công thức này cũng có khi viết là C_k^n thay vì $\binom{n}{k}$. Với R, phép tính này

rất đơn giản bằng hàm `choose(n, k)`. Sau đây là vài ví dụ minh họa:

- `choose(5, 2)`

`> choose(5, 2)`

`[1] 10`

- Tìm xác suất cặp A và B trong số 5 người được đặc cử vào hai chức vụ:

`> 1/choose(5, 2)`

`[1] 0.1`

5.2 Biến số ngẫu nhiên và hàm phân phối

Phần lớn phân tích thống kê dựa vào các luật phân phối xác suất để suy luận. Nếu chúng ta chọn ngẫu nhiên 10 bạn trong một lớp học và ghi nhận chiều cao và giới tính của 10 bạn đó, chúng ta có thể có một dãy số liệu như sau:

	1	2	3	4	5	6	7	8	9	10
Giới tính	Nữ	Nữ	Nam	Nữ	Nữ	Nữ	Nam	Nam	Nữ	Nam
Chiều cao (cm)	156	160	175	145	165	158	170	167	178	155

Nếu tính gộp chung lại, chúng ta có 6 bạn gái và 4 bạn trai. Nói theo phần trăm, chúng ta có 60% nữ và 40% nam. Nói theo ngôn ngữ xác suất, xác suất nữ là 0.6 và nam là 0.4.

Về chiều cao, chúng ta có giá trị trung bình là 162.9 cm, với chiều cao thấp nhất là 145 cm và cao nhất là 178 cm.

HÀM PHÂN PHỐI	MẬT ĐỘ	TÍCH LŨY	ĐỊNH BẬC	MÔ PHỎNG
Chuẩn	dnorm(x, mean, sd)	pnorm(q, mean, sd)	qnorm(p, mean, sd)	rnorm(n, mean, sd)
Nhị phân	dbinom(k, n, p)	pbinom(q, n, p)	qbinom (p, n, p)	rbinom(k, n, prob)
Poisson	dpois(k, lambda)	ppois(q, lambda)	qpois(p, lambda)	rpois(n, lambda)
Uniform	dunif(x, min, max)	punif(q, min, max)	qunif(p, min, max)	runif(n, min, max)
Negative binomial	dnbinom(x, k, p)	pnbinom(q, k, p)	qnbinom (p,k,prob)	rbinom(n, n, prob)
Beta	dbeta(x, shapel, shape2)	pbeta(q, shapel, shape2)	qbeta(p, shapel, shape2)	rbeta(n, shapel, shape2)
Gamma	dgamma(x, shape, rate, scale)	gamma(q, shape, rate, scale)	qgamma(p, shape, rate, scale)	rgamma(n, shape, rate, scale)
Geometric	dgeom(x, p)	pgeom(q, p)	qgeom(p, prob)	rgeom(n, prob)

HÀM PHÂN PHỐI	MẬT ĐỘ	TÍCH LŨY	ĐỊNH BẬC	MÔ PHỎNG
Exponential	dexp(x, rate)	pexp(q, rate)	qexp(p, rate)	rexp(n, rate)
Weibull	dnorm(x, mean, sd)	pnorm(q, mean, sd)	qnorm(p, mean, sd)	rnorm(n, mean, sd)
Cauchy	dcauchy(x, location, scale)	pcauchy(q, location, scale)	qcauchy(p, location, scale)	rcauchy(n, location, scale)
F	df(x, df1, df2)	pf(q, df1, df2)	qf(p, df1, df2)	rf(n, df1, df2)
T	dt(x, df)	pt(q, df)	qt(p, df)	rt(n, df)
Chi-squared	dchisq(x, df)	pchi(q, df)	qchisq(p, df)	rchisq(n, df)

Chú thích: Trong bảng trên, df = degrees of freedom (bậc tự do); prob = probability (xác suất); n = sample size (số lượng mẫu). Các thông số khác có thể tham khảo thêm cho từng luật phân phối. Riêng các luật phân phối F, t, Chi-squared còn có một thông số khác nữa là non-centrality parameter (ncp) được cho số 0. Tuy nhiên người sử dụng có thể cho một thông số khác thích hợp, nếu cần.

Nói theo ngôn ngữ thống kê xác suất, biến số giới tính và chiều cao là hai *biến số ngẫu nhiên* (random variable). Ngẫu nhiên là vì chúng ta không đoán trước một cách chính xác các giá trị này, nhưng chỉ có thể đoán giá trị tập trung, giá trị trung bình, và độ dao động của chúng. Biến giới tính chỉ có hai “giá trị” (nam hay nữ), và được gọi là biến *không liên tục*, hay *biến rời rạc* (discrete variable), hay *biến thứ bậc* (categorical variable). Còn biến chiều cao có thể có bất cứ giá trị nào từ thấp đến cao, và do đó có tên là *biến liên tục* (continuous variable).

Khi nói đến “phân phối” (hay distribution) là đề cập đến các giá trị mà biến số có thể có. Các *hàm phân phối* (distribution function) là hàm nhằm mô tả các biến số đó một cách có hệ thống. “Có hệ thống” ở đây có nghĩa là theo một mô hình toán học cụ thể với những thông số cho trước. Trong xác suất thống kê có khá nhiều hàm phân phối, và ở đây chúng ta sẽ xem xét qua một số hàm quan trọng nhất và thông dụng nhất: đó là phân phối nhị phân, phân phối Poisson, và phân phối chuẩn. Trong mỗi luật phân phối, có 4 loại hàm quan trọng mà chúng ta cần biết:

- Hàm mật độ xác suất (probability density distribution);
- Hàm phân phối tích lũy (cumulative probability distribution);
- Hàm định bậc (quantile); và
- Hàm mô phỏng (simulation).

R có những hàm sẵn trên có thể ứng dụng cho tính toán xác suất. Tên mỗi hàm được gọi bằng một tiếp đầu ngữ để chỉ loại hàm phân phối, và viết tắt tên của hàm đó. Các tiếp đầu ngữ là *d* (chỉ distribution hay xác suất), *p* (chỉ cumulative probability, xác suất tích lũy), *q* (chỉ định bậc hay quantile), và *r* (chỉ random hay số ngẫu nhiên). Các tên viết tắt là *norm* (normal, phân phối chuẩn), *binom* (binomial, phân phối nhị phân), *pois* (Poisson, phân phối Poisson), v.v... 2 bảng trên đây tóm tắt các hàm và thông số cho từng hàm.

5.3 Các hàm phân phối xác suất (probability distribution function)

5.3.1 Hàm phân phối nhị phân (Binomial distribution)

Như tên gọi, hàm phân phối nhị phân chỉ có hai giá trị: nam/nữ, sống/chết, có/không, v.v... Hàm nhị phân được phát biểu bằng định lý như sau: Nếu một thử nghiệm được tiến hành n lần, mỗi lần cho ra kết quả hoặc là thành công hoặc là thất bại, và gồm xác suất thành công được biết trước là p , thì xác suất có k lần thử nghiệm thành công là: $P(k | n, p) = C_k^n p^k (1-p)^{n-k}$, trong đó $k = 0, 1, 2, \dots, n$. Để hiểu định lý đó rõ ràng hơn, chúng ta sẽ xem qua vài ví dụ sau đây.

Ví dụ 1: Hàm mật độ nhị phân (Binomial density probability function).

Trong ví dụ trên, lớp học có 10 người, trong đó có 6 nữ. Nếu 3 bạn được chọn một cách ngẫu nhiên, xác suất mà chúng ta có 2 bạn nữ là bao nhiêu? Chúng ta có thể trả lời câu hỏi này một cách tương đối thủ công bằng cách xem xét tất cả các trường hợp có thể xảy ra. Mỗi lần chọn có 2 khả năng (nam hay nữ), và 3 lần chọn, chúng ta có $2^3 = 8$ trường hợp như sau.

BẠN 1	BẠN 2	BẠN 3	XÁC SUẤT
Nam	Nam	Nam	$(0.4)(0.4)(0.4) = 0.064$
Nam	Nam	Nữ	$(0.4)(0.4)(0.6) = 0.096$
Nam	Nữ	Nam	$(0.4)(0.6)(0.4) = 0.096$
Nam	Nữ	Nữ	$(0.4)(0.6)(0.6) = 0.144$
Nữ	Nam	Nam	$(0.6)(0.4)(0.4) = 0.096$
Nữ	Nam	Nữ	$(0.6)(0.4)(0.6) = 0.144$
Nữ	Nữ	Nam	$(0.6)(0.6)(0.4) = 0.144$
Nữ	Nữ	Nữ	$(0.6)(0.6)(0.6) = 0.216$
Tất cả các trường hợp			1.000

Chúng ta biết trước rằng trong nhóm 10 học sinh có 6 nữ, và do đó, xác suất nữ là 0.60. (Nói cách khác, xác suất chọn một bạn nam là 0.4). Do đó, xác suất mà tất cả 3 bạn được chọn đều là nam giới là: $0.4 \times 0.4 \times 0.4 = 0.064$. Trong bảng trên, chúng ta thấy có 3 trường hợp mà trong đó có 2 bạn gái: đó là trường hợp Nam-Nữ-Nữ, Nữ-Nữ-Nam, và Nữ-Nam-Nữ, cả 3 đều có xác suất 0.144. Cho nên, xác suất chọn đúng 2 bạn nữ trong số 3 bạn được chọn là $3 \times 0.144 = 0.432$.

Trong R, có hàm `dbinom(k, n, p)` có thể giúp chúng ta tính công thức $P(k|n, p) = C_k^n p^k (1-p)^{n-k}$ một cách nhanh chóng. Trong trường hợp trên, chúng ta chỉ cần đơn giản lệnh:

```
> dbinom(2, 3, 0.60)
[1] 0.432
```

Ví dụ 2: Hàm nhị phân tích lũy (Cumulative Binomial probability distribution). Xác suất thuốc chống loãng xương có hiệu nghiệm là khoảng 70% (tức là $p = 0.70$). Nếu chúng ta điều trị 10 bệnh nhân, xác suất có tối thiểu 8 bệnh nhân với kết quả tích cực là bao nhiêu? Nói cách khác, nếu gọi X là số bệnh nhân được điều trị thành công, chúng ta cần tìm $P(X \geq 8) = ?$ Để trả lời câu hỏi này, chúng ta sử dụng hàm `pbinom(k, n, p)`. Xin nhắc lại rằng hàm `pbinom(k, n, p)` cho chúng ta $P(X \leq k)$. Do đó, $P(X \geq 8) = 1 - P(X \leq 7)$. Cho nên, đáp số bằng R cho câu hỏi là:

```
> 1-pbinom(7, 10, 0.70)
[1] 0.3827828
```

Ví dụ 3: Mô phỏng hàm nhị phân: Biết rằng trong một quần thể dân số có khoảng 20% người mắc bệnh cao huyết áp; nếu chúng ta tiến hành chọn mẫu 1000 lần, mỗi lần chọn 20 người trong quần thể đó một cách ngẫu nhiên, sự phân

phối số bệnh nhân cao huyết áp sẽ như thế nào? Để trả lời câu hỏi này, chúng ta có thể ứng dụng hàm `rbinom (n, k, p)` trong R với những thông số như sau:

```
> b <- rbinom(1000, 20, 0.20)
```

Trong lệnh trên, kết quả mô phỏng được tạm thời chứa trong đối tượng tên là `b`. Để biết `b` có gì, chúng ta đếm bằng lệnh `table`:


```
> table(b)
b
 0  1  2  3  4  5  6  7  8  9 10
6 45 147 192 229 169 105 68 23 13  3
```

Dòng số liệu thứ nhất (0, 5, 6, ..., 10) là số bệnh nhân mắc bệnh cao huyết áp trong số 20 người mà chúng ta chọn. Dòng số liệu thứ hai cho chúng ta biết số lần chọn mẫu trong 1000 lần xảy ra. Do đó, có 6 mẫu không có bệnh nhân cao huyết áp nào, 45 mẫu với chỉ 1 bệnh nhân cao huyết áp, v.v... Có lẽ cách để hiểu là vẽ đồ thị các tần số trên bằng lệnh `hist` như sau:

```
> hist(b, main= "Number of hypertensive patients")
```

Trong lệnh trên `b` là biến số thể hiện cao huyết áp. Kết quả của lệnh trên là một biểu đồ thể hiện tần số bệnh nhân cao huyết áp như sau (xem **biểu đồ 1**).

Qua biểu đồ trên, chúng ta thấy xác suất có 4 bệnh nhân cao huyết áp (trong mỗi lần chọn mẫu 20 người) là cao nhất (22.9%). Điều này cũng có thể hiểu được, bởi vì tỉ lệ cao huyết áp là 20%, cho nên chúng ta kì vọng rằng trung bình 4 người trong số 20 người được chọn phải là cao huyết áp. Tuy nhiên, điều quan trọng mà biểu đồ trên thể hiện là có khi chúng ta quan sát đến 10 bệnh nhân cao huyết áp dù xác suất cho mẫu này rất thấp (chỉ 3/1000).



Biểu đồ 1. Phân phối số bệnh nhân cao huyết áp trong số 20 người được chọn ngẫu nhiên trong một quần thể gồm 20% bệnh nhân cao huyết áp, và chọn mẫu được lặp lại 1000 lần.

Ví dụ 4: Ứng dụng hàm phân phối nhị phân: Hai mươi khách hàng được mời uống hai loại bia A và B, và được hỏi họ thích bia nào. Kết quả cho thấy 16 người thích bia A. Vấn đề đặt ra là kết quả này có đủ để kết luận rằng bia A được nhiều người thích hơn bia B, hay là kết quả chỉ là do các yếu tố ngẫu nhiên gây nên?

Chúng ta bắt đầu giải quyết vấn đề bằng cách giả thiết rằng nếu không có khác nhau, thì xác suất $p = 0.50$ thích bia A và $q = 0.5$ thích bia B. Nếu giả thiết này đúng, thì xác suất mà chúng ta quan sát 16 người trong số 20 người thích bia A là bao nhiêu. Chúng ta có thể tính xác suất này bằng R rất đơn giản:

```
> 1- pbinom(15, 20, 0.5)
[1] 0.005908966
```

Đáp số là xác suất 0.005 hay 0.5%. Nói cách khác, nếu quả thật hai bia giống nhau thì xác suất mà 16/20 người thích bia A chỉ 0.5%. Tức là, chúng ta có bằng chứng cho thấy khả năng bia A quả thật được nhiều người thích hơn bia B, chứ không phải do yếu tố ngẫu nhiên. Chú ý, chúng ta dùng 15 (thay vì 16), là bởi vì $P(X \geq 16) = 1 - P(X \leq 15)$. Mà trong trường hợp ta đang bàn, $P(X \leq 15) = \text{pbinom}(15, 20, 0.5)$.

5.3.2 Hàm phân phối Poisson (Poisson distribution)

Hàm phân phối Poisson, nói chung, rất giống với hàm nhị phân, ngoại trừ thông số p thường rất nhỏ và n thường rất lớn. Vì thế, hàm Poisson thường được sử dụng để mô tả các biến số rất hiếm xảy ra (như số người mắc ung thư trong dân số chẳng hạn). Hàm Poisson còn được ứng dụng khá nhiều và thành công trong các nghiên cứu kỹ thuật và thị trường như số lượng khách hàng đến một nhà hàng mỗi giờ.

Ví dụ 5: Hàm mật độ Poisson (Poisson density probability function).

Qua theo dõi nhiều tháng, người ta biết được tỉ lệ đánh sai chính tả của một thư kí đánh máy. Tính trung bình cứ khoảng 2.000 chữ thì thư kí đánh sai 1 chữ. Hỏi xác suất mà thư kí đánh sai chính tả 2 chữ, hơn 2 chữ là bao nhiêu?

Vì tần số khá thấp, chúng ta có thể giả định rằng biến số “sai chính tả” (tạm đặt tên là biến số X) là một hàm ngẫu nhiên theo luật phân phối Poisson. Ở đây, chúng ta có tỉ lệ sai chính tả trung bình là 1 ($\lambda = 1$). Luật phân phối Poisson phát biểu rằng xác suất mà $X = k$, với điều kiện tỉ lệ trung bình λ , :

$$P(X = k | \lambda) = \frac{e^{-\lambda} \lambda^k}{k!}$$

Do đó, đáp số cho câu hỏi trên là: $P(X=2|\lambda=1) = \frac{e^{-1}1^2}{2!} = 0.1839$. Đáp số này có thể tính bằng R một cách nhanh chóng hơn bằng hàm `dpois` như sau:

```
> dpois(2, 1)
[1] 0.1839397
```

Chúng ta cũng có thể tính xác suất sai 1 chữ:

```
> dpois(1, 1)
[1] 0.3678794
```

Và xác suất không sai chữ nào:

```
> dpois(0, 1)
[1] 0.3678794
```

Chú ý trong hàm trên, chúng ta chỉ đơn giản cung cấp thông số $k = 2$ và $\lambda = 1$. Trên đây là xác suất mà thư kí đánh sai chính tả đúng 2 chữ. Nhưng xác suất mà thư kí đánh sai chính tả hơn 2 chữ (tức 3, 4, 5,... chữ) có thể ước tính bằng:

$$\begin{aligned}P(X > 2) &= P(X=3) + P(X=4) + P(X=5) + \dots \\&= 1 - P(X \leq 2) \\&= 1 - 0.3678 - 0.3678 - 0.1839 \\&= 0.08\end{aligned}$$

Bằng R, chúng ta có thể tính như sau:

```
# P(X ≤ 2)

> ppois(2, 1)
[1] 0.9196986

# 1-P(X ≤ 2)

> 1-ppois(2, 1)
[1] 0.0803014
```


5.3.3 Hàm phân phối chuẩn (Normal distribution)

Hai luật phân phối mà chúng ta vừa xem xét trên đây thuộc vào nhóm phân phối áp dụng cho các biến số phi liên tục (discrete distributions), mà trong đó biến số có những giá trị theo bậc thứ hay thể loại. Đối với các biến số liên tục, có vài luật phân phối thích hợp khác, mà quan trọng nhất là

phân phối chuẩn. Phân phối chuẩn là nền tảng quan trọng nhất của phân tích thống kê. Có thể nói hầu hết lý thuyết thống kê được xây dựng trên nền tảng của phân phối chuẩn. Hàm mật độ phân phối chuẩn có hai thông số: trung bình μ và phương sai σ^2 (hay độ lệch chuẩn σ). Gọi X là một biến số (như chiều cao chẳng hạn), hàm mật độ phân phối chuẩn phát biểu rằng xác suất mà $X = x$ là:

$$P(X = x | \mu, \sigma^2) = f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(x - \mu)^2}{2\sigma^2}\right]$$

Ví dụ 6: Hàm mật độ phân phối chuẩn (Normal density probability function). Chiều cao trung bình hiện nay ở phụ nữ Việt Nam là 156 cm, với độ lệch chuẩn là 4.6 cm. Cũng biết rằng, chiều cao này tuân theo luật phân phối chuẩn. Với hai thông số $\mu = 156$, $\sigma = 4.6$, chúng ta có thể xây dựng một hàm phân phối chiều cao cho toàn bộ quần thể phụ nữ Việt Nam, và hàm này có hình dạng như sau:



Biểu đồ 2. Phân phối chiều cao ở phụ nữ Việt Nam với trung bình 156 cm và độ lệch chuẩn 4.6 cm.

Trục hoành là chiều cao và trục tung là xác suất cho mỗi chiều cao.

Biểu đồ trên được vẽ bằng hai lệnh sau đây. Lệnh đầu tiên nhằm tạo ra một biến số `height` có giá trị 130, 131, 132, ..., 200 cm. Lệnh thứ hai là vẽ biểu đồ với điều kiện trung bình là 156 cm và độ lệch chuẩn là 4.6 cm.

```
> height <- seq(130, 200, 1)
> plot(height, dnorm(height, 156, 4.6),
      type="l",
      ylab="f(height)",
      xlab="Height",
      main="Probability distribution of height in
Vietnamese women")
```

Với hai thông số trên (và biểu đồ), chúng ta có thể ước tính xác suất cho bất cứ chiều cao nào. Chẳng hạn như xác suất một phụ nữ Việt Nam có chiều cao 160 cm là:

$$P(X = 160 \mid \mu=156, \sigma=4.6) = \frac{1}{4.6\sqrt{2\times 3.1416}} \exp\left[-\frac{(160-156)^2}{2(4.6)^2}\right]$$

$$= 0.0594$$

Hàm `dnorm(x, mean, sd)` trong R có thể tính toán xác suất này cho chúng ta một cách gọn nhẹ:

```
> dnorm(160, mean=156, sd=4.6)
[1] 0.05942343
```

(Đúng ra theo lý thuyết, xác suất phải là 0, nhưng đây là một vấn đề lý thuyết mà chúng ta sẽ không bàn ở đây).

Hàm xác suất chuẩn tích lũy (cumulative normal probability function).

Vì chiều cao là một biến số liên tục, trong thực tế chúng ta ít khi nào muốn tìm xác suất cho một giá trị cụ thể x , mà thường tìm xác suất cho một khoảng giá trị a đến b . Chẳng hạn như chúng ta muốn biết xác suất chiều cao từ 150 đến 160 cm (tức là $P(160 \leq X \leq 150)$), hay xác suất chiều cao thấp hơn 145 cm, tức $P(X < 145)$. Để tìm đáp số các câu hỏi như thế, chúng ta cần đến hàm xác suất chuẩn tích lũy, được định nghĩa như sau:

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

Vì thế, $P(160 \leq X \leq 150)$ chính là diện tích tính từ trục hoành = 150 đến 160 của **biểu đồ 2**. Trong R có hàm `pnorm(x, mean, sd)` dùng để tính xác suất tích lũy cho một phân phối chuẩn rất có ích.

$$\text{pnorm}(a, \text{mean}, \text{sd}) = \int_{-\infty}^a f(x) dx = P(X \leq a \mid \text{mean}, \text{sd})$$

Chẳng hạn như xác suất chiều cao phụ nữ Việt Nam bằng hoặc thấp hơn 150 cm là 9.6%:

```
> pnorm(150, 156, 4.6)
[1] 0.0960575
```

Hay xác suất chiều cao phụ nữ Việt Nam bằng hoặc cao hơn 165 cm là:

```
> 1-pnorm(164, 156, 4.6)
[1] 0.04100591
```

Nói cách khác, chỉ có khoảng 4.1% phụ nữ Việt Nam có chiều cao bằng hay cao hơn 165 cm.

Ví dụ 7: Ứng dụng luật phân phối chuẩn: Trong một quần thể, chúng ta biết rằng áp suất máu trung bình là 100 mmHg và độ lệch chuẩn là 13 mmHg, hỏi: có bao nhiêu người trong quần thể này có áp suất máu bằng hoặc cao hơn 120 mmHg? Câu trả lời bằng R là:

```
> 1-pnorm(120, mean=100, sd=13)
[1] 0.0619679
```

Tức khoảng 6.2% người trong quần thể này có áp suất máu bằng hoặc cao hơn 120 mmHg.

5.3.4 Hàm phân phối chuẩn chuẩn hóa (Standardized Normal distribution)

Một biến X tuân theo luật phân phối chuẩn với trung bình μ và phương sai σ^2 thường được viết tắt là:

$$X \sim N(\mu, \sigma^2)$$


Ở đây μ và σ^2 tùy thuộc vào đơn vị đo lường của biến số. Chẳng hạn như chiều cao được tính bằng cm (hay m), huyết áp được đo bằng mmHg, tuổi được đo bằng năm, v.v... cho nên đôi khi mô tả một biến số bằng đơn vị gốc rất khó so sánh. Một cách đơn giản hơn là chuẩn hóa (standardized) X sao cho số trung bình là 0 và phương sai là 1. Sau vài thao tác số học, có thể chứng minh cách biến đổi X để đáp ứng điều kiện trên là:

$$Z = \frac{X - \mu}{\sigma}$$

Nói theo ngôn ngữ toán: nếu $X \sim N(\mu, \sigma^2)$, thì $(X - \mu)/\sigma \sim N(0, 1)$. Như vậy qua công thức trên, Z thực chất là độ khác biệt giữa một số và trung bình tính bằng số độ lệch chuẩn. Nếu $Z = 0$, chúng ta biết rằng X bằng số trung bình

μ . Nếu $Z = -1$, chúng ta biết rằng X thấp hơn μ đúng 1 độ lệch chuẩn. Tương tự, $Z = 2.5$, chúng ta biết rằng X cao hơn μ đúng 2.5 độ lệch chuẩn, v.v...

Biểu đồ phân phối chiều cao của phụ nữ Việt Nam có thể mô tả bằng một đơn vị mới, đó là chỉ số z như sau:



Biểu đồ 3. Phân phối chuẩn hóa chiều cao ở phụ nữ Việt Nam.

Biểu đồ 3 được vẽ bằng hai lệnh sau đây:

```
> height <- seq(-4, 4, 0.1)
> plot(height, dnorm(height, 0, 1),
      type="l",
      ylab="f(z)",
      xlab="z",
      main="Probability distribution of height in
Vietnamese women")
```

Với phân phối chuẩn hoá, chúng ta có một tiện lợi là có thể dùng nó để mô tả và so sánh mật độ phân phối của bất cứ biến nào, vì tất cả đều được chuyển sang chỉ số z .

Trong biểu đồ trên, trục tung là xác suất z và trục hoành là biến số z . Chúng ta có thể tính toán xác suất z nhỏ hơn một hằng số (constant) nào đó bằng R. Ví dụ, chúng ta muốn tìm $P(z \leq -1.96) = ?$ cho một phân phối mà trung bình là 0 và độ lệch chuẩn là 1.

```
> pnorm(-1.96, mean=0, sd=1)
[1] 0.02499790
```

Hay $P(z \leq 1.96) = ?$

```
> pnorm(1.96, mean=0, sd=1)
[1] 0.9750021
```

Do đó, $P(-1.96 < z < 1.96)$ chính là:

```
> pnorm(1.96) - pnorm(-1.96)
[1] 0.9500042
```

Nói cách khác, xác suất 95% là z nằm giữa -1.96 và 1.96. (Chú ý trong lệnh trên chúng ta không cung cấp $\text{mean}=0$, $\text{sd}=1$, bởi vì trong thực tế, pnorm giá trị mặc định (default value) của thông số mean là 0 và sd là 1).

Ví dụ 6 (tiếp tục): Xin nhắc lại để tiện việc theo dõi, chiều cao trung bình ở phụ nữ Việt Nam là 156 cm và độ lệch chuẩn là 4.6 cm. Do đó, một phụ nữ có chiều cao 170 cm cũng có nghĩa là $z = (170 - 156) / 4.6 = 3.04$ độ lệch chuẩn, và tỉ lệ các phụ nữ Việt Nam có chiều cao cao hơn 170 cm là rất thấp, chỉ khoảng 0.1%.

```
> 1-pnorm(3.04)
[1] 0.001182891
```

Tìm định lượng (quantile) của một phân phối chuẩn. Đôi khi chúng ta cần làm một tính toán đảo ngược. Chẳng hạn như chúng ta muốn biết: nếu xác suất Z nhỏ hơn một hằng số z nào đó cho trước bằng p , thì z là bao nhiêu? Diễn tả theo kí hiệu xác suất, chúng ta muốn tìm z trong nếu:

$$P(Z < z) = p$$

Để trả lời câu hỏi này, chúng ta sử dụng hàm $\text{qnorm}(p, \text{mean}=, \text{sd}=)$.

Ví dụ 8: Biết rằng $Z \sim N(0, 1)$ và nếu $P(Z < z) = 0.95$, chúng ta muốn tìm z .

```
> qnorm(0.95, mean=0, sd=1)
[1] 1.644854
```

Hay $P(Z < z) = 0.975$ cho phân phối chuẩn với trung bình 0 và độ lệch chuẩn 1:

```
> qnorm(0.975, mean=0, sd=1)
[1] 1.959964
```

5.3.5 Hàm phân phối t, F và χ^2

Các hàm phân phối t, F và χ^2 trong thực tế là hàm của hàm phân phối chuẩn. Mỗi liên hệ và cách tính các hàm này có thể được mô tả bằng vài ghi chú sau đây:

- **Phân phối Khi bình phương (χ^2).** Phân phối χ^2 xuất phát từ tổng bình phương của một biến phân phối chuẩn. Nếu $x_i \sim N(0, 1)$, và gọi $u = \sum_{i=1}^n x_i^2$, thì u tuân theo luật phân phối Khi bình phương với bậc tự do n (thường viết tắt là df). Nói theo ngôn ngữ toán, $u \sim \chi_n^2$.

Ví dụ 9: Tìm xác suất của một biến Khi bình phương, do đó, chỉ cần hai thông số u và n . Chẳng hạn như nếu chúng ta muốn tìm xác suất $P(u=21, df=13)$, chỉ đơn giản dùng hàm `pchisq` như sau:

```
> dchisq(21, 13)
[1] 0.01977879
```

Tìm xác suất mà một biến số u nhỏ hơn 21 với bậc tự do 13 df. Tức là tìm $P(u \leq 21 \mid df=13) = ?$

```
> pchisq(21, 13)
[1] 0.9270714
```

Cũng có thể nói kết quả trên cho biết $P(\chi_{13}^2 < 21) = 0.927$.

Tìm quantile của một trị số u tương đương với 90% của một phân phối χ^2 với 15 bậc tự do:

```
> qchisq(0.95, 15)
[1] 24.99579
```

Nói cách khác, $P(\chi_{15}^2 < 24.99) = 0.95$.

Phi trung tâm (Non-centrality). Chú ý trong định nghĩa trên, phân phối χ^2 xuất phát từ tổng bình phương của một biến phân phối chuẩn có trung bình 0 và phương sai 1. Nhưng nếu một biến phân phối chuẩn có trung bình không phải là 0 và phương sai không phải là 1, thì chúng ta sẽ có một **phân phối Khi bình phương phi trung tâm**. Nếu $x_i \sim N(\mu_i, 1)$ và đặt $u = \sum_{i=1}^n x_i^2$, thì u tuân theo luật phân phối Khi bình phương phi trung tâm với bậc tự do n và thông số phi trung tâm (non-centrality parameter) λ như sau:

$$\lambda = \sum_{i=1}^n \mu_i^2$$

Và kí hiệu là $u \sim \chi_{n,\lambda}^2$. Có thể nói rằng, trung bình của u là $n+\lambda$, và phương sai của u là $2(n+2\lambda)$.

Tìm xác suất mà u nhỏ hơn hoặc bằng 21, với điều kiện bậc tự do là 13 và thông số non-centrality bằng 5.4:

```
> pchisq(21, 13, 5.4)
[1] 0.6837649
```

Tức là, $P(\chi_{13,5.4}^2 < 21) = 0.684$.

Tìm quantile của một trị số tương đương với 50% của một phân phối χ^2 với 7 bậc tự do và thông số non-centrality bằng 3.

```
> qchisq(0.5, 7, 3)
[1] 9.180148
```

Do đó, $P(\chi_{7,3}^2 < 9.180148) = 0.50$

- **Phân phối t (t distribution).** Chúng ta vừa biết rằng nếu $X \sim N(\mu, s^2)$ thì $(X - \mu)/\sigma^2 \sim N(0, 1)$. Nhưng phát biểu đó đúng (hay chính xác) khi chúng ta biết phương sai σ^2 . Trong thực tế, ít khi nào chúng ta biết chính xác phương sai, mà chỉ ước tính từ số liệu thực nghiệm. Trong trường hợp phương sai được ước tính từ số liệu nghiên cứu, và hãy gọi ước tính này là s^2 , thì chúng ta có thể phát biểu rằng: $(X - \mu)/s^2 \sim t(0, \nu)$, trong đó ν là bậc tự do.

Ví dụ 10: Tìm xác suất mà x lớn hơn 1, trong biến theo luật phân phối t với 6 bậc tự do:

```
> 1-pt(1.1, 6)
[1] 0.1567481
```

Tức là, $P(t_6 > 1.1) = 1 - P(t_6 < 1.1) = 0.157$.

Tìm định lượng của một trị số tương đương với 95% của một phân phối t với 15 bậc tự do:

```
> qt(0.95, 15)
[1] 1.753050
```

Nói cách khác, $P(t_{15} < 1.75035) = 0.95$.

- **Phân phối F.** Tỉ số giữa hai biến số theo luật phân phối χ^2 có thể chứng minh là tuân theo luật phân phối F . Nói cách khác, nếu $u \sim \chi_n^2$ và $v \sim \chi_m^2$, thì $u/v \sim F_{n,m}$, trong đó n là bậc tự do tử số (numerator degrees of freedom) và m là bậc tự do mẫu số (denominator degrees of freedom).

Ví dụ 11: Tìm xác suất mà một trị số F lớn hơn 3.24, biết rằng biến số đó tuân theo luật phân phối F với bậc tự do 3 và 15 df và thông số non-centrality 5:

```
> 1-pf(3.24, 3, 15, 5)
```

```
[1] 0.3558721
```

Do đó, $P(F_{3,15,5} > 3.24) = 1 - P(F_{3,15,5} \geq 3.24) = 0.355338$.

Với bậc tự do 3 và 15, tìm C sao cho $P(F_{3,15} > C) = 0.05$. Lời giải của R là:

```
> qf(1-0.05, 3, 15)
```

```
[1] 3.287382
```

Nói cách khác,

$$P(F_{3,15} > 3.287382) = 1 - P(F_{3,15} \geq 3.287382)$$

$$= 1 - 0.95 = 0.05$$

5.4 Mô phỏng (simulation)

Trong phân tích thống kê, đôi khi vì hạn chế số mẫu chúng ta khó có thể ước tính một cách chính xác các thông số, và trong trường hợp bất định đó, chúng ta cần đến mô phỏng để biết được độ dao động của một hay nhiều thông số. Mô phỏng thường dựa vào các luật phân phối. Đây là một lĩnh vực khá phức tạp không nằm trong phạm vi của chương này. Ở đây, chúng ta chỉ điểm một số mô hình mô phỏng mang tính minh họa để bạn đọc có thể dựa vào đó mà phát triển thêm.


Ví dụ 11: Mô phỏng để chứng minh phương sai của số trung bình bằng phương sai chia cho n ($\text{var}(\bar{X}) = \sigma^2 / n$). Chúng ta sẽ xem một biến số không liên tục với giá trị 1, 3 và 5 với xác suất như sau:

x	P(x)
1	0.60
3	0.30
5	0.10

Qua số liệu này, chúng ta biết rằng giá trị trung bình là $(1 \times 0.60) + (3 \times 0.30) + (5 \times 0.10) = 2.0$ và phương sai (bạn đọc có thể tự tính) là 1.8.

Bây giờ chúng ta sử dụng hai thông số này để thử mô phỏng 500 lần. Lệnh thứ nhất tạo ra 3 giá trị của x . Lệnh thứ hai nhập số xác suất cho từng giá trị của x . Lệnh `sample` yêu cầu R tạo nên 500 số ngẫu nhiên và cho vào đối tượng `draws`.

```
x <- c(1, 3, 5)
px <- c(0.6, 0.3, 0.1)
draws <- sample(x, size=500, replace=T, prob=px)
hist(draws, breaks=seq(1,5, by=0.25), main="1000 draws")
```



Từ luật phân phối xác suất chúng ta biết rằng tính trung bình sẽ có 60% lần có giá trị “1”, 30% có giá trị “2”, và 10% có giá trị “5”. Do đó, chúng ta kì vọng sẽ quan sát 300, 150 và 50 lần cho mỗi giá trị. Biểu đồ trên cho thấy phân phối các giá trị này gần với giá trị mà chúng ta kì vọng. Ngoài ra, chúng ta cũng biết rằng phương sai của biến số này là khoảng 1.8. Bây giờ chúng ta kiểm tra xem có đúng như kì vọng hay không:

```
> var(draws)
[1] 1.835671
```

Kết quả trên cho thấy phương sai của 500 mẫu là 1.836, tức không xa mấy so với giá trị kì vọng.


Bây giờ, chúng ta thử mô phỏng 500 giá trị trung bình $\bar{x}$ ($\bar{x}$ là số trung bình của 4 số liệu mô phỏng) từ quần thể trên:

```
> draws <- sample(x, size=4*500, replace=T, prob=px)
> draws = matrix(draws, 4)
> drawmeans = apply(draws, 2, mean)
```

Lệnh thứ nhất và thứ hai tạo nên đối tượng tên là `draws` với 4 dòng, mỗi dòng có 500 giá trị từ luật phân phối trên. Nói cách khác, chúng ta có $4 \times 500 = 2000$ số. 500 số cũng có nghĩa là 500 cột: 1 đến 500. Tức mỗi cột có 4 số. Lệnh thứ ba tìm

trị số trung bình cho mỗi cột. Lệnh này sẽ cho ra 500 số trung bình và chứa trong đối tượng `drawmeans`. Biểu đồ sau đây cho thấy phân phối của 500 số trung bình:

```
> hist(drawmeans,breaks=seq(1,5,by=0.25),
main="1000 means of 4 draws")
```



Chúng ta thấy rằng phương sai của phân phối này nhỏ hơn. Thật ra, phương sai của 500 số trung bình này là 0.45.

```
> var(drawmeans)
[1] 0.4501112
```

Đây là giá trị tương đương với giá trị 0.45 mà chúng ta kì vọng từ công thức $\text{var}(\bar{X}) = \sigma^2 / 4 = 1.8 / 4 = 0.45$.

5.4.1 Mô phỏng phân phối nhị phân

Ví dụ 12: Mô phỏng mẫu từ một quần thể với luật phân phối nhị phân.

Giả dụ chúng ta biết một quần thể có 20% người bị bệnh tiểu đường (xác suất $p = 0.2$). Chúng ta muốn lấy mẫu từ quần thể này, mỗi mẫu có 20 đối tượng, và phương án chọn mẫu được lặp lại 100 lần:


```
> bin <- rbinom(100, 20, 0.2)
> bin
[1] 4 4 5 3 2 2 3 2 5 4 3 6 7 3 4 4 1 5 3 5 3 4 4 5 1 4 4
4 4 3 2 4 2 2 5 4 5

[38] 7 3 5 3 3 4 3 2 4 5 2 4 5 5 4 2 2 2 8 5 5 5 3 4 5 7 4
3 6 4 6 6 8 8 3 3 1

[75] 1 4 4 2 3 9 7 4 4 0 0 8 6 9 3 1 4 5 6 4 5 3 2 4 3 2
```

Kết quả trên là số lần đầu, chúng ta sẽ có 4 người mắc bệnh; lần 2 cũng 4 người; lần 3 có 5 người mắc bệnh; v.v... kết quả này có thể tóm lược trong một biểu đồ như sau:

```
> hist(bin,
      xlab="Number of diabetic patients",
      ylab="Number of samples",
      main="Distribution of the number of diabetic patients")
```



```
> mean(bin)
[1] 3.97
```

Đúng như chúng ta kì vọng, vì chọn mỗi lần 20 đối tượng và xác suất 20%, nên chúng ta tiên đoán trung bình sẽ có 4 bệnh nhân tiểu đường.

5.4.2 Mô phỏng phân phối Poisson


Ví dụ 13: Mô phỏng mẫu từ một quần thể với luật phân phối Poisson. Trong ví dụ sau đây, chúng ta mô phỏng 100 mẫu từ một quần thể tuân theo luật phân phối Poisson với trung bình $\lambda = 3$:

```
> pois <- rpois(100, lambda=3)
> pois
> pois
[1] 4 3 2 4 2 3 4 4 0 7 5 0 3 3 4 2 2 6 1 4 2 3 3 5 4 2 1
4 0 2 1 5 1 2 2 2 6

[38] 1 3 6 3 3 5 4 3 2 2 5 3 3 3 1 4 7 3 4 3 2 6 1 4 1 0 5
2 2 2 3 6 8 4 4 1 4

[75] 1 0 0 4 3 3 2 3 3 3 4 1 5 4 4 1 3 1 6 4 4 4 2 2 2 4
```

Và mật độ phân phối:



Phân phối Poisson và phân phối mũ. Trong ví dụ sau đây, chúng ta mô phỏng thời gian bệnh nhân đến một bệnh viện. Biết rằng, bệnh nhân đến bệnh viện một cách ngẫu nhiên theo luật phân phối Poisson, với trung bình 15 bệnh nhân cho mỗi 150 phút. Có thể chứng minh rằng khoảng cách thời gian đến bệnh viện giữa hai bệnh nhân tuân theo luật phân phối mũ. Chúng ta muốn biết thời gian mà bệnh nhân ghé bệnh viện; do đó, chúng ta mô phỏng 15 thời gian giữa hai bệnh nhân từ luật phân phối mũ với tỉ lệ $15/150 = 0.1$ mỗi phút. Các lệnh sau đây đáp ứng yêu cầu đó:

Tạo thời gian đến bệnh viện

```
> appoint <- rexp(15, 0.1)
> times <- round(appoint,0)
> times
[1] 37 5 8 10 24 5 1 7 8 6 12 6 3 25 15
```


5.4.3 Mô phỏng phân phối χ^2 , t, F

Cách mô phỏng trên đây còn có thể áp dụng cho các luật phân phối khác như nhị phân âm (negative binomial distribution với `rnbinom`), gamma (`rgamma`), beta (`rbeta`), Khi bình phương (`rchisq`), hàm mũ (`rexp`), t (`rt`), F (`rf`), v.v... Các thông số cho các hàm mô phỏng này có thể tìm trong phần đầu của chương.

Các lệnh sau đây sẽ minh họa các luật phân phối thông thường đó:

- Phân phối Khi bình phương với một số bậc tự do:


```
> curve(dchisq(x, 1), xlim=c(0,10), ylim=c(0,0.6),  
col="red", lwd=3)  
> curve(dchisq(x, 2), add=T, col="green", lwd=3)  
> curve(dchisq(x, 3), add=T, col="blue", lwd=3)  
> curve(dchisq(x, 5), add=T, col="orange", lwd=3)  
> abline(h=0, lty=3)  
> abline(v=0, lty=3)  
> legend(par("usr")[2], par("usr")[4],  
xjust=1,  
c("df=1", "df=2", "df=3", "df=5"), lwd=3, lty=1,  
col=c("red", "green", "blue", "orange"))
```



Biểu đồ 4. Phân phối Khi bình phương với bậc tự do = 1, 2, 3, 5.

- Phân phối t :


```
> curve(dt(x, 1), xlim=c(-3,3), ylim=c(0,0.4),
        col="red", lwd=3)
> curve(dt(x, 2), add=T, col="blue", lwd=3)
> curve(dt(x, 5), add=T, col="green", lwd=3)
> curve(dt(x, 10), add=T, col="orange", lwd=3)
> curve(dnorm(x), add=T, lwd=4, lty=3)
> title(main="Student T distributions")
> legend(par("usr")[2], par("usr")[4], xjust=1,
        c("df=1", "df=2", "df=5",
          "df=10", "Normal distribution"),
        lwd=c(2,2,2,2,2),
        lty=c(1,1,1,1,3),
        col=c("red", "blue", "green", "orange", par("fg")))
```



Biểu đồ 5. Phân phối t với bậc tự do = 1, 2, 5, 10 so sánh với phân phối chuẩn.

- Phân phối F :


```
> curve(df(x,1,1), xlim=c(0,2), ylim=c(0,0.8), lwd=3)
> curve(df(x,3,1), add=T)
> curve(df(x,6,1), add=T, lwd=3)
> curve(df(x,3,3), add=T, col="red")
> curve(df(x,6,3), add=T, col="red", lwd=3)
> curve(df(x,3,6), add=T, col="blue")
> curve(df(x,6,6), add=T, col="blue", lwd=3)
> title(main="Fisher F distributions")
> legend(par("usr")[2], par("usr")[4],
        xjust=1,
        c("df=1,1", "df=3,1", "df=6,1", "df=3,3",
          "df=6,3", "df=3,6", "df=6,6"),
        lwd=c(1,1,3,1,3,1,3),
        lty=c(2,1,1,1,1,1,1),
        col=c(par("fg"), par("fg"), par("fg"),
              "red", "blue", "blue"))
```



Biểu đồ 6. Phân phối F với nhiều bậc tự do khác nhau.

- Phân phối *gamma*:

```
> curve( dgamma(x,1,1), xlim=c(0,5))
> curve( dgamma(x,2,1), add=T, col='red' )
> curve( dgamma(x,3,1), add=T, col='green' )
> curve( dgamma(x,4,1), add=T, col='blue' )
> curve( dgamma(x,5,1), add=T, col='orange' )
> title(main="Gamma probability distribution function")
> legend(par( 'usr' )[2], par( 'usr' )[4], xjust=1,
        c( 'k=1 (Exponential distribution)', 'k=2' ,
          'k=3' , 'k=4' , 'k=5' ),lwd=1, lty=1,
        col=c(par( 'fg' ), 'red' , 'green' , 'blue' , 'orange' ) )
```



Biểu đồ 7. Phân phối Gamma với nhiều hình dạng.


- Phân phối *beta*:

```
> curve( dbeta(x,1,1), xlim=c(0,1), ylim=c(0,4) )
> curve( dbeta(x,2,1), add=T, col='red' )
> curve( dbeta(x,3,1), add=T, col='green' )
> curve( dbeta(x,4,1), add=T, col='blue' )
> curve( dbeta(x,2,2), add=T, lty=2, lwd=2, col='red' )
```

```

> curve( dbeta(x,3,2), add=T, lty=2, lwd=2, col= 'green' )
> curve( dbeta(x,4,2), add=T, lty=2, lwd=2, col= 'blue' )
> curve( dbeta(x,2,3), add=T, lty=3, lwd=3, col= 'red' )
> curve( dbeta(x,3,3), add=T, lty=3, lwd=3, col= 'green' )
> curve( dbeta(x,4,3), add=T, lty=3, lwd=3, col= 'blue' )
> title(main="Beta distribution")
> legend(par( 'usr' )[1], par( 'usr' )[4], xjust=0,
        c( '(1,1)', '(2,1)', '(3,1)', '(4,1)',
          '(2,2)', '(3,2)', '(4,2)',
          '(2,3)', '(3,3)', '(4,3)' ),
        lwd=1, #c(1,1,1,1, 2,2,2, 3,3,3),
        lty=c(1,1,1,1, 2,2,2, 3,3,3),
        col=c(par( 'fg' ), 'red', 'green', 'blue',
              'red', 'green', 'blue',
              'red', 'green', 'blue' ))


```



Biểu đồ 8. Phân phối beta với nhiều hình dạng.

- Phân phối *Weibull*:

```
> curve(dexp(x), xlim=c(0,3), ylim=c(0,2))
> curve(dweibull(x,1), lty=3, lwd=3, add=T)
> curve(dweibull(x,2), col='red', add=T)
> curve(dweibull(x,.8), col='blue', add=T)
> title(main="Weibull Probability Distribution Function")
> legend(par('usr')[2], par('usr')[4], xjust=1,
        c('Exponential', 'Weibull, shape=1',
          'Weibull, shape=2', 'Weibull, shape=.8'),
        lwd=c(1,3,1,1),
        lty=c(1,3,1,1),
        col=c(par("fg"), par("fg"), 'red', 'blue'))
```




Biểu đồ 9. Phân phối Weibull.

- Phân phối *Cauchy*:

```
> curve(dcauchy(x), xlim=c(-5,5), ylim=c(0,.5), lwd=3)
> curve(dnorm(x), add=T, col='red', lty=2)
> legend(par('usr')[2], par('usr')[4], xjust=1,
```

```
c('Cauchy distribution', 'Gaussian distribution'),
lwd=c(3,1),
lty=c(1,2),
col=c(par("fg"), 'red'))
```



Biểu đồ 10. Phân phối Cauchy so sánh với phân phối chuẩn.

5.5 Chọn mẫu ngẫu nhiên (random sampling)

Trong xác suất và thống kê, lấy mẫu ngẫu nhiên rất quan trọng, vì nó đảm bảo tính hợp lý của các phương pháp phân tích và suy luận thống kê. Với R, chúng ta có thể lấy một mẫu ngẫu nhiên bằng cách sử dụng hàm `sample`.

Ví dụ: Chúng ta có một quần thể gồm 40 người (mã số 1, 2, 3,..., 40). Nếu chúng ta muốn chọn 5 đối tượng quần thể đó, ai sẽ là người được chọn? Chúng ta có thể dùng lệnh `sample()` để trả lời câu hỏi đó như sau:

```
> sample(1:40, 5)
[1] 32 26 6 18 9
```

Kết quả trên cho biết đối tượng 32, 26, 6, 18 và 9 được chọn. Mỗi lần ra lệnh này, R sẽ chọn một mẫu khác, chứ không hoàn toàn giống như mẫu trên. Ví dụ:

```
> sample(1:40, 5)
[1] 5 22 35 19 4
```

```
> sample(1:40, 5)
[1] 24 26 12 6 22
```

```
> sample(1:40, 5)
[1] 22 38 11 6 18
```

v.v...

Trên đây là lệnh để chúng ta chọn mẫu ngẫu nhiên mà không thay thế (random sampling without replacement), tức là mỗi lần chọn mẫu, chúng ta không bỏ lại các mẫu đã chọn vào quần thể.

Nhưng nếu chúng ta muốn chọn mẫu thay thế (tức mỗi lần chọn ra một số đối tượng, chúng ta bỏ vào lại trong quần thể để chọn tiếp lần sau). Ví dụ, chúng ta muốn chọn 10 người từ một quần thể 50 người, bằng cách lấy mẫu với thay thế (random sampling with replacement), chúng ta chỉ cần thêm tham số `replace=TRUE`:

```
> sample(1:50, 10, replace=T)

[1] 31 44 6 8 47 50 10 16 29 23
```

Hay ném một đồng xu 10 lần; mỗi lần, dĩ nhiên đồng xu có 2 kết quả H và T; và kết quả 10 lần có thể là:

```
> sample(c("H", "T"), 10, replace=T)

[1] "H" "T" "H" "H" "H" "T" "H" "H" "T" "T"
```

Cũng có thể tưởng tượng chúng ta có 5 quả banh màu xanh (X) và 5 quả banh màu đỏ (D) trong một bao. Nếu chúng ta chọn 1 quả banh, ghi nhận màu, rồi để lại vào bao; rồi lại chọn 1 quả banh khác, ghi nhận màu, và bỏ vào bao lại. Cứ như thế, chúng ta chọn 20 lần, kết quả có thể là:

```
> sample(c("X", "D"), 20, replace=T)

[1] "X" "D" "D" "D" "D" "D" "X" "X" "X" "X" "X" "D"
"X" "X" "D" "X" "X" "X" "X"

[20] "D"
```

Ngoài ra, chúng ta còn có thể lấy mẫu với một xác suất cho trước. Trong hàm sau đây, chúng ta chọn 10 đối tượng từ dãy số 1 đến 5, nhưng xác suất không bằng nhau:

```
> sample(5, 10, prob=c(0.3, 0.4, 0.1, 0.1, 0.1),  
replace=T)  
[1] 3 1 3 2 2 2 2 2 5 1
```

Đối tượng 1 được chọn 2 lần, đối tượng 2 được chọn 5 lần, đối tượng 3 được chọn 2 lần, v.v... Tuy không hoàn toàn phù hợp với xác suất 0.3, 0.4, 0.1 như cung cấp vì số mẫu còn nhỏ, nhưng cũng không quá xa với kì vọng.

06

Kiểm định thống kê và kiểm định giả thuyết

Trị số P (P value) có lẽ là một chỉ số phổ biến nhất trong phân tích dữ liệu và nghiên cứu khoa học. Cũng chính vì sự phổ biến mà nó cũng dễ bị hiểu lầm và lạm dụng. Một nghiên cứu ở một nhóm bác sĩ chuyên khoa và có kinh nghiệm trong nghiên cứu y học cho thấy có đến 85% không hiểu ý nghĩa của trị số P [1]. Đại đa số những người được hỏi hiểu rằng một kết luận (về sự khác biệt) với trị số $P = 0.05$ có nghĩa là khả năng mà kết luận đó sai là 5%, hay khả năng mà kết luận đó đúng là 95% (lấy 1 trừ cho 0.05). Nhiều người khác thì hiểu rằng một sự khác biệt với trị số P càng nhỏ thì mức độ ảnh hưởng càng có ý nghĩa và độ tin cậy của kết luận càng cao. Nhưng rất tiếc rằng cả hai cách hiểu này đều sai. Điều đáng ngạc nhiên là không những giới làm nghiên cứu khoa học hiểu sai, mà ngay cả các nhà nghiên cứu có kiến thức thống kê khá như dịch tễ học cũng hiểu sai. Thật ra, một số nhà thống kê chuyên nghiệp cũng hiểu sai ý nghĩa của trị số P bởi vì một số sách giáo khoa giải thích hoặc là sai, hoặc không rõ ràng!

Vậy thì ý nghĩa thật của trị số P là gì? Để trả lời câu hỏi này, chúng ta phải điểm qua triết lý khoa học, và triết lý phản nghiệm (falsificationism). Theo Karl Popper [2], cha đẻ của triết lý phản nghiệm, một giả thuyết được xem là mang tính “khoa học” nếu giả thuyết đó có khả năng “phản nghiệm” (falsified). Đặc điểm duy nhất để có thể phân biệt giữa một lý thuyết khoa học thực thụ với ngụy khoa học (pseudoscience) là thuyết khoa học luôn có đặc tính có thể “bị bác bỏ” hay “khả năng phản nghiệm” bằng những thực nghiệm đơn giản. Ông gọi đó là “khả năng phản nghiệm” (falsifiability) [3]. Phép phản nghiệm là phương cách tiến hành những thực nghiệm không phải để xác minh mà để

phê phán các lý thuyết khoa học, và có thể coi đây như là một nền tảng cho khoa học thực thụ. Chẳng hạn như giả thuyết [đơn giản] “vi khuẩn *V. cholerae* gây bệnh dịch tả” có thể bác bỏ nếu có một bệnh nhân dịch tả không nhiễm vi khuẩn *V. cholerae*.

Đứng trên phương diện khoa học, có hai mô hình thực tế để tiếp cận lý thuyết phản nghiệm: đó là mô hình kiểm định thống kê và mô hình kiểm định giả thuyết. Rất nhiều sách giáo khoa thống kê và khoa học đã được viết ra, nhưng rất tiếc, nhiều tác giả không giải thích hay không phân biệt được hai mô hình này. Có tác giả thậm chí còn nhầm lẫn khi diễn dịch, và đó cũng chính là một trong những nguyên nhân dẫn đến tình trạng hiểu lầm ý nghĩa của trị số P. Trong phần này, tôi sẽ giải thích ngắn gọn và cung cấp tài liệu tham khảo của hai mô hình để bạn đọc có thể hiểu qua và nghiên cứu thêm.


6.1 Mô hình kiểm định ý nghĩa thống kê (test of significance)

Triết lý phản nghiệm rất phổ biến và trở thành một mô hình để giải thích sự tiến bộ của khoa học. Chịu ảnh hưởng bởi triết lý này, Ronald A. Fisher (1890 - 1962), một nhà di truyền học người Anh và cũng là “cha đẻ” của nền thống kê học hiện đại, đề xuất một phương pháp định lượng để phản nghiệm một giả thuyết khoa học. Ông gọi phương pháp này là “**Test of Significance**” [4-5] (tôi tạm dịch là: **phương pháp kiểm định ý nghĩa thống kê**). Fisher quan niệm rằng thống kê là một bộ phận quan trọng của phương pháp suy luận theo phép qui nạp (inductive inference), tức là phương pháp suy luận dựa vào quan sát từ các mẫu (sample) và khái quát cho một quần thể (population). Phương pháp kiểm định ý nghĩa thống kê được tiến hành theo 3 bước như sau:

- *Bước 1, phát biểu một giả thuyết vô hiệu (null hypothesis).* Giả thuyết vô hiệu là giả thuyết ngược lại với giả thuyết mà nhà nghiên cứu muốn kiểm định. Chẳng hạn như nếu giả thuyết điều trị bằng thuốc Ramipril làm giảm nguy cơ tử vong, thì giả thuyết vô hiệu sẽ phát biểu là “tỉ lệ tử vong ở bệnh nhân được điều trị bằng Ramipril **bằng** với nhóm giả dược”. Gọi giả thuyết vô hiệu là H_0 .
- *Bước 2, thu thập dữ liệu liên quan đến giả thuyết.* Trong ví dụ trên, số liệu sẽ là số trường hợp tử vong. Gọi dữ liệu là D .
- *Bước 3, ước tính xác suất quan sát dữ liệu D nếu giả thuyết H_0 đúng.* Nói cách khác là viết theo ngôn ngữ toán, bước này ước tính $P(D | H_0)$. Đây chính là **trị số P (P-value)**.

Fisher đề nghị báo cáo trị số P một cách chính xác. Tức là không có những cách viết như $P < 0.05$ hay $P > 0.01$ mà phải là $P = 0.043$ hay $P = 0.002$. Fisher còn đề nghị rằng nếu trị số P thấp hơn 0.05 thì giả thuyết H_0 (vô hiệu) không phù hợp với số liệu quan sát được. Đối với Fisher, không có chuyện “bác bỏ giả thuyết” hay “chứng minh giả thuyết” mà chỉ có số liệu có phù hợp, có nhất quán với giả thuyết hay không mà thôi. Quan điểm này chịu ảnh hưởng “đậm” của triết lý phản nghiệm của Popper, vì theo triết lý này, chúng ta không thể chứng minh bất cứ một giả thuyết nào, mà chỉ có thể bác bỏ (disprove) một giả thuyết bằng dữ liệu quan sát được.

Cũng có thể xem trị số P như là một chỉ số ngạc nhiên. Ngày 27/4/2013, báo soha.vn dưới tựa đề “Choáng với chiều cao cực khủng của nam sinh lớp 12”, theo đó, một em học sinh lớp 12 có chiều cao 204 cm. Câu hỏi đặt ra là chiều cao này có đáng ngạc nhiên? Ngạc nhiên hay không còn tùy thuộc vào phân bố chiều cao của thanh niên Việt Nam. Theo nghiên cứu của chúng tôi, chiều cao của nam thanh niên Việt Nam trung bình là 170 cm và độ lệch chuẩn là 6.3 cm. Có thể thể hiện phân bố của quần thể như sau:



Chiều cao của em học sinh là 204 cm, tức nằm ngoài giá trị kì vọng của quần thể thanh niên Việt Nam. Thật ra, chúng ta có thể tính xác suất một em học sinh với chiều cao 204 cm trong quần thể có trung bình là 170 cm và độ lệch chuẩn 6.3 cm:

```
1 - pnorm(204, mean=170, sd=6.3)
```

với kết quả là 0.0000000339. Có thể xem đó là trị số P , một thước đo về sự ngạc nhiên.

6.2 Mô hình Kiểm định giả thuyết (test of hypothesis)

Jerzy Neyman (1894 - 1981) là một nhà toán học xuất sắc gốc Ba Lan và Egon Pearson (1895 - 1980) là một nhà thống kê học (con của giáo sư Karl Pearson, cha đẻ của lý thuyết Chi-square và hệ số tương quan) cùng lúc với Fisher, phát triển một phương pháp rất khác với Fisher, mà hai ông gọi là **Test of Hypothesis (Kiểm định giả thuyết)** [6]. Neyman và Pearson bác bỏ khái niệm suy luận theo qui nạp; hai ông nghĩ rằng thống kê học là một phương pháp hay cơ chế để hướng dẫn chúng ta đi đến một quyết định đúng về lâu về dài. Nói cách khác, Neyman và Pearson cho rằng phương pháp của Fisher vô nghĩa!

Một cách đơn giản, mô hình kiểm định giả thuyết của Neyman và Pearson có thể thực hiện qua các bước như sau:

- Bước 1, phát biểu giả thuyết chính (H_1) và giả thuyết vô hiệu (H_0).
- Bước 2, quyết định mức độ α và β có thể chấp nhận được và ước tính cỡ mẫu cần giả thuyết. α là xác suất bác bỏ giả thuyết H_1 nhưng đó là giả thuyết đúng. β là xác suất bác bỏ H_0 trong khi H_0 đúng.
- Bước 3, thu thập dữ liệu liên quan đến giả thuyết.
- Bước 4, nếu dữ liệu nằm trong khoảng bác bỏ giả thuyết H_0 thì chấp nhận giả thuyết H_1 ; nếu không thì chấp nhận giả thuyết H_0 . Chú ý rằng “chấp nhận” một giả thuyết không có nghĩa là chúng ta tin vào giả thuyết đó, mà chỉ có nghĩa là chúng ta hành động với điều kiện đó là giả thuyết đúng.

Nguyên lý của mô hình Neyman và Pearson là chúng ta dựa vào dữ liệu để chọn một giả thuyết sao cho về lâu về dài chúng ta không quá sai. Chính vì thế mà ngày nay chúng ta thường chọn $\alpha = 5\%$ và $\beta = 10\%$ đến 20% .

Fisher bác bỏ hoàn toàn mô hình của Neyman và Pearson [7]. Ông cho rằng đó là một mô hình... vô duyên. Fisher nhạo báng rằng các nhà toán học (ám chỉ Neyman và Pearson) “chẳng hiểu gì về thực nghiệm và đề ra một mô hình quá phi thực tế”. Trong những năm sau đó (thập niên 1930s) cộng đồng thống kê học chứng kiến một cuộc tranh luận dai dẳng và đôi khi nóng bỏng giữa Fisher và Neyman-Pearson trên các tạp san thống kê học ở Anh. Fisher tuy là một người thông minh tuyệt vời, một nhà tư tưởng với những suy nghĩ trừu tượng, nhưng lại là một người rất khó tính và có khi hẹp hòi. Sự hẹp hòi của Fisher thể hiện ở chỗ ông sử dụng chức quyền khoa bảng của mình để gây khó khăn cho Neyman đến nỗi ông này chịu

không nổi và phải di cư sang Mỹ và sau này trở thành giáo sư tại trường Đại học Berkeley. Sau này, Neyman được lịch sử ghi nhận là một nhà thống kê học xuất sắc có công cực kì to lớn cho khoa học hiện đại, sánh vai cùng các “đại thụ” trong khoa học hiện đại. Nước Mỹ quả thật là môi trường cho ông thi thố tài năng!

6.3 Một mô hình hỗn hợp

Trở trêu thay, mấy mươi năm sau, hai mô hình của Fisher và Neyman-Pearson được “hun đúc” thành một mô hình tổng hợp mà chúng ta ứng dụng ngày nay trong nghiên cứu y học. Mô hình này sử dụng kết quả kiểm định thống kê của Fisher để đi đến quyết định chấp nhận hay bác bỏ giả thuyết vô hiệu H_0 hay giả thuyết chính H_1 theo mô hình của Neyman và Pearson. Tiêu biểu cho mô hình này là nghiên cứu lâm sàng đối chứng ngẫu nhiên (randomized controlled clinical trial hay RCT). Theo đó, một nghiên cứu lâm sàng được tiến hành theo các bước như sau:

- Bước 1, định nghĩa một giả thuyết vô hiệu và một giả thuyết chính. Thí dụ trong một nghiên cứu lâm sàng, gồm hai nhóm bệnh nhân: một nhóm được điều trị bằng thuốc A, và một nhóm được điều trị bằng placebo, nhà nghiên cứu có thể phát biểu giả thuyết vô hiệu rằng độ hiệu nghiệm thuốc A tương đương với placebo.
- Bước 2, xác định xác suất α (còn gọi là sai số loại I) và β (còn gọi là sai số loại II), và ước tính cỡ mẫu dựa vào hai xác suất này.
- Bước 3, thu thập dữ liệu liên quan đến giả thuyết. Gọi dữ liệu là D .
- Bước 4, sử dụng phương pháp kiểm định ý nghĩa thống kê của Fisher ước tính xác suất $P(D | H_0)$. Gọi trị số này là P .
- Bước 5, nếu $P < 0.05$, bác bỏ giả thuyết H_0 . Chú ý, bác bỏ H_0 không có nghĩa là chúng ta chấp nhận giả thuyết H_1 .

Ví dụ: Có thể minh họa cho các bước trên bằng một ví dụ về nghiên cứu hiệu quả của thuốc Ramipril trong việc phòng chống tử vong và đột quỵ [1]. Với giả thuyết rằng thuốc có hiệu nghiệm giảm nguy cơ tử vong và đột quỵ, các nhà nghiên cứu so sánh tỉ lệ tử vong và đột quỵ giữa hai nhóm bệnh nhân: nhóm 1 được điều trị bằng Ramipril và nhóm 2 là nhóm giả dược (placebo). Bắt đầu bằng cách xác định $\alpha = 0.05$ và $\beta = 0.80$, các nhà nghiên cứu ước tính số lượng bệnh nhân cần thiết. Sau ba năm thu thập số liệu, kết quả có thể tóm lược trong bảng số liệu sau đây:

BẢNG 1. HIỆU QUẢ CỦA RAMIPRIL GIẢM NGUY CƠ NHỒI MÁU CƠ TIM, ĐỘT QUY, TỬ VONG VÀ TIỂU ĐƯỜNG THỂ HIỆN QUA TỈ SỐ NGUY CƠ VÀ TRỊ SỐ P		
	Tỉ số nguy cơ (relative risk) và khoảng tin cậy 95%	Trị số P
Nhồi máu cơ tim, đột quy, tử vong	0.83 (0.75 – 0.91)	0.0002
Tỉ lệ mới mắc bệnh tiểu đường	0.69 (0.56 – 0.85)	0.0006

HOPE/HOPE-TOO Study Investigators. Long-term effects of Ramipril on cardiovascular events and diabetes. Results of the HOPE Study Extension. *Circulation* 2005; 112:1339-1346.

Bởi vì trị số P thấp hơn mức α (0.05) mà các nhà nghiên cứu đề ra từ lúc đầu (trước khi thu thập số liệu); cho nên, các nhà nghiên cứu kết luận rằng sự khác biệt về tỉ lệ tử vong và đột quy giữa hai nhóm có ý nghĩa thống kê. Tất nhiên, *trị số P trên không có nghĩa là nghiên cứu đã chứng minh rằng thuốc Ramipril có hiệu quả giảm nguy cơ tử vong và đột quy*. Nó có nghĩa là nếu thật sự thuốc Ramipril không có hiệu quả giảm nguy cơ tử vong và đột quy thì xác suất mà các nhà nghiên cứu quan sát các số liệu trên là 0.0002.

6.4 Vấn đề của trị số P

Có lẽ nói không ngoa rằng trị số P là một con số phổ biến nhất trong khoa học từ khoảng 100 năm qua [9]. Hầu hết các bài báo khoa học đều trình bày trị số P như hàm ý nâng cao tính khoa học và độ tin cậy của bài báo. Tuy nhiên, ngay từ lúc mới “ra đời”, trị số P đã bị phê bình dữ dội. Có người cho rằng việc ứng dụng trị số P trong suy luận khoa học là một bước lùi, là một sự thoái hóa của khoa học, nên đề nghị không sử dụng trị số này trong nghiên cứu khoa học. Nhưng dù chịu nhiều chỉ trích và phê bình, ứng dụng phương pháp kiểm định giả thuyết và trị số P vẫn càng ngày càng phổ biến, đơn giản vì chúng ta chưa có một phương pháp khác tốt hơn, hay hợp lí hơn, hoặc đơn giản hơn. Trong phần này, tôi sẽ không điểm qua tất cả các phê bình trị số P (vì làm như thế cần một cuốn sách), mà chỉ nêu một số vấn đề chúng ta cần lưu ý khi diễn dịch trị số P .

6.4.1 Vấn đề logic

Như qua minh họa trên, trị số P không cho chúng ta biết gì về sự khả dĩ của một giả thuyết, bởi vì nó là một xác suất có điều kiện. Trị số P cho chúng ta biết xác suất của dữ liệu (data) nếu một giả thuyết là đúng. Cái khiếm khuyết

lớn nhất của trị số P là nó thiếu tính logic. Thật vậy, nếu chúng ta chịu khó xem xét lại ví dụ trên, có thể khái quát tiến trình của một nghiên cứu y học (dựa vào trị số P) như sau:

- Đề ra một giả thuyết chính vô hiệu (H_0)
- Từ giả thuyết vô hiệu, đề ra một giả thuyết chính (H_1)
- Tiến hành thu thập dữ liệu (D)
- Phân tích dữ kiện: tính toán xác suất D xảy ra nếu H_0 là thật. Nói theo ngôn ngữ toán xác suất, bước này chính là bước tính toán trị số P hay $P(D | H_0)$.

Vì thế, con số P có nghĩa là xác suất của dữ liệu D xảy ra *nếu* (nhấn mạnh: “nếu”) giả thuyết vô hiệu H_0 là đúng. Như vậy, con số P không trực tiếp cho chúng ta một ý niệm gì về sự thật của giả thuyết chính H_1 ; nó chỉ gián tiếp cung cấp bằng chứng để chúng ta chấp nhận giả thuyết chính và bác bỏ giả thuyết vô hiệu.

Logic đằng sau của trị số P có thể được hiểu như là một qui trình *chứng minh đảo ngược* (proof by contradiction):

- Mệnh đề 1: Nếu giả thuyết vô hiệu đúng, thì sự kiện này không thể xảy ra;
- Mệnh đề 2: Sự kiện xảy ra;
- Mệnh đề 3 (kết luận): Giả thuyết vô hiệu không thể đúng.

Nếu cách lập luận trên khó hiểu, chúng ta thử xem một ví dụ cụ thể như sau:

- Nếu ông Tuấn bị cao huyết áp, thì ông không thể có triệu chứng rụng tóc (hai hiện tượng sinh học này không liên quan với nhau, ít ra là theo kiến thức y khoa hiện nay);
- Ông Tuấn bị rụng tóc;
- Do đó, ông Tuấn không thể bị cao huyết áp.

Trị số P , do đó, gián tiếp phản ánh xác suất của mệnh đề 3. Và đó cũng chính là một khiếm khuyết quan trọng của trị số P , bởi vì nó ước tính mức độ khả dĩ của dữ liệu, chứ *không nói cho chúng ta biết mức độ khả dĩ của một giả thuyết*. Điều này làm cho việc suy luận dựa vào trị số P rất xa rời với thực tế, xa rời với khoa học thực nghiệm. Trong khoa học thực nghiệm, điều mà nhà nghiên cứu muốn biết là với dữ liệu mà họ có được, xác suất của giả thuyết

chính là bao nhiêu, chứ họ không muốn biết nếu giả thuyết đảo là sự thật thì xác suất của dữ liệu là bao nhiêu. Nói cách khác và dùng kí hiệu mô tả trên, nhà nghiên cứu muốn biết $P(H1 | D)$, chứ không muốn biết $P(D | H0)$ hay $P(D | H1)$.

6.4.2 Vấn đề kiểm định nhiều giả thuyết

Như đã nói trên, nghiên cứu y học là một qui trình kiểm định giả thuyết. Trong một nghiên cứu, ít khi nào chúng ta kiểm định chỉ một giả thuyết duy nhất, mà rất nhiều giả thuyết cùng một lúc. Chẳng hạn như trong một nghiên cứu về hiệu quả của Ramipril, các nhà nghiên cứu có thể phân tích hiệu quả của Ramipril qua nhiều tiêu chí lâm sàng như nguy cơ tử vong, nhồi máu cơ tim, đột quỵ, tỉ lệ mắc bệnh tiểu đường, v.v... từng giới tính, từng nhóm tuổi, hay phân tích theo các đặc tính lâm sàng của bệnh nhân. Mỗi một phân tích như thế có thể xem là một kiểm định giả thuyết. Ở đây, chúng ta phải đối diện với vấn đề nhiều giả thuyết (multiple tests of hypothesis hay còn gọi là **multiple comparisons**).

Vấn đề là như sau: nếu chúng ta kiểm định một giả thuyết chúng ta chấp nhận một sai sót 5% (giả dụ chúng ta chấp nhận tiêu chuẩn $P = 0.05$ để tuyên bố có ý nghĩa hay không có ý nghĩa thống kê). Nói cách khác, sự thật là *không* thuốc có hiệu quả sai, nhưng kết quả kiểm định thống kê cho ra kết quả có ý nghĩa thống kê, và chúng ta chấp nhận rằng sự kiện này có thể xảy ra với tần số 5%. Vấn đề đặt ra là trong bối cảnh kiểm định nhiều giả thuyết là như sau: **nếu trong số n thử nghiệm, chúng ta tuyên bố k thử nghiệm “có ý nghĩa thống kê” (tức là $P < 0.05$), thì xác suất có ít nhất một giả thuyết sai là bao nhiêu?**

Để trả lời câu hỏi này chúng ta sẽ bắt đầu bằng một ví dụ đơn giản. Mỗi kiểm định chúng ta chấp nhận một xác suất sai lầm là 0.05. Nói cách khác, chúng ta có xác suất đúng là 0.95. Nếu chúng ta thử nghiệm 3 giả thuyết, xác suất mà chúng ta đúng cả ba [dĩ nhiên] là: $0.95 \times 0.95 \times 0.95 = 0.8574$. Như vậy, xác suất có ít nhất một sai lầm trong ba tuyên bố “có ý nghĩa thống kê” là: $1 - 0.8574 = 0.1426$ (tức khoảng 14%).

Nói chung, nếu chúng ta thử nghiệm n giả thuyết, và mỗi lần thử nghiệm chúng ta chấp nhận một xác suất sai lầm là p , thì xác suất có ít nhất 1 sai lầm trong n lần thử nghiệm đó là $1 - (1 - p)^n$. Khi số lần kiểm định là $n = 10$ và $p = 0.05$ thì xác suất có ít nhất một kết luận sai lầm lên đến 40%!

“Bài học” rút ra từ cách lí giải trên là như sau: nếu chúng ta đọc một bài báo khoa học mà trong đó nhà nghiên cứu tiến hành nhiều thử nghiệm khác

nhau với các kết quả trị số $P < 0.05$, chúng ta có lí do để cho rằng xác suất mà một trong những cái-gọi-là “significant” (hay “có ý nghĩa thống kê”) đó rất cao. Chúng ta cần phải dè dặt với những kết quả phân tích như thế.

Đối với một người làm nghiên cứu, ý nghĩa của vấn đề thử nghiệm nhiều giả thuyết là: không nên “câu cá”. Xin nói thêm về khái niệm “câu cá” trong khoa học. Hãy tưởng tượng, một nhà nghiên cứu muốn tìm hiểu hiệu quả của một thuật điều trị mới cho các bệnh nhân đau khớp. Sau khi xem xét các nghiên cứu đã công bố trong y văn, nhà nghiên cứu quyết định tiến hành một nghiên cứu trên 300 bệnh nhân: phân nửa được điều trị bằng thuật mới, phân nửa chỉ sử dụng giả dược. Sau thời gian theo dõi, thu thập dữ liệu, nhà nghiên cứu phân tích và phát hiện sự khác biệt giữa hai nhóm không có ý nghĩa thống kê. Nói cách khác, thuật điều trị không có hiệu quả. Nhà nghiên cứu không chịu “đầu hàng”, nên tìm cho được một kết quả có ý nghĩa thống kê: chia bệnh nhân thành nhiều nhóm theo độ tuổi (trên 50 hay dưới 50), theo giới tính (nam hay nữ), thành phần kinh tế (có thu nhập cao hay thấp), và thói quen (chơi thể thao hay không). Tính chung, nhà nghiên cứu có 16 nhóm khác nhau, và có thể kiểm định 16 giả thuyết. Nhà nghiên cứu “khám phá” thuật điều trị có ý nghĩa thống kê trong nhóm phụ nữ tuổi trên 50 và có thu nhập cao. Và, kết quả trên được công bố. Đó là một qui trình làm việc mà giới nghiên cứu khoa học gọi là “fishing expedition” (một chuyến đi câu cá). Tất nhiên, một kết quả như thế không có giá trị khoa học và không thể tin được. (Với 16 kiểm định giả thuyết và với $P = 0.05$, xác suất mà một kiểm định có kết quả “significant” lên đến 55%, do đó chúng ta chẳng ngạc nhiên khi thấy có một “con cá” được bắt!)

Để cho kết quả trị số P có ý nghĩa nguyên thủy của nó trong bối cảnh thử nghiệm nhiều giả thuyết, các nhà nghiên cứu đề nghị sử dụng thuật điều chỉnh Bonferroni (tên của một nhà thống kê học người Ý từng đề nghị cách làm này). Theo đề nghị này, **trước khi** tiến hành nghiên cứu, nhà nghiên cứu phải xác định rõ giả thuyết nào là chính, và giả thuyết nào là phụ. Ngoài ra, nhà nghiên cứu còn phải đề ra kế hoạch sẽ thử nghiệm bao nhiêu giả thuyết **trước khi phân tích dữ liệu**. Chẳng hạn như nếu nhà nghiên cứu có kế hoạch thử nghiệm 20 so sánh và muốn giữ cho trị số P ở 0.05, thì thay vì dựa vào 0.05 là tiêu chuẩn để tuyên bố “significant”, nhà nghiên cứu phải dựa vào tiêu chuẩn 0.0025 (tức lấy 0.05 chia cho 20) để tuyên bố “significant”. Nói cách khác, chỉ khi nào một kết quả có trị số P thấp hơn 0.0025 (hay nói chung là P/n) thì nhà nghiên cứu mới có “quyền” tuyên bố kết quả đó có ý nghĩa thống kê.

6.4.3 Ý nghĩa thống kê không tương đương với ý nghĩa lâm sàng

Một sai lầm rất phổ biến trong giới y khoa là xem một khác biệt có “ý nghĩa thống kê” (statistical significance) tương đương với “ý nghĩa lâm sàng” (clinical significance). Có thể xem trị số P được tính toán từ tỉ số của tín hiệu (signal, mức độ khác biệt giữa hai nhóm) và nhiễu (noise hay độ dao động của mẫu). Gọi T là kiểm định thống kê, S là tín hiệu, và E là nhiễu, ý tưởng trên có thể mô tả như sau:

$$T = \frac{S}{E}$$

Khi số lượng cỡ mẫu tăng và nếu S bất biến thì T sẽ tăng, tức có cơ hội đạt ý nghĩa thống kê. Điều này có nghĩa là chúng ta có thể giảm E tối đa bằng cách tăng số lượng cỡ mẫu, và nó cũng có nghĩa là *một khác biệt rất nhỏ chẳng có ý nghĩa gì trong thực tế nhưng vẫn có thể có ý nghĩa thống kê*. Ngược lại, *một khác biệt hay ảnh hưởng (effect) lớn, nhưng nếu số lượng cỡ mẫu không đầy đủ không thể đạt được ngưỡng chuẩn “có ý nghĩa thống kê”* (tức $P > 0.05$).

Bảng 2 sau đây trình bày 4 nghiên cứu (tưởng tượng) với số cỡ mẫu khác nhau, từ 20 đến 2.000.000 bệnh nhân. Cột “Kết quả” trình bày số bệnh nhân được điều trị dứt bệnh và số trong ngoặc là phần trăm. Giả thuyết vô hiệu là xác suất kết quả 0.5 (tức 50%). Tất cả 4 nghiên cứu đều có trị số $P = 0.041$. Như có thể thấy qua bảng này, nghiên cứu 1 có tỉ lệ ảnh hưởng cao và có ý nghĩa lâm sàng (75%), và chỉ với 20 bệnh nhân, các nhà nghiên cứu có thể bác bỏ giả thuyết H_0 . Nhưng nghiên cứu 4, mức độ ảnh hưởng rất thấp (chỉ 50.07%, tức chỉ cao hơn giả thuyết vô hiệu 0.07%) nhưng vẫn có ý nghĩa thống kê vì số cỡ mẫu quá lớn!

Bảng 2. Ảnh hưởng của cỡ mẫu đến trị số P			
Nghiên cứu	Số lượng đối tượng	Kết quả điều trị thành công (%)	Trị số P
1	20	15 (75%)	0.041
2	200	114 (57%)	0.041
3	2000	1.046 (52,5%)	0.041
4	2.000.000	1.001.445 (50.07%)	0.041

Trong thực tế, có rất nhiều nghiên cứu mà độ khác biệt giữa hai nhóm rất nhỏ, nhưng vẫn có ý nghĩa thống kê [9-10]. Điều đáng quan tâm là kết quả có ý nghĩa thống kê như thế được các nhà nghiên cứu diễn dịch với hàm ý có ý nghĩa lâm sàng.

Ngược lại, có những nghiên cứu mà kết quả có ý nghĩa lâm sàng nhưng vì không đạt ngưỡng chuẩn $P < 0.05$, nên các nhà nghiên cứu lại diễn dịch rằng không có ý nghĩa lâm sàng! Chẳng hạn như một nghiên cứu về hiệu quả của bổ sung vitamin C và E ở phụ nữ mang thai [11], các nhà nghiên cứu kết luận rằng “Supplementation with vitamin C and E during pregnancy does not reduce the risk of serious outcomes in their infants” (Bổ sung vitamin C và E không làm giảm các triệu chứng lâm sàng nghiêm trọng). Nhưng khi xét qua số liệu thực tế thì thấy ở trẻ em mà mẹ có bổ sung vitamin C và E, tỉ lệ với triệu chứng lâm sàng giảm đến 21% ($P = 0.06$). Chỉ vì $P = 0.06$ mà các nhà nghiên cứu có xu hướng diễn dịch sai kết quả, và sai lầm này rất nghiêm trọng!

NHỮNG NGỘ NHẬN THÔNG THƯỜNG VỀ TRỊ SỐ P

1. Nếu $P = 0.05$, xác suất mà giả thuyết vô hiệu đúng là 5%.
2. Một kết quả với $P > 0.05$ (không có ý nghĩa thống kê) có nghĩa là không có khác biệt giữa hai nhóm.
3. Một kết quả có ý nghĩa thống kê cũng có ý nghĩa lâm sàng.
4. Những kết quả có cùng trị số P là bằng chứng phản biện lại giả thuyết vô hiệu.
5. $P = 0.05$ có nghĩa là dữ liệu quan sát được chỉ xảy ra 5% khi giả thuyết vô hiệu đúng.
6. $P = 0.05$ và $P < 0.05$ có ý nghĩa như nhau.
7. Trị số P phải viết một cách nghiêm chỉnh là $P < 0.02$ khi $P = 0.015$.
8. $P = 0.05$ có nghĩa là nếu chúng ta bác bỏ giả thuyết vô hiệu thì xác suất sai sót loại I là 5%.
9. Với ngưỡng $P = 0.05$, xác suất sai sót loại I là 5%.
10. Một kết luận khoa học nên dựa vào trị số P có ý nghĩa thống kê hay là không.

Tài liệu tham khảo

- [1] Wulff HR, Andersen B, Brandenhoff P, Guttler F. What do doctors know about statistics? *Statistics in Medicine* 1987; 6:3-10.
- [2] Karl Popper (28/07/1902 - 17/09/1994), người Áo, ông được xem là một triết gia khoa học hàng đầu của thế kỉ XX. Tác phẩm chính đầu tiên, *Logik der Forschung* (The Logic of Research), xuất bản năm 1934, được coi như là một tác phẩm kinh điển của phép phản nghiệm, một trường phái phổ biến của chủ nghĩa thực chứng logic (logical positivism), rồi tiếp cận đến khoa học được gọi là “chủ nghĩa phản nghiệm” (falsificationism), mà cơ sở dựa trên phép phê phán hơn là xác minh. Từ đó ông đã được thỉnh giảng ở Anh quốc, nơi sau này trở thành quê hương thứ hai của ông. Từ lí thuyết phản nghiệm của ông mà sau này người ta có thể phân định sự khác biệt giữa khoa học với ngụ khoa học. Ông nhận được rất nhiều giải thưởng vinh dự của cả

Hiệp hội Khoa học Chính trị Mỹ, Viện Hàn lâm Anh v.v... Ông đã được Nữ hoàng Elisabeth II phong tước hiệp sĩ năm 1965, và Huân chương Danh dự năm 1982. Ngoài tác phẩm nổi tiếng nêu trên ông đã cống hiến cho khoa học thế giới nhiều tác phẩm vô giá về triết lý khoa học.

- [3] Để biết triết lý phản nghiệm trong nghiên cứu lâm sàng, có thể đọc bài của Senn SJ. Falsificationism and clinical trials. *Stat Med* 1991 Nov;10(11):1679-92.
- [4] Fisher RA. On the interpretation of χ^2 from contingency tables, and the calculation of P. *Journal of the Royal Statistical Society* 1922; 85(1):87-94.
- [5] Fisher RA. *Statistical Methods for research workers*. Oliver and Boyd, 1954.
- [6] Neyman J, Pearson E. On the Problem of the Most Efficient Tests of Statistical Hypotheses. *Philosophical Transactions of the Royal Society of London. Series A, Containing Papers of a Mathematical or Physical Character* 1933; 231: 289-337.
- [7] Xem thêm chi tiết về những tranh luận liên quan đến kiểm định ý nghĩa thống kê và kiểm định giả thuyết trong sách *The Significance Test Controversy*, do DE Morrison và RE Henkel biên tập, Nhà xuất bản Aldine, Chicago: 1970.
- [8] Gigerenzer G, Swijtink Z, Porter T, Daston L, Beatty J, Kruger L. *The Empire of Chance: How Probability Changed Science and Everyday Life*. Cambridge University Press, 1989.
- [9] Barnard GA. Must clinical trials be large? The interpretation of P-values and the combination of test results. *Stat Med* 1990;9(6):601-14.
- [10] Barnard GA. On alleged gains in power from lower P-values. *Stat Med* 1989;8(12):1469-77.
- [11] Rumbold AR, Crowther CA, Haslam RR, Dekker GA, Robinson JS; ACTS Study Group. Vitamins C and E and the risks of preeclampsia and perinatal complications. *N Engl J Med* 2006;354(17):1796-806.

07

Văn phạm biểu đồ trong R

Yếu tố thị giác rất quan trọng. Quả thật, biểu đồ tốt có khả năng gây ấn tượng cho người đọc báo khoa học rất lớn, và thường có giá trị đại diện cho cả công trình nghiên cứu. Vì thế biểu đồ là một phương tiện hữu hiệu nhất để nhấn mạnh thông điệp của bài báo. Biểu đồ thường được sử dụng để thể hiện xu hướng và kết quả cho từng nhóm, nhưng cũng có thể dùng để trình bày dữ kiện một cách gọn gàng. Các biểu đồ dễ hiểu, nội dung phong phú là những phương tiện vô giá. Do đó, nhà nghiên cứu cần phải suy nghĩ một cách sáng tạo cách thể hiện số liệu quan trọng bằng biểu đồ. Vì thế, phân tích biểu đồ đóng một vai trò cực kì quan trọng trong phân tích thống kê. Có thể nói, không có đồ thị là phân tích thống kê không có nghĩa.

Trong ngôn ngữ R có rất nhiều cách để thiết kế một biểu đồ gọn và đẹp. Phần lớn những hàm để thiết kế biểu đồ có sẵn trong R, nhưng một số loại biểu đồ tinh vi và phức tạp khác có thể thiết kế bằng các package chuyên dụng như `lattice` có thể tải từ website của R. Chương này sẽ chỉ cách vẽ các biểu đồ thông dụng bằng cách sử dụng các hàm phổ biến trong R.

7.1 Môi trường và thiết kế biểu đồ


7.1.1 Nhiều biểu đồ cho một cửa sổ (windows)

Thông thường, R vẽ một biểu đồ cho một cửa sổ. Nhưng chúng ta có thể vẽ nhiều biểu đồ trong một cửa sổ bằng cách sử dụng hàm `par`. Chẳng hạn như `par(mfrow=c(1,2))` có hiệu năng chia cửa sổ ra thành một dòng và hai cột, tức là chúng ta có thể trình bày hai biểu đồ kề cạnh bên nhau. Còn

`par(mfrow=c(2,3))` chia cửa sổ ra thành 2 dòng và 3 cột, tức chúng ta có thể trình bày 6 biểu đồ trong một cửa sổ. Sau khi đã vẽ xong, chúng ta có thể quay về với “chế độ” 1 cửa sổ bằng lệnh `par(mfrow=c(1,1))`.

Ví dụ sau đây tạo ra một dữ liệu gồm hai biến x và y bằng phương pháp mô phỏng (tức số liệu hoàn toàn được tạo ra bằng R). Sau đó, chúng ta chia cửa sổ thành 2 dòng và 2 cột, và trình bày bốn loại biểu đồ từ dữ liệu được mô phỏng:

```
> par(mfrow=c(2,2))
> N <- 200
> x <- runif(N, -4, 4)
> y <- sin(x) + 0.5*rnorm(N)
> plot(x,y, main="Scatter plot of y and x")
> hist(x, main="Histogram of x")
> boxplot(y, main="Box plot of y")
> barplot(x, main="Bar chart of x")
> par(mfrow=c(1,1))
```




Biểu đồ 1. Cách chia cửa sổ thành 2 dòng và 2 cột và trình bày 4 biểu đồ trong cùng một cửa sổ.

7.1.2 Đặt tên cho trục tung và trục hoành

Biểu đồ thường có trục tung (y-axis) và trục hoành. Vì dữ liệu thường được gọi bằng các chữ viết tắt, cho nên biểu đồ cần phải có tên cho từng biến để dễ theo dõi. Trong ví dụ sau đây, biểu đồ bên trái không có tên mà chỉ dùng tên của biến gốc (tức x và y), còn bên phải có tên dễ hiểu hơn.

```
> par(mfrow=c(1,2))
> N <- 200
> x <- runif(N, -4, 4)
> y <- sin(x) + 0.5*rnorm(N)
> plot(x,y)
> plot(x, y, xlab="X factor",
       ylab="Production",
       main="Production and x factor \n Second line of
title here")
> par(mfrow=c(1,1))
```


Trong các lệnh trên, xlab (viết tắt từ x label) và ylab (viết tắt từ y label) dùng để đặt tên cho trục hoành và trục tung. Còn main được dùng để đặt tên cho biểu đồ. Chú ý rằng trong main có kí hiệu \n dùng để viết dòng thứ hai (nếu tên gọi biểu đồ quá dài).



Biểu đồ 2. Biểu đồ bên trái không có tên gọi, biểu đồ bên phải có tên gọi cho trục tung, trục hoành và tên của biểu đồ.

Ngoài ra, chúng ta còn có thể sử dụng hàm `title` và `sub` để đặt tên:

```
> plot(x, y, xlab="Time", ylab="Production")  
> title(main="Plot of production and x factor",  
sub="Figure 1")
```



7.1.3 Cho giới hạn của trục tung và trục hoành


Nếu không cung cấp giới hạn của trục tung và trục hoành, R sẽ tự động tìm điều chỉnh và cho các số liệu này. Tuy nhiên, chúng ta cũng có thể kiểm soát biểu đồ bằng cách sử dụng `xlim` và `ylim` để cho R biết cụ thể giới hạn của hai trục này:

```
> plot(x, y, xlab="X factor",  
ylab="Production",  
main="Plot of production and x factor",  
xlim=c(-5, 5),  
ylim=c(-3, 3))
```

7.1.4 Thể loại và đường biểu diễn

Trong một dãy biểu đồ, chúng ta có thể yêu cầu R vẽ nhiều kiểu và đường biểu diễn khác nhau.


```
> par(mfrow=c(2,2))
> plot(y, type="l"); title("lines")
> plot(y, type="b"); title("both")
> plot(y, type="o"); title("overstruck")
> plot(y, type="h"); title("high density")
```



Biểu đồ 3. Kiểu biểu đồ và đường biểu diễn.

Ngoài ra, chúng ta cũng có thể biểu diễn nhiều đường bằng `lty` như sau:

```
> par(mfrow=c(2,2))
> plot(y, type="l", lty=1); title(main="Production data",
sub="lty=1")
> plot(y, type="l", lty=2); title(main="Production data",
sub="lty=2")
> plot(y, type="l", lty=3); title(main="Production data",
sub="lty=3")
> plot(y, type="l", lty=4); title(main="Production data",
sub="lty=4")
```


Biểu đồ 4. Ảnh hưởng của `lty`.

7.1.5 Màu sắc, khung, và kí hiệu

Chúng ta có thể kiểm soát màu sắc của một biểu đồ bằng lệnh `col`. Giá trị mặc định của `col` là 1. Tuy nhiên, chúng ta có thể thay đổi các màu theo ý muốn hoặc bằng cách cho số hoặc bằng cách viết ra tên màu như "red", "blue", "green", "orange", "yellow", "cyan", v.v...

Ví dụ sau đây dùng một hàm để vẽ ba đường biểu diễn với ba màu đỏ, xanh nước biển, và xanh lá cây:


```
> plot(runif (10), ylim=c(0,1), type='l')
> for (i in c('red', 'blue', 'green'))
{
  lines(runif (10), col=i )
}
> title(main="Lines in various colours")
```



Lưu ý: Do sách được in trắng đen, Quý độc giả vui lòng tham khảo thêm các biểu đồ màu bằng cách nhập lệnh trực tiếp từ sách vào phần mềm R.

Ngoài ra, chúng ta còn có thể vẽ đường biểu diễn bằng cách tăng bề dày của mỗi đường:

```
> plot(runif(5), ylim=c(0,1), type='n')
> for (i in 5:1) {
  lines( runif(5), col=i, lwd=i ) }
> title(main="Varying the line thickness")
```




Hình dạng của biểu đồ cũng có thể thay đổi bằng type như sau:

```
> op <- par(mfrow=c(3,2))
> plot(runif(5), type = 'p',
```

```

main = "plot type 'p' (points)"
> plot(runif(5), type = 'l',
      main = "plot type 'l' (lines)")
> plot(runif(5), type = 'b',
      main = "plot type 'b' (both points and lines)")
> plot(runif(5), type = 's',
      main = "plot type 's' (stair steps)")
> plot(runif(5), type = 'h',
      main = "plot type 'h' (histogram)")
> plot(runif(5), type = 'n',
      main = "plot type 'n' (no plot)")
> par(op)

```



Khung biểu đồ có thể kiểm soát bằng lệnh `bty` với các thông số như sau:


<code>bty="n"</code>	Không có vòng khung chung quanh biểu đồ
<code>bty="o"</code>	Có 4 khung chung quanh biểu đồ
<code>bty="c"</code>	Vẽ một hộp gồm 3 cạnh chung quanh biểu đồ theo hình chữ C
<code>bty="l"</code>	Vẽ hộp 2 cạnh chung quanh biểu đồ theo hình chữ L
<code>bty="7"</code>	Vẽ hộp 2 cạnh chung quanh biểu đồ theo hình số 7

Cách hay nhất để bạn đọc làm quen với các cách vẽ biểu đồ này là bằng cách thử trên R để biết rõ hơn.

Kí hiệu của một biểu đồ cũng có thể thay thế bằng cách cung cấp số cho pch (plotting character) trong R. Các kí hiệu thông dụng là:

Available symbols																								
○	1	▽	6	⊠	11	●	16	●	21															
△	2	⊞	7	⊞	12	▲	17	■	22															
+	3	*	8	⊗	13	◆	18	◆	23															
×	4	⊞	9	⊞	14	●	19	▲	24															
◇	5	⊕	10	■	15	●	20	▼	25															

```
> plot(x, y, col="red", pch=16, bty="l")
```




Biểu đồ 5. Ảnh hưởng của pch=16 và col="red", bty="l".

7.1.6 Ghi chú (legend)

Hàm `legend` rất có ích cho việc ghi chú một biểu đồ và giúp người đọc hiểu được ý nghĩa của biểu đồ tốt hơn. Cách sử dụng `legend` có thể minh họa bằng ví dụ sau đây:

```
> N <- 200
> x <- runif(N, -4, 4)
> y <- x + 0.5*rnorm(N)
> plot(x,y, pch=16, main="Scatter plot of y and x")
> reg <- lm(y~x)
> abline(reg)
> legend(2,-2, c("Production", "Regression line"),
pch=16, lty=c(0,1))
```

Thông số `legend(2, -2)` có nghĩa là đặt phần ghi chú vào trục hoành (x-axis) bằng 2 và trục tung (y-axis) bằng -2.




Biểu đồ 6. Ảnh hưởng của legend.

7.1.7 Viết chữ trong biểu đồ

Phần lớn các biểu đồ không cung cấp phương tiện để viết chữ hay ghi chú trong biểu đồ, hay có cung cấp nhưng rất hạn chế. Trong R có hàm `mtext()` cho phép chúng ta đặt chữ viết hay giải thích bên cạnh hay trong biểu đồ.

Bắt đầu từ phía dưới của biểu đồ (`side=1`), chúng ta chuyển theo hướng kim đồng hồ đến cạnh số 4. Lệnh `plot` trong ví dụ sau đây không in tên của trục và tên của biểu đồ, nhưng chỉ cung cấp một cái khung. Trong ví dụ này, chúng ta sử dụng `cex` (character expansion) để kiểm soát kích thước của chữ viết. Theo mặc định thì `cex=1`, nhưng với `cex=2`, chữ viết sẽ có kích thước gấp hai lần kích thước mặc định. Lệnh `text()` cho phép chúng ta đặt chữ viết vào một vị trí cụ thể. Lệnh thứ nhất đặt chữ viết trong ngoặc kép và trung tâm tại `x=15`, `y=4.3`. Qua sử dụng `adj`, chúng ta còn có thể sắp xếp về phía trái (`adj=0`) sao cho tọa độ là điểm xuất phát của chữ viết.

```
plot(y, xlab=" ", ylab=" ", type="n")
> mtext("Text on side 1, cex=1", side=1, cex=1)
> mtext("Text on side 2, cex=1.2", side=2, cex=1.2)
> mtext("Text on side 3, cex=1.5", side=3, cex=1.5)
> mtext("Text on side 4, cex=2", side=4, cex=2)
> text(15, 4.3, "text(15, 4.3)")
> text(35, 3.5, adj=0, "text(35, 3.5), left aligned")
> text(40, 5, adj=1, "text(40, 5), right aligned")
```



7.1.8 Đặt kí hiệu vào biểu đồ

`abline()` có thể sử dụng để vẽ một đường thẳng, với những thông số như sau:

`abline(a,b)` : đường hồi qui tuyến tính $a = \text{intercept}$ và $b = \text{slope}$.


`abline(h=30)`: vẽ một đường ngang tại $y = 30$.

`abline(v=12)`: vẽ một đường thẳng đứng tại điểm $x = 12$.

Ngoài ra, chúng ta còn có thể cho vào biểu đồ một mũi tên để ghi chú một điểm số liệu nào đó.


```
> N <- 200
> x <- runif(N, -4, 4)
> y <- x + 0.5*rnorm(N)
> plot(x,y, pch=16, main="Scatter plot of y and x")
```

Scatter plot of y and x



Giả sử chúng ta muốn ghi chú ngay tại $x = 0$ và $y = 0$ là điểm trung tâm, chúng ta trước hết dùng `arrows` để vẽ mũi tên. Trong lệnh sau đây, `arrows(-1, 1, 1.5, 1.5)` có nghĩa như sau tọa độ $x = -1, y = 1$ bắt đầu vẽ mũi tên và chấm dứt tại tọa độ $x = 1.5, y = 1.5$. Phần `text(0, 1)` yêu cầu R viết chữ tại tọa độ $x = 0, y = 1$.

```
> arrows(-1, 1.0, 1.5, 1.5)
> text(0, 1, "Trung tam", cex=0.7)
```



7.2 Số liệu cho phân tích biểu đồ

Sau khi đã biết qua môi trường và những lựa chọn để thiết kế một biểu đồ, bây giờ chúng ta có thể sử dụng một số hàm thông dụng để vẽ các biểu đồ cho số liệu. Biểu đồ có thể chia thành 2 loại chính: biểu đồ dùng để mô tả một biến số và biểu đồ về mối liên hệ giữa hai hay nhiều biến số. Tất nhiên, biến số có thể là liên tục hay không liên tục, cho nên, trong thực tế, chúng ta có 4 loại biểu đồ. Trong phần sau đây, chúng ta sẽ điểm qua các loại biểu đồ, từ đơn giản đến phức tạp.

Có lẽ cách tốt nhất để tìm hiểu cách vẽ đồ thị bằng R là bằng một dữ liệu thực tế. Quay lại **ví dụ 2** trong chương trước, chúng ta có dữ liệu gồm 8 cột (hay biến số): `id`, `sex`, `age`, `bmi`, `hdl`, `ldl`, `tc`, và `tg`. (Chú ý, `id` là mã số của 50 đối tượng nghiên cứu; `sex` là giới tính (nam hay nữ); `age` là độ tuổi;

bmi là tỉ số trọng lượng; hdl là high density cholesterol; ldl là low density cholesterol; tc là tổng số - total - cholesterol; và tg triglycerides). Dữ liệu được chứa trong directory c:\works\insulin dưới tên chol.txt. Trước khi vẽ đồ thị, chúng ta bắt đầu bằng cách nhập dữ liệu này vào R.

```
> setwd("c:/works/stats")
> cong <- read.table("chol.txt", header=TRUE,
                      na.strings=".")
> attach(cong)
```

Hay để tiện việc theo dõi chúng ta sẽ nhập các dữ liệu đó bằng các lệnh sau đây:

```
sex <- c("Nam", "Nu", "Nu", "Nam",
         "Nam", "Nu", "Nam", "Nam", "Nam", "Nu",
         "Nu", "Nam", "Nu", "Nam", "Nam", "Nu", "Nu", "Nu",
         "Nu", "Nu", "Nu", "Nu", "Nu", "Nu", "Nam", "Nam",
         "Nu", "Nam", "Nu", "Nu", "Nu", "Nam", "Nam", "Nu",
         "Nu", "Nam", "Nu", "Nam", "Nu", "Nu", "Nam",
         "Nu", "Nam", "Nam", "Nam", "Nu", "Nam", "Nam", "Nu",
         "Nu")
age <- c(57, 64, 60, 65, 47, 65, 76, 61, 59, 57,
        63, 51, 60, 42, 64, 49, 44, 45, 80, 48,
        61, 45, 70, 51, 63, 54, 57, 70, 47, 60,
        60, 50, 60, 55, 74, 48, 46, 49, 69, 72,
        51, 58, 60, 45, 63, 52, 64, 45, 64, 62)

bmi <- c(17, 18, 18, 18, 18, 18, 19, 19, 19, 19, 20,
        20, 20, 20, 20, 20, 21, 21, 21, 21, 21, 21,
        21, 21, 22, 22, 22, 22, 22, 22, 22, 22, 22,
        22, 23, 23, 23, 23, 23, 23, 23, 23, 24, 24,
        24, 24, 24, 24, 25, 25)
```

```
hdl <- c(5.000,4.380,3.360,5.920,6.250,4.150,0.737,7.170,
        6.942,5.000, 4.217,4.823,3.750,1.904,6.900,
        0.633,5.530,6.625,5.960,3.800,5.375,3.360,5.000,
        2.608,4.130,5.000,6.235,3.600,5.625,5.360,6.580,
        7.545,6.440,6.170,5.270,3.220,5.400,6.300,
        9.110,7.750, 6.200,7.050,6.300,5.450,5.000,
        3.360,7.170,7.880,7.360,7.750)
```

```
ldl <- c(2.0, 3.0, 3.0, 4.0, 2.1, 3.0, 3.0, 3.0, 3.0,
        2.0, 5.0, 1.3, 1.2, 0.7, 4.0, 4.1, 4.3, 4.0,
        4.3, 4.0, 3.1, 3.0, 1.7, 2.0, 2.1, 4.0, 4.1,
        4.0, 4.2, 4.2, 4.4, 4.3, 2.3, 6.0, 3.0, 3.0,
        2.6, 4.4, 4.3, 4.0, 3.0, 4.1, 4.4, 2.8, 3.0,
        2.0, 1.0, 4.0, 4.6, 4.0)
```

```
tc <-c (4.0, 3.5, 4.7, 7.7, 5.0, 4.2, 5.9, 6.1, 5.9,
        4.0, 6.2, 4.1, 3.0, 4.0, 6.9, 5.7, 5.7, 5.3,
        7.1, 3.8, 4.3, 4.8, 4.0, 3.0, 3.1, 5.3, 5.3,
        5.4, 4.5, 5.9, 5.6, 8.3, 5.8, 7.6, 5.8, 3.1,
        5.4, 6.3, 8.2, 6.2, 6.2, 6.7, 6.3, 6.0, 4.0,
        3.7, 6.1, 6.7, 8.1, 6.2)
```

```
tg <- c(1.1, 2.1, 0.8, 1.1, 2.1, 1.5, 2.6, 1.5, 5.4, 1.9,
        1.7, 1.0, 1.6, 1.1, 1.5, 1.0, 2.7, 3.9, 3.0, 3.1,
        2.2, 2.7, 1.1, 0.7, 1.0, 1.7, 2.9, 2.5, 6.2, 1.3,
        3.3, 3.0, 1.0, 1.4, 2.5, 0.7, 2.4, 2.4, 1.4, 2.7,
        2.4, 3.3, 2.0, 2.6, 1.8, 1.2, 1.9, 3.3, 4.0, 2.5)
```

```
cong <- data.frame(sex, age, bmi, hdl, ldl, tc, tg)
```

Sau khi đã có số liệu, chúng ta sẵn sàng tiến hành phân tích số liệu bằng biểu đồ như sau:

7.3 Biểu đồ cho một biến số rời rạc (discrete variable): barplot

Biến `sex` trong dữ liệu trên có hai giá trị (nam và nu), tức là một biến không liên tục. Chúng ta muốn biết tần số của giới tính (bao nhiêu nam và bao nhiêu nữ) và vẽ một biểu đồ đơn giản. Để thực hiện ý định này, trước hết, chúng ta cần dùng hàm `table` để biết tần số:


```
> sex.freq <- table(sex)
> sex.freq
sex
Nam Nu
22 28
```

Có 22 nam và 28 nữ trong nghiên cứu. Sau đó dùng hàm `barplot` để thể hiện tần số này như sau:

```
> barplot(sex.freq, main= "Frequency of males
and females")
```


Biểu đồ trên cũng có thể có được bằng một lệnh đơn giản hơn (**Biểu đồ 7a**):

```
> barplot(table(sex), main= "Frequency of males
and females")
```



Biểu đồ 7a.

Tần số giới tính thể hiện bằng cột số.



Biểu đồ 7b.

Tần số giới tính thể hiện bằng dòng số.

Thay vì thể hiện tần số nam và nữ bằng 2 cột, chúng ta có thể thể hiện bằng hai dòng bằng thông số `horiz = TRUE`, như sau (xem kết quả trong **Biểu đồ 7b**):

```
> barplot(sex.freq,
          horiz = TRUE,
          col = rainbow(length(sex.freq)),
          main="Frequency of males and females")
```

7.4 Biểu đồ cho hai biến số rời rạc (discrete variable): barplot

Age là một biến số liên tục. Chúng ta có thể chia bệnh nhân thành nhiều nhóm dựa vào độ tuổi. Hàm `cut` có chức năng “cắt” một biến liên tục thành nhiều nhóm rời rạc. Chẳng hạn như:

```
> ageg <- cut(age, 3)
> table(ageg)

ageg
(42,54.7] (54.7,67.3] (67.3,80]
      19      24      7
```

Có hiệu quả chia biến `age` thành 3 nhóm. Tần số của ba nhóm này là: 42 tuổi đến 54.7 tuổi thành nhóm 1, 54.7 đến 67.3 thành nhóm 2, và 67.3 đến 80 tuổi thành nhóm 3. Nhóm 1 có 19 bệnh nhân, nhóm 2 và 3 có 24 và 7 bệnh nhân.

Bây giờ chúng ta muốn biết có bao nhiêu bệnh nhân trong từng độ tuổi và từng giới tính bằng lệnh `table`:

```
> age.sex <- table(sex, ageg)
> age.sex

ageg
sex (42,54.7] (54.7,67.3] (67.3,80]
Nam   10      10      2
Nu    9      14      5
```


Kết quả trên cho thấy chúng ta có 10 bệnh nhân nam và 9 nữ trong nhóm tuổi thứ nhất, 10 nam và 14 nữ trong nhóm tuổi thứ hai, v.v... Để thể hiện tần số của hai biến này, chúng ta vẫn dùng `barplot`:

```
> barplot(age.sex, main="Number of males and females in
each age group")
```



Biểu đồ 8a.

Tần số giới tính và nhóm tuổi thể hiện bằng cột số.



Biểu đồ 8b.

Tần số giới tính và nhóm tuổi thể hiện bằng hai dòng số.

Trong **Biểu đồ 8a**, mỗi cột là cho một độ tuổi, và phần đậm của cột là nữ, và phần màu nhạt là tần số của nam giới. Thay vì thể hiện tần số nam nữ trong một cột, chúng ta cũng có thể thể hiện bằng 2 cột với `beside=T` như sau (**Biểu đồ 8b**):

```
barplot(age.sex, beside=TRUE, xlab="Age group")
```

08

Phân tích dữ liệu bằng biểu đồ

Phân tích dữ liệu có thể thực hiện qua phân tích thống kê và phân tích đồ thị. Cả hai phương pháp đều có thể sử dụng để phân tích mô tả và phân tích suy luận. Biểu đồ là một phương tiện phản ánh dữ liệu rất quan trọng. Một biểu đồ nếu được soạn tốt có thể đi vào lịch sử khoa học, hay ít ra cũng xuất hiện vĩnh viễn trên bài báo khoa học và sách giáo khoa. Để có một biểu đồ tốt, đòi hỏi người phân tích phải đầu tư khá nhiều thời gian để suy nghĩ và soạn. Mỗi loại biểu đồ có mục đích riêng, và đòi hỏi phải suy nghĩ cẩn thận để chọn biểu đồ thích hợp.

Biểu đồ khoa học rất phổ biến và xuất hiện dưới nhiều dạng, từ mô tả đến phân tích. Những dạng biểu đồ thông dụng bao gồm:

- Biểu đồ bánh (pie chart)
- Biểu đồ thanh (bar chart)
- Biểu đồ phân bố (histogram)
- Biểu đồ hộp (box plot)
- Biểu đồ tán xạ (scatter plot)

Ngày nay, rất ít ai sử dụng biểu đồ bánh, biểu đồ thanh vì chúng không phản ánh tốt phân bố của dữ liệu. Có người nói thẳng rằng biểu đồ bánh là loại vô dụng nhất trong khoa học!


Để giới thiệu phân tích biểu đồ, chúng ta cần làm quen với dữ liệu insulin.txt dưới đây. Dữ liệu về nghiên cứu insulin trên 80 bệnh nhân. Dữ liệu thu thập bao gồm:

- **id** - mã số của đối tượng nghiên cứu
- **sex** - giới tính (0, 1)
- **age** - tuổi
- **bmi** - tỉ trọng cơ thể (cân nặng kg, chia cho chiều cao bình phương m²)
- Đo độ dày của da ở **abd** (vùng bụng), **subscapular** (vai), **supra-iliac** (vùng xương chậu), **triceps** (phần trên của tay)
- Đo chu vi của **hc** (mông) và **wc** (eo);
- Nồng độ **hdl**, **ldl**, **tc**, **tg** trong máu
- Huyết áp tâm trương (**diast**) và tâm thu (**syst**)
- Nồng độ **insulin**, **glucose** trong máu, và sau cùng là **ir** (kháng insulin).

8.1 Biểu đồ phân bố (histogram)


Chúng ta muốn vẽ một biểu đồ phân bố giá trị của nồng độ hdl. Cách đơn giản nhất là dùng hàm **hist(hdl)**. Tuy nhiên, hàm đơn giản này cần phải “trang trí” thêm bằng một số options như tăng số cột và màu:

```
hist(hdl, breaks=20, col="blue", border="white")
```



Nhìn qua biểu đồ này, chúng ta thấy chưa hoàn chỉnh. Cần phải thêm nhãn cho trục hoành và trục tung, và nói rộng giới hạn giá trị của trục hoành. Ngoài ra, cần phải thêm một tiêu đề (main) cho biểu đồ:


```
hist(hdl, breaks=20, col="blue", border="white",  
xlab="HDL Cholesterol", ylab="Frequency", xlim=c(0,10),  
main="Distribution of HDL")
```



Thỉnh thoảng, chúng ta cần một đường biểu diễn mật độ phân bố (density) cho dữ liệu. Chúng ta có thể dùng hàm `density()` cho mục tiêu này. Tuy nhiên, cần phải thay đổi trục tung, thay vì là “frequency”, để vẽ density chúng ta cần đơn vị xác suất với option `prob=T`:

```
hist(hdl, prob=T, breaks=20, col="blue", border="white",  
xlab="HDL Cholesterol", ylab="Frequency", xlim=c(0,10),  
main="Distribution of HDL")
```

```
lines(density(na.omit(hdl)), col="red", lwd=2)
```





8.2 Biểu đồ hộp (box plot)

Biểu đồ hộp là một trong những biểu đồ phổ biến nhất trong nghiên cứu khoa học. Biểu đồ hộp cung cấp rất nhiều thông tin về phân bố của một biến số kèm theo những chỉ số thống kê cơ bản. Biểu đồ hộp dưới đây mô tả dữ liệu về lượng mỡ toàn thân (whole body fat mass, đơn vị kg) của 611 nam và nữ người Việt. Biểu đồ hộp cung cấp cho chúng ta những thông tin sau đây:

- **Trung vị** thể hiện bằng thanh ngang màu đậm. Ở đây, chúng ta thấy số trung vị là khoảng 17 kg (chính xác là 16.8 kg). Nói cách khác, có 50% đối tượng có lượng mỡ 16.8 kg hoặc thấp hơn, và 50% người có lượng mỡ trên 16.8 kg. Biểu đồ hộp không cung cấp giá trị trung bình, vì nếu phân bố của biến tuân theo luật phân phối chuẩn (normal distribution) thì trung vị bằng trung bình.
- **Bách phân vị thứ 25** (Quartile 1 hay Q1), thanh ngang màu nhạt hơn nằm phía dưới của thanh trung vị. Chúng ta thấy Q1 là 13.7 kg. Nói cách khác, có 25% đối tượng có lượng mỡ 13.7 kg hoặc thấp hơn.


- **Bách phân vị thứ 75 (Quartile 3 hay Q3)**, thanh ngang màu nhạt hơn nằm phía trên của thanh trung vị. Chúng ta thấy Q3 là 20.3 kg. Nói cách khác, có 75% đối tượng có lượng mỡ 20.3 kg hoặc thấp hơn.
- Hiệu số giữa Q3 và Q1 được gọi là **interquartile range (IQR)**. Trong ví dụ này, $IQR = 20.3 - 13.7 = 6.6$ kg.
- Biểu đồ hộp còn có 2 “râu” (hay whisker) phía trên và phía dưới. Khoảng cách giữa Q1 và râu dưới là $Q1 - 1.5 \cdot IQR$. Tương tự, khoảng cách từ Q3 đến râu trên là $Q3 + 1.5 \cdot IQR$.
- Những giá trị nằm phía trên của râu trên (tức cao hơn $Q3 + 1.5 \cdot IQR$) có thể là giá trị ngoại vi (outlier). Xin nhấn mạnh là chỉ “có thể”, vì chúng ta chưa kiểm định xem những giá trị này thật sự là ngoại vi.



Với những mô tả về biểu đồ hộp trên, chúng ta sẽ sử dụng R vẽ biểu đồ hộp cho dữ liệu đang có. Giả dụ chúng ta muốn xem qua phân bố biến HDL, có thể dùng hàm sau đây:


```
boxplot(hdl, notch=T, col="blue", main="")
```

Trong hàm trên, hdl là biến cần mô tả. Chúng ta thêm option notch=T để biểu đồ có “eo”. Ngoài ra, col=“blue” là yêu cầu màu của hộp là màu xanh. Kết quả của hàm trên là:



Biểu đồ trên là đơn biến. Nếu chúng ta muốn so sánh HDL giữa nam và nữ, và trong dữ liệu đó là biến “sex”. Hàm trên có thể sửa lại như sau:

```
boxplot(hdl ~ sex, col="blue", notch=T, names=c("Men",
"Women"))
```




8.3 Biểu đồ tương quan

Một trong những biểu đồ phổ biến trong khoa học là biểu đồ tương quan, còn gọi là biểu đồ “tán xạ” (scatter plot). Nếu chúng ta muốn biết mối tương quan giữa BMI (body mass index) và insulin, một biểu đồ tương quan có thể đáp ứng mục tiêu trên. Trong R có hàm đơn giản là **plot(insulin ~ bmi)**; trong đó, biến đầu tiên là trục tung (y-axis) và biến thứ hai là trục hoành (x-axis). Hai biến được cách nhau bởi dấu ~ (hàm).


Tuy nhiên, chúng ta có thể thêm nhãn cho biến x và biến y, và kí hiệu biểu đồ bằng hàm dưới đây:

```
plot(insulin ~ bmi, pch=16, xlab="Body mass index",  
     ylab="Insulin")
```



Trong nhiều trường hợp, chúng ta muốn có vài ý tưởng về mối liên quan bằng một đường thẳng. Hàm **abline** có thể đáp ứng mục tiêu đó. Chú ý hàm **abline** thực ra là lấy output từ hàm **lm** (linear model). Khi hàm **lm(insulin ~ bmi)** chạy, chúng ta sẽ có một phương trình hồi qui tuyến tính $\text{insulin} = a + b \cdot \text{bmi}$. Giá trị a và b sẽ được **abline** dùng để vẽ đường biểu diễn:


```
abline(lm(insulin ~ bmi))
```



Biểu đồ trên khá tốt; tuy nhiên, trong package car có hàm `scatterplot` có thể vẽ biểu đồ tương quan tốt hơn, và cung cấp cả biểu đồ hộp cho biến x và biến y:

```
library(car)
```


```
scatterplot(insulin ~ bmi, pch=16, smooth=F, col="blue",  
lwd=2, xlab="Body mass index", ylab="Insulin")
```



Giả dụ, chúng ta muốn biết mối liên quan giữa insulin và BMI theo giới tính. Đây cũng là một hình thức phân tích tương tác (interaction analysis). Biến giới tính trong dữ liệu là sex. Do đó, hàm scatter có thể thêm như sau:

```
scatterplot(insulin ~ bmi | sex, pch=c(16, 14),
smooth=F, col=c("blue", "red"), lwd=c(1,2),
xlab="Body mass index", ylab="Insulin")
```

Kết quả cho thấy mối liên quan giữa insulin và BMI có thể khác biệt giữa nam và nữ.



8.4 Biểu đồ tương quan đa biến


Biểu đồ tương quan trên chỉ mô tả mối liên quan giữa 2 biến. Trong nhiều trường hợp, chúng ta muốn biết cùng một lúc mối tương quan của nhiều biến. Hàm `pairs.panels` trong package `psych` có thể đáp ứng mục tiêu phân biến đa biến rất tuyệt vời. Hàm `pairs.panels` có thể sử dụng qua 2 bước.

Bước I là nhập package `psych`. Sau đó là cho các biến cần phân tích vào một đối tượng. Trong ví dụ sau đây, các biến `age`, `bmi`, `whr`, `hdl`, `ldl`, `insulin`, `ir` được cho vào object có tên là `vars`.

```
library(psych)
vars = cbind(age, bmi, whr, hdl, ldl, insulin, ir)
```

Bước II là áp dụng hàm `pairs.panels` cho đối tượng `vars`:

```
pairs.panels(vars)
```



Như chúng ta thấy, biểu đồ trên thực chất là một ma trận biểu đồ. Phần dưới của ma trận là biểu đồ tương quan cho từng biến và đường biểu diễn. Phần trên của ma trận là hệ số tương quan, với kích thước tăng theo mức độ tương quan. Các ô trong đường chéo vẽ phân bố của từng biến. Đây là một biểu đồ cung cấp khá nhiều thông tin và có ích. Tuy nhiên, khi số biến tăng thì biểu đồ sẽ hơi khó đọc!

8.5 Biểu đồ với ggplot2

Có thể xem ggplot2 là một “phần mềm” trong R, vì ggplot2 có các hàm hoàn chỉnh để xây dựng những loại biểu đồ có chất lượng cao. ggplot2 do Hadley Wickham phát triển dựa trên triết lý của “The Grammar of Graphics” của Wilkinson. Wickham xuất bản một cuốn sách hướng dẫn cách sử dụng ggplot2. Trong chương này, tôi sẽ mô tả một số hàm để xây dựng những biểu đồ phổ biến trong khoa học.

Trong ggplot2 có 2 hàm chính là **qplot** và **ggplot**. Hàm qplot chủ yếu dành cho những trường hợp vẽ biểu đồ nhanh và không cần “trang trí” nhiều. Hàm ggplot là hàm chính trong ggplot2 dùng để vẽ tất cả các đồ thị đơn giản và phức tạp. Để sử dụng ggplot, chúng ta cần phải làm quen với một số cú pháp và “ngôn ngữ” của ggplot2:

- data là dataframe trong R;
- aesthetic là các biến cần thiết để vẽ và trang trí;
- geometric object là các đối tượng hình hay dạng biểu đồ;
- faceting dùng cho trường hợp nhiều biểu đồ;

Ví dụ như một hàm tiêu biểu của ggplot là:

```
p = ggplot(data=, aes(x=, y=))  
p + geom_yyyy
```

trong đó yyy = bar, boxplot, histogram, density, line, abline, area, jitter, rug, freqpoly, map, point, quantile, v.v.

Chú ý trong hàm trên ggplot(data=, aes(x=, y=)) được lưu trữ trong object p, và các hàm sau đó chỉ cộng thêm vào p. Đây là một điểm hoàn toàn mới của ggplot2.

Để minh họa cho việc sử dụng qplot xây dựng biểu đồ chúng ta cần phải làm việc trên một dữ liệu. Dữ liệu sau đây được đơn giản hoá từ kết quả kiểm định PISA liên quan đến học sinh Việt Nam. Dữ liệu bao gồm kết quả kiểm tra về môn toán, khoa học, và đọc hiểu cho 4959 học sinh 15 tuổi. Các biến cụ thể trong dữ liệu như sau:

- **REGION** là vùng, bao gồm các giá trị CENTRAL, NORTH, SOUTH;
- **TYPE** là loại trường công hay tư, với hai giá trị PUBLIC, PRIVATE;
- **AREA** là địa điểm của trường, với giá trị REMOTE (vùng sâu xa), RURAL (nông thôn) và URBAN (thành thị);
- **GENDER** chỉ giới tính, với hai giá trị Male và Female;
- **MATH** là điểm khả dĩ về môn toán, là một biến liên tục, giá trị từ 200 đến 850;
- **READING** là điểm khả dĩ về môn đọc và hiểu, là một biến liên tục, giá trị từ 200 đến 850;
- **SCIENCE** là điểm khả dĩ về môn khoa học, là một biến liên tục, giá trị từ 200 đến 850.

8.5.1 Biểu đồ phân bố (histogram)


Chúng ta muốn xem qua phân bố của biến MATH, tức điểm toán của tất cả học sinh. Hàm đơn giản nhất là

```
qplot(MATH)
```

nhưng đồ thị không được đẹp như chúng ta mong đợi. Một cách khác là dùng qplot kèm theo hàm geom_histogram:

```
qplot(MATH) + geom_histogram(col="white", fill="blue")
```

chúng ta sẽ có biểu đồ sau đây:




Tuy nhiên, qplot không thể vẽ mật độ phân bố. Do đó, để vẽ mật độ phân bố, chúng ta phải dùng đến hàm ggplot như sau:

```
p = ggplot(data=pisa, aes(MATH))
```

```
p + geom_histogram(binwidth=20, aes(y=..density..),  
col="white", fill="blue", lwd=0.5)
```


```
+ geom_density()
```

```
+ labs(x="MATH SCORE", y="Frequency")
```



Phân bố trên là cho tất cả các học sinh. Giả dụ chúng ta muốn có phân bố cho từng vùng, và chúng ta cần đến facet như sau:


```
qplot(MATH, col=AREA, geom="histogram", facets=~AREA)
```



Chúng ta cũng có thể xem qua phân bố điểm toán cho từng vùng và miền qua hàm ggplot như sau:


```
p = ggplot(data=pisa, aes(MATH))

p + geom_histogram(binwidth=20, aes(y=..density..),
  col="white", fill="blue", lwd=0.5) + geom_density()
+ facet_grid(REGION ~ AREA)
```



Nhưng thay vì vẽ trong mỗi cửa sổ, chúng ta muốn phân bố điểm toán của 3 vùng được vẽ trong cùng một biểu đồ. Hàm qplot hay ggplot có thể giúp chúng ta:

```
qplot(MATH, geom="density", fill=AREA, alpha=I(0.5)) +
  opts(legend.position="top")
```



Biểu đồ tương tự cũng có thể vẽ bằng hàm `ggplot`:

```
p = ggplot(data=pisa, aes(MATH, fill=AREA))
```


```
p + geom_density(alpha=0.5) + labs(x="MATH SCORE", y="Frequency")
```

8.5.2 Biểu đồ hộp (boxplot)

Biểu đồ hộp cũng có thể cung cấp những chỉ số thống kê và cho phép chúng ta so sánh giữa các nhóm. Trong biểu đồ hộp dưới đây, chúng ta so sánh điểm toán giữa học sinh 3 vùng (Bắc, Trung, và Nam).


```
p = ggplot(data=pisa, aes(x=REGION, y=MATH))
```

```
p + geom_boxplot()
```



Cũng có thể dùng hàm `qplot` có thêm màu theo `AREA`. Ngoài ra, phần legend được đặt trên biểu đồ với hàm `opts(legend.position="top")`.


```
qplot(x=AREA, y=MATH, geom="boxplot",
      col=AREA)+opts(legend.position="top")
```



8.5.3 Biểu đồ tương quan


Chúng ta muốn xem mối tương quan giữa điểm đọc hiểu và điểm toán cho tất cả các học sinh. Hàm `qplot` dưới đây có thể đáp ứng mục tiêu đó (chú ý `stat_smooth(method="lm")` là để vẽ đường biểu diễn):

```
qplot(x=READING, y=MATH) + stat_smooth(method="lm")
```




Nhưng nếu chúng ta muốn xem mối tương quan đó cho từng vùng (AREA) thì hàm sau đây sẽ đáp ứng:

```
qplot(x=READING, y=MATH, col=AREA) + stat_smooth(method="lm") +  
opts(legend.position="top")
```



Thay vì vẽ 3 vùng trong cùng một biểu đồ, chúng ta có thể tách ra 3 biểu đồ bằng hàm facet:

```
qplot(x=READING, y=MATH, col=AREA, facets=~AREA) +  
stat_smooth(method="lm") + opts(legend.position="top")
```



8.5.4 Biểu đồ theo thời gian cho từng cá nhân

Trong nghiên cứu y khoa, thỉnh thoảng có những nghiên cứu theo dõi bệnh nhân theo thời gian. Nói cách khác, mỗi bệnh nhân được đo lường nhiều lần trong những điều kiện can thiệp khác nhau. Mục tiêu đơn giản của những nghiên cứu là mô tả sự biến chuyển của một biến theo thời gian *cho từng cá nhân*.

Chẳng hạn như dữ liệu dưới đây trích từ một nghiên cứu trên 51 bệnh nhân; mỗi bệnh nhân được theo dõi suốt 2 năm, và trong thời gian đó mật độ xương cột sống (L1L4) và xương đùi (FNBMD). Chú ý không phải mỗi bệnh nhân đều có cùng số lần đo lường, có người chỉ có 2 lần, nhưng cũng có người có 5 lần đo. Dữ liệu dưới đây là một phần của nghiên cứu đó.


id	visit	L1L4	FNBMD
1	1	1.18	1.11
1	5	1.19	1.06
1	6	1.16	1.05
1	7	1.40	1.05
2	1	1.38	1.20
2	5	1.35	1.15
2	6	1.36	1.19
3	1	1.43	1.15
3	4	1.46	1.11
3	5	1.41	1.09
3	6	1.55	1.06
3	7	1.54	1.03
4	1	1.49	1.19
4	4	1.52	1.13
4	5	1.48	1.10
4	6	1.43	1.06
4	7	1.42	1.05

Chú ý rằng dữ liệu được sắp xếp theo mô hình dọc, mỗi bệnh nhân (id) xuất hiện nhiều lần, và mỗi lần được nhận dạng bằng giá trị của biến visit. Chúng ta muốn vẽ biểu đồ với trục hoành là visit và trục tung là L1L4 (mật độ xương), và mỗi dòng thể hiện mỗi bệnh nhân. Biểu đồ này còn có tên là biểu đồ “spaghetti”.

Đọc dữ liệu vào R và gọi là long. Sau đó dùng hàm ggplot dưới đây. Chú ý trong option group=id chính là chọn vẽ cho từng cá nhân:

```
p = ggplot(data=long, aes(x=visit, y=L1L4, group=id,
  colour = factor(id)))
```


```
p + geom_line() + opts(legend.text=theme_text(size=5))
```



Tuy nhiên, nếu chúng ta muốn vẽ một biểu đồ với mỗi cửa sổ là dữ liệu cho một cá nhân:

```
p = ggplot(data=long, aes(x=visit, y=L1L4))
```

```
p + geom_point() + geom_smooth(method=lm) + facet_wrap(~id)
```

Nói tóm lại, R có nhiều hàm có thể vẽ các biểu đồ khoa học có chất lượng tốt. Những biểu đồ được giới thiệu trên đây chỉ là một phần nhỏ trong kho tàng đồ thị khổng lồ của R. Có những biểu đồ tinh vi và phức tạp cũng có thể xây dựng bằng R nhưng đòi hỏi vài kỹ thuật lập chương trình. Như đã nói trong phần đầu, biểu đồ là một bộ phận rất quan trọng trong khoa học và đòi hỏi phải có những suy nghĩ và đầu tư thời gian thích đáng. Những biểu đồ đơn giản từ Excel hay các phần mềm tương tự chỉ đáp ứng những mục tiêu đơn giản, nhưng khó có thể sử dụng cho các mục tiêu khoa học và phân tích dữ liệu nghiêm túc. Hi vọng rằng những biểu đồ trên đây sẽ giúp cho bạn đọc phát triển thêm những biểu đồ phù hợp cho mỗi mục tiêu đặc thù.


Tài liệu tham khảo

- Wilkinson L. The Grammar of Graphics. Springer-Verlag New York, Inc. Secaucus, NJ, USA, 2005.
- Wickham H. ggplot2: Elegant Graphics for Data Analysis. Springer-Verlag Heidelberg, 2009.



09

Phân tích thống kê mô tả



Trong chương này, chúng ta sẽ sử dụng R cho mục đích phân tích thống kê mô tả. Nói đến thống kê mô tả là nói đến việc mô tả dữ liệu bằng các phép tính và chỉ số thống kê thông thường mà chúng ta đã làm quen qua từ thuở trung học như số trung bình (mean), số trung vị (median), phương sai (variance), độ lệch chuẩn (standard deviation)... cho các biến số liên tục, và tỉ số (proportion) cho các biến số không liên tục. Nhưng trước khi hướng dẫn phân tích thống kê mô tả, bạn đọc nên phân biệt hai khái niệm *tổng thể* (population) và *mẫu* (sample).

9.0 Khái niệm tổng thể (population) và mẫu (sample)

Có thể nói mục tiêu của nghiên cứu khoa học thực nghiệm là nhằm tìm hiểu và khám phá những cái *chưa được biết* (unknown), trong đó bao gồm những qui luật hoạt động của tự nhiên. Để khám phá, chúng ta sử dụng đến các phương pháp *phân loại*, *so sánh*, và *phỏng đoán*. Tất cả các phương pháp khoa học, kể cả thống kê học, được phát triển nhằm vào ba mục tiêu trên. Để phân loại, chúng ta phải đo lường một yếu tố hay tiêu chí có liên quan đến vấn đề cần nghiên cứu. Để so sánh và phỏng đoán, chúng ta cần đến các phương pháp kiểm định giả thiết và mô hình thống kê học.

Cũng như bất cứ mô hình nào, mô hình thống kê phải có thông số. Và muốn có thông số, chúng ta trước hết phải tiến hành đo lường, và sau đó là ước tính thông số từ đo lường. Chẳng hạn như để biết sinh viên nữ có chỉ số thông minh (IQ) bằng sinh viên nam hay không, chúng ta có thể làm nghiên cứu theo hai phương án:

- a. Một là lập danh sách tất cả sinh viên nam và nữ trên toàn quốc, rồi đo lường chỉ số IQ ở từng người, và sau đó so sánh giữa hai nhóm;
- b. Hai là chọn ngẫu nhiên một mẫu gồm n nam và m nữ sinh viên, rồi đo lường chỉ số IQ ở từng người, và sau đó so sánh giữa hai nhóm.

Phương án (a) rất tốn kém và có thể nói là không thực tế, vì chúng ta phải tập hợp tất cả sinh viên của cả nước, một việc làm rất khó thực hiện được. Nhưng nếu chúng ta có thể làm được, thì phương án này không cần đến thống kê học. Giá trị IQ trung bình của nữ và nam sinh viên tính từ phương án (a) là giá trị cuối cùng, và nó trả lời câu hỏi của chúng ta một cách trực tiếp, chúng ta không cần phải suy luận, không cần đến kiểm định thống kê.

Phương án (b) đòi hỏi chúng ta phải chọn n nam và m nữ sinh viên sao cho *đại diện* (representative) cho toàn thể sinh viên của cả nước. Tính “đại diện” ở đây có nghĩa là các số n nam và m nữ sinh viên này phải có cùng đặc tính như độ tuổi, trình độ học vấn, thành phần kinh tế, xã hội, nơi sinh sống, v.v... so với tổng thể sinh viên của cả nước. Bởi vì chúng ta không biết các đặc tính này trong toàn bộ tổng thể sinh viên, chúng ta không thể so sánh trực tiếp được, cho nên một phương pháp rất hữu hiệu là lấy mẫu một cách ngẫu nhiên. Có nhiều phương pháp lấy mẫu ngẫu nhiên đã được phát triển và chúng ta sẽ không bàn qua chi tiết của các phương pháp này, ngoại trừ muốn nhấn mạnh rằng, nếu cách lấy mẫu không ngẫu nhiên thì các ước số từ mẫu sẽ không có ý nghĩa khoa học cao, bởi vì các phương pháp phân tích thống kê dựa vào giả định rằng mẫu phải được chọn một cách ngẫu nhiên.

Chúng ta sẽ lấy một ví dụ cụ thể về tổng thể và mẫu qua ứng dụng R như sau. Ví dụ chúng ta có một tổng thể gồm 20 người và biết rằng chiều cao của họ như sau (tính bằng cm): 162, 160, 157, 155, 167, 160, 161, 153, 149, 157, 159, 164, 150, 162, 168, 165, 156, 157, 154 và 157. Như vậy, chúng ta biết rằng chiều cao trung bình của tổng thể là 158.65 cm.

Vì thiếu thốn phương tiện chúng ta không thể nghiên cứu trên toàn tổng thể mà chỉ có thể lấy mẫu từ tổng thể để ước tính chiều cao. Hàm `sample()` cho phép chúng ta lấy mẫu. Và ước tính chiều cao trung bình từ mẫu tất nhiên sẽ khác với chiều cao trung bình của tổng thể.

- Chọn 5 người từ tổng thể:

```
> height = c(162, 160, 157, 155, 167, 160, 161, 153,
149, 157, 159, 164, 150, 162, 168, 165, 156, 157,
154, 157)
> sample5 <- sample(height, 5)
```

```
> sample5  
[1] 153 157 164 156 149
```

Ước tính chiều cao trung bình từ mẫu này:

```
> mean(sample5)  
[1] 155.8
```

- Chọn 5 người khác từ tổng thể và tính chiều cao trung bình:

```
> sample5 <- sample(height, 5)  
> sample5  
[1] 157 162 167 161 150  
> mean(sample5)  
[1] 159.4
```

Chú ý ước tính chiều cao của mẫu thứ hai là 159.4 cm (thay vì 155.8 cm), bởi vì chọn ngẫu nhiên, cho nên đối tượng được chọn lần hai không nhất thiết phải là đối tượng lần thứ nhất, cho nên ước tính trung bình khác nhau.

- Bây giờ chúng ta thử lấy mẫu 10 người từ tổng thể và tính chiều cao trung bình:

```
> sample10 <- sample(height, 10)  
> sample10  
[1] 153 160 150 165 159 160 164 156 162 157  
> mean(sample10)  
[1] 158.6
```

Chúng ta có thể lấy nhiều mẫu, mỗi mẫu gồm 10 người và ước tính số trung bình từ mẫu, bằng một lệnh đơn giản hơn như sau:

```
> mean(sample(height, 10))  
[1] 156.7  
> mean(sample(height, 10))  
[1] 157.1  
> mean(sample(height, 10))  
[1] 159.3  
> mean(sample(height, 10))  
[1] 159.3  
> mean(sample(height, 10))  
[1] 158.3  
> mean(sample(height, 10))
```

Chú ý độ dao động của số trung bình từ 156.7 đến 159.3 cm.

- Chúng ta thử lấy mẫu 15 người từ tổng thể và tính chiều cao trung bình:

```
> mean(sample(height, 15))
[1] 158.6667
> mean(sample(height, 15))
[1] 159.4
> mean(sample(height, 15))
[1] 158.0667
> mean(sample(height, 15))
[1] 158.1333
> mean(sample(height, 15))
[1] 156.4667
```

Chú ý độ dao động của số trung bình bây giờ từ 158.0 đến 158.7 cm, tức thấp hơn mẫu với 10 đối tượng.

- Tăng cỡ mẫu lên 18 người (tức gần số đối tượng trong tổng thể)

```
> mean(sample(height, 18))
[1] 158.2222
> mean(sample(height, 18))
[1] 158.7222
> mean(sample(height, 18))
[1] 158.0556
> mean(sample(height, 18))
[1] 158.4444
> mean(sample(height, 18))
[1] 158.6667
> mean(sample(height, 18))
[1] 159.0556
> mean(sample(height, 18))
[1] 159
```

Bây giờ thì ước tính chiều cao khá ổn định, nhưng không khác gì so với cỡ mẫu với 15 người, do độ dao động từ 158.2 đến 159 cm.

Từ các ví dụ trên đây, chúng ta có thể rút ra một nhận xét quan trọng: Ước số từ các mẫu được chọn một cách ngẫu nhiên sẽ khác với thông số của tổng thể, nhưng khi số cỡ mẫu tăng lên thì độ khác biệt sẽ nhỏ lại dần. Do đó, một trong những vấn đề then chốt của thiết kế nghiên cứu là nhà nghiên

cứu phải ước tính cỡ mẫu sao cho ước số mà chúng ta tính từ mẫu gần (hay chính xác) so với thông số của tổng thể. Tôi sẽ quay lại vấn đề này trong chương 15.

Trong ví dụ trên, số trung bình của tổng thể là 158.65 cm. Trong thống kê học, chúng ta gọi đó là *thông số* (parameter). Và các số trung bình ước tính từ các mẫu chọn từ tổng thể đó được gọi là *ước số mẫu* (sample estimate). Do đó, xin nhắc lại để nhấn mạnh: những chỉ số liên quan đến tổng thể là thông số, còn những số ước tính từ các mẫu là ước số. Như ví dụ trên, ước số có độ dao động chung quanh thông số, và vì trong thực tế chúng ta không biết thông số, cho nên mục tiêu chính của phân tích thống kê là sử dụng ước số để suy luận về thông số.

Mục tiêu chính của phân tích thống kê mô tả là tìm những ước số của mẫu. Có hai loại đo lường: liên tục (continuous measurement) và không liên tục hay rời rạc (discrete measurement). Các biến liên tục như độ tuổi, chiều cao, trọng lượng cơ thể, v.v... là biến số liên tục, còn các biến mang tính phân loại như có hay không có bệnh, thích hay không thích, trắng hay đen, v.v... là những biến số không liên tục. Cách tính hai loại biến số này cũng khác nhau.

Ước số thông thường nhất dùng để mô tả một biến số liên tục là số trung bình (mean). Chẳng hạn như chiều cao của nhóm 1 gồm 5 đối tượng là 160, 160, 167, 156, và 161, do đó số trung bình là 160.8 cm. Nhưng chiều cao của nhóm 2 cũng gồm 5 đối tượng khác như: 142, 150, 187, 180 và 145, thì số trung bình vẫn là 160.8. Do đó, số trung bình không thể phản ánh đầy đủ sự phân phối của một biến liên tục, vì ở đây tuy hai nhóm có cùng trung bình nhưng độ khác biệt của nhóm 2 cao hơn nhóm 1 rất nhiều. Và chúng ta cần một ước số khác gọi là phương sai (variance). Phương sai của nhóm 1 là 15.7 cm^2 và nhóm 2 là 443.7 cm^2 .

Với một biến số không liên tục như 0 và 1 (0 kí hiệu còn sống, và 1 kí hiệu tử vong) thì ước số trung bình không còn ý nghĩa “trung bình” nữa, cho nên chúng ta có ước số tỉ lệ (proportion). Chẳng hạn như trong số 10 người có 2 người tử vong, thì tỉ lệ tử vong là 0.2 (hay 20%). Trong số 200 người có 40 người qua đời thì tỉ lệ tử vong vẫn là 0.2. Do đó, cũng như trường hợp trung bình, tỉ lệ không thể mô tả một biến không liên tục đầy đủ được. Chúng ta cần đến phương sai để, cùng với tỉ lệ, mô tả một biến không liên tục. Trong trường hợp 2/10 phương sai là 0.016, còn trong trường hợp 40/200, phương sai là 0.0008. Trong chương này, chúng ta sẽ làm quen với một số lệnh trong R để tiến hành những tính toán đơn giản trên.

9.1 Thống kê mô tả (descriptive statistics, summary)

Để minh họa cho việc áp dụng R vào thống kê mô tả, chúng ta sẽ sử dụng một dữ liệu nghiên cứu có tên là `igfdata`. Trong nghiên cứu này, ngoài các chỉ số liên quan đến giới tính, độ tuổi, trọng lượng và chiều cao, chúng ta đo lường các hormone liên quan đến tình trạng tăng trưởng như `igfi`, `igfbp3`, `als`, và các markers liên quan đến sự chuyển hóa của xương `pinp`, `ictp` và `p3np`. Có 100 đối tượng nghiên cứu. Dữ liệu này được chứa trong directory `c:\works\stats`. Trước hết, chúng ta cần phải nhập dữ liệu vào R với những lệnh sau đây (các câu chữ theo sau dấu `#` là những chú thích để bạn đọc theo dõi):

```
> options(width=100)

# chuyển directory
> setwd("c:/works/stats")

# đọc dữ liệu vào R
> igfdata <- read.table("igf.txt", header=TRUE, na.strings=".")
> attach(igfdata)

# xem xét các cột số trong dữ liệu

> names(igfdata)
[1] "id"   "sex"  "age"  "weight" "height" "ethnicity"
[7] "igfi" "igfbp3" "als"   "pinp"   "ictp"   "p3np"

> igfdata
      id  sex age weight height ethnicity  igfi  igfbp3
1     1 Female 15    42    162    Asian 189.000  4.00000
2     2  Male 16    44    160 Caucasian 160.000  3.75000
3     3 Female 15    43    157    Asian 146.833  3.43333
4     4 Female 15    42    155    Asian 185.500  3.40000
5     5 Female 16    47    167    Asian 192.333  4.23333
6     6 Female 25    45    160    Asian 110.000  3.50000
7     7 Female 19    45    161    Asian 157.000  3.20000
8     8 Female 18    43    153    Asian 146.000  3.40000
9     9 Female 15    41    149    Asian 197.667  3.56667
10    10 Female 24    45    157    African 148.000  3.40000
...
...
```

```

97  97 Female  17      54      168 Caucasian 204.667 4.96667
98  98  Male  18      55      169      Asian 178.667 3.86667
99  99 Female  18      48      151      Asian 237.000 3.46667
100 100  Male  15      54      168      Asian 130.000 2.70000

```

```

      id      als      pinp      ictp      p3np
1       1 323.667 353.970 11.2867  8.3367
2       2 333.750 375.885 10.4300  6.7450
3       3 248.333 199.507  8.3633 12.5000
4       4 251.000 483.607 13.3300 14.2767
5       5 322.000 105.430  7.9233  4.5033
6       6 284.667  76.487  4.9833  4.9367
7       7 274.000  75.880  6.3500  5.3200
8       8 303.000  86.360  7.3700  4.6700
9       9 308.500 254.803 11.8700  6.8200
10      10 273.000  44.720  3.7400  6.1600
...
...
97      97 441.333  64.130  5.1600  4.4367
98      98 273.000 185.913  7.5267  8.8333
99      99 324.333 105.127  5.9867  5.6600
100     100 259.333 325.840 10.2767  6.5933

```

Trên đây chỉ là một phần số liệu trong số 100 đối tượng.

Cho một biến số $x_1, x_2, x_3, \dots, x_n$ chúng ta có thể tính toán một số chỉ số thống kê mô tả như sau:

LÝ THUYẾT	HÀM R
Số trung bình: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$	mean(x)
Phương sai: $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$	var(x)
Độ lệch chuẩn: $s = \sqrt{s^2}$	sd(x)
Sai số chuẩn (standard error): $SE = \frac{s}{\sqrt{n}}$	Không có
Trị số thấp nhất	min(x)
Trị số cao nhất	max(x)
Toàn cụ (range)	range(x)

Ví dụ 1: Để tìm giá trị trung bình của độ tuổi, chúng ta chỉ đơn giản nhập lệnh:

```
> mean(age)
[1] 19.17
```

Hay phương sai và độ lệch chuẩn của tuổi:

```
> var(age)
[1] 15.33444
```

```
> sd(age)
[1] 3.915922
```

Tuy nhiên, R có lệnh `summary` có thể cho chúng ta tất cả thông tin thống kê về một biến số:

```
> summary(age)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 13.00   16.00   19.00   19.17   21.25   34.00
```

Nói chung, kết quả này đơn giản và cách viết tắt cũng có thể dễ hiểu. Chú ý, trong kết quả trên, có hai chỉ số “1st Qu” và “3rd Qu” có nghĩa là first quartile (tương đương với vị trí 25%) và third quartile (tương đương với vị trí 75%) của một biến số. First quartile = 16 có nghĩa là 25% đối tượng nghiên cứu có độ tuổi bằng hoặc nhỏ hơn 16 tuổi. Tương tự, Third quartile = 34 có nghĩa là 75% đối tượng có độ tuổi bằng hoặc thấp hơn 34 tuổi. Tất nhiên số trung vị (median) 19 cũng có nghĩa là 50% đối tượng có độ tuổi 19 trở xuống (hay 19 tuổi trở lên).

R không có hàm tính sai số chuẩn, và trong hàm `summary`, R cũng không cung cấp độ lệch chuẩn. Để có các số này, chúng ta có sử dụng hàm `describe` trong package `psych`.

```
library(psych)
describe(igfdata)
```

```
> describe(igfdata, skew=F, range=F)
      var    n  mean    sd    se
id      1 100  50.50 29.01  2.90
sex*     2 100   1.31  0.46  0.05
age      3 100  19.17  3.92  0.39
weight   4 100  49.91  3.93  0.39
height   5 100 163.08  7.88  0.79
ethnicity* 6 100   2.26  0.63  0.06
```

igfi	7	100	165.59	50.13	5.01
igfbp3	8	100	3.62	0.55	0.06
als	9	100	301.84	58.99	5.90
pinp	10	100	167.17	157.67	15.77
ictp	11	100	7.42	3.75	0.37
p3np	12	100	6.34	2.77	0.28

Ngoài ra, describe có thể tóm tắt dữ liệu theo nhóm. Nếu chúng ta muốn mô tả dữ liệu trên cho từng giới thì hàm describeBy dưới đây sẽ đáp ứng mục tiêu đó:

```
> describeBy(igfdata, group=sex, skew=F, range=F)
```

```
group: Female
```

	var	n	mean	sd	se
id	1	69	48.20	29.54	3.56
sex*	2	69	1.00	0.00	0.00
age	3	69	19.59	3.90	0.47
weight	4	69	49.35	3.98	0.48
height	5	69	161.94	7.94	0.96
ethnicity*	6	69	2.26	0.56	0.07
igfi	7	69	167.97	55.83	6.72
igfbp3	8	69	3.70	0.56	0.07
als	9	69	311.54	61.31	7.38
pinp	10	69	108.74	88.91	10.70
ictp	11	69	6.18	2.29	0.28
p3np	12	69	5.64	2.24	0.27

```
-----
```







```
group: Male
```

	var	n	mean	sd	se
id	1	31	55.61	27.57	4.95
sex*	2	31	2.00	0.00	0.00
age	3	31	18.23	3.84	0.69
weight	4	31	51.16	3.57	0.64
height	5	31	165.61	7.25	1.30
ethnicity*	6	31	2.26	0.77	0.14
igfi	7	31	160.29	34.44	6.19
igfbp3	8	31	3.44	0.51	0.09
als	9	31	280.24	47.57	8.54
pinp	10	31	297.21	196.97	35.38
ictp	11	31	10.17	4.80	0.86
p3np	12	31	7.90	3.20	0.57

R tính toán tất cả các biến số nào có thể tính toán được. Cho nên, ngay cả cột *id* (tức mã số của đối tượng nghiên cứu) R cũng tính luôn! (và chúng ta biết kết quả của cột *id* chẳng có ý nghĩa thống kê gì). Đối với các biến số mang tính phân loại như *sex* và *ethnicity* (sắc tộc) thì R chỉ báo cáo tần số cho mỗi nhóm.

Để xem qua phân phối của các hormones và chỉ số sinh hóa cùng một lúc, chúng ta có thể vẽ đồ thị cho tất cả 6 biến số. Trước hết, chia màn ảnh thành 6 cửa sổ (với 2 dòng và 3 cột); sau đó lần lượt vẽ:

```
> op <- par(mfrow=c(2,3))
> hist(igfi)
> hist(igfbp3)
> hist(als)
> hist(pinp)
> hist(ictp)
> hist(p3np)
```



9.2 Mô tả bằng bảng số liệu (tabular)

Bảng số liệu là một phương tiện tóm lược dữ liệu rất có ích. Bảng số liệu đơn giản có cột và dòng, nhưng bảng số liệu với nhiều biến có thể có thêm cột và dòng trong mỗi nhóm nhỏ. Trong R có hai hàm chính để tóm tắt dữ liệu bằng bảng số liệu:

- Hàm **CrossTable** (trong **gmodels**) có thể tóm lược hai biến phân nhóm (hay categorical variables);
- Hàm **tabular** (trong **tables**) có thể tóm lược hai hay nhiều biến phân nhóm hoặc biến liên tục.

Chúng ta sẽ sử dụng kết quả kiểm định PISA để minh họa cho hai hàm trên. Xin nhắc lại, dữ liệu PISA có các biến cụ thể như sau:

- **REGION** là vùng, bao gồm các giá trị CENTRAL, NORTH, SOUTH;
- **TYPE** là loại trường công hay tư, với hai giá trị PUBLIC, PRIVATE;
- **AREA** là địa điểm của trường, với giá trị REMOVE (vùng sâu xa), RURAL (nông thôn) và URBAN (thành thị);
- **GENDER** chỉ giới tính, với hai giá trị Male và Female;
- **MATH** là điểm khả dĩ về môn toán, là một biến liên tục, giá trị từ 200 đến 850;
- **READING** là điểm khả dĩ về môn đọc và hiểu, là một biến liên tục, giá trị từ 200 đến 850;
- **SCIENCE** là điểm khả dĩ về môn khoa học, là một biến liên tục, giá trị từ 200 đến 850.

9.2.1 Một biến phân nhóm

Bảng số liệu đơn giản nhất có một biến. Giả dụ chúng ta muốn biết số học sinh cho từng vùng, và biến vùng là REGION. Hàm tabular có thể sử dụng như sau. Chú ý tabular(REGION ~ 1) có nghĩa là chỉ muốn biết số học sinh cho từng vùng:

```
> tabular(REGION~1)
```

```
REGION  All  
CENTRAL 1591  
NORTH   1751  
SOUTH   1617
```

Nhưng nếu chúng ta muốn biết phần trăm cho từng vùng, chúng ta cần option Percent, nhưng trong trường hợp này chúng ta muốn tính phần trăm theo cột. Chú ý “n=1” là yêu cầu trình bày con số học sinh.

```
> tabular(REGION~1*(n=1 + Percent("col")))
```

```

All
n
REGION All Percent
CENTRAL 1591 32.08
NORTH 1751 35.31
SOUTH 1617 32.61

```

9.2.2 Hai hay nhiều biến phân nhóm

Chúng ta muốn biết số học sinh cho từng vùng và từng miền, hàm đơn giản nhất là:

```
> tabular(REGION ~ AREA)
```

```

AREA
REGION REMOTE RURAL URBAN
CENTRAL 121 771 699
NORTH 141 865 745
SOUTH 62 642 913

```

Có thể thêm phần trăm cho từng dòng:

```
> tabular(REGION ~ AREA*(n=1 + Percent("row")))
```

```

AREA
REMOTE RURAL URBAN
n n n
REGION All Percent All Percent All Percent
CENTRAL 121 7.605 771 48.46 699 43.93
NORTH 141 8.053 865 49.40 745 42.55
SOUTH 62 3.834 642 39.70 913 56.46

```

Hoặc phần trăm cho từng cột:

```
> tabular(REGION ~ AREA*(n=1 + Percent("col")))
```

	AREA					
	REMOTE		RURAL		URBAN	
	n		n		n	
REGION	All	Percent	All	Percent	All	Percent
CENTRAL	121	37.35	771	33.85	699	29.66
NORTH	141	43.52	865	37.97	745	31.61
SOUTH	62	19.14	642	28.18	913	38.74

Trong trường hợp trên, chúng ta chỉ quan tâm đến 2 biến, nhưng tabular có khả năng thống kê nhiều hơn 2 biến. Ví dụ như chúng ta muốn đếm số học sinh cho từng vùng, miền và loại trường (công hay tư). Có thể dùng "*" để thêm biến. Trong ví dụ sau đây, chúng ta lồng miền cho từng vùng:

```
> tabular(REGION*AREA ~ TYPE)
```

		TYPE	
REGION	AREA	PRIVATE	PUBLIC
CENTRAL	REMOTE	0	121
	RURAL	68	703
	URBAN	69	630
NORTH	REMOTE	12	129
	RURAL	68	797
	URBAN	102	643
SOUTH	REMOTE	0	62
	RURAL	44	598
	URBAN	64	849

Nhưng cũng có thể lồng loại trường trong miền:

```
> tabular(REGION ~ AREA*TYPE)
```

	AREA					
	REMOTE		RURAL		URBAN	
	TYPE		TYPE		TYPE	
REGION	PRIVATE	PUBLIC	PRIVATE	PUBLIC	PRIVATE	PUBLIC
CENTRAL	0	121	68	703	69	630
NORTH	12	129	68	797	102	643
SOUTH	0	62	44	598	64	849

Chú ý trong các bảng số liệu trên không có các chỉ số thống kê như Khi bình phương (Chi square). Hàm CrossTable (trong gmodels) có thể cung cấp chỉ số Ki bình phương:

```
> CrossTable(REGION, TYPE, prop.c=T, prop.r=T, prop.t=F,
prop.chisq=F, chisq=T)
```

```
Cell Contents
|-----|
|                N |
|      N / Row Total |
|      N / Col Total |
|-----|
```

Total Observations in Table: 4959

REGION	TYPE		Row Total
	PRIVATE	PUBLIC	
CENTRAL	137	1454	1591
	0.086	0.914	0.321
	0.321	0.321	
NORTH	182	1569	1751
	0.104	0.896	0.353
	0.426	0.346	
SOUTH	108	1509	1617
	0.067	0.933	0.326
	0.253	0.333	
Column Total	427	4532	4959
	0.086	0.914	

Statistics for All Table Factors

Pearson's Chi-squared test

```
-----
Chi^2 = 14.74409      d.f. = 2      p = 0.0006285803
```

9.2.3 Biến liên tục

Biến MATH (điểm toán) là một biến liên tục, và chúng ta muốn biết trung bình, độ lệch chuẩn cùng với số học sinh cho từng vùng. Hàm tabular có thể đáp ứng mục tiêu đó. Chú ý trong hàm dưới đây, dấu “*” dùng để cho thêm các chỉ số mà chúng ta cần. Cũng chú ý là $n=1$ là một cách yêu cầu số đối tượng.

```
> tabular(REGION ~ MATH*(n=1+mean+sd))
```

	MATH		
	n		
REGION	All	mean	sd
CENTRAL	1591	513.1	75.99
NORTH	1751	519.1	90.54
SOUTH	1617	498.9	81.38

Chúng ta cũng có thể tính toán các chỉ số thống kê mô tả cho từng vùng và loại trường:

```
> tabular(REGION*TYPE ~ MATH*(n=1+mean+sd))
```

		MATH		
		n		
REGION	TYPE	All	mean	sd
CENTRAL	PRIVATE	137	467.9	60.12
	PUBLIC	1454	517.4	75.96
NORTH	PRIVATE	182	471.4	63.36
	PUBLIC	1569	524.7	91.60
SOUTH	PRIVATE	108	486.3	52.51
	PUBLIC	1509	499.8	83.00

Nhưng thay vì trình bày loại trường theo dòng, chúng ta có thể trình bày theo cột:

```
> tabular(REGION ~ TYPE*MATH*(n=1+mean+sd))
```

	TYPE			PUBLIC		
	PRIVATE			PUBLIC		
	MATH			MATH		
	n			n		
REGION	All	mean	sd	All	mean	sd
CENTRAL	137	467.9	60.12	1454	517.4	75.96
NORTH	182	471.4	63.36	1569	524.7	91.60
SOUTH	108	486.3	52.51	1509	499.8	83.00

Hàm `tabular` có thể tóm tắt nhiều biến cùng một lúc. Trong hàm dưới đây, chúng ta tóm tắt `MATH` và `READING` cho từng vùng và loại trường:

```
> tabular(REGION*TYPE ~ (MATH + READING) * (n=1+mean+sd))
```

		MATH			READING		
		n			n		
REGION	TYPE	All	mean	sd	All	mean	sd
CENTRAL	PRIVATE	137	467.9	60.12	137	464.5	58.14
	PUBLIC	1454	517.4	75.96	1454	516.3	67.65
NORTH	PRIVATE	182	471.4	63.36	182	474.6	54.19
	PUBLIC	1569	524.7	91.60	1569	514.6	76.67
SOUTH	PRIVATE	108	486.3	52.51	108	491.0	46.00
	PUBLIC	1509	499.8	83.00	1509	503.2	72.39

Tóm lại, hàm `tabular` (trong `tables`) rất có ích trong việc tóm tắt dữ liệu phân nhóm và các biến liên tục. Trong thực tế, hàm `tabular` có thể tạo ra bảng số liệu dưới dạng LATEX và PDF. Tuy nhiên, phần này tôi để cho bạn đọc tự khám phá.

9.3 Kiểm định xem một biến có phải phân bố chuẩn

Trong phân tích thống kê, phần lớn các phép tính dựa vào giả định biến số phải là một biến số phân phối chuẩn (normal distribution). Do đó, một trong những việc quan trọng khi xem xét dữ kiện là phải kiểm định giả thiết phân phối chuẩn của một biến số. Trong đồ thị trên, chúng ta thấy các biến số như `igfi`, `pinp`, `ictp` và `p3np` có vẻ tập trung vào các giá trị thấp và không cân đối, tức dấu hiệu của một sự phân phối không chuẩn.

Để kiểm định nghiêm chỉnh, chúng ta cần phải sử dụng kiểm định thống kê có tên là “Shapiro test” và trong R gọi là hàm `shapiro.test`. Chẳng hạn như kiểm định giả thiết phân phối chuẩn của biến số `pinp`.

```
> shapiro.test(pinp)
      Shapiro-Wilk normality test

data:  pinp
W = 0.748, p-value = 8.314e-12
```


Vì trị số `p` (`p-value`) thấp hơn 0.05, chúng ta có thể kết luận rằng biến số `pinp` không đáp ứng luật phân phối chuẩn.

Nhưng với biến số `weight` (trọng lượng cơ thể) thì kiểm định này cho biết đây là một biến số tuân theo luật phân phối chuẩn vì trị số $p > 0.05$.

```
> shapiro.test(weight)
      Shapiro-Wilk normality test
data:  weight
W = 0.9887, p-value = 0.5587
```

Thật ra, kết quả trên cũng phù hợp với đồ thị của `weight`:

```
> hist(weight)
```



9.4 Kiểm định t (t.test)

Kiểm định t dựa vào giả thiết phân phối chuẩn. Có hai loại kiểm định t: kiểm định t cho một mẫu (one-sample t-test), và kiểm định t cho hai mẫu (two-sample t-test). Kiểm định t một mẫu nhằm trả lời câu hỏi dữ liệu từ một mẫu có phải thật sự bằng một thông số nào đó hay không. Còn kiểm định t hai mẫu thì nhằm trả lời câu hỏi hai mẫu có cùng một luật phân phối, hay cụ thể hơn là hai mẫu có thật sự có cùng trị số trung bình hay không. Tôi sẽ lần lượt minh họa hai kiểm định này qua số liệu `igfdata` trên.

9.4.1 Kiểm định t một mẫu

Ví dụ 2: Qua phân tích trên, chúng ta thấy tuổi trung bình của 100 đối tượng trong nghiên cứu này là 19.17 tuổi. Chẳng hạn như trong quần thể này, trước đây chúng ta biết rằng tuổi trung bình là 30 tuổi. Vấn đề đặt ra là có phải mẫu mà chúng ta có được có đại diện cho quần thể hay không. Nói cách khác, chúng ta muốn biết giá trị trung bình 19.17 có thật sự khác với giá trị trung bình 30 hay không.

Để trả lời câu hỏi này, chúng ta sử dụng kiểm định t. Theo lý thuyết thống kê, kiểm định t được định nghĩa bằng công thức sau đây:

$$t = \frac{\bar{x} - \mu}{s / \sqrt{n}}$$

Trong đó, $\bar{x}$ là giá trị trung bình của mẫu, μ là trung bình theo giả thiết (trong trường hợp này, 30), s là độ lệch chuẩn, và n là số lượng mẫu (100). Nếu giá trị t cao hơn giá trị lý thuyết theo phân phối t ở một tiêu chuẩn có ý nghĩa như 5% chẳng hạn thì chúng ta có lý do để phát biểu khác biệt có ý nghĩa thống kê. Giá trị này cho mẫu 100 có thể tính toán bằng hàm qt của R như sau:

```
> qt(0.95, 100)
```

```
[1] 1.660234
```

Nhưng có một cách tính toán nhanh gọn hơn để trả lời câu hỏi trên, bằng cách dùng hàm t.test như sau:

```
> t.test(age, mu=30)
```

```
One Sample t-test
```

```
data: age
```

```
t = -27.6563, df = 99, p-value < 2.2e-16
```

```
alternative hypothesis: true mean is not equal to 30
```

```
95 percent confidence interval:
```

```
18.39300 19.94700
```

```
sample estimates:
```

```
mean of x
```

```
19.17
```

Trong lệnh trên age là biến số chúng ta cần kiểm định, và mu=30 là giá trị giả thiết. R trình bày trị số $t = -27.66$, với 99 bậc tự do, và trị số $p < 2.2e-16$ (tức rất thấp). R cũng cho biết độ tin cậy 95% của age là từ 18.4 tuổi đến 19.9 tuổi (30 tuổi nằm quá ngoài khoảng tin cậy này). Nói cách khác, chúng ta có lý do để phát biểu rằng độ tuổi trung bình trong mẫu này thật sự thấp hơn độ tuổi trung bình của quần thể.

9.4.2 Kiểm định t hai mẫu

Ví dụ 3: Qua phân tích mô tả trên (phần summary) chúng ta thấy phụ nữ có độ hormone igfi cao hơn nam giới (167.97 và 160.29). Câu hỏi đặt ra là có phải thật sự đó là một khác biệt có hệ thống hay do các yếu tố ngẫu nhiên gây nên. Trả lời câu hỏi này, chúng ta cần xem xét mức độ khác biệt trung bình giữa hai nhóm và độ lệch chuẩn của độ khác biệt.

$$t = \frac{\bar{x}_2 - \bar{x}_1}{SED}$$

Trong đó $\bar{x}_1$ và $\bar{x}_2$ là số trung bình của hai nhóm nam và nữ, và SED là độ lệch chuẩn của $(\bar{x}_1 - \bar{x}_2)$. Thực ra, SED có thể ước tính bằng công thức:

$$SED = \sqrt{SE_1^2 + SE_2^2}$$

Trong đó SE_1 và SE_2 là sai số chuẩn (standard error) của hai nhóm nam và nữ. Theo lý thuyết xác suất, t tuân theo luật phân phối t với bậc tự do $n_1 + n_2 - 2$, trong đó n_1 và n_2 là số mẫu của hai nhóm. Chúng ta có thể dùng R để trả lời câu hỏi trên bằng hàm `t.test` như sau:

```
> t.test(igfi ~ sex)
```

```
Welch Two Sample t-test
```

```
data: igfi by sex
```

```
t = 0.8412, df = 88.329, p-value = 0.4025
```

```
alternative hypothesis: true difference in means is not  
equal to 0
```

```
95 percent confidence interval:
```

```
-10.46855 25.83627
```

```
sample estimates:
```

```
mean in group Female mean in group Male
```

```
160.2903
```

R trình bày các giá trị quan trọng trước hết:

```
t = 0.8412, df = 88.329, p-value = 0.4025
```

df là bậc tự do. Trị số $p = 0.4025$ cho thấy mức độ khác biệt giữa hai nhóm nam và nữ không có ý nghĩa thống kê (vì cao hơn 0.05 hay 5%).

95 percent confidence interval:

-10.46855 25.83627

là khoảng tin cậy 95% về độ khác biệt giữa hai nhóm. Kết quả tính toán trên cho biết độ igf ở nữ giới có thể thấp hơn nam giới 10.5 ng/L hoặc cao hơn nam giới khoảng 25.8 ng/L. Vì độ khác biệt quá lớn và đó là thêm bằng chứng cho thấy không có khác biệt có ý nghĩa thống kê giữa hai nhóm.

Kiểm định trên dựa vào giả thiết hai nhóm nam và nữ có khác phương sai. Nếu chúng ta có lí do để cho rằng hai nhóm có cùng phương sai, chúng ta chỉ thay đổi một thông số trong hàm `t` với `var.equal=TRUE` như sau:

```
> t.test(igfi~ sex, var.equal=TRUE)
```

Two Sample t-test

```
data: igfi by sex
```

```
t = 0.7071, df = 98, p-value = 0.4812
```

```
alternative hypothesis: true difference in means is not  
equal to 0
```

```
95 percent confidence interval:
```

```
-13.88137 29.24909
```

```
sample estimates:
```

```
mean in group Female    mean in group Male
```

```
167.9741
```

```
160.2903
```

Về mặt số, kết quả phân tích trên có khác chút ít so với kết quả phân tích dựa vào giả định hai phương sai khác nhau, nhưng trị số p cũng đi đến một kết luận rằng độ khác biệt giữa hai nhóm không có ý nghĩa thống kê.

9.5 So sánh phương sai (`var.test`)

Bây giờ chúng ta thử kiểm định xem phương sai giữa hai nhóm có khác nhau không. Để tiến hành phân tích, chúng ta chỉ cần lệnh:

```
> var.test(igfi ~ sex)
```

F test to compare two variances

data: igfi by sex

F = 2.6274, num df = 68, denom df = 30, p-value = 0.004529

alternative hypothesis: true ratio of variances is not equal to 1

95 percent confidence interval:

1.366187 4.691336

sample estimates:

ratio of variances

2.627396

Kết quả trên cho thấy độ khác biệt về phương sai giữa hai nhóm cao 2.62 lần. Trị số $p = 0.0045$ cho thấy phương sai giữa hai nhóm khác nhau có ý nghĩa thống kê. Như vậy, chúng ta chấp nhận kết quả phân tích của hàm `t.test(igfi ~ sex)`.

9.6 Kiểm định Wilcoxon cho hai mẫu (`wilcox.test`)

Kiểm định t dựa vào giả thiết là phân phối của một biến phải tuân theo luật phân phối chuẩn. Nếu giả định này không đúng, kết quả của kiểm định t có thể không hợp lý (valid). Để kiểm định phân phối của `igfi`, chúng ta có thể dùng hàm `shapiro.test` như sau:

```
> shapiro.test(igfi)
```

Shapiro-Wilk normality test

data: igfi

W = 0.8528, p-value = 1.504e-08

Trị số p nhỏ hơn 0.05 rất nhiều, cho nên chúng ta có thể nói rằng phân phối của `igfi` không tuân theo luật phân phối chuẩn. Trong trường hợp này, việc so sánh giữa hai nhóm có thể dựa vào phương pháp phi tham số (non-parametric) có tên là kiểm định Wilcoxon, vì kiểm định này (không như kiểm định t) không tùy thuộc vào giả định phân phối chuẩn.

```
> wilcox.test(igfi ~ sex)
```

Wilcoxon rank sum test with continuity correction

```
data: igfi by sex
```

```
W = 1125, p-value = 0.6819
```

```
alternative hypothesis: true mu is not equal to 0
```

Trị số $p = 0.682$ cho thấy quả thật độ khác biệt về igfi giữa hai nhóm nam và nữ không có ý nghĩa thống kê. Kết luận này cũng không khác với kết quả phân tích bằng kiểm định t.

9.7 Kiểm định t cho các biến số theo cặp (paired t-test, t.test)

Kiểm định t vừa trình bày trên là cho các nghiên cứu gồm hai nhóm độc lập nhau (như giữa hai nhóm nam và nữ), nhưng không thể ứng dụng cho các nghiên cứu mà một nhóm đối tượng được theo dõi theo thời gian. Chúng ta tạm gọi các nghiên cứu này là nghiên cứu theo cặp. Trong các nghiên cứu này, chúng ta cần sử dụng một kiểm định t có tên là paired t-test.

Ví dụ 4: Một nhóm bệnh nhân gồm 10 người được điều trị bằng một loại thuốc nhằm giảm huyết áp. Huyết áp của bệnh nhân được đo lúc khởi đầu nghiên cứu (lúc chưa điều trị), và sau khi điều trị. Số liệu huyết áp của 10 bệnh nhân như sau:

Trước khi điều trị (x_0)	180, 140, 160, 160, 220, 185, 145, 160, 160, 170
Sau khi điều trị (x_1)	170, 145, 145, 125, 205, 185, 150, 150, 145, 155

Câu hỏi đặt ra là độ biến chuyển huyết áp trên có đủ để kết luận rằng thuốc điều trị có hiệu quả giảm huyết áp. Để trả lời câu hỏi này, chúng ta dùng kiểm định t cho từng cặp như sau:

```
> # nhập dữ kiện
```

```
> before <- c(180, 140, 160, 160, 220, 185, 145, 160, 160, 170)
```

```
> after <- c(170, 145, 145, 125, 205, 185, 150, 150, 145, 155)
```

```
> bp <- data.frame(before, after)
```

```
> # kiểm định t
```

```
> t.test(before, after, paired=TRUE)
```

Paired t-test

data: before and after

t = 2.7924, df = 9, p-value = 0.02097

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

1.993901 19.006099

sample estimates:

mean of the differences

10.5

Kết quả trên cho thấy sau khi điều trị áp suất máu giảm 10.5 mmHg, và khoảng tin cậy 95% là từ 2.0 mmHg đến 19 mmHg, với trị số $p=0.0209$. Như vậy, chúng ta có bằng chứng để phát biểu rằng mức độ giảm huyết áp có ý nghĩa thống kê.

Chú ý nếu chúng ta phân tích sai bằng kiểm định thống kê cho hai nhóm độc lập dưới đây thì trị số $p = 0.32$ cho biết mức độ giảm áp suất không có ý nghĩa thống kê.

```
> t.test(before, after)
```

Welch Two Sample t-test

data: before and after

t = 1.0208, df = 17.998, p-value = 0.3209

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

-11.11065 32.11065

sample estimates:

mean of x mean of y

168.0 157.5

9.8 Kiểm định Wilcoxon cho các biến số theo cặp (wilcox.test)

Thay vì dùng kiểm định t cho từng cặp, chúng ta cũng có thể sử dụng hàm `wilcox.test` cho cùng mục đích:

```
> wilcox.test(before, after, paired=TRUE)
Wilcoxon signed rank test with continuity correction
data:  before and after
V = 42, p-value = 0.02291
alternative hypothesis: true mu is not equal to 0
```

Kết quả trên một lần nữa khẳng định rằng độ giảm áp suất máu có ý nghĩa thống kê với trị số ($p=0.023$) chẳng khác mấy so với kiểm định t cho từng cặp.

9.9 Tần số (frequency)

Hàm `table` trong R có chức năng cho chúng ta biết về tần số của một biến số mang tính phân loại như `sex` và `ethnicity`.

```
> table(sex)
sex
Female    Male
      69     31

> table(ethnicity)
ethnicity
African    Asian Caucasian    Others
       8       60         30         2
```

Một bảng thống kê 2 chiều:

```
> table(sex, ethnicity)
      ethnicity
sex    African Asian Caucasian Others
Female      4     43         22      0
Male        4     17          8      2
```

Chú ý trong các bảng thống kê trên, hàm `table` không cung cấp cho chúng ta số phần trăm. Để tính số phần trăm, chúng ta cần đến hàm `prop.table` và cách sử dụng có thể minh họa như sau:

```
# tạo ra một object tên là freq để chứa kết quả tần số
> freq <- table(sex, ethnicity)
```

```
# kiểm tra kết quả
```

```
> freq
```

```
      ethnicity
sex      African Asian Caucasian Others
Female      4     43          22      0
Male        4     17           8      2
```

```
# dùng hàm margin.table để xem kết quả
```

```
> margin.table(freq, 1)
```

```
sex
```

```
Female   Male
      69     31
```

```
> margin.table(freq, 2)
```

```
ethnicity
African      Asian Caucasian      Others
          8         60         30         2
```

```
# tính phần trăm bằng hàm prop.table
```

```
> prop.table(freq, 1)
```

```
      ethnicity
sex      African      Asian Caucasian      Others
Female 0.05797101 0.62318841 0.31884058 0.00000000
Male   0.12903226 0.54838710 0.25806452 0.06451613
```

Trong bảng thống kê trên, `prop.table` tính tỉ lệ sắc tộc cho từng giới tính. Chẳng hạn như ở nữ giới (female), 5.8% là người châu Phi, 62.3% là người châu Á, 31.8% là người Tây phương da trắng. Tổng cộng là 100%. Tương tự, ở nam giới tỉ lệ người châu Phi là 12.9%, châu Á là 54.8%, v.v..

```
# tính phần trăm bằng hàm prop.table
```

```
> prop.table(freq, 2)
```

```
      ethnicity
sex      African      Asian Caucasian      Others
Female 0.5000000 0.7166667 0.7333333 0.0000000
Male   0.5000000 0.2833333 0.2666667 1.0000000
```

Trong bảng thống kê trên, `prop.table` tính tỉ lệ giới tính cho từng sắc tộc. Chẳng hạn như trong nhóm người châu Á, 71.7% là nữ và 28.3% là nam.

```
# tính phần trăm cho toàn bộ bảng
> freq/sum(freq)
      ethnicity
sex      African Asian Caucasian Others
Female    0.04   0.43         0.22   0.00
Male      0.04   0.17         0.08   0.02
```

9.10 Kiểm định tỉ lệ (proportion test, `prop.test`, `binom.test`)

Kiểm định một tỉ lệ thường dựa vào giả định phân phối nhị phân (binomial distribution). Với một số mẫu n và tỉ lệ p , và nếu n lớn (tức hơn 50 chẳng hạn), thì phân phối nhị phân có thể tương đương với phân phối chuẩn với số trung bình np và phương sai $np(1 - p)$. Gọi x là số biến cố mà chúng ta quan tâm, kiểm định giả thiết $p = \pi$ có thể sử dụng thống kê sau đây:

$$z = \frac{x - n\pi}{\sqrt{n\pi(1 - \pi)}}$$

Ở đây, z tuân theo luật phân phối chuẩn với trung bình 0 và phương sai 1. Cũng có thể nói z^2 tuân theo luật phân phối Khi bình phương với bậc tự do bằng 1.

Ví dụ 5: Trong nghiên cứu trên, chúng ta thấy có 69 nữ và 31 nam. Như vậy tỉ lệ nữ là 0.69 (hay 69%). Để kiểm định xem tỉ lệ này có thật sự khác với tỉ lệ 0.5 hay không, chúng ta có thể sử dụng hàm `prop.test(x, n,  $\pi$ )` như sau:

```
> prop.test(69, 100, 0.50)
```

```
1-sample proportions test with continuity correction
```

```
data: 69 out of 100, null probability 0.5
X-squared = 13.69, df = 1, p-value = 0.0002156
alternative hypothesis: true p is not equal to 0.5
95 percent confidence interval:
 0.5885509 0.7766330
sample estimates:
 p
0.69
```

Trong kết quả trên, `prop.test` ước tính tỉ lệ nữ giới là 0.69, và khoảng tin cậy 95% là 0.588 đến 0.776. Giá trị Khi bình phương là 13.69, với trị số $p = 0.00216$. Như vậy, nghiên cứu này có tỉ lệ nữ cao hơn 50%.

Một cách tính chính xác hơn kiểm định tỉ lệ là kiểm định nhị phân `binom.test(x, n,  $\pi$ )` như sau:

```
> binom.test(69, 100, 0.50)
      Exact binomial test
data: 69 and 100
number of successes=69, number of trials=100,
p-value=0.0001831
alternative hypothesis: true probability of success is
not equal to 0.5. 95 percent confidence interval:
 0.5896854 0.7787112
sample estimates - probability of success: 0.69
```

Nói chung, kết quả của kiểm định nhị phân không khác gì so với kiểm định Khi bình phương, với trị số $p = 0.00018$, chúng ta càng có bằng chứng để kết luận rằng tỉ lệ nữ giới trong nghiên cứu này thật sự cao hơn 50%.

9.11 So sánh hai tỉ lệ (`prop.test`, `binom.test`)

Phương pháp so sánh hai tỉ lệ có thể khai triển trực tiếp từ lý thuyết kiểm định một tỉ lệ vừa trình bày trên. Cho hai mẫu với số đối tượng n_1 và n_2 , và số biến cố là x_1 và x_2 . Do đó, chúng ta có thể ước tính hai tỉ lệ p_1 và p_2 . Lý thuyết xác suất cho phép chúng ta phát biểu rằng độ khác biệt giữa hai mẫu $d = p_1 - p_2$ tuân theo luật phân phối chuẩn với số trung bình 0 và phương sai bằng:

$$V_d = \left(\frac{1}{n_1} + \frac{1}{n_2} \right) p(1-p)$$

Trong đó:

$$p = \frac{x_1 + x_2}{n_1 + n_2}$$

Do đó, $z = d/V_d$ tuân theo luật phân phối chuẩn với trung bình 0 và phương sai 1. Nói cách khác, z^2 tuân theo luật phân phối Khi bình phương với bậc tự do bằng 1. Do đó, chúng ta cũng có thể sử dụng `prop.test` để kiểm định hai tỉ lệ.

Ví dụ 6: Một nghiên cứu được tiến hành so sánh hiệu quả của thuốc chống gãy xương. Bệnh nhân được chia thành hai nhóm: nhóm A được điều trị gồm có 100 bệnh nhân, và nhóm B không được điều trị gồm 110 bệnh nhân. Sau thời gian 12 tháng theo dõi, nhóm A có 7 người bị gãy xương, và nhóm B có 20 người gãy xương. Vấn đề đặt ra là tỉ lệ gãy xương trong hai nhóm này bằng nhau (tức thuốc không có hiệu quả)? Để kiểm định xem hai tỉ lệ này có thật sự khác nhau, chúng ta có thể sử dụng hàm `prop.test(x, n,  $\pi$ )` như sau:

```
> fracture <- c(7, 20)
> total <- c(100, 110)
> prop.test(fracture, total)

      2-sample test for equality of proportions with
continuity correction

data:  fracture out of total
X-squared = 4.8901, df = 1, p-value = 0.02701
alternative hypothesis: two.sided
95 percent confidence interval:
 -0.20908963 -0.01454673
sample estimates:
   prop 1    prop 2 
0.0700000 0.1818182
```

Kết quả phân tích trên cho thấy tỉ lệ gãy xương trong nhóm 1 là 0.07 và nhóm 2 là 0.18. Phân tích trên còn cho thấy xác suất 95% rằng độ khác biệt giữa hai nhóm có thể từ 0.01 đến 0.20 (tức 1 đến 20%). Với trị số $p=0.027$, chúng ta có thể nói rằng tỉ lệ gãy xương trong nhóm A quả thật thấp hơn nhóm B.

9.12 So sánh nhiều tỉ lệ (`prop.test`, `chisq.test`)

Kiểm định `prop.test` còn có thể sử dụng để kiểm định nhiều tỉ lệ cùng một lúc. Trong nghiên cứu trên, chúng ta có 4 nhóm sắc tộc và tần số cho từng giới tính như sau:

```
> table(sex, ethnicity)

      ethnicity
sex      African Asian Caucasian Others
Female         4     43          22      0
Male           4     17           8      2
```

Chúng ta muốn biết tỉ lệ nữ giới giữa 4 nhóm sắc tộc có khác nhau hay không, và để trả lời câu hỏi này, chúng ta lại dùng `prop.test` như sau:

```
> female <- c( 4, 43, 22, 0)
> total <- c(8, 60, 30, 2)
> prop.test(female, total)
```

4-sample test for equality of proportions without continuity
correction

```
data:  female out of total
X-squared = 6.2646, df = 3, p-value = 0.09942
alternative hypothesis: two.sided
sample estimates:
  prop 1    prop 2    prop 3    prop 4 
0.5000000 0.7166667 0.7333333 0.0000000 
Warning message:
Chi-squared approximation may be incorrect in:
prop.test(female, total)
```

Tuy tỉ lệ nữ giới giữa các nhóm có vẻ khác nhau lớn (73% trong nhóm 3 (người da trắng) so với 50% trong nhóm 1 (châu Phi) và 71.7% trong nhóm châu Á, nhưng kiểm định Chi bình phương cho biết trên phương diện thống kê, các tỉ lệ này không khác nhau, vì trị số $p = 0.099$.

9.12.1 Kiểm định Khi bình phương (*Chi-squared test, chisq.test*)

Thật ra, kiểm định Khi bình phương còn có thể tính toán bằng hàm `chisq.test` như sau:

```
> chisq.test(sex, ethnicity)
```

Pearson's Chi-squared test

```
data:  sex and ethnicity
X-squared = 6.2646, df = 3, p-value = 0.09942

Warning message:
Chi-squared approximation may be incorrect in:
chisq.test(sex, ethnicity)
```

Kết quả này hoàn toàn giống với kết quả từ hàm `prop.test`.

9.12.2 Kiểm định Fisher (Fisher's exact test, *fisher.test*)

Trong kiểm định Khi bình phương trên, chúng ta chú ý cảnh báo:

"Warning message:

Chi-squared approximation may be incorrect in:
`prop.test(female, total) "`

Vì trong nhóm 4, không có nữ giới cho nên tỉ lệ là 0%. Hơn nữa, trong nhóm này chỉ có 2 đối tượng. Vì số lượng đối tượng quá nhỏ, cho nên các ước tính thống kê có thể không đáng tin cậy. Một phương pháp khác có thể áp dụng cho các nghiên cứu với tần số thấp như trên là kiểm định *fisher* (còn gọi là Fisher's exact test). Bạn đọc có thể tham khảo lý thuyết đằng sau kiểm định *fisher* để hiểu rõ hơn về logic của phương pháp này, nhưng ở đây, chúng ta chỉ quan tâm đến cách dùng R để tính toán kiểm định này. Chúng ta chỉ đơn giản lệnh:

```
> fisher.test(sex, ethnicity)
```

Fisher's Exact Test for Count Data

```
data: sex and ethnicity
```

```
p-value = 0.1048
```

```
alternative hypothesis: two.sided
```

Chú ý trị số *p* từ kiểm định Fisher là 0.1048, tức rất gần với trị số *p* của kiểm định Khi bình phương. Cho nên, chúng ta có thêm bằng chứng để khẳng định rằng tỉ lệ nữ giới giữa các sắc tộc không khác nhau một cách đáng kể.

10 Phân tích hồi qui tuyến tính

Phân tích hồi qui tuyến tính (linear regression analysis) có lẽ là một trong những phương pháp phân tích số liệu thông dụng nhất trong thống kê học. Có người từng viết “Cho con người 3 vũ khí - hệ số tương quan, hồi qui tuyến tính và một cây bút, con người sẽ sử dụng cả ba”! Trong chương này, tôi sẽ giới thiệu cách sử dụng R để phân tích hồi qui tuyến tính và các phương pháp liên quan như hệ số tương quan và kiểm định giả thiết thống kê.

Ví dụ 1: Để minh họa cho vấn đề, chúng ta thử xem xét nghiên cứu sau đây, mà trong đó nhà nghiên cứu đo lường độ cholesterol trong máu của 18 đối tượng nam. Tỉ trọng cơ thể (body mass index) cũng được ước tính cho mỗi đối tượng bằng công thức tính BMI là lấy trọng lượng (tính bằng kg) chia cho chiều cao bình phương (m^2). Kết quả đo lường như sau:

Bảng 1. Độ tuổi, tỉ trọng cơ thể và cholesterol.

MÃ SỐ ID (ID)	ĐỘ TUỔI (AGE)	BMI (BMI)	CHOLESTEROL (CHOL)
1	46	25.4	3.5
2	20	20.6	1.9
3	52	26.2	4.0
4	30	22.6	2.6
5	57	25.4	4.5
6	25	23.1	3.0
7	28	22.7	2.9
8	36	24.9	3.8
9	22	19.8	2.1
10	43	25.3	3.8

11	57	23.2	4.1
12	33	21.8	3.0
13	22	20.9	2.5
14	63	26.7	4.6
15	40	26.4	3.2
16	48	21.2	4.2
17	28	21.2	2.3
18	49	22.8	4.0

Nhìn sơ qua số liệu chúng ta thấy người có độ tuổi càng cao độ cholesterol cũng càng cao. Chúng ta thử nhập số liệu này vào R và vẽ một biểu đồ tán xạ như sau:


```
> age <- c(46,20,52,30,57,25,28,36,22,43,57,33,
           22,63,40,48,28,49)

> bmi <-c(25.4,20.6,26.2,22.6,25.4,23.1,22.7,24.9,
          19.8,25.3,23.2,21.8,20.9,26.7,26.4,21.2,
          21.2,22.8)

> chol <- c(3.5,1.9,4.0,2.6,4.5,3.0,2.9,3.8,
            2.1,3.8,4.1,3.0, 2.5,4.6,3.2,
            4.2,2.3,4.0)

> data <- data.frame(age, bmi, chol)

> plot(chol ~ age, pch=16)
```



Biểu đồ 1. Liên hệ giữa độ tuổi và cholesterol.

Biểu đồ 1 trên cho thấy mối liên hệ giữa độ tuổi (age) và cholesterol là một đường thẳng (tuyến tính). Để “đo lường” mối liên hệ này, chúng ta có thể sử dụng hệ số tương quan (coefficient of correlation).

10.1 Hệ số tương quan

Hệ số tương quan (r) là một chỉ số thống kê đo lường mối liên hệ tương quan giữa hai biến số, như giữa độ tuổi (x) và cholesterol (y). Hệ số tương quan có giá trị từ -1 đến 1. Hệ số tương quan bằng 0 (hay gần 0) có nghĩa là hai biến số không có liên hệ gì với nhau; ngược lại nếu hệ số bằng -1 hay 1 có nghĩa là hai biến số có một mối liên hệ tuyệt đối. Nếu giá trị của hệ số tương quan là âm ($r < 0$) có nghĩa là khi x tăng cao thì y giảm (và ngược lại, khi x giảm thì y tăng); nếu giá trị hệ số tương quan là dương ($r > 0$) có nghĩa là khi x tăng cao thì y cũng tăng, và khi x giảm cao thì y cũng giảm theo.

Thực ra có nhiều hệ số tương quan trong thống kê, nhưng ở đây tôi sẽ trình bày 3 hệ số tương quan thông dụng nhất: hệ số tương quan Pearson r , Spearman ρ , và Kendall τ .

10.1.1 Hệ số tương quan Pearson

Cho hai biến số x và y từ n mẫu, hệ số tương quan Pearson được ước tính bằng công thức sau đây:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

Trong đó, như định nghĩa phần trên, $\bar{x}$ và $\bar{y}$ là giá trị trung bình của biến số x và y . Để ước tính hệ số tương quan giữa độ tuổi age và cholesterol, chúng ta có thể sử dụng hàm `cor(x, y)` như sau:

```
> cor(age, chol)
[1] 0.936726
```

Chúng ta có thể kiểm định giả thiết hệ số tương quan bằng 0 (tức hai biến x và y không có liên hệ). Phương pháp kiểm định này thường dựa vào phép biến đổi Fisher mà R đã có sẵn một hàm `cor.test` để tiến hành việc tính toán.

```
> cor.test(age, chol)
Pearson's product-moment correlation
data: age and chol
t = 10.7035, df = 16, p-value = 1.058e-08
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.8350463 0.9765306
sample estimates:
      cor
0.936726
```

Kết quả phân tích cho thấy kiểm định $t = 10.70$ với trị số $p = 1.058e-08$; do đó, chúng ta có bằng chứng để kết luận rằng mối liên hệ giữa độ tuổi và cholesterol có ý nghĩa thống kê. Kết luận này cũng chính là kết luận chúng ta đã đi đến trong phân phân tích hồi qui tuyến tính trên.

10.1.2 Hệ số tương quan Spearman ρ

Hệ số tương quan Pearson chỉ hợp lí nếu biến số x và y tuân theo luật phân phối chuẩn. Nếu x và y không tuân theo luật phân phối chuẩn, chúng ta phải sử dụng một hệ số tương quan khác tên là Spearman, một phương pháp phân tích phi tham số. Hệ số này được ước tính bằng cách biến đổi hai biến số x và y thành thứ bậc (rank), và xem độ tương quan giữa hai dãy số bậc. Do đó, hệ số còn có tên tiếng Anh là Spearman's Rank correlation. R ước tính hệ số tương quan Spearman bằng hàm `cor.test` với thông số `method="spearman"` như sau:

```
> cor.test(age, chol, method="spearman")

Spearman's rank correlation rho
data: age and chol
S = 51.1584, p-value = 2.57e-09
alternative hypothesis: true rho is not equal to 0
sample estimates: rho = 0.947205
Warning message:
Cannot compute exact p-values with ties in: cor.test.
default(age, chol, method = "spearman")
```

Kết quả phân tích cho thấy giá trị $\rho=0.947$, và trị số $p=0.00000000257$. Kết quả từ phân tích này cũng không khác với phân tích hồi qui tuyến tính: mối liên hệ giữa độ tuổi và cholesterol rất cao và có ý nghĩa thống kê.

10.1.3 Hệ số tương quan Kendall τ

Hệ số tương quan Kendall (cũng là một phương pháp phân tích phi tham số) được ước tính bằng cách tìm các cặp số (x, y) “song hành” với nhau. Một cặp (x, y) song hành ở đây được định nghĩa là hiệu (độ khác biệt) trên trục hoành có cùng dấu hiệu (dương hay âm) với hiệu trên trục tung. Nếu hai biến số x và y không có liên hệ với nhau, thì số cặp song hành bằng hay tương đương với số cặp không song hành.

Bởi vì có nhiều cặp phải kiểm định, phương pháp tính toán hệ số tương quan Kendall đòi hỏi thời gian của máy tính khá cao. Tuy nhiên, nếu một dữ liệu dưới 5000 đối tượng thì một máy vi tính có thể tính toán khá dễ dàng. R dùng hàm `cor.test` với thông số `method="kendall"` để ước tính hệ số tương quan Kendall:

```
> cor.test(age, chol, method="kendall")
```

```
Kendall's rank correlation tau
```

```
data: age and chol
```

```
z = 4.755, p-value = 1.984e-06
```

```
alternative hypothesis: true tau is not equal to 0
```

```
sample estimates:
```

```
tau
```

```
0.8333333
```

```
Warning message:
```

```
Cannot compute exact p-value with ties in: cor.test.
```

```
default(age, chol, method = "kendall")
```

Kết quả phân tích hệ số tương quan Kendall một lần nữa khẳng định mối liên hệ giữa độ tuổi và cholesterol có ý nghĩa thống kê, vì hệ số $\tau = 0.833$ và trị số $p = 1.98e-06$.

Các hệ số tương quan trên đây đo mức độ tương quan giữa hai biến số, nhưng không cho chúng ta một phương trình để nối hai biến số đó với nhau. Do đó, vấn đề đặt ra là chúng ta tìm một phương trình tuyến tính để mô tả mối liên hệ này. Chúng ta sẽ ứng dụng mô hình hồi qui tuyến tính.

10.2 Mô hình hồi qui tuyến tính đơn giản

10.2.1 Vài hàng lí thuyết

Để tiện việc theo dõi và mô tả mô hình, gọi độ tuổi cho cá nhân i là x_i và cholesterol là y_i . Ở đây $i = 1, 2, 3, \dots, 18$. Mô hình hồi qui tuyến tính phát biểu rằng:

$$y_i = \alpha + \beta x_i + \varepsilon_i \quad [1]$$

Nói cách khác, phương trình trên giả định rằng độ cholesterol của một cá nhân bằng một hằng số α cộng với một hệ số β liên quan đến độ tuổi, và một sai số ε_i . Trong phương trình trên, α là *chặn* (intercept, tức giá trị lúc $x_i = 0$), và β là độ dốc (slope hay gradient). Trong thực tế, α và β là hai thông số (parameter, còn gọi là *regression coefficient* hay hệ số hồi qui), và ε_i là một biến số theo luật phân phối chuẩn với trung bình 0 và phương sai σ^2 .

Các thông số α , β và σ^2 phải được ước tính từ dữ liệu. Phương pháp để ước tính các thông số này là phương pháp *bình phương nhỏ nhất* (least squares method). Như tên gọi, phương pháp bình phương nhỏ nhất tìm giá trị α , β sao cho $\sum_{i=1}^n [y_i - (\alpha + \beta x_i)]^2$ nhỏ nhất. Sau vài thao tác toán, có thể chứng minh dễ dàng rằng, ước số cho α và β đáp ứng điều kiện đó là:

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad [2]$$

và

$$\hat{\alpha} = \bar{y} - \hat{\beta} \bar{x} \quad [3]$$

Ở đây, $\bar{x}$ và $\bar{y}$ là giá trị trung bình của biến số x và y . Chú ý, chúng ta viết $\hat{\alpha}$ và $\hat{\beta}$ (với dấu mũ phía trên) là để nhắc nhở rằng đây là hai ước số (estimates) của α và β , chứ không phải α và β (chúng ta không biết chính xác α và β , nên chỉ có thể ước tính mà thôi).

Sau khi đã có ước số $\hat{\alpha}$ và $\hat{\beta}$, chúng ta có thể ước tính độ cholesterol trung bình cho từng độ tuổi như sau:

$$\hat{y}_i = \hat{\alpha} + \hat{\beta} x_i$$

Tất nhiên, $\hat{y}_i$ ở đây chỉ là số trung bình cho độ tuổi x_i , và phần còn lại (tức $y_i - \hat{y}_i$) gọi là *phần dư* (hay *residual*). Và phương sai của phần dư có thể ước tính như sau:

$$s^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n-2} \quad [4]$$

s^2 chính là ước số của σ^2 .

Trong phân tích hồi qui tuyến tính, thông thường chúng ta muốn biết hệ số $\beta = 0$ hay khác 0. Nếu β bằng 0, thì $y_i = \alpha + \beta x_i + \varepsilon_i = \alpha + \varepsilon_i$, tức là những khác biệt giữa các đối tượng về cholesterol chỉ xoay quanh số trung bình và sai số ngẫu nhiên ε , hay nói cách khác, không có mối liên hệ gì giữa x và y ; nếu β khác với 0, chúng ta có bằng chứng để phát biểu rằng x và y có liên quan nhau. Để kiểm định giả thiết $\beta = 0$ chúng ta dùng xét nghiệm t sau đây:

$$t = \frac{\hat{\beta}}{SE(\hat{\beta})} \quad [5]$$

$SE(\hat{\beta})$ có nghĩa là sai số chuẩn (standard error) của ước số $\hat{\beta}$. Trong phương trình trên, t tuân theo luật phân phối t với bậc tự do $n-2$ (nếu thật sự $\beta = 0$).

10.2.2 Phân tích hồi qui tuyến tính đơn giản bằng R

Hàm `lm` (viết tắt từ **linear model**) trong R có thể tính toán các giá trị của $\hat{\alpha}$ và $\hat{\beta}$, cũng như s^2 một cách nhanh gọn. Chúng ta tiếp tục với ví dụ bằng R như sau:

```
> lm(chol ~ age)
```

```
Call:
```

```
lm(formula = chol ~ age)
```

```
Coefficients:
```

```
(Intercept)          age
  1.08922         0.05779
```

Trong lệnh trên, "chol ~ age" có nghĩa là mô tả chol là một hàm số của age. Kết quả tính toán của lm cho thấy $\hat{\alpha} = 1.0892$ và $\hat{\beta} = 0.05779$. Nói cách khác, với hai thông số này, chúng ta có thể ước tính độ cholesterol cho bất cứ độ tuổi nào trong khoảng tuổi của mẫu bằng phương trình tuyến tính:

$$\hat{y}_i = 1.08922 + 0.05779 \times \text{age}$$

Phương trình này có nghĩa là khi độ tuổi tăng 1 năm thì độ cholesterol tăng khoảng 0.058 mmol/L.

Thật ra, hàm lm còn cung cấp cho chúng ta nhiều thông tin khác, nhưng chúng ta phải đưa các thông tin này vào một object. Gọi object đó là reg, thì lệnh sẽ là:

```
> reg <- lm(chol ~ age)
> summary(reg)
```

```
Call: lm(formula = chol ~ age)
```

```
Residuals:
```

Min	1Q	Median	3Q	Max
-0.40729	-0.24133	-0.04522	0.17939	0.63040

```
Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.089218	0.221466	4.918	0.000154 ***
age	0.057788	0.005399	10.704	1.06e-08 ***

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.3027 on 16 degrees of freedom
```

```
Multiple R-Squared: 0.8775, Adjusted R-squared: 0.8698
```

```
F-statistic: 114.6 on 1 and 16 DF, p-value: 1.058e-08
```

Lệnh thứ hai, summary(reg), yêu cầu R liệt kê các thông tin tính toán trong reg. Phần kết quả chia làm 3 phần:

(a) Phần 1 mô tả phần dư (residuals) của mô hình hồi qui:

```
Residuals:
```

Min	1Q	Median	3Q	Max
-0.40729	-0.24133	-0.04522	0.17939	0.63040

Chúng ta biết rằng trung bình phần dư phải là 0, và ở đây, số trung vị là -0.04, cũng không xa 0 bao nhiêu. Các số quantiles 25% (1Q) và 75% (3Q) cũng khá cân đối chung quanh số trung vị, cho thấy phần dư của phương trình này tương đối cân đối.

(b) Phần hai trình bày ước số của $\hat{\alpha}$ và $\hat{\beta}$ cùng với sai số chuẩn và giá trị của kiểm định t. Giá trị kiểm định t cho $\hat{\beta}$ là 10.74 với trị số p=0.0000000106, cho thấy β không phải bằng 0. Nói cách khác, chúng ta có bằng chứng để cho rằng có một mối liên hệ giữa cholesterol và độ tuổi, và mối liên hệ này có ý nghĩa thống kê.

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	1.089218	0.221466	4.918	0.000154	***
age	0.057788	0.005399	10.704	1.06e-08	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(c) Phần ba của kết quả cho chúng ta thông tin về phương sai của phần dư (residual mean square). Ở đây, $s^2 = 0.3027$. Trong kết quả này còn có kiểm định F, cũng chỉ là một kiểm định xem có quả thật β bằng 0, tức có ý nghĩa tương tự như kiểm định t trong phần trên. Nói chung, trong trường hợp phân tích hồi qui tuyến tính đơn giản (với một yếu tố) chúng ta không cần phải quan tâm đến kiểm định F.

Residual standard error: 0.3027 on 16 degrees of freedom

Multiple R-Squared: 0.8775, Adjusted R-squared: 0.8698

F-statistic: 114.6 on 1 and 16 DF, p-value: 1.058e-08

Ngoài ra, phần 3 còn cho chúng ta một thông tin quan trọng, đó là trị số R^2 hay *hệ số xác định bội* (coefficient of determination). Hệ số này được ước tính bằng công thức:

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad [6]$$

Tức là bằng tổng bình phương giữa số ước tính và trung bình chia cho tổng bình phương số quan sát và trung bình. Trị số R^2 trong ví dụ này là 0.8775, có nghĩa là phương trình tuyến tính (với độ tuổi là một yếu tố) giải thích khoảng 88% các khác biệt về độ cholesterol giữa các cá nhân. Tất nhiên trị số R^2 có giá trị từ 0 đến 100% (hay 1). Giá trị R^2 càng cao là một dấu hiệu cho thấy mối liên hệ giữa hai biến số độ tuổi và cholesterol càng chặt chẽ.

Một hệ số cũng cần đề cập ở đây là *hệ số điều chỉnh xác định bội* (mà trong kết quả trên R gọi là “Adjusted R-squared”). Đây là hệ số cho chúng ta biết mức độ cải tiến của phương sai phần dư (residual variance) do yếu tố độ tuổi có mặt trong mô hình tuyến tính. Nói chung, hệ số này không khác mấy so với hệ số xác định bội, và chúng ta cũng không cần chú tâm quá mức.

10.2.3 Giả định của phân tích hồi qui tuyến tính

Tất cả các phân tích trên dựa vào một số giả định quan trọng như sau:

(a) x là một biến số cố định hay fixed, (“cố định” ở đây có nghĩa là không có sai sót ngẫu nhiên trong đo lường);

(b) ϵ_i phân phối theo luật phân phối chuẩn;

(c) ϵ_i có giá trị trung bình (mean) là 0;

(d) ϵ_i có phương sai σ^2 cố định cho tất cả x_i ; và

(e) các giá trị liên tục của ϵ_i không có liên hệ tương quan với nhau (nói cách khác, ϵ_1 và ϵ_2 không có liên hệ với nhau).

Nếu các giả định này không được đáp ứng thì mô hình mà chúng ta ước tính có vấn đề hợp lý (validity). Do đó, trước khi trình bày và diễn dịch mô hình trên, chúng ta cần phải kiểm tra xem các giả định trên có đáp ứng được hay không. Trong trường hợp này, giả định (a) không phải là vấn đề, vì độ tuổi không phải là một biến số ngẫu nhiên, và không có sai số khi tính độ tuổi của một cá nhân.

Đối với các giả định (b) đến (e), cách kiểm tra đơn giản nhưng hữu hiệu nhất là bằng cách xem xét mối liên hệ giữa $\hat{y}_i$, x_i , và phần dư e_i ($e_i = y_i - \hat{y}_i$) bằng những đồ thị tán xạ.

Với lệnh `fitted()` chúng ta có thể tính toán $\hat{y}_i$ cho từng cá nhân như sau (ví dụ đối với đối tượng số 1, 46 tuổi, độ cholesterol có thể tiên đoán như sau: $1.08922 + 0.05779 \times 46 = 3.747$).

```
> fitted(reg)
1          2          3          4          5          6          7          8
3.7474 2.2449 4.0942 2.8228 4.3831 2.5339 2.7072 3.1696

9          10         11          12         13          14         15         16
2.3605 3.5741 4.3831 2.9962 2.3605 4.7298 3.4007 3.8630


17         18
2.7072 3.9208
```

Với lệnh `resid()` chúng ta có thể tính toán phần dư e_i cho từng cá nhân như sau (với đối tượng 1, $e_1 = 3.5 - 3.74748 = -0.24748$):

```
> resid(reg)
1          2          3          4          5          6
-0.2474 -0.3449 -0.0942 -0.2228 0.1168 0.4660

7          8          9          10         11         12
0.1927 0.6304 -0.2605 0.2258 -0.2831 0.0037

13         14         15         16         17         18
0.1394 -0.1298 -0.2007 0.3369 -0.4072 0.0791
```



Biểu đồ 2. Phân tích phần dư để kiểm tra các giả định trong phân tích hồi quy tuyến tính.

Để kiểm tra các giả định trên, chúng ta có thể vẽ một loạt 4 đồ thị trên như sau:

```
> op <- par(mfrow=c(2,2)) #yêu cầu R dành ra 4 cửa sổ
> plot(reg)                #vẽ các đồ thị trong reg
```

(a) Đồ thị bên trái dòng 1 vẽ phần dư e_i và giá trị tiên đoán cholesterol $\hat{y}_i$. Đồ thị này cho thấy các giá trị phần dư tập trung quanh đường $y = 0$, cho nên giả định (c), hay ϵ_i có giá trị trung bình 0, là có thể chấp nhận được.

(b) Đồ thị bên phải dòng 1 vẽ giá trị phần dư và giá trị kì vọng dựa vào phân phối chuẩn. Chúng ta thấy các số phần dư tập trung rất gần các giá trị trên đường chuẩn, và do đó, giả định (b), tức ϵ_i phân phối theo luật phân phối chuẩn, cũng có thể đáp ứng.


(c) Đồ thị bên trái dòng 2 vẽ căn số phần dư chuẩn (standardized residual) và giá trị của $\hat{y}_i$. Đồ thị này cho thấy không có gì khác nhau giữa các số phần dư chuẩn cho các giá trị của $\hat{y}_i$, và do đó, giả định (d), tức ϵ_i có phương sai σ^2 cố định cho tất cả x_i , cũng có thể đáp ứng.

Nói chung qua phân tích phần dư, chúng ta có thể kết luận rằng mô hình hồi qui tuyến tính mô tả mối liên hệ giữa độ tuổi và cholesterol một cách khá đầy đủ và hợp lí.

10.2.4 Mô hình tiên lượng

Sau khi mô hình tiên đoán cholesterol đã được kiểm tra và tính hợp lí đã được thiết lập, chúng ta có thể vẽ đường biểu diễn của mối liên hệ giữa độ tuổi và cholesterol bằng lệnh `abline` như sau (xin nhắc lại object của phân tích là `reg`):

```
> plot(chol ~ age, pch=16)
> abline(reg)
```




Biểu đồ 3. Đường biểu diễn mối liên hệ giữa độ tuổi (age) và cholesterol.

Nhưng mỗi giá trị $\hat{y}_i$ được tính từ ước số $\hat{\alpha}$ và $\hat{\beta}$, mà các ước số này đều có sai số chuẩn, cho nên giá trị tiên đoán $\hat{y}_i$ cũng có sai số. Nói cách khác, $\hat{y}_i$ chỉ là trung bình, nhưng trong thực tế có thể cao hơn hay thấp hơn tùy theo chọn mẫu. Khoảng tin cậy 95% này có thể ước tính qua R bằng các lệnh sau đây:

```
> reg <- lm(chol ~ age)
> new <- data.frame(age = seq(15, 70, 5))
> pred.w.plim <- predict.lm(reg, new, interval="prediction")
> pred.w.clim <- predict.lm(reg, new, interval="confidence")
> resc <- cbind(pred.w.clim, new)
> resp <- cbind(pred.w.plim, new)
> plot(chol ~ age, pch=16)
> lines(resc$fit ~ resc$age)
> lines(resc$lwr ~ resc$age, col=2)
> lines(resc$upr ~ resc$age, col=2)
> lines(resp$lwr ~ resp$age, col=4)
> lines(resp$upr ~ resp$age, col=4)
```

(Chú ý: trong các lệnh trên, chúng ta sử dụng những biến số như `resc$fit`, `resc$lwr`, `resc$upr`, `resp$lwr`, `resp$upr`. Cách viết này có nghĩa là trích biến số `fit` từ đối tượng `resc`, hay `lwr` và `upr` (khoảng tin cậy 95%) của `resc`).



Biểu đồ 4. Giá trị tiên đoán và khoảng tin cậy 95%.

Biểu đồ 4 vẽ giá trị tiên đoán trung bình $\hat{y}_i$ (đường thẳng màu đen), và khoảng tin cậy 95% của giá trị này là đường màu đỏ. Ngoài ra, đường màu xanh là khoảng tin cậy của giá trị tiên đoán cholesterol cho một độ tuổi mới trong quần thể.

10.3 Mô hình hồi qui tuyến tính đa biến (multiple linear regression)

Mô hình được diễn đạt qua phương trình [1] $y_i = \alpha + \beta x_i + \varepsilon_i$ có một yếu tố duy nhất (đó là x), và vì thế thường được gọi là mô hình hồi qui tuyến tính đơn giản (simple linear regression model). Trong thực tế, chúng ta có thể phát triển mô hình này thành nhiều biến, chứ không chỉ giới hạn một biến như trên, chẳng hạn như:

$$y_i = \alpha + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + \varepsilon_i \quad [7]$$

Nói cụ thể hơn:

$$y_1 = \alpha + \beta_1 x_{11} + \beta_2 x_{21} + \dots + \beta_k x_{k1} + \varepsilon_1$$

$$y_2 = \alpha + \beta_1 x_{12} + \beta_2 x_{22} + \dots + \beta_k x_{k2} + \varepsilon_2$$

$$y_3 = \alpha + \beta_1 x_{13} + \beta_2 x_{23} + \dots + \beta_k x_{k3} + \varepsilon_3$$

...

$$y_n = \alpha + \beta_1 x_{1n} + \beta_2 x_{2n} + \dots + \beta_k x_{kn} + \varepsilon_n$$

Chú ý trong phương trình trên, chúng ta có nhiều biến x ($x_1, x_2, \dots$ đến x_k), và mỗi biến có một thông số β_j ($j = 1, 2, \dots, k$) cần phải ước tính. Vì thế mô hình này còn được gọi là mô hình hồi qui tuyến tính đa biến.

Phương pháp ước tính β_j cũng chủ yếu dựa vào phương pháp bình phương nhỏ nhất. Gọi $\hat{y}_i = \hat{\alpha} + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + \dots + \hat{\beta}_k x_{ki}$ là ước tính của y_i , phương pháp bình phương nhỏ nhất tìm giá trị $\hat{\alpha}, \hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_k$ sao cho $\sum_{i=1}^n (y_i - \hat{y}_i)^2$ nhỏ nhất.

Đối với mô hình hồi qui tuyến tính đa biến, cách viết và mô tả mô hình gọn nhất là dùng kí hiệu ma trận. Mô hình [7] có thể thể hiện bằng kí hiệu ma trận như sau:

$$Y = X\beta + \varepsilon$$

Trong đó: Y là một vector $n \times 1$, X là một ma trận $n \times k$ phần tử, β và một vector $k \times 1$, và ε là vector gồm $n \times 1$ phần tử:

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{bmatrix}, \quad X = \begin{bmatrix} 1 & x_{11} & x_{21} & \dots x_{k1} \\ 1 & x_{12} & x_{22} & \dots x_{k2} \\ \dots & \dots & \dots & \dots \\ 1 & x_{1n} & x_{2n} & x_{kn} \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \dots \\ \beta_k \end{bmatrix}, \quad \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \dots \\ \varepsilon_n \end{bmatrix}$$

Phương pháp bình phương nhỏ nhất giải vector β bằng phương trình sau đây:


$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

và tổng bình phương phần dư:

$$\varepsilon^T \varepsilon = \|Y - \hat{Y}\|^2$$

Ví dụ 2: Chúng ta quay lại nghiên cứu về mối liên hệ giữa độ tuổi, bmi và cholesterol. Trong ví dụ, chúng ta chỉ mới xét mối liên hệ giữa độ tuổi và cholesterol, mà chưa xem đến mối liên hệ giữa cả ba yếu tố độ tuổi, bmi và cholesterol. Biểu đồ 5 sau đây cho chúng ta thấy mối liên hệ giữa ba biến số này:

```
> pairs(data)
```



Biểu đồ 5. Giá trị tiên đoán và khoảng tin cậy 95%.

Cũng như giữa độ tuổi và cholesterol, mối liên hệ giữa bmi và cholesterol cũng gần tuân theo một đường thẳng. Biểu đồ trên còn cho chúng ta thấy độ tuổi và bmi có liên hệ với nhau. Thật vậy, phân tích hồi qui tuyến tính đơn giản giữa bmi và cholesterol cho thấy mối liên hệ này có ý nghĩa thống kê:

```
> summary(lm(chol ~ bmi))

Call: lm(formula = chol ~ bmi)

Residuals:
    Min       1Q   Median       3Q      Max
-0.9403 -0.3565 -0.1376  0.3040  1.4330

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -2.83187     1.60841  -1.761  0.09739 .
bmi           0.26410     0.06861   3.849  0.00142 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.623 on 16 degrees of freedom
Multiple R-Squared:  0.4808,    Adjusted R-squared:  0.4483
F-statistic: 14.82 on 1 and 16 DF,  p-value: 0.001418
```

BMI giải thích khoảng 48% độ dao động về cholesterol giữa các cá nhân. Nhưng vì BMI cũng có liên hệ với độ tuổi, chúng ta muốn biết nếu hai yếu tố này được phân tích cùng một lúc thì yếu tố nào quan trọng hơn. Để biết ảnh hưởng của cả hai yếu tố age (x_1) và bmi (tạm gọi là x_2) đến cholesterol (y) qua một mô hình hồi qui tuyến tính đa biến, và mô hình đó là:

$$y_i = \alpha + \beta_1 x_{1i} + \beta_2 x_{2i} + \varepsilon_i$$

Hay phương trình cũng có thể mô tả bằng kí hiệu ma trận: $Y = X\beta + \varepsilon$ vừa trình bày ở trên. Ở đây, Y là một vector 18×1 , X là một matrix 18×2 phần tử, β và một vector 2×1 , và ε là vector gồm 18×1 phần tử. Để ước tính hai hệ số hồi qui, β_1 và β_2 chúng ta cũng ứng dụng hàm `lm()` trong R như sau:

```
> mreg <- lm(chol ~ age + bmi)
> summary(mreg)

Call: lm(formula = chol ~ age + bmi)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.3762	-0.2259	-0.0534	0.1698	0.5679

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.455458	0.918230	0.496	0.627
age	0.054052	0.007591	7.120	3.50e-06 ***
bmi	0.033364	0.046866	0.712	0.487

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 0.3074 on 15 degrees of freedom
Multiple R-Squared: 0.8815, Adjusted R-squared: 0.8657
F-statistic: 55.77 on 2 and 15 DF, p-value: 1.132e-07

Kết quả phân tích trên cho thấy ước số $\hat{\alpha} = 0.455$, $\hat{\beta}_1 = 0.054$ và $\hat{\beta}_2 = 0.0333$. Nói cách khác, chúng ta có phương trình ước đoán độ cholesterol dựa vào hai biến số độ tuổi và bmi như sau:

$$\text{Cholesterol} = 0.455 + 0.054(\text{age}) + 0.0333(\text{bmi})$$

Phương trình cho biết khi độ tuổi tăng 1 năm thì cholesterol tăng 0.054 mg/L (ước số này không khác mấy so với 0.0578 trong phương trình chỉ có độ tuổi), và mỗi 1 kg/m² tăng BMI thì cholesterol tăng 0.0333 mg/L. Hai yếu tố này “giải thích” khoảng 88.2% ($R^2 = 0.8815$) độ dao động của cholesterol giữa các cá nhân.

Chúng ta chú ý phương trình với độ tuổi (trong phân tích phần trước) giải thích khoảng 87.7% độ dao động cholesterol giữa các cá nhân. Khi chúng ta thêm yếu tố BMI, hệ số này tăng lên 88.2%, tức chỉ 0.5%. Câu hỏi đặt ra là 0.5% tăng trưởng này có ý nghĩa thống kê hay không. Câu trả lời có thể xem qua kết quả kiểm định yếu tố bmi với trị số $p = 0.487$. Như vậy, bmi không cung cấp cho chúng ta thêm thông tin hay tiên đoán cholesterol hơn những gì chúng ta đã có từ độ tuổi. Nói cách khác, khi độ tuổi đã được xem xét, thì ảnh hưởng của bmi không còn ý nghĩa thống kê. Điều này có thể hiểu được, bởi vì qua biểu đồ 10.5 chúng ta thấy độ tuổi và bmi có một mối liên hệ khá cao. Vì hai biến này có tương quan với nhau, chúng ta không cần cả hai trong phương trình. (Tuy nhiên, ví dụ này chỉ có tính cách minh họa cho việc tiến hành phân tích hồi qui tuyến tính đa biến bằng R, chứ không có ý định mô phỏng dữ liệu theo định hướng sinh học).



Biểu đồ 6. Phân tích phần dư để kiểm tra các giả định trong phân tích hồi qui tuyến tính đa biến.

Tuy BMI không có ý nghĩa thống kê trong trường hợp này, biểu đồ 6 cho thấy các giả định về mô hình hồi qui tuyến tính có thể đáp ứng.

10.4 Phân tích hồi qui đa thức (Polynomial regression analysis)

Một khai triển tất nhiên từ phân tích hồi qui đa biến độc lập là phân tích hồi qui đa thức. Mô hình hồi qui đa biến mô tả một biến phụ thuộc như là một *hàm số tuyến tính* (linear function) của nhiều biến độc lập, trong khi đó mô hình hồi qui đa thức mô tả một biến phụ thuộc là *hàm số phi tuyến tính* (non-linear function) của một biến độc lập.

Nói theo ngôn ngữ toán học, mô hình hồi qui đa thức tìm mối liên hệ giữa biến phụ thuộc y và biến độc lập x theo những hàm số sau đây:

$$y_i = \alpha + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \dots + \beta_p x^p + \varepsilon_i.$$

Trong đó các thông số β_j ($j = 1, 2, 3, \dots, p$) là hệ số đo lường mối liên hệ giữa y và x ; và ε_i là phần dư của mô hình, với giả định ε_i tuân theo luật phân phối chuẩn với trung bình 0 và phương sai σ^2 . Cho một dãy cặp số $(y_1, x_1), (y_2, x_2), (y_3, x_3), \dots, (y_n, x_n)$, chúng ta có thể áp dụng phương pháp bình phương nhỏ nhất để ước tính β_j và σ^2 .

Trong mô hình trên, chúng ta có thể dễ dàng thấy rằng mô hình hồi qui đa thức còn là một phát triển trực tiếp từ mô hình hồi qui tuyến tính đơn giản. Tức là nếu $\beta_2 = 0, \beta_3 = 0, \dots$, và $\beta_p = 0$, thì mô hình trên đơn giản thành mô hình hồi qui tuyến tính một biến mà chúng ta gặp trong phần đầu của chương này. Nếu $y_i = \alpha + \beta_1 x + \beta_2 x^2 + \varepsilon_i$ thì mô hình đơn giản là một phương trình bậc hai, v.v.

Ví dụ 3: Thí nghiệm sau đây tìm mối liên hệ giữa hàm lượng gỗ cứng (hardwood concentration) và độ căng (tensile strength) của vật liệu. Mười chín vật liệu khác nhau với nhiều hàm lượng gỗ cứng được thử nghiệm để đo độ căng mạnh của vật liệu, và kết quả được tóm lược trong bảng số liệu sau đây:

ID	HÀM LƯỢNG GỖ CỨNG (X)	ĐỘ CĂNG MẠNH (Y)
1	1.0	6.3
2	1.5	11.1
3	2.0	20.0
4	3.0	24.0
5	4.0	26.1
6	4.5	30.0
7	5.0	33.8
8	5.5	34.0
9	6.0	38.1
10	6.5	39.9
11	7.0	42.0
12	8.0	46.1
13	9.0	53.1
14	10.0	52.0
15	11.0	52.5
16	12.0	48.0
17	13.0	42.8
18	14.0	27.8
19	15.0	21.9

Trước khi phân tích các số liệu này, chúng ta cần nhập số liệu vào R với những lệnh thông thường như sau:

```
> id <- 1:19

> conc <- c(1.0, 1.5, 2.0, 3.0, 4.0, 4.5, 5.0, 5.5,
            6.0, 6.5, 7.0, 8.0, 9.0, 10.0, 11.0, 12.0,
            13.0, 14.0, 15.0)

> strength <- c(6.3, 11.1, 20.0, 24.0, 26.1, 30.0,
               33.8, 34.0, 38.1, 39.9, 42.0, 46.1,
               53.1, 52.0, 52.5, 48.0, 42.8, 27.8, 21.9)

> data <- data.frame(id, conc, strength)
```

Chúng ta thử xem mô hình hồi qui tuyến tính đơn giản bằng lệnh:

```
> simple.model <- lm(strength ~ conc)
> summary(simple.model)
```

Call: lm(formula = strength ~ conc)

Residuals:

Min	1Q	Median	3Q	Max
-25.986	-3.749	2.938	7.675	15.840

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	21.3213	5.4302	3.926	0.00109 **
conc	1.7710	0.6478	2.734	0.01414 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 11.82 on 17 degrees of freedom
 Multiple R-Squared: 0.3054, Adjusted R-squared: 0.2645
 F-statistic: 7.474 on 1 and 17 DF, p-value: 0.01414

Kết quả trên cho thấy mô hình hồi qui tuyến tính đơn giản này ($\text{strength} = 21.32 + 1.77 \cdot \text{conc}$) giải thích khoảng 31% phương sai của strength. Ước số phương sai của mô hình này là: $s^2 = (11.82)^2 = 139.7$.

Bây giờ chúng ta xem qua biểu đồ và đường biểu diễn của mô hình trên:

```
> plot(strength ~ conc,
       xlab="Concentration of hardwood",
       ylab="Tensile strength",
       main="Relationship between hardwood concentration
            \n and tensile strengt", pch=16)

> abline(simple.model)
```



Biểu đồ 7. Mối liên hệ giữa hàm lượng gỗ cứng và độ căng mạnh của vật liệu.
Đường thẳng là đường biểu diễn của mô hình hồi qui tuyến tính đơn giản.

Qua biểu đồ này, chúng ta thấy rõ ràng mô hình hồi qui tuyến tính không thích hợp cho số liệu, bởi vì mối liên hệ giữa hai biến này không tuân theo một phương trình đường thẳng, mà là một đường cong. Nói cách khác, một mô hình phương trình bậc hai có lẽ thích hợp hơn. Gọi y là strength và x là conc, chúng ta có thể viết mô hình đó như sau:

$$y_i = \alpha + \beta_1 x + \beta_2 x^2$$

Bây giờ chúng ta sẽ sử dụng R để ước tính ba thông số trên.

```
> quadratic <- lm(strength ~ poly(conc, 2))
> summary(quadratic)
```

Call:

```
lm(formula = strength ~ poly(conc, 2))
```

Residuals:

Min	1Q	Median	3Q	Max
-5.8503	-3.2482	-0.7267	4.1350	6.5506

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	34.184	1.014	33.709	2.73e-16 ***
poly(conc, 2)1	32.302	4.420	7.308	1.76e-06 ***
poly(conc, 2)2	-45.396	4.420	-10.270	1.89e-08 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '.' 0.05 ' ' 1

Residual standard error: 4.42 on 16 degrees of freedom

Multiple R-Squared: 0.9085, Adjusted R-squared: 0.8971

F-statistic: 79.43 on 2 and 16 DF, p-value: 4.912e-09

Như vậy, mô hình mới:

$$y = 34.18 + 32.30x - 45.4x^2$$

giải thích khoảng 91% phương sai của y . Phương sai của y bây giờ là $s^2 = (4.42)^2 = 19.5$. So với mô hình tuyến tính, mô hình này rõ ràng là tốt hơn rất nhiều.

Chúng ta thử xét một mô hình cubic (bậc ba):

$$y_i = \alpha + \beta_1 x + \beta_2 x^2 + \beta_3 x^3$$

Xem có mô tả y tốt hơn mô hình phương trình bậc hai hay không.

```
> cubic <- lm(strength ~ poly(conc, 3))
```

```
> summary(cubic)
```

```
Call: lm(formula = strength ~ poly(conc, 3))
```

Residuals:

	Min	1Q	Median	3Q	Max
	-4.62503	-1.61085	0.04125	1.58922	5.02159

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	34.1842	0.5931	57.641	< 2e-16 ***
poly(conc, 3)1	32.3021	2.5850	12.496	2.48e-09 ***
poly(conc, 3)2	-45.3963	2.5850	-17.561	2.06e-11 ***
poly(conc, 3)3	-14.5740	2.5850	-5.638	4.72e-05 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '.' 0.05 ' ' 1

Residual standard error: 2.585 on 15 degrees of freedom

Multiple R-Squared: 0.9707, Adjusted R-squared: 0.9648

F-statistic: 165.4 on 3 and 15 DF, p-value: 1.025e-11

Mô hình cubic này thậm chí có khả năng mô tả y tốt hơn hai mô hình trước, với hệ số xác định bội (R^2) bằng 0.97, và tất cả các thông số trong mô hình đều có ý nghĩa thống kê. Biểu đồ sau đây so sánh 3 mô hình trên:

lặp lại các mô hình trên:

```
> linear <- lm(strength ~ conc)
> quadratic <- lm(strength ~ poly(conc, 2))
> cubic <- lm(strength ~ poly(conc, 3))
```

tạo nên một biến x với nhiều số gần nhau


```
> xnew <- (0:160)/10
```

Tính giá trị tiên đoán (predictive values) của y

```
> y2 = predict(quadratic, data.frame(conc=xnew))
> y3 = predict(cubic, data.frame(conc=xnew))
```

Vẽ 3 đường thẳng, bậc hai và bậc 3

```
> plot(strength ~ conc, pch=16,
      main="Hardwood concentration and tensile strength",
      sub="Linear, quadratic, and cubic fits")
> abline(linear, col="black")
> lines(xnew, y2, col="blue", lwd=3)
> lines(xnew, y3, col="red", lwd=4)
```



10.5 Xây dựng mô hình tuyến tính từ nhiều biến

Trong một nghiên cứu thông thường với một biến số phụ thuộc, nhiều biến số độc lập $x_1, x_2, x_3, \dots, x_k$, mà k có thể lên đến hàng chục, thậm chí hàng trăm. Các biến độc lập đó thường liên hệ với nhau. Có rất nhiều tổ hợp biến độc lập có khả năng tiên đoán biến phụ thuộc y . Ví dụ nếu chúng ta có 3 biến độc lập x_1, x_2 , và x_3 , để xây dựng mô hình tiên đoán y , chúng ta có thể phải xem xét các mô hình sau đây: $y = f_1(x_1)$, $y = f_2(x_2)$, $y = f_3(x_3)$, $y = f_4(x_1, x_2)$, $y = f_5(x_1, x_3)$, $y = f_6(x_2, x_3)$, $y = f_7(x_1, x_2, x_3)$, v.v... trong đó f_k là những hàm số được định nghĩa bởi hệ số liên quan đến các biến cụ thể. Khi k cao, số lượng mô hình cũng lên rất cao.

Vấn đề đặt ra là trong các mô hình đó, mô hình nào có thể tiên đoán y một cách đầy đủ, đơn giản và hợp lí. Chúng ta sẽ quay lại ba tiêu chuẩn này trong chương phân tích hồi qui logistic. Ở đây, chúng ta chỉ muốn bàn đến một tiêu chuẩn thống kê để xây dựng một mô hình hồi qui tuyến tính. Trong trường hợp có nhiều mô hình như thế, tiêu chuẩn thống kê để chọn một mô hình tối ưu thường dựa vào tiêu chuẩn thông tin Akaike (còn gọi là AIC hay Akaike Information Criterion).

Cho một mô hình hồi qui tuyến tính $\hat{y}_i = \hat{\alpha} + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik}$, chúng ta có $k+1$ thông số $(\hat{\alpha}, \hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_k)$, và có thể tính tổng bình phương phần dư (residual sum of squares, RSS):

$$RSS = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

Trong đó, n là số lượng mẫu. Công thức trên cho thấy nếu mô hình mô tả y đầy đủ thì RSS sẽ thấp, vì độ khác biệt giữa giá trị tiên đoán $\hat{y}$ và giá trị quan sát y gần nhau. Một qui luật chung của phân tích hồi qui tuyến tính là một mô hình với k biến độc lập sẽ có RSS thấp hơn mô hình với $k-1$ biến; và tương tự mô hình với $k-1$ biến sẽ có RSS thấp hơn mô hình với $k-2$ biến, v.v... Nói cách khác, mô hình càng có nhiều biến độc lập sẽ “giải thích” y càng tốt hơn. Nhưng vì một số biến độc lập x liên hệ với nhau, cho nên có thêm nhiều biến không có nghĩa là RSS sẽ giảm một cách có ý nghĩa. Một phép tính để dung hòa RSS và số biến độc lập trong một mô hình là AIC, được định nghĩa như sau:

$$AIC = \log \left(\frac{RSS}{n} \right) + \frac{2k}{n}$$

Mô hình nào có giá trị AIC thấp nhất được xem là mô hình “tối ưu”. Trong ví dụ sau đây, chúng ta sẽ dùng hàm *step* để tìm một mô hình tối ưu dựa vào giá trị AIC.

Ví dụ 4: Để nghiên cứu ảnh hưởng của các yếu tố như nhiệt độ, thời gian, và thành phần hóa học đến sản lượng CO_2 . Số liệu của nghiên cứu này có thể tóm lược trong bảng số 2. Mục tiêu chính của nghiên cứu là tìm một mô hình hồi qui tuyến tính để tiên đoán sản lượng CO_2 , cũng như đánh giá độ ảnh hưởng của các yếu tố này.

Bảng 2. Sản lượng CO_2 và một số yếu tố có thể ảnh hưởng đến CO_2

ID	Y	X1	X2	X3	X4	X5	X6	X7
1	36.98	5.1	400	51.37	4.24	1484.83	2227.25	2.06
2	13.74	26.4	400	72.33	30.87	289.94	434.90	1.33
3	10.08	23.8	400	71.44	33.01	320.79	481.19	0.97
4	8.53	46.4	400	79.15	44.61	164.76	247.14	0.62
5	36.42	7.0	450	80.47	33.84	1097.26	1645.89	0.22
6	26.59	12.6	450	89.90	41.26	605.06	907.59	0.76
7	19.07	18.9	450	91.48	41.88	405.37	608.05	1.71
8	5.96	30.2	450	98.60	70.79	253.70	380.55	3.93
9	15.52	53.8	450	98.05	66.82	142.27	213.40	1.97
10	56.61	5.6	400	55.69	8.92	1362.24	2043.36	5.08
11	26.72	15.1	400	66.29	17.98	507.65	761.48	0.60
12	20.80	20.3	400	58.94	17.79	377.60	566.40	0.90
13	6.99	48.4	400	74.74	33.94	158.05	237.08	0.63
14	45.93	5.8	425	63.71	11.95	130.66	1961.49	2.04
15	43.09	11.2	425	67.14	14.73	682.59	1023.89	1.57
16	15.79	27.9	425	77.65	34.49	274.20	411.30	2.38
17	21.60	5.1	450	67.22	14.48	1496.51	2244.77	0.32
18	35.19	11.7	450	81.48	29.69	652.43	978.64	0.44
19	26.14	16.7	450	83.88	26.33	458.42	687.62	8.82
20	8.60	24.8	450	89.38	37.98	312.25	468.38	0.02
21	11.63	24.9	450	79.77	25.66	307.08	460.62	1.72
22	9.59	39.5	450	87.93	22.36	193.61	290.42	1.88
23	4.42	29.0	450	79.50	31.52	155.96	233.95	1.43
24	38.89	5.5	460	72.73	17.86	1392.08	2088.12	1.35
25	11.19	11.5	450	77.88	25.20	663.09	994.63	1.61
26	75.62	5.2	470	75.50	8.66	1464.11	2196.17	4.78
27	36.03	10.6	470	83.15	22.39	720.07	1080.11	5.88

Chú thích: y = sản lượng CO_2 ; X1 = thời gian (phút); X2 = nhiệt độ (C); X3 = phần trăm hòa tan; X4 = lượng dầu (g/100g); X5 = lượng than đá; X6 = tổng số lượng hòa tan; X7 = số hydrogen tiêu thụ.

Trước khi phân tích số liệu, chúng ta cần nhập số liệu vào R bằng các lệnh thông thường. Số liệu sẽ chứa trong đối tượng REGdata.

```
> y <- c(36.98,13.74,10.08, 8.53,36.42,26.59,19.07,
        5.96,15.52,56.61,26.72,20.80,6.99,45.93,
        43.09,15.79,21.60,35.19,26.14, 8.60,
        11.63, 9.59, 4.42,38.89,11.19,75.62,36.03)

> x1 <- c(5.1,26.4,23.8,46.4, 7.0,12.6,18.9,30.2,
        53.8,5.6,15.1,20.3,48.4,5.8,11.2,27.9,5.1,
        11.7,16.7,24.8,24.9,39.5,29.0, 5.5, 11.5,
        5.2,10.6)

> x2 <- c(400,400, 400, 400, 450, 450, 450, 450, 450,
        400, 400, 400, 400, 425, 425, 425, 450, 450,
        450, 450, 450, 450, 450, 460, 450, 470, 470)

> x3 <- c(51.37,72.33,71.44,79.15,80.47,89.90,91.48,
        98.60,98.05,55.69, 66.29,58.94,74.74,63.71,
        67.14,77.65,67.22,81.48,83.88,89.38,79.77,
        87.93, 79.50,72.73,77.88,75.50,83.15)

> x4 <- c(4.24,30.87,33.01,44.61,33.84,41.26,41.88,
        70.79,66.82,8.92,17.98,17.79,33.94,11.95,
        14.73,34.49,14.48,29.69,26.33, 37.98,25.66,
        22.36,31.52,17.86,25.20, 8.66,22.39)

> x5 <- c(1484.83, 289.94, 320.79, 164.76, 1097.26,
        605.06, 405.37, 253.70, 142.27,1362.24, 507.65,
        377.60, 158.05, 130.66, 682.59, 274.20,
        1496.51, 652.43, 458.42, 312.25, 307.08,
        193.61,155.96,1392.08, 663.09,1464.11, 720.07)

> x6 <- c(2227.25, 434.90, 481.19, 247.14,1645.89,
        907.59,608.05, 380.55, 213.40,2043.36, 761.48,
        566.40,237.08,1961.49,1023.89, 411.30,2244.77,
        978.64,687.62, 468.38, 460.62, 290.42,233.95,
        2088.12,994.63,2196.17,1080.11)

> x7 <- c(2.06,1.33,0.97,0.62,0.22,0.76,1.71,3.93,1.97,
        5.08,0.60,0.90, 0.63,2.04,1.57,2.38,0.32,
        0.44,8.82,0.02,1.72,1.88,1.43,1.35,1.61,
        4.78,5.88)

> REGdata <- data.frame(y, x1,x2,x3,x4,x5,x6,x7)
```

Bây giờ chúng ta bắt đầu phân tích. Mô hình đầu tiên là mô hình gồm tất cả 7 biến độc lập như sau:

```
> reg <- lm(y ~ x1+x2+x3+x4+x5+x6+x7, data=REGdata)
> summary(reg)

Call: lm(formula = y ~ x1 + x2 + x3 + x4 + x5 + x6 + x7,
data = REGdata)

Residuals:
    Min       1Q   Median       3Q      Max
-20.035  -4.681  -1.144   4.072  21.214

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  53.937016   57.428952   0.939   0.3594
x1           -0.127653    0.281498  -0.453   0.6553
x2           -0.229179    0.232643  -0.985   0.3370
x3            0.824853    0.765271   1.078   0.2946
x4           -0.438222    0.358551  -1.222   0.2366
x5           -0.001937    0.009654  -0.201   0.8431
x6            0.019886    0.008088   2.459   0.0237 *
x7            1.993486    1.089701   1.829   0.0831 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.61 on 19 degrees of freedom
Multiple R-Squared:  0.728,    Adjusted R-squared:  0.6278
F-statistic: 7.264 on 7 and 19 DF,  p-value: 0.0002674
```

Kết quả trên cho thấy tất cả 7 biến số “giải thích” khoảng 73% phương sai của y . Nhưng trong 7 biến đó, chỉ có x_6 là có ý nghĩa thống kê ($p=0.024$). Chúng ta thử giảm mô hình thành một mô hình hồi qui tuyến tính đơn giản với chỉ biến x_6 .

```
> summary(lm(y ~ x6, data=REGdata))

Call: lm(formula = y ~ x6, data = REGdata)


Residuals:
    Min       1Q   Median       3Q      Max
-28.081  -5.829  -0.839   5.522  26.882

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  6.144181    3.483064   1.764   0.09 .
x6           0.019395    0.002932   6.616 6.24e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.7 on 25 degrees of freedom
Multiple R-Squared:  0.6365,    Adjusted R-squared:  0.6219
F-statistic: 43.77 on 1 and 25 DF,  p-value: 6.238e-07
```

Chỉ với một biến x_6 mà mô hình có thể giải thích khoảng 64% phương sai của y . Chúng ta chấp nhận mô hình này? Trước khi chấp nhận mô hình này, chúng ta phải xem xét độ tương quan giữa các biến độc lập:

```
> pairs(REGdata)
```



Kết quả trên cho thấy y có liên hệ với các biến như x_1 , x_5 và x_6 . Ngoài ra, biến x_5 và x_6 có một mối liên hệ rất mật thiết (gần như là một đường thẳng) với hệ số tương quan là 0.88. Ngoài ra, x_5 và x_1 hay x_6 và x_5 cũng có liên hệ với nhau nhưng theo một hàm số nghịch đảo. Điều này có nghĩa là biến x_5 và x_6 cung cấp một lượng thông tin như nhau để tiên đoán y , tức là chúng ta không cần cả hai trong một mô hình.

Để tìm một mô hình tối ưu trong bối cảnh có nhiều mối tương quan như thế, chúng ta ứng dụng step như sau. Chú ý cách cung cấp thông số $\text{lm}(y \sim .)$, dấu "." có nghĩa là yêu cầu R xem xét tất cả biến trong đối tượng REGdata.

```
> reg <- lm(y ~ ., data=REGdata)
> step(reg, direction="both")
```

Start: AIC= 134.07 y ~ x1 + x2 + x3 + x4 + x5 + x6 + x7 <table><tr><th></th><th>Df</th><th>Sum of Sq</th><th>RSS</th><th>AIC</th></tr><tr><td>- x5</td><td>1</td><td>4.54</td><td>2145.37</td><td>132.13</td></tr><tr><td>- x1</td><td>1</td><td>23.17</td><td>2164.00</td><td>132.36</td></tr><tr><td>- x2</td><td>1</td><td>109.34</td><td>2250.18</td><td>133.42</td></tr><tr><td>- x3</td><td>1</td><td>130.90</td><td>2271.74</td><td>133.68</td></tr><tr><td><none></td><td></td><td>2140.83</td><td>134.07</td><td></td></tr><tr><td>- x4</td><td>1</td><td>168.31</td><td>2309.14</td><td>134.12</td></tr><tr><td>- x7</td><td>1</td><td>377.09</td><td>2517.92</td><td>136.45</td></tr><tr><td>- x6</td><td>1</td><td>681.09</td><td>2821.92</td><td>139.53</td></tr></table>		Df	Sum of Sq	RSS	AIC	- x5	1	4.54	2145.37	132.13	- x1	1	23.17	2164.00	132.36	- x2	1	109.34	2250.18	133.42	- x3	1	130.90	2271.74	133.68	<none>		2140.83	134.07		- x4	1	168.31	2309.14	134.12	- x7	1	377.09	2517.92	136.45	- x6	1	681.09	2821.92	139.53	Step 1: AIC= 132.13 y ~ x1 + x2 + x3 + x4 + x6 + x7 <table><tr><th></th><th>Df</th><th>Sum of Sq</th><th>RSS</th><th>AIC</th></tr><tr><td>- x1</td><td>1</td><td>22.7</td><td>2168.1</td><td>130.4</td></tr><tr><td>- x2</td><td>1</td><td>113.8</td><td>2259.1</td><td>131.5</td></tr><tr><td>- x3</td><td>1</td><td>133.5</td><td>2278.9</td><td>131.8</td></tr><tr><td><none></td><td></td><td>2145.4</td><td>132.1</td><td></td></tr><tr><td>- x4</td><td>1</td><td>170.8</td><td>2316.2</td><td>132.2</td></tr><tr><td>+ x5</td><td>1</td><td>4.5</td><td>2140.8</td><td>134.1</td></tr><tr><td>- x7</td><td>1</td><td>375.7</td><td>2521.1</td><td>134.5</td></tr><tr><td>- x6</td><td>1</td><td>1058.5</td><td>3203.8</td><td>141.0</td></tr></table>		Df	Sum of Sq	RSS	AIC	- x1	1	22.7	2168.1	130.4	- x2	1	113.8	2259.1	131.5	- x3	1	133.5	2278.9	131.8	<none>		2145.4	132.1		- x4	1	170.8	2316.2	132.2	+ x5	1	4.5	2140.8	134.1	- x7	1	375.7	2521.1	134.5	- x6	1	1058.5	3203.8	141.0
	Df	Sum of Sq	RSS	AIC																																																																																							
- x5	1	4.54	2145.37	132.13																																																																																							
- x1	1	23.17	2164.00	132.36																																																																																							
- x2	1	109.34	2250.18	133.42																																																																																							
- x3	1	130.90	2271.74	133.68																																																																																							
<none>		2140.83	134.07																																																																																								
- x4	1	168.31	2309.14	134.12																																																																																							
- x7	1	377.09	2517.92	136.45																																																																																							
- x6	1	681.09	2821.92	139.53																																																																																							
	Df	Sum of Sq	RSS	AIC																																																																																							
- x1	1	22.7	2168.1	130.4																																																																																							
- x2	1	113.8	2259.1	131.5																																																																																							
- x3	1	133.5	2278.9	131.8																																																																																							
<none>		2145.4	132.1																																																																																								
- x4	1	170.8	2316.2	132.2																																																																																							
+ x5	1	4.5	2140.8	134.1																																																																																							
- x7	1	375.7	2521.1	134.5																																																																																							
- x6	1	1058.5	3203.8	141.0																																																																																							
Step 2: AIC= 130.42 y ~ x2 + x3 + x4 + x6 + x7 <table><tr><th></th><th>Df</th><th>Sum of Sq</th><th>RSS</th><th>AIC</th></tr><tr><td>- x2</td><td>1</td><td>96.8</td><td>2264.9</td><td>129.6</td></tr><tr><td>- x3</td><td>1</td><td>122.0</td><td>2290.0</td><td>129.9</td></tr><tr><td><none></td><td></td><td>2168.1</td><td>130.4</td><td></td></tr><tr><td>- x4</td><td>1</td><td>187.4</td><td>2355.5</td><td>130.7</td></tr><tr><td>+ x1</td><td>1</td><td>22.7</td><td>2145.4</td><td>132.1</td></tr><tr><td>+ x5</td><td>1</td><td>4.1</td><td>2164.0</td><td>132.4</td></tr><tr><td>- x7</td><td>1</td><td>385.0</td><td>2553.1</td><td>132.8</td></tr><tr><td>- x6</td><td>1</td><td>1526.2</td><td>3694.3</td><td>142.8</td></tr></table>		Df	Sum of Sq	RSS	AIC	- x2	1	96.8	2264.9	129.6	- x3	1	122.0	2290.0	129.9	<none>		2168.1	130.4		- x4	1	187.4	2355.5	130.7	+ x1	1	22.7	2145.4	132.1	+ x5	1	4.1	2164.0	132.4	- x7	1	385.0	2553.1	132.8	- x6	1	1526.2	3694.3	142.8	Step 3: AIC= 129.59 y ~ x3 + x4 + x6 + x7 <table><tr><th></th><th>Df</th><th>Sum of Sq</th><th>RSS</th><th>AIC</th></tr><tr><td>- x3</td><td>1</td><td>25.4</td><td>2290.3</td><td>127.9</td></tr><tr><td>- x4</td><td>1</td><td>90.9</td><td>2355.8</td><td>128.7</td></tr><tr><td><none></td><td></td><td>2264.9</td><td>129.6</td><td></td></tr><tr><td>+ x2</td><td>1</td><td>96.8</td><td>2168.1</td><td>130.4</td></tr><tr><td>+ x5</td><td>1</td><td>8.3</td><td>2256.5</td><td>131.5</td></tr><tr><td>+ x1</td><td>1</td><td>5.7</td><td>2259.1</td><td>131.5</td></tr><tr><td>- x7</td><td>1</td><td>384.9</td><td>2649.7</td><td>131.8</td></tr><tr><td>- x6</td><td>1</td><td>2015.6</td><td>4280.5</td><td>144.8</td></tr></table>		Df	Sum of Sq	RSS	AIC	- x3	1	25.4	2290.3	127.9	- x4	1	90.9	2355.8	128.7	<none>		2264.9	129.6		+ x2	1	96.8	2168.1	130.4	+ x5	1	8.3	2256.5	131.5	+ x1	1	5.7	2259.1	131.5	- x7	1	384.9	2649.7	131.8	- x6	1	2015.6	4280.5	144.8
	Df	Sum of Sq	RSS	AIC																																																																																							
- x2	1	96.8	2264.9	129.6																																																																																							
- x3	1	122.0	2290.0	129.9																																																																																							
<none>		2168.1	130.4																																																																																								
- x4	1	187.4	2355.5	130.7																																																																																							
+ x1	1	22.7	2145.4	132.1																																																																																							
+ x5	1	4.1	2164.0	132.4																																																																																							
- x7	1	385.0	2553.1	132.8																																																																																							
- x6	1	1526.2	3694.3	142.8																																																																																							
	Df	Sum of Sq	RSS	AIC																																																																																							
- x3	1	25.4	2290.3	127.9																																																																																							
- x4	1	90.9	2355.8	128.7																																																																																							
<none>		2264.9	129.6																																																																																								
+ x2	1	96.8	2168.1	130.4																																																																																							
+ x5	1	8.3	2256.5	131.5																																																																																							
+ x1	1	5.7	2259.1	131.5																																																																																							
- x7	1	384.9	2649.7	131.8																																																																																							
- x6	1	2015.6	4280.5	144.8																																																																																							
Step 4: AIC= 127.9 y ~ x4 + x6 + x7 <table><tr><th></th><th>Df</th><th>Sum of Sq</th><th>RSS</th><th>AIC</th></tr><tr><td>- x4</td><td>1</td><td>73.5</td><td>2363.8</td><td>126.7</td></tr><tr><td><none></td><td></td><td>2290.3</td><td>127.9</td><td></td></tr><tr><td>+ x3</td><td>1</td><td>25.4</td><td>2264.9</td><td>129.6</td></tr><tr><td>+ x1</td><td>1</td><td>11.3</td><td>2279.0</td><td>129.8</td></tr><tr><td>+ x5</td><td>1</td><td>6.3</td><td>2284.0</td><td>129.8</td></tr><tr><td>+ x2</td><td>1</td><td>0.3</td><td>2290.0</td><td>129.9</td></tr><tr><td>- x7</td><td>1</td><td>486.6</td><td>2776.9</td><td>131.1</td></tr><tr><td>- x6</td><td>1</td><td>1993.8</td><td>4284.1</td><td>142.8</td></tr></table>		Df	Sum of Sq	RSS	AIC	- x4	1	73.5	2363.8	126.7	<none>		2290.3	127.9		+ x3	1	25.4	2264.9	129.6	+ x1	1	11.3	2279.0	129.8	+ x5	1	6.3	2284.0	129.8	+ x2	1	0.3	2290.0	129.9	- x7	1	486.6	2776.9	131.1	- x6	1	1993.8	4284.1	142.8	Step 5: AIC= 126.75 y ~ x6 + x7 <table><tr><th></th><th>Df</th><th>Sum of Sq</th><th>RSS</th><th>AIC</th></tr><tr><td><none></td><td></td><td></td><td>2363.8</td><td>126.7</td></tr><tr><td>+ x4</td><td>1</td><td>73.5</td><td>2290.3</td><td>127.9</td></tr><tr><td>+ x1</td><td>1</td><td>33.4</td><td>2330.4</td><td>128.4</td></tr><tr><td>+ x3</td><td>1</td><td>8.1</td><td>2355.8</td><td>128.7</td></tr><tr><td>+ x5</td><td>1</td><td>7.7</td><td>2356.1</td><td>128.7</td></tr><tr><td>+ x2</td><td>1</td><td>7.3</td><td>2356.6</td><td>128.7</td></tr><tr><td>- x7</td><td>1</td><td>497.3</td><td>2861.2</td><td>129.9</td></tr><tr><td>- x6</td><td>1</td><td>4477.0</td><td>6840.8</td><td>153.4</td></tr></table>		Df	Sum of Sq	RSS	AIC	<none>			2363.8	126.7	+ x4	1	73.5	2290.3	127.9	+ x1	1	33.4	2330.4	128.4	+ x3	1	8.1	2355.8	128.7	+ x5	1	7.7	2356.1	128.7	+ x2	1	7.3	2356.6	128.7	- x7	1	497.3	2861.2	129.9	- x6	1	4477.0	6840.8	153.4
	Df	Sum of Sq	RSS	AIC																																																																																							
- x4	1	73.5	2363.8	126.7																																																																																							
<none>		2290.3	127.9																																																																																								
+ x3	1	25.4	2264.9	129.6																																																																																							
+ x1	1	11.3	2279.0	129.8																																																																																							
+ x5	1	6.3	2284.0	129.8																																																																																							
+ x2	1	0.3	2290.0	129.9																																																																																							
- x7	1	486.6	2776.9	131.1																																																																																							
- x6	1	1993.8	4284.1	142.8																																																																																							
	Df	Sum of Sq	RSS	AIC																																																																																							
<none>			2363.8	126.7																																																																																							
+ x4	1	73.5	2290.3	127.9																																																																																							
+ x1	1	33.4	2330.4	128.4																																																																																							
+ x3	1	8.1	2355.8	128.7																																																																																							
+ x5	1	7.7	2356.1	128.7																																																																																							
+ x2	1	7.3	2356.6	128.7																																																																																							
- x7	1	497.3	2861.2	129.9																																																																																							
- x6	1	4477.0	6840.8	153.4																																																																																							
Call: lm(formula = y ~ x6 + x7,data = REGdata) Coefficients: (Intercept) x6 x7 2.52646 0.01852 2.18575																																																																																											

Quá trình tìm mô hình tối ưu dừng ở mô hình với hai biến $x6$ và $x7$, vì mô hình này có giá trị AIC thấp nhất. Phương trình tuyến tính tiên đoán y là:

$$y = 2.526 + 0.0185(x6) + 2.186(x7).$$

```

> summary(lm(y ~ x6+x7, data=REGdata))
Call: lm(formula = y ~ x6 + x7, data = REGdata)

Residuals:
    Min       1Q   Median       3Q      Max
-23.2035  -4.3713   0.2513   4.9339  21.9682

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.526460    3.610055   0.700   0.4908
x6           0.018522    0.002747   6.742 5.66e-07 ***
x7           2.185753    0.972696   2.247  0.0341 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9.924 on 24 degrees of freedom
Multiple R-Squared:  0.6996,    Adjusted R-squared:  0.6746
F-statistic: 27.95 on 2 and 24 DF,  p-value: 5.391e-07

```

Phân tích chi tiết (kết quả trên) cho thấy hai biến này giải thích khoảng 70% phương sai của y .

10.6 Xây dựng mô hình tuyến tính bằng Bayesian Model Average (BMA)

Một vấn đề trong cách xây dựng mô hình trên là mô hình với x_6 và x_7 được xem là mô hình sau cùng, trong khi đó chúng ta biết rằng một mô hình x_5 và x_7 cũng có thể là một mô hình khả dĩ, bởi vì x_5 và x_6 có mối tương quan rất gần nhau. Nếu nghiên cứu được tiến hành tiếp và với thêm số liệu mới, có lẽ một mô hình khác sẽ “ra đời”.

Để đánh giá sự bất định trong việc xây dựng mô hình thống kê, một phép tính khác có triển vọng tốt hơn các phép tính trên là BMA (Bayesian Model Average). Bạn đọc muốn tìm hiểu thêm về phép tính này có thể tham khảo vài bài báo khoa học dưới đây. Nói một cách ngắn gọn, phép tính BMA tìm tất cả các mô hình khả dĩ (với 7 biến độc lập, số mô hình khả dĩ là $2^7 = 128$, chưa tính đến các mô hình tương tác!) và trình bày kết quả của các mô hình được xem là “tối ưu” nhất về lâu về dài. Tiêu chuẩn tối ưu cũng dựa vào giá trị AIC.

Để tiến hành phép tính BMA, chúng ta phải dùng đến package BMA (có thể tải về từ trang web của R <http://cran.R-project.org>). Sau khi đã có cài đặt package BMA trong máy tính, chúng ta phải nhập BMA vào môi trường vận hành của R bằng lệnh:

```
> library(BMA)
```

Sau đó, tạo ra một ma trận chỉ gồm các biến độc lập. Trong data frame chúng ta biết REGdata có 8 biến, với biến số 1 là y . Do đó, lệnh REGdata[, -1] có nghĩa là tạo ra một data frame mới ngoại trừ cột thứ nhất (tức y).

```
> xvars <- REGdata[, -1]
```

Kế tiếp, chúng ta định nghĩa biến phụ thuộc tên co2 từ REGdata:

```
> co2 <- REGdata[,1]
```

Bây giờ chúng ta đã sẵn sàng phân tích bằng phép tính BMA. Hàm bicreg được viết đặc biệt cho phân tích hồi qui tuyến tính. Cách áp dụng hàm bicreg như sau:

```
> bma <- bicreg(xvars, co2, strict=FALSE, OR=20)
```

Chúng ta sử dụng hàm summary để biết kết quả:

```
> summary(bma)
```

Call:

```
bicreg(x = xvars, y = co2, strict = FALSE, OR = 20)
```

16 models were selected

Best 5 models (cumulative posterior probability = 0.6599):

	p!=0	EV	SD	model 1	model 2	model 3
Intercept	100.0	5.75672	14.6244	2.5264	6.1441	8.6120
x1	12.4	-0.01807	0.1008	.	.	.
x2	10.4	-0.00075	0.0282	.	.	.
x3	10.7	0.00011	0.0791	.	.	.
x4	20.2	-0.03059	0.1020	.	.	-0.1419
x5	10.5	-0.00023	0.0030	.	.	.
x6	100.0	0.01815	0.0040	0.0185	0.0193	0.0164
x7	73.7	1.60766	1.2821	2.1857	.	2.1628

nVar

r2

BIC

post prob

	2	1	3
r2	0.700	0.636	0.709
BIC	-25.8832	-24.0238	-23.4412
post prob	0.311	0.123	0.092

	model 4	model 5
Intercept	7.5936	7.3537
x1	-0.1393	.
x2	.	.
x3	.	-0.0572
x4	.	.
x5	.	.
x6	0.0162	0.0179
x7	2.1233	2.2382

nVar

r2

BIC

post prob

	3	3
r2	0.704	0.701
BIC	-22.9721	-22.6801
post prob	0.072	0.063

BMA trình bày kết quả của 5 mô hình được đánh giá là tối ưu nhất cho tiên đoán y (model 1, model 2, ... model 5).


- Cột thứ nhất liệt kê danh sách các biến số độc lập;
- Cột 2 trình bày xác suất giả thiết một biến độc lập có ảnh hưởng đến y. Chẳng hạn như xác suất là x6 có ảnh hưởng đến y là 100%; trong khi

đó xác suất mà x_7 có ảnh hưởng đến y là 73.7%. Tuy nhiên xác suất các biến khác thấp hơn hay chỉ bằng 20%. Do đó, chúng ta có thể nói rằng mô hình với x_6 và x_7 có lẽ là mô hình tối ưu nhất.

- Cột 3 (EV) và 4 (SD) trình bày trị số trung bình và độ lệch chuẩn của hệ số cho mỗi biến số độc lập.
- Cột 5 là ước tính hệ số ảnh hưởng (regression coefficient) của mô hình 1. Như thấy trong cột này, mô hình 1 gồm intercept (tức α), và hai biến x_6 và x_7 . Mô hình này giải thích (như chúng ta đã biết qua phân tích phần trên) 70% phương sai của y . Trị số BIC (Bayesian Information Criterion) thấp nhất. Trong số tất cả mô hình mà BMA tìm, mô hình này có xác suất xuất hiện là 31.1%.
- Cột 6 là ước tính hệ số ảnh hưởng của mô hình 2. Như thấy trong cột này, mô hình 2 gồm intercept (tức α), và biến x_6 . Mô hình này giải thích 64% phương sai của y . Trong số tất cả mô hình mà BMA tìm, mô hình này có xác suất xuất hiện chỉ là 12.3%.
- Các mô hình khác cũng có thể diễn dịch một cách tương tự.

Một cách thể hiện kết quả trên là qua một biểu đồ như sau:

```
> imageplot.bma(bma)
```



Tài liệu tham khảo cho BMA

- Raftery, Adrian E. (1995). Bayesian model selection in social research (with Discussion). Sociological Methodology 1995 (Peter V. Marsden, ed.), pp. 111-196, Cambridge, Mass.: Blackwells.
- Một số bài báo liên quan đến BMA có thể tải từ trang web sau đây:
www.stat.colostate.edu/~jah/papers.

11

Phân tích phương sai (Analysis of variance)

Phân tích phương sai, như tên gọi, là một số phương pháp phân tích thống kê mà trọng điểm là phương sai (thay vì số trung bình). Phương pháp phân tích phương sai nằm trong “đại gia đình” các phương pháp có tên là mô hình tuyến tính (hay general linear models), bao gồm cả hồi qui tuyến tính mà chúng ta đã gặp trong chương trước. Trong chương này, chúng ta sẽ làm quen với cách sử dụng R trong phân tích phương sai. Chúng ta sẽ bắt đầu bằng một phân tích đơn giản, sau đó sẽ xem đến phân tích phương sai hai chiều, và các phương pháp phi tham số thông dụng.

11.1 Phân tích phương sai đơn giản (one-way analysis of variance - ANOVA)

Ví dụ 1: Bảng thống kê 1 dưới đây so sánh độ galactose trong 3 nhóm bệnh nhân: nhóm 1 gồm 9 bệnh nhân với bệnh Crohn; nhóm 2 gồm 11 bệnh nhân với bệnh viêm ruột kết (colitis); và nhóm 3 gồm 20 đối tượng không có bệnh (gọi là nhóm đối chứng). Câu hỏi đặt ra là độ galactose giữa 3 nhóm bệnh nhân có khác nhau hay không? Gọi giá trị trung bình của ba nhóm là μ_1 , μ_2 , và μ_3 , và nói theo ngôn ngữ của kiểm định giả thiết thì giả thiết đảo là:

$$H_o: \mu_1 = \mu_2 = \mu_3$$

Và giả thiết chính là: H_A : có một khác biệt giữa 3 μ_j ($j = 1, 2, 3$)

Bảng 1. Độ galactose cho 3 nhóm bệnh nhân Crohn, viêm ruột kết và đối chứng

NHÓM 1: BỆNH CROHN	NHÓM 2: BỆNH VIÊM RUỘT KẾT	NHÓM 3: ĐỐI CHỨNG (CONTROL)
1343	1264	1809 2850
1393	1314	1926 2964
1420	1399	2283 2973
1641	1605	2384 3171
1897	2385	2447 3257
2160	2511	2479 3271
2169	2514	2495 3288
2279	2767	2525 3358
2890	2827	2541 3643
	2895	2769 3657
	3011	
$n=9$ Trung bình: 1910 SD: 516	$n=11$ Trung bình: 2226 SD: 727	$n=20$ Trung bình: 2804 SD: 527

Chú thích: SD là độ lệch chuẩn (standard deviation).

Mới xem qua vấn đề, có lẽ bạn đọc sẽ nghĩ rằng chúng ta cần làm 3 so sánh (bằng phương pháp kiểm định t): giữa nhóm 1 và 2, nhóm 2 và 3, và nhóm 1 và 3. Nhưng cách làm này không hợp lí, vì có ba phương sai khác nhau. Cách thích hợp nhất để so sánh này là phân tích phương sai. Phân tích phương sai có thể ứng dụng để so sánh nhiều nhóm cùng một lúc (simultaneous comparisons).

11.1.1 Mô hình phân tích phương sai

Để minh họa cho phương pháp phân tích phương sai, chúng ta phải dùng kí hiệu. Gọi độ galactose của bệnh nhân i thuộc nhóm j ($j = 1, 2, 3$) là x_{ij} . Mô hình phân tích phương sai phát biểu rằng:

$$x_{ij} = \mu + \alpha_i + \varepsilon_{ij} \quad [1]$$

Hay cụ thể hơn:

$$x_{i1} = \mu + \alpha_1 + \varepsilon_{i1}$$

$$x_{i2} = \mu + \alpha_2 + \varepsilon_{i2}$$

$$x_{i3} = \mu + \alpha_3 + \varepsilon_{i3}$$

Tức là, giá trị galactose của bất cứ bệnh nhân nào bằng giá trị trung bình của toàn quần thể (μ) cộng/trừ cho ảnh hưởng của nhóm j được đo bằng hệ số ảnh hưởng α_i , và sai số ε_{ij} . Một giả định khác là ε_{ij} phải tuân theo luật phân

phối chuẩn với trung bình 0 và phương sai σ^2 . Hai thông số cần ước tính là μ và α_j . Cũng như phân tích hồi qui tuyến tính, hai thông số này được ước tính bằng phương pháp bình phương nhỏ nhất; tức là tìm ước số $\hat{\mu}$ và $\hat{\alpha}_j$ sao cho $\sum (x_{ij} - \hat{\mu} - \hat{\alpha}_j)^2$ nhỏ nhất.

Quay lại với số liệu nghiên cứu trên, chúng ta có những tóm tắt thống kê như sau:

NHÓM	SỐ ĐỐI TƯỢNG (N_j)	TRUNG BÌNH	PHƯƠNG SAI
1 - Crohn	$n_1 = 9$	$\bar{x}_1 = 1910$	$s_1^2 = 265944$
2 - Viêm ruột kết	$n_2 = 11$	$\bar{x}_2 = 2226$	$s_2^2 = 473387$
3 - Đối chứng	$n_3 = 20$	$\bar{x}_3 = 2804$	$s_3^2 = 277500$
Toàn bộ mẫu	$n = 40$	$\bar{x} = 2444$	

Chú thích: $x_{ij} = \bar{x} + (\bar{x}_j - \bar{x}) + (x_{ij} - \bar{x}_j)$ [2]

Trong đó, $\bar{x}$ là số trung bình của toàn mẫu, và $\bar{x}_j$ là số trung bình của nhóm j . Nói cách khác, phần $(\bar{x}_j - \bar{x})$ phản ánh độ khác biệt (hay cũng có thể gọi là hiệu số) giữa trung bình từng nhóm và trung bình toàn mẫu, và phần $(x_{ij} - \bar{x}_j)$ phản ánh hiệu số giữa một galactose của một đối tượng và số trung bình của từng nhóm. Theo đó, chúng ta có các nguồn dao động như sau:

- Tổng bình phương cho toàn bộ mẫu là:

$$\begin{aligned}
 SST &= \sum_i \sum_j (x_{ij} - \bar{x})^2 \\
 &= (1343-2444)^2 + (1393-2444)^2 + (1343-2444)^2 + \dots + (3657-2444)^2 \\
 &= 12133923
 \end{aligned}$$

- Tổng bình phương phản ánh độ khác nhau giữa các nhóm:

$$\begin{aligned}
 SSB &= \sum_i \sum_j (\bar{x}_i - \bar{x})^2 = \sum_j n_j (\bar{x}_j - \bar{x})^2 \\
 &= 9(1910 - 2444)^2 + 11(2226 - 2444)^2 + 20(2804 - 2444)^2 \\
 &= 5681168
 \end{aligned}$$

- Tổng bình phương phản ánh độ dao động trong mỗi nhóm:

$$SSW = \sum_i \sum_j (x_{ij} - \bar{x}_j)^2 = \sum_j (n_j - 1) s_j^2$$

$$= (9-1)(265944) + (11-1)(473387) + (20-1)(277500)$$

$$= 12133922$$

Có thể chứng minh rằng: $SST = SSB + SSW$.

SSW được tính từ mỗi bệnh nhân cho 3 nhóm, cho nên trung bình bình phương cho từng nhóm (mean square - MSW) là:

$$MSW = SSW / (N - k) = 12133922 / (40-3) = 327944$$

và trung bình bình phương giữa các nhóm là:

$$MSB = SSB / (k - 1) = 5681168 / (3-1) = 2841810$$

Trong đó N là tổng số bệnh nhân ($N = 40$) của ba nhóm, và $k = 3$ là số nhóm bệnh nhân. Nếu có sự khác biệt giữa các nhóm, thì chúng ta kì vọng rằng MSB sẽ lớn hơn MSW . Thành ra, để kiểm tra giả thiết, chúng ta có thể dựa vào kiểm định F :

$$F = MSB / MSW = 8.67 \quad [3]$$

Với bậc tự do $k-1$ và $N-k$. Các số liệu tính toán trên đây có thể trình bày trong một bảng phân tích phương sai (ANOVA table) như sau:

NGUỒN BIẾN THIÊN (SOURCE OF VARIATION)	BẬC TỰ DO (DEGREES OF FREEDOM)	TỔNG BÌNH PHƯƠNG (SUM OF SQUARES)	TRUNG BÌNH BÌNH PHƯƠNG (MEAN SQUARE)	KIỂM ĐỊNH F
Khác biệt giữa các nhóm (between-group)	2	5681168	2841810	8.6655
Khác biệt trong từng nhóm (with-group)	37	12133923	327944	
Tổng số	39	12133923		

11.1.2 Phân tích phương sai đơn giản với R

Tất cả các tính toán trên tương đối phức tạp, và tốn khá nhiều thời gian. Tuy nhiên với R, các tính toán đó có thể làm trong vòng 1 giây, sau khi dữ liệu đã được chuẩn bị đúng cách.

(a) **Nhập dữ liệu.** Trước hết, chúng ta cần phải nhập dữ liệu vào R. Bước thứ nhất là báo cho R biết rằng chúng ta có ba nhóm bệnh nhân (1, 2 và 3), nhóm 1 gồm 9 người, nhóm 2 có 11 người, và nhóm 3 có 20 người:

```
> group <- c(1,1,1,1,1,1,1,1,1,1, 2,2,2,2,2,2,2,2,2,2,2,
             3,3,3,3,3,3,3,3,3,3,3,3,3,3,3,3,3,3,3,3,3)
```

Để phân tích phương sai, chúng ta phải định nghĩa biến group là một yếu tố - factor.

```
> group <- as.factor(group)
```

Bước kế tiếp, chúng ta nhập số liệu galactose cho từng nhóm như định nghĩa trên (gọi object là galactose):

```
> galactose <- c(1343,1393,1420,1641,1897,2160,2169,2279,
                 2890,1264,1314,1399,1605,2385,2511,2514,
                 2767,2827,2895,3011,1809,2850,1926,2964,
                 2283,2973,2384,3171,2447,3257,2479,3271,
                 2495,3288,2525,3358,2541,3643,2769,3657)
```

Đưa hai biến group và galactose vào một dataframe và gọi là data:

```
> data <- data.frame(group, galactose)
> attach(data)
```

Sau khi đã có dữ liệu sẵn sàng, chúng ta dùng hàm `lm()` để phân tích phương sai như sau:

```
> analysis <- lm(galactose ~ group)
```

Trong hàm trên chúng ta cho R biết biến galactose là một hàm số của group. Gọi kết quả phân tích là analysis.

(b) Kết quả phân tích phương sai. Bây giờ chúng ta dùng lệnh `anova` để biết kết quả phân tích:

```
> anova(analysis)
Analysis of Variance Table
```

```
Response: galactose
          Df Sum Sq Mean Sq F value Pr(>F)
group      2  5683620  2841810  8.6655 0.0008191 ***
Residuals 37 12133923   327944
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Trong kết quả trên, có ba cột: Df (degrees of freedom) là bậc tự do; Sum Sq là tổng bình phương (sum of squares), Mean Sq là trung bình bình phương (mean square); F value là giá trị F như định nghĩa [3] vừa đề cập phần trên; và $\text{Pr}(>F)$ là trị số P liên quan đến kiểm định F .

Dòng group trong kết quả trên có nghĩa là bình phương giữa các nhóm (between-groups) và residual là bình phương trong mỗi nhóm (within-group). Ở đây, chúng ta có:

$$SSB = 5683620 \text{ và } MSB = 2841810$$

và:

$$MSB = 2841810 \text{ và } MSB = 327944$$

Như vậy, $F = 2841810 / 327944 = 8.6655$.

Trị số $p = 0.00082$ có nghĩa là tín hiệu cho thấy có sự khác biệt về độ galactose giữa ba nhóm.

(c) Ước số. Để biết thêm chi tiết kết quả phân tích, chúng ta dùng lệnh summary như sau:

```
> summary(analysis)
```

Call:

```
lm(formula = galactose ~ group)
```

Residuals:

```
Min      1Q  Median      3Q      Max
-995.5 -437.9  102.0  456.0  979.8
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1910.2	190.9	10.007	4.5e-12 ***
group2	316.3	257.4	1.229	0.226850
group3	894.3	229.9	3.891	0.000402 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 572.7 on 37 degrees of freedom

Multiple R-Squared: 0.319, Adjusted R-squared: 0.2822

F-statistic: 8.666 on 2 and 37 DF, p-value: 0.0008191

Theo kết quả trên đây, intercept chính là $\hat{\mu}$ trong mô hình [1]. Nói cách khác, $\hat{\mu} = 1910$ và sai số chuẩn là 190.9.

Để ước tính thông số $\hat{\alpha}_j$, R đặt $\hat{\alpha}_1 = 0$, và $\hat{\alpha}_2 = \hat{\alpha}_2 - \hat{\alpha}_1 = 316.3$, với sai số chuẩn là 257, và kiểm định $t = 316.3 / 257 = 1.229$ với trị số $p = 0.2268$. Nói cách khác, so với nhóm 1 (bệnh nhân Crohn), bệnh nhân viêm ruột kết có độ galactose trung bình cao hơn 257, nhưng độ khác biệt này không có ý nghĩa thống kê.

Tương tự, $\hat{\alpha}_3 = \hat{\alpha}_3 - \hat{\alpha}_1 = 894.3$, với sai số chuẩn là 229.9, kiểm định $t = 894.3/229.9 = 3.89$, và trị số $p = 0.00040$. So với bệnh nhân Crohn, nhóm đối chứng có độ galactose cao hơn 894, và mức độ khác biệt này có ý nghĩa thống kê.

11.2 So sánh nhiều nhóm (multiple comparisons) và điều chỉnh trị số p

Cho k nhóm, chúng ta có ít nhất là $k(k-1)/2$ so sánh. Ví dụ trên có 3 nhóm, cho nên tổng số so sánh khả dĩ là 3 (giữa nhóm 1 và 2, nhóm 1 và 3, và nhóm 2 và 3). Khi $k=10$, số lần so sánh có thể lên rất cao. Như đã đề cập trong chương 7, khi có nhiều so sánh, trị số p tính toán từ các kiểm định thống kê không còn ý nghĩa ban đầu nữa, bởi vì các kiểm định này có thể cho ra kết quả dương tính giả (tức kết quả với $p < 0.05$ nhưng trong thực tế không có khác nhau hay ảnh hưởng). Do đó, trong trường hợp có nhiều so sánh, chúng ta cần phải điều chỉnh trị số p sao cho hợp lí.

Có khá nhiều phương pháp điều chỉnh trị số p , và 4 phương pháp thông dụng nhất là: Bonferroni, Scheffé, Holm và Tukey (tên của 4 nhà thống kê học). Phương pháp nào thích hợp nhất? Không có câu trả lời dứt khoát cho câu hỏi này, nhưng hai điểm sau đây có thể giúp bạn đọc quyết định tốt hơn:

- Nếu $k < 10$, chúng ta có thể áp dụng bất cứ phương pháp nào để điều chỉnh trị số p . Riêng cá nhân tôi thì thấy phương pháp Tukey thường rất hữu ích trong so sánh.
- Nếu $k > 10$, phương pháp Bonferroni có thể trở nên rất “bảo thủ”. Bảo thủ ở đây có nghĩa là phương pháp này rất ít khi nào tuyên bố một so sánh có ý nghĩa thống kê, dù trong thực tế là có thật! Trong trường hợp này, các phương pháp Tukey, Holm và Scheffé có thể áp dụng.

Ở đây, chúng ta sẽ không bàn đến lí thuyết đằng sau các phương pháp này (vì bạn đọc có thể tham khảo trong các sách giáo khoa về thống kê), nhưng sẽ chỉ cách sử dụng R để tiến hành các so sánh theo phương pháp của Tukey.

Quay lại ví dụ trên, các trị số p trên đây là những trị số chưa được điều chỉnh cho so sánh nhiều lần. Trong chương về trị số p , đã nói các trị số này phóng đại ý nghĩa thống kê, không phản ánh trị số p lúc ban đầu (tức 0.05). Để điều chỉnh cho nhiều so sánh, chúng ta phải sử dụng đến phương pháp điều chỉnh Bonferroni.

Chúng ta có thể dùng lệnh `pairwise.t.test` để có được tất cả các trị số p so sánh giữa ba nhóm như sau:

```
> pairwise.t.test(galactose, group, p.adj="bonferroni")
```

Pairwise comparisons using t tests with pooled SD

data: galactose and group

	1	2
2	0.6805	-
3	0.0012	0.0321

P value adjustment method: bonferroni

Kết quả trên cho thấy trị số p giữa nhóm 1 (Crohn) và viêm ruột kết là 0.6805 (tức không có ý nghĩa thống kê); giữa nhóm Crohn và đối chứng là 0.0012 (có ý nghĩa thống kê), và giữa nhóm viêm ruột kết và đối chứng là 0.0321 (tức cũng có ý nghĩa thống kê).

Một phương pháp điều chỉnh trị số p khác có tên là phương pháp Holm:

```
> pairwise.t.test(galactose, group)
```

Pairwise comparisons using t tests with pooled SD

data: galactose and group

	1	2
2	0.2268	-
3	0.0012	0.0214

P value adjustment method: holm

Kết quả này cũng không khác so với phương pháp Bonferroni.

Tất cả các phương pháp so sánh trên sử dụng một sai số chuẩn chung cho cả ba nhóm. Nếu chúng ta muốn sử dụng cho từng nhóm thì lệnh sau đây (`pool.sd=F`) sẽ đáp ứng yêu cầu đó:

```
> pairwise.t.test(galactose, group, pool.sd=FALSE)
```

Pairwise comparisons using t tests with non-pooled SD

data: galactose and group

	1	2
2	0.2557	-
3	0.0017	0.0544

P value adjustment method: holm

Một lần nữa, kết quả này cũng không làm thay đổi kết luận.

11.2.1 So sánh nhiều nhóm bằng phương pháp Tukey


Trong các phương pháp trên, chúng ta chỉ biết trị số p so sánh giữa các nhóm, nhưng không biết mức độ khác biệt cũng như khoảng tin cậy 95% giữa các nhóm. Để có những ước số này, chúng ta cần đến một hàm khác có tên là `aov` (viết tắt từ *analysis of variance*) và hàm `TukeyHSD` (HSD là viết tắt từ *Honest Significant Difference*, tạm dịch là “Khác biệt có ý nghĩa thành thật”) như sau:

```
> res <- aov(galactose ~ group)
> TukeyHSD (res)
Tukey multiple comparisons of means
 95% family-wise confidence level

Fit: aov(formula = galactose ~ group)

$group
      diff      lwr      upr    p adj
2-1 316.3232 -312.09857 944.745 0.4439821
3-1 894.2778 333.07916 1455.476 0.0011445
3-2 577.9545  53.11886 1102.790 0.0281768
```

Kết quả trên cho chúng ta thấy nhóm 3 và 1 khác nhau khoảng 894 đơn vị, và khoảng tin cậy 95% từ 333 đến 1455 đơn vị. Tương tự, galactose trong nhóm bệnh nhân viêm ruột kết thấp hơn nhóm đối chứng (nhóm 3) khoảng 578 đơn vị, và khoảng tin cậy 95% từ 53 đến 1103.




Biểu đồ 1. Trung bình hiệu và khoảng tin cậy 95% giữa nhóm 1 và 2, 1 và 3, và 3 và 2. Trục hoành là độ galactose, trục tung là ba so sánh.

11.2.2 Phân tích bằng biểu đồ

Một phân tích thống kê không thể nào hoàn tất nếu không có một đồ thị minh họa cho kết quả. Các lệnh sau đây vẽ đồ thị thể hiện độ galactose trung bình và sai số chuẩn cho từng nhóm bệnh nhân. Biểu đồ này cho thấy, nhóm bệnh nhân Crohn có độ galactose thấp nhất (nhưng không thấp hơn nhóm viêm ruột kết), và cả hai nhóm thấp hơn nhóm đối chứng và sự khác biệt này có ý nghĩa thống kê.

```
> xbar <- tapply(galactose, group, mean)
> s <- tapply(galactose, group, sd)
> n <- tapply(galactose, group, length)
> sem <- s/sqrt(n)
> stripchart(galactose ~ group, "jitter", jit=0.05,
             pch=16, vert=TRUE)
> arrows(1:3, xbar+sem, 1:3, xbar-sem, angle=90, code=3,
         length=0.1)
> lines(1:3, xbar, pch=4, type="b", cex=2)
```



Biểu đồ 2. Độ galactose của nhóm 1 (bệnh nhân Crohn), nhóm 2 (bệnh nhân viêm ruột kết), và nhóm 3 (đối chứng).

11.3 Phân tích bằng phương pháp phi tham số

Phương pháp so sánh nhiều nhóm phi tham số (non-parametric statistics) tương đương với phương pháp phân tích phương sai là Kruskal-Wallis. Cũng như phương pháp Wilcoxon so sánh hai nhóm theo phương pháp phi tham số, phương pháp Kruskal-Wallis cũng biến đổi số liệu thành thứ bậc (ranks)

và phân tích độ khác biệt thứ bậc này giữa các nhóm. Hàm `kruskal.test` trong R có thể giúp chúng ta trong kiểm định này:

```
> kruskal.test(galactose ~ group)

Kruskal-Wallis rank sum test

data: galactose by group

Kruskal-Wallis chi-squared = 12.1381, df = 2,
p-value = 0.002313
```

Trị số p từ kiểm định này khá thấp ($p = 0.002313$) cho thấy có sự khác biệt giữa ba nhóm như phân tích phương sai qua hàm `lm` trên đây. Tuy nhiên, một bất tiện của kiểm định phi tham số Kruskal-Wallis là phương pháp này không cho chúng ta biết hai nhóm nào khác nhau, mà chỉ cho một trị số p chung. Trong nhiều trường hợp, phân tích phi tham số như kiểm định Kruskal-Wallis thường không có hiệu quả như các phương pháp thống kê tham số (parametric statistics).

**11.4 Phân tích phương sai hai chiều
(two-way analysis of variance - ANOVA)**

Phân tích phương sai đơn giản hay một chiều chỉ có một yếu tố (factor). Nhưng phân tích phương sai hai chiều (two-way ANOVA), như tên gọi, có hai yếu tố. Phương pháp phân tích phương sai hai chiều chỉ đơn giản khai triển từ phương pháp phân tích phương sai đơn giản. Thay vì ước tính phương sai của một yếu tố, phương pháp phương sai hai chiều ước tính phương sai của hai yếu tố.

Ví dụ 2: Trong ví dụ sau đây, để đánh giá hiệu quả của một kĩ thuật sơn mới, các nhà nghiên cứu áp dụng sơn trên 3 loại vật liệu (1, 2 và 3) trong hai điều kiện (1, 2). Mỗi điều kiện và loại vật liệu, nghiên cứu được lặp lại 3 lần. Độ bền được đo là chỉ số bền bỉ (tạm gọi là *score*). Tổng cộng, có 18 số liệu như sau:

Bảng 2. Độ bền bỉ của sơn cho 2 điều kiện và 3 vật liệu

ĐIỀU KIỆN (i)	VẬT LIỆU (j)		
	1	2	3
1	4.1, 3.9, 4.3	3.1, 2.8, 3.3	3.5, 3.2, 3.6
2	2.7, 3.1, 2.6	1.9, 2.2, 2.3	2.7, 2.3, 2.5

Số liệu này có thể tóm lược bằng số trung bình cho từng điều kiện và vật liệu trong bảng thống kê sau đây:

Bảng 3. Tóm lược số liệu từ thí nghiệm độ bền bỉ của nước sơn

ĐIỀU KIỆN (i)	VẬT LIỆU (j)			TRUNG BÌNH CHO 3 VẬT LIỆU
	1	2	3	
Trung bình				
1	4.10	3.07	3.43	3.533
2	2.80	2.13	2.50	2.478
Trung bình 2 nhóm	3.450	2.600	2.967	3.00
Phương sai				
1	0.040	0.063	0.043	
2	0.070	0.043	0.040	

Những tính toán sơ khởi trên đây cho thấy có thể có sự khác nhau (hay ảnh hưởng) của điều kiện và vật liệu thí nghiệm.

Gọi x_{ij} là score của điều kiện i ($i = 1, 2$) cho vật liệu j ($j = 1, 2, 3$). (Để đơn giản hóa vấn đề, chúng ta tạm thời bỏ qua k đối tượng). Mô hình phân tích phương sai hai chiều phát biểu rằng:

$$x_{ij} = \mu + \alpha_i + \beta_j + \varepsilon_{ij} \quad [4]$$

Hay cụ thể hơn: $x_{11} = \mu + \alpha_1 + \beta_1 + \varepsilon_{11}$

$$x_{12} = \mu + \alpha_1 + \beta_2 + \varepsilon_{12}$$

$$x_{13} = \mu + \alpha_1 + \beta_3 + \varepsilon_{13}$$

$$x_{21} = \mu + \alpha_2 + \beta_1 + \varepsilon_{21}$$

$$x_{22} = \mu + \alpha_2 + \beta_2 + \varepsilon_{22}$$

$$x_{23} = \mu + \alpha_2 + \beta_3 + \varepsilon_{23}$$

μ là số trung bình cho toàn quần thể, các hệ số α_i (ảnh hưởng của điều kiện i) và β_j (ảnh hưởng của vật liệu j) cần phải ước tính từ số liệu thực tế. ε_{ij} được giả định tuân theo luật phân phối chuẩn với trung bình 0 và phương sai σ^2 .

Trong phân tích phương sai hai chiều, chúng ta cần chia tổng bình phương ra thành 3 nguồn:

- Nguồn thứ nhất là tổng bình phương do khác biệt giữa 2 điều kiện:

$$SSc = \sum_i n_i (\bar{x}_i - \bar{x})^2$$

$$= 9(3.533 - 3.00)^2 + 9(2.478 - 3.00)^2$$

$$= 5.01$$

- Nguồn thứ hai là tổng bình phương khác biệt giữa 3 vật liệu:

$$SSm = \sum_j n_j (\bar{x}_j - \bar{x})^2$$

$$= 6(3.45 - 3.00)^2 + 6(2.60 - 3.00)^2 + 6(2.967 - 3.00)^2$$

$$= 2.18$$

- Nguồn thứ ba là tổng bình phương phần dư (residual sum of squares):

$$SSe = \sum_i \sum_j (x_{ij} - \bar{x}_i - \bar{x}_j + \bar{x})^2 = \sum (n_{ij} - 1) s_{ij}^2$$

$$= 2(0.040) + 2(0.063) + 2(0.043) + 2(0.070) + 2(0.043) + 2(0.040)$$

$$= 0.73$$

Trong các phương trình trên, $n = 3$ (lặp lại 3 lần cho mỗi điều kiện và vật liệu), $m = 3$ vật liệu, $\bar{x}$ là số trung bình cho toàn mẫu, $\bar{x}_i$ là số trung bình cho từng điều kiện, $\bar{x}_j$ là số trung bình cho từng vật liệu. Vì SSc có $m-1$ bậc tự do, SSm có $(n-1)$ bậc tự do, và SSe có $N-nm+2$ bậc tự do, trong đó N là tổng số mẫu (tức 18). Do đó, các trung bình bình phương

Giữa hai điều kiện: $MSc = SSc / (m-1) = 5.01 / 1 = 5.01$

Giữa ba vật liệu: $MSm = SSm / (n-1) = 2.18 / 2 = 1.09$

Phần dư: $MSe = SSe / (N-nm+2) = 0.73 / 14 = 0.052$

Do đó, so sánh độ khác biệt giữa hai điều kiện dựa vào kiểm định $F = MSc/Mse$ với bậc tự do 1 và 14. Tương tự, so sánh độ khác biệt giữa ba vật liệu có thể dựa vào kiểm định $F = MSm/Mse$ với bậc tự do 2 và 14. Các phân tích trên có thể trình bày trong một bảng phân tích phương sai như sau:

NGUỒN BIẾN THIÊN (SOURCE OF VARIATION)	BẬC TỰ DO (DEGREES OF FREEDOM)	TỔNG BÌNH PHƯƠNG (SUM OF SQUARES)	TRUNG BÌNH BÌNH PHƯƠNG (MEAN SQUARE)	KIỂM ĐỊNH F
Khác biệt giữa 2 điều kiện	1	5.01	5.01	95.6
Khác biệt giữa 3 vật liệu	2	2.18	1.09	20.8
Phần dư (residual)	14	0.73	0.052	
Tổng số	17	7.92		

11.4.1 Phân tích phương sai hai chiều với R

(a) Bước đầu tiên là nhập số liệu từ bảng 11.2 vào R. Chúng ta cần phải tổ chức dữ liệu sao cho có 4 biến như sau:

Condition (điều kiện)	Material (vật liệu)	Đối tượng	Score
1	1	1	4.1
1	1	2	3.9
1	1	3	4.3
1	2	4	3.1
1	2	5	2.8
1	2	6	3.3
1	3	7	3.5
1	3	8	3.2
1	3	9	3.6
2	1	10	2.7
2	1	11	3.1
2	1	12	2.6
2	2	13	1.9
2	2	14	2.2
2	2	15	2.3
2	3	16	2.7
2	3	17	2.3
2	3	18	2.5

Chúng ta có thể tạo ra một dãy số bằng cách sử dụng hàm `gl` (generating levels). Cách sử dụng hàm này có thể minh họa như sau:

```
> gl(9, 1, 18)
1) 1 2 3 4 5 6 7 8 9 1 2 3 4 5 6 7 8 9
Levels: 1 2 3 4 5 6 7 8 9
```

Trong lệnh trên, chúng ta tạo ra một dãy số 1, 2, 3, ... 9 hai lần (với tổng số 18 số). Mỗi một lần là một nhóm. Trong khi lệnh:

```
> gl(4, 9, 36)
[1] 1 1 1 1 1 1 1 1 1 2 2 2 2 2 2 2 2 2 3 3 3 3 3 3 3 3
3 4 4 4 4 4 4 4 4 4
Levels: 1 2 3 4
```

Trong lệnh trên, chúng ta tạo ra một dãy số với 4 bậc (1, 2, 3, 4) 9 lần (với tổng số 36 số).

Do đó, để tạo ra các bậc cho điều kiện và vật liệu, chúng ta lệnh như sau:

```
> condition <- gl(2, 9, 18)
```

```
> material <- gl(3, 3, 18)
```

Và tạo nên 18 mã số (tứ 1 đến 18):

```
> id <- 1:18
```

Sau cùng là số liệu cho score:

```
> score <- c(4.1, 3.9, 4.3, 3.1, 2.8, 3.3, 3.5, 3.2, 3.6,  
            2.7, 3.1, 2.6, 1.9, 2.2, 2.3, 2.7, 2.3, 2.5)
```

Tất cả cho vào một dataframe tên là data:

```
> data <- data.frame(condition, material, id, score)
```

```
> attach(data)
```

(b) Phân tích và kết quả sơ khởi. Bây giờ số liệu đã sẵn sàng cho phân tích. Để phân tích phương sai hai chiều, chúng ta vẫn sử dụng lệnh `lm` với các thông số như sau:

```
> twoway <- lm(score ~ condition + material)
```

```
> anova(twoway)
```

Analysis of Variance Table

Response: score

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
condition	1	5.0139	5.0139	95.575	1.235e-07	***
material	2	2.1811	1.0906	20.788	6.437e-05	***
Residuals	14	0.7344	0.0525			

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Ba nguồn dao động (variation) của score được phân tích trong bảng trên. Qua trung bình bình phương (mean square), chúng ta thấy ảnh hưởng của điều kiện có vẻ quan trọng hơn là ảnh hưởng của vật liệu thí nghiệm. Tuy nhiên, cả hai ảnh hưởng đều có ý nghĩa thống kê, vì trị số p rất thấp cho hai yếu tố.

(c) Ước số. Chúng ta yêu cầu R tóm lược các ước số phân tích bằng lệnh

summary:

```
> summary(twoway)
Call:
lm(formula = score ~ condition + material)

Residuals:
    Min       1Q   Median       3Q      Max
-0.32778 -0.16389  0.03333  0.16111  0.32222

Coefficients:
            Estimate Std. Error  t value Pr(>|t|)
(Intercept)   3.9778     0.1080   36.841  2.43e-15 ***
condition2    -1.0556     0.1080   -9.776  1.24e-07 ***
material2     -0.8500     0.1322   -6.428  1.58e-05 ***
material3     -0.4833     0.1322   -3.655  0.0026 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.229 on 14 degrees of freedom
Multiple R-Squared:  0.9074,    Adjusted R-squared:  0.8875
F-statistic: 45.72 on 3 and 14 DF, p-value: 1.761e-07
```

Kết quả trên cho thấy so với điều kiện 1, điều kiện 2 có score thấp hơn khoảng 1.056 và sai số chuẩn là 0.108, với trị số $p = 1.24e-07$, tức có ý nghĩa thống kê. Ngoài ra, so với vật liệu 1, score cho vật liệu 2 và 3 cũng thấp hơn đáng kể với độ thấp nhất ghi nhận ở vật liệu 2, và ảnh hưởng của vật liệu thí nghiệm cũng có ý nghĩa thống kê.

Giá trị có tên là "Residual standard error" được ước tính từ trung bình bình phương phần dư trong phần (a), tức là $\sqrt{0.0525} = 0.229$, tức là ước số của σ .

Hệ số xác định bội (R^2) cho biết hai yếu tố điều kiện và vật liệu giải thích khoảng 91% độ dao động của toàn bộ mẫu. Hệ số này được tính từ tổng bình phương trong kết quả phần (a) như sau:

$$R^2 = \frac{5.0139 + 2.1811}{5.0139 + 2.1811 + 0.7344} = 0.9074$$

Và sau cùng, hệ số R^2 điều chỉnh phản ánh độ “cải tiến” của mô hình. Để hiểu hệ số này tốt hơn, chúng ta thấy phương sai của toàn bộ mẫu là $s^2 = (5.0139 + 2.1811 + 0.7344) / 17 = 0.4644$. Sau khi điều chỉnh cho ảnh hưởng của điều kiện và vật liệu, phương sai này còn 0.0525 (tức là residual mean square). Như vậy hai yếu tố này làm giảm phương sai khoảng $0.4644 - 0.0525 = 0.4119$. Và hệ số R^2 điều chỉnh là:

$$\text{Adj } R^2 = 0.4119 / 0.4644 = 0.88$$

Tức là sau khi điều chỉnh cho hai yếu tố điều kiện và vật liệu phương sai của score giảm khoảng 88%.

(d) Hiệu ứng tương tác (interaction effects)

Để cho phân tích hoàn tất, chúng ta còn phải xem xét đến khả năng ảnh hưởng của hai yếu tố này có thể tương tác nhau (interactive effects). Tức là mô hình score trở thành:

$$x_{ij} = \mu + \alpha_i + \beta_j + (\alpha_i\beta_j)_{ij} + \varepsilon_{ij}$$

Chú ý phương trình trên có phần $(\alpha_i\beta_j)_{ij}$ phản ánh sự tương tác giữa hai yếu tố. Và chúng ta chỉ đơn giản lệnh R như sau:

```
> anova(twoway <- lm(score ~ condition+
material+condition*material))
Analysis of Variance Table
```

Response: score

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
condition	1	5.0139	5.0139	100.2778	3.528e-07 ***
material	2	2.1811	1.0906	21.8111	0.0001008 ***
condition:material	2	0.1344	0.0672	1.3444	0.2972719
Residuals	12	0.6000	0.0500		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Kết quả phân tích trên ($p = 0.297$ cho ảnh hưởng tương tác). Chúng ta có bằng chứng để kết luận rằng ảnh hưởng tương tác giữa vật liệu và điều kiện không có ý nghĩa thống kê, và chúng ta chấp nhận mô hình [4], tức không có tương tác.

(e) **So sánh giữa các nhóm.** Chúng ta sẽ ước tính độ khác biệt giữa hai điều kiện và ba vật liệu bằng hàm TukeyHSD với aov:

```
> res <- aov(score ~ condition+ material+condition)
> TukeyHSD(res)
Tukey multiple comparisons of means
95% family-wise confidence level
```

```
Fit: aov(formula = score ~ condition + material + condition)
```

```
$condition
```


	diff	lwr	upr	p adj
2-1	-1.055556	-1.287131	-0.8239797	1e-07

```
$material
```

	diff	lwr	upr	p adj
2-1	-0.8500000	-1.19610279	-0.5038972	0.0000442
3-1	-0.4833333	-0.82943612	-0.1372305	0.0068648
3-2	0.3666667	0.02056388	0.7127695	0.0374069

Biểu đồ 3 sau đây sẽ minh họa cho các kết quả trên:

```
> plot(TukeyHSD(res), ordered=TRUE)
There were 16 warnings (use warnings() to see them)
```



(f) **Biểu đồ.** Để xem qua độ ảnh hưởng của hai yếu tố điều kiện và vật liệu, chúng ta cần phải có một đồ thị, mà trong phân tích phương sai gọi là đồ thị tương tác. Hàm `interaction.plot` cung cấp phương tiện để vẽ biểu đồ này (xem **biểu đồ 4**):

```
> interaction.plot(score, condition, material)
```

11.5 Phân tích hiệp biến (analysis of covariance - ANCOVA)

Phân tích hiệp biến (sẽ viết tắt là ANCOVA) là phương pháp phân tích sử dụng cả hai mô hình hồi qui tuyến tính và phân tích phương sai. Trong phân tích hồi qui tuyến tính, cả hai biến phụ thuộc (dependent variable, cũng có thể gọi là “biến ứng” - response variable) và biến độc lập (independent variable hay predictor variable) phần lớn là ở dạng liên tục (continuous variable), như độ cholesterol và độ tuổi chẳng hạn. Trong phân tích phương sai, biến phụ thuộc là biến liên tục, còn biến độc lập thì ở dạng thứ bậc và thể loại (categorical variable), như độ galactose và nhóm bệnh nhân trong ví dụ 1 chẳng hạn. Trong phân tích hiệp biến, biến phụ thuộc là liên tục, nhưng biến độc lập có thể là liên tục và thể loại.

Ví dụ 3: Trong nghiên cứu mà kết quả được trình bày dưới đây, các nhà nghiên cứu đo chiều cao và độ tuổi của 18 học sinh thuộc vùng thành thị (urban) và 14 học trò thuộc vùng nông thôn (rural).

Bảng 4. Chiều cao của học trò vùng thành thị và nông thôn			
AREA	ID	AGE (MONTHS)	HEIGHT (CM)
urban	1	109	137.6
urban	2	113	147.8
urban	3	115	136.8
urban	4	116	140.7
urban	5	119	132.7
urban	6	120	145.4
urban	7	121	135.0
urban	8	124	133.0
urban	9	126	148.5
urban	10	129	148.3
urban	11	130	147.5
urban	12	133	148.8
urban	13	134	133.2
urban	14	135	148.7
urban	15	137	152.0
urban	16	139	150.6
urban	17	141	165.3
urban	18	142	149.9

rural	1	121	139.0
rural	2	121	140.9
rural	3	128	134.9
rural	4	129	149.5
rural	5	131	148.7
rural	6	132	131.0
rural	7	133	142.3
rural	8	134	139.9
rural	9	138	142.9
rural	10	138	147.7
rural	11	138	147.7
rural	12	140	134.6
rural	13	140	135.8
rural	14	140	148.5

Câu hỏi đặt ra là có sự khác biệt nào về chiều cao giữa trẻ em ở thành thị và nông thôn hay không. Nói cách khác, môi trường cư trú có ảnh hưởng đến chiều cao hay không, và nếu có thì mức độ ảnh hưởng là bao nhiêu?

Một yếu tố có ảnh hưởng lớn đến chiều cao là độ tuổi. Trong độ tuổi trưởng thành, chiều cao tăng theo độ tuổi. Do đó, so sánh chiều cao giữa hai nhóm chỉ có thể khách quan nếu độ tuổi giữa hai nhóm phải tương đương nhau. Để đảm bảo tính khách quan của so sánh, chúng ta cần phải phân tích số liệu bằng mô hình hiệp biến.

Việc đầu tiên là chúng ta phải nhập số liệu vào R với những lệnh sau đây:

```
# tạo ra dãy số id
> id <- c(1:18, 1:14)
# group 1=urban 2=rural và cần phải xác định group là một "factor"

> group <- c(1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,
            2,2,2,2,2,2,2,2,2,2,2,2,2,2,2,2)
> group <- as.factor(group)

> # nhập dữ liệu
> age <- c(109,113,115,116,119,120,121,124,126,129,130,
          133,134,135, 137,139,141,142, 121,121,128,
          129,131,132,133,134,138,138,138,140,140,140)

> height <- c(137.6,147.8,136.8,140.7,132.7,145.4,135.0,
             133.0,148.5, 148.3,147.5,148.8,133.2,
             148.7,152.0,150.6,165.3,149.9,
             139.0,140.9,134.9,149.5,148.7,131.0,142.3,
             139.9,142.9,147.7,147.7,134.6,135.8,148.5)

> # tạo một data frame
> data <- data.frame(id, group, age, height)
> attach(data)
```


Chúng ta thử xem qua vài chỉ số thống kê mô tả bằng cách ước tính độ tuổi và chiều cao trung bình cho từng nhóm học sinh:

```
> tapply(age, group, mean)
  1      2
126.8333 133.0714

> tapply(height, group, mean)
  1      2
144.5444 141.6714
```

Kết quả trên cho thấy nhóm học sinh thành thị có độ tuổi thấp hơn học sinh nông thôn khoảng 6.3 tháng (126.8 - 133.1). Tuy nhiên, chiều cao của học sinh thành thị cao hơn học sinh nông thôn khoảng 2.8 cm (144.5 - 141.7). Bạn đọc có thể dùng kiểm định t để thấy rằng sự khác biệt về độ tuổi giữa hai nhóm có ý nghĩa thống kê ($P = 0.045$).

Ngoài ra, biểu đồ sau đây còn cho thấy có một mối liên hệ tương quan giữa tuổi và chiều cao:



Biểu đồ 5. Chiều cao (cm) và độ tuổi (tháng tuổi) của hai nhóm học sinh thành thị và nông thôn.

Vì hai nhóm khác nhau về độ tuổi, và tuổi có liên hệ với chiều cao, cho nên chúng ta không thể phát biểu hay so sánh chiều cao giữa 2 nhóm học sinh mà không điều chỉnh cho độ tuổi. Để điều chỉnh độ tuổi, chúng ta sử dụng phương pháp phân tích hiệp biến.

11.5.1 Mô hình phân tích hiệp biến

Gọi y là chiều cao, x là độ tuổi, và g là nhóm. Mô hình căn bản của ANCOVA giả định rằng mỗi liên hệ giữa y và x là một đường thẳng, và độ dốc (gradient hay slope) của hai nhóm trong mỗi liên hệ này không khác nhau. Nói cách khác, viết theo kí hiệu của hồi qui tuyến tính, chúng ta có:

$$\begin{aligned}y_1 &= \alpha_1 + \beta x + e_1 && \text{in group 1} \\y_2 &= \alpha_2 + \beta x + e_2 && \text{in group 2.} \quad [5]\end{aligned}$$

Trong đó:

α_1 : là giá trị trung bình của y khi $x=0$ của nhóm 1;

α_2 : là giá trị trung bình của y khi $x=0$ của nhóm 2;

β : độ dốc của mỗi liên hệ giữa y và x ;

e_1 và e_2 : biến số ngẫu nhiên với trung bình 0 và phương sai σ^2 .

Gọi $\bar{x}$ là số trung bình của độ tuổi cho cả 2 nhóm, $\bar{x}_1$ và $\bar{x}_2$ là tuổi trung bình của nhóm 1 và nhóm 2. Như đã nói ở trên, nếu $\bar{x}_1 \neq \bar{x}_2$, thì so sánh chiều cao trung bình của nhóm 1 và 2 ($\bar{y}_1$ và $\bar{y}_2$) sẽ thiếu khách quan, vì

$$\bar{y}_1 = \alpha_1 + \beta \bar{x}_1 + e_1$$

$$\bar{y}_2 = \alpha_2 + \beta \bar{x}_2 + e_2$$

và mức độ khác biệt giữa hai nhóm bây giờ tùy thuộc vào hệ số β :

$$\bar{y}_1 - \bar{y}_2 = \alpha_1 - \alpha_2 + \beta(\bar{x}_1 - \bar{x}_2)$$

Chú ý rằng trong mô hình [5], chúng ta có thể diễn dịch $\alpha_1 - \alpha_2$ là độ khác biệt chiều cao trung bình giữa hai nhóm nếu cả hai nhóm có cùng tuổi trung bình. Mức khác biệt này thể hiện ảnh hưởng của hai nhóm nếu không có một yếu tố nào liên hệ đến y . Để ước tính $\alpha_1 - \alpha_2$, chúng ta không thể đơn giản trừ hai số trung bình $\bar{y}_1 - \bar{y}_2$, nhưng phải điều chỉnh cho x . Gọi x^* là một giá trị chung cho cả hai nhóm, chúng ta có thể ước tính giá trị điều chỉnh y cho nhóm 1 (kí hiệu $\bar{y}_{1a}$) như sau:

$$\bar{y}_{1a} = \bar{y}_1 - \beta(\bar{x}_1 - x^*)$$

$\bar{y}_{1a}$ có thể xem là một ước số cho chiều cao trung bình của nhóm 1 (thành thị) cho giá trị x là x^* . Tương tự:

$$\bar{y}_{2a} = \bar{y}_2 - \beta(\bar{x}_2 - x^*)$$

là ước số cho chiều cao trung bình của nhóm 2 (nông thôn) với cùng giá trị x^* . Từ đây, chúng ta có thể ước tính ảnh hưởng của thành thị và nông thôn bằng công thức sau đây:

$$\bar{y}_{1a} - \bar{y}_{2a} = \bar{y}_2 - \bar{y}_1 - \beta(\bar{x}_1 - \bar{x}_2)$$

Do đó, vấn đề là chúng ta phải ước tính β . Có thể chứng minh rằng ước số β từ phương pháp bình phương nhỏ nhất cũng là ước tính khách quan cho $\alpha_1 - \alpha_2$. Khi viết bằng mô hình tuyến tính, mô hình hiệp biến có thể mô tả như sau:

$$y = \alpha + \beta x + \gamma g + \delta(xg) + e \quad [6]$$

Nói cách khác, mô hình trên phát biểu rằng chiều cao của một học sinh bị ảnh hưởng bởi 3 yếu tố: độ tuổi (β), thành thị hay nông thôn (γ), và tương tác giữa hai yếu tố đó (δ). Nếu $\delta = 0$ (tức ảnh hưởng tương tác không có ý nghĩa thống kê), mô hình trên giảm xuống thành:

$$y = \alpha + \beta x + \gamma g + e \quad [7]$$

Nếu $\gamma = 0$ (tức ảnh hưởng của thành thị không có ý nghĩa thống kê), mô hình trên giảm xuống thành:

$$y = \alpha + \beta x + e \quad [8]$$

11.5.2 Phân tích bằng R

Các thảo luận vừa trình bày trên xem ra khá phức tạp, nhưng trong thực tế, với R, cách ước tính rất đơn giản bằng hàm `lm`. Chúng ta sẽ phân tích ba mô hình [6], [7] và [8]:

```
> # model 6
> model6 <- lm(height ~ group + age + group:age)

> # model 7
> model7 <- lm(height ~ group + age)

> # model 8
> model8 <- lm(height ~ age)
```

Chúng ta cũng có thể so sánh cả ba mô hình cùng một lúc bằng lệnh anova như sau:

```
> anova(model6, model7, model8)
```

```
Analysis of Variance Table
```

```
Model 1: height ~ group + age + group:age
```

```
Model 2: height ~ group + age
```

```
Model 3: height ~ age
```

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	28	1270.44				
2	29	1338.02	-1	-67.57	1.4893	0.23251
3	30	1545.95	-1	-207.93	4.5827	0.04114 *

```
---
```

```
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Chú ý “model 1” chính là mô hình [6], “model 2” là mô hình [7], và “model 3” là mô hình [8]. RSS là residual sum of squares, tức tổng bình phương phần dư cho mỗi mô hình. Kết quả phân tích trên cho thấy:

- Toàn bộ mẫu có $18 + 14 = 32$ học sinh, mô hình [6] có 4 thông số (α , β , γ và δ), cho nên mô hình này có $32 - 4 = 28$ bậc tự do. Tổng bình phương của mô hình là 1270.44.
- Mô hình [7] có 3 thông số (tức còn 29 bậc tự do), cho nên tổng bình phương phần dư cao hơn mô hình [7]. Tuy nhiên, đứng trên phương diện xác suất thì trung bình bình phương phần dư của mô hình này $1338.02 / 29 = 46.13$, không khác mấy so với mô hình [6] (trung bình bình phương là: $1270.44 / 28 = 45.36$), vì trị số $p = 0.2325$, tức không có ý nghĩa thống kê. Nói cách khác, bỏ hệ số tương tác δ không làm thay đổi khả năng tiên đoán của mô hình một cách đáng kể.
- Mô hình [8] chỉ có 2 thông số (và do đó có 30 bậc tự do), với tổng bình phương là 1545.95. Trung bình bình phương phần dư của mô hình này là 51.53 ($1545.95 / 30$), tức cao hơn hai mô hình [6] một cách đáng kể, vì trị số $p = 0.0411$.

Qua phân tích trên, chúng ta thấy mô hình [7] là tối ưu hơn cả, vì chỉ cần 3 thông số mà có thể “giải thích” được dữ liệu một cách đầy đủ. Bây giờ chúng ta sẽ chú tâm vào phân tích kết quả của mô hình này.

```
> summary(model7)
```

Call:

```
lm(formula = height ~ group + age)
```

Residuals:

Min	1Q	Median	3Q	Max
-14.324	-3.285	0.879	3.956	14.866

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	91.8171	17.9294	5.121	1.81e-05	***
group2	-5.4663	2.5749	-2.123	0.04242	*
age	0.4157	0.1408	2.953	0.00619	**

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.793 on 29 degrees of freedom

Multiple R-Squared: 0.2588, Adjusted R-squared: 0.2077

F-statistic: 5.063 on 2 and 29 DF, p-value: 0.01300

Qua phần ước tính thông số trình bày trên đây, chúng ta thấy tính trung bình chiều cao học sinh tăng khoảng 0.41 cm cho mỗi tháng tuổi. Chú ý trong kết quả trên, phần “group2” có nghĩa là hệ số hồi qui (regression coefficient) cho nhóm 2 (tức là nông thôn), vì R phải đặt hệ số cho nhóm 1 bằng 0 để tiện việc tính toán. Vì thế, chúng ta có hai phương trình (hay hai đường biểu diễn) cho hai nhóm học sinh như sau:

Đối với học sinh thành thị:

$$\text{Height} = 91.817 + 0.4157(\text{age})$$

Và đối với học sinh nông thôn:

$$\text{Height} = 91.817 - 5.4663(\text{rural}) + 0.4157(\text{age})$$

Nói cách khác, sau khi điều chỉnh cho độ tuổi, nhóm học sinh nông thôn (rural) có chiều cao thấp hơn nhóm thành thị khoảng 5.5 cm và mức độ khác biệt này có ý nghĩa thống kê vì trị số $p = 0.0424$. (Chú ý là trước khi điều chỉnh cho độ tuổi, mức độ khác biệt là 2.8 cm).

Các biểu đồ sau đây sẽ minh họa cho các mô hình trên:


```
> par(mfrow=c(2,2))

> plot(age, height, pch=as.character(group), main="Mô hình 1")
> abline(144.54, 0) #mean value for urban
> abline(141.67, 0) #mean value for rural

> plot(age, height, pch=as.character(group), main="Mô hình 2")
> abline(102.63, 0.3138) #single line for dependence on age

> plot(age, height, pch=as.character(group), main="Mô hình 3")
> abline(91.8, 0.416) #line for males
> abline(91.8-5.46,0.416) #line for females parallel

> plot(age, height, pch=as.character(group), main="Mô hình 4")
> abline(79.7, 0.511) #line for males
> abline(79.7+47.08, 0.511-0.399) #line for females parallel
> par(mfrow=c(1,1))
```



Biểu đồ 6. Mô hình 1: chiều cao là hàm số của nơi trú ngụ, nhưng không có liên hệ với độ tuổi; Mô hình 2: giả thiết rằng chiều cao phụ thuộc vào độ tuổi, nhưng không có khác nhau giữa hai nhóm thành thị và nông thôn; Mô hình 3: giả thiết rằng mối liên hệ giữa chiều cao và tuổi của nhóm thành thị tương đương với nhóm nông thôn (hai đường song song), nhưng học sinh thành thị có chiều cao cao hơn nông thôn; và mô hình 4 giả thiết rằng mức độ khác biệt về chiều cao giữa hai nhóm tùy thuộc vào độ tuổi (tức có tương tác giữa độ tuổi và nơi trú ngụ): ở tuổi <120 tháng, chiều cao hai nhóm không khác nhau mấy, nhưng khi tuổi >120 tháng tuổi thì nhóm học sinh thành thị có chiều cao cao hơn nhóm nông thôn. Phân tích trên cho thấy mô hình 3 là tốt nhất.

11.6 Phân tích phương sai cho thí nghiệm giai thừa (factorial experiment)

Ví dụ 4: Để khảo sát ảnh hưởng của 4 loại thuốc trừ sâu (1, 2, 3 và 4) và ba loại giống (B1, B2 và B3) đến sản lượng của cam, các nhà nghiên cứu tiến hành một thí nghiệm loại giai thừa. Trong thí nghiệm này, mỗi giống cam có 4 cây cam được chọn một cách ngẫu nhiên, và 4 loại thuốc trừ sâu áp dụng (cũng ngẫu nhiên) cho mỗi cây cam. Kết quả nghiên cứu (sản lượng cam) cho từng giống và thuốc trừ sâu như sau:

Bảng 5. Sản lượng cam cho 3 loại giống và 4 loại thuốc trừ sâu

GIỐNG CAM (VARIETY)	THUỐC TRỪ SÂU (PESTICIDE)				TỔNG SỐ
	1	2	3	4	
B1	29	50	43	53	175
B2	41	58	42	73	214
B3	66	85	63	85	305
Tổng số	136	193	154	211	694

Mô hình phân tích thí nghiệm giai thừa cũng không khác gì so với phân tích phương sai hai chiều như trình bày trong phần trên. Cụ thể hơn, mô hình mà chúng ta xem xét là:

$$\text{product} = \alpha + \beta(\text{variety}) + \gamma(\text{pesticide}) + \varepsilon$$

Trong đó, α là hằng số biểu hiện trung bình toàn mẫu, β là hệ số ảnh hưởng của ba giống cam, γ là hệ số ảnh hưởng của 4 loại thuốc trừ sâu, và ε là phần dư (residual) của mô hình.

Chúng ta có thể sử dụng hàm aov của R để ước tính các thông số trên như sau:

```
# trước hết chúng ta nhập số liệu
> variety <- c(1, 1, 1, 1, 2, 2, 2, 2, 3, 3, 3, 3)
> pesticide <- c(1, 2, 3, 4, 1, 2, 3, 4, 1, 2, 3, 4)
> product <- c(29, 50, 43, 53, 41, 58, 42, 73, 66, 85, 69, 85)

# định nghĩa variety và pesticide là hai yếu tố (factors)
> variety <- as.factor(variety)
> pesticide <- as.factor(pesticide)

# cho vào một data frame tên là data
> data <- data.frame(variety, pesticide, product)
```

```
# phân tích phương sai bằng aov và cho vào object analysis
> analysis <- aov(product ~ variety + pesticide)
> anova(analysis)
```

Analysis of Variance Table

Response: product

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
variety	2	2225.17	1112.58	44.063	0.000259	***
pesticide	3	1191.00	397.00	15.723	0.003008	**
Residuals	6	151.50	25.25			

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Kết quả trên cho thấy cả hai yếu tố giống cây (variety) và thuốc trừ sâu (pesticide) đều có ảnh hưởng đến sản lượng cam, vì trị số $p < 0.05$. Để so sánh cụ thể cho từng hai nhóm, chúng ta sử dụng hàm TukeyHSD như sau:

```
> TukeyHSD(analysis)
```

Tukey multiple comparisons of means
95% family-wise confidence level

Fit: aov(formula = product ~ variety + pesticide)

\$variety

	diff	lwr	upr	p adj
2-1	9.75	-1.152093	20.65209	0.0749103
3-1	32.50	21.597907	43.40209	0.0002363
3-2	22.75	11.847907	33.65209	0.0016627


\$pesticide

	diff	lwr	upr	p adj
2-1	19	4.797136	33.202864	0.0140509
3-1	6	-8.202864	20.202864	0.5106152
4-1	25	10.797136	39.202864	0.0036109
3-2	-13	-27.202864	1.202864	0.0704233
4-2	6	-8.202864	20.202864	0.5106152
4-3	19	4.797136	33.202864	0.0140509

Kết quả phân tích giữa các loại giống cho thấy giống B3 có sản lượng cao hơn giống B1 khoảng 32 đơn vị với khoảng tin cậy 95% từ 21 đến 43 ($p = 0.0002$). Giống cam B3 cũng tốt hơn giống B2, với độ khác biệt trung bình khoảng 22 đơn vị ($p = 0.0017$). Nhưng không có khác biệt đáng kể giữa giống B2 và B1.

So sánh giữa các loại thuốc trừ sâu, kết quả trên cho chúng ta biết thuốc trừ sâu 4 có hiệu quả cao hơn thuốc 1 và 3. Ngoài ra, thuốc 2 cũng có hiệu quả cao hơn thuốc 1. Còn các so sánh khác không có ý nghĩa thống kê. Biểu đồ Tukey sau đây minh họa cho kết luận trên.

```
> plot(TukeyHSD(analysis), ordered=TRUE)
```



11.7 Phân tích phương sai cho thí nghiệm hình vuông Latin (Latin square experiment)

Ví dụ 5: Để so sánh hiệu quả của 2 loại phân bón (A và B) cùng 2 phương pháp canh tác (a và b), các nhà nghiên cứu tiến hành một thí nghiệm hình vuông Latin. Theo đó, có 4 nhóm can thiệp tổng hợp từ hai loại phân bón và phương pháp canh tác: Aa, Ab, Ba, và Bb (sẽ cho mã số, lần lượt, là 1 = Aa, 2 = Ab, 3 = Ba, 4 = Bb). Bốn phương pháp (treatment) đó được áp dụng trong 4 mẫu ruộng (sample = 1, 2, 3, 4) và 4 loại cây trồng (variety = 1, 2, 3, 4). Tổng cộng, thí nghiệm có 4 x 4 = 16 mẫu. Tiêu chí để đánh giá là sản lượng, và kết quả sản lượng được tóm tắt trong bảng sau đây:

Bảng 6. Sản lượng cho 2 loại phân bón và 2 phương pháp canh tác:

MẪU RUỘNG (SAMPLE)	GIỐNG (VARIETY)			
	1	2	3	4
1	175 Aa	143 Ba	128 Bb	166 Ab
2	170 Ab	178 Aa	140 Ba	131 Bb
3	135 Bb	173 Ab	169 Aa	141 Ba
4	145 Ba	136 Bb	165 Ab	173 Aa

Câu hỏi đặt ra là các phương pháp canh tác và phân bón có ảnh hưởng đến sản lượng hay không. Để trả lời câu hỏi đó, chúng ta phải xem xét đến các nguồn làm cho sản lượng thay đổi hay biến thiên. Nhìn qua thí nghiệm và bảng số liệu trên, rất dễ dàng hình dung ra 3 nguồn biến thiên chính:

- Nguồn thứ nhất là khác biệt giữa các phương pháp canh tác và phân bón;
- Nguồn thứ hai là khác biệt giữa các loại giống cây;
- Nguồn thứ ba là khác biệt giữa các mẫu ruộng;

Và phần còn lại là khác biệt trong mỗi mẫu ruộng và loại giống. Để có một cái nhìn chung về số liệu, chúng ta hãy tính trung bình cho từng nhóm qua bảng số sau đây:

TRUNG BÌNH CHO TỪNG LOẠI GIỐNG	TRUNG BÌNH CHO TỪNG MẪU	TRUNG BÌNH CHO TỪNG PHƯƠNG PHÁP
1: 156.25	1: 153.00	1: 173.75
2: 157.50	2: 154.75	2: 168.50
3: 150.50	3: 154.50	3: 142.25
4: 152.75	4: 154.75	4: 132.50
Tổng trung bình: 154.25	Tổng trung bình: 154.25	Tổng trung bình: 154.25

Bảng tóm lược trên cho phép chúng ta tính tổng bình phương cho từng nguồn biến thiên. Khởi đầu là tổng bình phương cho toàn bộ thí nghiệm (sẽ tạm gọi là SS_{total}):

- Tổng bình phương chung cho toàn thí nghiệm:

$$SS_{total} = (175 - 154.25)^2 + (143 - 154.25)^2 + \dots (165 - 154.25)^2 + (173 - 154.25)^2 = 4941$$

- Tổng bình phương do khác biệt giữa các loại giống ($SS_{variety}$). Chú ý là vì trung bình mỗi giống được tính từ 4 số, cho nên chúng ta phải nhân cho 4 khi tính tổng bình phương:

$$SS_{variety} = 4(156.25 - 154.25)^2 + 4(157.50 - 154.25)^2 + 4(150.50 - 154.25)^2 + 4(152.75 - 154.25)^2 = 123.5$$

Vì có 4 loại giống và một thông số, cho nên bậc tự do là $4 - 1 = 3$. Theo đó, trung bình bình phương (mean square) là: $123.5 / 3 = 41.2$.

- Tổng bình phương do khác biệt giữa giống (SS_{sample}). Chú ý là vì trung bình mỗi mẫu được tính từ 4 số, cho nên khi tính tổng bình phương, cần phải nhân cho 4:

$$SS_{sample} = 4(153.00 - 154.25)^2 + 4(154.75 - 154.25)^2 + 4(154.50 - 154.25)^2 + 4(154.75 - 154.25)^2 = 8.5$$

Vì có 4 mẫu và một thông số, cho nên bậc tự do là $4 - 1 = 3$, và theo đó trung bình bình phương là: $8.5 / 3 = 2.8$.

Tổng bình phương do khác biệt giữa các phương pháp (SS_{method}). Chú ý là vì trung bình mỗi phương pháp được tính từ 4 số, cho nên khi tính tổng bình phương, cần phải nhân cho 4:

$$SS_{\text{sample}} = 4(173.75 - 154.25)^2 + 4(168.50 - 154.25)^2 + 4(142.25 - 154.25)^2 + 4(132.50 - 154.25)^2 = 4801.50$$

Vì có 4 phương pháp và một thông số, cho nên bậc tự do là $4 - 1 = 3$, và theo đó trung bình bình phương là: $4801.5/3 = 1600.5$.

- Tổng bình phương phần dư (residual sum of squares):

$$SS_{\text{residual}} = SS_{\text{total}} - SS_{\text{method}} - SS_{\text{sample}} - SS_{\text{variety}} \\ = 4941.0 - 4801.5 - 8.5 - 123.5 = 7.5$$

Những ước tính trên đây có thể trình bày trong một bảng phân tích phương sai như sau:

NGUỒN BIẾN THIÊN	BẬC TỰ DO (DEGREES OF FREEDOM)	TỔNG BÌNH PHƯƠNG (SUM OF SQUARES)	TRUNG BÌNH BÌNH PHƯƠNG (MEAN SQUARE)	KIỂM ĐỊNH F
Giữa 4 mẫu ruộng	3	8.5	2.8	2.3
Giữa 4 loại giống	3	123.5	41.2	32.9
Giữa 4 phương pháp	3	4801.5	1600.5	1280.4
Phần dư (residual)	6	7.5		
Tổng số	16	4941.0		

Qua phân tích thủ công và đơn giản trên, chúng ta thấy phương pháp canh tác và loại giống có ảnh hưởng lớn đến sản lượng. Để tính toán chính xác trị số p, chúng ta có thể sử dụng R để tiến hành phân tích phương sai cho thí nghiệm hình vuông Latin.

Vấn đề tổ chức số liệu sao cho thích hợp để R có thể tính toán là rất quan trọng. Nói một cách ngắn gọn, mỗi số liệu phải là một số đặc thù (unique). Trong thí nghiệm trên, chúng ta có 4 loại giống, 4 mẫu, cho nên tổng số là 16 số liệu. Và, 16 số liệu này phải được định nghĩa cho từng loại giống, từng mẫu, và quan trọng hơn là cho từng phương pháp canh tác. Chẳng hạn như, trong ví dụ bảng số liệu 10.6 trên, 175 là sản lượng của phương pháp canh tác 1 (tức Aa), loại giống 1, và mẫu 1; nhưng 173 (số ở góc phải cuối bảng) là sản lượng của phương pháp canh tác 1, nhưng từ loại giống 4, và mẫu 4; v.v.

- Trước hết, chúng ta nhập số liệu sản lượng, và gọi đó là *y*:

```
> y <- c(175, 143, 128, 166,
         170, 178, 140, 131,
         135, 173, 169, 141,
         145, 136, 165, 173)
```
- Kế đến, gọi *variety* là giống gồm 4 bậc (1, 2, 3, 4) cho từng số liệu trong *y* (và cũng định nghĩa rằng *variety* là một factor, tức biến thứ bậc):

```
> variety <- c(1,2,3,4,
               1,2,3,4,
               1,2,3,4,
               1,2,3,4)

> variety <- as.factor(variety)
```
- Gọi *sample* là mẫu gồm 4 bậc (1, 2, 3, 4) cho từng số liệu trong *y* (và cũng định nghĩa rằng *sample* là một factor, tức biến thứ bậc):

```
> sample <- c(1,1,1,1,
              2,2,2,2,
              3,3,3,3,
              4,4,4,4)

> sample <- as.factor(sample)
```
- Nhập số liệu cho phương pháp, *method*, cũng gồm 4 bậc (1, 2, 3, 4) cho từng số liệu trong *y* (và cũng định nghĩa rằng *method* là một factor, tức biến thứ bậc):

```
> method <- c(1, 3, 4, 2,
              2, 1, 3, 4,
              4, 2, 1, 3,
              3, 4, 2, 1)

> method <- as.factor(method)
```
- Tổng hợp tất cả các số liệu trên vào một data frame và gọi là *data*:

```
> data <- data.frame(sample, variety, method, y)
```

- In data để kiểm tra xem số liệu có đúng và thích hợp hay chưa:

```
> data
```

	sample	variety	method	y
1	1	1	1	175
2	1	2	3	143
3	1	3	4	128
4	1	4	2	166
5	2	1	2	170
6	2	2	1	178
7	2	3	3	140
8	2	4	4	131
9	3	1	4	135
10	3	2	2	173
11	3	3	1	169
12	3	4	3	141
13	4	1	3	145
14	4	2	4	136
15	4	3	2	165
16	4	4	1	173

Bây giờ chúng ta đã sẵn sàng dùng hàm `lm` hay `aov` để phân tích số liệu. Ở đây chúng ta sẽ sử dụng hàm `aov` để tính các nguồn biến thiên trên (kết quả tính toán sẽ chứa trong đối tượng `latin`):

```
> latin <- aov(y ~ sample + variety + method)
```

```
> summary(latin)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
sample	3	8.5	2.8	2.2667	0.1810039
variety	3	123.5	41.2	32.9333	0.0004016 ***
method	3	4801.5	1600.5	1280.4000	8.293e-09 ***
Residuals	6	7.5	1.3		

```
---
```

```
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


Tất cả các kết quả này (dĩ nhiên) là những kết quả mà chúng ta đã tóm tắt trong bảng phân tích phương sai một cách “thủ công” trên đây. Tuy nhiên, ở đây R cung cấp cho chúng ta trị số p (trong $Pr > F$) để có thể suy luận thống kê. Và, qua trị số p, chúng ta có thể phát biểu rằng mẫu ruộng không có ảnh hưởng đến sản lượng, nhưng loại giống và phương pháp canh tác thì có ảnh hưởng đến sản lượng.

Để biết mức độ khác biệt giữa các phương pháp canh tác và giữa các loại giống, chúng ta dùng hàm TukeyHSD như sau:


```
> TukeyHSD(latin)
$variety
      diff      lwr      upr      p adj
2-1  1.25 -1.4867231  3.9867231  0.4528549
3-1 -5.75 -8.4867231 -3.0132769  0.0014152
4-1 -3.50 -6.2367231 -0.7632769  0.0173206
3-2 -7.00 -9.7367231 -4.2632769  0.0004803
4-2 -4.75 -7.4867231 -2.0132769  0.0038827
4-3  2.25 -0.4867231  4.9867231  0.1034761

$method
      diff      lwr      upr      p adj
2-1  -5.25  -7.986723  -2.513277  0.0023016
3-1 -31.50 -34.236723 -28.763277  0.0000001
4-1 -41.25 -43.986723 -38.513277  0.0000000
3-2 -26.25 -28.986723 -23.513277  0.0000004
4-2 -36.00 -38.736723 -33.263277  0.0000000
4-3  -9.75 -12.486723  -7.013277  0.0000730
```

So sánh giữa các loại giống cho thấy có sự khác biệt giữa giống 3 và 1, 4 và 1, 3 và 2, 4 và 2.

Tất cả các so sánh giữa các phương pháp canh tác đều có ý nghĩa thống kê. Nhưng loại nào có sản lượng cao nhất? Để trả lời câu hỏi này, chúng ta sẽ sử dụng biểu đồ hộp:

```
> boxplot(y ~ method, xlab="Methods (1=Aa, 2=Ab,
3=Ba, 4=Bb", ylab="Production")
```



Biểu đồ so sánh sản lượng của bốn phương pháp canh tác.

11.8 Phân tích phương sai cho thí nghiệm giao chéo (cross-over experiment)

Ví dụ 6: Để thử nghiệm hiệu ứng của một thuốc mới đối với chứng ra mồ hôi (thuốc này được bào chế để chữa trị bệnh tim, nhưng ra mồ hôi là một ảnh hưởng phụ), các nhà nghiên cứu tiến hành một nghiên cứu trên 16 bệnh nhân. Số bệnh nhân này được chia thành 2 nhóm (tạm gọi là nhóm AB và BA) một cách ngẫu nhiên. Mỗi nhóm gồm 8 bệnh nhân. Bệnh nhân được theo dõi hai lần: tháng thứ nhất và tháng thứ 2. Đối với bệnh nhân nhóm AB, tháng thứ nhất họ được điều trị bằng thuốc, tháng thứ hai họ được cho sử dụng giả dược (placebo). Ngược lại, với bệnh nhân nhóm BA, tháng thứ nhất sử dụng giả dược, và tháng thứ hai được điều trị bằng thuốc. Tiêu chí để đánh giá là thời gian ra mồ hôi trên trán (tính từ lúc uống thuốc đến khi ra mồ hôi) sau khi sử dụng thuốc hay giả dược. Kết quả nghiên cứu được trình bày trong bảng số liệu sau đây:

Bảng 7. Kết quả nghiên cứu hiệu ứng ra mồ hôi của thuốc điều trị bệnh tim

NHÓM	MÃ SỐ BỆNH NHÂN SỐ (ID)	THỜI GIAN (PHÚT) RA MỒ HÔI TRÊN TRÁN	
		THÁNG 1	THÁNG 2
AB		A	Placebo
	1	6	4
	3	8	7
	5	12	6
	6	7	8
	9	9	10
	10	6	4
	13	11	6
	15	8	8
BA		Placebo	A
	2	5	7
	4	9	6
	7	7	11
	8	4	7
	11	9	8
	12	5	4
	14	8	9
	16	9	13

Câu hỏi chính là có sự khác biệt về thời gian ra mồ hôi giữa hai nhóm điều trị bằng thuốc và giả dược hay không?

Để trả lời câu hỏi trên, chúng ta cần tiến hành phân tích phương sai. Nhưng vì cách thiết kế nghiên cứu khá đặc biệt (hai nhóm bệnh nhân với cách sắp xếp can thiệp theo hai thứ tự khác nhau), nên các phương pháp phân tích trên không thể áp dụng được. Có một phương pháp thông dụng là phân tích phương sai trong từng nhóm, rồi sau đó so sánh giữa hai nhóm. Một trong những vấn đề chúng ta cần phải lưu ý là khả năng hiệu ứng kéo dài (còn gọi là carry-over effect), tức là trong nhóm AB, hiệu quả của tháng thứ 2 có thể chịu ảnh hưởng kéo dài từ tháng thứ nhất khi bệnh nhân được điều trị bằng thuốc thật. Trước hết, chúng ta thử tóm lược dữ liệu bằng bảng sau đây:

Bảng 8. Tóm lược kết quả thí nghiệm hiệu ứng ra mồ hôi của thuốc điều trị bệnh tim

NHÓM	MÃ SỐ BỆNH NHÂN SỐ (ID)	THỜI GIAN (PHÚT) RA MỒ HÔI TRÊN TRÁN		TRUNG BÌNH CHO TỪNG BỆNH NHÂN
		THÁNG 1	THÁNG 2	
AB		A	Placebo	
	1	6	4	5.0
	3	8	7	7.5
	5	12	6	9.0
	6	7	8	7.5
	9	9	10	9.5
	10	6	4	5.0
	13	11	6	8.5
	15	8	8	8.0
	Trung bình	8.375	6.625	7.50
BA		Placebo	A	
	2	5	7	6.0
	4	9	6	7.5
	7	7	11	9.0
	8	4	7	5.5
	11	9	8	8.5
	12	5	4	4.5
	14	8	9	8.5
	16	9	13	11.0
	Trung bình	7.000	8.125	7.5625
Trung bình cho 2 nhóm		7.6875	7.3750	7.5312

Trung bình cho nhóm A = $(8.375 + 8.125) / 2 = 8.25$

Trung bình cho nhóm P (giả dược) = $(6.625 + 7.000) / 2 = 6.8125$

Qua bảng tóm lược trên, chúng ta có thể tính toán một số tổng bình phương:

- Tổng bình phương do khác biệt giữa hai nhóm điều trị bằng thuốc và giả dược:

$$SSTreat = 16(8.25 - 7.5312)^2 + 16(8.125 - 7.5312)^2 = 16.53$$

- Tổng bình phương do khác biệt giữa tháng 1 và tháng 2:

$$SSPeriod = 16(7.6875 - 7.5312)^2 + 16(7.3750 - 7.5312)^2 = 0.781$$

- Tổng bình phương do khác biệt giữa hai nhóm AB và BA (thứ tự):
 $SS_{seq} = 16(7.50 - 7.5312)^2 + 16(7.5625 - 7.5312)^2 = 0.031$
- Tổng bình phương do khác biệt giữa các bệnh nhân trong cùng nhóm AB hay BA:

$$SS_w = (5.0 - 7.50)^2 + (7.5 - 7.50)^2 + (9.0 - 7.50)^2 + \dots \\ + (8.0 - 7.50)^2 + (6.0 - 7.5625)^2 + (7.5 - 7.5625)^2 \\ + (9.0 - 7.5625)^2 + \dots + (11.0 - 7.5625)^2 = 103.44$$

- Tổng bình phương cho toàn bộ mẫu:
 $SS_{total} = (6 - 7.5312)^2 + (9 - 7.5312)^2 + \dots + (13 - 7.5312)^2 + (9 - 7.5312)^2 \\ = 167.97$
- Tổng bình phương còn lại (tức phần dư):
 $SS_{res} = 167.97 - 16.53 - 0.781 - 0.031 - 103.44 = 47.19$

Đến đây, chúng ta có thể lập bảng phân tích phương sai như sau:

Bảng 9. Kết quả phân tích phương sai số liệu trong bảng 11.7

NGUỒN BIẾN THIÊN	BẬC TỰ DO (DEGREES OF FREEDOM)	TỔNG BÌNH PHƯƠNG (SUM OF SQUARES)	TRUNG BÌNH BÌNH PHƯƠNG (MEAN SQUARE)	KIỂM ĐỊNH F
Giữa hai nhóm điều trị	1	16.53	16.53	4.90
Giữa hai tháng	1	0.781	0.781	0.23
Giữa AB và BA	1	0.031	0.031	0.004
Trong mỗi nhóm	14	103.44	7.39	
Phần dư (residual)	14	47.19	3.37	
Tổng số	31	167.97		

Qua phân tích trên, chúng ta thấy độ khác biệt giữa thuốc và giả dược lớn hơn là độ khác biệt giữa hai tháng hay hai nhóm AB và BA. Kiểm định F để thử nghiệm giả thiết thuốc và giả dược có hiệu quả như nhau là kiểm định $F = 16.53 / 3.37 = 4.90$ với bậc tự do 1 và 14. Dựa trên lí thuyết xác suất, trị số F với bậc tự do 1 và 14 là 4.60. Do đó, chúng ta có thể kết luận rằng thuốc này có hiệu ứng làm ra mồ hôi lâu hơn nhóm giả dược.

Tất cả các tính toán “thủ công” trên chỉ là minh họa cho cách phân tích phương sai trong thí nghiệm giao chéo. Trong thực tế, chúng ta có thể sử dụng R để tiến hành các tính toán đó như cách tính phương sai cho các thí nghiệm đơn giản. Vấn đề chính là tổ chức số liệu cho phân tích. R (cũng như nhiều

phần mềm khác) yêu cầu người sử dụng phải nhập từng số liệu một, và **mỗi số liệu phải gắn liền với một bệnh nhân, một nhóm điều trị, một tháng (hay giai đoạn), và một nhóm thứ tự**. Đó là một yêu cầu rất quan trọng, vì nếu tổ chức số liệu không đúng, kết quả phân tích có thể sai.

Phần sau đây sẽ mô tả từng bước một:

bước 1: nhập dữ liệu và đặt tên object là y

```
> y <- c(6,8,12,7,9,6,11,8,  
        4,7,6,8,10,4,6,8,  
        5,9,7,4,9,5,8,9,  
        7,6,11,7,8,4,9,13)
```

bước 2: cứ mỗi số liệu trong bước 1, chỉ ra nhóm AB hay BA (mã số 1 và 2)

```
> seq <- c(1,1,1,1,1,1,1,1,  
          1,1,1,1,1,1,1,1,  
          2,2,2,2,2,2,2,2,  
          2,2,2,2,2,2,2,2)
```

```
> seq <- as.factor(seq)
```

bước 3: cứ mỗi số liệu trong bước 1, chỉ ra tháng 1 hay tháng 2

```
> period <- c(1,1,1,1,1,1,1,1,  
             2,2,2,2,2,2,2,2,  
             2,2,2,2,2,2,2,2,  
             1,1,1,1,1,1,1,1)
```

```
> period <- as.factor(period)
```

bước 4: cứ mỗi số liệu trong bước 1, chỉ ra nhóm A hay placebo bằng mã số 1 và 2:

```
> treat <- c(1,1,1,1,1,1,1,1,  
            2,2,2,2,2,2,2,2,  
            1,1,1,1,1,1,1,1,  
            2,2,2,2,2,2,2,2)
```

```
> treat <- as.factor(treat)
```

bước 5: cứ mỗi số liệu trong bước 1, chỉ ra mã số cho từng bệnh nhân

```
> id <- c(1,3,5,6,9,10,13,15,  
         1,3,5,6,9,10,13,15,  
         2,4,7,8,11,12,14,16,  
         2,4,7,8,11,12,14,16)
```

```
> id <- as.factor(id)
```

bước 6: lập thành một data frame tên là data và in ra để kiểm tra một lần nữa.

```
> data <- data.frame(seq, period, treat, id, y)
```

```
> data
```

	seq	period	treat	id	y
1	1	1	1	1	6
2	1	1	1	3	8
3	1	1	1	5	12
4	1	1	1	6	7
5	1	1	1	9	9
6	1	1	1	10	6
7	1	1	1	13	11
8	1	1	1	15	8
9	1	2	2	1	4
10	1	2	2	3	7
11	1	2	2	5	6
12	1	2	2	6	8
13	1	2	2	9	10
14	1	2	2	10	4
15	1	2	2	13	6
16	1	2	2	15	8
17	2	2	1	2	7
18	2	2	1	4	6
19	2	2	1	7	11
20	2	2	1	8	7
21	2	2	1	11	8
22	2	2	1	12	4
23	2	2	1	14	9
24	2	2	1	16	13
25	2	1	2	2	5
26	2	1	2	4	9
27	2	1	2	7	7
28	2	1	2	8	4
29	2	1	2	11	9
30	2	1	2	12	5
31	2	1	2	14	8
32	2	1	2	16	9

Bây giờ chúng ta đã sẵn sàng dùng hàm `lm` của R để phân tích số liệu. Chú ý rằng cách dùng hàm `lm` cho phân tích phương sai áp dụng cho thí nghiệm giao chéo hoàn toàn không khác gì với cách dùng cho các thí nghiệm khác. Khía cạnh khác biệt duy nhất là cách tổ chức dữ liệu cho phân tích như trình bày trên.

```
> xover <- lm(y ~ treat+seq+period)
> anova(xover)
```

Analysis of Variance Table

Response: y

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
treat	1	16.531	16.531	4.9046	0.04388 *
seq	1	0.031	0.031	0.0093	0.92466
period	1	0.781	0.781	0.2318	0.63764
id	14	103.438	7.388	2.1921	0.07711 .
Residuals	14	47.187	3.371		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Kết quả phân tích trên đây dĩ nhiên giống với cách tính thủ công mà chúng ta đã tiến hành ở phần trên. Nói tóm lại, mức độ khác biệt giữa thuốc và giả dược có ý nghĩa thống kê, với trị số F là 0.044.

Chúng ta cũng có thể yêu cầu khoảng tin cậy 95% cho độ khác biệt giữa hai nhóm (bằng cách lệnh TukeyHSD) như sau (chú ý là với TukeyHSD chúng ta chỉ sử dụng hàm aov chứ không phải lm):

```
> TukeyHSD(aov(y ~ treat+seq+period+id))
Tukey multiple comparisons of means
95% family-wise confidence level
```

Fit: aov(formula = y ~ treat + seq + period + id)

\$treat

	diff	lwr	upr	p adj
2-1	-1.4375	-2.829658	-0.04534186	0.0438783

\$seq

	diff	lwr	upr	p adj
2-1	0.0625	-1.329658	1.454658	0.924656

\$period

	diff	lwr	upr	p adj
2-1	-0.3125	-1.704658	1.079658	0.6376395

Chú ý kết quả:

\$treat

diff lwr upr p adj

2-1 -1.4375 -2.829658 -0.04534186 0.0438783

cho biết tính trung bình thời gian ra mồ hôi của nhóm được điều trị cao hơn nhóm giả được khoảng 1.44 phút, và khoảng tin cậy 95% là từ 0.05 phút đến 2.8 phút. Còn các kết quả so sánh giữa hai nhóm AB và BA (seq) hay giữa tháng 1 và tháng 2 (period) không có ý nghĩa thống kê.

11.9 Phân tích phương sai cho thí nghiệm tái đo lường (repeated measure experiment)

Ví dụ 7: Một nghiên cứu sơ khởi (pilot study) được tiến hành để đánh giá hiệu nghiệm của một vắc-xin mới chống bệnh thấp khớp. Nghiên cứu gồm 8 bệnh nhân, được chia thành 2 nhóm một cách ngẫu nhiên. Nhóm 1 gồm 4 bệnh nhân được điều trị bằng vắc-xin; nhóm 2 cũng gồm 4 bệnh nhân nhưng được nhận giả dược (placebo, hay đối chứng). Bệnh nhân được theo dõi trong 3 tháng, và cứ mỗi tháng, bệnh nhân được hỏi về tình trạng của bệnh ra sao. Tình trạng bệnh được “đo lường” bằng một chỉ số có giá trị từ 0 (không có hiệu nghiệm, bệnh vẫn như trước) đến 10 (có hiệu nghiệm tuyệt đối, hết bệnh). Kết quả nghiên cứu có thể tóm tắt trong bảng số liệu sau đây:

Bảng 10. Kết quả nghiên cứu vắc-xin chống đau thấp khớp

NHÓM	MÃ SỐ BỆNH NHÂN (ID)	CHỈ SỐ BỆNH QUA TỪNG THÁNG		
		THÁNG 1	THÁNG 2	THÁNG 3
Vắc-xin				
	1	6	3	0
	2	7	3	1
	3	4	1	2
	4	8	4	3
Placebo				
	5	6	5	5
	6	9	4	6
	7	5	3	4
	8	6	2	3

Câu hỏi chính là có sự khác biệt nào giữa hai nhóm vắc-xin và giả dược hay không?

Để đơn giản hóa cách phân tích phương sai cho thí nghiệm tái đo lường, chúng ta sẽ tránh dùng kí hiệu toán, mà chỉ minh họa bằng vài phép tính “thủ công” để bạn đọc có thể theo dõi. Trước hết, chúng ta cần phải tóm lược số liệu bằng cách tính trung bình cho mỗi bệnh nhân, mỗi nhóm điều trị, và mỗi tháng như sau:

Bảng 11. Tóm lược số liệu nghiên cứu vắc-xin chống đau thấp khớp

NHÓM ĐIỀU TRỊ	ID	CHỈ SỐ BỆNH QUA TỪNG THÁNG			TRUNG BÌNH
		1	2	3	
Vắc-xin	1	6	3	0	3.000
	2	7	3	1	3.667
	3	4	1	2	2.333
	4	8	4	3	5.000
	Trung bình	6.25	2.75	1.50	3.500
	SD	1.71	1.26	1.29	
Placebo	5	6	5	5	5.333
	6	9	4	6	6.333
	7	5	3	4	4.000
	8	6	2	3	3.667
	Trung bình	6.50	3.50	4.50	4.833
	SD	1.73	1.29	1.29	
Trung bình cho hai nhóm		6.375	3.125	3.000	4.167

Qua bảng trên, chúng ta có thể thấy rằng có 5 nguồn làm cho kết quả thí nghiệm khác nhau:

- a. Giữa vắc-xin và giả dược (có lẽ là nguồn mà chúng ta cần biết!);
- b. Giữa 3 tháng theo dõi;
- c. Giữa ba tháng trong mỗi nhóm điều trị, mà giới thống kê thường đề cập đến là “interaction” (tương tác), và trong trường hợp này, tương tác giữa nhóm điều trị và thời gian;
- d. Giữa các bệnh nhân trong cùng một nhóm điều trị;
- e. Và sau cùng là phần dư, tức phần mà chúng ta không thể “giải thích” sau khi xem xét các nguồn (a) đến (d) trên.
- Trước hết là tổng bình phương giữa hai nhóm điều trị (vắc-xin và giả dược), tôi sẽ gọi là *SStreat*:

$$SStreat = 12(3.500 - 4.167)^2 + 12(4.833 - 4.167)^2 = 10.667$$

- Kế đến là tổng bình phương giữa 3 tháng điều trị, gọi là SS_{time} :

$$SS_{time} = 8(6.375 - 4.167)^2 + 8(3.125 - 4.167)^2 + 8(3.000 - 4.167)^2 \\ = 58.583$$

- Nguồn thứ ba là tổng bình phương do tương tác giữa điều trị và thời gian, gọi là SS_{int}

$$SS_{int} = 4(6.25 - 4.167)^2 + 4(2.75 - 4.167)^2 \\ + 4(1.50 - 4.167)^2 + 4(6.50 - 4.167)^2 \\ + 4(3.50 - 4.167)^2 + 4(4.50 - 4.167)^2 \\ - SS_{vaccine} - SS_{time} \\ = 77.833 - 10.667 - 58.583 = 8.583$$

- Nguồn thứ tư là tổng bình phương do tương tác giữa bệnh nhân trong mỗi nhóm điều trị, gọi là $SS_{patient}(treat)$:

$$SS_{patient}(treat) = 3(3.000 - 3.350)^2 + 3(3.667 - 3.350)^2 \\ + 3(2.333 - 3.350)^2 + 3(5.000 - 3.350)^2 \\ + 3(5.333 - 4.833)^2 + 3(6.333 - 4.833)^2 \\ + 3(4.000 - 4.833)^2 + 3(3.667 - 4.833)^2 \\ = 25.333$$

- Ngoài ra, tổng bình phương cho toàn mẫu là:

$$SS_{total} = (6 - 4.167)^2 + (3 - 4.167)^2 + (0 - 4.167)^2 + \dots + (3 - 4.167)^2 \\ = 115.333$$

- Từ đó, chúng ta có thể ước tính tổng bình phương cho phần dư:

$$SSE = SS_{total} - SS_{vaccine} - SS_{time} - SS_{patient}(vaccine) - SS_{vaccine-time} \\ = 115.333 - 10.667 - 58.583 - 25.333 - 8.583 \\ = 12.167$$

Tất cả các tính toán thủ công trên, như bạn đọc có thể thấy, khá phức tạp, và rất dễ sai sót. Nhưng trong R, chúng ta có thể có kết quả nhanh chóng. Sau đây, sẽ trình bày cách phân tích phương sai tái đo lường bằng R:

Chúng ta có thể lập bảng phân tích phương sai như sau:

NGUỒN BIẾN THIÊN	BẬC TỰ DO (DEGREES OF FREEDOM)	TỔNG BÌNH PHƯƠNG (SUM OF SQUARES)	TRUNG BÌNH BÌNH PHƯƠNG (MEAN SQUARE)	KIỂM ĐỊNH F
Giữa vắc xin và placebo	1	10.667	10.667	2.53
Bệnh nhân (nhóm điều trị)	6	25.333	4.222	-
Giữa 3 tháng	2	58.583	29.292	28.89
Thời gian và nhóm điều trị	2	8.583	4.292	4.23
Phần dư (residual)	12	12.167	1.014	-
Tổng số	23	115.333		

- Trước hết, chúng ta nhập dữ liệu cho từng bệnh nhân. Cũng như bất cứ phần mềm thống kê nào, mỗi giá trị phải được kèm theo những biến số đặc trưng như cho mỗi bệnh nhân, mỗi nhóm, và mỗi thời gian:

```
y <- c(6,7,4,8,
       3,3,1,4,
       0,1,2,3,
       6,9,5,6,
       5,4,3,2,
       5,6,4,3)
```

- Trong mỗi số liệu trên, cho R biết thuộc nhóm điều trị (mã số 1) hay giả dược (mã số 2). Cũng nên cho R biết `treat` là một biến thứ bậc (categorical variable) chứ không phải biến số (numerical variable):

```
treat <- c(1,1,1,1,
           1,1,1,1,
           1,1,1,1,
           2,2,2,2,
           2,2,2,2,
           2,2,2,2)

treat <- as.factor(treat)
```

- Trong mỗi số liệu trên, cho R biết thuộc tháng nào (mã số 1, 2, 3), và định nghĩa `time` là một biến thứ bậc.

```
time <- c(1,1,1,1,
          2,2,2,2,
          3,3,3,3,
          1,1,1,1,
          2,2,2,2,
          3,3,3,3)

time <- as.factor(time)
```

- Trong mỗi số liệu trên, cho R biết thuộc bệnh nhân nào (mã số 1, 2, 3, ..., 8), và định nghĩa `id` là một biến thứ bậc.

```
id <- c(1,2,3,4, 1,2,3,4, 1,2,3,4, 5,6,7,8, 5,6,7,8,
5,6,7,8)
```

```
id <- as.factor(id)
```

- Nhập tất cả biến vào một data frame và đặt tên là `data`. Kiểm tra một lần nữa xem số liệu đã đúng với ý định sắp xếp hay chưa. Xin nhắc lại, trước khi phân tích số liệu, việc quan trọng là phải kiểm tra lại cho thật kĩ số liệu để đảm bảo số liệu đã được tổ chức đúng và thích hợp.

```
data <- data.frame(id, time, treat, y)
```

```
data
```

	id	time	treat	y
1	1	1	1	6
2	2	1	1	7
3	3	1	1	4
4	4	1	1	8
5	1	2	1	3
6	2	2	1	3
7	3	2	1	1
8	4	2	1	4
9	1	3	1	0
10	2	3	1	1
11	3	3	1	2
12	4	3	1	3
13	5	1	2	6
14	6	1	2	9
15	7	1	2	5
16	8	1	2	6
17	5	2	2	5
18	6	2	2	4
19	7	2	2	3
20	8	2	2	2
21	5	3	2	5
22	6	3	2	6
23	7	3	2	4
24	8	3	2	3

Bây giờ, chúng ta đã sẵn sàng sử dụng R để phân tích. Hàm chính để phân tích phương sai là `aov` (analysis of variance). Trong hàm này, chú ý cách cung cấp thông số bằng cách dùng một hàm khác có tên là `Error`. Trong hàm `Error`, chúng ta cho R biết rằng mỗi bệnh nhân (`id`) “thuộc” vào một nhóm điều trị và do đó thuộc vào biến `time`. Cách để cho R biết là: `Error(id/time)`. Cụ thể hơn:

```
> repeated <- aov(y ~ treat*time + Error(id/time))
```

Lệnh trên đây yêu cầu R phân tích theo mô hình: `y = treat + time + treat*time` (chú ý `treat*time` tương đương với `treat+time+treat*time`), và trung bình bình phương phần dư phải được tách thành hai phần: một phần trong các bệnh nhân, và một phần giữa các tháng điều trị (viết tắt bằng kí hiệu `id/time`). Tất cả kết quả cho vào đối tượng có tên là `repeated`. Chúng ta yêu cầu một bảng tóm lược kết quả từ đối tượng `repeated`:

```
> summary(repeated)
```

Error: id

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
treat	1	10.6667	10.6667	2.5263	0.1631
Residuals	6	25.3333	4.2222		

Error: id:time

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
time	2	58.583	29.292	28.8904	2.586e-05 ***
treat:time	2	8.583	4.292	4.2329	0.04064 *
Residuals	12	12.167	1.014		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Kết quả phân tích trong phần đầu của bảng trên cho thấy sự khác biệt giữa nhóm điều trị bằng thuốc và giả dược không có ý nghĩa thống kê ($p = 0.16$). Như vậy chúng ta có thể kết luận thuốc không có hiệu nghiệm giảm đau thấp khớp?

Câu trả lời là “không”, bởi vì phần thứ hai của bảng phân tích phương sai cho thấy mối tương tác giữa `treat` và `time` (trị số $p = 0.041$). Điều này có nghĩa là độ khác biệt giữa thuốc và giả dược tùy thuộc vào tháng điều trị. Thật vậy, nếu chúng ta xem lại bảng 10.11 sẽ thấy trong tháng 1, trung bình của

nhóm vắc-xin và giả dược không mấy khác nhau (6.25 và 6.50), nhưng đến tháng thứ 2 và nhất là tháng thứ 3 thì độ khác biệt giữa hai nhóm rất cao (như tháng thứ ba: 1.50 cho vắc-xin và 4.50 cho nhóm giả dược). Như vậy, độ hiệu nghiệm trong nhóm được điều trị tăng dần theo thời gian, còn trong nhóm giả dược thì hầu như không có khác biệt giữa 3 tháng. Tóm lại, qua thí nghiệm sơ khởi này chúng ta có thể nói vắc-xin có vẻ có hiệu quả giảm đau trong các bệnh nhân thấp khớp.

* * *

Trên đây là vài cách sử dụng cho việc phân tích phương sai với các thí nghiệm thông dụng. Thiết kế và phân tích thí nghiệm (experimental design) là một lĩnh vực nghiên cứu tương đối chuyên sâu, những chỉ dẫn trên đây không thể mô tả tất cả các phép tính cũng như phương pháp cho tất cả thí nghiệm. Tuy nhiên, trong thực tế, các phương pháp và thí nghiệm rất thường được áp dụng trong khoa học thực nghiệm. R có một package tên là `nlme` (non-linear mixed-effects) cũng có thể sử dụng cho các phân tích trên và các mô hình phức tạp hơn với đa biến và đa thứ bậc. Package này cũng có thể tải về máy miễn phí tại website của R: <http://cran.R-project.org>.

12

Phân tích hồi qui logistic

Trong các chương trước về phân tích hồi qui tuyến tính và phân tích phương sai, chúng ta tìm mô hình và mối liên hệ giữa một biến phụ thuộc liên tục (continuous dependent variable) và một hay nhiều biến độc lập (independent variable) hoặc là liên tục hoặc là không liên tục. Nhưng trong nhiều trường hợp, biến phụ thuộc không phải là biến liên tục mà là biến mang tính đo lường nhị phân: có/không, mắc bệnh/không mắc bệnh, chết/sống, xảy ra/không xảy ra, v.v..., còn các biến độc lập có thể là liên tục hay không liên tục. Chúng ta cũng muốn tìm hiểu mối liên hệ giữa các biến độc lập và biến phụ thuộc.

Ví dụ 1: Trong một nghiên cứu do tác giả tiến hành để tìm hiểu mối liên hệ giữa nguy cơ gãy xương (fracture, viết tắt là fx) và mật độ xương cùng một số chỉ số sinh hóa khác, 139 bệnh nhân nam (hay nói đúng hơn là đối tượng nghiên cứu) tuổi từ 60 trở lên. Năm 1990, các số liệu sau đây được thu thập cho mỗi đối tượng: độ tuổi (age), tỉ trọng cơ thể (body mass index hay BMI), mật độ chất khoáng trong xương (bone mineral density hay BMD), chỉ số hủy xương ICTP, chỉ số tạo xương PINP. Các đối tượng nghiên cứu được theo dõi trong vòng 15 năm. Trong thời gian theo dõi, các bệnh nhân bị gãy xương hay không gãy xương được ghi nhận. Câu hỏi đặt ra ban đầu là có một mối liên hệ gì giữa BMD và nguy cơ gãy xương hay không. Số liệu của nghiên cứu này được trình bày trong phần cuối của chương này, và sẽ trình bày một phần dưới đây để bạn đọc nắm được vấn đề.

Bảng 1. Một phần số liệu nghiên cứu về các yếu tố nguy cơ gây gãy xương

id	fx	age	bmi	bmd	ictp	pinp
1	1	79	24.7252	0.818	9.170	37.383
2	1	89	25.9909	0.871	7.561	24.685
3	1	70	25.3934	1.358	5.347	40.620
4	1	88	23.2254	0.714	7.354	56.782
5	1	85	24.6097	0.748	6.760	58.358
6	0	68	25.0762	0.935	4.939	67.123
7	0	70	19.8839	1.040	4.321	26.399
8	0	69	25.0593	1.002	4.212	47.515
9	0	74	25.6544	0.987	5.605	26.132
10	0	79	19.9594	0.863	5.204	60.267
...						
137	0	64	38.0762	1.086	5.043	32.835
138	1	80	23.3887	0.875	4.086	23.837
139	0	67	25.9455	0.983	4.328	71.334

Ở đây, vì biến phụ thuộc (gãy xương) không được đo lường theo tính liên tục (mà chỉ là *có* hay *không*), cho nên phương pháp phân tích hồi qui tuyến tính để phân tích mối liên hệ giữa biến phụ thuộc và biến độc lập. Một phương pháp phân tích được phát triển tương đối gần đây (vào thập niên 1970s) có tên là logistic regression analysis (hay phân tích hồi qui logistic) có thể áp dụng cho trường hợp trên.

Trong nghiên cứu này, sau 15 năm theo dõi, có 38 bệnh nhân bị gãy xương. Tính theo phần trăm, tỉ lệ gãy xương là $38 / 139 = 0.273$ (hay 27.3%).

12.1 Mô hình hồi qui logistic

Cho một tần số biến cố x ghi nhận từ n đối tượng, chúng ta có thể tính xác suất của biến cố đó là:

$$p = \frac{x}{n}$$


p có thể xem là một chỉ số đo lường nguy cơ của một biến cố. Một cách thể hiện nguy cơ khác là *odds*, tạm dịch là *khả năng*. Khả năng của một biến cố được định nghĩa đơn giản bằng tỉ số xác suất biến cố xảy ra trên xác suất biến cố không xảy ra:

$$odds = \frac{p}{1-p} \quad [1]$$

Hàm *logit* của *odds* được định nghĩa như sau:

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right) \quad [2]$$

Mối liên hệ giữa p và $\text{logit}(p)$ là một mối liên hệ liên tục và theo dạng như sau:



Biểu đồ 1. Mối liên hệ giữa $\text{logit}(p)$ và p , cho $0 < p < 1$.

Chú ý: biểu đồ trên được vẽ bằng các lệnh sau đây:

```
p <- seq(0, 1, length=100)
p <- p[2:(length(p)-1)]
logit <- function(t)
{
  log(t / (1-t))
}
plot(logit(p) ~ p, type="l")
```

Cho một biến độc lập x (x có thể là liên tục hay không liên tục), mô hình hồi qui logistic phát biểu rằng:

$$\text{logit}(p) = \alpha + \beta x \quad [3]$$

Tương tự như mô hình hồi qui tuyến tính, α và β là hai thông số tuyến tính cần phải ước tính từ dữ liệu nghiên cứu. Nhưng ý nghĩa của thông số này, đặc biệt là thông số β , rất khác với ý nghĩa mà ta đã quen với mô hình hồi qui tuyến tính. Để hiểu ý nghĩa của hai thông số này, chúng ta sẽ quay lại với ví dụ 1.

Ví dụ 1 (tiếp theo): Vấn đề mà chúng ta muốn biết là mối liên hệ giữa mật độ xương bmd và nguy cơ gãy xương (x). Để tiện cho việc minh họa, gọi bmd là x , vấn đề mà chúng ta cần biết có thể viết bằng ngôn ngữ mô hình như sau

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right) = \alpha + \beta x \quad [4]$$

Nói cách khác:

$$\text{odds}(p) = \frac{p}{1-p} = e^{\alpha + \beta x}$$

Mô hình hồi qui logistic vừa trình bày trên phát biểu rằng mối liên hệ giữa xác suất gãy xương (p) và mật độ xương bmd là một mối liên hệ theo hình chữ S. Mô hình trên còn cho thấy xác suất gãy xương p tùy thuộc vào giá trị của x . Do đó, mô hình trên có thể viết một cách chính xác hơn rằng *khả năng* gãy xương với điều kiện x là:

$$\text{odds}(p|x) = e^{\alpha + \beta x}$$

Khi $x = x_0$, khả năng gãy xương là: $\text{odds}(p|x = x_0) = e^{\alpha + \beta x_0}$

Khi $x = x_0 + 1$ (tức tăng 1 đơn vị từ x_0), khả năng gãy xương là:

$$\text{odds}(p|x = x_0 + 1) = e^{\alpha + \beta(x_0 + 1)}$$

Và, tỉ số của hai xác suất gãy xương:

$$\frac{\text{odds}(p|x = x_0 + 1)}{\text{odds}(p|x = x_0)} = \frac{e^{\alpha + \beta(x_0 + 1)}}{e^{\alpha + \beta x_0}} = e^{\beta} \quad [5]$$

Trong dịch tễ học, e^{β} được gọi là *odds ratio*, tạm dịch là *tỉ số khả năng* hay *tỉ số khả dĩ*. Nói cách khác, hệ số β trong mô hình hồi qui logistic chính là tỉ số khả dĩ.

Phương pháp để ước tính thông số trong mô hình [3] khá phức tạp (dùng phương pháp maximum likelihood - tức phương pháp *Hợp lí cực đại*) và không nằm trong phạm vi của cuốn sách này, nên sẽ không trình bày ở đây (bạn đọc có thể tham khảo sách giáo khoa để biết thêm, nếu cần thiết). Tuy nhiên, có lẽ cần để cập một cách ngắn gọn là phương pháp hợp lí cực đại cung cấp cho chúng ta một hệ phương trình như sau:

$$\begin{cases} \sum_{i=1}^n y_i = \sum_{i=1}^n \left(1 + e^{-(\hat{\alpha} + \hat{\beta}x_i)}\right)^{-1} \\ \sum_{i=1}^n x_i y_i = \sum_{i=1}^n x_i \left(1 + e^{-(\hat{\alpha} + \hat{\beta}x_i)}\right)^{-1} \end{cases}$$

Trong đó, y_i là biến phụ thuộc (gãy xương với giá trị 0 hay 1), và x_i là biến độc lập (mật độ xương), và n là số mẫu. Để tìm ước số $\hat{\alpha}$ và $\hat{\beta}$, một trong những phép tính hay sử dụng là iterative weighted least square hay Newton-Raphson. R sử dụng phép tính Newton-Raphson để tìm hai ước số đó.

Sau khi đã có ước số $\hat{\alpha}$ và $\hat{\beta}$ chúng ta có thể ước tính xác suất p cho bất cứ giá trị nào của x như sau (sau vài thao tác đại số):

$$\hat{p} = \frac{e^{\hat{\alpha} + \hat{\beta}x}}{1 + e^{\hat{\alpha} + \hat{\beta}x}} = \frac{1}{1 + e^{-(\hat{\alpha} + \hat{\beta}x)}}$$

Chú ý chúng ta dùng dấu mũ $\hat{p}$ để chỉ số ước tính (predicted value), chứ không phải p là xác suất quan sát. Nếu mô hình mô tả dữ liệu tốt và đầy đủ, độ khác biệt giữa p và $\hat{p}$ nhỏ; nếu mô hình không thích hợp hay không tốt, độ khác biệt đó có thể sẽ cao. Độ khác biệt giữa p và $\hat{p}$ được gọi là *deviance*. Phương pháp tính deviance khá phức tạp, nhưng đó không phải là chủ đề ở đây, cho nên chúng ta chỉ nói qua khái niệm mà thôi. Khi chúng ta có nhiều mô hình để mô phỏng một hay nhiều mối liên hệ, deviance có thể được sử dụng để đánh giá sự thích hợp của một mô hình, hay để chọn một mô hình “tối ưu”.

12.2 Phân tích hồi qui logistic bằng R

Ví dụ 1 (tiếp theo): Bây giờ, chúng ta quay lại với ví dụ 1, dùng số liệu trong Bảng 12.1 để ước tính hai thông số α và β bằng R. Trước hết chúng ta phải nhập toàn bộ số liệu vào một data frame, và cho một cái tên, chẳng hạn như *fracture*. Trong trường hợp của ví dụ này, dữ liệu được chứa trong directory `c:\works\stats` dưới tên `fracture.txt`, do đó, các lệnh sau đây cần thiết để nhập số liệu:

```
# báo cho R biết nơi chứa số liệu
> setwd("c:/works/stats")

# nhập số liệu và cho vào một data frame tên fracture
> fracture <- read.table("fracture.txt", header=TRUE,
na.string=".")

# kiểm tra xem có bao nhiêu biến trong dữ liệu fracture
> names(fracture)
[1] "id" "fx" "age" "bmi" "bmd" "ictp" "pinp"

# Chọn những bệnh nhân có đầy đủ số liệu cho phân tích
> fulldata <- na.omit(fracture)
> attach(fulldata)
```


Hai biến mà chúng ta quan tâm trong ví dụ này là: fx (gãy xương) và bmd (mật độ xương). Chúng ta kiểm tra xem có bao nhiêu bệnh nhân gãy xương:

```
> table(fx)
fx
 0  1
101 38
```

Kế đến, xem mật độ xương trong nhóm gãy xương và không gãy xương ra sao:

```
> tapply(bmd, fx, mean)
      0      1
0.9444851 0.9016667
```

```
> boxplot(bmd ~ fx, xlab="Fracture: 1=yes, 0=no)", ylab="BMD")
```



Kết quả trên cho thấy, bmd trong nhóm bệnh nhân bị gãy xương thấp hơn so với nhóm không bị gãy xương (0.90 và 0.94). Và, kiểm định t sau đây cho thấy mức độ khác biệt này không có ý nghĩa thống kê ($p = 0.15$).

```
> t.test(bmd~fx)
```

```
Welch Two Sample t-test
```

```
data: bmd by fx
```

```
t = 1.4572, df = 53.952, p-value = 0.1508
```

```
alternative hypothesis: true difference in means is not  
equal to 0
```

```
95 percent confidence interval:
```

```
-0.01609226 0.10172922
```

```
sample estimates:
```

```
mean in group 0 mean in group 1
```

```
0.9444851 0.9016667
```

Để ước tính thông số trong mô hình [4], hàm số glm (viết tắt từ *generalized linear model*) trong R có thể áp dụng, với “cú pháp” như sau:

```
> logistic <- glm(fx ~ bmd, family="binomial")  
> summary(logistic)
```

```
Call:
```

```
glm(formula = fx ~ bmd, family = "binomial")
```

```
Deviance Residuals:
```

```
Min      1Q  Median      3Q      Max  
-1.0287 -0.8242 -0.7020  1.3780  2.0709
```

```
Coefficients:
```

```
Estimate Std. Error z value Pr(>|z|)  
(Intercept)  1.063    1.342   0.792   0.428  
bmd          -2.270    1.455  -1.560   0.119
```

```
(Dispersion parameter for binomial family taken to be 1)
```

```
Null deviance: 157.81 on 136 degrees of freedom  
Residual deviance: 155.27 on 135 degrees of freedom  
AIC: 159.27
```

```
Number of Fisher Scoring iterations: 4
```

Chúng ta sẽ lần lượt xem qua các kết quả trên:

- a. Trong lệnh `logistic <- glm(fx~bmd, family="binomial")` chúng ta yêu cầu R phân tích theo mô hình fx là một hàm số với bmd như mô hình [4]. Trong `glm` có nhiều luật phân phối, mà trong đó phân phối nhị phân (binomial) là một luật phân phối chuẩn cho hồi qui logistic. Do đó, `family="binomial"` cần thiết cho R.
- b. Deviance: phần thứ nhất của kết quả cho biết qua về deviance:

Deviance Residuals:

Min	1Q	Median	3Q	Max
-1.0287	-0.8242	-0.7020	1.3780	2.0709

Deviance như giải thích trên phản ánh độ khác biệt về giá trị quan sát và ước tính của $\text{logit}(p)$ (hay giữa mô hình và dữ liệu, cũng tương tự như *mean square residual* trong phân tích hồi qui tuyến tính vậy). Đối với một mô hình đơn lẻ như ví dụ này thì giá trị của deviance không có ý nghĩa gì nhiều.

- a. Phần kế tiếp cung cấp ước số của $\hat{\alpha}$ (mà R đặt tên là `intercept`) và $\hat{\beta}$ (`bmd`) và sai số chuẩn (standard error).

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	1.063	1.342	0.792	0.428
bmd	-2.270	1.455	-1.560	0.119

Qua kết quả này, chúng ta có $\hat{\alpha} = 1.063$ và $\hat{\beta} = -2.27$. Ước số $\hat{\beta}$ là số âm cho thấy mối liên hệ giữa nguy cơ gãy xương và bmd là mối liên hệ nghịch đảo: xác suất gãy xương tăng khi giá trị của bmd giảm. Tuy nhiên, kiểm định z (tính bằng cách lấy ước số chia cho sai số chuẩn) cho chúng ta thấy ảnh hưởng của bmd không có ý nghĩa thống kê, vì trị số $P = 0.119$.

Nhớ rằng tỉ số khả dĩ (odds ratio hay viết tắt là OR) chính là $e^{-2.27} = 0.1033$. Nói cách khác, khi bmd tăng 1 g/cm^2 (đơn vị đo lường của bmd là g/cm^2) thì tỉ số OR giảm 0.9067 hay 90.67%. Nhưng tăng 1 g/cm^2 là mật độ rất cao trong xương và không thực tế. Cho nên một

cách tính khác là tính trên độ lệch chuẩn (standard deviation) của bmd. Chúng ta sẽ tìm hiểu độ lệch chuẩn của bmd:

```
> sd(bmd)
```

```
[1] 0.1406543
```

Do đó, OR sẽ tính trên mỗi 0.14 g/cm². Và OR cho mỗi độ lệch chuẩn, do đó, là:

$$e^{-2.27 \cdot 0.1406} = 0.7267$$

Tức là, khi bmd tăng một độ lệch chuẩn thì tỉ số khả dĩ gãy xương giảm khoảng 28%. Cũng có thể nói cách khác, là khi bmd *giảm* một độ lệch chuẩn thì tỉ số khả dĩ tăng $e^{2.27 \cdot 0.1406} = 1.376$ hay khoảng 38%.

Một cách khác để biết ảnh hưởng của bmd là ước tính xác suất gãy xương là qua phương trình:

$$\hat{p} = \frac{e^{1.063 - 2.27(bmd)}}{1 + e^{1.063 - 2.27(bmd)}}$$

Theo đó, khi bmd = 1.00, p = 0.23. Khi bmd = 0.86 (tức giảm 1 độ lệch chuẩn), p = 0.291. Tức là, nếu BMD giảm 1 độ lệch chuẩn thì xác suất gãy xương tăng $0.291/0.23 = 1.265$ hay 26.5%.

- b. Phần cuối của kết quả cung cấp deviance cho hai mô hình: mô hình không có biến độc lập (null deviance), và mô hình với biến độc lập, tức là bmd trong ví dụ (residual deviance).

Null deviance: 157.81 on 136 degrees of freedom

Residual deviance: 155.27 on 135 degrees of freedom

AIC: 159.27

Qua hai số này, chúng ta thấy bmd ảnh hưởng rất thấp đến việc tiên đoán gãy xương, chỉ làm giảm deviance từ 157.8 xuống còn 155.27, và mức độ giảm này không có ý nghĩa thống kê.

Ngoài ra, R còn cung cấp giá trị của AIC (Akaike Information Criterion) được tính từ deviance và bậc tự do. Chúng ta sẽ quay lại ý nghĩa của AIC trong phần sắp đến khi so sánh các mô hình.

12.3 Ước tính xác suất bằng R

Trong phân tích trên, chúng ta cho các kết quả vào đối tượng `logistic`. Trong đối tượng này có nhiều thông tin có ích, nhưng nếu muốn xem các thông tin này chúng ta phải dùng đến các lệnh như `summary` chẳng hạn. Trong phần này, chúng ta sẽ xem qua vài hàm trong R để lấy các thông tin liên quan đến việc tiên đoán xác suất.

- `predict` dùng để liệt kê các giá trị ước tính (predicted values) của mô hình $\log\left(\frac{p}{1-p}\right) = \alpha + \beta x$ cho từng bệnh nhân.

```
> predict(logistic)
```

1	2	3	4	5	6
2.37757	1.08569	-2.14111	1.49282	0.96537	-0.94125
7	8	9	10	11	12
-1.73368	-1.67564	-0.66528	-0.50704	-0.94185	-0.64874
...					

Các số trên là $\log(p / (1 - p))$, tức *log odds*, không có ý nghĩa thực tế bao nhiêu. Chúng ta muốn biết giá trị tiên đoán xác suất p tính từ phương trình

$$\hat{p} = \frac{e^{1.063 - 2.27(bmd)}}{1 + e^{1.063 - 2.27(bmd)}}. \text{ Để có giá trị này cho từng bệnh nhân, chúng ta cho thông}$$

số `type="response"` vào hàm `predict` như sau:


```
> predict(logistic, type="response")
```

1	2	3	4	5	6	7
0.915	0.747	0.105	0.816	0.724	0.281	0.150
8	9	10	11	12	13	14
0.158	0.339	0.376	0.281	0.343	0.443	0.238
...						

Trong kết quả trên (chỉ in một phần) ước tính xác suất gãy xương cho bệnh nhân 1 là 0.915, cho bệnh nhân 2 là 0.747, v.v...

- Chúng ta có thể xem xét các giá trị tiên đoán này với độ `bmd` bằng cách dùng hàm `plot` thông thường:

```
> plot(bmd, fitted(glm(fx ~ bmd, family="binomial")))
```




Xác suất tiên đoán gãy xương (trục tung) và độ bmd (trục hoành) qua mô hình hồi qui logistic.

Biểu đồ trên có thể cải tiến bằng cách cho các khoảng cách giá trị bmd gần nhau hơn (như 0.50, 0.55, 0.60, ..., 1.20 chẳng hạn), và dùng đường biểu diễn thay vì dùng dấu chấm. Các lệnh sau đây sẽ cải tiến biểu đồ.

```
> logistic <- glm(fx ~ bmd, family="binomial")

#cho fnbmd từ > 0.50, 0.55, 0.6, ..., 1.2
> fnbmd <- seq(0.5, 1.2, 0.05)

#cho vào một dataframe mới
> new.data <- data.frame(bmd = fnbmd)
> predicted <- predict(logistic, new.data, type="response")
> plot(predicted ~ fnbmd, type="l")
```



Xác suất tiên đoán gãy xương (trục tung) và độ bmd (trục hoành) qua mô hình hồi qui logistic.

12.4 Phân tích hồi qui logistic từ số liệu giản lược bằng R

Trong quá trình phân tích số liệu vừa trình bày trên đây, chúng ta có số liệu cho từng bệnh nhân và các biến độc lập đều là biến liên tục. Nhưng trong nhiều trường hợp biến độc lập là bậc thứ (và bởi vì biến phụ thuộc chỉ có hai giá trị 0 và 1) cho nên trên lý thuyết chúng ta có thể tóm lược dữ liệu bằng các bảng tần số (frequency table).

Ví dụ 2: Trong một nghiên cứu về ảnh hưởng của thói quen hút thuốc lá, tình trạng béo phì, thở ngáy (trong khi ngủ) đến nguy cơ bệnh cao huyết áp, các nhà nghiên cứu tóm lược số liệu như sau (số liệu trích từ Altman, trang 353):

smoking	obesity	snoring	ntotal	nhyper
0	0	0	60	5
1	0	0	17	2
0	1	0	8	1
1	1	0	2	0
0	0	1	187	35
1	0	1	85	13
0	1	1	51	15
1	1	1	23	8
Tổng số			433	79

Bảng 2. Tóm lược số liệu liên quan đến hút thuốc lá (smoking), béo phì (obesity), ngáy (snoring), và cao huyết áp. ntotal là tổng số bệnh nhân cho từng nhóm, và nhyper là số bệnh nhân trong tổng số bị bệnh cao huyết áp. Các biến số smoking, obesity, và snoring có giá trị 0=no và 1=yes.

Trong nghiên cứu có 433 bệnh nhân, và trong số này 79 người (hay 18%) bị bệnh cao huyết áp. Tuy nhiên, tỉ lệ này dao động khá cao theo từng nhóm bệnh nhân. Chẳng hạn như trong nhóm không hút thuốc lá (smoking=0), không béo phì (obesity=0) và không ngáy (snoring=0), tỉ lệ cao huyết áp là 8.3% (5/60). Trong khi đó nhóm với 3 yếu tố nguy cơ trên (smoking=1, obesity=1, snoring=1) thì có hơn 1 phần 3 hay 35% (8/23) bị bệnh cao huyết áp.

Để phân tích mối liên hệ giữa 3 yếu tố nguy cơ đó và bệnh cao huyết áp, trước hết cần phải cho số liệu vào R theo đúng như bảng số liệu trên.

```
> noyes <- c("no", "yes") #định nghĩa biến noyes có 2 giá trị
> smoking <- gl(2,1,8, noyes) #biến smoking
> obesity <- gl(2,2,8, noyes) #biến obesity
> snoring <- gl(2,4,8, noyes) #biến snoring
> ntotal <- c(60, 17, 8, 2, 187, 85, 51, 23)
> nhyper <- c(5, 2, 1, 0, 35, 13, 15, 8)
> data <- data.frame(smoking, obesity, snoring, ntotal, nhyper)
```

```
> data
  smoking obesity snoring ntotal nhyper
1    no     no     no      60      5
2   yes     no     no      17      2
3    no     yes     no       8      1
4   yes     yes     no       2      0
5    no     no     yes     187     35
6   yes     no     yes      85     13
7    no     yes     yes      51     15
8   yes     yes     yes      23      8
```

Bây giờ chúng ta có thể sử dụng hàm glm để phân tích số liệu. Trước hết, chúng ta phải tạo thêm một biến số proportion như sau:

```
> proportion <- nhyper/ntotal
> logistic <- glm(proportion ~ smoking+obesity+snoring,
family="binomial", weight=ntotal)
```

Chú ý trong hàm glm trên, chúng ta mô phỏng proportion như là một hàm số của smoking, obesity và snoring, vẫn với phân phối nhị phân (binomial), nhưng có thêm một thông số weight=ntotal. Thông số weight yêu cầu R sử dụng ntotal là một số tóm lược (thay vì một bệnh nhân). Bây giờ, chúng ta có thể xem qua kết quả phân tích:

```
> summary(logistic)
```

```
Call:
glm(formula = proportion ~ smoking + obesity + snoring,
family = "binomial", weights = ntotal)
```

```
Deviance Residuals:
    1      2      3      4      5      6      7      8
-0.04344  0.54145 -0.25476 -0.80051  0.19759 -0.46602
-0.21262  0.56231
```

```
Coefficients:
```

```
      Estimate Std. Error z value Pr(>|z|)
(Intercept) -2.37766   0.38018  -6.254  4e-10 ***
smokingyes   -0.06777   0.27812  -0.244  0.8075
obesityyes    0.69531   0.28509   2.439  0.0147 *
snoringyes    0.87194   0.39757   2.193  0.0283 *
```

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
(Dispersion parameter for binomial family taken to be 1)
```

```
Null deviance: 14.1259 on 7 degrees of freedom
Residual deviance: 1.6184 on 4 degrees of freedom
AIC: 34.537
```

```
Number of Fisher Scoring iterations: 4
```

Kết quả trên cho thấy biến smoking không có ý nghĩa thống kê; cho nên có lẽ chúng ta nên bỏ biến này ra ngoài mô hình và có một mô hình đơn giản hơn:

```
> logistic <- glm(proportion ~ obesity+snoring,
                    family="binomial", weight=ntotal)

> summary(logistic)

Call:
glm(formula = proportion ~ obesity + snoring,
    family = "binomial", weights = ntotal)

Deviance Residuals:
1       2       3       4       5       6
-0.01247  0.47756 -0.24050 -0.82050  0.30794 -0.62742
7       8
-0.14449  0.45770

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept) -2.3921    0.3757  -6.366 1.94e-10 ***
obesityyes   0.6954    0.2851   2.440  0.0147 *
snoringyes   0.8655    0.3967   2.182  0.0291 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 14.1259 on 7 degrees of freedom
Residual deviance: 1.6781 on 5 degrees of freedom
AIC: 32.597

Number of Fisher Scoring iterations: 4
```

Phân tích phương sai trên deviance sau đây cũng khẳng định obesity và snoring là hai biến có ảnh hưởng đến cao huyết áp:

```
> anova(logistic, test="Chisq")
Analysis of Deviance Table

Model: binomial, link: logit

Response: proportion

Terms added sequentially (first to last)

      Df Deviance Resid. Df Resid. Dev P(>|Chi|)
NULL              7   14.1259
obesity 1    6.8260      6    7.2999  0.0090
snoring 1    5.6218      5    1.6781  0.0177
```

12.5 Phân tích hồi qui logistic đa biến và chọn mô hình

Một trong những vấn đề khó khăn và có khi khá nan giải trong việc phân tích hồi qui logistic đa biến là chọn một mô hình để có thể mô tả đầy đủ dữ liệu. Một nghiên cứu với một biến phụ thuộc y và 3 biến độc lập x_1 , x_2 và x_3 , chúng ta có thể có những mô hình sau đây để tiên đoán y : $y = f(x_1)$, $y = f(x_2)$, $y = f(x_3)$, $y = f(x_1, x_2)$, $y = f(x_1, x_3)$, $y = f(x_2, x_3)$, và $y = f(x_1, x_2, x_3)$, trong đó f là hàm số. Nói chung với k biến độc lập $x_1, x_2, x_3, \dots, x_k$, chúng ta có rất nhiều mô hình (2^k) để tiên đoán y . Trong điều kiện có nhiều mô hình khả dĩ như thế, vấn đề đặt ra là mô hình nào được xem là tối ưu?

Câu hỏi trên đặt ra một câu hỏi cơ bản khác: thế nào là “tối ưu”? Nói một cách ngắn gọn một mô hình tối ưu phải đáp ứng ba tiêu chuẩn sau đây:

- Đơn giản
- Đầy đủ
- Có ý nghĩa thực tế

Tiêu chuẩn đơn giản đòi hỏi mô hình có ít biến số độc lập, vì nếu quá nhiều biến số thì vấn đề diễn dịch sẽ trở nên khó khăn, và có khi thiếu thực tế. Nói một cách ví von, nếu chúng ta bỏ ra 50.000 đồng để mua 500 trang sách tốt hơn là bỏ ra 60.000 ngàn để mua cùng số trang sách. Tương tự, một mô hình với 3 biến độc lập mà có khả năng mô tả dữ liệu tương đương với mô hình với 5 biến độc lập, thì mô hình đầu được chọn. Một mô hình đơn giản là một mô hình... tiết kiệm! (Tiếng Anh gọi là *parsimonious model*).

Tiêu chuẩn đầy đủ ở đây có nghĩa là mô hình đó phải mô tả dữ liệu một cách thỏa đáng, tức phải tiên đoán gần (hay càng gần càng tốt) với giá trị thực tế quan sát của biến phụ thuộc y . Nếu giá trị quan sát của y là 10, và nếu có một mô hình tiên đoán là 9 và một mô hình tiên đoán là 6 thì mô hình đầu phải được xem là đầy đủ hơn.

Tiêu chuẩn “có ý nghĩa thực tế”, như cách gọi, có nghĩa là mô hình đó phải được yểm trợ bằng lí thuyết hay có ý nghĩa sinh học (nếu là nghiên cứu sinh học), ý nghĩa lâm sàng (nếu là nghiên cứu lâm sàng), v.v... Có thể số điện thoại một cách nào đó có liên quan đến tỉ lệ gãy xương, nhưng tất nhiên một mô hình như thế hoàn toàn vô nghĩa. Đây là một tiêu chuẩn quan trọng, bởi vì nếu một phân tích thống kê dẫn đến một mô hình dù rất có ý nghĩa toán học mà không có ý nghĩa thực tế thì mô hình đó cũng chỉ là một trò chơi con số, không có giá trị khoa học thật sự.

Tiêu chuẩn thứ ba (có ý nghĩa thực tế) thuộc về lĩnh vực lý thuyết, và chúng ta sẽ không bàn ở đây. Chúng ta sẽ bàn qua tiêu chuẩn đơn giản và đầy đủ. Một thước đo quan trọng và có ích để chúng ta quyết định một mô hình đơn giản và đầy đủ là Akaike Information Criterion (AIC) mà chúng ta đã gặp trong phần đầu của chương này. Để hiểu AIC, chúng ta quay lại với ví dụ 1.

Xin nhắc lại trong ví dụ 1, chúng ta muốn tiên đoán gãy xương (biến fx) từ các biến độc lập sau đây: độ tuổi (age), tỉ số cơ thể (bmi), mật độ chất khoáng trong xương (bmd), và hai chỉ số hủy xương ($ictp$) và tạo xương ($pinp$).

(a) Chúng ta thử mô hình fx là hàm số của độ tuổi:

```
> attach(fulldata)
> summary(glm(fx ~ age, family="binomial", data=fulldata))
```

Coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
(Intercept) -8.06447    2.72559 -2.959 0.00309 **
age           0.09806    0.03766  2.604 0.00922 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

(Dispersion parameter for binomial family taken to be 1)

```
Null deviance: 157.81 on 136 degrees of freedom
Residual deviance: 150.74 on 135 degrees of freedom
AIC: 154.74
```

Chúng ta để ý thấy residual deviance = 150.74, và AIC = 154.74. Thật ra, AIC được ước tính từ công thức:

$$AIC = \text{Residual Deviance} + 2(\text{số thông số})$$

Trong mô hình trên, chúng ta có 2 thông số (intercept và age), cho nên $AIC = 150.74 + 4 = 154.74$.

(b) Mô hình thứ hai mà chúng ta muốn so sánh là fx là hàm số của $ictp$:

```
> summary(glm(fx ~ ictp, family="binomial", data=fulldata))
```

Coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
(Intercept) -3.9206     0.7726 -5.074 3.89e-07 ***
ictp          0.6066     0.1527  3.973 7.11e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
(Dispersion parameter for binomial family taken to be 1)
Null deviance: 157.81 on 136 degrees of freedom
Residual deviance: 139.15 on 135 degrees of freedom
AIC: 143.15
```

Cũng với hai thông số, nhưng mô hình này có giá trị residual deviance (139.15) nhỏ hơn mô hình với độ tuổi (150.74), và do đó AIC cũng thấp hơn (143.15 so với 154.74). Kết quả này cho thấy mô hình với *ictp* mô tả *fx* đầy đủ hơn là mô hình với độ tuổi. So sánh này cho thấy trong hai mô hình này, chúng ta sẽ chọn mô hình với *ictp*.

(c) Bây giờ chúng ta thử xem mô hình với *ictp* và *age*.

```
> summary(glm(fx ~ ictp + age, family="binomial",
data=fulldata))

(Intercept) -8.25707  2.91403 -2.834 0.004603 **
ictp         0.55461  0.15665  3.540 0.000399 ***
age          0.06398  0.04067  1.573 0.115701
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
(Dispersion parameter for binomial family taken to be 1)
```

```
Null deviance: 157.81 on 136 degrees of freedom
Residual deviance: 136.61 on 134 degrees of freedom
AIC: 142.61
```

Mô hình này với 3 thông số (*intercept*, *age* và *ictp*), nhưng trị số AIC chỉ giảm xuống 142.61 (so với mô hình với *ictp* là 143.15), một độ giảm rất khiêm tốn, trong khi chúng ta phải “tiêu” thêm một thông số! Chúng ta có thể kết luận rằng *age* không cần thiết trong mô hình này. Thật vậy, trị số *p* cho *age* là 0.115, tức không có ý nghĩa thống kê.

Qua ba trường hợp trên, chúng ta có thể rút ra một nhận xét chung: một mô hình đơn giản và đầy đủ phải là mô hình có trị số AIC càng thấp càng tốt và các biến độc lập phải có ý nghĩa thống kê. Thành ra, vấn đề đi tìm một mô hình đơn giản và đầy đủ là thật sự đi tìm một (hay nhiều) mô hình với trị số AIC thấp nhất hay gần thấp nhất.

Tất nhiên, chúng ta có thể xem xét nhiều mô hình khác bằng cách thay thế hay tổng hợp các biến số độc lập với nhau. Nhưng một việc làm như thế rất phức tạp, đòi hỏi nhiều thời gian và có khi rườm rà. R có một hàm gọi là *step* có thể giúp chúng ta đi tìm một mô hình đơn giản và đầy đủ. Trong ví dụ trên, cách sử dụng hàm *step* sẽ được viết như sau:

```
> temp <- glm(fx ~ ., family="binomial", data=fulldata)
```


Trong lệnh trên, thông số “fx ~ .” có nghĩa là tìm tất cả các biến độc lập (kí hiệu “.”) để tiên đoán fx trong dataframe fulldata. Kết quả cho vào đối tượng temp. Để xem kết quả trong temp, chúng ta lệnh search như sau:

```
> search <- step(temp)

> search <- step(temp)
Start: AIC= 146.09
fx ~ id + age + bmi + bmd + ictp + pinp
```

	Df	Deviance	AIC
- pinp	1	132.45	144.45
- id	1	132.47	144.47
- age	1	132.63	144.63
- bmi	1	133.41	145.41
- bmd	1	133.87	145.87
<none>		132.09	146.09
- ictp	1	148.90	160.90

```
Step: AIC= 144.45
fx ~ id + age + bmi + bmd + ictp
```

	Df	Deviance	AIC
- id	1	132.81	142.81
- age	1	133.14	143.14
- bmi	1	133.66	143.66
- bmd	1	134.00	144.00
<none>		132.45	144.45
- ictp	1	149.05	159.05

```
Step: AIC= 142.81
fx ~ age + bmi + bmd + ictp
```

	Df	Deviance	AIC
- age	1	133.32	141.32
- bmi	1	133.67	141.67
- bmd	1	134.33	142.33
<none>		132.81	142.81
- ictp	1	149.88	157.88

```
Step: AIC= 141.33
fx ~ bmi + bmd + ictp
```

	Df	Deviance	AIC
- bmi	1	134.34	140.34
<none>		133.32	141.32
- bmd	1	135.65	141.65
- ictp	1	155.18	161.18

```
Step: AIC= 140.34
fx ~ bmd + ictp
```

```
      Df Deviance   AIC
<none>      134.34 140.34
- bmd   1   139.15 143.15
- ictp  1   155.27 159.27
```

Trong kết quả trên, R báo cáo cho chúng ta biết từng bước trong quá trình đi tìm một mô hình tối ưu. Khởi đầu là mô hình với tất cả 6 biến, và trị số AIC = 146.09. Bước thứ hai chỉ gồm 5 biến (loại bỏ pinp) và AIC = 144.45, v.v... Kết quả có thể tóm lược trong bảng sau đây:

MÔ HÌNH	AIC
fx ~ id + age + bmi + bmd + ictp + pinp	146.09
fx ~ id + age + bmi + bmd + ictp	144.45
fx ~ age + bmi + bmd + ictp	142.81
fx ~ bmi + bmd + ictp	141.33
fx ~ bmd + ictp	140.34

Kết quả 5 bước tìm mô hình, R dừng lại với mô hình gồm 2 biến bmd và ictp vì có giá trị AIC thấp nhất. Thật ra, nếu không muốn in tất cả các bước đi tìm mô hình, chúng ta chỉ cần lệnh summary như sau:

```
> summary(search)
```

Call:

```
glm(formula = fx ~ bmd + ictp, family = "binomial",
data = fulldata)
```

Deviance Residuals:

```
      Min       1Q   Median       3Q      Max
-1.9126 -0.7317 -0.5559  0.4212  2.1242
```

Coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
(Intercept) -1.0651     1.5029  -0.709   0.4785
bmd          -3.4998     1.6638  -2.103   0.0354 *
ictp          0.6876     0.1704   4.036 5.43e-05 ***
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

(Dispersion parameter for binomial family taken to be 1)

```
Null deviance: 157.81 on 136 degrees of freedom
Residual deviance: 134.34 on 134 degrees of freedom
AIC: 140.34
```

```
Number of Fisher Scoring iterations: 4
```

Kết quả này đơn giản hơn kết quả của hàm `search`, vì `summary` chỉ trình bày mô hình sau cùng. Nói tóm lại, trong phân tích này, chúng ta kết luận rằng `bmd` (mật độ chất khoáng trong xương) và `ictp` (marker về chu trình hủy xương) là hai yếu tố có liên hệ hay ảnh hưởng đến nguy cơ gãy xương.

12.6 Chọn mô hình hồi qui logistic bằng Bayesian Model Average (BMA)

Trong chương 10, chúng ta đã xem qua cách chọn và xây dựng một mô hình hồi qui tuyến tính bằng ứng dụng phép tính BMA. Chúng ta cũng có thể ứng dụng BMA vào việc xây dựng một mô hình hồi qui logistic.

Tiếp tục ví dụ 1, chúng ta sẽ chuẩn bị dữ liệu cho phân tích BMA bằng cách chọn ra biến phụ thuộc (trong trường hợp này là `fx`) và một ma trận gồm các biến độc lập. Tiếp theo đó, chúng ta sử dụng hàm `bic.glm` để tìm các biến có ảnh hưởng đến `fx`.

```
> attach(fulldata)

> names(fulldata)
[1] "id" "fx" "age" "bmi" "bmd" "ictp" "pinp"
# Chọn cột 3 đến 7 (từ age đến pinp) làm ma trận biến độc lập
> xvars <- fulldata[,3:7]
# Chọn fx làm biến phụ thuộc
> y <- fx
# Gọi hàm bic.glm với các thông số như sau:
> bma.search <- bic.glm(xvars, y, strict=F, OR=20,
                        glm.family="binomial")
# Tóm lược kết quả phân tích:
> summary(bma.search)
```

```
Call: bic.glm.data.frame(x = xvars, y = y,
                        glm.family="binomial", strict=F, OR=20)
```

9 models were selected

Best 5 models (cumulative posterior probability = 0.8836):

	p!=0	EV	SD	model 1	model 2
Intercept	100	-2.85	2.865	-3.920	-1.065
age	15.3	0.008	0.026	.	.
bmi	21.7	-0.023	0.054	.	.
bmd	39.7	-1.341	1.976	.	-3.499

ictp	100.0	0.645	0.169	0.606	0.687
pinp	5.7	-0.0003	0.004	.	.


nVar		1	2
BIC		-525.04	-524.94
post prob		0.307	0.291

	model 3	model4	model 5
Intercept	-1.201	-8.257	-0.072
age	.	0.063	.
bmi	-0.116	.	-0.070
bmd	.	.	-2.696
ictp	0.680	0.554	0.714
pinp	.	.	.

nVar	2	2	3
BIC	-523.63	-522.67	-521.03
post prob	0.151	0.094	0.041

Kết quả phân tích trên đây cho thấy xác suất mà ictp là liên quan đến gãy xương là 100%, trong khi đó, xác suất cho bmd chỉ khoảng 40%. Nhưng quan trọng hơn, mô hình “tối ưu” nhất là mô hình với ictp, và xác suất cho mô hình này là 0.307. Mô hình tối ưu thứ hai gồm có ictp và bmd (cũng là mô hình dựa vào tiêu chuẩn AIC như mô tả phần trên), nhưng xác suất cho mô hình này tương đối thấp hơn (0.291). Ba mô hình khác cũng có thể là “ứng viên” để mô tả xác suất gãy xương đầy đủ. Rõ ràng, qua phân tích BMA, chúng ta có nhiều lựa chọn mô hình hơn, và ý thức được sự bất định của một mô hình thống kê.

```
> imageplot.bma(bma.search)
```



Biểu đồ trên thể hiện kết quả bằng số trong phần trước. Qua biểu đồ này chúng ta thấy *ictp* là yếu tố có ảnh hưởng đến nguy cơ gãy xương có tính nhất quán cao nhất (xuất hiện trong 100% mô hình). Yếu tố quan trọng thứ hai có lẽ là *bmd* hay *bmi*. Các yếu tố như *age* và *pinp* tuy có khả năng ảnh hưởng đến nguy cơ gãy xương, nhưng các yếu tố này không có độ nhất quán cao như các yếu tố vừa kể trên.

Xây dựng mô hình thống kê là một nghệ thuật. Vì tính nghệ thuật của việc làm, nhà nghiên cứu phải cân nhắc rất nhiều yếu tố để đi đến một mô hình đẹp. Bởi vì mô hình là nhằm mục đích mô tả thực tế, một mô hình đẹp là mô hình mô tả sát với thực tế. Tuy nhiên nếu một mô hình phản ánh 100% thực tế thì đó không còn là “mô hình” nữa, hay quá phức tạp không thể ứng dụng được. Ngược lại một mô hình chỉ mô tả thực tế khoảng 1% thì cũng không thể sử dụng được. Xây dựng mô hình phải làm sao tìm điểm cân bằng cho hai thái cực đó. Đó là một yêu cầu rất cao, cho nên xây dựng mô hình không chỉ tùy thuộc vào các phép tính thống kê, toán học, mà còn phải xem xét đến các yếu tố thực tế để bảo đảm cho sự hữu ích của mô hình. Nói như nhà thống kê học George Box: “*Mô hình nào cũng sai so với thực tế, nhưng trong số các mô hình sai đó, có một vài mô hình có ích*”.

Phụ chương: Mô hình hồi qui Poission

Số liệu sau đây phản ánh số ca mắc bệnh ung thư da ở phụ nữ thuộc “thành phố song sinh” Minneapolis – St Paul:

ĐỘ TUỔI	DÂN SỐ	SỐ TRƯỜNG HỢP UNG THƯ DA	TỈ LỆ PHÁT SINH TRÊN 1000 DÂN SỐ
15-24	1	172,675	0.0058
25-34	16	146,207	0.1094
35-44	30	121,374	0.2472
45-54	71	111,353	0.6376
55-64	102	83,004	1.2289
65-74	130	55,932	2.3243
75-84	133	29,007	4.5851
85+	40	7,538	5.3064

Dựa vào hai số liệu trên, chúng ta có thể ước tính tỉ lệ phát sinh (*incidence rate*) tính trên 1000 dân số, và tỉ lệ này được trình bày trong cột cuối cùng của bảng số liệu. Chúng ta dễ dàng thấy tỉ lệ phát sinh ung thư da tăng theo độ tuổi.

Chúng ta cần một mô hình để mô tả xu hướng trên, hay mối liên hệ giữa độ tuổi và tỉ lệ phát sinh. Ở đây, có một khó khăn là dân số khác nhau giữa các

độ tuổi, mà tỉ lệ thì tùy thuộc vào độ tuổi. Cho nên chúng ta cần một mô hình có thể điều chỉnh cho hai yếu tố này. Một mô hình thích hợp cho trường hợp này là mô hình hồi qui Poisson.

Gọi N_i là dân số của độ tuổi i^{th} , và gọi μ_i là số trường hợp ung thư da, chúng ta có thể xem tỉ số $\frac{\mu_i}{N_i}$ như là một tỉ lệ phát sinh bệnh. Bây giờ, để tiện cho việc tính toán, chúng ta hoán chuyển tỉ số này sang đơn vị logarithm:

$$\log\left(\frac{\mu_i}{N_i}\right) = \log(\mu_i) - \log(N_i) \quad [1]$$

Mô hình hồi qui Poisson phát biểu rằng log của tỉ lệ phát sinh, tức là $\log\left(\frac{\mu_i}{N_i}\right)$, là một hàm số của độ tuổi (và chúng ta kí hiệu độ tuổi bằng x). Nói cách khác, mô hình này phát biểu rằng:

$$\log\left(\frac{\mu_i}{N_i}\right) = \alpha + \beta x_i \quad [2]$$

Thay thế [1] vào vế trái của [2], chúng ta có:

$$\log(\mu_i) - \log(N_i) = \alpha + \beta x_i$$

hay nói cách khác:

$$\log(\mu_i) = \alpha + \beta x_i + \log(N_i) \quad [3]$$

Mô hình [3] chính là mô hình hồi qui Poisson. Cách diễn đạt mô hình theo công thức [3] cho phép chúng ta xây dựng một hàm số khả dĩ (likelihood function) để ước tính các thông số α và β . Trong mô hình trên, $\log(N_i)$ được gọi là *offset*, tức là “điểm nhấn”.

Chúng ta có thể sử dụng R để ước tính các thông số trong mô hình [3] như sau:

```
age = c(19.5, 29.5, 39.5, 49.5, 59.5, 69.5, 79.5, 89.4)
cases = c(1, 16, 30, 71, 102, 130, 133, 40)
pop = c(172675, 123065, 96216, 92051, 72159, 54722, 32185, 8328)
dataset = data.frame(age, cases, pop)
fit = glm(cases ~ age + offset(log(pop)),
family=poisson, data=dataset)
summary(fit)
```

Kết quả của phân tích là:

```
Deviance Residuals:
    Min       1Q   Median       3Q      Max
-4.87198 -1.67519 -0.07185  1.20816  1.99291

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept) -10.551604   0.168780  -62.52  <2e-16 ***
age          0.063629   0.002475   25.71  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 845.789  on 7  degrees of freedom
Residual deviance:  44.288  on 6  degrees of freedom
AIC: 91.688

Number of Fisher Scoring iterations: 5
```

Chúng ta chỉ chú ý đến thông số intercept và age. Thay thế các thông số này vào mô hình [3] chúng ta có:

$$\log(\mu_i) = -10.552 + 0.064x_i + \log(N_i) \text{ trong đó, } x \text{ là độ tuổi.}$$

Cũng có thể viết mô hình trên thành tỉ lệ phát sinh (thay vì log của tỉ lệ) như sau:

$$\frac{\mu_i}{N_i} = e^{-10.552 + 0.064x}$$

Nếu tuổi là 19.5 ($x = 19.5$), chúng ta có thể ước tính tỉ lệ phát sinh là:

$$\frac{\mu_i}{N_i} = e^{-10.552 + 0.064 \times 19.5} = 0.0000904$$

Nếu tuổi là 29.5, tỉ lệ phát sinh là:

$$\frac{\mu_i}{N_i} = e^{-10.552 + 0.064 \times 29.5} = 0.000171$$

Tỉ số của hai tỉ lệ phát sinh này là: $0.000171 / 0.0000904 = 1.89$. Nói cách khác, tỉ lệ phát sinh tăng gấp 1.89 lần cho mỗi 10 tuổi tăng. Con số 1.89 này còn có tên là *relative risk* hay *tỉ số nguy cơ tương đối*.

Thật ra, chúng ta có thể ước tính ngay từ ước số của R:

```
Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept) -10.551604   0.168780  -62.52  <2e-16 ***
age          0.063629   0.002475   25.71  <2e-16 ***
```

Trong phần trên, $\beta = 0.0636$ có nghĩa là cứ mỗi một tuổi tăng thì tỉ số nguy cơ tương đối tăng $e^{0.0636} = 1.065$ (hay tăng 6.5%). Do đó, khi tăng 10 tuổi thì nguy cơ tương đối mắc bệnh tăng $e^{0.0636 \times 10} = 1.89$, hay 89%.

13

Phân tích sống còn (event history hay survival analysis)

Qua ba chương trước, chúng ta đã làm quen với các mô hình thống kê cho các biến phụ thuộc liên tục (như áp suất máu) và biến bậc thứ (như có/không, bệnh hay không bệnh). Trong nghiên cứu khoa học, và đặc biệt là y học và kỹ thuật, có khi nhà nghiên cứu muốn tìm hiểu ảnh hưởng đến các biến phụ thuộc mang tính thời gian. Nhà kinh tế học John Maynard Keynes từng nói một câu có liên quan đến chủ đề mà tôi sẽ mô tả trong chương này như sau: “Về lâu về dài tất cả chúng ta đều chết, cái khác nhau là chết sớm hay chết muộn mà thôi.” Thành ra, ở đây việc theo dõi hay mô tả một biến bậc thứ như sống hay chết tuy quan trọng, nhưng... không chính xác. Cái biến số quan trọng hơn và chính xác hơn là thời gian dẫn đến việc sự kiện xảy ra.

Trong các nghiên cứu khoa học, kể cả nghiên cứu lâm sàng, các nhà nghiên cứu thường theo dõi đối tượng trong một thời gian, có khi lên đến vài mươi năm. Biến cố xảy ra trong thời gian đó như có bệnh hay không có bệnh, sống hay chết, v.v... là những biến cố có ý nghĩa lâm sàng nhất định, nhưng thời gian dẫn đến bệnh nhân mắc bệnh hay chết còn quan trọng hơn cho việc đánh giá ảnh hưởng của một thuật điều trị hay một yếu tố nguy cơ. Nhưng thời gian này khác nhau giữa các bệnh nhân. Chẳng hạn như thời điểm từ lúc điều trị ung thư đến thời điểm bệnh nhân chết rất khác nhau giữa các bệnh nhân, và độ khác biệt đó có thể tùy thuộc vào các yếu tố như độ tuổi, giới tính, tình trạng bệnh, và các yếu tố mà có khi chúng ta không/chưa đo lường được như tương tác giữa các gen.

Mô hình chính để thể hiện mối liên hệ giữa thời gian dẫn đến bệnh (hay không bệnh) và các yếu tố nguy cơ (risk factors) là mô hình có tên là “survival

analysis” (có thể tạm dịch là *phân tích sống sót*). Cụm từ “survival analysis” xuất phát từ nghiên cứu trong bảo hiểm, và giới nghiên cứu y khoa từ đó dùng cụm từ cho bộ môn của mình. Nhưng như nói trên, sống/chết không phải là biến duy nhất, vì trong thực tế chúng ta cũng có những biến như có bệnh hay không bệnh, xảy ra hay không xảy ra, và do đó, trong giới tâm lý học, người ta dùng cụm từ “event history analysis” (phân tích biến cố) mà người viết cảm thấy có vẻ thích hợp hơn là *phân tích sống sót*. Ngoài ra, trong các bộ môn kỹ thuật, người ta dùng một cụm từ khác, *reliability analysis* (phân tích độ tin cậy), để chỉ cho khái niệm *survival analysis*. Tuy nhiên, trong chương này tôi sẽ dùng cụm từ *phân tích biến cố*.

13.1 Mô hình phân tích số liệu mang tính thời gian

Ví dụ 1: Thời gian dẫn đến ngưng sử dụng IUD. Một nghiên cứu về hiệu quả của một y cụ ngừa thai trên 18 phụ nữ, tuổi từ 18 đến 35. Một số phụ nữ ngưng sử dụng y cụ vì bị chảy máu. Còn số khác thì tiếp tục sử dụng. Bảng số liệu sau đây là thời gian (tính bằng tuần) kể từ lúc bắt đầu sử dụng y cụ đến khi chảy máu (tức ngưng sử dụng) hay đến khi kết thúc nghiên cứu (tức vẫn còn sử dụng đến khi chấm dứt nghiên cứu).

Bảng 1. Thời gian dẫn đến ngưng sử dụng hay tiếp tục sử dụng y cụ IUD

MÃ SỐ BỆNH NHÂN	THỜI GIAN (TUẦN)	TÌNH TRẠNG (NGỪNG=1 HAY TIẾP TỤC=0)
1	18	0
2	10	1
3	13	0
4	30	1
5	19	1
6	23	0
7	38	0
8	54	0
9	36	1
10	107	1
11	104	0
12	97	1
13	107	0
14	56	0
15	59	1
16	107	0
17	75	1
18	93	1

Câu hỏi đặt ra là mô tả thời gian ngưng sử dụng y cụ. Thuật ngữ “mô tả” ở đây có nghĩa là ước tính số trung vị thời gian dẫn đến ngưng sử dụng, hay xác suất mà phụ nữ ngưng sử dụng vào một thời điểm nào đó. Tình trạng tiếp tục sử dụng có khi gọi là “survival” (tức “sống sót”).

Để giải quyết vấn đề trên, đối với những phụ nữ đã ngưng sử dụng vấn đề ước tính thời gian không phải là khó. Nhưng vấn đề quan trọng trong dữ liệu mang tính thời gian này là một số phụ nữ vẫn còn tiếp tục sử dụng, bởi vì chúng ta không biết họ còn sử dụng bao lâu nữa, trong khi nghiên cứu phải “đóng sỏ” theo một thời điểm định trước. Những trường hợp đó được gọi bằng một thuật ngữ khó hiểu là “censored” hay “survival” (tức còn sống, hay còn tiếp tục sử dụng, hay biến cố chưa xảy ra).

Gọi T là thời gian còn tiếp tục sử dụng (có khi gọi là *survival time*). T là một biến ngẫu nhiên, với hàm mật độ (probability density distribution) $f(t)$, và hàm phân phối tích lũy (cumulative distribution) là:

$$F(t) = \int_{-\infty}^t f(s) ds$$

Đây là xác suất mà một cá nhân ngưng sử dụng (hay kinh qua biến cố) tại thời điểm t . Hàm bổ sung $S(t) = 1 - F(t)$ thường được gọi là hàm “sống sót” (survival function).

Số liệu thời gian T thường được mô phỏng bằng hai hàm xác suất: hàm sống sót và hàm nguy cơ (*hazard function*). Hàm sống sót như định nghĩa trên là xác suất một cá nhân còn “sống sót” (hay trong ví dụ trên, còn sử dụng y cụ) đến một thời điểm t . Hàm nguy cơ, thường được viết bằng kí hiệu $h(t)$ hay $\lambda(t)$ là xác suất mà cá nhân đó ngưng sử dụng (hay xảy ra biến cố) ngay tại thời điểm t .

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{\Pr[(t \leq T < t + \Delta t) | T \geq t]}{\Delta t} = \frac{f(t)}{S(t)}$$

sao cho $h(t) \delta t$ là xác suất một cá nhân ngưng sử dụng trong khoảng thời gian ngắn δt với điều kiện cá nhân đó sống đến thời điểm t . Từ mối liên hệ:

$$\Pr(\text{sống sót đến } t + \delta t) = \Pr(\text{sống sót đến } t) \cdot \Pr(\text{sống sót đến } \delta t | \text{sống đến } t)$$

chúng ta có:

$$1 - F(t + \delta t) = (1 - F(t)) \times (1 - h(t) \delta t)$$

Từ đó, chúng ta có:

$$\delta t F'(t) = (1 - F(t))h(t) \delta t$$

Suy ra, hàm nguy cơ là:
$$h(t) = \frac{f(t)}{1 - F(t)}$$

Và hàm nguy cơ tích lũy:

$$\Lambda(t) = \int_{-\infty}^t \lambda(u) du$$

Từ định nghĩa hàm nguy cơ $-h(t) = \frac{-f(t)}{1 - F(t)}$, chúng ta có thể viết:

$$\Lambda(t) = -\log(1 - F(t))$$

Một số hàm nguy cơ có thể ứng dụng để mô tả thời gian này. Hàm đơn giản nhất là một hằng số, dẫn đến một mô hình Poisson (thuộc nhóm các luật phân phối mũ):

$$f(t) = \lambda e^{-\lambda t} \quad (t \geq 0)$$

Do đó:

$$F(t) = 1 - e^{-\lambda t}$$

Cho nên:
$$h(t) = \lambda$$

Những lý thuyết trên đây thoạt đầu mới xem qua có vẻ tương đối rắc rối, nhưng với số liệu thực tế thì sẽ dễ theo dõi hơn. Bây giờ chúng ta quay lại với số liệu từ **Ví dụ 1**. Để tiện việc theo dõi và tính toán, chúng ta cần phải sắp xếp lại dữ liệu trên theo thứ tự thời gian, bất kể đó là thời gian ngưng sử dụng hay còn tiếp tục sử dụng:

10 13* 18* 19 23* 30 36 38* 54*
56* 59 75 93 97 104* 107 107* 107*

Trong dãy số liệu trên dấu “*” là để đánh dấu thời gian censored (tức còn tiếp tục sử dụng IUD). Cách đơn giản nhất là chia thời gian từ 10 tuần (ngắn nhất) đến 107 tuần (lâu nhất) thành nhiều khoảng thời gian như trong bảng phân tích sau đây:

Bảng 2. Ước tính xác suất tích lũy cho mỗi khoảng thời gian

MỐC THỜI GIAN (t)	KHOẢNG THỜI GIAN (TUẦN)	SỐ PHỤ NỮ LÚC BẮT ĐẦU THỜI ĐIỂM (N_i)	SỐ PHỤ NỮ NGỪNG SỬ DỤNG (D_i)	XÁC SUẤT NGỪNG SỬ DỤNG $H(t)$	XÁC SUẤT CÒN SỬ DỤNG P_i	XÁC SUẤT TÍCH LŨY $S(t)$
1	0 – 9	18	0	0.0000	1.0000	1.0000
2	10 – 18	18	1	0.0555	0.9445	0.9445
3	19 – 29	15	1	0.0667	0.9333	0.8815
4	30 – 35	13	1	0.0769	0.9231	0.8137
5	36 – 58	12	1	0.0833	0.9167	0.7459
6	59 – 74	8	1	0.1250	0.8750	0.6526
7	75 – 92	7	1	0.1428	0.8572	0.5594
8	93 – 96	6	1	0.1667	0.8333	0.4662
9	97 – 106	5	1	0.2000	0.8000	0.3729
10	107 –	3	1	0.3333	0.6667	0.2486

Trong bảng tính toán trên, chúng ta có:

- Cột thứ nhất là mốc thời gian (tạm kí hiệu là t). Cột này không có ý nghĩa gì, ngoại trừ sử dụng để làm chỉ số;
- Cột thứ 2 là khoảng thời gian (duration) tính bằng tuần. Như đề cập trên, chúng ta chia thời gian thành nhiều khoảng để tính toán, chẳng hạn như từ 0 đến 9 tuần, 10 đến 18 tuần, v.v... Chú ý rằng trong thực tế, chúng ta không có số liệu cho thời gian từ 0 đến 9 tuần, nhưng khoảng thời gian này đặt ra để làm cái mốc khởi đầu để thuận tiện cho việc ước tính sau này. Đây chỉ là những phân chia tương đối tùy tiện và chỉ có tính cách minh họa; trong thực tế máy tính có thể làm việc đó cho chúng ta;
- Cột thứ 3 là số đối tượng nghiên cứu n_i (hay cụ thể hơn là số phụ nữ trong nghiên cứu này) *bắt đầu* một khoảng thời gian. Chẳng hạn như khoảng thời gian 0-9, tại thời điểm bắt đầu 0, có 18 phụ nữ (hay cũng có thể hiểu rằng số phụ nữ được theo dõi/quan sát ít nhất 0 tuần là 18 người).

Trong khoảng thời gian 10-18, ngay tại thời điểm bắt đầu 10, chúng ta có 18 phụ nữ; nhưng trong khoảng thời gian 19-29, ngay tại thời điểm bắt đầu 19, chúng ta có 15 phụ nữ (cụ thể là: 19 23* 30 36 38* 54* 56* 59 75 93 97 104* 107 107* 107*); v.v...

Nói cách khác, cột này thể hiện số đối tượng với thời gian quan sát tối thiểu là t . Do đó, trong khoảng thời gian 97 – 106, chúng ta có 5 phụ nữ với thời gian theo dõi từ 97 tuần trở lên (97 104* 107 107* 107*).

- Cột thứ 4 trình bày số phụ nữ ngưng sử dụng y cụ d_i (hay biến cố xảy ra) trong một *khoảng thời gian*. Chẳng hạn như trong khoảng thời gian 10 - 18 tuần, có một phụ nữ ngưng sử dụng (tại 10 tuần); trong khoảng thời gian 19 - 29 tuần cũng có một trường hợp ngưng sử dụng (tại 19 tuần), v.v...
- Cột thứ 5 là xác suất nguy cơ $h(t)$ trong một khoảng thời gian. Một cách đơn giản, $h(t)$ được ước tính bằng cách lấy d_i chia cho n_i . Ví dụ trong khoảng thời gian 10-18 có 1 phụ nữ ngưng sử dụng (trong số 18 phụ nữ), và xác suất nguy cơ là $1/18 = 0.0555$. Xác suất này được ước tính cho từng khoảng thời gian.
- Cột thứ 6 là xác suất còn sử dụng cho một khoảng thời gian, tức lấy 1 trừ cho $h(t)$ trong cột thứ 5. Xác suất này không cung cấp nhiều thông tin, nhưng chỉ được trình bày để dễ theo dõi tính toán trong cột kế tiếp.
- Cột thứ 7 là xác suất tích lũy còn sử dụng y cụ $S(t)$ (hay cumulative survival probability). Đây là cột số liệu quan trọng nhất cho phân tích. Vì tính chất “tích lũy”, cho nên cách ước tính được nhân từ hai hay nhiều xác suất.

Trong khoảng thời gian 0-9, xác suất tích lũy chính là xác suất còn sử dụng trong cột 6 (vì không có ai ngưng sử dụng).

Trong khoảng thời gian 10-18, xác suất tích lũy được ước tính bằng cách lấy xác suất còn sử dụng trong thời gian 0-9 nhân cho xác suất còn sử dụng trong thời gian 10-18, tức là: $1.000 \times 0.9445 = 0.9445$. Ý nghĩa của ước tính này là: xác suất còn sử dụng cho đến thời gian 9 tuần là 94.45%.

Tương tự, trong khoảng thời gian 19-29 tuần, xác suất tích lũy còn sử dụng được tính bằng cách lấy xác suất tích lũy còn sử dụng đến tuần 10-18 nhân cho xác suất còn sử dụng trong khoảng thời gian 19-29: $0.9445 \times 0.9333 = 0.8815$. Tức là, xác suất còn sử dụng đến tuần 29 là 88.15%.

Nói chung, công thức ước tính $S(t)$ là $\hat{S}(t) = \prod_{i=1}^k \left(\frac{n_i - d_i}{n_i} \right)$. Chú ý dấu mũ “^” trên $S(t)$ là để nhắc nhở rằng đó là ước số. Nếu gọi xác suất còn sử dụng trong khoảng thời gian t là p_i (tức cột 6), thì $S(t)$ cũng có thể tính bằng công thức: $\hat{S}(t) = \prod_{i=1}^k p_i$.

Phép ước tính được mô tả trên thường được gọi là *ước tính Kaplan-Meier* (Kaplan-Meier estimates), hay thỉnh thoảng cũng được gọi là *product-limit estimate*.

13.2 Ước tính Kaplan-Meier bằng R

Tất cả các tính toán trên, tất nhiên, có thể được tiến hành bằng R. Trong R có một package tên là `survival` (do Terry Therneau và Thomas Lumley phát triển) có thể ứng dụng để phân tích biến cố. Trong phần sau đây chúng ta sẽ từng bước sử dụng package này.

Quay lại với Ví dụ 1, việc đầu tiên mà chúng ta cần làm là nhập dữ liệu vào R. Nhưng trước hết, chúng ta phải nhập package `survival` vào môi trường làm việc:

```
> library(survival)
```

Kế đến, chúng ta tạo ra hai biến số: biến thứ nhất gồm thời gian (hãy gọi là `weeks` cho trường hợp này), và biến thứ hai là chỉ số cho biết đối tượng ngưng sử dụng y cụ (cho giá trị 1) hay còn tiếp tục sử dụng (cho giá trị 0) và đặt tên biến này là `status`. Sau đó nhập hai biến vào một `dataframe` (và gọi là `data`) để tiện việc phân tích.

```
> weeks <- c(10, 13, 18, 19, 23, 30, 36, 38, 54, 56, 59,
75, 93, 97, 104, 107, 107, 107)
> status <- c(1, 0, 0, 1, 0, 1, 1, 0, 0, 0, 1, 1, 1, 1,
0, 1, 0, 0)
> data <- data.frame(weeks, status)
```

Bây giờ, chúng ta đã sẵn sàng phân tích. Để ước tính Kaplan-Meier, chúng ta sẽ sử dụng hai hàm `Surv` và `survfit` trong package `survival`. Hàm `Surv` dùng để tạo ra một biến số hợp (combined variable) với thời gian và tình trạng. Ví dụ, trong lệnh sau đây:

```
> survtime <- Surv(weeks, status==1)
> survtime
[1] 10 13+ 18+ 19 23+ 30 36 38+ 54+ 56+ 59 75 93 97
[15] 104+ 107 107+ 107+
```

Chúng ta sẽ có `survtime` là một biến với thời gian và dấu “+” (chỉ còn sống sót, hay censored observation, hay trong trường hợp này là còn sử dụng y cụ). Biến số này chỉ có giá trị và ý nghĩa cho phân tích của R, chứ trong thực tế, có lẽ chúng ta không cần nó.

Còn hàm `survfit` cũng khá đơn giản, chúng ta chỉ cần cung cấp hai thông số: thời gian và chỉ số như ví dụ sau đây:

```
> survfit(Surv(weeks, status==1))
```

Hay nếu đã có object `survtime` thì chúng ta chỉ đơn giản “gọi”:

```
> survfit(survtime)
```

```
Call: survfit(formula = survtime)
```

```

n events median 0.95LCL 0.95UCL
18      9    93    59    Inf

```

Kết quả trên đây chẳng có gì hấp dẫn, vì nó cung cấp những thông tin mà chúng ta đã biết: có 9 biến cố (ngưng sử dụng y cụ) trong số 18 đối tượng. Thời gian (median - trung vị) ngưng sử dụng là 93 tuần, với khoảng tin cậy 95% từ 59 tuần đến vô cực (`Inf = infinity`). Để có thêm kết quả chúng ta cần phải đưa kết quả phân tích vào một object chẳng hạn như `kp` và dùng hàm `summary` để biết thêm chi tiết:

```
> kp <- survfit(Surv(weeks, status==1) ~ 1)
```

```
> summary(kp)
```

```
Call: survfit(formula = Surv(weeks, status == 1) ~ 1)
```

```

time n.risk n.event survival std.err lower 95% CI upper 95% CI
10    18     1  0.944 0.0540    0.844    1.000
19    15     1  0.881 0.0790    0.739    1.000
30    13     1  0.814 0.0978    0.643    1.000
36    12     1  0.746 0.1107    0.558    0.998
59     8     1  0.653 0.1303    0.441    0.965
75     7     1  0.559 0.1412    0.341    0.917
93     6     1  0.466 0.1452    0.253    0.858
97     5     1  0.373 0.1430    0.176    0.791
107    3     1  0.249 0.1392    0.083    0.745

```

Một phần của kết quả này (cột `time`, `n.risk`, `n.event`, `survival`) chúng ta đã tính toán “thủ công” trong bảng trên. Tuy nhiên R còn cung cấp cho chúng ta sai số chuẩn (standard error) của $S(t)$ và khoảng tin cậy 95%.

Khoảng tin cậy 95% được ước tính từ công thức:


$$\hat{S}(t) \pm 1.96 \times se[\hat{S}(t)],$$

mà trong đó:

$$se[\hat{S}(t)] = \hat{S}(t) \times \left\{ \sum_{i=1}^k \frac{d_i}{n_i(n_i - d_i)} \right\}.$$

Công thức sai số chuẩn này còn được gọi là *công thức Greenwood* (hay *Greenwood's formula*). Chúng ta có thể thể hiện kết quả trên bằng một biểu đồ bằng hàm `plot` như sau:

```
> plot(kp, xlab="Time (weeks)",
      ylab="Cumulative survival probability")
```



Trong biểu đồ trên, trục hoành là thời gian (tính bằng tuần) và trục tung là xác suất tích lũy còn sử dụng y cụ. Đường chính giữa chính là xác suất tích lũy $\hat{S}(t)$, hai đường chấm là khoảng tin cậy 95% của $\hat{S}(t)$. Qua kết quả phân tích này, chúng ta có thể phát biểu rằng xác suất sử dụng y cụ đến tuần 107 là khoảng 25% và khoảng tin cậy từ 8% đến 74.5%. Khoảng tin cậy khá rộng cho biết ước số có độ dao động cao, đơn giản vì số lượng đối tượng nghiên cứu còn tương đối thấp.

13.3 So sánh hai hàm xác suất tích lũy: kiểm định log-rank (log-rank test)

Phân tích trên chỉ áp dụng cho một nhóm đối tượng, và mục đích chính là ước tính $S(t)$ cho từng khoảng thời gian. Trong thực tế, nhiều nghiên cứu có mục đích so sánh $S(t)$ giữa hai hay nhiều nhóm khác nhau. Chẳng hạn như trong các nghiên cứu lâm sàng, nhất là nghiên cứu chữa trị ung thư, các nhà nghiên cứu thường so sánh thời gian sống sót giữa hai nhóm bệnh nhân để đánh giá mức độ hiệu nghiệm của một thuật điều trị.

Ví dụ 2: Một nghiên cứu trên 48 bệnh nhân với bệnh mụn giộp (herpes) ở bộ phận sinh dục nhằm xét nghiệm hiệu quả của một loại vắc-xin mới (tạm gọi bằng mã danh gd2). Bệnh nhân được chia thành 2 nhóm một cách ngẫu nhiên: nhóm 1 được điều trị bằng gd2 (gồm 25 người), và 23 người còn lại trong nhóm hai nhận giả dược (placebo). Tình trạng bệnh được theo dõi trong vòng 12 tháng. Bảng số liệu sau đây trình bày thời gian (tính bằng tuần và gọi tắt là *time*) đến khi bệnh tái phát. Ngoài ra, mỗi bệnh nhân còn cung cấp số liệu về số lần bị nhiễm trong vòng 12 tháng trước khi tham gia công trình nghiên cứu (*episodes*). Theo kinh nghiệm lâm sàng, *episodes* có liên hệ mật thiết đến xác suất bị nhiễm (và chúng ta sẽ quay lại với cách phân tích biến số này trong một phần sau). Câu hỏi đặt ra là gd2 có hiệu nghiệm làm giảm nguy cơ bệnh tái phát hay không.

Bảng 3. Thời gian đến nhiễm trùng ở bệnh nhân với bệnh mụn giộp cho nhóm gd2 và giả dược

id	episodes	time	infected	id	episodes	time	infected
1	12	8	1	2	9	15	1
3	10	12	0	4	10	44	0
6	7	52	0	5	12	2	0
7	10	28	1	9	7	8	1
8	6	44	1	11	7	12	1
10	8	14	1	13	7	52	0
12	8	3	1	16	7	21	1
14	9	52	1	17	11	19	1
15	11	35	1	19	16	6	1
18	13	6	1	21	16	10	1
20	7	12	1	22	6	15	0
23	13	7	0	25	15	4	1
24	9	52	0	27	9	9	0
26	12	52	0	29	10	27	1
28	13	36	1	30	17	1	1
31	8	52	0	32	8	12	1
33	10	9	1	35	8	20	1
34	16	11	0	37	8	32	0
36	6	52	0	38	8	15	1
39	14	15	1	41	14	5	1
40	13	13	1	43	13	35	1
42	13	21	1	45	9	28	1
44	16	24	0	47	15	6	1
46	13	52	0				
48	9	28	1				

Chú thích: trong biến *infected* (nhiễm), 1 có nghĩa là bị nhiễm, và 0 là không bị nhiễm.

Trong trường hợp trên chúng ta có hai nhóm để so sánh. Một cách phân tích đơn giản là ước tính $S(t)$ cho từng nhóm và từng khoảng thời gian, rồi so sánh hai nhóm bằng một kiểm định thống kê thích hợp. Song, phương pháp phân tích này có nhược điểm là nó không cung cấp cho chúng ta một “bức tranh” chung của tất cả các khoảng thời gian. Ngoài ra, vấn đề so sánh giữa hai nhóm trong nhiều khoảng thời gian khác nhau làm cho kết quả rất khó diễn dịch.

Để khắc phục hai nhược điểm so sánh trên, một phương pháp phân tích được phát triển có tên là log-rank test (kiểm định log-rank). Đây là một phương pháp phân tích phi thông số để kiểm định giả thiết rằng hai nhóm có cùng $S(t)$. Phương pháp này cũng chia thời gian ra thành k khoảng thời gian, $t_1, t_2, t_3, \dots, t_k$, mà khoảng thời gian t_j ($j = 1, 2, 3, \dots, k$) phản ánh thời điểm j khi một hay nhiều đối tượng của hai nhóm cộng lại. Gọi d_{ij} là số bệnh nhân trong nhóm i ($i = 1, 2$) bị bệnh trong khoảng thời gian t_j . Gọi $d_j = d_{1j} + d_{2j}$ là tổng số bệnh nhân mắc bệnh và đặt $n_j = n_{1j} + n_{2j}$ là tổng số bệnh nhân của hai nhóm trong khoảng thời gian t_j . Với $j = 1, 2, 3, \dots, k$, chúng ta có thể ước tính:

$$e_{1j} = \frac{n_{1j}d_j}{n_j} \quad \text{và} \quad e_{2j} = \frac{n_{2j}d_j}{n_j}$$

$$v_j = \frac{n_{1j}n_{2j}d_j(n_j - d_j)}{n_j^2(n_j - 1)}$$

(Ở đây, e_{1j} , e_{2j} là số bệnh nhân trong nhóm 1 và 2 mà chúng ta tiên đoán là sẽ mắc bệnh nếu có cùng xác suất mắc bệnh trong cả hai nhóm (tức xác suất trung bình), v_j là phương sai). Ngoài ra, chúng ta có thể ước tính tổng số bệnh nhân mắc bệnh cho nhóm 1 và 2:

$$O_1 = \sum_{j=1}^k d_{1j} \quad \text{và} \quad O_2 = \sum_{j=1}^k d_{2j}$$

Và tổng số bệnh nhân mắc bệnh nếu có cùng chung xác suất mắc bệnh cho cả hai nhóm:

$$E_1 = \sum_{j=1}^k v_j \quad \text{và} \quad V = \sum_{j=1}^k v_j$$

Gọi T_i là một biến ngẫu nhiên phản ánh thời gian từ khi được điều trị đến khi mắc bệnh cho nhóm i , và gọi $S_i(t) = \Pr(T_i \geq t)$, kiểm định log-rank được định nghĩa như sau:

$$\chi^2 = \frac{(O_1 - E_1)^2}{V}$$

Nếu $\chi^2 > \chi^2_{1,\alpha}$ (trong đó, $\chi^2_{1,\alpha}$ là trị số Chi bình phương với độ ý nghĩa thống kê $\alpha = 0.95$), chúng ta có bằng chứng để kết luận rằng độ khác biệt về $S(t)$ giữa hai nhóm có ý nghĩa thống kê.

13.4 Kiểm định log-rank bằng R

Ví dụ 2 (tiếp tục): Chúng ta quay lại với ví dụ 2 và sẽ sử dụng R để tính toán kiểm định log-rank. Trước hết, chúng ta phải nhập các dữ liệu cần thiết bằng các lệnh thông thường như sau:

```
> group <- c(1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
             1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
             2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2,
             2, 2, 2, 2, 2, 2, 2, 2, 2)

> episode <- c(12, 10, 7, 10, 6, 8, 8, 9, 11, 13, 7, 13, 9,
               12, 13, 8, 10, 16, 6, 14, 13, 13, 16, 13, 9,
               9, 10, 12, 7, 7, 7, 7, 11, 16, 16, 6, 15,
               9, 10, 17, 8, 8, 8, 8, 14, 13, 9, 15)

> time <- c(8, 12, 52, 28, 44, 14, 3, 52, 35, 6, 12, 7, 52,
            52, 36, 52, 9, 11, 52, 15, 13, 21, 24, 52, 28,
            15, 44, 2, 8, 12, 52, 21, 19, 6, 10, 15, 4, 9, 27, 1,
            12, 20, 32, 15, 5, 35, 28, 6)

> infected <- c(1, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 0, 1,
                0, 1, 0, 0, 1, 1, 1, 0, 0, 1,
                1, 0, 0, 1, 1, 0, 1, 1, 1, 1, 0, 1, 0, 1, 1,
                1, 1, 0, 1, 1, 1, 1, 1)

> data <- data.frame(group, episode, time, infected)
```

(a) Chúng ta ứng dụng hàm `survfit` để ước tính xác suất tích lũy $S(t)$ cho từng nhóm bệnh nhân và cho kết quả vào đối tượng `kp.by.group` như sau (chú ý cách cung cấp thông số `~ group`):

```
> library(survival)
> kp.by.group <- survfit(Surv(time, infected==1) ~ group)
> summary(kp.by.group)
Call: survfit(formula = Surv(time, infected == 1) ~ group)
```


```
group=1
time n.risk n.event survival std.err lower 95% CI upper 95% CI
```

3	25	1	0.960	0.0392	0.886	1.000
6	24	1	0.920	0.0543	0.820	1.000
8	22	1	0.878	0.0660	0.758	1.000
9	21	1	0.836	0.0749	0.702	0.997
12	19	1	0.792	0.0829	0.645	0.973
13	17	1	0.746	0.0902	0.588	0.945
14	16	1	0.699	0.0958	0.534	0.915
15	15	1	0.653	0.1001	0.483	0.882
21	14	1	0.606	0.1033	0.434	0.846
28	12	2	0.505	0.1080	0.332	0.768
35	10	1	0.454	0.1083	0.285	0.725
36	9	1	0.404	0.1074	0.240	0.680
44	8	1	0.353	0.1052	0.197	0.633
52	7	1	0.303	0.1016	0.157	0.584

group=2						
time	n.risk	n.event	survival	std.err	lower 95% CI	upper 95% CI
1	23	1	0.957	0.0425	0.8767	1.000
4	21	1	0.911	0.0601	0.8004	1.000
5	20	1	0.865	0.0723	0.7346	1.000
6	19	2	0.774	0.0889	0.6183	0.970
8	17	1	0.729	0.0946	0.5650	0.940
10	15	1	0.680	0.1000	0.5099	0.907
12	14	2	0.583	0.1067	0.4072	0.835
15	12	2	0.486	0.1088	0.3132	0.754
19	9	1	0.432	0.1093	0.2630	0.709
20	8	1	0.378	0.1082	0.2156	0.662
21	7	1	0.324	0.1053	0.1712	0.613
27	6	1	0.270	0.1007	0.1300	0.561
28	5	1	0.216	0.0939	0.0921	0.506
35	3	1	0.144	0.0859	0.0447	0.463

Những thông tin trên cung cấp cho chúng ta “xác suất sống sót” trong từng thời điểm, nhưng vì là những con số nên khó cảm nhận được sự khác biệt giữa hai nhóm. Một cách khác thể hiện các xác suất này là qua biểu đồ Kaplan-Meier cho từng nhóm. Cách vẽ biểu đồ này có thể bằng lệnh sau đây:

```
> plot(kp.by.group,
      xlab="Time",
      ylab="Cum. survival probability",
      col=c("black", "red"))
```



Qua biểu đồ trên, chúng ta có thể thấy khá rõ là nhóm được điều trị bằng gd2 (đường màu đen phía trên) có xác suất nhiễm (hay bệnh tái phát) thấp hơn nhóm giả dược (đường màu đỏ nét đứt, phía dưới). Nhưng phân tích trên không cung cấp trị số p để chúng ta phát biểu kết luận.

(b) Để có trị số p, chúng ta cần phải sử dụng hàm `survdif` như sau:

```
> survdif(Surv(time, infected==1) ~ group)
```

Call:

```
survdif(formula = Surv(time, infected == 1) ~ group)
```

	N	Observed	Expected	(O-E) ² /E	(O-E) ² /V
group=1	25	15	20.0	1.26	3.65
group=2	23	17	12.0	2.11	3.65

Chisq= 3.7 on 1 degrees of freedom, p= 0.056

Kết quả phân tích log-rank cho trị số $p = 0.056$. Vì $p > 0.05$, chúng ta vẫn chưa có bằng chứng thuyết phục để kết luận rằng gd2 quả thật có hiệu nghiệm giảm nguy cơ tái phát bệnh.

13.5 Mô hình Cox (hay Cox's proportional hazards model)

Kiểm định log-rank là phương pháp cho phép chúng ta so sánh $S(t)$ giữa hai hay nhiều nhóm. Nhưng trong thực tế, $S(t)$ hay hàm nguy cơ $h(t)$ có thể không chỉ khác nhau giữa các nhóm, mà còn chịu sự chi phối của các yếu tố

khác. Vấn đề đặt ra là làm sao ước tính mức độ ảnh hưởng của các yếu tố nguy cơ (risk factors) đến $h(t)$. Chẳng hạn như trong nghiên cứu trên, số lần bệnh nhân từng bị nhiễm (biến episode) được xem là có ảnh hưởng đến nguy cơ bệnh tái phát. Do đó, vấn đề đặt ra là nếu chúng ta xem xét và điều chỉnh cho ảnh hưởng của episode thì mức độ khác biệt về $S(t)$ giữa hai nhóm có thật sự tồn tại hay không?

Vào khoảng giữa thập niên 1970s, David R. Cox, giáo sư thống kê học thuộc Đại học Imperial College (London, Anh) phát triển một phương pháp phân tích dựa vào mô hình hồi qui (regression) để trả lời câu hỏi trên (D.R. Cox, Regression models and life tables (with discussion), Journal of the Royal Statistical Society series B, 1972; 74:187-220). Phương pháp phân tích đó, sau này được gọi là *Mô hình Cox*. Mô hình Cox được đánh giá là một trong những phát triển quan trọng nhất của khoa học nói chung (không chỉ khoa học thống kê) trong thế kỉ 20! Bài báo vừa đề cập đã được trích dẫn hàng vạn lần trong vòng 30 năm qua.

Vì mô tả chi tiết mô hình Cox nằm ngoài phạm vi của chương sách này, nên chúng ta chỉ xem qua vài nét chính để bạn đọc có thể nắm vấn đề. Gọi $x_1, x_2, x_3, \dots, x_p$ là p yếu tố nguy cơ. x có thể là các biến liên tục hay không liên tục. Mô hình Cox phát biểu rằng:

$$h(t) = \lambda(t) e^{\beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \dots + \beta_p x_p}$$

$h(t)$ được định nghĩa như phần trên (tức hàm nguy cơ), β_j ($j = 1, 2, 3, \dots, p$) là hệ số ảnh hưởng liên quan đến x_j và $\lambda(t)$ là hàm số nguy cơ nếu các yếu tố nguy cơ x không tồn tại (còn gọi là baseline hazard function). Vì mức độ ảnh hưởng của một yếu tố nguy cơ x_j thường được thể hiện bằng tỉ số nguy cơ (*hazard ratio*, HR, cũng tương tự như odds ratio trong phân tích hồi qui logistic), hệ số $\exp(\beta_j)$ chính là HR cho khi x_j tăng một đơn vị.

Hàm `coxph` trong package R có thể được ứng dụng để ước tính hệ số β_j . Trong lệnh sau đây:

```
> analysis <- coxph(Surv(time, infected==1) ~ group)
```

Trong lệnh trên, chúng ta muốn kiểm định ảnh hưởng của hai nhóm điều trị đến hàm nguy cơ $h(t)$ và kết quả được chứa trong đối tượng `analysis`. Để tóm lược `analysis`, chúng ta sử dụng hàm `summary`:

```
> summary(analysis)
Call:
coxph(formula = Surv(time, infected == 1) ~ group)

n= 48
      coef exp(coef) se(coef)  z    p
group 0.684   1.98    0.363  1.88 0.06

      exp(coef) exp(-coef) lower .95 upper .95
group    1.98    0.505    0.973    4.04

Rsquare= 0.071 (max possible= 0.986 )
Likelihood ratio test= 3.55 on 1 df,  p=0.0597
Wald test          = 3.55 on 1 df,  p=0.0596
Score (logrank) test = 3.67 on 1 df,  p=0.0553
```

Nên nhớ nhóm điều trị được cho mã số 1, và nhóm giả được có mã số 2. Do đó, kết quả phân tích trên cho biết khi group tăng 1 đơn vị thì $h(t)$ tăng 1.98 lần (với khoảng tin cậy 95% dao động từ 0.97 đến 4.04). Nói cách khác, nguy cơ bệnh tái phát trong nhóm giả được cao hơn nhóm điều trị gấp 2 lần. Tuy nhiên vì khoảng tin cậy 95% bao gồm cả 1 và trị số $p = 0.06$, cho nên chúng ta vẫn không thể kết luận rằng mức độ ảnh hưởng này có ý nghĩa thống kê.

Nhưng chúng ta cần phải xem xét (và điều chỉnh) cho ảnh hưởng của quá trình bệnh trong quá khứ được đo lường bằng biến số episode. Để tiến hành phân tích này, chúng ta cho thêm episode vào hàm coxph như sau:

```
> analysis <- coxph(Surv(time, infected==1) ~ group + episode)
> summary(analysis)
Call:
coxph(formula = Surv(time, infected == 1) ~ group + episode)

n= 48
      coef exp(coef) se(coef)  z    p
group  0.874   2.40    0.3712  2.35 0.0190
episode 0.172   1.19    0.0648  2.66 0.0079

      exp(coef) exp(-coef) lower .95 upper .95
group    2.40    0.417    1.16    4.96
episode  1.19    0.842    1.05    1.35

Rsquare= 0.196 (max possible= 0.986 )
Likelihood ratio test= 10.5 on 2 df,  p=0.00537
Wald test          = 10.4 on 2 df,  p=0.00555
Score (logrank) test = 10.6 on 2 df,  p=0.00489
```

Kết quả phân tích trên cho chúng ta một diễn dịch khác và có lẽ chính xác hơn. Mô hình $h(t)$ bây giờ là:

$$h(t | group, episode) = \lambda(t) e^{0.874(group) + 0.172(episode)}$$

Nếu episode tạm thời giữ cố định, tỉ số $h(t)$ giữa hai nhóm là:

$$\frac{h(t | group = 2)}{h(t | group = 1)} = e^{0.874(2-1)} = 2.40$$

Tương tự, nếu group tạm thời giữ cố định, khi episode tăng một đơn vị, tỉ số nguy cơ sẽ tăng 1.14 lần.


Nói cách khác, mỗi lần mắc bệnh trong quá khứ (tức episode tăng 1 đơn vị) làm tăng nguy cơ tái phát bệnh 19% (với khoảng tin cậy 95% dao động từ 5% đến 35%). Nhóm giả được có nguy cơ bệnh tái phát tăng gấp 2.4 lần so với nhóm điều trị bằng gd2 (và khoảng tin cậy 95% có thể từ 1.2 đến gần 5 lần). Cả hai yếu tố (nhóm điều trị) và episode đều có ý nghĩa thống kê, vì trị số $p < 0.05$.

Nhưng episode là một biến liên tục. Vấn đề đặt ra là sau khi điều chỉnh episode thì hàm $S(t)$ cho từng nhóm sẽ ra sao? Cách khách quan nhất là giả định cả hai nhóm gd2 và giả được có cùng số lần episode (như số trung bình chẳng hạn), và hàm $S(t)$ cho từng nhóm có thể ước tính bằng:

```
> Cox.model <- survfit(coxph(Surv(time, infected==1)
~episode+strata(group)))
> plot(Cox.model,
      xlab= " Time " ,
      ylab= " Cumulative survival probability " ,
      col=c( " black " , " red " ))
```

hay đơn giản hơn:

```
> plot(survfit(coxph(Surv(time,
      infected==1)~episode+strata(group))),
      xlab="Time",
      ylab="Cumulative survival probability",
      col=c("black", "red"))
```

13.6 Xây dựng mô hình Cox bằng Bayesian Model Average (BMA)

Cũng như trường hợp của phân tích hồi qui tuyến tính đa biến và phân tích hồi qui logistic đa biến, vấn đề tìm một mô hình “tối ưu” để tiên đoán biến cố trong điều kiện có nhiều biến độc lập là một vấn đề nan giải. Phần lớn sách giáo khoa thống kê học trình bày ba phương án chính để tìm một mô hình tối ưu: forward algorithm, backward algorithm, và tiêu chuẩn AIC.

Với phương án forward algorithm, chúng ta khởi đầu tìm biến độc lập x có ảnh hưởng lớn đến biến phụ thuộc y , rồi từng bước thêm các biến độc lập khác x cho đến khi mô hình không còn cải tiến thêm nữa.

Với phương án backward algorithm, chúng ta khởi đầu bằng cách xem xét tất cả biến độc lập x trong dữ liệu có thể có ảnh hưởng lớn đến biến phụ thuộc y , rồi từng bước loại bỏ từng biến độc lập x cho đến khi mô hình chỉ còn lại những biến có ý nghĩa thống kê.

Hai phương án trên (forward và backward algorithm) dựa vào phần dư (residual) và trị số P để xét một mô hình tối ưu. Một phương án thứ ba là dựa vào tiêu chuẩn Akaike Information Criterion (AIC) vừa được trình bày trong chương trước. Để hiểu phương pháp xây dựng mô hình dựa vào AIC chúng ta sẽ lấy một ví dụ thực tế như sau. Giả dụ chúng ta muốn đi từ tỉnh A đến tỉnh B qua huyện C, và mỗi tuyến đường chúng ta có 3 lựa chọn: bằng xe hơi, bằng đường thủy, và bằng xe gắn máy. Tất nhiên, đi xe hơi đắt tiền hơn đi xe gắn máy; mặt khác, đi đường thủy tuy ít tốn kém nhưng chậm hơn đi bằng xe hơi hay xe gắn máy. Nếu có tất cả 6 phương án đi, vấn đề đặt ra là chúng ta muốn tìm một phương án đi sao cho ít tốn kém nhất, nhưng tiêu ra một thời gian

ngắn nhất! Tương tự, phương pháp xây dựng mô hình dựa vào tiêu chuẩn AIC là đi tìm một mô hình sao cho ít thông số nhất nhưng có khả năng tiên đoán biến phụ thuộc đầy đủ nhất.

Nhưng cả ba phương án trên có vấn đề là mô hình “tối ưu” nhất được xem là mô hình sau cùng, và tất cả suy luận khoa học đều dựa vào ước số của mô hình đó. Trong thực tế, bất cứ mô hình nào (kể cả mô hình “tối ưu”) cũng có độ bất định của nó, và khi chúng ta có thêm số liệu, mô hình tối ưu chưa chắc là mô hình sau cùng, và do đó suy luận có thể sai lầm. Một cách tốt hơn và có triển vọng hơn để xem xét đến yếu tố bất định này là Bayesian Model Average (BMA).

Với phân tích BMA, thay vì chúng ta hỏi yếu tố độc lập x ảnh hưởng đến biến phụ thuộc có ý nghĩa thống kê hay không, chúng ta hỏi: xác suất mà biến độc lập x có ảnh hưởng đến y là bao nhiêu. Để trả lời câu hỏi đó BMA xem xét tất cả các mô hình có khả năng giải thích y , và xem trong các mô hình đó, biến x xuất hiện bao nhiêu lần.

Ví dụ 3: Trong ví dụ sau đây, chúng ta sẽ mô phỏng một nghiên cứu với 5 biến độc lập x_1, x_2, x_3, x_4 , và x_5 . Ngoại trừ x_1 , 4 biến kia được mô phỏng theo luật phân phối chuẩn. Biến y là thời gian và kèm theo biến tử vong (death). Trong 5 biến x này, chỉ có biến x_1 có liên hệ với xác suất tử vong bằng mối liên hệ $\exp(3 \cdot x_1 + 1)$, còn các biến x_2, x_3, x_4 , và x_5 được mô phỏng hoàn toàn độc lập với nguy cơ tử vong. Chúng ta sẽ sử dụng phương pháp xây dựng mô hình theo tiêu chuẩn AIC và BMA để so sánh.

Nhập package survival và BMA để phân tích

```
> library(survival)
> library(BMA)
```

Tạo ra 5 biến số độc lập

```
> x1 <- (1:50)/2 - 3
> x2 <- rnorm(50)
> x3 <- rnorm(50)
> x4 <- rnorm(50)
> x5 <- rnorm(50)
```

Mô phỏng mối liên hệ $\text{risk} = \exp(\text{beta} \cdot x_1 + 1)$

```
> model <- exp(3*x1 + 1)
```

Tạo ra biến số phụ thuộc y

```
> y <- rexp(50, rate = model)
```

```
# Tạo ra biến sự kiện theo luật phân phối mũ, tỉ lệ 0.3
> censored <- rexp(50, rate=0.3)
> ycensored <- pmin(y, censored)
> death <- as.numeric(y <= censored)
```

```
# Cho tất cả biến số vào data frame tên simdata
> simdata <- data.frame(y, death, x1,x2,x3,x4,x5)
```

```
# Phân tích bằng mô hình Cox
> cox <- coxph(Surv(y, death) ~ ., data=simdata)
> summary(cox)
Call:
coxph(formula = Surv(y, death) ~ ., data = simdata)
```

```
n= 50
```

	coef	exp(coef)	se(coef)	z	p
x1	3.2325	25.344	0.568	5.6908	1.3e-08
x2	-0.0319	0.969	0.331	-0.0963	9.2e-01
x3	0.3112	1.365	0.327	0.9518	3.4e-01
x4	0.1364	1.146	0.297	0.4600	6.5e-01
x5	0.4898	1.632	0.313	1.5643	1.2e-01

	exp(coef)	exp(-coef)	lower .95	upper .95
x1	25.344	0.0395	8.325	77.16
x2	0.969	1.0324	0.506	1.85
x3	1.365	0.7326	0.719	2.59
x4	1.146	0.8725	0.641	2.05
x5	1.632	0.6127	0.883	3.01

```
Rsquare= 0.992 (max possible= 0.997 )
Likelihood ratio test= 241 on 5 df, p=0
Wald test = 33.3 on 5 df, p=3.36e-06
Score (logrank) test = 107 on 5 df, p=0
```

Kết quả trên cho thấy biến x1, x3 và x5 ảnh hưởng có ý nghĩa thống kê đến biến y. Tất nhiên, đây là một kết quả sai vì chúng ta biết rằng chỉ có x1 là có ý nghĩa thống kê mà thôi. Bây giờ chúng ta thử áp dụng cách xây dựng mô hình dựa vào tiêu chuẩn AIC:

```
# Tìm mô hình dựa vào tiêu chuẩn AIC
> searchAIC <- step(cox, direction="both")
> summary(searchAIC)
Call:
coxph(formula = Surv(y, death) ~ x1 + x5, data = simdata)
```

```
n= 50
```

	coef	exp(coef)	se(coef)	z	p
x1	3.126	22.79	0.529	5.91	3.4e-09
x5	0.429	1.54	0.297	1.45	1.5e-01

```

exp(coef) exp(-coef) lower .95 upper .95
x1      22.79    0.0439    8.080    64.27
x5       1.54    0.6510    0.858     2.75

```

```

Rsquare= 0.992 (max possible= 0.997 )
Likelihood ratio test= 240 on 2 df, p=0
Wald test          = 35.3 on 2 df, p=2.18e-08
Score (logrank) test = 104 on 2 df, p=0

```

Kết quả này cho thấy x1 và x5 là hai yếu tố độc lập và ảnh hưởng của chúng đến biến y được xem là có ý nghĩa thống kê. Một lần nữa, kết quả này sai! Bây giờ chúng ta sẽ áp dụng phép tính BMA:

#tìm mô hình bằng phép tính BMA

```

> time <- simdata$y
> death <- simdata$death
> xvars <- simdata[,c(3,4,5,6,7)]
> bma <- bic.surv(xvars, time, death)
> summary(bma)
> imageplot.bma(bma)

```

Call:

```
bic.surv.data.frame(x = xvars, surv.t = time, cens = death)
```


8 models were selected

Best 5 models (cumulative posterior probability = 0.8911):

	p!=0	EV	SD	model 1	model 2
x1	100.0	3.036	0.509	2.9805	3.1262
x2	9.6	0.001	0.096	.	.
x3	14.6	0.041	0.155	.	.
x4	10.0	0.006	0.092	.	.
x5	31.0	0.135	0.261	.	0.42920
nVar				1	2
BIC				-233.774	-232.126
post prob				0.458	0.201

	model 3	model 4	model 5
x1	3.0390	2.9829	2.9810
x2	.	.	0.0214
x3	0.2705	.	.
x4	.	0.0250	.
x5	.	.	.
nVar	2	2	2
BIC	-230.713	-229.933	-229.930
post prob	0.099	0.067	0.067

Kết quả phân tích BMA cho thấy mô hình tối ưu là mô hình 1 chỉ có một biến có ý nghĩa thống kê: đó là biến x_1 . Xác suất mà yếu tố này có ảnh hưởng đến nguy cơ tử vong là 100%. Đây chính là kết quả mà chúng ta kì vọng, bởi vì chúng ta đã mô phỏng chỉ có x_1 có ảnh hưởng đến y mà thôi. Mô hình 2 có hai biến x_1 và x_5 (tức cũng chính là mô hình mà tiêu chuẩn AIC xác định), nhưng mô hình này chỉ có xác suất 0.201 mà thôi. Các mô hình 3(x_1 và x_3), mô hình 4 (x_1 và x_4) và mô hình 5 (x_1 và x_2) cũng có khả năng nhưng xác suất quá thấp (dưới 0.1) cho nên chúng ta không thể chấp nhận được. Biểu đồ sau đây thể hiện các kết quả trên:



Biểu đồ trên trình bày 8 mô hình, và trong tất cả 8 mô hình, biến x_1 xuất hiện một cách nhất quán (xác suất 100%). Còn các biến khác có ảnh hưởng nhưng không nhất quán. Qua so sánh giữa hai phương pháp xây dựng mô hình rõ ràng cho thấy cách phân tích BMA cung cấp cho chúng ta mô hình phù hợp đáng tin cậy nhất và có vẻ phù hợp với thực tế nhất.

Trên đây là những phương pháp phân tích biến cố thông dụng nhất trong khoa học thực nghiệm với mô hình Cox và kiểm định log-rank. Mô hình Cox có thể khai triển thành những mô hình phức tạp và tinh vi hơn cho các nghiên cứu phức tạp khác với nhiều biến và tương tác giữa các yếu tố nguy cơ. Tài liệu hướng dẫn cách sử dụng package `survival` có thể giúp bạn đọc tìm hiểu sâu hơn. Tài liệu này có tại trang web www.cran.R-project.org.

14

Phân tích đa biến

Phân tích đa biến (multivariate analysis) là thuật ngữ dùng để chỉ các phương pháp phân tích nhiều biến cùng một lúc. Trong mô hình hồi qui tuyến tính đơn giản hay phân tích tương quan, chúng ta có biến y là biến phụ thuộc, và x là biến độc lập (biến tiên lượng). Trong trường hợp đó, chúng ta gọi là phân tích hai biến - *bivariate analysis*. Nhưng trong mô hình hồi qui tuyến tính đa biến, chúng ta chỉ có 1 biến y , nhưng nhiều biến x , và trong trường hợp này, chúng ta gọi là *multivariable analysis*. Phân tích đa biến để cập đến trường hợp chúng ta có nhiều biến y .

Có nhiều phương pháp trong nhóm phân tích đa biến, bao gồm phân tích phân định (discriminant analysis), phân tích phương sai đa biến (MANOVA), phân tích thành phần (principal component analysis), phân tích yếu tố (factor analysis), phân tích cụm (cluster analysis), v.v. Trong chương này, tôi chỉ giới thiệu 2 phương pháp phổ biến nhất, đó là phân tích thành phần và phân tích cụm. Các phương pháp khác hoặc là kém thông dụng, hoặc đã được thay thế bởi các phương pháp hiện đại khác nên tôi sẽ không giới thiệu ở đây.

14.1 Phân tích thành phần (Principal component analysis)

Phân tích thành phần (principal component analysis - PCA) là một phương pháp phân tích đa biến để mô tả và hiểu những khác biệt, dao động qua kỹ thuật giảm số lượng biến (variable reduction). Trong thực tế, các principal components hay PC, tức thành phần, là những biến được tạo ra từ những biến gốc trong khi phân tích.

Giả dụ chúng ta có dữ liệu bao gồm p biến số $X_1, X_2, X_3, \dots, X_p$, PCA sử dụng kỹ thuật xoay toạ độ gốc để tạo nên p biến mới không có liên quan nhau. Các biến độc lập mới này được gọi là *principal component* - tôi dịch ngắn là thành phần. Các biến mới này có đơn vị đường thẳng được chuẩn hoá (bằng 1). Nói cách khác, mỗi PC là hàm số của nhiều biến:

$$a_1X_1 + a_2X_2 + a_3X_3 + \dots + a_pX_p$$

sao cho

$$a_1^2 + a_2^2 + a_3^2 + \dots + a_p^2 = 1$$

Các thành phần (PC) có những đặc điểm chung như sau. Thành phần thứ nhất

$$\text{PRIN1} = a_{11}X_1 + a_{12}X_2 + a_{13}X_3 + \dots + a_{1p}X_p$$

có độ dao động lớn nhất trong các thành phần. Thành phần thứ hai

$$\text{PRIN2} = a_{21}X_1 + a_{22}X_2 + a_{23}X_3 + \dots + a_{2p}X_p$$

có độ dao động thấp hơn PRIN1 nhưng cao hơn các thành phần còn lại. PRIN2 không có tương quan với PRIN1.

Nói chung, thành phần j^{th} , PRIN $_j$ ($j = 1, 2, 3, \dots, p$) có độ dao động lớn nhất trong tất cả các thành phần còn lại, và không có liên quan đến PRIN1, PRIN2, PRIN3,... PRIN $_{(j-1)}$. Dĩ nhiên, thành phần sau cùng, PRIN $_p$, có độ dao động thấp nhất.

Mỗi thành phần (từ nay tôi sẽ gọi là PC) có trung bình và phương sai. Phương sai của PC có tên là **eigenvalues**. Các hệ số trong các PC có tên là **eigenvectors**.

14.1.1 Ví dụ 1: Dữ liệu về nhiệt độ

Dữ liệu dưới đây là nhiệt độ (F) vào tháng 1 và tháng 7 của 64 địa phương thuộc Mỹ. Một số số liệu tiêu biểu như sau:

```
# Dữ liệu đọc vào là temp từ Temperature.csv
# temp = read.csv("Temperature.csv", header=T)
# temp$id = 1:nrow(temp)
```


```
> head(temp)
```

```
      city january july id
1  mobile    51.2  81.6  1
2  phoenix    51.2  91.2  2
```

3	little rock	39.5	81.4	3
4	sacramento	45.1	75.2	4
5	denver	29.9	73.0	5
6	hartford	24.8	72.7	6

Chúng ta sẽ dùng ggplot2 để xem qua dữ liệu về nhiệt độ tháng 1 và tháng 7 cho từng thành phố:

```
library(ggplot2)
p = ggplot(data=temp, aes(x=january, y=july))
p = p + geom_point()
p = p + coord_fixed(ratio=1)
p = p + geom_text(aes(label=city), vjust=-0.5, alpha=0.25)
p = p + labs(title="Temperature for selected cities")
p
```



Trong R, hàm **princomp()** được sử dụng cho phân tích thành phần. Một cách mặc định hàm princomp() tính toán trên ma trận hiệp biến (covariance matrix), nhưng ma trận hệ số phương sai cũng có thể dùng như là input. Các chỉ số thành phần sẽ có tên PRIN1, PRIN2, PRIN3,... PRINp, và tất cả có trung bình bằng 0.

```
pca = princomp(~january + july, data=temp)
summary(pca)
loadings(pca)
```



```
> summary(pca)
```

Importance of components:

	Comp.1	Comp.2
Standard deviation	12.3217642	3.0004557
Proportion of Variance	0.9440228	0.0559772
Cumulative Proportion	0.9440228	1.0000000

```
> loadings(pca)
```

Loadings:

	Comp.1	Comp.2
january	-0.939	0.343
july	-0.343	-0.939

	Comp.1	Comp.2
SS loadings	1.0	1.0
Proportion Var	0.5	0.5
Cumulative Var	0.5	1.0

Dữ liệu có 2 biến, nên số PC cũng bằng 2. PRIN1 (R gọi là Comp.1) là hàm số của january và july:

$$\text{PRIN1} = -0.939 \times \text{january} - 0.343 \times \text{july}$$

Trọng số tháng 1 cao gần gấp 3 lần trọng số tháng 7. Điều này hợp lí, vì PRIN1 phải tối ưu hoá dữ liệu, và nhiệt độ tháng 1 dao động rất cao so với nhiệt độ tháng 7. Đối với PRIN2:

$$\text{PRIN2} = 0.343 \times \text{january} - 0.939 \times \text{july}$$


Như chúng ta thấy, PRIN1 giải thích 94.4% dao động của dữ liệu, kể đến là PRIN2 (hay Comp.2) giải thích 5.6%.

Chúng ta có thể xem qua tỉ lệ phương sai cho từng PC:

```
par(mfrow=c(1,2))
```

```
biplot(pca)
```

```
screplot(pca)
```



14.1.2 Diễn giải PCA


Dữ liệu dưới đây trích từ nghiên cứu của Jolicouer và Mosimann, theo đó, họ đo mai rùa của 24 con rùa. Mỗi mai rùa có 3 thông số: chiều dài (length), bề rộng (width), và chiều cao (height).

length	width	height
98	81	38
103	84	38
103	86	42
105	86	42
109	88	44
123	92	50
123	95	46
133	99	51
133	102	51
133	102	51
134	100	48
136	102	49
138	98	51
138	99	51
141	105	53

147	108	57
149	107	55
153	107	56
155	115	63
155	117	60
158	115	62
159	118	63
162	124	61
177	132	67

Chúng ta có thể xem qua dữ liệu bằng biểu đồ:

```
shell = read.table("shell.txt", header=T)
library(psych)
pairs.panels(shell)
```



Biểu đồ trên cho thấy cả 3 biến có độ tương quan cao ($r = 0.97$). Bây giờ chúng ta sẽ dùng PCA để phân tích và xem có thể giảm số biến:

```
pca = princomp(~length + width + height, data=shell)
summary(pca)
loadings(pca)
```

Và kết quả:

```
> summary(pca)
```

Importance of components:

	Comp.1	Comp.2	Comp.3
Standard deviation	25.4970668	2.547081962	1.653745717
Proportion of Variance	0.9860122	0.009839832	0.004148005
Cumulative Proportion	0.9860122	0.995851995	1.000000000

```
> loadings(pca)
```

Loadings:

	Comp.1	Comp.2	Comp.3
length	0.814	0.555	-0.172
width	0.496	-0.818	-0.291
height	0.302	-0.151	0.941

	Comp.1	Comp.2	Comp.3
SS loadings	1.000	1.000	1.000
Proportion Var	0.333	0.333	0.333
Cumulative Var	0.333	0.667	1.000

Kết quả trên cho chúng ta 3 PC:

$$\text{PRIN1} = 0.81 \times \text{Length} + 0.50 \times \text{Width} + 0.30 \times \text{Height}$$

$$\text{PRIN2} = -0.56 \times \text{Length} - 0.82 \times \text{Width} - 0.15 \times \text{Height}$$

$$\text{PRIN3} = (-0.17 \times \text{Length} - 0.29 \times \text{Width}) + 0.94 \times \text{Height}$$

Khi diễn giải các thành phần, chúng ta không quá quan tâm đến hệ số cao hay thấp, nhưng quan tâm đến *dấu* của hệ số. Trong PRIN1, tất cả các hệ số đều dương tính, và cho thấy phản ánh một đặc điểm. Đặc điểm đó là gì có khi đòi hỏi tính *sáng tạo* trong diễn giải. Có thể nói rằng cả ba đặc tính length, width, và height phản ánh **kích thước - size**. PRIN1 giải thích gần 99% dữ liệu.

Thế còn PRIN2 và PRIN3 có nghĩa gì? Chúng ta chú ý hệ số width và height (PRIN2), và hệ số length và width (PRIN3) đều âm tính. Theo tác giả Jolicouer và Mosimann, PRIN2 và PRIN3 phản ánh **hình dạng - shape**. Dĩ nhiên, đối với tác giả khác, có thể người ta có cách diễn giải khác.

14.2 Phân tích cụm (cluster analysis)

Phân tích cụm là một công cụ để khai thác dữ liệu và tìm các nhóm có những đặc điểm giống nhau. Phân tích cụm cũng có thể ứng dụng để nhóm các biến có dữ liệu quan sát giống nhau. Mục tiêu của phân tích cụm là xác định các nhóm dựa vào độ giống nhau (hay tương đồng). Các cụm được thẩm định để tìm những đặc điểm có thể giải thích sự hình thành các nhóm/cụm.

Có nhiều thuật toán cho phân tích cụm. Ở đây, tôi chỉ tập trung vào thuật toán đơn giản nhất và phổ biến nhất gọi là *agglomerative hierarchical clustering method*. Phương pháp này xem mỗi dòng dữ liệu (tạm gọi là observation) là một cụm hay nhóm. Khi hai observation giống nhau thì sẽ được cho vào một nhóm, tức một cụm với hai observations. Khi các cụm còn lại có một observation. Các cụm sau đó được nối kết nhau một cách tuần tự cho đến khi chỉ còn 1 cụm.

Ví dụ: Chúng ta có 8 observation trong dữ liệu sau đây; mỗi observation có 2 biến (hay 2 đặc tính), x_1 và x_2 . Phương pháp phân tích cụm sẽ thực hiện như sau:

Bước 1: mỗi observation là một cụm

Bước 2: Xác định một cụm mới bằng cách tìm hai observations rất giống nhau hay gần nhau. Chúng ta còn lại 7 cụm.

Bước 3: Tìm một cụm mới bằng cách nhóm 2 cụm gần nhau nhất hay giống nhau nhất. Chúng ta còn lại 6 cụm.

Bước 4 - Bước 7: Tiếp tục qui trình nhập các cụm từng bước một.

Bước 8: Hợp nhất hai cụm còn lại. Sau đó dùng biểu đồ cây (dendrogram) để tóm lược các bước hình thành cụm.

```

dat = read.table(text="
x1 x2
4 8
6 6
10 11
11 8
17 5
19 3
20 11
21 2
", header=T)

```

Phân tích thành phần

```
pca = princomp( ~ x1 + x2, data = dat)
```

Thể hiện dữ liệu gốc bằng biểu đồ

```

library(ggplot2)
p = ggplot(data=dat, aes(x = x1, y = x2))
p = p + geom_point()
p = p + geom_text(aes(label = 1:nrow(dat)), hjust = -0.5,
alpha = 0.5) # labels
p = p + labs(title = "Ví dụ đơn giản")
p


```

Thể hiện thành phần PC

```


p = ggplot(as.data.frame(pca$scores), aes(x = Comp.1,
y = Comp.2))
p = p + geom_point()
p = p + geom_text(aes(label = rownames(pca$scores)),
hjust = -0.5, alpha = 0.5)
p = p + labs(title = "PCA scores")
p

```



Đây là kết quả phân tích khoảng cách (distance) mà chúng ta sẽ bàn thêm trong biểu đồ sau.

```
# tạo ra ma trận khoảng cách giữa các điểm
dist = dist(dat)
hc.average = hclust(dist, method = "average")
op = par(no.readonly=T)
# lưu trữ biểu đồ gốc
par(mfrow=c(3,2), mar=c(2, 2, 2.5, 1))
# margins là c(bottom, left, top, right)
library(cluster)
for (iclus in 7:2) {
  clusplot(dat, cutree(hc.average, k = iclus),
    color=T, labels=2, lines=0,
    cex=2, cex.txt=1, col.txt="gray20",
    main = paste(iclus, "clusters"), sub = NULL)
}
par(op)
```



Thứ tự của việc phân cụm được tóm tắt trong biểu đồ dendrogram ở phía tay mặt (phần dưới).

tạo ma trận khoảng cách các điểm

```
dist = dist(dat)
```

```
dist
```

```
> dist
```

	1	2	3	4	5	6	7
2	2.828427						
3	6.708204	6.403124					
4	7.000000	5.385165	3.162278				
5	13.341664	11.045361	9.219544	6.708204			
6	15.811388	13.341664	12.041595	9.433981	2.828427		


```

7 16.278821 14.866069 10.000000 9.486833 6.708204 8.062258
8 18.027756 15.524175 14.212670 11.661904 5.000000 2.236068 9.055385

```


```

op = par(no.readonly = TRUE)
par(mfrow = c(1,3))
hc.single = hclust(dist, method = "single")
plot(hc.single, hang = -1, main = "single")

hc.complete = hclust(dist, method = "complete")
plot(hc.complete, hang = -1, main = "complete")


hc.average = hclust(dist, method = "average")
plot(hc.average, hang = -1, main = "average")
par(op)

```



14.2.1 Đo lường khoảng cách (distance)

Khoảng cách giữa các cụm là một chỉ số quan trọng trong phân tích cụm. Có nhiều “thước đo” giữa các cụm: (a) “Single linkage distance” là khoảng cách tối thiểu giữa các điểm của 2 cụm; (b) “Complete linkage distance” là khoảng cách tối đa giữa các điểm của 2 cụm; và (c) “Average linkage distance” là khoảng cách trung bình giữa các điểm của 2 cụm. Trong 3 thước đo này, khoảng cách giữa các điểm tính theo công thức Euclid. Biểu đồ dưới đây minh họa cho 3 thước đo đó:



Với một thước đo khoảng cách, khoảng cách giữa hai cụm được đánh giá ở mỗi bước. Hai cụm nào gần nhất được nhập thành một. Như chúng ta thấy, việc lựa chọn một thước đo khoảng cách có thể ảnh hưởng đến kết quả phân tích. Thước đo single linkage, vì đo khoảng cách ngắn nhất giữa các điểm của 2 cụm, nên có thể cho ra các cụm bất thường. Thước đo complete linkage dùng khoảng cách xa nhất giữa các điểm nên có thể cho ra những cụm có cùng đường kính. Thước đo average linkage dùng khoảng cách trung bình giữa các điểm nên có xu hướng cho ra những cụm có cùng độ dao động. Do đó, người phân tích phải dùng nhiều thước đo khoảng cách để đi đến một kết quả có thể chấp nhận được.

Ví dụ: Phân biệt răng của vài sinh vật

Bảng số liệu dưới đây là kết quả của một nghiên cứu về các loại răng của 32 động vật có vú. Các biến viết tắt có nghĩa là:

- v1: số răng sữa phía trên;
- v2: số răng sữa phía dưới ;
- v3: số răng nanh phía trên;
- v4: số răng nanh phía dưới;
- v5: số răng hàm nhỏ phía trên;

- v6: số răng hàm nhỏ phía dưới;
- v7: số răng hàm phía trên;
- v8: số răng hàm phía dưới.

Mục tiêu của phân tích là dùng những số liệu đó để nhận dạng các động vật có cùng số răng qua 8 loại răng.

mammal	v1	v2	v3	v4	v5	v6	v7	v8
Brown_Bat	2	3	1	1	3	3	3	3
Mole	3	2	1	0	3	3	3	3
Pigmy_Bat	2	3	1	1	2	2	3	3
House_Bat	2	3	1	1	1	2	3	3
Red_Bat	1	3	1	1	2	2	3	3
Pika	2	1	0	0	2	2	3	3
Rabbit	2	1	0	0	3	2	3	3
...								
Reindeer	0	4	1	0	3	3	3	3
Elk	0	4	1	0	3	3	3	3
Deer	0	4	0	0	3	3	3	3
Moose	0	4	0	0	3	3	3	3


Chúng ta bắt đầu phân tích bằng cách đọc dữ liệu:

```
teeth = read.table("teeth.txt", header=T)
# Tính khoảng cách giữa các điểm
distance = dist(teeth[,-1])
iclusters=8
```

```
# average linkage
```

```
hc.average = hclust(distance, method = "average")
plot(hc.average, hang=-1, main="Average linkage",
labels=teeth[,1])
```

và kết quả là:



14.2.2 Xác định số cụm

Phân tích cụm có thể sử dụng để tìm số cụm tối ưu hoặc số cụm đã được xác định trước bằng nhiều thuật toán khác nhau. Tuy nhiên, vấn đề quan trọng của phân tích là làm sao nhận ra số cụm trong dữ liệu. Một cách đơn giản là tiếp tục phân nhóm cho đến khi các cụm được nối kết với nhau và tương đối khác nhau. Đôi khi, kinh nghiệm với dữ liệu cũng có thể cho chúng ta một qui luật để ngưng phân chia. Trong R, có package **NbClust** có thể dùng cho việc xác định số cụm cần thiết.

Để sử dụng **NbClust** chúng ta cần phải hoán chuyển các biến từ integer sang numeric:

```
teeth1 = as.numeric(as.matrix(teeth[,-1]))
library(NbClust)
NbClust(teeth1, method = "average", index = "all")
```


Kết quả cho thấy số cụm tối ưu có lẽ là 5:

Among all indices:

- * 1 proposed 4 as the best number of clusters
- * 5 proposed 5 as the best number of clusters

***** Conclusion *****

* According to the majority rule, the best number of clusters is 5



Trong thực tế, có nhiều phương pháp thống kê để tìm số cụm. Tuy nhiên, không có phương pháp nào là tốt nhất. Những phương pháp đề nghị sử dụng các chỉ số như tiêu chuẩn cubic clustering criteria (ccc), kiểm định giống như F, kiểm định giống như t test, v.v. Nhiều chuyên gia đề nghị dùng tiêu chuẩn ccc hoặc kiểm định F tương đối cao.


```
# tính khoảng cách
distance = dist(teeth[,-1])

# số clusters tối đa
iclusters = 5

# vẽ biểu đồ dendrogram
hc.average = hclust(distance, method = "average")


plot(hc.average, hang = -1, main=paste("Teeth with average
linkage and", iclusters, "clusters"),
labels = teeth[,1])

rect.hclust(hc.average, k = iclusters)
```



Một cách khác để xem xét các cluster là dùng phân tích thành phần như sau:

```
# tạo ra các thành phần PC
clusplot(teeth, cutree(hc.average, k = iclusters),
color=T, labels=2, lines=0, cex=2, cex.txt=1,
col.txt="gray20", main= paste("Teeth PCA with average
linkage and", iclusters, "clusters"), sub = NULL)
```




Ví dụ: Tỷ lệ sinh và tử vong

Số liệu dưới đây phản ánh tỉ lệ sinh (birth rate) và tỉ lệ tử vong của 74 nước trên thế giới. Chúng ta muốn ứng dụng phương pháp phân tích cụm để nhận dạng các nước có đặc điểm giống nhau.

country	birth	death
afghan	52	30
algeria	50	16
angola	47	23
argentina	22	10
australia	16	8
austria	12	13
banglades	47	19
belguim	12	12
...		
vietnam	42	17
yugoslav	18	8
zaire	45	18

Chúng ta sẽ đọc dữ liệu vào R và phân tích theo trình tự được giải thích qua các ví dụ trên. Trước hết chúng ta muốn xem qua dữ liệu thực tế:

```
bd = read.table("birthdeath.txt", header=T)
library(ggplot2)
p = ggplot(bd, aes(x = birth, y = death))
p = p + geom_point(size = 2)
p = p + geom_text(aes(label = country), hjust = -0.1,
alpha = 0.2)
p = p + coord_fixed(ratio = 1) # makes 1 unit equal
length on x- and y-axis
p = p + labs(title = "1976 crude birth and death rates")
p
```



Tìm số clusters tối ưu


```
library(NbClust)
bd1 = as.numeric(as.matrix(bd[, -1]))
nclusters = NbClust(bd1, method="complete", index="all")
```

#số clusters tối ưu là 2

- * Among all indices:
- * 2 proposed 2 as the best number of clusters
- * 1 proposed 4 as the best number of clusters
- * 1 proposed 5 as the best number of clusters
- * 1 proposed 6 as the best number of clusters
- * 1 proposed 15 as the best number of clusters


***** Conclusion *****

* According to the majority rule, the best number of clusters is 2




Nhưng biểu đồ trên cũng gợi ý số cụm có thể là 3. Chúng ta thử dùng biểu đồ dendrogram để thấy thêm:

```
distance = dist(bd[,-1])
iclusters = 3
hc.complete = hclust(distance, method = "complete")
plot(hc.complete, hang=-1, main="Countries with complete
linkage", iclusters, labels=bd[,1])
rect.hclust(hc.complete, k=iclusters)
```



```
clusplot(bd, cutree(hc.complete, k = iclusters),
color=T, labels=2, lines=0, cex=2, cex.txt=1,
col.txt="gray20", main= paste("Birth/Death with complete
linkage", iclusters, "clusters"), sub = NULL)
```




```
# thêm một biến về số cụm
bd$clusters = factor(cutree(hc.complete, k=iclusters))
# đồ với dữ liệu gốc + phân chia theo cụm

library(ggplot2)


p = ggplot(bd, aes(x=birth, y=death, colour=clusters,
shape=clusters))

p = p + geom_point(size = 2)
p = p + geom_text(aes(label=country), hjust=-0.1, alpha=0.2)
p = p + coord_fixed(ratio = 1)
p = p + labs(title = "1976 crude birth and death rates,
complete linkage")
print(p)
```




Bây giờ, như là để so sánh, chúng ta sẽ dùng thước đo “single linkage”.

```
# Tìm số cụm tối ưu
bd2 = as.numeric(as.matrix(bd[, -1]))
nclusters = NbClust(bd2, method = "single", index = "all")
```

vẽ dữ liệu gốc với 3 cụm

```
clusters = factor(cutree(hc.single, k=iclusters))
library(ggplot2)
p = ggplot(bd, aes(x=death, y=birth, colour= clusters,
shape=clusters))
p = p + geom_point(size = 2)
p = p + geom_text(aes(label = country), hjust = -0.1,
alpha = 0.2)
p = p + coord_fixed(ratio = 1)
p = p + labs(title = "1976 crude birth and death rates,
single linkage")
print(p1)
```



Như chúng ta thấy kết quả của phương pháp single linkage và complete linkage rất khác nhau. Có thể số cụm thì giống nhau (3), nhưng thành phần trong cụm thì rất khác nhau.

15

Mô hình ảnh hưởng hỗn hợp (mixed-effects model)

Một trong những mô hình nghiên cứu phổ biến có tên là *prospective study*, hay nghiên cứu theo thời gian. Trong mô hình nghiên cứu theo thời gian, các đối tượng nghiên cứu được theo dõi theo thời gian để đánh giá hiệu quả của một thuật can thiệp. Chẳng hạn như hai nhóm bệnh nhân được điều trị bằng hai loại thuốc, và mỗi bệnh nhân được đo nồng độ glucose mỗi 6 tháng. Vấn đề đặt ra là làm thế nào để đánh giá hiệu quả của can thiệp một cách có hệ thống. Chúng ta không thể dùng t-test cho 6 thời điểm, vì làm như thế là gặp vấn đề kiểm định nhiều giả thuyết. Và lại, mỗi bệnh nhân được đo lường nhiều lần, và các giá trị phải có liên quan nhau; do đó, kiểm định nhiều giả thuyết mà không xem xét đến sự tương quan trong mỗi cá nhân là một sai lầm nghiêm trọng.

Chương này sẽ hướng dẫn cách phân tích số liệu để kiểm định giả thuyết về ảnh hưởng của thuốc bằng một mô hình thống kê được xem là “chuẩn vàng” hiện nay: đó là mô hình *mixed-effects* mà tôi tạm dịch là “mô hình ảnh hưởng hỗn hợp”. Phân tích bằng mô hình này cần có máy tính và chương trình phân tích thống kê. Tôi sẽ sử dụng phần mềm R để phân tích, và sẽ trình bày các mã trong bài để bạn đọc dễ dàng theo dõi.

15.1 Phân biệt fixed effect và random effect

Một trong những khó khăn của người mới học thống kê và thí nghiệm là khái niệm fixed effects (có lẽ dịch là *ảnh hưởng cố định*) và random effects (*ảnh hưởng ngẫu nhiên*). Sách giáo khoa cũng không giải thích rõ ràng, một phần vì tác giả không xem đó là quan trọng, một phần vì... khó hiểu. Tuy nhiên, để

sử dụng R (đặc biệt là package lme4) thì chúng ta cần phải phân biệt hai khái niệm trên. Trong phần này, tôi sẽ giải thích fixed effects và random effects qua một số ví dụ cụ thể.

Phân tích phương sai 1 chiều (one-way analysis of variance)

Số liệu dưới đây là điểm cho 3 nhóm vận động viên. Nhóm 1 gồm 10 người, nhóm hai gồm 6 người, và nhóm 3 có 9 người. Mục tiêu là kiểm định giả thuyết ba nhóm này có cùng điểm. Phương pháp kiểm định mà chúng ta nghĩ đến là phân tích phương sai (ANOVA), với hàm `lm(Score ~ Group)` như đã giới thiệu trong Chương 11.

ID	GROUP	SCORE
1	1	3
2	1	13
3	1	13
4	1	8
5	1	11
6	1	9
7	1	12
8	1	7
9	1	16
10	1	15
11	2	18
12	2	6
13	2	21
14	2	34
15	2	26
16	2	11
17	3	24
18	3	14
19	3	21
20	3	5
21	3	17
22	3	17
23	3	23
24	3	19
25	3	7

Mô hình trung bình

Trong mô hình phân tích phương sai, bằng ngôn ngữ của mô hình tuyến tính, chúng ta có thể phát biểu rằng: Gọi Score của đối tượng i ($i = 1, 2, 3, \dots, 25$)

và nhóm j là Y_{ij} . Chúng ta nghĩ rằng những dao động về Y_{ij} được xác định bởi giá trị trung bình của mỗi nhóm (tạm gọi là β_j), với $j = 1, 2, 3$, cộng với một sai số ngẫu nhiên kí hiệu là ε_{ij} . Nói cách khác, chúng ta có:

$$Y_{ij} = \beta_j + \varepsilon_{ij} \tag{1}$$

Trong đó, $\varepsilon_{ij} \sim N(0, \sigma^2)$. Nói cách khác ε_{ij} giả định tuân theo luật phân bố chuẩn với trung bình 0 và phương sai σ^2 . Có thể hiểu mô hình này bằng cách trình bày lại bảng số liệu trên như sau:

ID	QUAN SÁT		MÔ HÌNH HOÁ	
	GROUP	SCORE	β_j	ε_{ij}
1	1	3	β_1	ε_{11}
2	1	13	β_1	ε_{21}
3	1	13	β_1	ε_{31}
...	...	...	...	...
8	1	7	β_1	ε_{81}
9	1	16	β_1	ε_{91}
10	1	15	β_1	ε_{101}
11	2	18	β_2	ε_{12}
12	2	6	β_2	ε_{22}
13	2	21	β_2	ε_{32}
14	2	34	β_2	ε_{42}
15	2	26	β_2	ε_{52}
16	2	11	β_2	ε_{62}
17	3	24	β_3	ε_{13}
18	3	14	β_3	ε_{23}
19	3	21	β_3	ε_{33}
20	3	5	β_3	ε_{43}
...	...	...	...	...
25	3	7	β_3	ε_{93}

Ở mức độ nhóm, chúng ta mô hình rằng những khác biệt giữa các cá nhân trong nhóm bằng giá trị trung bình μ_0 , cộng với các khác biệt ngẫu nhiên (kí hiệu là u_{oj}) chung quanh giá trị trung bình:

$$\beta_j = \mu_0 + u_{oj} \tag{2}$$

Trong đó, $u_{oj} \sim N(0, \tau_{00})$. Thay thế [2] vào [1]:

$$Y_{ij} = \mu_0 + (u_{oj} + \varepsilon_{ij}) \tag{3}$$

Theo mô hình trên, μ_0 là một *fixed effect* vì là một thông số. Còn $(u_{0j} + \varepsilon_{ij})$ được gọi là *random effects* vì phản ánh phương sai.

Hàm **lmer** (linear mixed effect regression) trong package **lme4** rất có ích trong việc ước tính các thông số của mô hình trên. Hàm lmer có hai phần chính: fixed effects và random effects (trong ngoặc). Do đó, để hiểu và sử dụng lmer, chúng ta cần phải viết xuống mô hình phân tích. Chúng ta sẽ tạo ra một dataframe có tên là test như sau:

```
Score = c(3, 13, 13, 8, 11, 9, 12, 7, 16, 15, 18, 6, 21,
34, 26, 11, 24, 14, 21, 5, 17, 17, 23, 19, 7)
```

```
Group = c(rep("1", 10), rep("2", 6), rep("3", 9))
```

```
test = data.frame(Group, Score)
```

Để ước tính các thông số của mô hình [3], chúng ta dùng lmer như sau:

```
library(lme4)
```

```
fit = lmer(Score ~ 1 + (1 | Group), data=test, REML=0)
```

```
summary(fit)
```

Trong hàm trên số “1” chỉ intercept, tức mô hình đơn giản nhất, chỉ có số trung bình cho toàn bộ quần thể. Phần random effects, (1 | Group) phản ánh u_{0j} trong mỗi nhóm.

```
> summary(fit)
Linear mixed model fit by maximum likelihood ['lmerMod']
Formula: Score ~ 1 + (1 | Group)
Data: test

      AIC      BIC    logLik deviance
175.0157 178.6723 -84.5079 169.0157

Random effects:
Groups      Name      Variance Std.Dev.
Group      (Intercept)  7.082    2.661
Residual                45.797    6.767
Number of obs: 25, groups: Group, 3

Fixed effects:
              Estimate Std. Error t value
(Intercept)   15.150      2.059    7.358
```

Đối chiếu với mô hình $Y_{ij} = \mu_0 + (u_{0j} + \varepsilon_{ij})$, chúng ta thấy ước số của $\mu_0 = 15.2$. Phương sai giữa các nhóm là $\tau_{00} = 7.08$, và phương sai giữa các cá nhân là $\sigma^2 = 45.8$.

Mô hình ảnh hưởng nhóm

Với mô hình mới, chúng ta cho rằng điểm của mỗi cá nhân Y_{ij} là hàm số của intercept (μ_0) + trung bình của mỗi nhóm (β_j) + sai số ngẫu nhiên. Nói cách khác, mô hình mới là:

$$Y_{ij} = \mu_0 + \beta_j + \varepsilon_{ij} \quad [4]$$

Với $\varepsilon_{ij} \sim N(0, \sigma^2)$. Trong đó, trung bình của mỗi nhóm β_j là hàm số của trung bình thật của nhóm và sai số ngẫu nhiên.

$$\beta_j = \alpha_j + u_{oj} \quad [5]$$

Với $u_{oj} \sim N(0, \tau_{00})$. Thay [5] vào [4] chúng ta có mô hình:

$$Y_{ij} = \mu_0 + \alpha_j + (u_{oj} + \varepsilon_{ij})$$

Chúng ta dùng hàm lmer cho mô hình trên như sau:

```
fit1 = lmer(Score ~ 1 + Group + (1 | Group), data=test,  
REML=0)
```

```
summary(fit1)
```

```
> summary(fit1)
Linear mixed model fit by maximum likelihood ['lmerMod']
Formula: Score ~ 1 + Group + (1 | Group)
Data: test

      AIC      BIC    logLik deviance
173.3541 179.4484 -81.6770 163.3541

Random effects:
Groups   Name      Variance Std.Dev.
Group    (Intercept)  0.0      0.000
Residual                40.3     6.348
Number of obs: 25, groups: Group, 3

Fixed effects:
              Estimate Std. Error t value
(Intercept)   10.700      2.007    5.330
Group2         8.633       3.278    2.634
Group3         5.633       2.917    1.931
```

Mô hình trên cho thấy so sánh với nhóm 1 điểm của nhóm 2 cao hơn 8.6 điểm, và nhóm 3 cao hơn 5.6 điểm, nhưng sự khác biệt đều không có ý nghĩa thống kê. Chú ý residual (tức σ^2) giảm từ 45.8 xuống còn 40.3.

15.2 Mô hình ảnh hưởng hỗn hợp cho nghiên cứu theo thời gian

Bảng số liệu dưới đây trình bày kết quả của một thí nghiệm trên chuột. Nghiên cứu có 19 con chuột, được chia thành 2 nhóm: nhóm thứ nhất được cho uống thuốc ($n = 9$ con chuột) và nhóm thứ hai là nhóm chứng (không uống thuốc, gồm 10 con chuột). Ở mỗi con chuột, nồng độ đường trong máu (glucose) được đo tại 4 thời điểm: trước khi uống thuốc (T_0), 2 giờ, 3 giờ, và 4 giờ sau khi uống thuốc (tạm kí hiệu T_2 , T_3 và T_4). Mô hình nghiên cứu này có khi được đề cập đến dưới cái tên *repeated measure design*. Kết quả của thí nghiệm như sau:

Bảng 1. Nồng độ glucose trong máu của chuột qua 4 thời điểm

TREATMENT	ID	T0	T2	T3	T4
Test	1	5.9	3.9	3.9	3.6
Test	2	5.3	4.7	3.5	3.2
Test	3	4.6	3.7	3.3	3.2
Test	4	6.2	4.6	4.3	3.9
Test	5	6.0	5.4	5.2	4.8
Test	6	6.4	4.7	4.8	4.3
Test	7	7.6	4.1	3.8	4.1
Test	8	5.9	3.1	3.6	3.3
Test	9	7.5	6.1	5.4	4.6
Control	10	6.2	5.3	4.9	4.5
Control	11	6.9	5.6	5.9	5.9
Control	12	5.6	4.7	4.6	4.0
Control	13	5.1	3.9	2.9	2.9
Control	14	5.7	4.7	4.3	4.6
Control	15	5.0	4.0	3.5	3.3
Control	16	5.2	4.2	4.0	3.8
Control	17	7.7	6.2	6.1	5.7
Control	18	8.0	5.8	6.5	6.0
Control	19	7.7	5.0	6.3	6.2
Chú thích: id là cột chỉ mã số của chuột.					

Chúng ta thấy nồng độ đường (sẽ gọi là glucose) ở cả hai nhóm có xu hướng giảm theo thời gian. Câu hỏi chính là thuốc có ảnh hưởng đến sự thuyên giảm glucose hay không? Cụm từ “ảnh hưởng” ở đây có thể hiểu rõ hơn: nó chính là sự khác biệt (difference) về mức độ giảm glucose giữa hai nhóm chuột. Vì thế, câu hỏi trên có thể diễn giải một cách định lượng như sau: mức độ giảm glucose ở nhóm uống thuốc cao (hay thấp) hơn nhóm chứng hay không?

Thẩm định số liệu

Chúng ta cần một mô hình để mô tả mức độ giảm *cho mỗi con chuột*. Hãy xem xét chuột số 1 ($id = 1$) với các số liệu sau đây (gọi T là thời điểm):

- Trước khi uống thuốc ($T = 0$) thì glucose = 5.9 mmol/L
- Sau khi uống thuốc 2 giờ ($T = 2$), glucose giảm xuống 3.9 (tức giảm 33%)
- Sau khi uống thuốc 3 giờ ($T = 3$), glucose vẫn ở 3.9 (tức giảm 33%)
- Sau khi uống thuốc 4 giờ ($T = 4$), glucose giảm thêm một chút 3.5 (tức giảm 41%)

Nhưng đối với chuột có $id = 9$ thì nồng độ glucose lúc đầu cao hơn (9 mmol/L), và giảm liên tục đến thời điểm 4 giờ sau khi uống thuốc còn 4.6 mmol/L, tức giảm 49%. Chúng ta có thể xem xét qua sự thay đổi nồng độ glucose cho từng chuột bằng biểu đồ 1 sau đây:

nhập số liệu glucose và gọi tên biến của là y :

```
y = c(5.9, 3.9, 3.9, 3.6, 5.3, 4.7, 3.5, 3.2, 4.6, 3.7,
      3.3, 3.2, 6.2, 4.6, 4.3, 3.9, 6.0, 5.4, 5.2, 4.8,
      6.4, 4.7, 4.8, 4.3, 7.6, 4.1, 3.8, 4.1, 5.9, 3.1,
      3.6, 3.3, 7.5, 6.1, 5.4, 4.6, 6.2, 5.3, 4.9, 4.5,
      6.9, 5.6, 5.9, 5.9, 5.6, 4.7, 4.6, 4.0, 5.1, 3.9,
      2.9, 2.9, 5.7, 4.7, 4.3, 4.6, 5.0, 4.0, 3.5, 3.3,
      5.2, 4.2, 4.0, 3.8, 7.7, 6.2, 6.1, 5.7, 8.0, 5.8,
      6.5, 6.0, 7.7, 5.0, 6.3, 6.2)
```

3 lệnh sau đây thực hiện 3 việc:

tạo biến số id

tạo biến số $time$ có giá trị 0,2,3,4 lặp lại 19 lần

tạo biến số $treatment$

```
id = rep(1:19, each=4)
```

```
time = rep(c(0,2,3,4), 19)
```

```
treatment = rep(1:2, c(9*4, 10*4))
```

```
glucose = data.frame(id,treatment, time ,y)
```


```
library(rms)
```

```
library(lattice)
```

```
library(lme4)
```

Vẽ biểu đồ cho từng con chuột

```
xyplot(y ~ time | id, type=c("p","r"), as.table=time,
       xlab="Time", ylab="Glucose")
```



Biểu đồ 1. Nồng độ glucose cho từng con chuột qua từng thời điểm.

Xem xét qua hai trường hợp trên và biểu đồ 1 cho chúng ta thấy hai điểm đáng chú ý: thứ nhất *nồng độ glucose lúc ban đầu* (baseline) khác nhau giữa các chuột; và thứ hai, *tốc độ* (rate) giảm glucose cũng khác nhau giữa các chuột. Chúng ta cần một số kí hiệu để bàn luận về mô hình:

- i là mã số định danh của chuột 1 đến 19 ($i = 1, 2, 3, \dots, 19$);
- y_i là nồng độ glucose đo lường được cho chuột i ;
- a_i là nồng độ glucose trước khi uống thuốc của chuột i ;
- b_i là tốc độ giảm glucose của chuột i .
- Tốc độ giảm glucose tùy thuộc vào thời gian và thời gian **time** có thể tạm kí hiệu bằng T . Ở đây $T = 0, 2, 3$, và 4.

Chúng ta có thể hình dung ra một mô hình để mô tả sự thay đổi nồng độ glucose ở từng con chuột như sau:

$$y_i = a_i + b_i T$$

Mô hình trên phát biểu rằng giá trị glucose đo lường của từng chuột được xác định bằng giá trị lúc ban đầu (chưa can thiệp) và tốc độ thay đổi theo thời gian T . Nhưng ở đây, chúng ta chỉ đo lường nồng độ glucose qua 4 thời điểm, và mỗi lần đo lường đều có độ nhiễu (tức không hoàn toàn chính xác, do kỹ thuật đo lường hay do sự dao động sinh học ở mỗi chuột mà chúng ta chưa biết), cho nên chúng ta cần thêm một thông số khác để cho mô hình hoàn chỉnh hơn. Thông số đó là độ nhiễu và tạm kí hiệu bằng e_i . Bây giờ thì mô hình trên trở thành:

$$y_i = a_i + b_i T + e_i \quad [1]$$

Đây là mô hình hồi qui tuyến tính (linear regression model) mà có lẽ các bạn đã từng biết qua. Đối với chuột id = 1, chúng ta có thể ước tính thông số a và b trên bằng lệnh R như sau:

```
time = c(0, 2, 3, 4)
y = c(5.9, 3.9, 3.9, 3.6)
summary(lm(y ~ time))
```

```
> summary(lm(y ~ time))
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.6171	0.4467	12.574	0.00627 **
time	-0.5743	0.1659	-3.461	0.07428 .

Do đó, $a_1 = 5.6$ và $b_1 = -0.57$. Nói cách khác ước số nồng độ glucose lúc ban đầu của chuột 1 là 5.6 mmol/L, và giảm khoảng 0.57 mmol/L mỗi giờ (60 phút) sau khi uống thuốc. Phân tích tương tự chúng ta sẽ có ước số cho chuột số 9 là: $a_1 = 7.52$ và $b_1 = -0.72$.

```
time = c(0, 2, 3, 4)
y = c(7.5, 6.1, 5.4, 4.6)
summary(lm(y ~ time))
```

```
> summary(lm(y ~ time))
```


Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	7.52000	0.04071	184.73	2.93e-05 ***
time	-0.72000	0.01512	-47.62	0.000441 ***

Biểu đồ 2 sau đây cho chúng ta thấy sự dao động của nồng độ glucose lúc ban đầu cũng như tốc độ thay đổi glucose theo thời gian giữa các chuột:

```
fit = by(glucose, id,
function(data) fitted.values(lm(y ~ time, data=data)))
fit = unlist(fit)
names(fit) = NULL

interaction.plot(time, id, fit, xlab="Time", ylab="Glucose")
```



Biểu đồ 2. Sự dao động về nồng độ glucose cho từng chuột giữa các thời điểm.

Chúng ta thấy rằng thông số a_i , b_i là hai thông số chúng ta quan tâm. Nên nhớ rằng hai thông số này dao động giữa các chuột, cho nên chúng ta cần kí hiệu i để nhắc nhở. Nếu chuột trong nghiên cứu được phân nhóm một cách ngẫu nhiên, chúng ta kì vọng rằng nồng độ trung bình lúc ban đầu (tức trung bình a_i) giữa hai nhóm sẽ không khác nhau, và ảnh hưởng của thuốc chủ yếu được phản ánh qua tốc độ tăng glucose giữa hai nhóm (tức trung bình b_i).

Chúng ta thử kiểm định sự khác biệt giữa hai nhóm bằng phương pháp kiểm định t (qua R) như sau

```
y = c(5.9, 5.3, 4.6, 6.2, 6.0, 6.4, 7.6, 5.9, 7.5,  
      6.2, 6.9, 5.6, 5.1, 5.7, 5.0, 5.2, 7.7, 8.0, 7.7)
```

```
treatment = rep(c(1,0), c(9,10))
```

lệnh trên tạo ra biến số treatment với 2 giá trị 0 để chỉ nhóm chứng gồm 10 chuột, và 1 để chỉ nhóm thuốc gồm 9 chuột

```
t.test(y ~ treatment)
```

```
t = 0.3164, df = 16.849, p-value = 0.7556  
alternative hypothesis: true difference in means is not equal to 0  
95 percent confidence interval:  
-0.876183  1.185072  
sample estimates:  
mean in group 0 mean in group 1  
6.310000      6.155556
```

Chúng ta thấy qua kết quả trên rằng nồng độ glucose lúc ban đầu trong nhóm chứng là 6.31 và nhóm điều trị là 6.16, và độ khác biệt này không có ý nghĩa thống kê ($P = 0.7556$).

15.3 Mô hình tăng trưởng không điều kiện (unconditional linear growth)

Mô hình đơn giản nhất là mô tả tăng trưởng của từng cá nhân, còn gọi là *unconditional growth model*. Xin nhắc lại, qua mô hình [1] chúng ta phát biểu rằng nồng độ glucose ở mỗi chuột i ở một thời điểm T là kết quả của 3 giá trị: (a) nồng độ glucose lúc ban đầu (baseline glucose); (b) tỉ lệ thay đổi tùy theo thời gian T ; và (c) giá trị nhiễu do đo lường và do dao động sinh học mà chúng ta không giải thích được (e_i):

$$y_i = a_i + b_i T + e_i$$

Theo mô hình này: nồng độ glucose của chuột 1, 2, 3, ..., 19 và số liệu ước tính (quan sát) được là:

MÔ HÌNH	QUAN SÁT
$y_1 = a_1 + b_1T + e_1$	$y_1 = 5.62 - 0.57T + e_1$
$y_2 = a_2 + b_2T + e_2$	$y_2 = 5.42 - 0.55T + e_2$
$y_3 = a_3 + b_3T + e_3$	$y_3 = 4.52 - 0.37T + e_3$
...	...
$y_{19} = a_{19} + b_{19}T + e_{19}$	$y_{19} = 7.07 - 0.34T + e_{19}$

Quan sát mô hình trên chúng ta thấy nồng độ glucose lúc ban đầu dao động trong khoảng 5 đến 8 mmol/L, nhưng chúng ta không biết số thật là bao nhiêu. Do đó, chúng ta có thể giả định bằng một mô hình đơn giản rằng nồng độ glucose lúc ban đầu giữa các chuột bằng một số trung bình cộng (hay trừ) độ khác biệt giữa các chuột với số trung bình đó. Gọi số trung bình là A , và u là độ khác biệt của a_i so với A , chúng ta có:

$$a_i = A + u \quad [2]$$

Bởi vì tốc độ biến đổi (giảm) glucose cũng dao động giữa các chuột, do đó chúng ta cũng có thể giả định rằng tốc độ trung bình là B , và độ khác biệt giữa b_i là B là v :

$$b_i = B + v \quad [3]$$

Thay thế [2] và [3] vào phương trình [1] chúng ta có (tôi viết lại phương trình 1 để dễ theo dõi):

$$y_i = a_i + b_iT + e_i \quad [1]$$

$$y_i = (A + u) + (B + v)T + e_i$$

Sắp xếp lại phương trình trên cho gọn, chúng ta có:

$$y_i = (A + BT) + (u + vT + e_i) \quad [4]$$

Thấy gì qua phương trình trên? Phương trình có 2 phần: phần đầu, $(A + BT)$, là phần mà giới thống kê học gọi là “fixed effects” (ảnh hưởng cố định - thuật ngữ không mấy chính xác nhưng chúng ta tạm hiểu là ảnh hưởng không ngẫu nhiên); phần hai, $(u + vT + e_i)$, là phần “random effects” (ảnh hưởng ngẫu nhiên). Sở dĩ gọi ảnh hưởng ngẫu nhiên là vì u , v và e đều là các thông số phản ánh độ nhiễu (noise) của mô hình. Các thông số trong phương trình này có ý nghĩa như sau:

- A là nồng độ glucose trung bình lúc ban đầu (trước khi uống thuốc) của quần thể các chuột được nghiên cứu;
- B là tốc độ trung bình (tỉ lệ giảm nồng độ glucose) tính trên mỗi giờ của các chuột trong nghiên cứu;
- u phản ánh độ dao động về nồng độ glucose lúc ban đầu giữa các chuột;
- v cho chúng ta biết độ dao động về tốc độ giảm glucose giữa các chuột; và
- e_i là độ dao động ở mỗi chuột.

Mô hình sinh học nào cũng có giả định. Trong mô hình [4] trên, chúng ta giả định rằng:

- u tuân theo luật phân phối chuẩn (normal distribution) với số trung bình bằng 0 và phương sai u^2 . Viết theo kí hiệu thống kê học là: $u \sim N(0, u^2)$.
- v tuân theo luật phân phối chuẩn (normal distribution) với số trung bình bằng 0 và phương sai v^2 , hay $v \sim N(0, v^2)$.
- e_i cũng theo luật phân phối tương tự: $e_i \sim N(0, e^2)$

Tại sao 0? Tại vì chúng ta giả định rằng tính trung bình, các độ nhiễu bằng 0 để giá trị trung bình (expected value hay giá trị kì vọng) của mô hình [4] là (kí hiệu E có nghĩa là *expected*, hay nói nôm na là “tính trung bình”):

$$E(y_i) = (A + BT) + (0 + 0T + 0)$$

$$E(y_i) = A + BT$$

Chúng ta sẽ triển khai và ước tính các thông số trong mô hình [4] bằng R. Nhắc lại, mô hình [4]. Trước hết, chúng ta đọc dữ liệu glucose và tạo ra một dataframe tạm gọi là glucose:

```
y = c(5.9, 3.9, 3.9, 3.6, 5.3, 4.7, 3.5, 3.2, 4.6, 3.7,
      3.3, 3.2, 6.2, 4.6, 4.3, 3.9, 6.0, 5.4, 5.2, 4.8,
      6.4, 4.7, 4.8, 4.3, 7.6, 4.1, 3.8, 4.1, 5.9, 3.1,
      3.6, 3.3, 7.5, 6.1, 5.4, 4.6, 6.2, 5.3, 4.9, 4.5,
      6.9, 5.6, 5.9, 5.9, 5.6, 4.7, 4.6, 4.0, 5.1, 3.9,
      2.9, 2.9, 5.7, 4.7, 4.3, 4.6, 5.0, 4.0, 3.5, 3.3,
      5.2, 4.2, 4.0, 3.8, 7.7, 6.2, 6.1, 5.7, 8.0, 5.8,
      6.5, 6.0, 7.7, 5.0, 6.3, 6.2)
id = rep(1:19, each=4)
time = rep(c(0,2,3,4), 19)
treatment = rep(1:2, c(9*4, 10*4))
glucose = data.frame(id,treatment, time ,y)
```

Đối với mô hình [4],

$$y_i = (A + BT) + (u + vT + e_i)$$

các mã R sau đây có thể sử dụng để phân tích:

```
library(lme4)
fit1 = lmer(y ~ 1 + time + (1 + time | id), data=glucose,
REML=0)
summary(fit1)
```

Chú ý hàm lmer được mô phỏng theo cách viết 2 phần: phần đầu là fixed effects, và phần 2 (trong ngoặc) là random effects. Khi viết “1 + time” chúng ta có thể hiểu đó là “intercept + time” (hay $A + B \cdot \text{time}$). Kết quả của mô hình này như sau:

Random effects:				
Groups	Name	Variance	Std.Dev.	Corr
id	(Intercept)	0.6581762	0.8113	
	time	0.0007453	0.0273	1.00
	Residual	0.2481143	0.4981	
Number of obs: 76, groups: id, 19				
Fixed effects:				
	Estimate	Std. Error	t value	
(Intercept)	6.05038	0.21322	28.38	
time	-0.48496	0.03914	-12.39	
Correlation of Fixed Effects:				
	(Intr)			
time	-0.263			

Chú ý kết quả được chia thành 3 phần: phần random effects, phần fixed effects, và phần tương quan giữa các thông số fixed effects.

Chúng ta tập trung vào phần fixed effects trước. Ước số $\text{time} = -0.485$ chính là B trong phần BT của mô hình trên. Ngoài ra, $\text{intercept} = 6.05$ chính là ước số của A trong mô hình trên. Nói cách khác, mô hình [4] bây giờ là (phần fixed effects):

$$y_i = 6.05 - 0.485T$$

Mô hình này cho biết nồng độ glucose *trung bình* của quần thể là 6.05 mmol/L và tốc độ giảm 0.485 mmol/L sau mỗi giờ theo dõi.

Tuy nhiên, đó chỉ là phần fixed effects; chúng ta còn một phần random effects, và R cung cấp các kết quả:

Random effects:

Groups	Name	Variance	Std.Dev.	Corr
id	(Intercept)	0.6581762	0.8113	
	time	0.0007453	0.0273	1.00
Residual		0.2481143	0.4981	

Các kết quả trên đây có thể diễn giải như sau (theo mô hình [4]):

- Phương sai $v^2 = 0.658$ (tức $\text{var}(\text{intercept}) = 0.658$) phản ánh độ dao động về nồng độ glucose lúc ban đầu (trước khi can thiệp) giữa các chuột. Như chúng ta có thể đoán được, có sự khác biệt giữa các chuột về nồng độ glucose, nên chúng ta không ngạc nhiên khi thấy khoảng tin cậy 95% có ý nghĩa thống kê;
- Phương sai $u^2 = 0.00075$ (tức $\text{var}(\text{time}) = 0.00075$) phản ánh độ dao động về tốc độ giảm glucose giữa các chuột. Như có thể thấy qua ước số này, độ dao động về tốc độ không khác nhau đáng kể giữa chuột;

Dòng Residual = 0.248 (chính là ước số của $e^2 = 0.248$), phản ánh độ dao động nồng độ glucose ở mỗi chuột.

15.4 Mô hình ảnh hưởng của điều trị (conditional growth model)

Chúng ta để ý thấy trong mô hình [4] không có biến số nào liên quan đến điều trị! Đó là vì mô hình căn bản. Bây giờ chúng ta thử xem qua lí giải trong phương trình [2] và [3]:

$$a_i = A + u$$

$$b_i = B + v$$

Chúng ta muốn có khác biệt đáng kể về nồng độ glucose lúc ban đầu (a_i) giữa hai nhóm chuột, do đó phương trình [2] trở thành:

$$a_i = A_0 + A_1 \times \text{treatment} + u$$

Ngoài ra, có thể có sự khác biệt về tốc độ giảm glucose giữa hai nhóm (b_i), và chúng ta cần tìm hiểu mức độ khác biệt hay ảnh hưởng này. Một cách để biết ảnh hưởng của điều trị là viết lại phương trình [3] thành:

$$b_i = B_0 + B_1 \times \text{treatment} + v$$

Do đó, mô hình [1] trở thành:

$$y_i = a_i + b_i T + e_i \quad [1]$$

$$y_i = (A_0 + A_1 \times \text{treatment} + u) + (B_0 + B_1 \times \text{treatment} + v)T + e_i$$

$$y_i = (A_0 + A_1 \times \text{treatment} + B_0 T + B_1 \times \text{treatment} \times T) + (u + vT + e_i) \quad [5]$$

Đây là mô hình chính của nghiên cứu. Trong mô hình trên, ngoài các thông số khác đã giải thích, chúng ta thấy có hai thông số mới và ý nghĩa của 2 thông số này như sau:

- $A_1 \times \text{treatment}$ phản ánh sự khác biệt nồng độ glucose lúc ban đầu giữa hai nhóm chuột;
- $B_1 \times \text{treatment} \times T$ phản ánh mức độ khác biệt về tốc độ giảm glucose giữa hai nhóm chuột; do đó, chính là kiểm định thống kê cho giả thuyết của nghiên cứu.

Bây giờ, chúng ta sẽ dùng lme4 để ước tính các thông số trong mô hình [5].

```
fit2 = lmer(y ~ 1 + treatment + time + time:treatment +
(1+time|id), data=glucose, REML=0)

summary(fit2)
```

Kết quả như sau:

Random effects:				
Groups	Name	Varlance	Std.Dev.	Corr
id	(Intercept)	6.878e-01	0.829313	
	time	5.157e-06	0.002271	1.00
Residual		2.299e-01	0.479518	
Number of obs: 76, groups: id, 19				
Fixed effects:				
	Estimate	Std. Error	t value	
(Intercept)	5.81683	0.69150	8.412	
treatment	0.15302	0.43060	0.355	
time	-0.74032	0.11962	-6.189	
treatment:time	0.16730	0.07449	2.246	
Correlation of Fixed Effects:				
	(Intr)	trtmnt	time	
treatment	-0.950			
time	-0.377	0.358		
trtmnt:tm	0.358	-0.377	-0.950	

Đối chiếu với mô hình [5], các thông số trên như sau:

$y_i = (A_0 + A_1 \times \text{treatment} + B_0 T + B_1 \times \text{treatment} \times T) + (u + vT + e)$		
THÔNG SỐ	Ý NGHĨA	ƯỚC SỐ
A_0	Nồng độ trung bình glucose lúc ban đầu của quần thể	5.82
A_1	Khác biệt về nồng độ glucose lúc ban đầu giữa hai nhóm	0.15
B_0	Ảnh hưởng của thời gian (time) đến sự giảm glucose	-0.74
B_1	Khác biệt về tốc độ giảm glucose giữa hai nhóm	0.17

Do đó, mô hình [5] trở thành:

$$y_i = 5.82 + 0.15 \times \text{treatment} - 0.74 \times \text{time} + 0.17 \times \text{treatment} \times \text{time}$$

Nên nhớ rằng chúng ta gọi **treatment = 1** chỉ thuốc và **treatment = 2** chỉ nhóm chứng, và **time** có 4 giá trị: 0, 2, 3, và 4. Cho nên, mô hình mô tả sự dao động của glucose trong nhóm được điều trị bằng thuốc là:

$$y_1 = 5.82 + 0.15 \times 1 - 0.74 \times \text{time} + 0.17 \times 1 \times \text{time}$$

$$y_1 = 5.97 - 0.57 \times \text{time}$$

và cho nhóm chứng là:

$$y_2 = 5.82 + 0.15 \times 2 - 0.74 \times \text{time} + 0.17 \times 2 \times \text{time}$$

$$y_2 = 6.12 - 0.40 \times \text{time}$$

Như vậy, hai nhóm có nồng độ glucose khởi đầu giống nhau (5.97 và 6.12 và $P = 0.74$), nhưng tốc độ giảm glucose của nhóm thuốc là 0.57 mmol/L/giờ, cao hơn nhóm chứng 0.40 mmol/L/giờ, và sự khác biệt này có ý nghĩa thống kê ($P = 0.027$). Do đó, qua kết quả này, chúng ta có thể kết luận rằng thuốc có hiệu quả giảm glucose cao hơn nhóm không được điều trị.

Thông số B_0 (tức tốc độ trung bình giảm glucose của quần thể) không có ý nghĩa ở đây, bởi vì có sự tương tác giữa hai nhóm và thời gian.

Bây giờ chúng ta thử xét qua phần random effects:

Random effects:				
Groups	Name	Variance	Std.Dev.	Corr
id	(Intercept)	6.878e-01	0.829313	
	time	5.157e-06	0.002271	1.00
Residual		2.299e-01	0.479518	
Number of obs: 76, groups: id, 19				

Chúng ta có thể so sánh các thông số trong mô hình này với mô hình trước như sau:

PHƯƠNG SAI (VARIANCE)	MÔ HÌNH [4]	MÔ HÌNH [5]
u^2 : độ dao động về tốc độ giảm glucose giữa các chuột	0.00075	0.0000051
v^2 : độ dao động về nồng độ glucose lúc ban đầu	0.658	0.687
e^2 : độ dao động nồng độ glucose ở mỗi chuột	0.248	0.230

Chúng ta chú ý trong so sánh trên, mô hình [4] có 2 thông số cố định, nhưng mô hình [5] có 4 thông số cố định. Do đó, chúng ta không ngạc nhiên khi mô hình [5] tốt hơn mô hình [4]. Sự “tốt hơn” đó có thể thấy qua e^2 , giảm từ 0.248 xuống 0.230 hay giảm 6%. Một sự giảm thiểu khiêm tốn nhưng vẫn có ý nghĩa.

Tóm lại

Các phân tích trên đây cho thấy thuốc có hiệu quả giảm nồng độ glucose trong máu. Mức độ giảm glucose tăng theo thời gian và có ý nghĩa thống kê, dù mức độ ảnh hưởng có phần khiêm tốn.

Trong quá khứ, chúng ta thường sử dụng phương pháp “repeated ANOVA” để phân tích các số liệu được đo nhiều lần ở một đối tượng nghiên cứu. Nhưng phương pháp đó có một số vấn đề về kỹ thuật tính toán và giả định, cho nên không còn được xem là phương pháp chuẩn nữa.

Ngày nay, với R, mô hình ảnh hưởng hỗn hợp được xem là một trong những mô hình phổ biến nhất và thích hợp nhất cho phân tích các thí nghiệm như vừa mô tả. Như trình bày ở phần trên vấn đề chủ yếu trong việc phân tích số liệu không phải là tính toán (vì đã có phần mềm máy tính), đó là những suy nghĩ và mô hình cho dữ liệu. Những suy nghĩ này phải xuất phát từ tình hình thực tế và quan trọng hơn hết là kiến thức sinh học. Ngoài ra, cũng cần phải xem xét các thông số cần thận để thẩm định tính phù hợp của các thông số cho từng trường hợp cụ thể.

Có lẽ một số bạn cảm thấy nao núng trước những lí giải và công thức trong mô hình phân tích trên, nhưng quả thật mô hình rất đơn giản. Chúng ta muốn có câu trả lời cho câu hỏi: sự giảm nồng độ glucose có khác biệt giữa hai nhóm chuột hay không? Từ câu hỏi đó, chúng ta đặt ra một số mô hình để mô tả dữ liệu. Mô hình mà không có ý nghĩa sinh học chỉ là những mô hình toán học, và theo tôi, những mô hình như thế chẳng có lợi ích gì cho khoa học hay y học lâm sàng.

Khoa học là hành trình đi tìm câu hỏi và câu trả lời. Các phân tích trên đây thật ra còn khá đơn giản. Còn một số câu hỏi khác cũng cần được đặt ra. Chẳng hạn như có nên hoán chuyển số liệu sang log để phân tích hay phân tích theo số liệu gốc (mmol/L)? Nếu có thông tin khác về đặc điểm sinh học của từng chuột, các đặc điểm này có ảnh hưởng gì đến ảnh hưởng của thuốc? Tuy nhiên, hiện nay với một thí nghiệm đơn giản như thế tôi nghĩ rằng mô hình trên cũng thích hợp và đầy đủ. Hi vọng lần sau chúng ta sẽ quay lại với một mô hình ảnh hưởng hỗn hợp khác.

16 Phân tích tổng hợp

Một vấn đề khoa học cần đến nhiều nghiên cứu. Một nghiên cứu riêng lẻ không thể giải quyết hay cung cấp câu trả lời dứt khoát cho một vấn đề khoa học. Nhu cầu lặp lại nghiên cứu trong điều kiện khác nhau rất quan trọng trong hoạt động khoa học. Trong nghiên cứu khoa học nói chung và y học nói riêng, nhiều khi chúng ta cần phải xem xét nhiều kết quả nghiên cứu từ nhiều nguồn khác nhau để giải quyết một vấn đề cụ thể.

16.1 Nhu cầu cho phân tích tổng hợp

Trong những năm gần đây, trong nghiên cứu khoa học xuất hiện khá nhiều nghiên cứu dưới danh mục “meta-analysis”, tạm dịch là “phân tích tổng hợp”. Vậy phân tích tổng hợp là gì, mục đích, và cách tiến hành ra sao là những câu hỏi mà rất nhiều bạn đọc muốn biết. Chương này tôi sẽ mô tả vài khái niệm và cách tiến hành một phân tích tổng hợp, với hi vọng bạn đọc có thể tự mình làm một phân tích mà không cần đến các phần mềm đắt tiền.

Nguồn gốc và ý tưởng tổng hợp dữ liệu khởi đầu từ thế kỉ 17. Thời đó, các nhà thiên văn học nghĩ rằng cần phải hệ thống hóa dữ liệu từ nhiều nguồn để có thể đi đến một quyết định chính xác và hợp lí hơn các nghiên cứu riêng lẻ. Nhưng phương pháp phân tích tổng hợp hiện đại phải nói là bắt đầu từ hơn nửa thế kỉ trước trong ngành tâm lí học. Năm 1952, nhà tâm lí học Hans J. Eysenck tuyên bố rằng tâm lí trị liệu (psychotherapy) chẳng có hiệu quả gì cả. Hơn hai mươi năm sau, năm 1976, Gene V. Glass, một nhà tâm lí học người Mỹ, muốn chứng minh rằng Eysenck sai, nên ông tìm cách thu thập dữ

liệu của hơn 375 nghiên cứu về tâm lý trị liệu trong quá khứ, và tiến hành tổng hợp chúng bằng một phương pháp mà ông đặt tên là “meta-analysis” [1]. Qua phương pháp phân tích này, Glass tuyên bố rằng tâm lý trị liệu có hiệu quả và giúp ích cho bệnh nhân.

Phân tích tổng hợp - hay meta-analysis - từ đó được các bộ môn khoa học khác, nhất là y học, ứng dụng để giải quyết các vấn đề như hiệu quả của thuốc trong việc điều trị bệnh nhân. Cho đến nay, các phương pháp phân tích tổng hợp đã phát triển một bước dài, và trở thành một phương pháp chuẩn để thẩm định các vấn đề gai góc, các vấn đề mà sự nhất trí giữa các nhà khoa học vẫn chưa đạt được. Có người xem phân tích tổng hợp có thể cung cấp một câu trả lời sau cùng cho một câu hỏi y học. Tuy phát biểu này quá lạc quan, nhưng phân tích tổng hợp là một phương pháp rất có ích cho chúng ta giải quyết những vấn đề còn trong vòng tranh cãi. Phân tích tổng hợp cũng có thể giúp cho chúng ta nhận ra những lĩnh vực nào cần phải nghiên cứu thêm hay cần thêm bằng chứng.

Kết quả của mỗi nghiên cứu đơn lẻ thường được đánh giá hoặc là “tích cực” (tức là, chẳng hạn như, thuật điều trị có hiệu quả), hoặc là “tiêu cực” (tức là thuật điều trị không có hiệu quả), và sự đánh giá này dựa vào trị số P. Thuật ngữ tiếng Anh gọi qui trình đó là “significance testing” - thử nghiệm ý nghĩa thống kê. Nhưng ý nghĩa thống kê tùy thuộc vào số mẫu được chọn trong nghiên cứu, và một kết quả “tiêu cực” không có nghĩa là giả thiết của nghiên cứu sai, mà có thể đó là tín hiệu cho thấy số lượng mẫu chưa đầy đủ để đi đến một kết luận đáng tin cậy. Cái logic của phân tích tổng hợp, do đó, là chuyển hướng từ **significance testing** sang ước tính **effect size** - mức độ ảnh hưởng. Câu trả lời mà phân tích tổng hợp muốn đưa ra không chỉ đơn giản là có hay không có ý nghĩa thống kê (significant hay insignificant) mà là mức độ ảnh hưởng bao nhiêu, có đáng để chúng ta quan tâm, có thích hợp để chúng ta ứng dụng vào thực tế hay không.

16.2 Fixed-effects và Random-effects

Hai thuật ngữ mà bạn đọc thường gặp trong các phân tích tổng hợp là fixed-effects (tạm dịch là **ảnh hưởng bất biến**) và random-effects (**ảnh hưởng biến thiên**). Để hiểu hai thuật ngữ này chúng ta sẽ xem xét một ví dụ tương đối đơn giản. Hãy tưởng tượng chúng ta muốn ước tính chiều cao của người Việt Nam trong độ tuổi trưởng thành (18 tuổi trở lên). Chúng ta có thể tiến hành 100 nghiên cứu tại nhiều địa điểm khác nhau trên toàn quốc;

mỗi nghiên cứu chọn mẫu (samples) một cách ngẫu nhiên từ 10 người đến vài chục ngàn người; và cứ mỗi nghiên cứu chúng ta tính toán chiều cao trung bình. Như vậy, chúng ta có 100 số trung bình, và chắc chắn những con số này không giống nhau: một số nghiên cứu có chiều cao trung bình thấp, cao hay... trung bình. Phân tích tổng hợp là nhằm mục đích sử dụng 100 số trung bình đó để ước tính chiều cao cho toàn thể người Việt. Có hai cách để ước tính: fixed-effects meta-analysis (phân tích tổng hợp ảnh hưởng bất biến) và random-effects meta-analysis (phân tích tổng hợp ảnh hưởng biến thiên) [2].

Phân tích tổng hợp ảnh hưởng bất biến xem sự khác biệt giữa 100 con số trung bình đó là do các yếu tố ngẫu nhiên liên quan đến mỗi nghiên cứu (còn gọi là within-study variance) gây nên. Cái giả định đằng sau cách nhận thức này là: nếu 100 nghiên cứu đó đều được tiến hành giống nhau (như có cùng số lượng đối tượng, cùng độ tuổi, cùng tỉ lệ giới tính, cùng chế độ dinh dưỡng, v.v...) thì sẽ không có sự khác biệt giữa các số trung bình.

Nếu chúng ta gọi số trung bình của 100 nghiên cứu đó là $x_1, x_2, \dots, x_{100}$, quan điểm của phân tích tổng hợp ảnh hưởng bất biến cho rằng mỗi x_i là một biến số gồm hai phần: một phần phản ánh số trung bình của toàn bộ quần thể dân số (tạm gọi là M), và phần còn lại (khác biệt giữa x_i và M) là một biến số e_i . Nói cách khác:

$$\begin{aligned}x_1 &= M + e_1 \\x_2 &= M + e_2 \\&\dots \\x_{100} &= M + e_{100}\end{aligned}$$

Hay nói chung là:

$$x_i = M + e_i$$

Tất nhiên e_i có thể <0 hay >0 . Nếu M và e_i độc lập với nhau (tức không có tương quan gì với nhau) thì phương sai của x_i (gọi là $\text{var}[x_i]$) có thể viết như sau:

$$\text{var}[x_i] = \text{var}[M] + \text{var}[e_i] = 0 + s_e^2$$

Chú ý $\text{var}[M] = 0$ vì M là một hằng số bất biến, s_e^2 là phương sai của e_i . Mục đích của phân tích tổng hợp là ước tính M và s_e^2 .

Phân tích tổng hợp ảnh hưởng biến thiên xem mức độ khác biệt (còn gọi là variance hay phương sai) giữa các số trung bình là do hai nhóm yếu tố gây nên: các yếu tố liên quan đến mỗi nghiên cứu (within-study variance) và các yếu tố giữa các nghiên cứu (between-study variance). Các yếu tố khác biệt giữa các nghiên cứu như địa điểm, độ tuổi, giới tính, dinh dưỡng, v.v... cần phải được xem xét và phân tích. Nói cách khác, phân tích tổng hợp ảnh hưởng biến thiên đi xa hơn phân tích tổng hợp ảnh hưởng bất biến một bước bằng cách xem xét đến những khác biệt giữa các nghiên cứu. Do đó, kết quả từ phân tích tổng hợp ảnh hưởng biến thiên thường “bảo thủ” hơn các phân tích tổng hợp ảnh hưởng bất biến.

Quan điểm của phân tích tổng hợp ảnh hưởng biến thiên cho rằng mỗi nghiên cứu có một giá trị trung bình cá biệt phải ước tính, gọi là m_i . Do đó, x_i là một biến số gồm hai phần: một phần phản ánh số trung bình của quần thể mà mẫu được chọn (m_i , chú ý ở đây có chỉ từ i để chỉ một nghiên cứu riêng lẻ i), và phần còn lại (khác biệt giữa x_i và m_i) là một biến số e_i . Ngoài ra, phân tích tổng hợp ảnh hưởng biến thiên còn phát biểu rằng m_i dao động chung quanh số tổng trung bình M bằng một biến ngẫu nhiên ε_i . Nói cách khác:

$$x_i = m_i + e_i$$

Trong đó:

$$m_i = M + \varepsilon_i$$

Do đó:

$$x_i = M + \varepsilon_i + e_i$$

Và phương sai của x_i bây giờ có hai thành phần:

$$\text{var}[x_i] = \text{var}[M] + \text{var}[\varepsilon_i] + \text{var}[e_i] = 0 + s_\varepsilon^2 + s_e^2$$

Như ta thấy qua công thức này, s_e^2 phản ánh độ dao động giữa các nghiên cứu (between-study variation), còn s_ε^2 phản ánh độ dao động trong mỗi nghiên cứu (within-study variation). Mục đích của phân tích tổng hợp ảnh hưởng biến thiên là ước tính M , s_ε^2 và s_e^2 .

Nói tóm lại, Phân tích tổng hợp ảnh hưởng bất biến và Phân tích tổng hợp ảnh hưởng biến thiên chỉ khác nhau ở phương sai. Trong khi phân tích tổng hợp bất biến xem $s_e^2 = 0$, thì phân tích tổng hợp biến thiên đặt yêu cầu phải ước tính s_e^2 . Tất nhiên, nếu $s_e^2 = 0$ thì kết quả của hai phân tích này giống nhau. Trong bài này tôi sẽ tập trung vào cách phân tích tổng hợp ảnh hưởng bất biến.

16.3 Qui trình của một phân tích tổng hợp

Cũng như bất cứ nghiên cứu nào, một phân tích tổng hợp được tiến hành qua các công đoạn như: thu thập dữ liệu, kiểm tra dữ liệu, phân tích dữ liệu, và kiểm tra kết quả phân tích.

- Bước thứ nhất: sử dụng hệ thống thư viện y khoa PubMed hay một hệ thống thư viện khoa học của chuyên ngành để tìm những bài báo liên quan đến vấn đề cần nghiên cứu. Bởi vì có nhiều nghiên cứu, vì lí do nào đó (như kết quả “tiêu cực” chẳng hạn), không được công bố, cho nên nhà nghiên cứu có khi cũng cần phải thu thập các nghiên cứu đó. Việc làm này tuy nói thì dễ, nhưng trong thực tế không dễ dàng chút nào!
- Bước thứ hai: rà soát xem trong số các nghiên cứu được truy tìm đó, có bao nhiêu đạt các tiêu chuẩn đã được đề ra. Các tiêu chuẩn này có thể là đối tượng bệnh nhân, tình trạng bệnh, độ tuổi, giới tính, tiêu chí, v.v... Chẳng hạn như trong số hàng trăm nghiên cứu về ảnh hưởng của vitamin D đến loãng xương, có thể chỉ vài chục nghiên cứu đạt tiêu chuẩn như đối tượng phải là phụ nữ sau thời kỳ mãn kinh, mật độ xương thấp, phải là nghiên cứu lâm sàng đối chứng ngẫu nhiên (randomized controlled clinical trials - RCT), tiêu chí phải là gãy xương đùi, v.v... (Những tiêu chuẩn này phải được đề ra trước khi tiến hành nghiên cứu).
- Bước thứ ba: chiết số liệu và dữ kiện (data extraction). Sau khi đã xác định được đối tượng nghiên cứu, bước kế tiếp là phải lên kế hoạch chiết số liệu từ các nghiên cứu đó. Chẳng hạn như nếu là các nghiên cứu RCT, chúng ta phải tìm cho được số liệu cho hai nhóm can thiệp và đối chứng. Có khi các số liệu này không được công bố hay trình bày trong bài báo, và trong trường hợp đó, nhà nghiên cứu phải trực tiếp liên lạc với tác giả để tìm số liệu. Một bảng tóm lược kết quả nghiên cứu có thể tương tự như **Bảng 1** dưới đây.
- Bước thứ tư: tiến hành phân tích thống kê. Trong bước này, mục đích là ước tính mức độ ảnh hưởng chung cho tất cả nghiên cứu và độ dao động của ảnh hưởng đó. Phần dưới đây sẽ giải thích cụ thể cách làm.
- Bước thứ năm: xem xét các kết quả phân tích, và tính toán thêm một số chỉ tiêu khác để đánh giá độ tin cậy của kết quả phân tích.

Cũng như phân tích thống kê cho từng nghiên cứu riêng lẻ tùy thuộc vào loại tiêu chí (như là biến số liên tục - continuous variables - hay biến số nhị phân - dichotomous variables), phương pháp phân tích tổng hợp cũng tùy thuộc vào các tiêu chí của nghiên cứu. Chúng ta sẽ lần lượt mô tả hai phương pháp chính cho hai loại biến số liên tục và nhị phân.

16.4 Phân tích tổng hợp ảnh hưởng bất biến cho một tiêu chí liên tục (Fixed-effects meta-analysis for a continuous outcome)

16.4.1 Phân tích tổng hợp bằng tính toán “thủ công”

Ví dụ 1: Thời gian nằm viện để điều trị ở các bệnh nhân đột quỵ là một tiêu chí quan trọng trong việc vạch định chính sách tài chính. Các nhà nghiên cứu muốn biết sự khác biệt về thời gian nằm viện giữa hai nhóm bệnh viện chuyên khoa và bệnh viện đa khoa. Các nhà nghiên cứu rà soát và thu thập số liệu từ 9 nghiên cứu như sau (xem **Bảng 1**). Một số nghiên cứu cho thấy thời gian nằm viện trong các bệnh viện chuyên khoa ngắn hơn các bệnh viện đa khoa (như nghiên cứu 1, 2, 3, 4, 5, 8), một số nghiên cứu khác cho thấy ngược lại (như nghiên cứu 7 và 9). Vấn đề đặt ra là các số liệu này có phù hợp với giả thiết bệnh nhân các bệnh viện chuyên khoa thường có thời gian nằm viện ngắn hơn các bệnh viện đa khoa hay không. Chúng ta có thể trả lời câu hỏi này qua các bước sau đây:

Bước 1: Tóm lược dữ liệu trong một bảng thống kê như sau:

Bảng 1. Thời gian nằm bệnh viện của các bệnh nhân đột quỵ trong hai nhóm bệnh viện chuyên khoa và đa khoa

NGHIÊN CỨU (i)	BỆNH VIỆN CHUYÊN KHOA			BỆNH VIỆN ĐA KHOA		
	N_{1i}	LOS_{1i}	SD_{1i}	N_{2i}	LOS_{2i}	SD_{2i}
1	155	55	47	156	75	64
2	31	27	7	32	29	4
3	75	64	17	71	119	29
4	18	66	20	18	137	48
5	8	14	8	13	18	11
6	57	19	7	52	18	4
7	34	52	45	33	41	34
8	110	21	16	183	31	27
9	60	30	27	52	23	20
Tổng cộng	548			610		

Chú thích: Trong bảng này, i là chỉ số chỉ mỗi nghiên cứu, $i = 1, 2, \dots, 9$. N_1 và N_2 là số bệnh nhân nghiên cứu cho từng nhóm bệnh viện; LOS_1 và LOS_2 (length of stay): thời gian trung bình nằm viện (tính bằng ngày); SD_1 và SD_2 : độ lệch chuẩn (standard deviation) của thời gian nằm viện.

Bước 2: Ước tính mức độ khác biệt trung bình và phương sai (variance) cho từng nghiên cứu. Mỗi nghiên cứu ước tính một độ ảnh hưởng, hay nói chính xác hơn là khác biệt về thời gian nằm viện kí hiệu, và chúng ta sẽ đặt kí hiệu là d_i . Chỉ số ảnh hưởng này chỉ đơn giản là:

$$d_i = LOS_{1i} - LOS_{2i}$$

Phương sai của d_i (tôi sẽ kí hiệu là s_i^2) được ước tính bằng một công thức chuẩn dựa vào độ lệch chuẩn và số đối tượng trong từng nghiên cứu. Với mỗi nghiên cứu i ($i = 1, 2, 3, \dots, 9$), chúng ta có:

$$s_i^2 = \frac{(N_{1i} - 1)SD_{1i}^2 + (N_{2i} - 1)SD_{2i}^2}{N_{1i} + N_{2i} - 2} \left(\frac{1}{N_{1i}} + \frac{1}{N_{2i}} \right)$$

Chẳng hạn như với nghiên cứu 1, chúng ta có:

$$d_1 = 75 - 55 = 20$$

và phương sai của d_1 :

$$s_1^2 = \frac{(155 - 1)(47)^2 + (156 - 1)(64)^2}{155 + 156 - 2} \left(\frac{1}{155} + \frac{1}{156} \right) = 40.59$$

hay độ lệch chuẩn: $s_1 = \sqrt{40.59} = 6.37$

Với độ lệch chuẩn s_i chúng ta có thể ước tính khoảng tin cậy 95% (95% confidence interval hay 95%CI) cho d_i bằng lí thuyết phân phối chuẩn (Normal distribution). Cần nhắc lại rằng, nếu một biến số tuân theo định luật phân phối chuẩn thì 95% các giá trị của biến số sẽ nằm trong khoảng $\pm 1,96$ lần độ lệch chuẩn. Do đó, khoảng tin cậy 95% cho mức độ khác biệt của nghiên cứu 1 là:

$$d_i - 1.96*s_i = 20 - 1.96*6.37 = 7.71 \text{ ngày}$$

đến


$$d_i + 1.96*s_i = 20 + 1.96*6.37 = 32.49 \text{ ngày}$$

Tiếp tục tính như thế cho các nghiên cứu khác, chúng ta sẽ có thêm bốn cột trong bảng sau đây:

Bảng 1a. Độ khác biệt về thời gian giữa hai nhóm và khoảng tin cậy 95%

NGHIÊN CỨU (I)	d_i	s_i^2	s_i	$d_i - 1.96 \cdot s_i$	$d_i + 1.96 \cdot s_i$
1	20	40.6	6.37	7.51	32.49
2	2	2.0	1.43	-0.80	4.80
3	55	15.3	3.91	47.34	62.66
4	71	150.2	12.26	46.98	95.02
5	4	20.2	4.49	-4.81	12.81
6	-1	1.2	1.11	-3.17	1.17
7	-11	95.4	9.77	-30.14	8.14
8	10	8.0	2.83	4.45	15.55
9	-7	20.7	4.55	-15.92	1.92

Đến đây chúng ta có thể thể hiện mức độ ảnh hưởng d_i và khoảng tin cậy 95% trong một biểu đồ có tên là “**forest plot**” như sau:



Biểu đồ forest thể hiện giá trị của d_i và khoảng tin cậy 95%. Mức độ ảnh hưởng d_i ghi nhận từ nghiên cứu 5, 7 và 9 được xem là không có ý nghĩa thống kê, vì khoảng tin cậy 95% vượt qua cột mốc 0.

Bước 3: Ước tính “trọng số” (weight) cho mỗi nghiên cứu. Trọng số (W_i) thực ra chỉ là số đảo của phương sai s_i^2 ,

$$W_i = 1 / s_i^2$$

Chẳng hạn như với nghiên cứu 1, chúng ta có: $W_1 = \frac{1}{40.59} = 0.0246$

Và chúng ta có thêm một cột mới cho bảng trên như sau:

Bảng 1b. Trọng số (weight) cho từng nghiên cứu

NGHIÊN CỨU	d_i	s_i^2	W_i
1	20	40.6	0.0246
2	2	2.0	0.4886
3	55	15.3	0.0654
4	71	150.2	0.0067
5	4	20.2	0.0495
6	-1	1.2	0.8173
7	-11	95.4	0.0105
8	10	8.0	0.1245
9	-7	20.7	0.0483
Tổng số			1.6354

Bước 4: Ước tính trị số trung bình của d cho tất cả các nghiên cứu. Chúng ta có thể đơn giản tính trung bình d bằng cách cộng tất cả d_i và chia cho 9, nhưng cách tính như thế không khách quan, bởi vì mỗi giá trị d_i có một phương sai và trọng số (W_i) cá biệt. Chẳng hạn như nghiên cứu 4, vì phương sai cao nhất (150.2), chúng tỏ rằng nghiên cứu này có số đối tượng ít hay độ dao động rất cao, và độ dao động cao có nghĩa là chúng ta không đặt “niềm tin cậy” vào đó cao được. Chính vì thế mà trọng số cho nghiên cứu này rất thấp, chỉ 0.0067. Ngược lại, nghiên cứu 6 có trọng số cao vì độ dao động thấp (phương sai thấp) và ước tính ảnh hưởng của nghiên cứu này có “trọng lượng” hơn các nghiên cứu khác trong nhóm.

Do đó, để tính trung bình d cho tổng số nghiên cứu, chúng ta phải xem xét đến trọng số W_i . Với mỗi d_i và W_i chúng ta có thể tính trị số **trung bình trọng số (weighted mean)** theo phương pháp chuẩn như sau:

$$d = \frac{\sum_{i=1}^9 W_i d_i}{\sum_{i=1}^9 W_i}$$

Bất cứ một ước tính thống kê (estimate) nào cũng phải có một phương sai. Và trong trường hợp d , phương sai (kí hiệu là s_d^2) chỉ đơn giản là số đảo của tổng trọng số W_i :

$$s_d^2 = \frac{1}{\sum_{i=1}^9 W_i}$$

Sai số chuẩn (standard error, SE) của d , do đó là: $SE(d) = s_d$. Theo lí thuyết phân phối chuẩn (Normal distribution), khoảng tin cậy 95% (95% confidence interval, 95%CI) có thể được ước tính như sau:

$$95\%CI \text{ của } d = d \pm 1.96(s_d)$$

Để tính d chúng ta cần thêm một cột nữa: đó là cột $W_i d_i$. Chẳng hạn như với nghiên cứu 1, chúng ta có $W_1 d_1 = 0,0246 \times 20 = 0,4928$. Tiếp tục như thế, chúng ta có thêm một cột.

Bảng 1c. Tính toán trị số trung bình

NGHIÊN CỨU	d_i	s_i^2	W_i	$W_i d_i$
1	20	40.6	0.0246	0.4928
2	2	2.0	0.4886	0.9771
3	55	15.3	0.0654	3.5993
4	71	150.2	0.0067	0.4726
5	4	20.2	0.0495	0.1981
6	-1	1.2	0.8173	-0.8173
7	-11	95.4	0.0105	-0.1153
8	10	8.0	0.1245	1.2450
9	-7	20.7	0.0483	-0.3383
Tổng số			1.6354	5.7140

Sau đó, cộng tất cả W_i và $W_i d_i$ (trong hàng “Tổng số” của bảng trên). Như vậy, trị số trung bình trọng số của d là:

$$d = \frac{\sum_{i=1}^9 W_i d_i}{\sum_{i=1}^9 W_i} = \frac{0.4928 + 0.9771 + \dots - 0.3383}{0.0246 + 0.4886 + \dots + 0.0483} = \frac{5.7140}{1.6354} = 3.49$$

Và phương sai của d là: $s_d^2 = \frac{1}{1.6345} = 0.61$.

Nói cách khác, sai số chuẩn (standard error) của d là:

$$s_d = \sqrt{0.61} = 0.782.$$

Khoảng tin cậy 95% (95% confidence interval hay 95%CI) có thể được ước tính như sau:

$$3.49 \pm 1,96 \cdot 0.782 = 1.96 \text{ đến } 5.02.$$

Đến đây, chúng ta có thể nói rằng, tính trung bình, thời gian nằm viện tại các bệnh viện đa khoa dài hơn các bệnh viện chuyên khoa 3.49 ngày và 95% khoảng tin cậy là từ 1.96 ngày đến 5.02 ngày.

Bước 5: Ước tính chỉ số đồng nhất (homogeneity) và bất đồng nhất (heterogeneity) giữa các nghiên cứu [3]. Trong thực tế, đây là chỉ số đo lường độ khác biệt giữa mỗi nghiên cứu và trị số trung bình trọng số. Chỉ số đồng nhất (index of homogeneity) được tính theo công thức sau đây:

$$Q = \sum_{i=1}^k W_i (d_i - d)^2$$

Ở đây, k là số nghiên cứu (trong ví dụ trên $k = 9$). Theo lý thuyết xác suất, Q có độ phân phối theo luật *Chi-square* với **bậc tự do (degrees of freedom - df)** là $k-1$ (tức là χ_{k-1}^2). Nói cách khác, nếu Q lớn hơn χ_{k-1}^2 thì đó là tín hiệu cho thấy sự bất đồng nhất giữa các nghiên cứu “có ý nghĩa thống kê” (significant).

Nhiều nghiên cứu trong thời gian qua chỉ ra rằng Q thường không phát hiện được sự bất đồng nhất một cách nhất quán, cho nên ngày nay ít ai dùng chỉ số này trong phân tích tổng hợp. Một chỉ số khác thay thế Q có tên là **index of heterogeneity (I^2)**, tạm dịch là **chỉ số bất đồng nhất**, nhưng sẽ giữ cách viết I^2 . Chỉ số này được định nghĩa như sau:

$$I^2 = \frac{Q - (k-1)}{Q}$$

I^2 có giá trị từ âm đến 1. Nếu $I^2 < 0$, thì chúng ta sẽ cho nó là 0; nếu I^2 gần bằng 1 thì đó là dấu hiệu cho thấy có sự bất đồng nhất giữa các nghiên cứu.

Trong ví dụ trên, để ước tính Q và I^2 , chúng ta cần tính $W_i (d_i - d)^2$ cho từng nghiên cứu. Chẳng hạn như, với nghiên cứu 1:

$$W_i (d_i - d)^2 = 0,0246 \cdot (20 - 3.49)^2 = 6,7129$$

Bảng 1d. Tính toán các chỉ số đồng nhất và bất đồng nhất

NGHIÊN CỨU	d_i	s_i^2	w_i	$w_i d_i$	$w_i (d_i - d)^2$
1	20	40.6	0.0246	0.4928	6.7129
2	2	2.0	0.4886	0.9771	1.0903
3	55	15.3	0.0654	3.5993	173.6080
4	71	150.2	0.0067	0.4726	30.3356
5	4	20.2	0.0495	0.1981	0.0127
6	-1	1.2	0.8173	-0.8173	16.5054
7	-11	95.4	0.0105	-0.1153	2.2026
8	10	8.0	0.1245	1.2450	5.2701
9	-7	20.7	0.0483	-0.3383	5.3215
Tổng số			1.6354	5.7140	241.05

Sau khi đã ước tính $w_i(d_i - d)^2$ cho từng nghiên cứu, chúng ta cộng lại số này (xem cột sau cùng) và đó chính là Q :

$$Q = \sum_{i=1}^k w_i (d_i - d)^2 = 241.05$$

Từ đó, I^2 có thể ước tính như sau:

$$I^2 = \frac{241.05 - 8}{241.05} = 0.966$$

Chỉ số bất đồng nhất I^2 rất cao, cho thấy độ dao động về d_i giữa các nghiên cứu rất cao. Điều này chúng ta có thể thấy được chỉ qua nhìn vào cột số 2 trong bảng thống kê trên.

Bước 6: Đánh giá khả năng publication bias [4]. Publication bias (tạm dịch: **trong thiên vị**) là một khái niệm tương đối mới có thể giải thích bằng tình huống thực tế sau đây. Chúng ta biết rằng khi một nghiên cứu cho ra kết quả “negative” (kết quả tiêu cực, tức là không phát hiện một ảnh hưởng hay một mối liên hệ có ý nghĩa thống kê) công trình nghiên cứu đó rất khó có cơ hội được công bố trên các tập san, bởi vì giới chủ bút tập san nói chung không thích in những bài như thế. Ngược lại, một nghiên cứu với một kết quả “tích cực” (tức có ý nghĩa thống kê) thì nghiên cứu có khả năng xuất hiện trên các tập san khoa học cao hơn là các nghiên cứu với kết quả “tiêu cực”. Thế nhưng phần lớn những phân tích tổng hợp lại dựa vào các kết quả đã công bố trên

các tập san khoa học. Do đó, ước tính của một phân tích tổng hợp có khả năng thiếu khách quan, vì chưa xem xét đầy đủ đến các nghiên cứu tiêu cực chưa bao giờ công bố.


Một số nhà nghiên cứu đề nghị dùng biểu đồ funnel (còn gọi là **funnel plot**) để kiểm tra khả năng publication bias. Biểu đồ funnel được thể hiện bằng cách vẽ **độ chính xác - precision** (trục tung, y-axis) với ước tính mức độ ảnh hưởng cho từng nghiên cứu. Ở đây precision được định nghĩa là số đảo của sai số chuẩn (standard error):

$$\text{precision} = \frac{1}{s_{di}}$$

Nói cách khác, biểu đồ funnel biểu diễn *precision* với d_i . Chẳng hạn như với nghiên cứu 1, chúng ta có: $\text{precision} = 1/\sqrt{40.6} = 0,157$. Tính cho từng nghiên cứu, chúng ta dùng bảng thống kê sau để vẽ biểu đồ funnel như sau:

Bảng 1e. Ước tính publication bias

NGHIÊN CỨU	d_i	s_i^2	$1/s_i$
1	20	40.6	0.1570
2	2	2.0	0.6990
3	55	15.3	0.2558
4	71	150.2	0.0816
5	4	20.2	0.2225
6	-1	1.2	0.9041
7	-11	95.4	0.1024
8	10	8.0	0.3528
9	-7	20.7	0.2198



Biểu đồ funnel (biểu đồ phễu): trục tung là precision và trục hoành là d . Biểu đồ này cho thấy phần lớn các nghiên cứu có kết quả thời gian nằm viện trong các bệnh viện đa khoa thường lâu hơn các bệnh viện chuyên khoa.

Cái logic đằng sau biểu đồ funnel là nếu các công trình nghiên cứu lớn (tức có độ precision cao) có khả năng được công bố cao, thì số lượng nghiên cứu với kết quả tích cực sẽ nhiều hơn số lượng nghiên cứu nhỏ hay với kết quả tiêu cực trong các tập san. Và nếu điều này xảy ra, thì biểu đồ funnel sẽ thể hiện một sự thiếu cân đối (asymmetry). Nói cách khác, sự thiếu cân đối của một biểu đồ funnel là dấu hiệu cho thấy có vấn đề về publication bias. Nhưng vấn đề đặt ra là publication bias đó có ý nghĩa thống kê hay không? Biểu đồ funnel không thể trả lời câu hỏi này, chúng ta cần đến các phương pháp phân tích định lượng nghiên cứu chỉnh hơn.

Kiểm định Egger

Vài năm gần đây có ý kiến cho rằng biểu đồ funnel rất khó diễn dịch, và có thể gây nên ngộ nhận về publication bias [5-6]. Thật vậy, một số tập san y học có chính sách khuyến khích các nhà nghiên cứu tìm một phương pháp khác để đánh giá *publication bias* thay vì dùng biểu đồ funnel.

Một trong những phương pháp đó là kiểm định Egger (còn gọi là **Egger's test**). Với phương pháp này, chúng ta mô hình rằng $SND = a + b \times precision$, trong đó SND được ước tính bằng cách lấy d chia cho sai số chuẩn của d , tức

là: $SND_i = \frac{d_i}{s_{di}}$, a và b là hai thông số phải ước tính từ mô hình hồi qui đường

thẳng đó. Ở đây, a cung cấp cho chúng ta một ước số về tình trạng thiếu cân đối của biểu đồ funnel: $a > 0$ có nghĩa là xu hướng nghiên cứu càng có qui mô lớn càng có ước số về độ ảnh hưởng với sự chính xác cao.

Trong ví dụ trên, chúng ta có thể dùng một phần mềm phân tích thống kê (như SAS hay R) để ước tính a và b như sau:

$$SND_i = 4.20 + -4.17084 \times precision_i$$

Kết quả ước số $a = 4.20$ tuy là > 0 nhưng không có ý nghĩa thống kê, cho nên ở đây bằng chứng cho thấy không có sự publication bias.

Tuy nhiên, như đã thấy trong thực tế, kiểm định Egger này cũng chỉ là một cách thể hiện biểu đồ funnel mà thôi, chứ cũng không có thay đổi gì lớn. Có một cách đánh giá publication bias, cho đến nay, được xem là đáng tin cậy nhất:

đó là phương pháp phân tích hồi qui đường thẳng (linear regression) giữa d_i và tổng số mẫu (N_i). Nói cách khác, chúng ta tìm a và b trong mô hình [7]:

$$d_i = a + b \cdot N_i$$

Nếu không có publication bias thì giá trị của b sẽ rất gần với 0 hay không có ý nghĩa thống kê. Nếu trị số b khác với 0 thì đó là một tín hiệu của publication bias. Trong ví dụ vừa nêu với dữ liệu sau đây,

NGHIÊN CỨU	d_i	N_i
1	20	311
2	2	63
3	55	146
4	71	36
5	4	21
6	-1	109
7	-11	67
8	10	293
9	-7	112

chúng ta có phương trình:

$$d_i = 16.0 - 0.0009 \cdot N_i$$

và quả thật giá trị của b quá thấp (cũng như không có ý nghĩa thống kê), cho nên đến đây chúng ta có thể kết luận rằng không có vấn đề publication bias trong nghiên cứu vừa đề cập đến.

Nói tóm lại, qua phân tích tổng hợp này, chúng ta có bằng chứng đáng tin cậy để kết luận rằng thời gian nằm viện của bệnh nhân trong các bệnh viện đa khoa dài hơn các bệnh viện chuyên khoa khoảng 3 ngày rưỡi, hoặc trong 95% trường hợp thời gian khác biệt khoảng từ 2 ngày đến 5 ngày. Kết quả này cũng cho thấy không có thiên vị xuất bản (publication bias) trong phân tích.

16.4.2 Phân tích tổng hợp bằng R

R có hai package được viết và thiết kế cho phân tích tổng hợp. Package được sử dụng khá thông dụng là meta. Bạn đọc có thể tải miễn phí từ trang web của R (trong phần packages): <http://cran.R-project.org>.

Để phân tích tổng hợp bằng R chúng ta phải nhập package meta vào môi trường vận hành của R (với điều kiện, tất nhiên, là bạn đọc đã tải và cài đặt meta vào R).

```
> library(meta)
```

Sau đó, chúng ta sẽ nhập số liệu trong ví dụ 1 vào R biến như sau:

- Nhập dữ liệu cho từng cột trong **Bảng 1** và cho vào một dataframe gọi là los:

```
> n1 <- c(155, 31, 75, 18, 8, 57, 34, 110, 60)
```

```
> los1 <- c(55, 27, 64, 66, 14, 19, 52, 21, 30)
```

```
> sd1 <- c(47, 7, 17, 20, 8, 7, 45, 16, 27)
```

```
> n2 <- c(156, 32, 71, 18, 13, 52, 33, 183, 52)
```

```
> los2 <- c(75, 29, 119, 137, 18, 18, 41, 31, 23)
```

```
> sd2 <- c(64, 4, 29, 48, 11, 4, 34, 27, 20)
```

```
> los <- data.frame(n1, los1, sd1, n2, los2, sd2)
```

- Sử dụng hàm metacont (dùng để phân tích các biến liên tục - do đó cont = continuous variable) và cho kết quả vào đối tượng res:

```
> res <- metacont(n1, los1, sd1, n2, los2, sd2, data=los)
```

```
> res
```

```
> res
```

	WMD	95%-CI	%W(fixed)	%W(random)
1	-20 [-32.4744; -7.5256]	1.44	10.69	
2	-2 [-4.8271; 0.8271]	28.11	12.67	
3	-55 [-62.7656; -47.2344]	3.73	11.89	
4	-71 [-95.0223; -46.9777]	0.39	7.39	
5	-4 [-12.1539; 4.1539]	3.38	11.80	
6	1 [-1.1176; 3.1176]	50.11	12.72	
7	11 [-8.0620; 30.0620]	0.62	8.76	
8	-10 [-14.9237; -5.0763]	9.27	12.41	
9	7 [-1.7306; 15.7306]	2.95	11.67	

Number of trials combined: 9

	WMD	95%-CI	z	p.value
Fixed effects model	-3.464	[-4.96; -1.96]	-4.53	<0.0001
Random effects model	-13.98	[-24.03; -3.93]	-2.73	0.0064

Quantifying heterogeneity:

$\tau^2 = 205.4094$; $H = 5.46$ [4.54; 6.58];

$I^2 = 96.7\%$ [95.2%; 97.7%]

Test of heterogeneity:


Q	d.f.	p.value
238.92	8	< 0.0001

Method: Inverse variance method

meta cung cấp cho chúng ta hai kết quả: một kết quả dựa vào mô hình fixed-effects và một dựa vào mô hình random-effects. Như thấy qua kết quả trên, mức độ khác biệt giữa hai mô hình khá lớn, nhưng kết quả chung thì giống nhau, tức kết quả của cả hai mô hình đều có ý nghĩa thống kê.

Ngoài ra, chúng ta cũng có thể sử dụng hàm `plot` để thể hiện kết quả trên bằng biểu đồ forest như sau:

```
> forest(res, lwd=3)
```



16.5. Phân tích tổng hợp ảnh hưởng bất biến cho một tiêu chí nhị phân (Fixed-effects meta-analysis for a dichotomous outcome)

Trong phần trên, tôi vừa mô tả những bước chính trong một phân tích tổng hợp những nghiên cứu mà tiêu chí là một biến liên tục (continuous variable). Đối với các biến liên tục, trị số trung bình và độ lệch chuẩn là hai chỉ số thống kê thường được sử dụng để tóm lược. Nhưng hai chỉ số này không thể ứng dụng cho những tiêu chí mang tính thể loại hay thứ bậc như tử vong, gãy xương, v.v... vì những tiêu chí này chỉ có hai giá trị: hoặc là có, hoặc là không. Một người hoặc là còn sống hay chết, bị gãy xương hay không gãy xương, mắc bệnh suy tim hay không mắc bệnh suy tim, v.v... Đối với những biến này, chúng ta cần một phương pháp phân tích khác với phương pháp dành cho các biến liên tục.

16.5.1 Mô hình phân tích

Đối với những tiêu chí nhị phân (chỉ có hai giá trị), chỉ số thống kê tương đương với trị số trung bình là **tỉ lệ** hay **proportion** (có thể tính phần trăm); và chỉ số tương đương với độ lệch chuẩn là sai số chuẩn (**standard error**). Chẳng hạn như nếu một nghiên cứu theo dõi 25 bệnh nhân trong một thời gian, và trong thời gian đó có 5 bệnh nhân mắc bệnh, thì tỉ lệ (kí hiệu là p) đơn giản là: $p = 5/25 = 0,20$ (hay 20%). Theo lí thuyết xác suất, phương sai của p (kí hiệu là $\text{var}[p]$) là:

$$\text{var}[p] = p(1-p)/n = 0,2 \times (1 - 0,2)/25 = 0,0064.$$

Theo đó, sai số chuẩn của p (kí hiệu $\text{SE}[p]$) là:

$$\text{SE}[p] = \sqrt{\text{var}[p]} = \sqrt{0,0064} = 0,08.$$

Chúng ta còn có thể ước tính khoảng tin cậy 95% của tỉ lệ như sau:

$$p \pm 1,96 \times \text{SE}[p] = 0,2 \pm 1,96 \times 0,08 = 0,04 \text{ đến } 0,36.$$

Vì cách tính của các tiêu chí nhị phân khá đặc thù, cho nên phương pháp phân tích tổng hợp các nghiên cứu với biến nhị phân cũng khác. Để minh họa cách phân tích tổng hợp dạng này, chúng ta sẽ lấy một ví dụ (phỏng theo một nghiên cứu có thật).

Ví dụ 2: Beta-blocker (viết tắt là BB) là một loại thuốc có chức năng điều trị và phòng chống cao huyết áp. Có giả thiết cho rằng BB cũng có thể phòng chống bệnh suy tim, hay ít ra là làm giảm nguy cơ suy tim. Để thử nghiệm giả thiết này, hàng loạt nghiên cứu lâm sàng đối chứng ngẫu nhiên đã được

tiến hành trong thời gian 20 năm qua. Mỗi nghiên cứu có 2 nhóm bệnh nhân: nhóm được điều trị bằng BB, và một nhóm không được điều trị (còn gọi là placebo hay giả dược). Trong thời gian 2 năm theo dõi, các nhà nghiên cứu xem xét tần số tử vong cho từng nhóm. **Bảng 2** sau đây tóm lược 13 nghiên cứu trong quá khứ:

Bảng 2. Beta-blocker và bệnh suy tim (congestive heart failure)

NGHIÊN CỨU (i)	BETA-BLOCKER		PLACEBO	
	N ₁	TỬ VONG (d ₁)	N ₂	TỬ VONG (d ₂)
1	25	5	25	6
2	9	1	16	2
3	194	23	189	21
4	25	1	25	2
5	105	4	34	2
6	320	53	321	67
7	33	3	16	2
8	261	12	84	13
9	133	6	145	11
10	232	2	134	5
11	1327	156	1320	228
12	1990	145	2001	217
13	214	8	212	17
Tổng cộng	4879	420	4516	612

N: số bệnh nhân nghiên cứu;

Tử vong: số bệnh nhân chết trong thời gian theo dõi.

Như chúng ta thấy, một số nghiên cứu có số mẫu khá nhỏ, lại có những nghiên cứu với số mẫu gần 4000 người! Câu hỏi đặt ra là tổng hợp các nghiên cứu này, kết quả có nhất quán hay phù hợp với giả thiết BB làm giảm nguy cơ suy tim hay không? Để trả lời câu hỏi này, chúng ta tiến hành những bước sau đây:

Bước 1: Ước tính mức độ ảnh hưởng cho từng nghiên cứu. Mỗi nghiên cứu có hai tỉ lệ: một cho nhóm BB và một cho nhóm placebo (giả dược). Gọi hai tỉ lệ này là p_1 và p_2 , chỉ số để đánh giá mức độ ảnh hưởng của thuốc BB là tỉ số nguy cơ tương đối (relative risk – RR), và RR có thể được ước tính như sau:

$$RR = \frac{p_1}{p_2}$$

Chẳng hạn như, trong nghiên cứu 1, chúng ta có: $p_1 = \frac{5}{25} = 0,20$ và

$p_2 = \frac{6}{25} = 0,24$. Như vậy tỉ số nguy cơ cho nghiên cứu 1 là: $RR = \frac{0,20}{0,24} = 0,833$.

Tính toán tương tự cho các nghiên cứu còn lại, chúng ta sẽ có một bảng như sau:

Bảng 2a. Ước tính tỉ lệ tử vong và tỉ số nguy cơ tương đối

NGHIÊN CỨU (I)	TỈ LỆ TỬ VONG NHÓM BB (p_1)	TỈ LỆ TỬ VONG NHÓM PLACEBO (p_2)	TỈ SỐ NGUY CƠ (RR)
1	0.200	0.240	0.833
2	0.111	0.125	0.889
3	0.119	0.111	1.067
4	0.040	0.080	0.500
5	0.038	0.059	0.648
6	0.166	0.209	0.794
7	0.091	0.125	0.727
8	0.046	0.155	0.297
9	0.045	0.076	0.595
10	0.009	0.037	0.231
11	0.118	0.173	0.681
12	0.073	0.108	0.672
13	0.037	0.080	0.466

Bước 2: Biến đổi RR thành đơn vị logarithm và tính phương sai, sai số chuẩn. Mỗi ước số thống kê, như có lần nói, đều có một luật phân phối, và luật phân phối có thể phản ánh bằng phân sai (hay sai số chuẩn). Cách tính phương sai của RR khá phức tạp, cho nên chúng ta sẽ tính bằng một phương pháp gián tiếp. Theo phương pháp này, chúng ta sẽ biến đổi RR thành $\log[RR]$ (chú ý “log” ở đây có nghĩa là loga tự nhiên, tức là $\log_e$ hay có khi còn viết tắt là $\ln$ – natural logarithm), và sau đó sẽ tính phương sai của $\log[RR]$.

Nếu N_1 và N_2 là lần lượt tổng số mẫu của nhóm 1 và nhóm 2; và d_1 và d_2 là số tử vong của nhóm 1 và nhóm 2 của một nghiên cứu, thì phương sai của $\log[RR]$ có thể ước tính bằng công thức sau đây:

$$\text{Var}[\log RR] = \frac{1}{d_1} - \frac{1}{N_1 - d_1} + \frac{1}{d_2} - \frac{1}{N_2 - d_2}$$

Và sai số chuẩn của $\log[RR]$ là:

$$\text{SE}[\log RR] = \sqrt{\frac{1}{d_1} - \frac{1}{N_1 - d_1} + \frac{1}{d_2} - \frac{1}{N_2 - d_2}}$$

Trong ví dụ trên, với nghiên cứu 1, chúng ta có:

$$\text{Log}[RR] = \log_e(0.833) = -0.182$$

Với phương sai:

$$\text{var}[\log RR] = \frac{1}{5} - \frac{1}{25-5} + \frac{1}{6} - \frac{1}{25-6} = 0.264$$

Và sai số chuẩn:

$$SE[\log RR] = \sqrt{0.264} = 0.514$$

Dựa vào luật phân phối chuẩn, chúng ta cũng có thể tính toán khoảng tin cậy 95% của RR cho từng nghiên cứu bằng cách biến đổi ngược lại theo đơn vị RR. Chẳng hạn như với nghiên cứu 1, chúng ta có khoảng tin cậy 95% của $\log[RR]$ là:

$$\log RR \pm 1.96 * SE[\log RR] = -0.182 \pm 1.96 * 0.514 = -1.19 \text{ đến } 0.82$$

hay biến đổi thành đơn vị nguyên thủy của RR là:


$$\exp(-1.19) = 0.30 \text{ đến } \exp(0.82) = 2.28$$

Tính toán tương tự cho các nghiên cứu khác, chúng ta có thêm một bảng mới như sau:

Bảng 2b. Ước tính tỉ số nguy cơ tương đối, phương sai, sai số chuẩn và khoảng tin cậy 95% cho từng nghiên cứu

NGHIÊN CỨU (/)	TỈ SỐ NGUY CƠ (RR)	LOG[RR]	VAR[LOGRR]	SE[LOGRR]	PHẦN THẤP 95% CI CỦA RR	PHẦN CAO 95% CI CỦA RR
1	0.200	-0.182	0.264	0.514	0.30	2.28
2	0.111	-0.118	1.304	1.142	0.09	8.33
3	0.119	0.065	0.079	0.282	0.61	1.85
4	0.040	-0.693	1.415	1.189	0.05	5.15
5	0.038	-0.434	0.709	0.842	0.12	3.37
6	0.166	-0.231	0.026	0.162	0.58	1.09
7	0.091	-0.318	0.729	0.854	0.14	3.87
8	0.046	-1.214	0.142	0.377	0.14	0.62
9	0.045	-0.520	0.242	0.492	0.23	1.56
10	0.009	-1.465	0.688	0.829	0.05	1.17
11	0.118	-0.385	0.009	0.095	0.56	0.82
12	0.073	-0.398	0.010	0.102	0.55	0.82
13	0.037	-0.763	0.174	0.417	0.21	1.06

Chúng ta có thể thể hiện RR và khoảng tin cậy 95% bằng biểu đồ forest như sau:



Biểu đồ forest thể hiện giá trị của RR và khoảng tin cậy 95%. Các ước tính khoảng tin cậy 95%CI của RR vượt qua cột mốc 1 được xem là không có ý nghĩa thống kê.

Bước 3: Ước tính trọng số (weight) cho từng nghiên cứu và RR cho toàn bộ nghiên cứu. Biểu đồ trên cho thấy một số nghiên cứu có độ dao động RR rất lớn (chứng tỏ các nghiên cứu này có số mẫu nhỏ hay ước số RR không ổn định), và ngược lại, một số nghiên cứu lớn có ước số RR ổn định hơn. Trọng số cho mỗi nghiên cứu (W_i - cho vào kí hiệu i) để đo lường độ ổn định này là số đảo của phương sai:

$$W_i = \frac{1}{\text{var}[\log RR_i]}$$

Và số trung bình trọng số của $\log[RR]$ (kí hiệu là $\log wRR$) có thể ước tính từ tổng của tích $W_i \times \log[RR_i]$:

$$\log wRR = \frac{\sum W_i \times \log[RR_i]}{\sum W_i}$$

Với phương sai:

$$\text{Var}[\log wRR] = \frac{1}{\sum W_i}$$

và sai số chuẩn:

$$SE[\log wRR] = \sqrt{\frac{1}{\sum W_i}} \cdot i1$$

Ngoài ra, khoảng tin cậy 95% có thể ước tính bằng:

$$\log wRR \pm SE[\log wRR]$$

Để tính trung bình trọng số logRR, chúng ta cần một cột $W_i \times \log[RR_i]$.
 Chẳng hạn như với nghiên cứu 1, chúng ta có:

$$W_1 = \frac{1}{0,264} = 3.79$$

và

$$W_i \times \log[RR_i] = 3.79 \times (-0.182) = -0.69$$

Tính toán tương tự cho các nghiên cứu khác, chúng ta sẽ có một bảng số liệu mới như sau:

Bảng 2c. Ước tính tỉ trọng số (W_i)

NGHIÊN CỨU (i)	LOG[RR]	VAR(LOGRR)	W_i	$W_i \times \text{LOG}[RR_i]$
1	-0.182	0.264	3.79	-0.69
2	-0.118	1.304	0.77	-0.09
3	0.065	0.079	12.61	0.82
4	-0.693	1.415	0.71	-0.49
5	-0.434	0.709	1.41	-0.61
6	-0.231	0.026	38.30	-8.86
7	-0.318	0.729	1.37	-0.44
8	-1.214	0.142	7.03	-8.54
9	-0.520	0.242	4.13	-2.15
10	-1.465	0.688	1.45	-2.13
11	-0.385	0.009	110.78	-42.63
12	-0.398	0.010	96.13	-38.23
13	-0.763	0.174	5.75	-4.39
Tổng số			284.24	-108.42

Chúng ta có:

$$\sum W_i = 3.79 + 0.77 + \dots + 5.75 = 284.24$$

$$\sum W_i \times \log[RR_i] = -0.69 - 0.09 + \dots - 4.39 = -108.42$$

Do đó, trung bình trọng số của $\log[RR]$ có thể ước tính bằng:

$$\log wRR = \frac{\sum W_i \times \log[RR_i]}{\sum W_i} = \frac{-108,42}{284,24} = -0.38$$

Với phương sai:

$$Var[\log wRR] = \frac{1}{\sum W_i} = \frac{1}{284,24} = 0.0035$$

và sai số chuẩn:

$$SE[\log wRR] = \sqrt{\frac{1}{\sum W_i}} = \sqrt{0.0035} = 0.06$$

Do đó, khoảng tin cậy 95% của $\log wRR$ có thể ước tính bằng:

$$\log wRR \pm SE[\log wRR] = -0.38 \pm 1.96 \times 0.06 = 0.498 \text{ đến } -0.265$$

Nhưng chúng ta muốn thể hiện bằng đơn vị gốc (tức tỉ số); do đó, các ước số trên phải được biến chuyển về đơn vị gốc:

$$RR = \exp(\log wRR) = \exp(-0.38) = 0.68$$

Và khoảng tin cậy 95%:

$$\exp(-0.498) = 0.61 \text{ đến } \exp(-0.265) = 0.77.$$

Đến đây chúng ta có thể nói rằng tỉ lệ tử vong trong các bệnh nhân được điều trị bằng BB là 0.68 (hay thấp hơn 32%) so với các bệnh nhân placebo. Ngoài ra, vì khoảng tin cậy 95% không bao gồm 1, chúng ta cũng có thể phát biểu rằng mức độ khác biệt này có ý nghĩa thống kê.

Bước 4: Ước tính chỉ số đồng nhất và bất đồng nhất. Như đã nói trong phần (1) liên quan đến phân tích biến liên tục, sau khi đã ước tính tỉ số nguy cơ trung bình, chúng ta cần phải xem xét chỉ số I^2 . Để ước tính chỉ số I^2 , chúng ta cần tính $W_i(\log RR_i - \log wRR)^2$ cho mỗi nghiên cứu. Chẳng hạn như với nghiên cứu 1, chúng ta có:

$$W_i(\log RR_i - \log wRR)^2 = 3.79 \times (-0.182 + 0.38)^2 = 0.1502$$

và tính toán tương tự cho các nghiên cứu khác, chúng ta sẽ có một bảng số liệu mới như sau:

Bảng 2d. Ước tính chỉ số heterogeneity (I^2)

NGHIÊN CỨU (i)	Log[RR _i]	W _i	W _i (logRR _i - log wRR) ²
1	-0.182	3.79	0.1502
2	-0.118	0.77	0.0533
3	0.065	12.61	2.5118
4	-0.693	0.71	0.0687
5	-0.434	1.41	0.0040
6	-0.231	38.30	0.8635
7	-0.318	1.37	0.0054
8	-1.214	7.03	4.8731
9	-0.520	4.13	0.0790
10	-1.465	1.45	1.7074
11	-0.385	110.78	0.0012
12	-0.398	96.13	0.0253
13	-0.763	5.75	0.8382
Tổng số		284.24	11.1811

Ví dụ 2 có $k = 13$ nghiên cứu. Do đó:

$$Q = \sum_{i=1}^k W_i (\log RR_i - \log wRR)^2 = 11.1811$$

Và

$$I^2 = \frac{Q - (k - 1)}{Q} = \frac{11.18 - 12}{11.18} = -0.16$$

Vì $I^2 < 0$, nên chúng ta có thể cho $I^2 = 0$. Nói cách khác, mức độ khác biệt về RR giữa các nghiên cứu không có ý nghĩa thống kê.

Bước 5: đánh giá khả năng publication bias. Như đã giải thích ở trên, cách đánh giá khả năng publication bias có ý nghĩa nhất là phân tích hồi qui đường thẳng log[RR] và tổng số mẫu (N):

$$\log[RR_i] = a + b \times N_i$$


Dựa vào bảng thống kê sau.

NGHIÊN CỨU (i)	Log[RR] _i	N _i
1	-0.182	50
2	-0.118	25
3	0.065	383
4	-0.693	50
5	-0.434	139
6	-0.231	641
7	-0.318	49
8	-1.214	345
9	-0.520	278
10	-1.465	366
11	-0.385	2647
12	-0.398	3991
13	-0.763	426

Chúng ta có thể ước tính a và b như sau:

$$\log[RR_i] = -0.534 + 0.00003 \times N_i$$

Ước tính $b = 0.00003$ không có ý nghĩa thống kê ($p = 0.782$). Do đó, chúng ta có thể phát biểu rằng mức độ thiên lệch về xuất bản không đáng kể trong phân tích tổng hợp này.



Biểu đồ funnel cũng cho thấy không có vấn đề publication bias

16.5.2 Phân tích bằng R

Package meta có hàm metabin có thể sử dụng để tiến hành phân tích tổng hợp cho các biến nhị phân như số liệu trong ví dụ 2 trên đây. Khởi đầu, chúng ta “ nạp ” package meta (nếu chưa làm) vào môi trường vận hành, và sau đó thu nhập số liệu vào một data frame:

```
library(meta)

# Số liệu từ ví dụ 2
n1 <- c(25,9,194,25,105,320,33,261,133,232,1327,1990,214)
d1 <- c(5,1,23,1,4,53,3,12,6,2,156,145,8)
n2 <- c(25,16,189,25,34,321,16,84,145,134,1320,2001,212)
d2 <- c(6,2,21,2,2,67,2,13,11,5,228,217,17)

# Tạo một dataframe lấy tên là bb
bb <- data.frame(n1,d1,n2,d2)

# Phân tích bằng hàm metabin và kết quả trong res
> res <- metabin(d1,n1,d2,n2,data=bb,sm="RR")
> res
> res
```

	RR	95%-CI	%W(fixed)	%W(random)
1	0.8333	[0.2918; 2.3799]	1.26	1.26
2	0.8889	[0.0930; 8.4951]	0.27	0.27
3	1.0670	[0.6116; 1.8617]	4.47	4.47
4	0.5000	[0.0484; 5.1677]	0.25	0.25
5	0.6476	[0.1240; 3.3814]	0.51	0.51
6	0.7935	[0.5731; 1.0986]	13.08	13.08
7	0.7273	[0.1346; 3.9282]	0.49	0.49
8	0.2971	[0.1410; 0.6258]	2.49	2.49
9	0.5947	[0.2262; 1.5632]	1.48	1.48
10	0.2310	[0.0454; 1.1744]	0.52	0.52
11	0.6806	[0.5635; 0.8221]	38.81	38.81
12	0.6719	[0.5496; 0.8214]	34.31	34.31
13	0.4662	[0.2056; 1.0570]	2.07	2.07

Number of trials combined: 13

	RR	95%-CI	z	p.value
Fixed effects model	0.6821	[0.6064; 0.7672]	-6.3741	< 0.0001
Random effects model	0.6821	[0.6064; 0.7672]	-6.3741	< 0.0001

Quantifying heterogeneity:

$\tau^2 = 0$; $H = 1$ [1; 1.45]; $I^2 = 0\%$ [0%; 52.6%]

Test of heterogeneity:

Q d.f. p.value


11 12 0.5292

Method: Inverse variance method

Kết quả từ mô hình fixed-effects và random-effects một lần nữa cho chúng ta bằng chứng để kết luận rằng beta-blocker có hiệu nghiệm trong việc làm giảm nguy cơ tử vong.

```
# Biểu đồ forest
```

```
> forest(res, lwd=3)
```



Thực ra, trong khoa học nói chung, chúng ta đã có một truyền thống lâu đời về việc duyệt xét bằng chứng nghiên cứu (review), duyệt xét kiến thức hiện hành. Nhưng các duyệt xét như thế thường mang tính định chất (qualitative review), và vì tính định chất, chúng ta khó mà biết chính xác được những khác biệt mang tính định lượng giữa các nghiên cứu. Phân tích tổng hợp cung cấp cho chúng ta một phương tiện định lượng để hệ thống bằng chứng. Với phân tích tổng hợp, chúng ta có cơ hội để:

- Xem xét những nghiên cứu nào đã được tiến hành để giải quyết vấn đề;
- Kết quả của các nghiên cứu đó như thế nào;
- Hệ thống các tiêu chí lâm sàng đáng quan tâm;
- Rà soát những khác biệt về đặc tính giữa các nghiên cứu;
- Cách thức để tổng hợp kết quả; và
- Truyền đạt kết quả một cách khoa học.

Mục đích của phân tích tổng hợp, xin nhắc lại một lần nữa, là ước tính một chỉ số ảnh hưởng trung bình sau khi đã xem xét tất cả kết quả nghiên cứu hiện hành. Một kết quả chung như thế giúp cho chúng ta đi đến một kết luận chính xác và đáng tin cậy hơn.

Hai ví dụ trên đây hi vọng đã giúp ích cho bạn đọc hiểu được “cơ chế” và ý nghĩa của một phân tích tổng hợp. Hi vọng bạn đọc có thể tự mình làm một phân tích như thế khi đã có dữ liệu. Thực ra, tất cả các tính toán trên có thể thực hiện bằng một phần mềm như Microsoft Excel. Ngoài ra, một số phần mềm chuyên môn khác (như SAS chẳng hạn) cũng có thể tiến hành những phân tích trên. Các phép tính trong phân tích tổng hợp thật đơn giản. Vấn đề của phân tích tổng hợp không phải là tính toán, mà là dữ liệu đằng sau tính toán.

Phân tích tổng hợp cũng không phải là không có những khiếm khuyết. Trong nghiên cứu người ta có câu “rác vào, rác ra”, tức là nếu các dữ liệu được sử dụng trong phân tích không có chất lượng cao thì kết quả của phân tích tổng hợp cũng chẳng có giá trị khoa học gì. Do đó, vấn đề quan trọng nhất trong phân tích tổng hợp là chọn lựa dữ liệu và nghiên cứu để phân tích. Vấn đề này cần phải được cân nhắc cực kì cẩn thận để đảm bảo tính hợp lí và khoa học của kết quả.

Tài liệu tham khảo và chú thích

[1] Glass GV. Primary, secondary, and meta-analysis of research. Educational Researcher 1976; 5:3-8.

[2] Normand SL. Meta-analysis: formulating, evaluating, combining, and reporting, Stat Med 1999;18(3):321-59.

[3] Higgins JPT, Thompson SG. Quantifying heterogeneity in a meta-analysis, Stat Med 2002;21:1539-1558.

[4] Egger M, Davey Smith G, Schneider M, Minder C. Bias in meta-analysis detected by a simple, graphical test. Br Med J 1997;315:629–34.

[5] Tang JL, Liu JL, Misleading funnel plot for detection of bias in meta-analysis. J Clin Epidemiol 2000;53(5):477-84.

[6] Peters JL, Sutton AJ, Jones DR, Abrams KR, Rushton L. Comparison of two methods to detect publication bias in meta-analysis. JAMA 2006;295(6):676-80.

[7] Macaskill P, Walter SD, Irwig L. A comparison of methods to detect publication bias in meta-analysis, Stat Med 2001;20:641-654.

Tóm tắt phân tích tổng hợp

ĐỐI VỚI CÁC BIẾN SỐ LIÊN TỤC	ĐỐI VỚI CÁC BIẾN SỐ NHỊ PHÂN
Nhóm 1 (số mẫu, trung bình, độ lệch chuẩn): $n_{1i}, x_{1i}, s_{1i}; i = 1, 2, 3, \dots k$	Nhóm 1 (số mẫu, số sự kiện): $n_{1i}, x_{1i}; i = 1, 2, 3, \dots k$
Nhóm 2 (số mẫu, trung bình, độ lệch chuẩn): n_{2i}, x_{2i}, s_{2i}	Nhóm 2 (số mẫu, số sự kiện): $n_{2i}, x_{2i}; i = 1, 2, 3, \dots k$
Độ ảnh hưởng (effect size, ES): $d_i = x_{2i} - x_{1i}$	Độ ảnh hưởng (effect size, ES) tính bằng tỉ số nguy cơ RR: $RR_i = \left(\frac{x_{2i}}{n_{2i}} \right) \div \left(\frac{x_{1i}}{n_{1i}} \right)$ Biến chuyển sang logarithm: $\theta_i = \log(RR_i)$

Phương sai của d_i : $s_{d_i}^2 = \frac{(n_{1i} - 1)s_{1i}^2 + (n_{2i} - 1)s_{2i}^2}{n_{1i} + n_{2i} - 2} \times \left(\frac{1}{n_{1i}} + \frac{1}{n_{2i}} \right)$	Phương sai của θ_i : $s_{\theta}^2 = \frac{1}{x_{1i}} - \frac{1}{n_{1i} - x_{1i}} + \frac{1}{x_{2i}} - \frac{1}{n_{2i} - x_{2i}}$
Sai số (standard error) của d_i : $s_{d_i} = \sqrt{s_{d_i}^2}$	Sai số của θ_i : $s_{\theta} = \sqrt{\frac{1}{x_{1i}} - \frac{1}{n_{1i} - x_{1i}} + \frac{1}{x_{2i}} - \frac{1}{n_{2i} - x_{2i}}}$
Trọng số: $W_i = \frac{1}{s_{d_i}^2}$	Trọng số: $W_i = \frac{1}{s_{\theta}^2}$
Ước số ảnh hưởng chung: $d = \sum_{i=1}^k W_i d_i / \sum_{i=1}^k W_i$	Ước số ảnh hưởng chung: $\theta = \sum_{i=1}^k W_i \theta_i / \sum_{i=1}^k W_i$
Phương sai của d: $s^2 = 1 / \sum_{i=1}^k W_i$	Phương sai của q: $s^2 = 1 / \sum_{i=1}^k W_i$
Khoảng tin cậy 95%: $d \pm 1,96 \times \sqrt{s^2}$	Khoảng tin cậy 95%: $\theta \pm 1,96 \times \sqrt{s^2}$
Index of homogeneity: $Q = \sum_{i=1}^k W_i (d_i - d)^2$	Index of homogeneity: $Q = \sum_{i=1}^k W_i (\theta_i - \theta)^2$
Index of heterogeneity: $I^2 = \frac{Q - (k - 1)}{Q}$	Index of heterogeneity: $I^2 = \frac{Q - (k - 1)}{Q}$
Xem xét publication bias: Phân tích hồi qui tuyến tính: $d_i = a + b * N_i$. (N_i là tổng số mẫu của nghiên cứu i). Xem ý nghĩa thống kê của b.	Xem xét publication bias: Phân tích hồi qui tuyến tính: $q_i = a + b * N_i$. (N_i là tổng số mẫu của nghiên cứu i). Xem ý nghĩa thống kê của b.
Ước tính phương sai giữa các nghiên cứu (between-study variance): $\tau^2 = \max \left[0, \frac{Q - (k - 1)}{\sum_{i=1}^k W_i - \frac{\sum_{i=1}^k W_i^2}{\sum_{i=1}^k W_i}} \right]$	Ước tính phương sai giữa các nghiên cứu (between-study variance): $\tau^2 = \max \left[0, \frac{Q - (k - 1)}{\sum_{i=1}^k W_i - \frac{\sum_{i=1}^k W_i^2}{\sum_{i=1}^k W_i}} \right]$

17 Phương pháp Bootstrap

Năm 1979, Giáo sư Bradley Efron (1) giới thiệu phương pháp phân tích có tên là “Bootstrap”. Chỉ trong vòng vài năm, phương pháp Bootstrap (2) được phát triển thêm và ứng dụng rất phổ biến, mà có người nói ví von là sự lan rộng của phương pháp này như là một trận... cháy rừng! Trong thực tế, cộng đồng thống kê học xem phương pháp Bootstrap là một cuộc *cách mạng* trong khoa học thống kê. Trong chương này, tôi sẽ giải thích ý tưởng và vài ứng dụng phổ biến của phương pháp Bootstrap. Tôi sẽ không giải thích lý thuyết đằng sau phương pháp Bootstrap, nhưng hi vọng qua vài ứng dụng, bạn đọc sẽ tìm hiểu những cơ sở lý thuyết của phương pháp này.

Một trong những chức năng chính yếu của thống kê là tóm lược một mẫu nghiên cứu (sample) và khái quát hoá dữ liệu (hay phát hiện) ra một quần thể (population) mà mẫu được thu thập. Chúng ta biết rằng các chỉ số liên quan đến mẫu được gọi là *statistic*. Một số statistic cơ bản là trung bình, trung vị, độ lệch chuẩn, tỉ lệ, v.v. Dĩ nhiên, một statistic hay chỉ số thống kê như số trung bình chẳng hạn sẽ dao động từ mẫu này đến mẫu khác, và chúng ta muốn biết mức độ dao động chung quanh trung bình quần thể. Chúng ta có thể dùng lý thuyết xác suất để ước tính tất cả các giá trị trung bình mẫu khả dĩ, và trình bày trong một phân bố gọi là *phân bố mẫu* (sampling distribution).

Nhưng trong nhiều trường hợp chúng ta không có lý thuyết xác suất để xây dựng một phân bố mẫu. Chẳng hạn như chúng ta không có phương pháp toán nào để xây dựng phân bố mẫu cho trung vị. Trong những trường hợp này, phương pháp Bootstrap có thể giúp chúng ta giải quyết vấn đề một cách lịch thiệp. Thật vậy, với Bootstrap, chúng ta có thể tạo ra phân bố mẫu cho bất cứ chỉ số thống kê nào mà có khi chẳng cần đến lý thuyết xác suất.

17.1 Lấy mẫu có hoàn lại và không có hoàn lại

Để hiểu phương pháp Bootstrap, chúng ta phải đi qua hai cách lấy mẫu: lấy mẫu có hoàn lại (sampling with replacement) và lấy mẫu không có hoàn lại (sampling without replacement). Để minh họa cho hai cách lấy mẫu, giả dụ chúng ta có một *quần thể* gồm 10 giá trị như sau:

```
population = c(1, 2, 3, 4, 5, 6, 7, 8, 9, 10)
```

Lấy mẫu không hoàn lại có nghĩa là mỗi lần lấy một giá trị từ quần thể, giá trị đó không được hoàn lại cho quần thể. Vì thế, giá trị của mẫu luôn luôn đặc thù, không giống nhau. Trong R, chúng ta có hàm `sample(x, n, replace=F)` để lấy mẫu không hoàn lại. Ví dụ:

```
> sample(population, 5, replace=F)
```

```
[1] 9 1 5 3 8
```

Trong hàm trên, chúng ta lấy mẫu với 5 đối tượng từ quần thể `population`, và không có hoàn lại. Chú ý tất cả các giá trị mẫu không giống nhau. Chúng ta có thể lấy mẫu nhiều lần, và mỗi mẫu có giá trị khác nhau:

```
> sample(population, 5, replace=F)
```

```
[1] 7 8 5 6 10
```

```
> sample(population, 5, replace=F)
```

```
[1] 7 2 5 3 1
```

```
> sample(population, 5, replace=F)
```

```
[1] 3 2 7 6 9
```

Lấy mẫu có hoàn lại có nghĩa là lấy một giá trị từ quần thể, rồi bỏ giá trị mới lấy ra vào quần thể đó, và lần hai tiếp tục lấy một giá trị khác (nhưng cũng có thể là giá trị cũ). Trong R, chúng ta có hàm `sample(x, n, replace=T)` giúp lấy mẫu có hoàn lại:

```
> sample(population, 5, replace=T)
```

```
[1] 1 9 5 4 1
```

Trong hàm trên, chúng ta lấy 5 giá trị từ quần thể `population`, nhưng có hoàn lại. Chú ý giá trị 1 lặp lại 2 lần. Chúng ta có thể lấy nhiều mẫu như thế và kết quả cũng có thể lặp lại hơn 2 lần, hay không lặp lại:

```
> sample(population, 5, replace=T)
```

```
[1] 8 7 7 3 3
```

```
> sample(population, 5, replace=T)
```

```
[1] 4 10 10 2 10
```

```
> sample(population, 5, replace=T)
```

```
[1] 2 9 4 6 10
```

Phương pháp bootstrap dựa vào ý tưởng lấy mẫu có hoàn lại. Ý tưởng chủ đạo của bootstrap là dùng dữ liệu của một mẫu nghiên cứu để xây dựng một quần thể, với mục tiêu là xấp xỉ phân bố mẫu của một chỉ số thống kê.

17.2 Giải thích bootstrap: xác định khoảng tin cậy 95% cho trung vị

Chúng ta muốn xác định khoảng tin cậy 95% (KTC95) cho số trung vị. Nhưng không có lý thuyết thống kê nào cung cấp một giải pháp để xác định KTC95 cho số trung vị. Trong trường hợp này, phương pháp bootstrap có thể rất có ích để đáp ứng mục tiêu. Để cụ thể hoá vấn đề, chúng ta có số liệu về đau thấp khớp của 11 bệnh nhân như sau:

0.05, 0.15, 0.35, 0.25, 0.20, 0.05, 0.10, 0.05, 0.30,
0.05, và 0.25

hay dùng ngôn ngữ R:

```
pain=c(0.05, 0.15, 0.35, 0.25, 0.20, 0.05, 0.10, 0.05,  
0.30, 0.05, 0.25)
```

(Chú ý chỉ số càng cao, độ đau càng nghiêm trọng). Số trung bình của 11 bệnh nhân là 0.163 và độ lệch chuẩn 0.112. Vì số trung bình thấp hơn 2 lần độ lệch chuẩn, chúng ta có thể kết luận rằng biến số này không tuân theo luật phân bố chuẩn. Số trung vị của `pain` là 0.15:

```
> median(pain)
```

```
[1] 0.15
```

Vấn đề bây giờ là xác định khoảng tin cậy 95% của số trung vị. Nói cách khác, nếu nghiên cứu được lặp lại 1000 lần, và mỗi lần chọn 11 đối tượng, thì KTC95 của số trung vị ra sao. Phương pháp bootstrap rất có ích để giải quyết vấn đề. Phương pháp này được tiến hành như sau:

- Bước 1: Bắt đầu bằng mẫu gốc $x_1, x_2, x_3, \dots, x_n$. Trong ví dụ trên:

0.05, 0.05, 0.05, 0.05, 0.10, 0.15, 0.20, 0.25, 0.25,
0.30, 0.35

- Bước 2: Chọn ngẫu nhiên n cá nhân từ mẫu gốc với qui trình *lấy mẫu có hoàn lại*. Mỗi lần chọn mẫu, tính số trung vị và tạm gọi số này là m_i .
- Bước 3: Lặp lại bước hai N lần (N thường là 1000 hay 10000 hay thậm chí 1 triệu – tùy theo nhu cầu). Trong trường hợp trên, 10 mẫu đầu tiên có thể là:

Mẫu 1: 0.05 0.05 0.10 0.05 0.20 0.20 0.05 0.25 0.10 0.10 0.30 → 0.10
 Mẫu 2: 0.05 0.25 0.30 0.05 0.30 0.30 0.05 0.05 0.25 0.05 0.35 → 0.25
 Mẫu 3: 0.35 0.10 0.05 0.25 0.05 0.05 0.20 0.25 0.15 0.25 0.10 → 0.15
 Mẫu 4: 0.05 0.05 0.10 0.25 0.15 0.05 0.20 0.05 0.10 0.25 0.05 → 0.10
 Mẫu 5: 0.30 0.25 0.05 0.25 0.25 0.05 0.20 0.05 0.25 0.05 0.05 → 0.20
 Mẫu 6: 0.05 0.25 0.10 0.05 0.05 0.15 0.25 0.05 0.05 0.05 0.05 → 0.05
 Mẫu 7: 0.05 0.15 0.25 0.05 0.05 0.30 0.20 0.25 0.30 0.05 0.35 → 0.20
 Mẫu 8: 0.05 0.05 0.20 0.05 0.10 0.05 0.05 0.10 0.20 0.10 0.05 → 0.05
 Mẫu 9: 0.05 0.05 0.10 0.25 0.20 0.25 0.25 0.20 0.35 0.25 0.35 → 0.25
 Mẫu 10: 0.05 0.05 0.05 0.25 0.35 0.25 0.25 0.15 0.20 0.20 0.15 → 0.20

v.v.

(Chú ý: số phía sau → có nghĩa là số trung vị cho từng mẫu)

- Bước 4: Đến đây chúng ta có N số trung vị. Sắp xếp N số từ thấp đến cao và đánh số: 1, 2, 3, ..., N . Chọn số trung vị ở hạng 2.5% và 97.5% của N số trung vị, và đó chính là khoảng tin cậy 95%. Chẳng hạn như nếu $N = 1000$ lần, thì khoảng tin cậy 95% chính là số trung vị hàng thứ 25 và 975.

Các bước tính toán trên có thể thực hiện bằng ngôn ngữ R (hay một ngôn ngữ hay phần mềm nào mà bạn đọc quen thuộc) rất dễ dàng. Đối với R, các mã sử dụng (và giải thích kèm theo) như sau:

```
# nhập các số liệu gốc vào một vector có tên là x
pain = c(0.05,0.15,0.35,0.25,0.20,0.05,0.10,0.05,0.30,0.05,0.25)

# bước 2 - xác định xem có bao nhiêu số liệu trong vector x
n = length(pain)

# muốn lấy 10000 mẫu từ số liệu gốc, còn gọi là bootstrap samples
B = 10000


# tạo một vector mới để chứa số trung vị
median = numeric(B)
```

```
# bắt đầu lấy B mẫu và mỗi mẫu tính toán số trung vị
for (i in 1:B)
{
  bs.sample = sample(pain, n, replace=T)
  median[i] = median(bs.sample)
}

# Bước 3: ước tính khoảng tin cậy 95%
quantile(median, probs=c(0.025, 0.975))
```

Hàm quantile cho chúng ta biết khoảng tin cậy 95% của số trung vị là 0.05 đến 0.25. Chúng ta cũng có thể xem phân bố của 10000 số trung vị mẫu:

```
> hist(median, col="blue", border="white", main="")
```



Qua ví dụ trên, chúng ta có thể tóm tắt phương pháp bootstrap như sau: phương pháp bootstrap là một phương pháp mô phỏng dựa vào dữ liệu thực tế để dùng cho suy luận khoa học. Phương pháp này có thể tóm lược trong 3 bước:

1. Từ một mẫu nghiên cứu n đối tượng, lấy nhiều mẫu bootstrap [có hoàn lại] và mỗi mẫu có n đối tượng;
2. Trong mỗi mẫu bootstrap, tính chỉ số thống kê θ^* ;
3. Xem xét phân bố θ^* .

17.3 Ứng dụng 1: So sánh hai số trung vị

Số liệu dưới đây là số ngày sống sót của hai nhóm chuột. Nhóm thứ nhất là nhóm chứng (không được điều trị), và nhóm thứ hai là nhóm được điều trị. Thời gian sống sót của nhóm 1 (trung vị) là 46 ngày, và nhóm điều trị là 94 ngày. Câu hỏi đặt ra là điều trị có thật sự ảnh hưởng đến thời gian sống sót:

Nhóm chứng ($n = 9$): 52, 104, 146, 10, 51, 30, 40, 27, 46

Nhóm điều trị ($n = 7$): 94, 197, 16, 38, 99, 141, 23

Chúng ta có thể ứng dụng phương pháp bootstrap để giải đáp câu hỏi trên. Chúng ta sẽ dùng R như sau:

```
# nhập dữ liệu
control = c(52, 104, 146, 10, 51, 30, 40, 27, 46)
treatment = c(94, 197, 16, 38, 99, 141, 23)

# mẫu bootstrap 10000
B = 10000


# định danh hai biến cho 2 nhóm
con = rep(NA, B)
trt = rep(NA, B)

# lấy mẫu bootstrap
for (i in 1:B) {
  con[i] = median(sample(control, replace=T))
  trt[i] = median(sample(treatment, replace=T))
  dif[i] = trt[i]-con[i]
}

# tìm khoảng tin cậy 95% của dif
ci.bs = c(quantile(dif, c(0.025)), quantile(dif, c(0.975)))

# tạo dataframe để vẽ biểu đồ
diff = data.frame(dif)

library(ggplot2)
p = ggplot(data=diff, aes(x=dif))
p = p + geom_histogram(aes(y=..density..), binwidth=5,
  color="black", fill="white")
p = p + geom_density(alpha=0.2, fill="#FF6666")
p = p + geom_vline(xintercept=0, col="#BB0000",
  linetype="dashed")
p = p + geom_vline(xintercept=ci.bs[1], col="#BB0000",
  linetype="longdash")
p = p + geom_vline(xintercept=ci.bs[2], col="#BB0000",
  linetype="longdash")
p = p + xlab("Difference")
p
```



```
> quantile(dif, c(0.025, 0.5, 0.975))
2.5%    50%  97.5%
-29     48   101
```

Chúng ta thấy tính trung bình, hiệu số của 2 trung vị là 48 ngày (tính trung bình, nhóm được điều trị sống lâu hơn nhóm chứng 48 ngày), nhưng khoảng tin cậy 95% dao động từ -29 đến 101 ngày. Nói cách khác, nhóm điều trị có thể có thời gian sống sót thấp hơn nhóm chứng 29 ngày, hoặc cao hơn nhóm chứng 101 ngày. Với khoảng tin cậy 95% như thế, chúng ta không thể kết luận hiệu quả của điều trị về thời gian sống sót.

17.4 Ứng dụng 2: So sánh hai tỉ lệ

Bảng số liệu dưới đây tóm lược một nghiên cứu về aspirin và bệnh tim mạch ở người đàn ông trung niên. Nghiên cứu được thiết kế theo mô hình thử nghiệm lâm sàng đối chứng ngẫu nhiên (randomized controlled trial). Theo đó, một nhóm gồm 22071 nam được chia thành 2 nhóm một cách ngẫu nhiên: nhóm thứ nhất bao gồm 11037 người được cho uống aspirin mỗi ngày, và nhóm hai bao gồm 11034 người không uống aspirin (còn gọi là nhóm chứng). Các nhà nghiên cứu muốn biết aspirin cho giảm nguy cơ bệnh nhồi máu cơ tim. Kết quả sau 3 năm nghiên cứu có 104 người trong nhóm điều trị và 189 người trong nhóm chứng bị nhồi máu cơ tim:

NHÓM	SỐ ĐỐI TƯỢNG	SỐ BỊ BỆNH (NHỒI MÁU CƠ TIM)	SỐ KHÔNG MẮC BỆNH
Aspirin	11037	104	10937
Placebo (chứng)	11034	189	10845

Câu hỏi nghiên cứu là tỉ lệ (hay nguy cơ) bệnh của hai nhóm có thực sự khác nhau. Một phương pháp đơn giản nhất để trả lời câu hỏi trên là so sánh hai nguy cơ (risk). Trong y khoa, nguy cơ có thể xem như là xác suất mắc bệnh. Dựa vào số liệu trên, chúng ta có thể tính nguy cơ mắc bệnh của nhóm aspirin là

$$\text{Risk}_1 = 104 / 11037 = 0.0094$$

và nguy cơ của nhóm chứng:

$$\text{Risk}_2 = 189 / 11034 = 0.0171$$

Tỉ số của hai nguy cơ ($\text{Risk}_1 / \text{Risk}_2$) thường được gọi là *risk ratio (RR)*. Nếu $\text{RR} = 1$, thuốc không có hiệu quả; nếu $\text{RR} < 1$, aspirin giảm nguy cơ bệnh; nhưng nếu $\text{RR} > 1$ thì điều đó có nghĩa là aspirin tăng nguy cơ bệnh. Trong trường hợp trên, $\text{RR} = 0.0094 / 0.0171 = 0.55$. Nói cách khác, nguy cơ mắc bệnh trong nhóm aspirin bằng 55% nhóm chứng. Một cách khác để kết luận là aspirin giảm nguy cơ nhồi máu cơ tim 45%.

Nhưng vấn đề là ước tính KTC95 của RR, và qua đó chúng ta có thể suy luận về hiệu quả của aspirin. Trong thực tế, chúng ta có thể ước tính KTC95 bằng lí thuyết xác suất [3], nhưng ở đây, chúng ta sẽ ứng dụng phương pháp bootstrap để ước tính KTC95 cho RR.

```
# nhập dữ liệu cho 2 nhóm
n = c(11037, 11034)
disease = c(104, 189)

# tạo 2 biến có tên là aspirin và control. Mỗi biến bao gồm
# giá trị 1 (bệnh), 0 (không bệnh).
Ví dụ: hàm rep(1, disease[1]) tạo ra
# 104 đối tượng với giá trị 1.
Tương tự rep(0, n[1]-disease[1]) tạo ra
# 11037-104 đối tượng với giá trị 0.
Hàm c(rep(1, disease[1]), rep(0,
# n[1]-disease[1])) là nhập hai vector thành một và gọi
là aspirin.
```

```

aspirin = c(rep(1, disease[1]), rep(0, n[1]-disease[1]))
control = c(rep(1, disease[2]), rep(0, n[2]-disease[2]))

# xác định số mẫu bootstrap
B = 10000

# tạo ra hai vector trống cho nhóm aspirin và control
bs1 = rep(NA, B)
bs2 = rep(NA, B)

# lấy mẫu bootstrap
for (i in 1:B) {
  resample1 = sample(aspirin, n[1], replace=T)
  dis1 = sum(resample1)
  resample2 = sample(control, n[2], replace=T)
  dis2 = sum(resample2)
  bs1[i] = dis1/n[1]
  bs2[i] = dis2/n[2]
}

RR = bs1/bs2
quantile(RR, c(0.025, 0.50, 0.975))

```

Với hàm `quantile` trên, chúng ta sẽ thấy `RR` trung bình là 0.55 (tức như chúng ta tính “thủ công”). Hơn nữa, khoảng tin cậy 95% của `RR` dao động trong khoảng 0.43 đến 0.70. Nói cách khác, aspirin giảm nguy cơ bệnh từ 31% đến 57%. Vì khoảng tin cậy 95% đều dưới 1, chúng ta có chứng cứ để kết luận aspirin có hiệu quả giảm nguy cơ bệnh nhồi máu cơ tim.

Chúng ta có thể dùng `ggplot2` để vẽ biểu đồ phân bố của `RR`. Để vẽ biểu đồ này, trước hết chúng ta phải đưa 10000 giá trị `RR` vào một dataframe tạm gọi là `rr`. Sau đó vẽ biểu đồ phân bố, và vẽ khoảng tin cậy 95%.

```

# đưa khoảng tin cậy 95% vào biến ci.bs
ci.bs = c(quantile(RR, 0.025), quantile(RR, 0.975))

# tạo ra một dataframe
rr = data.frame(RR)

```

```
library(ggplot2)

p = ggplot(data=rr, aes(x=RR))

p = p + geom_histogram(aes(y=..density..),
  bandwidth=0.02, col= "blue ", fill= "white ")


p = p + geom_density(alpha=0.2, fill= "#FF6666 ")

p = p + geom_vline(xintercept=1, col= "#BB0000 ",
  linetype= "dashed ")

p = p + geom_vline(xintercept=ci.bs[1], col= "#00AA00 ",
  linetype= "longdash ")

p = p + geom_vline(xintercept=ci.bs[2], col= "#00AA00 ",
  linetype= "longdash ")

p
```



Dĩ nhiên, với phương pháp bootstrap, chúng ta có thể tính hiệu số ($\text{Risk}_1 - \text{Risk}_2$) thay vì tỉ số nguy cơ ($\text{Risk}_1 / \text{Risk}_2$).

17.5 Ứng dụng 3: So sánh với phương pháp cổ điển

Dữ liệu sau đây được thu thập từ một nghiên cứu đánh giá một phương pháp can thiệp lên bệnh nhân mất trí nhớ. Mỗi bệnh nhân phải trải qua 20 test

về xử lý tình huống hàng ngày, như tự làm vệ sinh, thay quần áo, mở cửa bằng chìa khoá, v.v. Số liệu dưới đây phản ánh phần trăm bệnh nhân thành công trong số 20 test.

Nhóm can thiệp ($n = 11$): 0.05, 0.15, 0.35, 0.25, 0.20, 0.05, 0.10, 0.05, 0.30, 0.05, 0.25

Nhóm chứng ($n = 8$): 0, 0.15, 0, 0.05, 0, 0, 0.05, 0.10

Câu hỏi nghiên cứu là can thiệp có hiệu quả tăng sự độc lập của bệnh nhân. Giả thuyết là phần trăm làm đúng của nhóm can thiệp không khác với nhóm chứng. Chúng ta có thể dùng phương pháp kiểm định t để kiểm định giả thuyết:

```
treated = c(0.05, 0.15, 0.35, 0.25, 0.20, 0.05, 0.10,
0.05, 0.30, 0.05, 0.25)
control = c(0, 0.15, 0, 0.05, 0, 0, 0.05, 0.10)
t.test(treated, control)
```

```
> t.test(treated, control)
```

Welch Two Sample t-test

data: treated and control

$t = 3.0583$, $df = 15.485$, **p-value = 0.007736**

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

0.03655926 0.20321347

sample estimates:

mean of x mean of y

0.1636364 0.0437500

Chúng ta thấy giả thuyết không có hiệu quả có thể bác bỏ vì trị số $P = 0.0077$, và khoảng tin cậy 95% khác biệt giữa hai nhóm là 0.037 đến 0.203.

Nhưng phương pháp kiểm định t có vấn đề về giả định, vì số liệu không tuân theo luật phân bố chuẩn, và phương sai của hai nhóm cũng không tương đương nhau. Do đó, chúng ta sẽ ứng dụng phương pháp bootstrap để kiểm định giả thuyết. Chúng ta sẽ làm theo các bước:

1. Lấy mẫu từ nhóm điều trị
2. Lấy mẫu từ nhóm chứng
3. Tính hiệu số của 2 số trung bình
4. Lặp lại bước 1-3 B lần
5. Xem xét phân bố để xác định khoảng tin cậy 95%

Chúng ta triển khai các bước trên qua R như sau:

```
treat = c(0.05, 0.15, 0.35, 0.25, 0.20, 0.05, 0.10,
0.05, 0.30, 0.05, 0.25)
control = c(0, 0.15, 0, 0.05, 0, 0, 0.05, 0.10)
n1 = length(treat)
n2 = length(control)
B = 10000
difference = numeric(B)
no.effect = 0
for (i in 1:B) {
  bs.treat <- sample(treat, n1, replace=T)
  bs.control <- sample(control, n2, replace=T)
  difference[i] = mean(bs.treat) - mean(bs.control)
  if (difference[i] < 0) no.effect = no.effect+1
}
```

Chúng ta tìm hiểu trong số 10000 mẫu, có bao nhiêu mẫu mà can thiệp có ảnh hưởng:

```
> no.effect/10000
```

```
[1] 5e-04
```


Ở một góc độ đơn giản, chúng ta có thể nói xác suất can thiệp có hiệu quả là $1 - 0.0005 = 0.9995$ hay 99.95%.

Khoảng tin cậy 95% giữa 2 nhóm dao động trong khoảng 0.05 đến 0.19:

```
> quantile(difference, probs=c(0.025, 0.50, 0.975))
      2.5%      50%      97.5%
0.04659091 0.11931818 0.19261364
```

Chúng ta có thể xem qua phân bố của khác biệt giữa hai nhóm:

```
hist(difference, breaks=20, col="blue", border="white")
```



Chúng ta chú ý khoảng tin cậy 95% bootstrap của hai chỉ số trung bình giữa hai nhóm (0.05 đến 0.19) không khác nhiều so với phương pháp cổ điển (0.037 đến 0.203). Điều này cho thấy phương pháp cổ điển khá “robust” khi dữ liệu không đáp ứng các giả định phổ biến.

Nói tóm lại, phương pháp phân tích bootstrap dựa vào khái niệm tái chọn mẫu (resampling) và mô phỏng (dựa trên dữ liệu thực tế) để tìm phân bố cho một chỉ số thống kê. Trong thực tế, phương pháp bootstrap đã được ứng dụng cho rất nhiều vấn đề phức tạp mà phương pháp cổ điển không có giải pháp. Cần phải nói rằng phương pháp bootstrap không thể biến dữ liệu xấu thành dữ liệu tốt được. Trong vài trường hợp, phương pháp bootstrap vẫn thất bại khi nghiên cứu được thiết kế quá kém hay không phù hợp. Việc ứng dụng phương pháp bootstrap do đó đòi hỏi suy xét cẩn thận.

Chú thích và Tài liệu tham khảo

- [1] Efron B (1979). Bootstrap methods: Another look at jackknife. Ann. Stat. 7, 1-26.
- [2] Danh từ “bootstrap” xuất phát từ cuốn tiểu thuyết “The Adventures of Baron Munchausen” của Rudolph Erich Raspe. Trong tiểu thuyết, vị bá tước bị rơi xuống đáy một cái hồ, ông nghĩ rằng ông có thể tự mình thoát khỏi bằng cách dùng dây giấy (bootstrap) để từ từ kéo mình lên khỏi hồ.

[3] Phương pháp ước tính khoảng tin cậy 95% của một tỉ số nguy cơ RR dựa vào phương pháp Greenwood. Theo đó, RR được hoán chuyển sang đơn vị log; tính phương sai và sai số chuẩn và khoảng tin cậy 95% cho logRR; hoán chuyển ngược lại đơn vị RR. Để dễ theo dõi, tôi in lại kết quả nghiên cứu trong bảng dưới đây:

NHÓM	SỐ ĐỐI TƯỢNG	SỐ BỊ BỆNH (NHÓI MÁU CƠ TIM)	SỐ KHÔNG MẮC BỆNH
Aspirin	11037	104	10937
Placebo (chứng)	11034	189	10845

Bước 1: hoán chuyển từ RR sang logRR. Chúng ta biết rằng $RR = 0.55$, nên

$$\log RR = \log(0.55) = -0.598$$

Bước 2: tính phương sai, sai số chuẩn và khoảng tin cậy 95% của logRR:

$$\text{var}(\log RR) = \left(\frac{1}{104} - \frac{1}{11037} \right) + \left(\frac{1}{189} - \frac{1}{11034} \right) = 0.0147$$

Sai số chuẩn của logRR:

$$SE(\log RR) = \sqrt{\text{var}(\log RR)} = \sqrt{0.0147} = 0.121$$

Khoảng tin cậy 95% của logRR:

$$\begin{aligned} \log RR \pm 1.96 \times SE(\log RR) &= -0.598 \pm 1.96 \times 0.121 \\ &= -0.835, -0.361 \end{aligned}$$

Bước 3: hoán chuyển ngược lại đơn vị tỉ số:

$$95\%CI\ RR = \exp(-0.835), \exp(-0.361) = 0.43, 0.70$$

18

Phương pháp Bayes

Phương pháp phân tích dữ liệu cổ điển và phổ biến dựa vào lí thuyết *phản nghiệm*, nhưng là một phương pháp có nhiều khiếm khuyết vốn đã được chỉ ra ngay từ khi phương pháp này ra đời vào khoảng 100 năm trước. Phương pháp thống kê cổ điển được tiến hành 3 bước:

- Bước thứ nhất, phát biểu giả thuyết vô hiệu H_0 ;
- Bước thứ hai, thu thập dữ liệu D ; và
- Bước thứ ba, ước tính xác suất D xảy ra nếu H_0 là thật: $P(D | H_0)$.

Đó là qui trình chứng minh đảo ngược (proof by contradiction) hay còn gọi là *phản chứng*. Qui trình này có thể áp dụng trong toán học, nhưng khi ứng dụng vào khoa học thực nghiệm thì nhiều khi trở nên... vô duyên. Trong khoa học thực nghiệm, chúng ta muốn biết với dữ liệu thu thập được, xác suất giả thuyết H_0 đúng là bao nhiêu, chứ không ai lại đặt câu hỏi nếu giả thuyết H_0 là đúng thì xác suất D xảy ra là bao nhiêu!

Có thể minh họa trường hợp trên qua vấn đề chẩn đoán và xét nghiệm trong y khoa. Phương pháp cổ điển hiện nay cũng giống như trả lời câu hỏi “*nếu tôi mắc bệnh thì xác suất kết quả xét nghiệm dương tính là bao nhiêu*”. Nhưng trong thực tế, bệnh nhân muốn biết ngược lại: “*nếu kết quả xét nghiệm là dương tính, xác suất mà tôi mắc bệnh là bao nhiêu?*” Phương pháp phân tích cổ điển không thể trả lời câu hỏi sau. Trong vài năm gần đây, một phương pháp phân tích “mới” ra đời và đang dần trở thành phổ biến trong nghiên cứu khoa học, vì nó có thể trả lời câu hỏi mà chúng ta quan tâm: *với dữ liệu thực tế này, xác suất giả thuyết của tôi đúng là bao nhiêu?*

18.1 Giới thiệu khái niệm Bayes

Nói là “mới” nhưng trong thực tế thì không mới, bởi vì cơ sở lý thuyết của phương pháp này đã ra đời từ thế kỉ 18. Đó là suy luận theo trường phái Bayes (Bayesian inference) do Thomas Bayes đề xuất vào năm 1763 [1]. Thomas Bayes là một linh mục, nhưng cũng là một nhà toán học tài tử. Tuy là “tài tử” nhưng di sản của ông để lại (chỉ một bài báo duy nhất) làm thay đổi cả thế giới khoa học, thay đổi cách suy nghĩ về sự bất định trong khoa học, và chỉ ra một phương pháp suy luận hoàn toàn logic. Ngày nay, phương pháp Bayes được ứng dụng trong hầu hết tất cả lĩnh vực khoa học, kể cả trong công nghệ thông tin (ứng dụng Bayes trong việc ngăn chặn những thư rác điện tử), tiên lượng kinh tế, phân tích các mối liên hệ xã hội, và lý giải qui trình suy nghĩ của con người. Ngày nay, suy luận theo trường phái Bayes được nhắc đến trên báo chí đại chúng chứ không chỉ trong báo khoa học. Những tờ báo lớn như *New York Times*, *Economist*, *Guardian*, v.v. đều thường xuyên nhắc đến phương pháp suy luận Bayes.

Suy luận Bayes dựa vào định lý Bayes (Bayesian Theorem). Có thể phát biểu định lý Bayes theo ngôn ngữ hàng ngày như sau: những gì chúng ta *biết* là tổng hợp những gì chúng ta đã biết cộng với *chứng cứ* thực tế. Có thể nói rằng Định lý Bayes thể hiện cách suy nghĩ rất phổ biến của tất cả chúng ta: đó là chúng ta tiếp thu kiến thức một cách tích lũy.

Để minh họa cho ý tưởng trên, chúng ta thử xem qua ví dụ sau đây. Giả dụ rằng chúng ta có số liệu về chiều cao (tính bằng cm) của 10 người như sau:

156, 158, 160, 162, 164, 166, 168, 170, 172, 175

Với số liệu trên, chúng ta có thể tính trị số trung bình là 165.1 cm.

Nhưng nếu tôi biết rằng số liệu đó được thu thập trên 670 người, và trong đó có 20 người với chiều cao 156 cm, 30 người với chiều cao 158 cm, 50 người có chiều cao 160 cm, v.v. (xem bảng dưới đây). Thì số trung bình bây giờ chắc chắn không phải là 165.1 cm, vì nó còn tùy thuộc vào thông tin về số đối tượng cho từng chiều cao.

CHIỀU CAO	SỐ NGƯỜI	XÁC SUẤT
156	20	0.030
158	30	0.045
160	50	0.075
162	100	0.149
164	150	0.224
166	130	0.194
168	100	0.149
170	50	0.075
172	30	0.045
175	10	0.015
Tổng	670	1.000

Nếu chúng ta diễn tả số người bằng xác suất (cột 3 trong bảng trên), thì xác suất đó có thể xem như là một trọng số. Bây giờ, chiều cao trung bình có thể tính như là tổng tích số của chiều cao và trọng số:

$$(156 \times 0.030) + (158 \times 0.045) + \dots + (175 \times 0.015) = 164.85$$

CHIỀU CAO (x_i)	SỐ NGƯỜI	XÁC SUẤT (p_i)	$x_i * p_i$
156	20	0.030	4.66
158	30	0.045	7.07
160	50	0.075	11.94
162	100	0.149	24.18
164	150	0.224	36.72
166	130	0.194	32.21
168	100	0.149	25.07
170	50	0.075	12.69
172	30	0.045	7.70
175	10	0.015	2.61
Tổng	670	1.000	164.85

Như vậy, chiều cao trung bình bây giờ chính xác là 164.85 cm, chứ không phải 165.1 cm.

Ví dụ trên đây cho thấy kết quả phân tích có thể thay đổi khi chúng ta có thông tin. Trong trường hợp 1, chúng ta không có thông tin nào khác là 10 giá trị chiều cao, và chỉ có thể dựa vào đó để tính giá trị trung bình. Nhưng trong trường hợp 2, chúng ta có thông tin tiên định về phân bố của chiều cao trong cộng đồng, nên số trung bình chính xác hơn.

Suy luận Bayes có thể phát biểu một cách đơn giản như sau:

$$[\text{Thông tin đang có}] * [\text{Thông tin trước đây}] = [\text{Thông tin mới}]$$

Trong ví dụ trên, thông tin đang có là 10 giá trị về chiều cao; thông tin trước đây chính là xác suất phân bố của từng chiều cao; và thông tin mới là tích số của hai thông tin đang có và thông tin trước đây.

Như đã nói ở trên, suy luận Bayes dựa vào định lý Bayes. Định lý Bayes dĩ nhiên cũng có thể mô tả một cách đơn giản qua xác suất. Gọi H là giả thuyết, và D là dữ liệu thực tế, Định lý Bayes phát biểu rằng xác suất H với điều kiện D xảy ra – kí hiệu $P(H | D)$ – là:

$$P(H | D) = \frac{P(D | H) \times P(H)}{P(D)}$$

Trong đó

- $P(H)$ là xác suất giả thuyết trước khi làm thí nghiệm; và
- $P(D | H)$ là xác suất dữ liệu xảy ra với điều kiện giả thuyết H là đúng;
- $P(D)$ là phân bố của dữ liệu, có thể xem là một hằng số.

Thay vì dùng H như là một giả thuyết, chúng ta có thể thay H bằng θ như là một thông số chúng ta muốn biết. Trường phái cổ điển hay frequentist (tần số) xem θ là cố định, nhưng trường phái Bayes xem θ có một phân bố riêng, và do đó, không cố định. Chúng ta cũng có thể viết theo ngôn ngữ của hàm số:

$$f(\theta | D) = \frac{f(D | \theta) f(\theta)}{f(D)}$$

hay

$$f(\theta | D) \propto f(D | \theta) \times f(\theta)$$

Một cách khác để phát biểu Định lý Bayes là:

Likelihood $\times$ Prior Probability of Hypothesis = Posterior Probability of Hypothesis

Trong đó,

- Likelihood = $P(D | H)$, hay $f(D | \theta)$, tức phân bố của dữ liệu;
- Prior Probability of Hypothesis = $P(H)$ hay $f(\theta)$, có thể xem là xác suất tiên định;
- Posterior Probability of Hypothesis = $P(H | D)$, hay $f(\theta | D)$, có thể xem là **xác suất hậu định**.

Nhìn qua định lý trên, chúng ta thấy suy luận Bayes có 3 thông tin. Thông tin thứ nhất là thông tin mà chúng ta muốn biết, thuật ngữ tiếng Anh gọi là *posterior information* - thông tin hậu định. Thông tin thứ hai là thông tin chúng ta đã biết, tiếng Anh là *prior information* - thông tin tiên định. Và, thông tin thứ ba là thông tin thực tế, thuật ngữ tiếng Anh là *likelihood*. Ở đây, “thông tin” có nghĩa là xác suất hay phân bố.

18.2 Ứng dụng phương pháp Bayes I: Ước tính một tỉ lệ

Một cuộc điều tra dịch tễ học trong một quần thể 1500 người cho thấy tỉ lệ loãng xương là 25%. Chúng ta sẽ diễn giải tỉ lệ này có nghĩa gì - qua lăng kính lý thuyết Bayes. Dĩ nhiên, nếu cuộc điều tra được lặp lại ở một quần thể khác, tỉ

lệ có thể không phải là 25% nhưng là một con số khác, có thể thấp hơn, nhưng cũng có thể cao hơn 25%. Do đó, thông số tỉ lệ loãng xương, θ , cần phải xem như là một phân bố. Để phân tích theo phương pháp Bayes, chúng ta cần thông tin tiên định. Thông tin tiên định phải được mô tả bằng một luật xác suất.

Chúng ta có thể tưởng tượng tỉ lệ loãng xương có thể dao động trong khoảng 1% đến 100%. Đơn giản nhất là mỗi tỉ lệ có xác suất tiên định như nhau, còn gọi là uniform distribution. Nói cách khác, xác suất có tỉ lệ loãng xương 1% cũng bằng với xác suất có tỉ lệ loãng xương 100%. Chúng ta biết rằng xác suất tiên định này không hợp lí, vì không có cộng đồng nào có tỉ lệ loãng xương 1% hay 100%.

TỈ LỆ LOÃNG XƯƠNG	XÁC SUẤT TIỀN ĐỊNH (UNIFORM DISTRIBUTION)
1%	0.01
2%	0.01
3%	0.01
...	...
100%	0.01

Một luật phân bố rất có ích để mô tả thông tin tiên định là luật phân bố beta (beta distribution). Luật phân bố beta có 2 thông số, tạm gọi là a và b , và được định nghĩa như sau:

$$P(x | a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1}$$

Trong đó $P(x | a, b)$ là xác suất của giá trị x xác định bởi 2 thông số a và b . $\Gamma(a+b)$ và $\Gamma(a)$, $\Gamma(b)$ là luật phân bố gamma. Theo lí thuyết xác suất, số trung bình và phương sai của phân bố beta với hai thông số a và b là:

Trung bình:

$$m = a / (a + b) \quad [1]$$

và phương sai:

$$v = \frac{ab}{(a+b)^2(a+b+1)} \quad [2]$$

hoặc:

$$v = \frac{m(1-m)}{a+b+1}$$

Chúng ta cần ước tính hai thông số a và b . Chúng ta biết rằng nhiều nghiên cứu trước đây cho thấy tỉ lệ loãng xương thường dao động trong khoảng 20%

đến 35%, rất ít quần thể nào có tỉ lệ loãng xương thấp hơn 20% hay cao hơn 35%. Dựa vào dữ liệu này, chúng ta có thể suy luận rằng tỉ lệ loãng xương trung bình là khoảng 27%,

$$m = 0.27$$

và khoảng tin cậy 95% là từ 20% đến 35%, và do đó độ lệch chuẩn là

$$s = (0.35 - 0.25) / 2 = 0.05$$

hay $v = (0.05)^2 = 0.025$. Dựa vào hai công thức trên và sau vài thao tác đại số, chúng ta có:

$$a + b = [m(1 - m)/s^2] - 1$$

Thay thế $m = 0.27$ và $v = 0.025$, chúng ta có

$$a + b = 6.884$$

Nhưng [1] cho biết


$$a = m(a + b)$$

Thay thế m và $a+b$ vào phương trình trên, chúng ta có $a = 0.27 \cdot 6.884 = 1.86$, và $b = 6.884 - 1.86 = 5.024$.

$$\theta \sim \text{Beta}(1.86, 5.024)$$

Chúng ta có thể thể hiện phân bố này bằng R (**Biểu đồ 1**):

```
curve(dbeta(x, 1.86, 5.024), from=0, to=1,
      ylab="Xác suất", xlab="Tỉ lệ loãng xương", lty=1, lwd=2)
```



Biểu đồ 1. Phân bố thông tin tiên định beta(1.86, 5.024). Trục hoành là tỉ lệ loãng xương, dao động 0 đến 1; trục tung là xác suất tiên định cho từng tỉ lệ. Biểu đồ giả định rằng tỉ lệ trung bình là 27%, rất ít quần thể có tỉ lệ dưới 20% hay trên 35%.

Dữ liệu thực tế

Số liệu thực tế là con số 25% tỉ lệ loãng xương. Đây là một biến nhị phân, nên chúng ta có thể giả định rằng biến này tuân theo luật phân phối nhị phân (binomial distribution).

Gọi n là số người được hỏi, k là số người trả lời loãng xương (yes), luật phân bố nhị phân phát biểu rằng xác suất có k người trả lời yes với tỉ lệ trả lời yes (kí hiệu θ) là:

$$P(k; n, \theta) = \binom{n}{k} \theta^k (1 - \theta)^{n-k}$$

Nói theo ngôn ngữ xác suất, k phân bố theo luật phân bố nhị phân:

$$k \sim \text{Bin}(\theta, n)$$

Thuật ngữ Bayes đề cập đến phân bố trên là “likelihood” - khả dĩ. Chúng ta biết rằng có 1500 người được hỏi (tức $n = 1500$), và với tỉ lệ 25%, chúng ta biết rằng có 375 người loãng xương.

Thông tin hậu định (posterior information)

Theo Định lí Bayes, thông tin hậu định là tích số của thông tin tiền định và likelihood. Nói cách khác:

$$\text{Posterior} = \text{Prior} \times \text{Likelihood}$$

Chúng ta có:

$$\text{Prior} \propto \theta^{a-1} (1 - \theta)^{b-1}, \text{ trong đó } a = 1.86, b = 5.024.$$

$$\text{Likelihood} \propto \theta^k (1 - \theta)^{n-k}; \text{ trong đó, } k = 375 \text{ và } n = 1500.$$

Do đó, posterior $\propto \theta^{a-1} (1 - \theta)^{b-1} \theta^k (1 - \theta)^{n-k}$. Vài thao tác đại số, chúng ta có:


$$\text{Posterior} \propto \theta^{a+k-1} (1 - \theta)^{b+n-k-1}$$

Tức là, thông số θ (hậu định) tuân theo luật phân phối beta! Khi luật phân bố tiền định và hậu định có cùng luật phân bố, thuật ngữ Bayes gọi là *conjugated*. Chúng ta có thể sử dụng R để thể hiện thông tin hậu định như sau:

```
a=1.86; b=5.024; n=1500; k=0.25*1500
```

```
curve(dbeta(x, a+k-1, b+n-k-1), from=0.2, to=0.30,
```

```
xlab="Ti le loang xuong", ylab="Xac suat", lty=1, lwd=4)
```



Biểu đồ 2. Phân bố thông tin hậu định

Biểu đồ trên cho thấy tỉ lệ loãng xương (sau khi đã điều chỉnh cho thông tin tiền định) là ~25%. Dĩ nhiên, xác suất hậu định chịu ảnh hưởng xác suất tiền định, và điều này cho thấy cần phải cẩn thận trong việc chọn luật phân bố cho xác suất tiền định trong phân tích Bayes.

18.3 Ứng dụng phương pháp Bayes II: So sánh hai tỉ lệ

Bảng số liệu dưới đây thể hiện số bệnh nhân bị tai biến trong một nghiên cứu gồm 2 nhóm (tạm gọi là nhóm A và nhóm B). Nhóm 1 có tỉ lệ tai biến là 55% (11/20), và nhóm 2 là 25% (5/20).

NHÓM	SỐ BỊ TAI BIẾN	SỐ KHÔNG BỊ TAI BIẾN
A	11	9
B	5	15

Câu hỏi nghiên cứu là hai nhóm có cùng nguy cơ bị tai biến? Gọi $X \sim \text{Binomial}(n_1, p_1)$ và $p_1 = X / n_1$, và $Y \sim \text{Binomial}(n_2, p_2)$ và $p_2 = Y / n_2$. Chúng ta muốn biết phân bố của $p_1 - p_2$ ra sao.

Thông tin tiền định cho μ_1 và μ_2 : $\text{Beta}(a_1, b_1)$ và $\text{Beta}(a_2, b_2)$. Thông tin hậu định:

$$\pi(p_1, p_2) \propto p_1^{x+a_1-1} (1-p_1)^{n_1+b_1-1} p_2^{y+a_2-1} (1-p_2)^{n_2+b_2-1}$$


Chúng ta có thể triển khai bằng R như sau:

```
#nhập dữ liệu
x = 11; n1 = 20; alpha1 = 1; beta1 = 1
y = 5; n2 = 20; alpha2 = 1; beta2 = 1

# mô phỏng 10000 giá trị của phân bố beta cho p1 và p2
p1 = rbeta(10000, x + alpha1, n1 - x + beta1)
p2 = rbeta(10000, y + alpha2, n2 - y + beta2)

# tính hiệu số p2-p1 và vẽ biểu đồ
rd = p2 - p1
plot(density(rd))

quantile(rd, c(.025, 0.5, 0.975))
```



```
> quantile(rd, c(.025, 0.5, 0.975))
      2.5%      50%      97.5%
-0.538766742 -0.273079884  0.009308546
```

Kết quả trên cho thấy nhóm 2 có tỉ lệ tai biến thấp hơn nhóm 1 khoảng 27%, nhưng khoảng tin cậy 95% dao động trong khoảng 0% đến 54%. Chúng ta cũng có thể tính xác suất nhóm 2 thấp hơn nhóm 1 bằng hàm `table(p2 < p1)`, và kết quả là 97.3%. Tương tự, xác suất mà nhóm 2 thấp hơn nhóm 1 ít nhất là 5% là 94.3% (`table((p2 + 0.05) < p1)`)

18.4 Ứng dụng phương pháp Bayes III: Một số trung bình

Chúng ta thử xem qua một trường hợp lâm sàng sau đây: Nam bệnh nhân, 60 tuổi, sức khỏe bình thường, BMI 23 kg/m², không có tiền căn gia đình với bệnh tiểu đường. Tuy nhiên kết quả xét nghiệm glucose trong máu là 127 mg/dL. Theo tiêu chuẩn, ông được chẩn đoán là tiểu đường, nhưng ông nghi ngờ. Ông muốn biết nguy cơ thật mình mắc bệnh tiểu đường. Phân tích Bayes có thể giúp gì bác sĩ để nói chuyện với bệnh nhân?

Trường hợp trên rất tiêu biểu trong lâm sàng. Trước một xét nghiệm sinh hóa với kết quả “dương tính”, và biết rằng phương pháp xét nghiệm có những hạn chế về độ chính xác, người bác sĩ cũng như bệnh nhân muốn biết khả năng mình mắc bệnh là cao hay thấp. Vấn đề càng khó hơn khi kết quả xét nghiệm gần ngưỡng chẩn đoán bệnh (như glucose trên đây), người thầy thuốc phân vân không biết nên ra chẩn đoán mắc bệnh hay không mắc bệnh, bởi vì ai cũng biết rằng bất cứ xét nghiệm nào cũng không hoàn hảo. May mắn thay, phân tích Bayes có thể trả lời câu hỏi khả năng bệnh nhân mắc bệnh tiểu đường là bao nhiêu.

Có 3 yếu tố trong suy luận Bayes: đó là *posterior probability*, *prior probability*, và *likelihood* mà tôi đã đề cập trong phần trên. Chúng ta thử xét qua 3 thông tin trong công thức trên một cách chi tiết hơn như sau:

Thông tin tiền định là sự phân bố về nồng độ glucose trong cộng đồng. Hai thông số để phản ánh một phân bố là số trung bình và độ lệch chuẩn (hay phương sai). Nghiên cứu của chúng tôi [chưa công bố] trong cộng đồng người Việt cho thấy ở nam 60 tuổi, nồng độ glucose trung bình là 105 mg/dL và độ lệch chuẩn là 29.32 mg/dL. Gọi hai thông số này là:

$$m_0 = 105 \text{ và } s_0 = 29.32$$

Đo lường nồng độ glucose trong máu không phải hoàn toàn chính xác. Chúng ta biết rằng nồng độ glucose trong máu dao động trong mỗi cá nhân ngay trong điều kiện bình thường. Chẳng hạn như trường hợp dưới đây, khi bệnh nhân được đo glucose 5 lần liên tục trong 5 ngày, và kết quả như sau (mg/dL):

127, 124, 125, 120, 126

Nếu chỉ dựa vào kết quả ngày thứ nhất và ngày thứ năm, cá nhân này được phân vào nhóm tiểu đường (vì nồng độ glucose cao hơn hay bằng 126 mg/dL). Nhưng nếu dựa vào kết quả ngày thứ hai, thứ ba và thứ tư thì cá nhân không được

chẩn đoán tiểu đường. Đây là một tình trạng bất định rất phổ biến trong lâm sàng và chẩn đoán. Khác với sự bất định trong chẩn đoán ung thư vú (khi độ chính xác được định lượng bằng độ nhạy, độ đặc hiệu hay tỉ lệ dương tính giả), sự bất định trong các đo lường mang tính liên tục (continuous variable) như nồng độ glucose được định lượng bằng hệ số tin cậy mà thuật ngữ tiếng Anh là *coefficient of reliability*.

Để ước tính hệ số tin cậy, người ta thường làm những nghiên cứu ngắn hạn. Trong đó, một nhóm cá nhân được lấy máu và đo trên 2 lần (thường là 3 lần). Từ dữ liệu đó, có thể ước tính phương sai nồng độ glucose. Phương sai này thực chất gồm có 2 thành phần: phương sai do dao động trung bình *trong mỗi cá nhân* (viết tắt là W) và phương sai do dao động *giữa các cá nhân* (B). Hệ số tin cậy (viết tắt là R) được tính bằng cách lấy B chia cho tổng phương sai:

$$R = B / (B + W)$$

Hệ số tin cậy và đặc biệt là phương sai W là những thông tin tiền định rất quan trọng trong việc đi đến một chẩn đoán chính xác về lâu về dài. Nghiên cứu trước đây của chúng tôi cho thấy phương sai W là 815 mg/dL^2 (hay độ lệch chuẩn là 28.55 mg/dL) và hệ số tin cậy $R = 0.86$.

Dữ liệu thực tế chính là nồng độ glucose của cá nhân này được đo lường nhiều lần thì chắc chắn nồng độ không phải là 127 nhưng có thể dao động theo luật phân phối chuẩn. Do đó, chúng ta có thể phát biểu rằng đối với bệnh nhân, nồng độ glucose tuân theo luật phân phối chuẩn với trung bình 127 mg/dL và độ lệch chuẩn 28.55 mg/dL . Có thể thể hiện dữ liệu này như sau:

$$m_1 = 127 \text{ và } s_1 = 28.55$$

Thông tin hậu định được ước tính từ thông tin tiền định và dữ liệu thực tế. Phương pháp ước tính dựa vào định lý Bayes như trình bày trong [1]. Nhắc lại rằng thông tin tiền định tuân theo luật phân phối chuẩn $N(105, 29.32)$, và dữ liệu thực tế cũng tuân theo luật phân phối chuẩn $N(127, 28.55)$. Theo định lý Bayes:

$$\text{Xác suất hậu định} = N(105, 29.32) \times N(127, 28.55)$$

Vài thao tác đại số có thể chứng minh rằng xác suất hậu định cũng tuân theo luật phân phối chuẩn. Trong trường hợp luật phân phối hậu định có cùng hàm số với thông tin tiền định, thuật ngữ Bayes gọi là *conjugate*. Nói cách khác:

$$N(m, s) = N(105, 29.32) \times N(127, 28.55)$$

Hay nói chung:

$$N(m, s) = N(m_0, s_0) \times N(m_1, s_1)$$

Trong đó, $N(m, s)$ là phân phối hậu định với thông số trung bình m và độ lệch chuẩn s . Có thể chứng minh dễ dàng rằng:

$$m = \frac{\frac{m_0}{s_0^2} + \frac{m_1}{s_1^2}}{\frac{1}{s_0^2} + \frac{1}{s_1^2}} \quad \text{và} \quad s = \frac{1}{\sqrt{\left(\frac{1}{s_0^2} + \frac{1}{s_1^2}\right)}}$$

Thay thế $m_0 = 105$, $s_0 = 29.32$, $m_1 = 127$ và $s_1 = 28.55$, chúng ta có:

$$m_{\text{posterior}} = \frac{\frac{105}{29.32^2} + \frac{127}{28.55^2}}{\frac{1}{29.32^2} + \frac{1}{28.55^2}} = 116$$

$$s_{\text{posterior}} = \frac{1}{\sqrt{\left(\frac{1}{29.32^2} + \frac{1}{28.55^2}\right)}} = 20.5$$

Nói cách khác, nồng độ glucose trung bình về lâu về dài (hay nồng độ thật) của cá nhân là 116 mg/dL, nhưng có thể dao động trong khoảng 75.8 đến 156.2 mg/dL với xác suất 95% (tức $116 - 1.96 \times 20.5$ đến $116 + 1.96 \times 20.5$). Có thể hình dung phân bố glucose của bệnh nhân này như sau (bằng R):

```
mean=116; sd=20.5; lb=mean-1.96*sd; ub=mean+1.96*sd
crit=126
x = seq(-4, 4, length=10000)*sd + mean
hx = dnorm(x, mean, sd)
plot(x, hx, type="n", xlab="Glucose (mg/dL", ylab="Density")
i = x > crit
lines(x, hx)
polygon(c(crit, x[i], ub), c(0, hx[i], 0), col="red")
```

Nhưng chúng ta muốn biết $P(\text{glucose} > 126)$. Bởi vì nồng độ glucose tuân theo luật phân phối chuẩn với trung bình 116 mg/dL và độ lệch chuẩn 20.5 mg/dL, nên có thể mô tả bằng công thức sau đây:

$$f(\text{glucose}) = \frac{1}{20.5\sqrt{2\pi}} e^{-\frac{(\text{glucose}-116)^2}{2 \times (20.5)^2}}$$

Xác suất trên chính là diện tích dưới đường biểu diễn của hàm số glucose cho bệnh nhân đó. Theo đó:

$$P(\text{glucose} > 126) = \int_{126}^{\infty} f(\text{glucose}) = 0.312$$

Nếu dùng R:

```
1-pnorm(q=126, mean=116, sd=20.5)
```

Nói cách khác, mặc dù nồng độ glucose của cá nhân này nằm trong ngưỡng chẩn đoán tiểu đường (127 mg/dL), nhưng vì biết được độ tin cậy của phương pháp xét nghiệm và thông tin tiền định trong cộng đồng, xác suất mà bệnh nhân có nồng độ glucose trên 126 mg/dL thật ra chỉ 31.2%, chưa đủ thuyết phục để chẩn đoán cá nhân này mắc bệnh tiểu đường, nếu chưa có thêm thông tin khác về bệnh nhân.

Ví dụ trên đây cho thấy phân tích Bayes có ý nghĩa rất thiết thực. Thiết thực là vì kết quả phân tích có thể ứng dụng cho một cá nhân, chứ không hẳn một quần thể theo trường phái phân tích cổ điển frequentist. Khác với phương pháp cổ điển dựa vào giả định thông số (như trung bình và độ lệch chuẩn) là bất biến (fixed) và áp dụng cho một quần thể, nhưng phương pháp Bayes không chấp nhận giả định đó vì mỗi cá nhân (mỗi bệnh nhân) có một *profile* riêng, một phân bố riêng cho cá nhân đó. Tuy nhiên, khó khăn trong phân tích Bayes là chúng ta phải chọn thông tin tiền định hợp lý, vì có khi thông tin tiền định ảnh hưởng đến kết quả của phân tích hậu định và dẫn đến kết luận thiếu độ tin cậy cao. Đây cũng là một yếu tố làm cho nhiều người ngần ngại khi tiếp cận với phương pháp Bayes vì họ không có thông tin tiền định. Tuy nhiên, trong thực tế thì chúng ta có thể sử dụng thông tin tiền định qua các luật phân bố xác suất rất hữu hiệu.

18.5 Ứng dụng phương pháp Bayes IV: Diễn giải kết quả nghiên cứu

Trường hợp 1: Bổ sung vitamin D + calcium (CaD) và nhồi máu cơ tim. Một phân tích dữ liệu của công trình nghiên cứu WHI mới công bố trên tập san BMJ (2) cho thấy phụ nữ dùng bổ sung calcium và vitamin D có nguy cơ nhồi máu cơ tim tăng (**Bảng 1**). Tỷ số nguy cơ là 1.22 và khoảng tin cậy 95% dao động từ 1.0 đến 1.5. Bệnh nhân đang dùng bổ sung calcium và vitamin D rất quan tâm khi nghe tin này và muốn được bác sĩ tư vấn. Bác sĩ phải nói gì với bệnh nhân?

Bảng 1. Kết quả nghiên cứu WHI: tần số nhồi máu cơ tim (MI) trong nhóm dùng calcium và vitamin D (CaD) và nhóm giả dược (placebo)

NHÓM CÁN THIỆP	MI	KHÔNG MI	TỔNG SỐ
CaD	209 (2.48%)	8220	8429
Placebo	168 (2.03%)	8121	8289

Trường hợp 2: Strontium ranelate và gãy xương đốt sống. Một công trình nghiên cứu lâm sàng đối chứng ngẫu nhiên (randomized controlled trial) về hiệu quả của một loại thuốc điều trị loãng xương (strontium ranelate - SR) (3), trong đó 1442 bệnh nhân loãng xương được chia thành 2 nhóm: nhóm 1 gồm 719 người được điều trị với SR, và nhóm placebo gồm 723 người. Sau 3 năm điều trị và theo dõi, kết quả cho thấy số ca gãy xương đốt sống trong nhóm điều trị là 46 (6.4%) và trong nhóm giả dược là 88 (12.2%). Kết quả này có ý nghĩa lâm sàng hay không?

Bảng 2. Kết quả nghiên cứu hiệu quả của strontium ranelate trong điều trị loãng xương ở phụ nữ sau mãn kinh

NHÓM CÁN THIỆP	SỐ BỆNH NHÂN GỠ XƯƠNG ĐỐT SỐNG	SỐ BỆNH NHÂN KHÔNG GỠ XƯƠNG	TỔNG SỐ
Strontium ranelate	46 (6.4%)	673	719
Placebo	88 (12.2%)	635	723

Chúng ta thử tiếp cận hai câu hỏi trên qua suy luận Bayes. Xin nhắc lại Định lí Bayes trong bối cảnh hiện tại: gọi H_A là giả thuyết thuốc có hiệu quả, D là dữ liệu quan sát được, xác suất H_A đúng với dữ liệu D là:

$$P(H_A | D) = \frac{P(H_A) \times P(D | H_A)}{P(D)}$$

Trong đó, $P(H_A)$ là xác suất H_A đúng (còn gọi là xác suất tiên định – prior probability); $P(D | H_A)$ là xác suất dữ liệu quan sát được nếu H_A đúng; và $P(D)$ là xác suất dữ liệu xảy ra.

Xác suất tiên định

Trước khi thực hiện một công trình nghiên cứu, chúng ta thường đã có vài ý kiến về khả năng của một giả thuyết. “Khả năng” có thể mô tả bằng xác suất. Chẳng hạn như đối với mối liên hệ giữa CaD và nhồi máu cơ tim (nghiên cứu 1), thiếu những lí do sinh học nào để tin rằng có một mối liên hệ như thế; cho nên chúng ta có thể phát biểu sơ khởi rằng xác suất có mối liên hệ là rất thấp, như $\pi = 0.05$ (5%). Trong nghiên cứu 2 (strontium ranelate) và gãy

xương đốt sống, chúng ta có nhiều nghiên cứu cơ bản cho thấy SR có thể tăng mật độ xương và do đó có thể giảm nguy cơ gãy xương. Nhưng để có lí do thực hiện một nghiên cứu lâm sàng chúng ta phải chấp nhận khả năng 50/50 (equipoise), tức xác suất có hiệu quả là $\pi = 0.5$.

Trong thực tế, xác suất tiền định có thể “phát biểu” bằng các luật phân bố xác suất. Bởi vì dữ liệu của cả hai nghiên cứu có thể mô tả bằng tỉ số nguy cơ (relative risk – RR). Tỉ số nguy cơ có thể dao động, chẳng hạn như từ 0.2 (thuốc giảm nguy cơ 80%) đến 10 (thuốc tăng nguy cơ 5 lần). Nhưng chúng ta biết rằng khả năng thuốc giảm nguy cơ 90% hay tăng nguy cơ gấp 5 lần là rất thấp, nếu không muốn nói là không khả dĩ. Vì thế có thể thể hiện xác suất tiền định bằng luật phân phối chuẩn.

Trong phân phối chuẩn, thay vì thể hiện bằng RR, chúng ta thể hiện bằng logarit RR (kí hiệu logRR) tiện hơn. Do đó, thay vì phát biểu $RR = 1$, chúng ta phát biểu $\log RR = 0$ (vì log của 1 là 0); thay vì $RR = 0.2$, chúng ta viết $\log RR = -1.61$; và thay vì $RR = 5$, chúng ta viết $\log RR = 1.61$. Phân phối chuẩn của logRR được xác định bởi 2 thông số: trung bình và phương sai. Gọi số trung bình của logRR là m_0 và phương sai của logRR là v_0 . Với giả thuyết vô hiệu, chúng ta giả định rằng không có sự khác biệt giữa hai nhóm (như CaD và giả dược, hay giữa SR và giả dược), do đó:

$$m_0 = 0$$

Nhưng chúng ta nghĩ rằng logRR có thể dao động từ -2.3 đến 1.61, với khả năng $\log RR < -2.3$ là 2.5%, và khả năng $\log RR > 1.61$ là 2.5%. Do đó, độ lệch chuẩn tiền định (standard deviation, kí hiệu s_0) có thể ước tính bằng:


$$s_0 = [1.61 - (-1.61)] / 3.92 = 0.821$$

Vì thế, phương sai (độ lệch chuẩn bình phương) bằng:

$$v_0 = (0.997)^2 = 0.675$$

Có thể thể hiện phân bố này bằng **Biểu đồ 3** sau đây:

```
mean=0; sd=0.821; lb=mean-1.96*sd; ub=mean+1.96*sd
x = seq(-4, 4, length=10000)*sd + mean
hx = dnorm(x, mean, sd)
plot(x, hx, type="n", xlab="LogRR", ylab="Density")
i <- x >= lb & x <= ub
lines(x, hx)
polygon(c(lb,x[i],ub), c(0,hx[i],0), col="red")
```



Biểu đồ 3. Phân bố xác suất tiên định thể hiện “niềm tin”, với giả thuyết khởi đầu là trung bình $RR = 1$ (tức $\text{LogRR} = 0$) và độ lệch chuẩn 0.821. Diện tích tô màu đỏ là khoảng tin cậy 95%, thể hiện xác suất $RR < 0.2$ là 2.5% và xác suất $RR > 5$ cũng 2.5%.

Dữ liệu thực tế

Dữ liệu thực tế được trình bày trong Bảng 1 và 2. Tuy nhiên, vì chúng ta làm việc với tỉ số nguy cơ qua đơn vị logarit, nên dữ liệu phải được trình bày lại dưới hình thức logRR và khoảng tin cậy 95%. Để tiện theo dõi, tôi trình bày lại dữ liệu trong bảng số liệu dưới đây:

NHÓM CAN THIỆP	BỆNH	KHÔNG BỆNH	TỔNG SỐ
Bối cảnh chung			
Nhóm can thiệp	<i>a</i>	<i>b</i>	<i>a+b</i>
Nhóm không can thiệp	<i>c</i>	<i>d</i>	<i>c+d</i>
Nghiên cứu 1			
CaD	209 (2.48%)	8220	8429
Placebo	168 (2.03%)	8121	8289
Nghiên cứu 2			
Strontium ranelate	46 (6.4%)	673	719
Placebo	88 (12.2%)	635	723

Trước hết chúng ta cần phải ước tính RR, và sau đó là logRR. Gọi tỉ lệ mắc bệnh trong nhóm điều trị là p_1 và nhóm giả dược là p_0 , chúng ta có thể ước tính tỉ số nguy cơ RR như sau:

$$RR = \frac{p_1}{p_0}$$

Do đó, logRR (sẽ kí hiệu là m_1) có thể ước tính đơn giản là:

$$m_1 = \log(RR)$$

Theo lí thuyết thống kê, phương sai của logRR (kí hiệu v_1) là:

$$v_1 = \frac{1/a}{1/(a+b)} + \frac{1/c}{1/(c+d)}$$

Cố nhiên, độ lệch chuẩn cũng có thể tính từ v_1 như sau: $s_1 = \sqrt{v_1}$.


Dựa vào những công thức trên, chúng ta có thể ước tính m_1 và v_1 cho hai nghiên cứu trên như sau:

NGHIÊN CỨU	CHỈ TIÊU LÂM SÀNG	M_1	V_1	S_1	KTC95%
1. CaD và placebo	Nhồi máu cơ tim	0.2016	0.0104	0.102	0.0008, 0.402
2. SR và placebo	Gãy xương đốt sống	-0.6431	0.0303	0.174	-0.984, -0.302

Có thể thể hiện phân bố của dữ liệu thực tế của hai nghiên cứu trên qua hai **Biểu đồ 4** dưới đây:

```
par(mfrow=c(1,2))
mean=0.2016; sd=0.102; lb=mean-1.96*sd; ub=mean+1.96*sd
x = seq(-4,4,length=1000)*sd + mean
hx = dnorm(x,mean,sd)
plot(x, hx, type="n", xlab="LogRR (CaD)", ylab="Density", main=" ")
lines(x, hx)

mean=-0.6431; sd=0.174; lb=mean-1.96*sd; ub=mean+1.96*sd
x = seq(-4,4,length=1000)*sd + mean
hx = dnorm(x,mean,sd)
plot(x, hx, type="n", xlab="LogRR (Strontium ranelate)",
ylab="Density", main=" ")
lines(x, hx)
```



Biểu đồ 4.

Phân bố logRR cho nghiên cứu 1 (trái, CaD và nhồi máu cơ tim) và nghiên cứu 2 (bên phải, strontium ranelate và gãy xương đốt sống).

Từ kết quả trên, có thể hoán chuyển ngược lại đơn vị RR và khoảng tin cậy 95%. Khoảng tin cậy 95% của m_1 có thể ước tính đơn giản bằng lý thuyết phân phối chuẩn: tức là lấy trung bình cộng hoặc trừ cho 1.96 lần độ lệch chuẩn:

$$\text{KTC95\%} = m_1 \pm 1.96s_1$$

Kết quả trình bày trong cột sau cùng của bảng số liệu trên. Cố nhiên, bởi vì đơn vị logarit chỉ dùng cho tính toán, và trong thực tế chúng ta cần hoán chuyển sang đơn vị thường (tức RR) để có thể hiểu được. Do đó, có thể lấy hàm số mũ của các kết quả trên như sau (ví dụ cho nghiên cứu 1):

- RR (nhồi máu cơ tim) = $e^{0.2016} = 1.22$
- và khoảng tin cậy 95%: $e^{0.008}$ đến $e^{0.401} = 1.00$ đến 1.50

Kết quả hoán chuyển có thể xem bảng dưới đây.

NGHIÊN CỨU	OUTCOME	RR	KTC95%
1. CaD và placebo	Nhồi máu cơ tim	1.22	1.00, 1.50
2. SR và placebo	Gãy xương đốt sống	0.52	0.37, 0.74

Cần nói thêm rằng, đối với phân tích cổ điển, qui trình phân tích ngừng ở đây. Có lẽ nhà nghiên cứu kết luận rằng CaD tăng nguy cơ nhồi máu cơ tim 22% và ảnh hưởng này dao động trong khoảng 0% đến 50% ($P = 0.05$). Tương

tự, trong nghiên cứu 2, strontium ranelate giảm nguy cơ gãy xương đốt sống 48%, nhưng mức độ ảnh hưởng có thể giảm từ 28% đến 63% ($P < 0.001$). Cả hai kết quả đều có ý nghĩa thống kê.

Xác suất hậu định

Nhưng nếu chịu khó suy nghĩ, chúng ta sẽ không hài lòng với kết luận đó. Trong trường hợp CaD và nhồi máu cơ tim, một tỉ số nguy cơ 1.22 có thể nói là một sự ảnh hưởng rất thấp, nhất là trong điều kiện khoảng tin cậy 95% có thể là không có ảnh hưởng (phần hạ của khoảng tin cậy 95% bằng 1). Nói cách khác, kết quả này quá “mong manh”. Chỉ cần thay 2 ca nhồi máu cơ tim trong nhóm chứng là kết quả sẽ không có ý nghĩa thống kê. Chúng ta hỏi: có phải kết quả trên do ngẫu nhiên, hay là một kết quả *dương tính giả*.

Vấn đề thứ hai là kết quả trên có ý nghĩa lâm sàng hay không? Nên nhớ rằng kết quả trên dựa vào giả thuyết vô hiệu là nguy cơ mắc bệnh của hai nhóm bằng nhau. Tức là dù có khác biệt 0.1% vẫn được xem là có khác biệt. Nhưng trong thực tế 0.1% khác biệt chẳng có ý nghĩa lâm sàng nào cả. Do vậy, để trả lời câu hỏi này, chúng ta cần phải xác định ngưỡng tỉ số nguy cơ để có thể cho là có ý nghĩa lâm sàng. Theo y văn trong lĩnh vực tim mạch, phần lớn những nghiên cứu lâm sàng được thiết kế để chứng minh can thiệp giảm nguy cơ từ 15% trở lên. Một ngưỡng tương tự cũng thường hay thấy trong các nghiên cứu loãng xương. Do đó, chúng ta sẽ đề ra ngưỡng 15% để đánh giá tầm quan trọng lâm sàng. Nói cách khác, chúng ta có một tiêu chí mới:

- Nếu CaD (hay bất cứ can thiệp nào) tăng nguy cơ nhồi máu cơ tim cao hơn 15% (tức tỉ số nguy cơ cao hơn 1.15 hay $\log RR > 0.14$) sẽ được xem là có hại;
- Tương tự, nếu can thiệp nào giảm nguy cơ gãy xương đốt sống trên 15% (tức tỉ số nguy cơ thấp hơn 0.85, hay $\log RR < -0.16$) thì sẽ được xem là thật sự có ý nghĩa lâm sàng.

Phân tích Bayes nhằm trả lời những câu hỏi trên. Để trả lời câu hỏi trên, chúng ta cần phải ước tính xác suất hậu định (posterior probability) của một giả thuyết. Thông số mà chúng ta quan tâm là tỉ số nguy cơ RR. Nhưng như đề cập trên, để cho tiện lợi trong tính toán, chúng ta sẽ dựa vào đơn vị $\log RR$. Gọi số trung bình của $\log RR$ (hậu định) là m và phương sai của $\log RR$ là v . Định lí Bayes phát biểu rằng:

$$N(m, v) = N(m_0, v_0) \times N(m_1, v_1)$$

Trong đó N là viết tắt của phân bố chuẩn (Normal distribution), và những thông số trong ngoặc là số trung bình và phương sai. Công thức trên hàm ý nói rằng phân bố logRR hậu định bằng phân bố logRR tiền định nhân cho phân bố logRR của dữ liệu thực tế. Sau vài thao tác toán, có thể chứng minh rằng:

$$m = \frac{\frac{m_0}{v_0} + \frac{m_1}{v_1}}{\frac{1}{v_0} + \frac{1}{v_1}} \quad \text{và} \quad v = \frac{1}{\frac{1}{v_0} + \frac{1}{v_1}}$$

Công thức trên cho thấy m chính là một trọng số trung bình (weighted average) của logRR tiền định và logRR thực tế. Trọng số ở đây là số đảo phương sai ($1/v_0$ và $1/v_1$). Phương sai nhỏ có trọng số lớn, và ngược lại, phương sai lớn (tức dữ liệu có dao động lớn) có trọng số nhỏ. Vì xác suất hậu định tuân theo luật phân phối chuẩn, cho nên 2 thông số trên có nghĩa là hàm phân phối chuẩn của xác suất hậu định là:

$$f(x) = \frac{1}{\sqrt{2\pi v}} \exp\left[-\frac{(x-m)^2}{2v}\right]$$

Trong đó, x là số logRR khả dĩ. Hàm $f(x)$ cung cấp một số ước tính rất có ích. Chẳng hạn như chúng ta có thể đặt câu hỏi: xác suất mà CaD tăng nguy cơ nhồi máu cơ tim trên 15% là bao nhiêu? Như nói trên, tăng nguy cơ trên 15% có nghĩa là $P(\logRR > 0.14)$. Do đó, đáp số cho câu trả lời là:

$$\Pr(\logRR > 0.14) = \int_{0.14}^{\infty} f(x)$$

Tuy công thức có vẻ phức tạp, nhưng thật ra, tất cả những tính toán có thể thực hiện bằng phần mềm Excel hay R một cách rất dễ dàng.

Quay lại với hai nghiên cứu trên, chúng ta có thể ước tính hai thông số hậu định m và v cho nghiên cứu 1 như sau:

$$m = \frac{\frac{0}{0.675} + \frac{0.2016}{0.0104}}{\frac{1}{0.675} + \frac{1}{0.0104}} = 0.197 \quad \text{và} \quad v = \frac{1}{\frac{1}{0.675} + \frac{1}{0.0104}} = 0.010$$

Một tính toán tương tự cho nghiên cứu 2 sẽ cho ra kết quả $m = -0.624$ và $v = 0.029$. Chúng ta có thể tóm lược 3 thông tin vừa phân tích trong bảng dưới đây:

NGHIÊN CỨU	TIỀN ĐỊNH		DỮ LIỆU		HẬU ĐỊNH	
	M_0	V_0	M_1	V_1	M	V
Đơn vị logarit						
1. CaD và placebo	0	0.675	0.2016	0.0104	0.197	0.010
2. SR và placebo	0	0.675	-0.6431	0.0303	-0.615	0.029

Kết quả trên cho thấy, logRR hậu định không thay đổi nhiều so với logRR thực tế. Lí do là vì chúng ta bắt đầu bằng thông tin tiền định với logRR = 0. Ngoài ra, vì phương sai của thông tin tiền định cao (phản ánh sự bất định về kiến thức của chúng ta), nên trọng số của thông tin tiền định không cao.

Dựa vào kết quả trên, chúng ta có thể ước tính xác suất ($\logRR > 0.14$) cho nghiên cứu 1 và ($\logRR < -0.16$) cho nghiên cứu 2. Kết quả là:

- Nghiên cứu 1: $P(\logRR > 0.14) = 0.725$
- Nghiên cứu 2: $P(\logRR < -0.16) = 0.996$

Nói cách khác, xác suất CaD tăng nguy cơ nhồi máu cơ tim trên 15% là 72.5%, và xác suất SR giảm nguy cơ gãy xương đốt sống trên 15% là 99.6%. Cần nói thêm rằng, chỉ khi nào xác suất có hiệu quả lâm sàng trên 90% hoặc trên 95% mới có thể xem là đáng chú ý. Do đó, trong hai trường hợp trên, ảnh hưởng của CaD đến nguy cơ nhồi máu cơ tim không đáng chú ý, nhưng ảnh hưởng của SR đến nguy cơ gãy xương đốt sống là đáng chú ý. Có thể thể hiện hai xác suất trên đây qua **Biểu đồ 5** dưới đây:

```
par(mfrow=c(1,2))
# plot for CaD and MI
mean=0.197; sd=sqrt(0.01); lb=mean-1.96*sd; ub=mean+1.96*sd
crit=log(1.15)
x = seq(-4, 4, length=10000)*sd + mean
hx = dnorm(x, mean, sd)
plot(x, hx, type="n", xlab="LogRR", ylab="Density")
i = x > crit
lines(x, hx)
polygon(c(crit, x[i], ub), c(0,hx[i],0), col="red")


# plot for SR and vert fx
mean=-0.615; sd=sqrt(0.029); lb=mean-1.96*sd; ub=mean+1.96*sd
crit=log(0.85)
```



```

x = seq(-4, 4, length=10000)*sd + mean
hx = dnorm(x, mean, sd)
plot(x, hx, type="n", xlab="LogRR", ylab="Density")
i = x < crit
lines(x, hx)
polygon(c(crit, x[i], crit), c(0, hx[i], 0), col="red")

```



Biểu đồ 5. Phân bố logRR cho nghiên cứu 1 (trái, CaD và nhồi máu cơ tim) và nghiên cứu 2 (bên phải, strontium ranelate và gãy xương đốt sống). Diện tích tô đậm là xác suất có ý nghĩa lâm sàng (tức xác suất $RR > 1.15$ hay $\log RR > 0.14$ cho nghiên cứu 1, và $RR < 0.85$ hay $\log RR < -0.16$ cho nghiên cứu 2).

Xin nhắc lại, những kết quả trên là tính trên đơn vị logarit. Để dễ hiểu hơn, chúng ta cần phải hoán chuyển sang đơn vị RR bằng cách lấy hàm số mũ của LogRR và khoảng tin cậy 95%.

Với nghiên cứu 1, $\log RR = 0.197$, phương sai $v = 0.01$, nên độ lệch chuẩn là $s = \sqrt{0.01} = 0.1$. Từ đó, khoảng tin cậy 95% của LogRR là $0.197 \pm 1.96 \times 0.10 = 0.001$ đến 0.393 . Nói cách khác, $RR = e^{0.197} = 1.22$, và khoảng tin cậy 95% là $e^{0.001} = 1.0$ đến $e^{0.393} = 1.48$. Kết quả hoán chuyển được trình bày trong bảng số liệu sau đây:

NGHIÊN CỨU	<i>m</i>	<i>s</i>	RR	KHOẢNG TIN CẬY 95%
1. CaD và placebo	0.197	0.10	1.22	1.00 đến 1.48
2. SR và placebo	-0.615	0.17	0.54	0.39 đến 0.75

Những kết quả trên là bằng chứng để chúng ta có thể phát biểu rằng tỉ số nguy cơ nhồi máu cơ tim liên quan đến CaD là 1.22, và xác suất 95% của tỉ số nguy cơ là từ 1.0 đến 1.48. Tương tự, chúng ta cũng có thể kết luận rằng tỉ số nguy cơ gãy xương đốt sống liên quan đến strontium ranelate là 0.54 và xác suất 95% là tỉ số này sẽ dao động trong khoảng 0.39 đến 0.75. Tuy nhiên, chỉ có ảnh hưởng của strontium ranelate đến nguy cơ gãy xương đốt sống là có ý nghĩa lâm sàng, còn ảnh hưởng của CaD đến nguy cơ nhồi máu cơ tim thì vẫn còn bất định, chưa thể kết luận một cách khẳng định như nhóm tác giả viết.

Xem xét kĩ kết quả phân tích trên, chúng ta có thể thấy rằng thông tin tiền định đóng vai trò quan trọng. Đó cũng là một khía cạnh của phương pháp Bayes bị phê bình khá nhiều. Những phê phán có thể tóm lược trong hai điểm chính: thông tin tiền định đến từ đâu, và thông tin tiền định có thể không khách quan. Cả hai phê phán đều hợp lí, nhưng cũng... không hợp lí. Hợp lí là vì việc xác định thông tin tiền định rất khó. Khó hơn là làm sao để định lượng khả năng của một giả thuyết. Tuy nhiên không hợp lí là vì trong thực tế, chúng ta có thể có khá nhiều thông tin trước khi thực hiện một nghiên cứu lâm sàng, và do đó, không thể nói rằng không có thông tin. Và lại, nếu không có thông tin về khả năng của một giả thuyết, chúng ta có thể khởi đầu bằng xác suất 50/50, tức hoàn toàn khách quan. Thực ra, nếu một nghiên cứu lâm sàng (như đánh giá hiệu quả thuốc) mà khả năng thuốc có hiệu quả hơn 50% là không có lí do gì để có nhóm chứng! Do đó, tất cả các nghiên cứu lâm sàng đối chứng ngẫu nhiên phải bắt đầu bằng xác suất tiền định là 50%, và đó cũng chính là một thông tin cho phân tích Bayes. Chính vì thế mà có người cho rằng không có lí do gì dữ liệu nghiên cứu lâm sàng không sử dụng phương pháp phân tích Bayes.

Phân tích Bayes đòi hỏi tính toán phức tạp hơn phương pháp phân tích theo trường phái tần số. Có nhiều vấn đề quá phức tạp không/chưa ai có thể giải được! Tuy nhiên, một điều rất may mắn là với sự phát triển của máy tính và thuật toán MCMC (Markov Chain Monte Carlo), hầu như bất cứ vấn đề nào cũng có thể giải đáp được (mà toán học không giải được). Do đó, phương pháp Bayes càng ngày càng được ứng dụng trong nghiên cứu lâm sàng với nhiều thành công ngoạn mục. Người ta tiên đoán rằng phương pháp Bayes sẽ “thống trị” khoa học trong thế kỉ 21, và phương pháp tần số sẽ dần dần lùi vào hậu trường do những khiếm khuyết cơ bản của nó. Kinh nghiệm của cá nhân chúng tôi cho thấy phương pháp Bayes giải quyết được nhiều vấn đề nghiên cứu và cung cấp những câu trả lời mà trước đây còn tranh cãi [4-6], nhất là vấn đề cá nhân hóa trong tiên lượng y khoa [7].

Tóm lại, suy luận khoa học theo phương pháp Bayes là một suy luận dựa vào logic thông thường, mà bất cứ bác sĩ lâm sàng nào hay thậm chí người ngoài khoa học nào cũng nắm được. Đó là một cách tích lũy kiến thức. Những gì chúng ta đã biết (thông tin tiên định) cộng với những gì chúng ta thu thập được (dữ liệu thực tế) giúp cho chúng ta củng cố kiến thức tốt hơn (thông tin hậu định). Trong nghiên cứu lâm sàng, chúng ta muốn có câu trả lời cho 2 câu hỏi: (a) với những dữ liệu quan sát được, xác suất có ảnh hưởng thật là bao nhiêu, và (b) xác suất ảnh hưởng có ý nghĩa lâm sàng là bao nhiêu. Chỉ có phương pháp Bayes trả lời được hai câu hỏi này. Phương pháp phân tích theo tần số (frequentist) như trị số P không thể cung cấp câu trả lời cho hai câu hỏi trên. Chính vì thế mà suy luận theo phương pháp Bayes ngày càng được ứng dụng trong tất cả các lĩnh vực khoa học và công nghệ.

Tài liệu tham khảo và chú thích

- [1] Bayes, Thomas; Price, Mr. (1763). An Essay towards solving a Problem in the Doctrine of Chances. *Philosophical Transactions of the Royal Society of London* 53 (0): 370-418. Có thể xem bản gốc của bài báo quan trọng này tại địa chỉ:
<http://www.stat.rice.edu/~blairc/seminar/Files/danTalk.pdf>
- [2] Bolland MJ, Grey A, Avenell A, Gamble GD, Reid IR. Calcium supplements with or without vitamin D and risk of cardiovascular events: reanalysis of the Women's Health Initiative limited access dataset and meta-analysis. *BMJ* 2011;342:d2040.
- [3] Meunier PJ, et al. The Effects of Strontium Ranelate on the Risk of Vertebral Fracture in Women with Postmenopausal Osteoporosis. *N Engl J Med* 2004;350:459-68.
- [4] Nguyen TV. Interpretation of Randomized Controlled Trials of Fracture Prevention. *IBMS BoneKEy*, August 1, 2009; 6(8): 279 - 294.
- [5] Nguyen ND, Wang CY, Eisman JA, Nguyen TV. On the association between statin and fracture: a Bayesian consideration. *Bone* 2007 Apr;40(4):813-20.
- [6] Nguyen ND, Eisman JA, Nguyen TV. Anti-hip fracture efficacy of bisphosphonates: a Bayesian analysis of clinical trials. *J Bone Miner Res* 2006;21(2):340-9.
- [7] Nguyen TV. Individualization of osteoporosis risk. *Osteoporos Int* 2007 Sep;18(9):1153-6.

19 Hướng dẫn sử dụng WinBUGS

Trong khoảng một thập niên gần đây, WinBUGS đã trở thành một chương trình máy tính phân tích thống kê quan trọng. WinBUGS do một nhóm chuyên gia thống kê thuộc Hội đồng Nghiên cứu Y khoa Anh (Medical Research Council - MRC) phát triển, với sự tài trợ trực tiếp của chính phủ Anh. Sự ra đời của WinBUGS và phiên bản trước đó là BUGS (Bayesian Inference Using Gibbs Sampling) là một trong những phát triển quan trọng nhất trong thế kỉ 21 trong khoa học thống kê học, vì chương trình này giải được rất nhiều vấn đề mà trước đây người ta chỉ bàn luận trên lý thuyết. WinBUGS dùng phương pháp tính toán (Markov Chain Monte Carlo - MCMC) để thực hiện những tính toán rất phức tạp mà trước đây không ai giải được. Có thể nói không ngoa rằng nếu không có WinBUGS thì các mô hình phân tích theo phương pháp Bayes không có diện mạo như ngày nay.

Do đó, chúng ta cần phải học WinBUGS. Bài này chỉ dẫn cách cài đặt và sử dụng WinBUGS cho phân tích thống kê theo mô hình Bayes. Tôi cũng minh họa hai phân tích đơn giản qua WinBUGS. Trong bất cứ vấn đề kỹ thuật nào, chỉ có thể thành thạo khi thực hành chứ không chỉ đọc. Do đó, bạn đọc có thể làm theo những qui trình từng bước được mô tả trong bài để có thêm kinh nghiệm.

Vài năm gần đây, đã có khá nhiều tài liệu chỉ dẫn cách sử dụng WinBUGS. Tuy nhiên, kinh nghiệm của tôi cho thấy những tài liệu này không dễ đọc chút nào! Thậm chí, có tài liệu viết khá cụ thể, nhưng vẫn làm cho những người mới làm quen với WinBUGS cảm thấy lúng túng và rối rắm. Do đó, tôi soạn bài này để giúp cho những người mới sử dụng WinBUGS lần đầu, và tôi sẽ cố gắng mô tả các qui trình sử dụng một cách chi tiết và cụ thể.

19.1 Cài đặt WinBUGS

WinBUGS là chương trình được chạy từ máy tính cá nhân. Do đó, cần phải tải các nhu liệu từ website của winBUGS để cài đặt trong máy.


- Truy cập website của nhóm thống kê Hội đồng nghiên cứu y khoa Anh: <http://www.mrc-bsu.cam.ac.uk/bugs/winbugs/contents.shtml>
- Tải về máy các nhu liệu sau đây: WinBUGS14.exe và keys (WinBUGS14_immortality_key.txt).
- Khởi động chương trình WinBUGS14.exe, và nhu liệu này sẽ tự động cài đặt WinBUGS trong máy. Sau khi cài đặt xong, máy tính sẽ có một folder mới:

C:\Program Files\WinBUGS14

và trong đó có nhiều folder nhỏ khác, nhưng có lẽ folder liên quan nhất là


C:\Program Files\WinBUGS14\Bugs

- Nên tạo ra một icon trong desktop để sử dụng WinBUGS về lâu về dài. Cách tạo icon có thể làm theo qui trình như sau:
 - Vào folder C:\Program Files\WinBUGS14
 - Dùng chuột bấm nút phải nhấn vào file có WinBUGS icon và chọn "Create Shortcut"




Hình 1. Tạo ra shortcut cho WinBUGS

Nhưng trước khi sử dụng WinBUGS, chúng ta cần phải báo cho WinBUGS biết các mã số trong một file gọi là chìa khóa: WinBUGS14_immortality_key.txt. Cách cài đặt khóa trong WinBUGS như sau:



Hình 2. Khởi động WinBUGS

- Khởi động WinBUGS (từ desktop)
- Click vào tab **File** và chọn **New** để mở một window mới hoàn toàn



Hình 3. Cài mã khóa (key)

- Mở file WinBUGS14_immortality_key.txt (dùng notepad), và copy toàn bộ (Control-A)
- Chuyển sang WinBUGS và dán vào window trống. Từ tab **Tools**, chọn **Decode**:

Một box mới sẽ xuất hiện. Click vào **Decode All**. Đến đây thì chúng ta đã xong công đoạn cài đặt WinBUGS, và có thể sử dụng chương trình này một cách... lâu dài.

19.2 Phân tích dữ liệu với WinBUGS

So với các chương trình máy tính về phân tích thống kê khác (như SAS, R, SPSS, v.v.), cách phân tích trên WinBUGS tương đối khó hơn. Tuy nhiên, các mô hình phân tích Bayes chỉ có thể thực hiện một cách hữu hiệu qua WinBUGS, chứ không thể qua một chương trình khác. Ngay cả các chương trình như SAS và R có vài phần để phân tích Bayes nhưng vẫn còn rất “nhiều khê” và rất chậm. Ngược lại WinBUGS có thể ứng dụng cho tất cả mô hình Bayes và rất hữu hiệu. Qui trình phân tích bằng WinBUGS có thể tóm lược qua 10 bước sau đây:

Tóm lược qui trình chạy một mô hình trên WinBUGS

BƯỚC	MÔ TẢ	WinBUGS
1	Mô tả mô hình (model specification)	File → New
2	Kiểm tra lệnh và mô hình (model checking)	File → Specification = Specification Tool → (check model)
3	Nhập dữ liệu (data loading)	Specification Tool → load data
4	Chạy thử (compile)	Specification Tool → compile
5	Giá trị khởi đầu (initial values)	Specification Tool → gen inits
6	Thông số (specification of parameters)	Inference → Samples = Sample Monitor Tool
7	Mô phỏng (simulation)	Model → Update = Update Tool (updates: số lần mô phỏng update)
8	Kết quả (results)	Sample Monitor Tool → node → (stats, density)
9	Chẩn đoán (diagnosis)	Sample Monitor Tool → history

Chúng ta có thể bắt đầu bằng một ví dụ đơn giản và cụ thể. Một nghiên cứu về hiệu quả của thuốc trên 25 bệnh nhân cho thấy có 11 bệnh nhân đáp ứng (tức thuốc có hiệu quả). Chúng ta muốn biết khoảng tin cậy 95% của tỉ lệ hiệu quả là bao nhiêu. Chúng ta sẽ ứng dụng phương pháp Bayes để phân tích. Phương pháp Bayes có 3 phần: thông tin tiền định (prior information), dữ liệu thực tế (likelihood), và thông tin hậu định (posterior information).

Dữ liệu thực tế là số liệu chúng ta có được: $n = 25$ và $x = 11$. Có thể chọn luật phân bố nhị phân (binomial distribution) để mô tả kết quả này. Luật phân phối nhị phân cũng có 2 thông số: số cỡ mẫu n và tỉ lệ p . Nói cách khác:

$$x \sim \text{Bin}(p, n)$$

Thông tin tiên định: chúng ta không có một “thiên kiến” nào về hiệu quả của thuốc, nên sẽ chọn luật phân bố beta để mô tả thông tin tiên định. Phân bố beta có 2 thông số, tạm gọi là a và b :

$$p \sim \text{Beta}(a, b)$$


Chúng ta cho thông số $a = b = 1$.

Để phân tích mô hình trên với WinBUGS, chúng ta sẽ làm theo qui trình từng bước sau đây:

Bước 1. Mô tả mô hình phân tích


Bước đầu tiên trong WinBUGS là mô tả mô hình bằng cách viết ra lệnh, và lưu trữ thành một file. Bước này có thể thực hiện theo qui trình sau đây:

- Khởi động WinBUGS, nhấn chuột vào tab **File** (trên WinBUGS menu) và chọn **New**:



Hình 4. Khởi động và tạo ra file mới

- Trong bước này, chúng ta phải viết ra mô hình trong window trống như dưới đây:




Hình 5. Mô tả mô hình bằng các lệnh

Bất cứ một chương trình nào cũng có 2 phần: mô hình (MODEL) và dữ liệu (DATA). Trong phần mô hình, chúng ta mô tả mô hình phân tích. Cách viết mô hình trong WinBUGS rất giống như cách viết thống kê, nên cũng tiện cho việc giảng dạy và bàn luận. Trong phần dữ liệu, chúng ta cung cấp dữ liệu để mô hình có thể sử dụng.


Bước 2. Kiểm tra “ngữ pháp” (check model)

Ngữ pháp rất quan trọng. Nếu ngữ pháp sai, WinBUGS sẽ không chạy. Do đó, trước khi chạy WinBUGS chúng ta lúc nào cũng phải kiểm tra các lệnh và hàm cẩn thận. Để kiểm tra, nhấn chuột vào tab **Model** (trên menu của WinBUGS) và chọn **Specification**:




Hình 6. Chọn specification từ Model

Sau đó, một dialogue box có tên là **Specification Tool** sẽ xuất hiện như sau:




Hình 7. Specification Tool

Nhấn chuột và tô đậm (highlight) **MODEL**, di dời chuột sang **Specification Tool** và nhấn **check model**;



Hình 8. Kiểm tra ngữ pháp của mô hình

và chú ý đến thông điệp phía dưới (bên trái) của window:




Hình 9. Thông điệp sau khi kiểm tra ngữ pháp của mô hình

Trong trường hợp này, chúng ta có thông điệp cho biết ngữ pháp của mô hình là đúng (model is syntactically correct). Nếu có vấn đề, chúng ta cần phải xem xét cẩn thận các lệnh một lần nữa và kiểm tra cho đến khi nào có thông điệp này mới có thể tiến đến bước kế tiếp.

Bước 3. Nhập dữ liệu (load data)


Trong bước này, chúng ta vẫn dùng **Specification Tool** để cho WinBUGS biết số liệu thực tế. Chúng ta làm theo qui trình:

- Nhấn chuột vào và bôi đậm **list** (trong phần DATA) như dưới đây:



Hình 10. Nhập dữ liệu


- Di chuyển chuột sang **Specification Tool**, nhấn vào nút **load data**. Một thông điệp sẽ hiện phía dưới (phần trái) cho biết dữ liệu đã được nhập (data loaded):



Hình 11. Thông điệp sau khi nhập dữ liệu


Bước 4. Chạy thử mô hình (compile)

Trong bước này, chúng ta báo cho WinBUGS biết có thể sử dụng mô hình cho dữ liệu mới nhập. Trong **Specification Tool**, chọn **compile**.



Hình 12. Chạy thử (compile)


Một thông điệp sẽ hiện phía dưới (phần trái) cho biết dữ liệu đã được thử (model compiled):



Hình 13. Thông điệp sau khi chạy thử

Bước 5. Cho giá trị khởi đầu (generating initials - gen inits)

Vì yêu cầu của phương pháp mô phỏng Monte Carlo, nên các mô hình Bayes đều cần có một giá trị khởi đầu, gọi là initial values. Cách tốt nhất là để cho WinBUGS tự động cho các giá trị này, bằng cách dùng **Specification Tool**, và chọn **gen inits**:




Hình 14. Dữ liệu khởi đầu

Sau khi chọn **gen inits**, một thông điệp phía dưới (bên trái) sẽ xuất hiện:
initial values generated, model initialized

Bước 6. Mô tả thông số (parameter)


Một mô hình có ít nhất là một thông số (parameter). Chúng ta cần phải cho WinBUGS biết thông số cần ước tính là gì. Trong trường hợp trên, thông số chúng ta cần biết là p - tỉ lệ bệnh nhân đáp ứng thuốc.

Để thực hiện bước này, nhấn chuột vào tab **Inference** trên menu của WinBUGS và chọn **Sample**:



Hình 15. Chọn Sample từ Inference


Một dialogue mới có tên là **Sample Monitor Tool** sẽ xuất hiện như hình dưới đây:



Hình 16. Sample Monitor Tool

Trong **Sample Monitor Tool** chúng ta có thể cho WinBUGS biết những thông số chúng ta cần phân tích. Như đề cập trên, chúng ta muốn biết khoảng tin cậy 95% của p (là tên thông số trong MODEL), nên chọn bách phân vị (**percentiles**) 2.5, trung vị (**median**) là 97.5.

Đưa chuột vào box có tên **node** trong **Sample Monitor Tool** và gõ **p**:




Hình 17. Chọn thông số cho phân tích

Sau đó, nút **set** sẽ được kích hoạt (activated). Nhấn chuột vào **set** cho đến khi tất cả các thông số đã được liệt kê. Cũng có thể thấy các thông số (nếu cần) bằng cách nhấn chuột vào nút **node**.

Bước 7. Mô phỏng (generating simulated values)


Sau khi mô hình đã được mô tả, thông số đã được chọn, bước kế tiếp là mô phỏng. Để thực hiện bước này, nhấn chuột vào tab **Model** trên menu của WinBUGS và chọn **Update**:



Hình 18. Chọn Model và Update


Sau đó một dialogue box có tên là **Update Tool** sẽ xuất hiện:

11, n=25)



Hình 19. Update Tool

Trong **Update Tool** có phần update, nơi chúng ta cần cho WinBUGS biết số lần mô phỏng là bao nhiêu. Chẳng hạn như tôi cho số lần mô phỏng là 5000:




Hình 20. Update

Nhấn vào nút **update**, WinBUGS sẽ chạy (tùy theo mô hình) vài giây hay vài phút. Sau khi bước này xong, chúng ta đã có kết quả, và bước kế tiếp là xem xét kết quả.


Bước 8. Xem xét kết quả thông tin hậu định (posterior information)

Trong bước này, chúng ta sẽ xem kết quả phân tích. Để thực hiện bước này, chúng ta quay lại **Sample Monitor Tool** và cung cấp 1001 vào field beg (có nghĩa là yêu cầu WinBUGS bỏ 1000 mô phỏng đầu vốn chỉ để lấy các giá trị initials). Cần nhắc lại rằng nhớ chọn thông số (trường hợp này là p) từ field node:



Hình 21. Cung cấp tên thông số cho phân tích

Sau khi chọn **p**, các nút trong **Sample Monitor Tool** sẽ kích hoạt, và chúng ta có thể xem qua kết quả. Nhấn chuột vào **stats** (để có các thông số khoảng tin cậy 95%) và **density** để có biểu đồ phân bố của **p**. Kết quả là:




Hình 22. Kết quả phân tích

Trong phần stats, chúng ta thấy tỉ lệ trung bình là 44.2%, với khoảng tin cậy 95% dao động trong khoảng 26.8% đến 62.6%. Biểu đồ phân bố thể hiện mô phỏng 5000 lần cũng phù hợp với các kết quả trên.

Bước 9. Chẩn đoán (diagnosis)

Trước khi chấp nhận kết quả trên, chúng ta cần phải kiểm tra phần kỹ thuật tính toán có đạt yêu cầu hay chưa. Đạt yêu cầu khi các bước tính toán theo chu kì đã “converged” (tức ổn định). Để kiểm tra kỹ thuật, chúng ta sử dụng **Sample Monitor Tool** và nhấn chuột vào nút **history**. Kết quả là:



Hình 23. Chẩn đoán

Kết quả trình bày trong biểu đồ có tên **Time Series** cho thấy mô hình và tính toán ổn định.

19.3 Phân tích 2 nhóm

Số liệu về tử vong trong 2 nhóm phẫu thuật như sau: Trong số 18 bệnh nhân được phẫu thuật bằng phương pháp 1, có 3 người tử vong; trong nhóm 23 người được phẫu thuật bằng phương pháp mới có 2 người tử vong.

NHÓM	SỐ BỆNH NHÂN (n)	SỐ TỬ VONG (x)
Nhóm 1	18	3
Nhóm 2	23	2

Câu hỏi nghiên cứu là có khác biệt gì giữa hai nhóm. Nếu gọi P_1 và P_2 là tỉ lệ tử vong của nhóm 1 và 2, câu hỏi nghiên cứu có thể đặt ra theo ba cách diễn đạt:

- Gọi $D = P_1 - P_2$, câu hỏi là $D > 0$?
- Gọi $RR = P_1 / P_2$ (tỉ số nguy cơ), câu hỏi cũng có thể là $RR > 1$?
- Nếu đặt $OR = P_1 / (1 - P_1) / P_2 / (1 - P_2)$ (tỉ số odds), câu hỏi cũng có thể là $OR > 1$?

Chúng ta có thể phân tích 3 câu hỏi trên bằng WinBUGS như sau:

```
MODEL {


# prior information
p1 ~ dbeta(0.5, 0.5)
p2 ~ dbeta(0.5, 0.5)

# data or likelihood
x1 ~ dbin(p1, n1)
x2 ~ dbin(p2, n2)

# effect size
diff = p1-p2
rr = p1/p2
or = (p1/(1-p1)) / (p2/(1-p2))
logOR = log(or)
ppos = step(OR - 1)
}


DATA list(x1=3, n1=18, x2=2, n2=23)
```

Chúng ta vẫn tiến hành những bước kiểm tra “ngữ pháp” (check model), cung cấp dữ liệu (load data), chạy thử mô hình (compile), cho giá trị khởi đầu (generating initials - gen inits), và tính toán thông tin hậu định (posterior information). Vì mô hình này có nhiều thông số, nên trong field **node** của **Sample Monitor Tool** chúng ta phải cung cấp những thông số như p1, p2, or, rr, và ppos (xác suất $OR > 1$). Chú ý dấu “*” trong node có nghĩa là tất cả các thông số:



Hình 24. Sample Monitor Tool: mô tả thông số cho phân tích

Kết quả sẽ là:



Hình 25. Kết quả phân tích 2 tỉ lệ

Trên đây là chỉ dẫn đơn giản từng bước một để sử dụng WinBUGS cho các phân tích theo mô hình Bayes. Hi vọng rằng các chỉ dẫn trên đây đã và sẽ giúp cho các bạn thực hiện được những phân tích đơn giản và trung bình.

Để sử dụng WinBUGS một cách hữu hiệu, người sử dụng cần phải làm quen với “ngữ pháp” của chương trình máy tính. Bài này không có mục đích mô tả các lệnh đó. Bạn đọc có thể truy cập trang web www.mrc-bsu.cam.ac.uk để tải về các tài liệu chỉ dẫn và cẩm nang để tham khảo.

Phương pháp phân tích dữ liệu theo trường phái Bayes được đánh giá là phương pháp chính trong thế kỉ 21. Vì phương pháp tần số (frequentist methods) có nhiều khiếm khuyết, và càng ngày càng có nhiều người nhận ra sự hữu ích của phương pháp Bayes, nên hiện nay WinBUGS càng ngày càng được nhắc đến thường xuyên. Ở Việt Nam, phương pháp Bayes chưa được quan tâm vì thiếu tài liệu và các trường đại học cũng chưa có những chương trình giảng dạy có hệ thống. Chương này mang tính giới thiệu và hi vọng sẽ góp một phần nhỏ để giới thiệu phương pháp Bayes đến các bạn quan tâm.



20

Thiết kế thí nghiệm (Design of experiments)



Cụm từ “thí nghiệm” ở đây không chỉ bao gồm các hoạt động trong phòng thí nghiệm, mà còn bao gồm cả những công trình khảo sát rộng lớn hơn như thử nghiệm lâm sàng đối chứng ngẫu nhiên (randomized clinical trial), các công trình nghiên cứu tiêu biểu một thời điểm (còn gọi là nghiên cứu cắt ngang hay cross-sectional study), thăm dò ý kiến, điều tra về dân số, v.v... Ngay cả một chính sách kinh tế cũng có thể xem là một thí nghiệm - thí nghiệm xã hội.

Một thí nghiệm đạt tiêu chuẩn khoa học phải là một thí nghiệm được thiết kế có hệ thống và khách quan. Chẳng hạn, như để biết tỉ lệ mắc bệnh đái tháo đường trong một quần thể, chúng ta không cần phải khám nghiệm tất cả cá nhân trong quần thể đó, mà chỉ chọn ngẫu nhiên một số cá nhân đại diện. Tuy nhiên, nếu số lượng cá nhân đại diện (còn gọi là *mẫu*) quá thấp thì công trình nghiên cứu sẽ không cho kết quả chính xác; ngược lại nếu số lượng mẫu quá lớn, chúng ta sẽ phung phí tiền bạc và cơ sở vật chất một cách không cần thiết. Do đó, mục tiêu của thiết kế nghiên cứu là (i) để phát hiện một ảnh hưởng hay tác dụng của một can thiệp, và (ii) sử dụng cơ sở vật chất và tài lực một cách tối ưu.

Qua các chương trước, chúng ta đã làm quen với một số mô hình phân tích số liệu. Kết quả của các phân tích này chỉ có giá trị khoa học khi số liệu được thu thập đúng phương pháp, và khi công trình nghiên cứu được thiết kế một cách tối ưu. Các mô hình thống kê không thể cung cấp cho chúng ta thông tin về chất lượng của nghiên cứu, vì đây là một khía cạnh cần sự thẩm định cẩn thận của nhà nghiên cứu. Do đó, thiết kế nghiên cứu, đóng một vai

trò rất quan trọng cho việc thành bại của một công trình khoa học. Có thể nói rằng một nghiên cứu nếu được thiết kế cẩn thận và đúng phương pháp thì mức độ thành công đã đạt được 50%. Chương này và chương sau sẽ bàn qua một số khái niệm căn bản về thiết kế nghiên cứu và một số mô hình nghiên cứu thông dụng.

20.1 Thuật ngữ

Để thuận tiện cho việc theo dõi và quán triệt các khái niệm nghiên cứu, có lẽ chúng ta phải làm quen và phân biệt được một số thuật ngữ quan trọng trong khi thiết kế một nghiên cứu.

Đơn vị nghiên cứu (experimental unit): Tùy theo lĩnh vực nghiên cứu, đơn vị nghiên cứu có thể là đối tượng (như bệnh nhân hay tình nguyện viên), mẫu ruộng, sản phẩm, qui trình sản xuất, v.v... Đơn vị nghiên cứu là đối tượng sử dụng trực tiếp cho việc đo lường. Chẳng hạn như, trong nghiên cứu về vị đắng của cà phê, nhà nghiên cứu có thể cho một nhóm người tiêu thụ nếm thử nhiều loại cà phê khác nhau, và các loại cà phê này chính là đơn vị nghiên cứu. Trong các nghiên cứu lâm sàng, nhà nghiên cứu có thể chọn hai nhóm bệnh nhân để so sánh hiệu quả của hai thuật điều trị, và trong trường hợp này, mỗi bệnh nhân là một đơn vị nghiên cứu.

Yếu tố can thiệp (factors): là những can thiệp (intervention) áp dụng trên các đối tượng nghiên cứu. Yếu tố can thiệp còn có khi được gọi là biến độc lập (independent variable) hay biến giải thích (explanatory variable). Trong ví dụ nghiên cứu lâm sàng vừa đề cập trên, hai thuật điều trị là yếu tố can thiệp. Hay trong nghiên cứu về hiệu quả của hai loại giống lúa, thì giống lúa được xem là yếu tố can thiệp.

Mức độ can thiệp (treatment levels): là những “giá trị” của một yếu tố can thiệp. Chẳng hạn như nếu hai thuật điều trị là hai loại thuốc, và mỗi loại thuốc có 3 liều lượng, thì liều lượng là mức độ can thiệp. Hay trong nghiên cứu cảm quan, nhà nghiên cứu có thể cho người tiêu thụ nếm thử vị ngọt của một loại bia, nhưng bia được sản xuất với ba công thức khác nhau, thì công thức chính là mức độ can thiệp.

Nhóm (block): Trong nhiều nghiên cứu, một nhóm yếu tố can thiệp có thể sắp đặt thành từng nhóm (hay khối). Chẳng hạn như trong một nghiên cứu cảm quan về vị đắng của 3 loại cà phê (A, B và C), nhà nghiên cứu có thể chọn một số đối tượng nghiên cứu (người tiêu thụ) và chia đối tượng thành ba nhóm 1, 2 và 3 như sau:

	NHÓM 1	NHÓM 2	NHÓM 3
Can thiệp	A, B, C	A, B, C	A, B, C

Trong phương án này, cá nhân trong mỗi nhóm đều thử nghiệm tất cả 3 loại cà phê, và thứ tự A, B, C không thay đổi giữa các nhóm. Phương án này còn có tên là *balance complete block design* (phương án cân đối nhóm).

Hoặc nhà nghiên cứu có thể chọn 2 loại cà phê cho ba nhóm:

	NHÓM 1	NHÓM 2	NHÓM 3
Can thiệp	A, B	B, C	A, C

Trong phương án này, mỗi nhóm chỉ thử nghiệm 2 loại cà phê, nhưng thứ tự loại cà phê được thay đổi theo từng nhóm. Phương án này còn có tên là *balance incomplete block design* (phương án cân đối nhóm không đầy đủ).

Phương án cân đối nhóm còn được sử dụng khá phổ biến trong các nghiên cứu lâm sàng. Chẳng hạn như nghiên cứu thử nghiệm hiệu quả của hai loại thuốc điều trị bệnh loãng xương, nhà nghiên cứu có thể chọn 100 bệnh nhân, và chia thành 5 nhóm (mỗi nhóm có 20 người). Trong mỗi nhóm, 10 người được điều trị bằng thuốc A và 10 người được điều trị bằng thuốc B. Phân nhóm phải được tiến hành hoàn toàn ngẫu nhiên để đảm bảo tính khách quan của nghiên cứu.


Tiêu chí (response variable): là biến số chịu ảnh hưởng của yếu tố can thiệp. Chẳng hạn như trong nghiên cứu cảm quan về vị đắng của cà phê thì vị đắng là tiêu chí nghiên cứu; hay trong nghiên cứu về hiệu quả của hai thuật điều trị bệnh loãng xương thì mật độ xương (bone mineral density) là tiêu chí.

Ví dụ 1: Một thí nghiệm cảm quan đơn giản. Để biết người tiêu thụ đánh giá độ ngọt của một loại nước ngọt thế nào, các nhà nghiên cứu sản xuất ra hai loại nước ngọt với công thức A và B. Trong thí nghiệm, người tiêu thụ được cho thử nước ngọt và cho điểm độ ngọt (từ 1 = “không ngọt” đến 10 = “quá ngọt”) như sau. Vấn đề đặt ra là tìm một phương án nghiên cứu sao cho lượng thông tin thu thập được tối đa và đảm bảo tiêu chuẩn khoa học.


1 (không ngọt)	2	3	4	5	6	7	8	9	10 (quá ngọt)
-------------------	---	---	---	---	---	---	---	---	------------------

Phương án 1: các nhà nghiên cứu ngẫu nhiên mời n (n có thể là 15) khách hàng và cho mỗi khách hàng uống thử cả hai loại nước ngọt và phân tích khác biệt về độ ngọt giữa hai sản phẩm từ mỗi người.

Phương án 2: ngẫu nhiên chọn $2n$ (hay 30 người), rồi ngẫu nhiên chia thành 2 nhóm. Nhóm 1 uống nước ngọt công thức A, và nhóm 2 uống nước ngọt công thức B như sau:



Phương án 3: ngẫu nhiên chọn n (hay 15 khách hàng); mỗi khách hàng được cho uống hai loại nước ngọt, nhưng thứ tự AB và BA được phân chia một cách ngẫu nhiên như sau. Phương án này có 2 yếu tố can thiệp (A và B) cho mỗi nhóm (block). Nói cách khác, mỗi khách hàng là một “nhóm”.



Mỗi phương án trên đều có lợi thế và bất tiện. Thứ nhất, về mặt cơ sở vật chất và chi phí, phương án 2 đòi hỏi số lượng đối tượng nghiên cứu cao gấp hai lần phương án 1, đắt tiền hơn và tốn nhiều thời gian hơn.

Thứ hai, về mặt khoa học, phương án 2 đòi hỏi nhà nghiên cứu phải so sánh hai nhóm một cách độc lập, và độ nhiễu thông tin (noise) của phương án này chắc chắn phải cao hơn độ nhiễu của phương án 1 và 3. “Độ nhiễu”

ở đây có thể đo bằng phương sai (variance). Để hiểu khái niệm quan trọng này, chúng ta cần phải đi qua một khái niệm thống kê học căn bản. Gọi tiêu chí đo độ ngọt của hai nhóm là x_1 và x_2 ; Gọi phương sai của độ ngọt của hai nhóm là s_1^2 và s_2^2 . Bởi vì theo phương án 2, hai nhóm độc lập nhau (tức là khách hàng thử sản phẩm A không phải là khách hàng thử sản phẩm B) cho nên phương sai của độ khác biệt giữa hai sản phẩm $x_1 - x_2$ (kí hiệu $s_{x_1 - x_2}^2$) là:

$$s_{x_1 - x_2}^2 = s_1^2 + s_2^2 \quad [1]$$

Nếu phương sai của hai nhóm bằng nhau $s_1^2 = s_2^2 = s^2$, thì phương sai của độ khác biệt đơn giản là:

$$s_{x_1 - x_2}^2 = 2 s^2.$$

Nhưng với phương án 1, bởi vì mỗi khách hàng thử cả hai sản phẩm, do đó, x_1 và x_2 **không độc lập** với nhau, và phương sai của độ khác biệt là:

$$s_{x_1 - x_2}^2 = s_1^2 + s_2^2 - 2 \text{cov}(x_1, x_2) \quad [2]$$

Trong đó, $\text{cov}(x_1, x_2)$ có nghĩa là hiệp biến (covariance), tức phản ánh độ tương quan giữa x_1 và x_2 . Bởi vì độ tương quan giữa x_1 và x_2 chắc chắn phải là một số dương (lớn hơn 0); Do đó, phương sai trong công thức [2] luôn luôn nhỏ hơn phương sai trong công thức [1].

Nói cách khác, độ nhiễu thông tin của phương án 1 và 3 lúc nào cũng nhỏ hơn độ nhiễu của phương án 2. Do đó, phương án 1 và 3 có ưu thế hơn phương án 2.

Thứ ba, phương án 1 và 3 giống nhau ở điểm mỗi khách hàng uống thử cả hai loại sản phẩm, nhưng phương án 3 thì thứ tự sản phẩm được thay đổi ngẫu nhiên (chứ không cố định như phương án 1). Sự thay đổi ngẫu nhiên như từ A sang B (và B sang A) cũng có thể xem là một cách “blocking” (phân nhóm), do đó, nhà nghiên cứu có thể kiểm soát thêm một nguồn dao động quan trọng.

Vì vậy, trong ba phương án này, có thể nói phương án 3 là tối ưu nhất. Nhưng tất nhiên vấn đề còn tùy thuộc vào đặc tính của sản phẩm và tình hình thực tế. Có nhiều sản phẩm mà phương án 1 và 3 không thể áp dụng vì lí do an toàn hay hiệu ứng “hawthorne” (sẽ bàn trong phần dưới đây).

20.2 Ba nguyên tắc quan trọng của một nghiên cứu

Một nghiên cứu khoa học phải tuân thủ theo ba nguyên tắc: ngẫu nhiên hóa (randomization), lặp lại nhiều lần (replication), và phân nhóm (blocking).

Tại sao phải ngẫu nhiên hóa? Trong nhiều nghiên cứu, chúng ta phải lấy mẫu (sample) từ một quần thể (population). Một trong những yêu cầu quan trọng của lấy mẫu là mẫu phải mang tính đại diện cho quần thể. Chẳng hạn như trong quần thể 1 triệu người có 50% nam và 20% người có trình độ văn hóa cao hơn lớp 12, nếu chúng ta chọn 100 người từ quần thể này, mẫu được chọn được xem là đại diện khi có khoảng 50 nam và 20 người có học vấn trên lớp 12. Chọn mẫu ngẫu nhiên là phương án tốt nhất để đảm bảo tính đại diện này.

Đối với một nhóm đối tượng, ngẫu nhiên hóa còn có khả năng cân đối các đặc điểm giữa các nhóm can thiệp. Giả dụ chúng ta đã mời được một nhóm gồm 50 tình nguyện viên sẵn sàng tham gia vào một công trình nghiên cứu cảm quan để thử vị chua của 2 loại nước giải khát (nói cách khác, chúng ta có 2 nhóm, và mỗi nhóm có 25 người). Dĩ nhiên 50 người này có nhiều đặc tính cá nhân khác nhau, chẳng hạn như độ tuổi, giới tính, trình độ văn hóa, sở thích cá nhân, v.v... Tất cả những đặc tính này có thể có ảnh hưởng đến cảm nhận về sản phẩm. Do đó, để “cân đối” các đặc tính này cho hai nhóm, cách duy nhất và khách quan nhất là phân chia họ thành hai nhóm một cách ngẫu nhiên.

Vì phần lớn các mô hình phân tích thống kê dựa vào giả định rằng đối tượng được chọn ngẫu nhiên từ một quần thể, cho nên ngẫu nhiên hóa còn đảm bảo tính hợp lý của kết quả phân tích.

Một trong những “tiêu chuẩn vàng” của khoa học là kết quả nghiên cứu phải có tính *có thể lặp lại* (repeatability) hay tái xác nhận. Nói một cách khác, nếu có một nghiên cứu đã được công bố bởi một nhà khoa học nào đó; Nếu một nhà nghiên cứu khác lặp lại nghiên cứu đó bằng những phương pháp và với điều kiện đã được mô tả, phải đạt được những kết quả tương tự. Đó là một tiêu chuẩn cực kì quan trọng để phân biệt giữa khoa học và ngụy khoa học (pseudoscience). Một quan sát được lặp lại nhiều lần thì quan sát đó có độ tin cậy cao. Và độ tin cậy cao cho phép kết luận nghiên cứu có giá trị cao.

Ngẫu nhiên hóa có thể làm cân đối các đặc điểm của đối tượng nghiên cứu cho các yếu tố can thiệp, nhưng với điều kiện số lượng đối tượng phải tương đối lớn. Khi số lượng đối tượng nghiên cứu nhỏ, thì ngẫu nhiên hóa không có hiệu quả cao. Chẳng hạn như với 6 đối tượng chia thành 2 nhóm, ngẫu nhiên hóa có thể cho ra kết quả 4 đối tượng thuộc nhóm A và 2 đối tượng

thuộc nhóm B. Do đó, một cách khác để đảm bảo tính cân đối là phân nhóm. Trong trường hợp trên, chúng ta có thể chia thành 3 nhóm (mỗi nhóm 2 đối tượng), và ngẫu nhiên hóa được tiến hành cho từng nhóm.

Phân nhóm không ảnh hưởng đến khâu phân tích số liệu, bởi vì chúng ta không có mục đích tìm hiểu tiêu chí cho từng nhóm. Phân nhóm chỉ có ảnh hưởng và giá trị trong khâu thiết kế nghiên cứu.

20.3 Ảnh hưởng giả dược (placebo), Hawthorne, và kín đáo

Trong các thí nghiệm liên quan đến con người và bệnh nhân, hai yếu tố khác có thể ảnh hưởng đến kết quả nghiên cứu, đó là giả dược và sự kín đáo (blinding). Để hiểu rõ hai ảnh hưởng này, chúng ta có thể xem xét một ví dụ sau đây. Để biết thuốc alendronate có hiệu quả ngăn ngừa gãy xương hay không, các nhà nghiên cứu chia 100 bệnh nhân thành hai nhóm can thiệp: nhóm 1 có 50 bệnh nhân được cho uống thuốc alendronate thật, và nhóm 2 cũng gồm 50 bệnh nhân được cho uống thuốc alendronate giả (còn gọi là giả dược hay placebo), nhưng hai loại thuốc hoàn toàn giống nhau, bệnh nhân và bác sĩ không thể phân biệt được thuốc nào là giả và thuốc nào là thật!

Thí nghiệm như vừa mô tả đặt ra hai vấn đề nan giải. Kinh nghiệm từ nhiều nghiên cứu lâm sàng y khoa cho thấy một xu hướng chung là bệnh nhân thường tự cho rằng sức khỏe họ có cải tiến hay tốt hơn, chỉ vì họ được điều trị (cho dù “điều trị” là giả dược)! Yếu tố tâm lý này thường được gọi là **“placebo effect”** hay *hiệu ứng giả dược*. Hiệu ứng giả dược có thể giải thích khoảng 35% kết quả của các nghiên cứu lâm sàng, đặc biệt là đối với các thuốc giảm đau, suyễn, trầm cảm (depression), bệnh đường ruột, và cao huyết áp. Chính vì lý do này, việc đánh giá hiệu quả của một thuật điều trị thường phải có một nhóm đối chứng (hay placebo) và độ khác biệt giữa hai nhóm can thiệp có thể xác định là hệ quả của thuốc thật hay do giả dược.

Yếu tố thứ hai là hiệu ứng Hawthorne. Con người nói chung có khả năng thích ứng rất cao, và khả năng này gây ra không ít khó khăn cho nghiên cứu khoa học. Chẳng hạn như, khi chúng ta cho một nhóm người tiêu thụ nếm vị đắng của cà phê nhiều lần, thì lần đầu người tiêu thụ vì chưa quen với vị đắng nên họ có thể cảm thấy rất đắng và cho điểm cao, nhưng đến lần 2 hay lần 3 thì vì đã quen với vị đắng nên họ cho điểm thấp xuống. Hay trong nghiên cứu lâm sàng, nếu bệnh nhân biết mình đang được theo dõi, họ sẽ cố gắng làm hài lòng bác sĩ và sự khách quan của bệnh nhân có thể bị ảnh hưởng. Thuật ngữ cho hiện tượng này là “Hawthorne effect”.

Yếu tố thứ ba là sự chủ quan của nhà nghiên cứu. Nếu bác sĩ biết bệnh nhân sử dụng thuốc thật hay giả được, cách đánh giá của họ có thể ảnh hưởng đến kết quả nghiên cứu. Vì thế, trong các nghiên cứu lâm sàng nghiêm chỉnh, nhà nghiên cứu không được biết bệnh nhân đang được điều trị bằng thuốc hay giả được, và phương cách này có tên là “blinding” (làm mù), tạm dịch là “kín đáo”. Việc giữ kín này phải được duy trì ở bệnh nhân và bác sĩ. Nói cách khác, cả bệnh nhân và bác sĩ đều không biết bệnh nhân thuộc vào nhóm can thiệp hay nhóm giả được.

Tuy nhiên, không phải bất cứ nghiên cứu lâm sàng nào cũng có thể duy trì sự kín đáo như thế. Chẳng hạn như nghiên cứu về hiệu quả của một thuật giải phẫu, bệnh nhân chắc chắn biết họ được giải phẫu thật hay giả (vì không có cái gọi là “giải phẫu giả”). Ngoài ra, vì lý do y đức, không phải nghiên cứu nào cũng có thể sử dụng giả được. Nếu chúng ta biết rằng căn bệnh có nguy hiểm đến tính mạng của bệnh nhân và thuốc có hiệu quả, thì không có lý do gì nhà nghiên cứu cho bệnh nhân dùng giả được. Trong các trường hợp này, nhà nghiên cứu phải suy nghĩ kỹ và phát triển một phương án nghiên cứu sao cho vừa không vi phạm y đức mà vừa đáp ứng các tiêu chuẩn khoa học.

20.4 Vài ví dụ về nguyên tắc của thiết kế nghiên cứu

Để quán triệt rõ các nguyên tắc trên, chúng ta thử xem qua một công trình nghiên cứu sau đây về hiệu quả của sinh tố C cho điều trị cảm cúm. Có giả thiết cho rằng sinh tố C có thể ngăn ngừa cảm cúm. Vấn đề đặt ra là chúng ta nên thiết kế nghiên cứu để thử nghiệm giả thiết này như thế nào để đạt tiêu chuẩn khoa học. Giả dụ, chúng ta có 50 người tình nguyện tham gia vào công trình nghiên cứu, chúng ta có thể chọn một trong những phương án sau đây:


Phương án 1. Cho 50 người uống sinh tố C trong vòng 6 tháng, và trong thời gian đó ghi nhận số lần cảm cúm. Kết quả cho thấy sau 6 tháng điều trị, tần số cảm cúm trung bình là 1.4 lần / đối tượng.

Phương án 2. Chia 50 người thành 2 nhóm nam và nữ. Cả hai nhóm được điều trị bằng sinh tố C trong vòng 6 tháng. Kết quả cho thấy sau 6 tháng điều trị, tần số cảm cúm trung bình trong nhóm nam là 1.4 lần / đối tượng, còn nhóm nữ tần số này là 1.9 lần / đối tượng.

Phương án 3. Chia 50 người thành 2 nhóm một cách ngẫu nhiên. Nhóm 1 gồm 25 người được điều trị bằng sinh tố C trong vòng 6 tháng. Nhóm 2


không được điều trị, nhưng vẫn được theo dõi 6 tháng. Kết quả cho thấy sau 6 tháng điều trị, tần số cảm cúm trung bình trong nhóm 1 là 1.4 lần / đối tượng, còn nhóm đối chứng là 1.9 lần/đối tượng.

Phương án 4. Nhờ một công ti dược sản xuất 50 hộp thuốc sinh tố C, và 50 hộp giả dược sinh tố C. Chia 50 người thành 2 nhóm một cách ngẫu nhiên: nhóm 1 gồm 25 người được điều trị bằng sinh tố C; nhóm 2 nhận giả dược. Cả hai nhóm được theo dõi 6 tháng. Kết quả cho thấy sau 6 tháng điều trị, tần số cảm cúm trung bình trong nhóm 1 là 1.4 lần/đối tượng, còn nhóm đối chứng là 1.4 lần/đối tượng.



Phương án 5. Cũng giống như phương án 4, nhưng chúng ta phân chia (blocking) hai nhóm can thiệp theo giới tính. Giới tính có thể có ảnh hưởng đến nguy cơ cảm cúm (nam thường bắt cần hơn nữ), cho nên chúng ta chia 50 người thành hai nhóm nam và nữ. Mỗi nhóm được ngẫu nhiên hóa thành hai nhóm can thiệp để đảm bảo cân đối nam và nữ cho từng nhóm. Cả hai nhóm được theo dõi 6 tháng. Sau 6 tháng điều trị, tần số cảm cúm trung bình cho từng nhóm can thiệp và giới tính có thể tóm lược như sau:

	NHÓM 1 (SINH TỐ C)	NHÓM 2 (ĐỐI CHỨNG)
Nam	1.4	1.9
Nữ	1.2	1.5



Dựa vào các nguyên lý thiết kế trên, có gì sai lầm trong 4 phương án nghiên cứu trên? Sau đây là vài nhận xét chính:

- Sai lầm của phương án 1 là không có nhóm đối chứng, cho nên kết quả không thể so sánh và cũng rất khó diễn dịch. Tần số trung bình 1.4 lần/đối tượng chẳng có ý nghĩa gì.
- Phương án 2 có nhóm đối chứng, nhưng vì yếu tố can thiệp được phân chia theo giới tính, cho nên độ khác biệt giữa tần số trung bình 1.4 và 1.9 lần/đối tượng không thể nói là do ảnh hưởng của giới tính hay do ảnh hưởng của sinh tố C.
- Phương án 3 có nhóm đối chứng, nhưng sai lầm là không có blinding, vì đối tượng nghiên cứu biết họ nhận hay không nhận thuốc. Nhóm được điều trị có thể sẽ chủ quan không rửa tay (vì nghĩ rằng sinh tố C đã bảo vệ họ), và điều này có thể ảnh hưởng đến kết quả nghiên cứu. Vì thế, kết quả này cũng khó diễn dịch.
- Phương án 4 không có sai lầm nào. Phương án này có nhóm đối chứng và đối tượng nghiên cứu được phân chia một cách ngẫu nhiên và kín đáo, đảm bảo việc so sánh có giá trị khoa học.
- Phương án 5 cũng không có sai lầm nào và tốt hơn phương án 4, vì ảnh hưởng của giới tính được kiểm soát qua cách phân chia ngẫu nhiên

20.5 Thí nghiệm với một yếu tố (single-factor designs)

Như tên gọi ám chỉ, các thí nghiệm một yếu tố chỉ có một yếu tố can thiệp. Phần lớn, các thử nghiệm lâm sàng đối chứng ngẫu nhiên (chia bệnh một cách ngẫu nhiên thành hai nhóm can thiệp) là một dạng của thiết kế này. Tuy nhiên, có nhiều phương án trong thiết kế này có thể ứng dụng cách phân nhóm (blocking). Ví dụ sau đây sẽ cho chúng ta một ý tưởng về hiệu quả của phân nhóm trong các thí nghiệm một yếu tố.

Ví dụ 2: Một nhóm nghiên cứu nông nghiệp muốn nghiên cứu ảnh hưởng của phân bón đến sự tăng trưởng của lúa. Ba liều lượng urê được sử dụng (thấp, trung bình, và cao - sẽ viết tắt bằng tiếng Anh là low, medium và high). Nhóm nghiên cứu chọn 6 địa điểm (A, B, C, D, E, và F), và mỗi địa điểm có 3 mảnh đất để thí nghiệm (1, 2, 3). Sau đây là vài phương án thí nghiệm mà nhóm nghiên cứu có thể chọn:

Phương án 1 - CRD (completely randomized design): Ở đây, nhóm nghiên cứu có $6 \times 3 = 18$ nơi để thí nghiệm, và 3 yếu tố can thiệp để chia nhóm. Nói cách khác, mỗi yếu tố can thiệp sẽ được áp dụng tại 3 nơi. Với phương án này CRD 3 yếu tố can thiệp được ngẫu nhiên hóa cho tất cả 18 nơi, và kết quả có thể là:

ĐỊA ĐIỂM	MẢNH ĐẤT 1	MẢNH ĐẤT 2	MẢNH ĐẤT 3
A	Low	High	Low
B	Medium	Medium	High
C	High	Medium	Low
D	Medium	Low	High
E	Medium	Low	Medium
F	Low	High	High

Trong phương án này, vì cách phân chia ngẫu nhiên, cho nên mỗi địa điểm có khi “nhận” hai liều lượng urê “low” và một loại urê “high” (như địa điểm A). Thành ra, so sánh giữa hai yếu tố can thiệp, như “low” và “high”, phải điều chỉnh độ dao động giữa các địa điểm.

Phương án 2 - RCB (randomized block design): Với phương án này, mỗi địa điểm và mỗi mảnh đất sẽ được áp dụng một yếu tố can thiệp; do đó, hoàn toàn cân đối. Nếu xem ba mảnh đất ở mỗi địa điểm thí nghiệm là ba block, thì phương án này đảm bảo tại mỗi địa điểm, mỗi block được phân chia một can thiệp như sau:

ĐỊA ĐIỂM	MẢNH ĐẤT 1	MẢNH ĐẤT 2	MẢNH ĐẤT 3
A	Low	High	Medium
B	Medium	Low	High
C	High	Medium	Low
D	Medium	Low	High
E	High	Low	Medium
F	Low	High	Medium

Phương án 3 - IBD (incomplete block design): Với phương án này, nhà nghiên cứu có thể chỉ cần 2 mảnh đất, và mỗi mảnh đất được áp dụng một yếu tố can thiệp như sau:

ĐIỂM	MẢNH ĐẤT 1	MẢNH ĐẤT 2
A	Low	High
B	Medium	Low
C	High	Medium
D	Medium	Low
E	High	Low
F	Low	High

Phương pháp phân tích kết quả từ các nghiên cứu này đã được trình bày trong chương 11.

20.6 Thí nghiệm với hai yếu tố (two-factor designs)

Các thiết kế vừa trình bày trong phần trên nhằm mục đích đánh giá ảnh hưởng của một yếu tố can thiệp. Trong nhiều trường hợp, nhà nghiên cứu muốn đánh giá ảnh hưởng của hai yếu tố can thiệp, và các phương án trên không thể ứng dụng được. Chẳng hạn như khi nhà nghiên cứu muốn phân tích ảnh hưởng của ánh sáng (cao hay thấp) và độ ẩm (khô hay ướt) đến sự tăng trưởng của cây giống trong một nhà kính (greenhouse), thì các phương án thí nghiệm với hai yếu tố cần phải được xem xét cẩn thận.

Phương án 1 - CRD. Chúng ta muốn điều tra ảnh hưởng của nhiệt độ (thấp và cao), vật liệu (A và B), và phương pháp sản xuất (cơ khí và hóa chất) đến độ mạnh của giấy. Các phối hợp yếu tố can thiệp có thể như sau:

NHÓM CÁN THIỆP	NHIỆT ĐỘ	VẬT LIỆU	PHƯƠNG PHÁP
1	Thấp	A	Cơ khí
2	Cao	A	Cơ khí
3	Thấp	B	Cơ khí
4	Thấp	A	Hóa chất

Qua thiết kế này, chúng ta có thể phân tích ảnh hưởng của nhiệt độ bằng cách so sánh độ mạnh giữa nhóm 1 và 2. Ảnh hưởng của vật liệu có thể so sánh giữa nhóm 1 và 3. Ảnh hưởng của phương pháp có thể so sánh giữa nhóm 1 và 4.

Những so sánh trên hợp lí chỉ với điều kiện là ảnh hưởng của các yếu tố can thiệp là **cộng hưởng** (additive effect). Nói cách khác, các so sánh trên chỉ hợp lí nếu ảnh hưởng của một yếu tố không phụ thuộc vào các yếu tố khác, chẳng hạn như ảnh hưởng của nhiệt độ không tùy thuộc vào ảnh hưởng của vật liệu hay phương pháp. Nếu giả định này không đúng thì kết quả so sánh có thể thiếu khách quan và sai.

Phương án 2 – Giai thừa (factorial design). Một phương án khác cho nhiều thông tin hơn phương án trên và cho phép chúng ta phân tích ảnh hưởng tương tác của các yếu tố can thiệp là **factorial design**. Trong trường hợp trên, chúng ta có 3 yếu tố can thiệp, và mỗi yếu tố có 2 bậc, cho nên tổng số là $2^3 = 8$ nhóm như sau:

NHÓM CAN THIỆP	NHIỆT ĐỘ	VẬT LIỆU	PHƯƠNG PHÁP
1	Thấp	A	Cơ khí
2	Cao	A	Cơ khí
3	Thấp	B	Cơ khí
4	Cao	B	Cơ khí
5	Thấp	A	Hóa chất
6	Cao	A	Hóa chất
7	Thấp	B	Hóa chất
8	Cao	B	Hóa chất

Với phương án “cân đối” này, chúng ta có thể ước tính ảnh hưởng của mỗi yếu tố can thiệp dễ dàng:

- Ảnh hưởng của nhiệt độ: so sánh nhóm 1, 3, 5, 7 và 2, 4, 6, 8;
- Ảnh hưởng của vật liệu: so sánh nhóm 1, 2, 5, 6 và 3, 4, 7, 8;
- Ảnh hưởng của phương pháp: so sánh nhóm 1, 2, 3, 4 và 5, 6, 7, 8.

Ngoài ra, **ảnh hưởng tương tác (interaction effects)** cũng có thể ước tính bằng cách so sánh tổng hợp giữa các nhóm. Chẳng hạn như để biết ảnh hưởng của nhiệt độ có tùy thuộc vào phương pháp sản xuất hay không, chúng ta có thể so sánh giữa nhóm 1+3 và 2+4, và 5+7 với 6+8.

Phương án 3 – Phân mẫu (Split-plot design). Để điều tra ảnh hưởng của 3 loại giống đậu nành (A, B và C) và hai loại phân bón (P1 và P2), các nhà

nghiên cứu so sánh sản lượng đậu nành được trồng trọt dưới 6 điều kiện can thiệp trên. Nếu mỗi điều kiện can thiệp được lặp lại 2 lần, thì nghiên cứu cần $2 \times 6 = 12$ mảnh đất (plot) cho nghiên cứu.

Một cách thiết kế cho nghiên cứu trên là phương án giai thừa như để cập phần trên, nhưng phương án này có thể khó khăn trong thực tế. Một phương án khác dễ dàng hơn và thực tế hơn là phương án phân mẫu. Phương án này cần đến hai lần sắp xếp ngẫu nhiên. Trước hết, hai loại phân bón được phân chia một cách ngẫu nhiên cho 4 nhóm như sau:

1	2	3	4
P1	P2	P2	P1

Bước hai, ba loại giống sẽ được phân ngẫu nhiên cho từng nhóm, và kết quả có thể giống như sau:

1 P1	2 P2	3 P2	4 P1
B	C	A	C
A	B	C	A
C	A	B	B

Phương án 4 – Hình vuông Latin (Latin square). Công ti dầu muốn so sánh hiệu suất (đo bằng cây số - km - trên mỗi lít) của 4 loại dầu (A, B, C và D). Công ti có được 4 tài xế và 4 loại xe. Vì độ dao động hay khác biệt giữa người lái xe và loại xe, hai yếu tố này phải được kiểm soát trong khi thiết kế nghiên cứu. Phương án tốt nhất cho nghiên cứu này là phương án hình vuông Latin. Theo phương án này, 4 loại dầu được phân chia một cách ngẫu nhiên cho từng tài xế và loại xe như sau:

TÀI XẾ	LOẠI XE			
	FORD	TOYOTA	HONDA	NISSAN
1	D	B	C	A
2	B	C	A	D
3	C	A	D	B
4	A	D	B	C

Như vậy, tài xế 1 sẽ điều khiển xe Ford với dầu loại D, sau đó là Toyota với loại dầu B, Honda với dầu C và Nissan với dầu A, v.v... Với phương án này, công ti có thể phân tích ảnh hưởng cộng hưởng của từng loại dầu, hay phân tích ảnh hưởng tương tác giữa loại dầu và loại xe, hay giữa loại dầu và tài xế. Cách phân tích số liệu từ phương án hình vuông Latin đã được mô tả chi tiết ở Chương 11 (11.7).

20.7 Phương pháp ngẫu nhiên hóa

Trong tất cả các phương án trên, một khía cạnh then chốt là sắp xếp các đối tượng nghiên cứu vào các yếu tố can thiệp một cách ngẫu nhiên (tôi sẽ gọi tắt là *ngẫu nhiên hóa* – randomize). Giả dụ, chúng ta có 8 đối tượng (có thể là bệnh nhân) cần phân chia cho ba nhóm can thiệp T1, T2 và T3. Nếu theo yêu cầu, nhóm T1 và T3 mỗi nhóm cần phải có 3 đối tượng và nhóm T2 cần 2 đối tượng:

T1	T2	T3
n=3	n=2	n=3

Vấn đề đặt ra là làm cách nào để ngẫu nhiên hóa? Chúng ta có thể làm một số bước như sau:

- Trước hết, chúng ta lập danh sách 8 đối tượng:
T1 T1 T1 T2 T2 T3 T3 T3
- Dùng hàm `sample` để chọn ngẫu nhiên (`sample(1:8)` có chức năng tạo ra một dãy số ngẫu nhiên từ 1 đến 8):

```
> sample(1:8)
[1] 7 2 5 4 1 8 6 3
```

- Nhập hai dãy số với nhau, chúng ta có:

```
T1    T1    T1    T2    T2    T3    T3    T3
7    2    5    4    1    8    6    3
```

Nói cách khác, đối tượng số 7, 2 và 5 sẽ nhận can thiệp T1, đối tượng 4, 1 nhận can thiệp T2, và đối tượng 8, 6 và 3 nhận T3.

* * *

Bất cứ công trình nghiên cứu khoa học nào cũng được tiến hành theo một qui trình gần như bất biến: đặt giả thiết, thiết kế nghiên cứu, thu thập dữ liệu, phân tích dữ liệu, và báo cáo kết quả. Do đó, phân tích số liệu là khâu gần cuối cùng của một công trình nghiên cứu (trước khi diễn dịch kết quả phân tích và viết báo cáo khoa học). Các khâu trong qui trình nghiên cứu trên có liên hệ khăng khít với nhau. Nếu một khâu trong qui trình đó có vấn đề thì hệ quả là khâu tiếp theo cũng có vấn đề. Mượn cách nói của người xưa “Vạn sự khởi đầu nan”, cũng có thể nói rằng khi thiết kế nghiên cứu sai thì kết quả phân tích cũng không có ý nghĩa gì. Tất cả các phương pháp phân tích số liệu chỉ cho ra kết quả tốt khi công trình nghiên cứu được thiết kế đúng và thích hợp. Do đó, xem xét cẩn thận các phương án nghiên cứu và đối chiếu với tình hình thực tế là một nhu cầu rất quan trọng cho nghiên cứu khoa học.

21

Ước tính cỡ mẫu

Mỗi nghiên cứu khoa học có liên quan đến quần thể và cỡ mẫu đều cần phải có ước tính số đối tượng cần thiết. Hai chữ “đối tượng” ở đây cần phải hiểu theo nghĩa rộng: với nghiên cứu lâm sàng, đối tượng có thể là bệnh nhân; với nghiên cứu mang tính điều tra xã hội, đối tượng có thể là cá nhân trong cộng đồng; với nghiên cứu trên động vật, đối tượng có thể là chuột. Mục tiêu của việc ước tính cỡ mẫu là ước tính số lượng đối tượng cần thiết (không quá thấp và cũng không quá cao) để kiểm định một hay nhiều giả thuyết khoa học. Số lượng đối tượng có liên quan đến đạo đức khoa học, qui mô nghiên cứu và chi phí, nên việc ước tính cỡ mẫu cần phải được xem xét và cân nhắc rất cẩn thận.

21.1 Thông tin cần thiết cho ước tính cỡ mẫu

Những yếu tố cần phải xem xét và cân nhắc trong ước tính cỡ mẫu là mô hình nghiên cứu, biến số phân tích, mức độ ảnh hưởng, và mức độ sai sót trong kiểm định giả thuyết. Nhà nghiên cứu cần phải có những thông tin này trước khi ước tính cỡ mẫu. Không có những thông tin trên thì không thể ước tính cỡ mẫu. Dưới đây là vài giải thích ngắn về 4 thông tin trên.

21.1.1. Mô hình nghiên cứu

Trong nghiên cứu y khoa, người ta phân biệt các mô hình nghiên cứu theo thời gian như sau:

Nghiên cứu cắt ngang (cross-sectional study) là mô hình nghiên cứu thường có mục tiêu ước tính một tỉ lệ hiện hành (prevalence) của bệnh ngay

tại thời điểm thực hiện nghiên cứu. Ví dụ như nhà nghiên cứu muốn ước tính số người mắc bệnh xương khớp trong quần thể, nhà nghiên cứu có thể lấy mẫu gồm n cá nhân, và làm xét nghiệm để xác định có mắc bệnh hay không. Tỷ lệ mắc bệnh có thể ước tính từ xét nghiệm ngay tại thời điểm đó.

Nghiên cứu bệnh chứng (case-control study) là nghiên cứu ngược thời gian để đánh giá mối liên quan giữa một yếu tố nguy cơ và bệnh. Thông thường, nhà nghiên cứu chọn một nhóm bệnh nhân và một nhóm chứng, và thu thập thông tin về yếu tố nguy cơ *trong quá khứ* của mỗi cá nhân.

Nghiên cứu đoàn hệ (prospective study, có khi còn gọi là longitudinal study) là nghiên cứu thường có mục tiêu tìm hiểu yếu tố nguy cơ có ảnh hưởng đến nguy cơ mắc bệnh. Chẳng hạn như để đánh giá mối liên quan giữa tỉ trọng cơ thể (body mass index - BMI) và tử vong, nhà nghiên cứu có thể lấy mẫu n cá nhân, đo BMI lúc ban đầu, và sau đó theo dõi trong vòng [ví dụ như] 5 năm để biết bao nhiêu người sống và tử vong. Mối liên quan giữa BMI lúc ban đầu và nguy cơ tử vong có thể phân tích từ dữ liệu theo thời gian như thế. Nghiên cứu lâm sàng RCT (randomized controlled trials) có thể xem là một mô hình nghiên cứu đoàn hệ.

21.1.2. Biến số kết quả

Một nghiên cứu định lượng thường có một biến số chính, hay gọi là *outcome* hay *biến kết quả*. Biến kết quả có thể là biến liên tục (như huyết áp, nồng độ glucose, mật độ xương, v.v.) hoặc biến nhị phân (như sống/chết, bệnh/không bệnh). Phân biệt biến kết quả rất quan trọng vì sự phân biệt này xác định phương pháp ước tính cỡ mẫu.

21.1.3. Mức độ ảnh hưởng

Đây là một thông tin rất quan trọng cho ước tính cỡ mẫu. Không có thông tin này thì không thể nào ước tính cỡ mẫu. Trong thực tế, mức độ ảnh hưởng (còn gọi là *effect size* - SE) tùy thuộc vào mô hình nghiên cứu. Dưới đây là vài mô tả về cách xác định thông tin về mức độ ảnh hưởng đơn giản:

- Nếu là nghiên cứu cắt ngang, và mục tiêu là ước tính một tỉ lệ hiện hành (prevalence rate). Nhưng vì tỉ lệ có thể dao động giữa các mẫu nghiên cứu, nên một tham số khác cần phải xem xét đến: đó là sai số (gọi là *margin of error*). Giả dụ rằng chúng ta biết rằng tỉ lệ là p và sai số là e , thì $ES = p / e$.

- Nếu là nghiên cứu cắt ngang, và mục tiêu là ước tính một tham số liên tục. Chẳng hạn như để ước tính mật độ xương trong quần thể, nhà nghiên cứu có thể lấy mẫu n cá nhân, và đo mật độ xương. Trị số trung bình của mẫu là một ước số cho giá trị trung bình của quần thể. Do đó, trị số trung bình mẫu m vẫn chịu sự dao động ngẫu nhiên giữa các mẫu, và sai số để mô tả là *sai số e*. Trong trường hợp này, $ES = m / e$.
- Nếu là nghiên cứu có mục tiêu so sánh giữa hai nhóm, và trong trường hợp này nghiên cứu phải có hai tham số về trung bình (T_1 và T_2) và tham số về độ lệch chuẩn (S_1 và S_2), ES được định nghĩa là hiệu số giữa T_1 và T_2 chia cho S :

$$ES = \frac{T_1 - T_2}{\sqrt{S_1^2 + S_2^2}}$$

Nếu biến kết quả là biến liên tục, nghiên cứu sẽ có hai số trung bình m_1 và m_2 , và trong trường hợp này, $ES = (m_1 - m_2) / \sqrt{S_1^2 + S_2^2}$

Nếu biến kết quả là biến nhị phân, nghiên cứu sẽ có hai tỉ lệ p_1 và p_2 , và trong trường hợp này, ES có thể ước tính bằng hiệu số $ES = \arcsin(p_1) - \arcsin(p_2)$.

21.1.4. Mức độ sai sót trong kiểm định giả thuyết

Đứng trên quan điểm phương pháp luận, mỗi nghiên cứu thường có mục đích kiểm định một giả thuyết khoa học chính. Trong thống kê, người ta phân biệt 2 loại giả thuyết: giả thuyết vô hiệu (*null hypothesis*, thường kí hiệu là H_0) và giả thuyết đảo (*alternative hypothesis*, kí hiệu H_A). Giả thuyết vô hiệu, như tên gọi, phát biểu ngược lại với những gì nhà nghiên cứu muốn biết. Nếu giả thuyết đảo (hay giả thuyết chính) là bệnh nhân nhóm A có nguy cơ biến chứng cao hơn bệnh nhân nhóm B, thì giả thuyết vô hiệu sẽ phát biểu là “bệnh nhân nhóm A có nguy cơ biến chứng cao hơn bệnh nhân nhóm B”. Tương tự, nếu giả thuyết chính phát biểu rằng có mối tương quan giữa X và Y, thì giả thuyết vô hiệu phát biểu rằng không có mối tương quan giữa X và Y.

Ví dụ như, nếu nhà nghiên cứu muốn xác định hiệu quả của thuốc chống loãng xương, và quyết định tiến hành một nghiên cứu theo mô hình RCT, với hai nhóm bệnh nhân: Một nhóm được điều trị bằng thuốc và một nhóm chứng, cả hai nhóm được theo dõi 3 năm. Biến kết quả là tỉ lệ gãy xương trong thời gian theo dõi. Gọi tỉ lệ gãy xương của hai nhóm là p_1 và p_2 , giả thuyết vô hiệu (kí hiệu H_0) là:

$$H_0: p_1 = p_2$$

Và giả thuyết chính có thể là:

$$H_A: p_1 \neq p_2$$

Nên nhớ rằng, nhà nghiên cứu không thể chứng minh H_0 ; nhà nghiên cứu chỉ có thể bác bỏ H_0 và do đó gián tiếp chấp nhận H_A . Cơ sở để bác bỏ hay chấp nhận một giả thuyết là chỉ số thống kê (như t test, K bình phương, hồi qui tuyến tính, v.v.). Kết quả kiểm định thống kê có thể “có ý nghĩa thống kê” (*statistical significance*) hay không có ý nghĩa thống kê (*statistical insignificance*). Do đó, mỗi kiểm định giả thuyết, nhà nghiên cứu phải đối phó với 4 tình huống (xem bảng):

Bảng 1: Kết quả kiểm định thống kê và giả thuyết vô hiệu

KẾT QUẢ KIỂM ĐỊNH THỐNG KÊ	GIẢ THUYẾT H_0 ĐÚNG	GIẢ THUYẾT H_0 SAI
Có ý nghĩa (tức bác bỏ H_0)	Sai sót loại I (type I error, α)	Đúng
Không có ý nghĩa (chấp nhận H_0)	Đúng	Sai sót loại II (type II error, β)

- Kết quả kiểm định “có ý nghĩa thống kê”, và giả thuyết H_0 là đúng, nhà nghiên cứu kết luận sai, và sai sót này tạm gọi là sai sót loại I (*type I error*, hay *alpha*);
- Kết quả kiểm định “có ý nghĩa thống kê”, và giả thuyết H_0 là sai, nhà nghiên cứu kết luận đúng;
- Kết quả kiểm định “không có ý nghĩa thống kê”, và giả thuyết H_0 là đúng, nhà nghiên cứu kết luận đúng;
- Kết quả kiểm định “không có ý nghĩa thống kê”, và giả thuyết H_0 là sai, nhà nghiên cứu kết luận sai, và sai sót này tạm gọi là sai sót loại II (*type II error*, hay *beta*).

Nhà nghiên cứu phải xác định mức độ sai sót loại I và loại II trước khi ước tính cỡ mẫu. Thông thường, α được xác định ở mức 0.05 hay 0.01, còn đối với β , các nhà nghiên cứu thường chấp nhận sai sót 0.20 hay 0.10. Cần nói thêm rằng, $1 - \beta$ còn được đề cập đến là *power*. *Power* của một nghiên cứu là độ nhạy của nghiên cứu đó (cũng tương tự như độ nhạy hay *sensitivity* của một xét nghiệm chẩn đoán). Cần nhắc lại rằng, độ nhạy của một xét nghiệm có nghĩa là xác suất mà một cá nhân mắc bệnh có kết quả dương tính. Do đó, *power* của nghiên cứu là xác suất mà nghiên cứu cho ra kết quả có ý nghĩa thống kê nếu giả thuyết H_A đúng (H_0 sai).

Mỗi sai sót α và β đi kèm theo một hằng số của phân bố chuẩn (z), và hằng số này được sử dụng trong tính toán cỡ mẫu. Chẳng hạn như (trong trường hợp kiểm định 2 chiều) nếu $\alpha = 0.05$ thì $z = 1.96$, nếu $\alpha = 0.01$ thì $z = 2.56$. Sau đây là vài hằng số phổ biến:

Bảng 2: Hằng số z liên quan đến sai sót loại I và loại II

HÀNG SỐ Z LIÊN QUAN ĐẾN α (KIỂM ĐỊNH 2 CHIỀU)	HÀNG SỐ Z LIÊN QUAN ĐẾN β
$\alpha = 0.01, z = 2.576$	$\beta = 0.01, z = 2.326$
$\alpha = 0.05, z = 1.960$	$\beta = 0.05, z = 1.645$
$\alpha = 0.10, z = 1.645$	$\beta = 0.10, z = 1.282$
$\alpha = 0.20, z = 1.282$	$\beta = 0.20, z = 0.842$

Chú thích: có thể tính bằng hàm $qnorm(x/2)$, trong đó $x = 0.01, 0.05, 0.10, v.v.$

21.2 Ước tính cỡ mẫu bằng R

Phần lớn các phương pháp ước tính cỡ mẫu có thể tóm gọn trong công thức sau:

$$n = \frac{kC(\alpha, \beta)}{(ES)^2}$$

Trong đó, k là hằng số cố định, $C(\alpha, \beta)$ là hằng số z liên quan đến sai sót loại I và sai sót loại II như sau:

Sai số α	Sai số $\beta = 0.10$	Sai số $\beta = 0.20$
0.05	$C = 13.0$	$C = 7.85$
0.01	$C = 17.8$	$C = 11.7$

Trong công thức trên, vì ES là mẫu số, nên nếu ES thấp thì n sẽ tăng, và nếu ES cao thì n sẽ giảm. Tất cả các phương pháp ước tính cỡ mẫu qua công thức trên có thể triển khai trong R một cách dễ dàng. Tuy nhiên, trong R có một số package (như **samplesize**, **pwr**, **epicalc**) có thể sử dụng cho ước tính cỡ mẫu, và người sử dụng chỉ cần gõ lệnh và cung cấp những thông tin vừa mô tả. Phần dưới đây, tôi sẽ minh họa một số trường hợp ước tính cỡ mẫu cho từng mô hình nghiên cứu và biến kết quả. Mỗi trường hợp sẽ được bắt đầu bằng vài điểm chính về lý thuyết và minh họa bằng một ví dụ cụ thể.

21.2.1. Cỡ mẫu để ước tính một tỉ lệ

Lý thuyết: Nhiều nghiên cứu có mục đích đơn giản là ước tính tỉ lệ. Chẳng hạn như các cuộc điều tra xã hội muốn biết bao nhiêu người thích hay không thích một đảng phái chính trị hay một món hàng, hoặc nghiên cứu y tế công cộng có mục đích ước tính tỉ lệ hiện hành (prevalence) của một bệnh.

Gọi π là tỉ lệ trong quần thể (population) mà chúng ta không biết, nhưng muốn ước tính dựa trên một mẫu nghiên cứu (sample). Gọi p là tỉ lệ có thể tính từ mẫu nghiên cứu gồm n đối tượng. Với giá trị p và n chúng ta có thể ước tính khoảng tin cậy $(1-\alpha)\%$ của π dao động trong khoảng $(p - z_{\alpha/2}e) < \pi < (p + z_{\alpha/2}e)$, trong đó $e = \sqrt{p(1-p)/n}$ là sai số mẫu - margin of error. Trong thực tế, e chính là sai số chuẩn [standard error] của p . Do đó, phát biểu ngược lại, số cỡ mẫu n cần thiết cho nghiên cứu phụ thuộc vào α , e và giá trị p như sau:

$$n = \left(\frac{z_{\alpha/2}}{e} \right)^2 p(1-p) \quad [1]$$

Ví dụ 1: Nhà nghiên cứu muốn ước tính cỡ mẫu cho một nghiên cứu có mục tiêu chính là xác định tỉ lệ bệnh tiểu đường. Theo y văn, tỉ lệ bệnh tiểu đường trong cộng đồng người trung niên là 10%. Nói cách khác, $p = 0.10$. Nhà nghiên cứu muốn ước tính số đối tượng cần thiết để ước tính tỉ lệ đó, và chấp nhận xác suất 95% là tỉ lệ có thể dao động trong khoảng 8% đến 12%. Nói cách khác $e = (0.12 - 0.08) / 4 = 0.01$, tức sai số là 1%.

Chúng ta có thể dùng công thức [1] để ước tính; trong đó, $z_{\alpha/2} = 1.96$ (xem bảng 2), $p = 0.10$, và $e = 0.01$. Chúng ta có thể tính thủ công với R:

```
alpha=0.05; z = qnorm(0.05/2)
p=0.10; e = 0.01
n = (z/e)^2*p*(1-p)
```

Hoặc dùng hàm **n.for.survey** trong **epicalc** như sau. Chú ý nếu chưa có epicalc trong R, cần phải cài đặt trước với lệnh **install.packages("epicalc")**. Trong epicalc, sai số e được gọi là delta.

```
library(epicalc)
n = n.for.survey(p=0.10, delta=0.01, alpha=0.05)
```

Kết quả cho thấy $n = 3457$. Nói cách khác, nhà nghiên cứu cần tuyển ngẫu nhiên 3457 đối tượng cho công trình nghiên cứu.

Cách tính trên dành cho trường hợp dân số vô hạn (infinite). Trong trường hợp nhà nghiên cứu biết rằng một cộng đồng có dân số N , ví dụ như 100,000 người, thì cách tính có thay đổi:

```
n = n.for.survey(p=0.10, delta=0.01, alpha=0.05,
popsiz=100000)
```

Kết quả cho thấy $n = 3342$. Dĩ nhiên, thay đổi δ (tức e) sẽ thay đổi số cỡ mẫu khá lớn. Chẳng hạn như nếu nhà nghiên cứu chấp nhận sai số 2% ($\delta=0.02$) thì số cỡ mẫu bây giờ là $n = 857$ người.

21.2.2. Cỡ mẫu để ước tính số trung bình quần thể

Lí thuyết: Chúng ta muốn ước tính giá trị trung bình μ của một biến trong quần thể (không biết). Tuy nhiên, chúng ta biết rằng độ lệch chuẩn của biến là σ . Với một mẫu gồm n đối tượng, chúng ta có thể ước tính giá trị trung bình mẫu m , và theo lí thuyết thống kê, giá trị trung bình quần thể sẽ nằm trong khoảng $m \pm z_{\alpha/2}(\sigma/\sqrt{n})$ với khoảng tin cậy $(1 - \alpha)\%$. Gọi $z_{\alpha/2}(\sigma/\sqrt{n})$ là sai số e , giải phương trình trên để tính n , chúng ta có công thức ước tính cỡ mẫu đơn giản:

$$n = \left(\frac{z_{\alpha/2} \sigma}{e} \right)^2 \quad [2]$$

Ví dụ 2: Chúng ta muốn ước tính tuổi bị ung thư vú, và muốn làm một nghiên cứu cắt ngang. Thông tin mà chúng ta có là độ lệch chuẩn của độ tuổi ung thư là 12 tuổi, và chúng ta muốn ước tính độ tuổi ung thư chính xác trong khoảng ± 2.5 tuổi (tức độ rộng của khoảng tin cậy 95% là 5 tuổi). Nói theo ngôn ngữ thống kê của công thức [2], chúng ta có: $e = 2.5$ và $\sigma = 12$.

Dùng R:

```
alpha=0.05; z = qnorm(0.05/2)
sigma=12; e = 2.5
n = (z/e*sigma)^2 ; n
```

Kết quả là chúng ta cần $n = 88$ đối tượng cho công trình nghiên cứu.

21.2.3. Cỡ mẫu để so sánh 2 tỉ lệ

Lí thuyết: Trong trường hợp hai tỉ lệ π_1 và π_2 , tham số mà chúng ta quan tâm là hiệu số $\delta = \pi_1 - \pi_2$. Để kiểm định giả thuyết vô hiệu $\pi_1 = \pi_2$, chúng ta sẽ ước tính 2 tỉ lệ p_1 và p_2 từ mẫu nghiên cứu n_1 và n_2 đối tượng. Kiểm định z cho 2 tỉ lệ là:

$$Z = (p_1 - p_2) / SD$$

Trong đó, SD là độ lệch chuẩn của hiệu số:

$$SD = \sqrt{\bar{p}(1-\bar{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}$$

và $\bar{p}$ là tỉ lệ trung bình, tức $\bar{p} = (p_1 + p_2) / 2$.

Giả định rằng, cỡ mẫu hai nhóm tương đương nhau và gọi chung là n , giải 2 phương trình trên, chúng ta sẽ có công thức ước tính cỡ mẫu (1):

$$n = \frac{2\bar{p}(1-\bar{p})(z_{\alpha/2} + z_{\beta})^2}{(p_1 - p_2)^2} \quad [3]$$

Ví dụ 3: Một nghiên cứu lâm sàng có mục tiêu đánh giá hiệu quả của một thuốc điều trị bệnh ung thư vú. Mô hình nghiên cứu là RCT, nhà nghiên cứu chia bệnh nhân thành 2 nhóm: nhóm dùng thuốc hiện hành (nhóm 1) và nhóm dùng thuốc mới (nhóm 2). Biến kết quả là tỉ lệ sống sót sau 5 năm. Sau khi duyệt qua y văn, nhà nghiên cứu biết rằng tỉ lệ sống sót của nhóm 1 là $p_1 = 75\%$, và giả thuyết rằng thuốc mới sẽ tăng cải tiến tỉ lệ sống sót 20%, tức $p_2 = 90\%$ (lấy 75×1.2). Nhà nghiên cứu muốn ước tính cỡ mẫu sao cho nghiên cứu có xác suất 90% để “phát hiện” mức độ ảnh hưởng đó với xác suất sai sót loại I là 5%.

Sử dụng công thức [3] cho ví dụ trên, chúng ta có $p_1 = 0.75$; $p_2 = 0.90$; $z_{\alpha/2} = 1.96$; $z_{\beta} = 1.282$. Chúng ta có thể dùng hàm **n.for.2p** trong **epicalc** để ước tính cỡ mẫu:

```
library(epicalc)
n = n.for.2p(p1=0.75, p2=0.90, power=0.9,
alpha=0.05, ratio=1)
```

Kết quả cho thấy $n = 292$ bệnh nhân (146 cho nhóm 1 và 146 cho nhóm 2). Chú ý trong hàm trên, power là $1 - \beta = 1 - 0.10 = 0.90$. Tham số ratio = 1 có nghĩa là số cỡ mẫu của nhóm 1 bằng số cỡ mẫu của nhóm 2. Nếu chúng ta muốn số cỡ mẫu nhóm 2 hơn nhóm 1 gấp 2 lần thì ratio = 2.

21.2.4. Cỡ mẫu để so sánh 2 số trung bình

Lí thuyết: Đối với nghiên cứu so sánh hai nhóm độc lập với biến kết quả là biến liên tục, tham số quan tâm là hiệu số của hai số trung bình quần thể π_1 và π_2 , tức $\delta = \pi_1 - \pi_2$. Giả thuyết đặt ra là:

$$H_0: \pi_1 = \pi_2 \text{ hay } \delta = 0$$

$$H_A: \pi_1 \neq \pi_2 \text{ hay } \delta \neq 0$$

Dĩ nhiên, chúng ta không biết π_1 và π_2 , mà chỉ có thể ước tính hai số trung bình m_1 và m_2 qua mẫu n_1 và n_2 đối tượng. Phương pháp căn bản để kiểm định giả thuyết là t-test. Gọi m_1 và m_2 là số trung bình mẫu của hai nhóm, s_1 và s_2 là độ lệch chuẩn, và n_1 và n_2 là số đối tượng cho hai nhóm so sánh, kiểm định t được định nghĩa là hiệu số của hai số trung bình chia cho độ lệch chuẩn của hiệu số:

$$t = \frac{m_1 - m_2}{SD(m_1 - m_2)}$$

Trong đó,

$$s = SD(m_1 - m_2) = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Giả dụ rằng cỡ mẫu của hai nhóm bằng nhau $n_1 = n_2$ và gọi chung là $n = n_1 = n_2$. Vấn đề là tìm n sao cho giá trị của t có nghĩa thống kê, tức sao cho trị số P của t thấp hơn α . Giải phương trình trên, chúng ta có (1):

$$n = \frac{2s^2(z_{\alpha/2} + z_\beta)^2}{(m_1 - m_2)^2} \quad [4]$$

Nhớ rằng mức độ ảnh hưởng ES là:

$$ES = \frac{(m_1 - m_2)}{s}$$

Do đó, công thức [4] cũng có thể viết lại đơn giản hơn:

$$n = \frac{2(z_{\alpha/2} + z_\beta)^2}{(ES)^2} \quad [5]$$

Nếu $\alpha = 0.05$ và $\beta = 0.20$ (tức power bằng 0.8), thì công thức trên còn đơn giản hơn:

$$n = \frac{16}{(ES)^2} \quad [6]$$

Ví dụ 4: Để đánh giá hiệu quả của thuốc chống loãng xương, nhà nghiên cứu thiết kế một nghiên cứu lâm sàng gồm 2 nhóm bệnh nhân: Nhóm 1 được điều trị bằng thuốc mới, nhóm 2 là nhóm chứng (placebo). Biến kết quả là mật độ xương hay BMD (tính bằng g/cm²). Qua nghiên cứu sơ khởi, nhà nghiên cứu biết rằng BMD trung bình ở phụ nữ sau mãn kinh là $m_1 = 0.80$ g/cm² và độ lệch chuẩn là $s = 0.12$ g/cm². Qua y văn, nhà nghiên cứu biết rằng thuốc có thể tăng BMD 5% sau 1 năm điều trị. Do đó, có thể nói mục tiêu là BMD trung bình của nhóm điều trị là $m_2 = 0.8 \times 1.05 = 0.84$. Giả dụ rằng độ lệch chuẩn của nhóm 2 cũng là 0.12 g/cm². Nói cách khác, độ ảnh hưởng ES là: $ES = (0.84 - 0.80) / 0.12 = 0.33$. Nhà nghiên cứu muốn có power là 80% và sai sót loại I là 5%. Công thức ước tính cỡ mẫu cho trường hợp này là:

$$n = \frac{2s^2 (z_{\alpha/2} + z_{\beta})^2}{(m_1 - m_2)^2}$$

Chúng ta có thể dùng hàm **n.for.2means** trong **epicalc** để ước tính cỡ mẫu:

```
library(epicalc)
n = n.for.2means(mu1=0.80, mu2=0.84, sd1=0.12,
sd2=0.12, power=0.9, alpha=0.05, ratio=1)
```

Trong hàm trên **mu1** và **mu2** là chỉ số trung bình của hai nhóm, **sd1** và **sd2** là độ lệch chuẩn của hai nhóm, và giả dụ rằng cỡ mẫu nhóm 1 bằng nhóm 2 (ratio = 1).

Kết quả cho thấy nhà nghiên cứu cần tuyển $n = 284$ bệnh nhân (142 cho mỗi nhóm) cho công trình nghiên cứu.

21.2.5. Cỡ mẫu so sánh hai xác suất sống sót (survival curves)

Lí thuyết: Đối với nghiên cứu so sánh hai nhóm độc lập với biến kết quả là biến thời gian sống sót (survival time), cách ước tính cỡ mẫu còn tùy thuộc vào số biến cố xảy ra. Do đó, có hai ước tính: số biến cố xảy ra cần quan sát và số đối tượng (bệnh nhân). Trong phân tích sống còn, chỉ số quan trọng nhất là hazard ratio (HR, tức tỉ số rủi ro). HR là tỉ số của hai *xác suất biến cố xảy ra* tại một thời điểm (kí hiệu là λ_1 và λ_2 cho 2 nhóm so sánh):

$$HR = \frac{\lambda_1}{\lambda_2}$$

Nếu giả định rằng (và trong thực tế cũng phù hợp cho nhiều trường hợp) xác suất sống còn tuân theo luật phân bố mũ (exponential distribution), mối liên quan giữa λ và tỉ lệ sống sót π tại thời điểm T và trung vị thời gian sống còn M có thể tóm tắt:

$$\lambda = \frac{-\log \pi_T}{T} = \frac{-\log 0.5}{M}$$

Nhưng trong thực tế, rất khó có được λ_1 và λ_2 , nên HR thường được ước tính dựa vào *xác suất sống sót* (kí hiệu π_1 và π_2):

$$HR = \frac{\log \pi_1}{\log \pi_2}$$

Dĩ nhiên, qua công thức trên, chúng ta có thể phát biểu rằng: $\pi_2 = \exp(HR \times \log \pi_1)$.

Trong nhiều trường hợp, chúng ta có thể nghĩ đến số trung vị thời gian sống sót (median survival time) M_1 và M_2 cho hai nhóm, và HR có thể định nghĩa là:

$$HR = \frac{M_1}{M_2}$$

Với những lí giải trên, và nếu chúng ta giả định rằng số bệnh nhân nhóm 1 và nhóm 2 theo tỉ lệ $1/r$, thì số biến cố cần quan sát cho nhóm 1 (với sai sót α và β) là (2):

$$e_1 = \frac{(z_{\alpha/2} + z_{\beta})^2}{(1+r)r} \left(\frac{1+rHR}{1-HR} \right)^2 \quad [7]$$

và số biến cố cần quan sát cho nhóm 2: $e_2 = re_1$.

Tương tự, chúng ta có thể tính số bệnh nhân cho nhóm 1 là:

$$n_1 = \frac{1}{r} \left[\frac{(z_{\alpha/2} + z_{\beta})^2}{(1-\pi_1) + r(1-\pi_2)} \right] \left(\frac{1+rHR}{1-HR} \right)^2 \quad [8]$$

và số bệnh nhân cho nhóm 2: $n_2 = rn_1$.

Bảng 3: Số biến cố cần quan sát để so sánh hai hàm số sống còn với $\alpha = 0.05$ và $\beta = 0.20$. Kết quả chỉ tính cho nhóm 1 (e_1). Nhóm 2 là $e_2 = r^*e_1$

π_2	π_1									
	0.05	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45	0.50
0.10	230									
0.15	78	422								
0.20	44	126	584							
0.25	30	64	163	708						
0.30	22	40	79	189	793					
0.35	17	29	48	89	206	839				
0.40	14	22	33	53	95	214	851			
0.45	12	17	24	35	55	96	213	832		
0.50	11	14	19	25	36	55	94	205	787	
0.55	9	12	15	19	25	35	53	89	191	721
0.60	8	10	12	15	19	25	33	49	82	172
0.65	8	9	10	12	15	18	23	31	44	73
0.70	7	8	9	10	12	14	17	21	27	39
0.75	6	7	8	9	10	11	13	15	18	23
0.80	6	6	7	7	8	9	10	11	13	15
0.85	5	6	6	6	7	7	8	9	9	11
0.90	5	5	5	6	6	6	6	7	7	8
0.95	5	5	5	5	5	5	5	5	6	6

π_2	π_1									
	0.50	0.55	0.60	0.65	0.70	0.75	0.80	0.85	0.90	0.95
0.55	721									
0.60	172	638								
0.65	73	149	544							
0.70	39	62	125	444						
0.75	23	32	51	99	343					
0.80	15	19	26	39	74	246				
0.85	11	12	15	20	29	51	159			
0.90	8	9	10	11	14	19	31	87		
0.95	6	6	6	7	8	9	11	15	33	

Ví dụ 5: Một nghiên cứu lâm sàng theo mô hình RCT nhằm mục đích đánh giá hiệu quả của levamisole (một loại thuốc điều trị ung thư ruột) so với nhóm chứng (placebo). Qua y văn, biết rằng tỉ lệ sống sót trong vòng 1 năm của nhóm chứng là 50%, và hi vọng rằng nhóm được điều trị là 60%. Số biến cố cần quan sát để đạt $\alpha = 0.05$ và $\beta = 0.20$ là 172 cho nhóm 1 và 172 cho nhóm 2.

Có thể áp dụng công thức [7] để tính. Trong đó, chúng ta có $\pi_1 = 0.5$ và $\pi_2 = 0.60$, $HR = \log(0.6) / \log(0.5) = 0.7369$, và nếu $r = 1$ (cỡ mẫu hai nhóm bằng nhau):

$$e_1 = \frac{(1.96 + 0.842)^2}{(1+1) \times 1} \left(\frac{1+1 \times 0.7369}{1-0.7369} \right) = 172$$

Cũng có thể tính bằng hàm `epi.studysize` trong package `epiR` như sau:

```
library(epiR)
epi.studysize(treat=0.60, control=0.50, n=NA,
sigma=NA, power=0.80, r=1, conf.level=0.95,
sided.test=2, method = "survival")
```

21.2.6. Cỡ mẫu cho nghiên cứu bệnh chứng

Trong nghiên cứu bệnh chứng, như đề cập trong phần đầu, mục tiêu là so sánh tỉ lệ phơi nhiễm yếu tố nguy cơ giữa nhóm bệnh và nhóm chứng. Gọi E là có yếu tố nguy cơ, NE là không có yếu tố nguy cơ, D là bệnh, ND là không mắc bệnh (nhóm chứng). Trong nghiên cứu bệnh chứng, chúng ta có thể ước tính π_1 là xác suất E trong nhóm bệnh, và π_2 là xác suất E trong nhóm chứng:

$$\pi_1 = P(E | D)$$

$$\pi_2 = P(E | ND)$$

Giả thuyết đặt ra là:

$$H_0: \pi_1 = \pi_2$$

$$H_A: \pi_1 / \pi_2 = \lambda$$

Xin nhắc lại rằng chúng ta không biết π_1 và π_2 trong quần thể. Tuy nhiên, với mẫu nghiên cứu, chúng ta có thể ước tính hai chỉ số tương ứng là p_1 và p_2 . Gọi P = xác suất phơi nhiễm yếu tố nguy cơ = $P(E)$, chúng ta có thể nói rằng tỉ lệ quan sát $p_1 \approx P$. Với giả thuyết H_A , chúng ta có tỉ lệ phơi nhiễm yếu tố nguy cơ trong nhóm chứng là:

$$p_2 = \frac{\lambda P}{1 + (\lambda - 1)P}$$

Số cỡ mẫu n có thể ước tính từ các lí giải trên như sau (1):

$$n = \frac{(r+1)[1+(\lambda-1)P]^2}{rP^2(P-1)^2(\lambda-1)^2} \left[z_{\alpha/2} \sqrt{(r+1)P_c(1-P_c)} + z_{\beta} \sqrt{\frac{\lambda P(1-P)}{[1+(\lambda-1)P]^2} + rP(1-P)} \right]^2 \quad [9]$$

Trong đó: r là tỉ số cỡ mẫu nhóm bệnh trên nhóm chứng (thường $r = 1$), và

$$P_c = \frac{P}{1+r} \left[\frac{r\lambda}{1+(\lambda-1)P} + 1 \right] \quad [10]$$

Ví dụ 6: Một nghiên cứu bệnh chứng về mối liên quan giữa hút thuốc lá và bệnh tim mạch được hoạch định. Theo kế hoạch, một nhóm bệnh nhân và một nhóm chứng (cỡ mẫu như nhau, tức $r = 1$) sẽ được so sánh về tỉ lệ hút thuốc lá. Các nhà nghiên cứu đặt giả thuyết tỉ số nguy cơ là 2, khoảng 30% người trong cộng đồng hút thuốc lá. Câu hỏi đặt ra là cần bao nhiêu người cho nghiên cứu để có power 90% để phát hiện tỉ số đó có ý nghĩa thống kê ở mức độ 5%. Trong trường hợp này, chúng ta có: $P = 0.30$, $\lambda = 2$, $z_{\alpha/2} = 1.96$, và $z_{\beta} = 1.2816$.

Thay các giá trị này vào phương trình [10]:

$$P_c = \frac{0.3}{2} \left[\frac{2}{1+0.3} + 1 \right] = 0.3808$$

và số cỡ mẫu là:

$$n = \frac{2 \times 1.3^2}{0.3^2(-0.7)^2} \left[1.96 \sqrt{2(0.3808)(0.6192)} + 1.28 \sqrt{\frac{2(0.3)(0.7)}{1.3^2} + (0.3 \times 0.7)} \right]^2 = 376$$

Có thể dùng hàm **epi.studysize** trong **epiR** và có cùng kết quả:

```
library(epiR)
epi.studysize(treat = 2/100, control = 1/100, n = NA,
sigma = 0.30, power = 0.90, r = 1, conf.level = 0.95,
sided.test = 2, method = "case.control")
```

Trong hàm trên, nhóm control và treat được cho giá trị sao cho $\lambda = 2$, sigma là tỉ lệ hút thuốc lá (tức yếu tố phơi nhiễm trong nhóm chứng).

21.2.7. Cỡ mẫu cho nghiên cứu đoàn hệ

Lí thuyết: Nghiên cứu đoàn hệ (prospective cohort study) thường có mục tiêu tiên lượng và đánh giá yếu tố nguy cơ liên quan đến bệnh. Ngược lại với nghiên cứu bệnh chứng (đi ngược thời gian), nghiên cứu đoàn hệ đi xuôi theo thời gian. Theo đó, nhà nghiên cứu chọn một nhóm đối tượng, đo lường các yếu tố tiên lượng hay yếu tố nguy cơ lúc đầu, và sau đó theo dõi một thời gian để thu thập số ca mắc bệnh. Chỉ số thống kê để đánh giá mối liên quan giữa một yếu tố nguy cơ (như hút thuốc lá chẳng hạn) và nguy cơ mắc bệnh là *tỉ số nguy cơ* (còn gọi là *risk ration* hay *relative risk* - RR). Gọi xác suất mắc bệnh (còn gọi là *nguy cơ* - *risk*) trong thời gian theo dõi ở nhóm có yếu tố nguy cơ là p_1 , và nhóm không có yếu tố nguy cơ là p_2 , RR được định nghĩa đơn giản là:

$$RR = p_1 / p_2$$

Vấn đề thống kê là ước tính số đối tượng và số bệnh cần thiết sao cho RR có ý nghĩa thống kê (tức $P < \alpha$) với power $1 - \beta$.

Giả thuyết đặt ra là:

$$H_0: RR = 1 \text{ (hay } \pi_1 = \pi_2 \text{)}$$

$$H_A: RR \neq 1 \text{ (hay } \pi_1 \neq \pi_2 \text{)}$$

Trong đó, π_1 và π_2 là nguy cơ mắc bệnh ở nhóm có yếu tố nguy cơ và nhóm không có yếu tố nguy cơ trong quần thể. Tuy nhiên, với mẫu nghiên cứu, chúng ta có thể ước tính hai chỉ số tương ứng là p_1 và p_2 . Phương pháp ước tính cỡ mẫu có thể dựa vào phương pháp ước tính cỡ mẫu cho hai tỉ lệ theo hướng RR. Có thể chứng minh qua một số thao tác toán, số cỡ mẫu cần thiết là (1):

$$n = \frac{r+1}{r(RR-1)^2 \pi_2^2} \left[z_{\alpha/2} \sqrt{(r+1)\pi(1-\pi)} + z_{\beta} \sqrt{RR\pi_2(1-RR\pi_2) + r\pi_2(1-\pi_2)} \right]^2 \quad [11]$$

Trong đó, π là tỉ lệ mắc bệnh trung bình của hai nhóm:

$$\pi = \frac{\pi_2(r.RR+1)}{r+1}$$

Trong trường hợp $r = 1$

$$\pi = \frac{\pi_1 + \pi_2}{2}$$

Ví dụ 7: Nhà nghiên cứu muốn đánh giá mối liên quan giữa hút thuốc lá và bệnh tim mạch qua một nghiên cứu đoàn hệ mà đối tượng sẽ được theo dõi 5 năm. Trước đây, có nghiên cứu cho thấy tỉ lệ tử vong vì bệnh tim mạch mỗi năm ở người không hút thuốc lá là 413 / 100,000. Nhà nghiên cứu giả định rằng hút thuốc lá sẽ tăng nguy cơ tử vong 40% (nói cách khác, $RR = 1.4$). Nhà nghiên cứu muốn ước tính số cỡ mẫu (số người hút thuốc lá và không hút thuốc lá) cần thiết với điều kiện $\alpha = 0.05$ (một chiều) và $power = 90\%$ (tức $beta = 0.1$).

Ở đây, chúng ta có thể ước tính vài thông số cần thiết như sau: tỉ lệ tử vong 5 năm nhóm không hút thuốc là $\pi_2 = 5 \times 413/100000 = 0.02065$, $\pi_1 = 0.02065 \times 1.4 = 0.02891$, $z_{0.05} = 1.6449$, $z_{0.10} = 1.2816$. Nếu $r = 1$, chúng ta có:

$$\pi = \frac{0.02065 \times 2.4}{2} = 0.02478$$

và:

$$n = \frac{2}{0.4^2 (0.02065)^2} \left[1.6449 \sqrt{(2)(0.02478)(0.97522)} + 1.2816 \sqrt{(0.02891)(0.02065)(0.97935)} \right]^2 = 12130$$

Nói cách khác, nhà nghiên cứu cần tuyển 12130 cá nhân (6065 người hút thuốc và 6065 người không hút thuốc) cho công trình nghiên cứu.

Có thể dùng hàm **epi.studysize** trong **epiR** và có cùng kết quả:

```
library(epiR)
smoke=1.4*(5*413)/100000
nonsmoke=(5*413)/100000
epi.studysize(treat=smoke, control=nonsmoke, n=NA, sigma=NA,
power=0.90, r=1, conf.level=0.95, sided.test=1, method="cohort.count")
```

21.2.8. Cỡ mẫu cho nghiên cứu chẩn đoán

Lí thuyết: Trong nghiên cứu chẩn đoán, nhà nghiên cứu hay quan tâm đến hai chỉ số quan trọng: độ nhạy (sensitivity) và độ đặc hiệu (specificity). Độ nhạy, có khi hiểu là *dương tính thật* hay *true positive*, là xác suất bệnh nhân có kết quả dương tính (+ve). Độ đặc hiệu, có khi hiểu là âm tính thật hay *true negative*, là xác suất một người không có bệnh có kết quả xét nghiệm âm tính (-ve). Gọi D là bệnh, ND là không bệnh, định nghĩa trên có thể viết theo ngôn ngữ xác suất như sau:

$$\text{Sensitivity} = P(+ve | D)$$

$$\text{Specificity} = P(-ve | ND)$$

Do đó, trong nghiên cứu chẩn đoán, chúng ta muốn biết cần bao nhiêu bệnh nhân (n_d) để “chứng minh” một độ nhạy này với độ nhạy khác. Thông thường, chúng ta muốn so sánh độ nhạy của nghiên cứu (Se) và với độ nhạy hiện tại (Se_0). Phương pháp ước tính n_d có thể dựa vào phương pháp ước tính cỡ mẫu cho 2 tỉ lệ (2):

$$n_d = \frac{\left[z_{\alpha/2} \sqrt{Se_0(1-Se_0)} + z_\beta \sqrt{Se(1-Se)} \right]^2}{(Se_0 - Se)^2} \quad [12]$$

Nếu nghiên cứu muốn so sánh hai độ nhạy (Se_1 và Se_2), công thức trên có thể chỉnh sửa thành (cho hai nhóm độc lập):

$$n_d = \frac{\left[z_{\alpha/2} \sqrt{(Se_1 + Se_2)(2 - Se_1 - Se_2)} + z_\beta \sqrt{2[Se_1(1-Se_1) + Se_2(1-Se_2)]} \right]^2}{(Se_1 - Se_2)^2} \quad [13]$$

Công thức trên ước tính cỡ mẫu cho 2 nhóm độc lập. Trong nhiều trường hợp, nhà nghiên cứu có thể so sánh độ nhạy trong cùng một nhóm, và số bệnh cần thiết là:

$$n_d = \frac{\left[z_{\alpha/2} \Lambda + z_\beta \sqrt{\Lambda^2 - \zeta^2(3 + \Lambda)/4} \right]^2}{\Lambda \zeta^2} \quad [14]$$

trong đó,

$$\Lambda = (1 - Se_1)Se_2 + (1 - Se_2)Se_1$$

$$\zeta = (1 - Se_1)Se_2 - (1 - Se_2)Se_1$$

Ví dụ 8: Nhà nghiên cứu muốn đánh giá độ nhạy của một xét nghiệm mới trong việc chẩn đoán rối loạn cường dương. Biết rằng trong cộng đồng có khoảng 55% người rối loạn cường dương. Nghiên cứu trước đây cho thấy độ nhạy của phương pháp xét nghiệm hiện hành là 85%. Nhà nghiên cứu hi vọng rằng xét nghiệm mới sẽ có độ nhạy 95%, và muốn ước tính số cỡ mẫu cần thiết cho nghiên cứu với điều kiện $\alpha = 0.05$ (một chiều) và $\beta = 0.20$.

Với những thông tin trên, chúng ta có $z_{0.05} = 1.645$, $z_{0.20} = 0.842$.

Dùng công thức [12], số cỡ mẫu (bệnh nhân) cần thiết là:

$$n_d = \frac{\left[1.645 \sqrt{(0.86)(1 - 0.86)} + 0.842 \sqrt{(0.95)(1 - 0.95)} \right]^2}{(0.95 - 0.86)^2} = 75$$

Nhà nghiên cứu cần tuyển 75 bệnh nhân và số không mắc bệnh (tính theo tỉ lệ hiện hành 55%) là $75 / 0.55 = 136$. Tính chung, công trình nghiên cứu cần 211 cá nhân.

Ví dụ 9: Một nghiên cứu có mục tiêu là so sánh hai độ nhạy của hai phương pháp xét nghiệm để chẩn đoán bệnh viêm răng với mức độ ý nghĩa thống kê 5% (kiểm định hai chiều) và power 80%. Nhà nghiên cứu giả định rằng xét nghiệm 1 có độ nhạy là 66%, và xét nghiệm 2 có độ nhạy 27%. Số bệnh nhân cần thiết có thể ước tính như sau:

$$n_d = \frac{\left[1.96 \sqrt{(0.27 + 0.66) \left(2 - 0.27 - 0.66 \right)} + 0.842 \sqrt{2 \left[0.67 \left(1 - 0.27 \right) + 0.66 \left(1 - 0.66 \right) \right]} \right]^2}{(0.66 - 0.27)^2} = 49$$

Nếu tỉ lệ viêm răng trong cộng đồng là 25%, số nhóm chứng có thể ước tính là $49 / 0.25 = 200$. Tính chung, nhà nghiên cứu cần tuyển mộ 49 bệnh nhân và 200 người thuộc nhóm chứng cho công trình nghiên cứu.

Tuy nhiên, nếu hai xét nghiệm có thể làm trên 1 nhóm đối tượng thì:

$$\Lambda = (1 - 0.27)0.66 + (1 - 0.66)0.27 = 0.5736$$

và

$$\zeta = (1 - 0.27)0.66 - (1 - 0.66)0.27 = 0.3900$$

Công thức [14] sẽ cho ra kết quả cỡ mẫu cần thiết:

$$n_d = \frac{\left[1.96 \times 0.5736 + 0.8416 \sqrt{0.5736^2 - 0.3900^2(3 + 0.5736)/4} \right]^2}{0.5736 \times 0.3900^2} = 26$$

Do đó, số cỡ mẫu cần xét nghiệm là $26 / 0.25 = 92$ (giả định rằng tỉ lệ viêm răng là 25%).

21.2.9. Cỡ mẫu cho đường biểu diễn ROC (receiver operating characteristic curve)

Lí thuyết: Đường biểu diễn ROC là một chỉ số thống kê phản ánh mức độ phân biệt (discrimination) bệnh và không bệnh của một phương pháp xét nghiệm. Trong chẩn đoán, khi phương pháp xét nghiệm tăng độ nhạy thì độ đặc hiệu sẽ giảm, và ngược lại, khi độ nhạy giảm thì độ đặc hiệu tăng. ROC là một “thỏa hiệp” giữa độ nhạy và độ đặc hiệu, để có độ nhạy và độ đặc hiệu tối ưu nhất.

Đường ROC được vẽ với trục tung là độ nhạy, và trục hoành là tỉ lệ dương tính giả (FPR - false positive rate). FPR thật sự là 1 trừ cho độ đặc hiệu. Diện tích dưới đường ROC được gọi là *area under the curve* (AUC). Mục tiêu của nghiên cứu chẩn đoán thường là (a) ước tính AUC, hoặc (b) so sánh các phương pháp xét nghiệm là so sánh AUC sao cho có ý nghĩa thống kê.

Đối với nghiên cứu có mục tiêu ước tính AUC trong một khoảng tin cậy w , công thức ước tính số bệnh nhân cần thiết là (3-4):

$$n_d = 4 \left(z_{\alpha/2} \times \frac{\sigma}{w} \right)^2$$

Trong đó:

$$\sigma = \frac{e^{-A^2/4}}{2\sqrt{\pi}} \sqrt{1 + \frac{1}{R} + \frac{5A^2}{8} + \frac{A^2}{8R}}$$

$$A = z_{1-FPR} - z_{1-TPR}$$

Chú ý: FPR = 1 - độ đặc hiệu, và TPR = độ nhạy.

Ví dụ 10: Nhà nghiên cứu muốn ước tính số cỡ mẫu cần thiết để đánh giá độ chính xác của MRI trong việc chẩn đoán viêm khớp xương. Khoảng 40% cá nhân có viêm khớp xương. Qua y văn, nhà nghiên cứu biết rằng độ nhạy là 45% và độ đặc hiệu là 90%, và khoảng tin cậy của AUC $w = 10\%$ (tức 0.1).

Với các thông tin trên, chúng ta có thể tính: $R = 0.6 / 0.4 = 1.5$, $FPR = 0.1$, $TPR = 0.45$. Do đó, $z_{0.1} = 1.2816$, và $z_{0.45} = 0.1257$, $A = 1.2816 - 0.1257 = 1.1559$, $\sigma = 0.3265$ (các bạn có thể kiểm tra). Từ đó, số cỡ mẫu cần thiết là:

$$n_d = 4 \left[\frac{0.3265^2}{0.1^2} \right] 1.96 = 164$$

Số đối tượng nhóm chứng là $164 \times 1.5 = 246$. Tính chung, nhà nghiên cứu cần $164 + 246 = 410$ đối tượng.

21.3 Vài nhận xét

Trong nghiên cứu khoa học, đặc biệt là những công trình nghiên cứu liên quan đến con người và động vật, việc xác định cỡ mẫu là một bước cực kì quan trọng. Quan trọng vì số lượng đối tượng nghiên cứu quyết định ngân sách và qui mô của nghiên cứu. Ngoài ra, đứng trên quan điểm y đức, số lượng đối

tượng cũng liên quan đến đạo đức khoa học. Một nghiên cứu có quá ít đối tượng sẽ không có khả năng kiểm định giả thuyết và kết quả chẳng có ý nghĩa gì, và nghiên cứu đó được xem là vi phạm đạo đức. Ngược lại, một nghiên cứu có quá nhiều đối tượng hơn số cần thiết cũng là một vi phạm đạo đức, vì gây bất tiện không cần thiết cho những người tham gia. Đối với các nghiên cứu về thuốc, xác định cỡ mẫu còn có ý nghĩa pháp lí trong việc đăng kí thuốc. Hội nghị ICH (International Conference on Harmonization) (5) có qui định rằng các công ti được muốn đăng kí được phẩm phải đệ trình đầy đủ hồ sơ và dữ liệu, trong đó phải có phần phương pháp ước tính cỡ mẫu. Do đó, tuy là bước đầu trong nghiên cứu, nhưng việc xác định cỡ mẫu là một bước trung tâm trong thiết kế nghiên cứu.

Xác định cỡ mẫu là một khoa học, nhưng cũng có thể xem là một nghệ thuật. Tính khoa học của ước tính cỡ mẫu là cơ sở lí thuyết xác suất và giả định đằng sau mỗi công thức tính. Chính vì cơ sở khoa học này mà các phép tính phải mang tính tái thiết lập (repeatability). Nếu phương pháp tính toán được mô tả đầy đủ và minh bạch, người khác có thể đi đến cùng kết quả, và điều đó rất quan trọng trong tính minh bạch. Tuy nhiên, trong thực tế thì không hẳn như thế. Trong một thẩm định và phân tích 446 đề cương nghiên cứu đệ trình cho ủy ban y đức ở Anh, các nhà nghiên cứu phát hiện chỉ có 134 (30%) đề cương mô tả cách tính đầy đủ và người khác có thể lặp lại kết quả tính toán, 70% còn lại thì kết quả không tái lập được (6). Đó là một kết quả bất ngờ và đáng quan tâm vì đây là những công trình nghiên cứu có liên quan đến con người.

Tính nghệ thuật trong việc xác định cỡ mẫu là cách chọn mức độ ảnh hưởng cho tính toán. Trong rất nhiều trường hợp, nhà nghiên cứu không biết được mức độ ảnh hưởng là bao nhiêu, không biết được độ nhạy hay độ chính xác của một xét nghiệm. Nhưng những thông số này lại rất cần cho việc tính toán cỡ mẫu! Do đó, nhà nghiên cứu phải vận dụng suy nghĩ để tìm một thông số cho tính toán. Một nghiên cứu phải cho ra kết quả có ích, do đó, thông số đó phải có ý nghĩa thực tế hay ý nghĩa lâm sàng. Cần phải phân biệt ý nghĩa thống kê và ý nghĩa lâm sàng. Khi một nghiên cứu có cỡ mẫu lớn, bất cứ một khác biệt nhỏ nào cũng có thể có ý nghĩa thống kê ($P < 0.05$), nhưng không có ý nghĩa lâm sàng. Ngược lại, một kết quả có thể có ý nghĩa lâm sàng nhưng không có ý nghĩa thống kê khi cỡ mẫu quá nhỏ. Do đó, nghệ thuật ở đây là phải chọn một thông số về ảnh hưởng vừa có ý nghĩa thống kê và có ý nghĩa lâm sàng. Như là một hướng dẫn chung, nếu mức độ ảnh hưởng (ES) khoảng 0.1-0.3 là “nhỏ”, 0.3-0.5 là “trung bình”, và >0.5 được xem là “lớn” (7). Việc chọn mức độ ảnh hưởng cho tính toán cỡ mẫu đòi hỏi nhà nghiên cứu phải suy nghĩ về vấn đề mình quan tâm và phù hợp với tình hình thực tế.

Tính toán cỡ mẫu phải được thực hiện trước khi triển khai nghiên cứu. Trong thực tế, có tình huống xảy ra khi kết quả nghiên cứu không có ý nghĩa thống kê, nhà nghiên cứu bèn tính toán power và số cỡ mẫu cần thiết để phát hiện mức độ ảnh hưởng quan sát. Cách làm như thế có khi được gọi là *post-hoc analysis of power*. Nhưng ước tính cỡ mẫu và tính toán power sau khi công trình nghiên cứu đã hoàn tất hay sau khi xem qua kết quả hoàn toàn không có giá trị khoa học và phi logic (8-9). Cần nhớ rằng power là xác suất mà một kiểm định thống kê bác bỏ giả thuyết vô hiệu khi giả thuyết vô hiệu sai; do đó, power chỉ có ý nghĩa khi giả thuyết vô hiệu sai. Nhưng vấn đề là một kết quả không có ý nghĩa thống kê không nói cho chúng ta biết giả thuyết vô hiệu là đúng hay sai. Do đó, tính cỡ mẫu và power sau khi đã quan sát kết quả là hàm ý giả định rằng giả thuyết vô hiệu sai nhưng lại không phù hợp với dữ liệu thực tế. Cần phải tuyệt đối tránh tính toán cỡ mẫu và power sau khi quan sát một kết quả không có ý nghĩa thống kê. Khoảng tin cậy 95% cung cấp cho chúng ta nhiều thông tin hơn là một phân tích hậu định về power.

Một số nhà nghiên cứu (đặc biệt là ở Việt Nam) có thói quen tính toán cỡ mẫu sao cho ăn khớp với số đối tượng họ có thể tiếp cận được hay đã có sẵn. Chẳng hạn như nhà nghiên cứu đã có 30 bệnh nhân, và họ cố gắng điều chỉnh các thông số trong công thức ước tính cỡ mẫu sao cho kết quả là 30. Việc làm này dẫn đến nhiều kết quả vô lý, chẳng hạn như sai số mẫu gần bằng với tham số chính như tỉ lệ hiện hành! Đây là một thói quen, nếu không muốn nói là một sự “lươn lẹo” và phản khoa học không thể chấp nhận trong văn hoá khoa học. Như đã đề cập ở trên, việc ước tính cỡ mẫu phải được thực hiện trước khi triển khai nghiên cứu và phải được tiến hành một cách có đầu tư *suy nghĩ* và nghiêm chỉnh.

Xin nhấn mạnh một lần nữa là phương pháp ước tính cỡ mẫu phụ thuộc vào mô hình nghiên cứu, biến kết quả, sai sót trong kiểm định giả thuyết, và mức độ ảnh hưởng. Mỗi mô hình nghiên cứu với mỗi loại biến kết quả có một công thức ước tính cỡ mẫu đặc thù. Chẳng hạn như không thể dùng công thức [1] để ước tính cỡ mẫu cho nghiên cứu so sánh một biến liên tục giữa hai nhóm nghiên cứu. Tuy nhiên, trong thực tế ở Việt Nam, rất nhiều nhà nghiên cứu tính toán cỡ mẫu chỉ dựa vào công thức [1] cho hầu hết các mô hình nghiên cứu! Việc áp dụng công thức tính toán một cách tùy tiện như thế là một sai lầm rất căn bản và khó chấp nhận được. Sai lầm này có khi nguy hiểm, vì cho ra kết quả sai, làm ảnh hưởng đến chất lượng nghiên cứu.

Như có thể thấy qua các trường hợp vừa trình bày, phương pháp ước tính cỡ mẫu dựa trên một giả định rất đơn giản: cái gì nhỏ thì rất khó tìm (cần nhiều cỡ mẫu), và cái gì lớn thì dễ tìm (cần ít cỡ mẫu). Gắn kết với cỡ mẫu là khái niệm power (mà có nhiều người dịch là *lực nghiên cứu*, nhưng trong thực tế là độ nhạy

của nghiên cứu). Độ nhạy của nghiên cứu là xác suất bác bỏ giả thuyết vô hiệu khi giả thuyết vô hiệu sai. Cỡ mẫu càng cao, độ nhạy càng cao; cỡ mẫu càng thấp, độ nhạy cũng giảm theo. Trong thực tế, có tình trạng thiếu nhất quán giữa công thức ước tính cỡ mẫu trong đề cương nghiên cứu và trong báo cáo khoa học. Một phân tích mới công bố trên BMJ (6) cho thấy chỉ có 11 trong số 62 nghiên cứu mà mô tả về cách tính cỡ mẫu nhất quán giữa đề cương và bài báo! Sự thiếu nhất quán như thế dẫn đến khó khăn trong diễn giải kết quả. Do đó, những thông số được sử dụng trong ước tính cỡ mẫu cần phải được mô tả cẩn thận và rõ ràng, vì những thông tin này rất có ích cho việc đánh giá tính khả tín của kết quả nghiên cứu. Những ví dụ trong bài này chủ yếu liên quan đến nghiên cứu y khoa (vốn đa dạng), nhưng cũng áp dụng cho các nghiên cứu xã hội học. Hi vọng rằng những chỉ dẫn trên đây sẽ giúp cho các nhà nghiên cứu hiểu hơn về ý tưởng và ý nghĩa của việc ước tính cỡ mẫu cho một công trình nghiên cứu khoa học.

Tài liệu tham khảo

- (1) Woodward M. Epidemiology: Study Design and Data Analysis, Third Edition, Chapter 8. Chapman & Hall 2013.
- (2) Machin D, Campbell MJ, Tan SB, Tan SH. Sample size tables for clinical studies, 3rd Edition, Chapter 13. Blackwell Publishing 2009.
- (3) Obuchowski NA, McClish DW. Sample size determination for diagnostic accuracy studies involving binomial ROC curve indices. Stat Med 1997;16:1529-42.
- (4) Li J, Fine J. One sample size for sensitivity and specificity in prospective diagnostic accuracy studies. Stat Med 2004;23:2537-50.
- (5) Clark T, Berger U, Mansmann U. Sample size determinations in original research protocols for randomised clinical trials submitted to UK research ethics committees: review. BMJ 2013 Mar 21;346:f1135.
- (6) Chan AW, Hróbjartsson A, Jørgensen K, Gøtzsche PC, Altman DG. Discrepancies in sample size calculations and data analyses reported in randomised trials: comparison of publications with protocols. BMJ 2008;337:a2299
- (7) Cohen, J. Statistical power analysis for the behavioral sciences (2nd ed.). New Jersey: Lawrence Erlbaum, 1988.
- (8) Hoenig JM, Heisey DM. The abuse of power: the pervasive fallacy of power. The American Statistician 2001;55:1-6.
- (9) Onwuegbuzie AJ, Leech NL. Post-hoc power: A concept whose time has come. Understanding Statistics 2004;3(4):201-230.

22

Phân tích số liệu dãy thời gian (Time Series Analysis)

Một trong những dữ liệu phổ biến trong kinh tế và y khoa là dữ liệu mang tính thời gian và chu kỳ. Chẳng hạn như tỉ lệ tử vong theo năm, tỉ giá đồng USD được ghi chép từng ngày qua nhiều năm, nhịp tim của bệnh nhân được máy ghi nhận theo từng phút trong một ngày. Trong thuật ngữ tiếng Anh, những dữ liệu này được đề cập đến như là “time series data” - dữ liệu theo thời gian. Những dữ liệu theo thời gian có đặc điểm là chúng biến chuyển theo chu kỳ và có xu hướng. Nói cách khác, “phía dưới” những biến chuyển của dữ liệu theo thời gian là một số yếu tố mà phân tích thống kê cần phải phát hiện.

Phương pháp dữ liệu theo thời gian bao gồm các phương pháp “chiết xuất” các chỉ số thống kê phản ánh những đặc điểm của dữ liệu. Một hướng phân tích khác là xây dựng mô hình tiên lượng dữ liệu tương lai dựa vào những dữ liệu đã quan sát trong quá khứ. Dĩ nhiên, các mô hình hồi qui tuyến tính cũng có thể sử dụng cho tiên lượng, nhưng các mô hình như thế có vài vấn đề về giả định và khó ứng dụng cho dữ liệu theo thời gian. Ngoài một số package chuyên dụng như **TSA**, **tseries**, và **timeSeries**, trong R đã có sẵn một số hàm cơ bản để phân tích các dữ liệu theo thời gian. Trong chương này, tôi sẽ giới thiệu phương pháp đơn giản và một số hàm cơ bản cho phân tích dữ liệu. Các phương pháp đó bao gồm phân tích mô tả xu hướng và chu kỳ (hay mùa), và các mô hình Moving Average, Autoregressive, và ARIMA.

22.1 Dữ liệu và nhập dữ liệu

Việc cần làm đầu tiên trong phân tích dữ liệu theo thời gian là nhập dữ liệu theo đúng thời gian. Trong chương này, chúng ta sẽ làm quen với 3 dữ liệu theo thời gian.

Ví dụ 1: Tuổi tử vong của vua Anh Quốc. Số liệu dưới đây phản ánh tuổi tử vong của 42 vị vua của Anh Quốc. Trong trường hợp này, dữ liệu không hẳn mang tính thời gian, vì khoảng cách giữa các năm tử vong của vua không bằng nhau. Thông thường, dữ liệu chỉ là một dãy số liệu như sau:

```
60 43 67 50 56 42 50 65 68 43 65 34 47 34 49 41 13 35 53 56 16
43 69 59 48 59 86 55 68 51 33 49 67 77 81 67 71 81 68 70 77 56
```

Ví dụ 2: Bán hàng lưu niệm. Số liệu thu thập về lượng hàng lưu niệm bán cho du khách ở một vùng du lịch thuộc bang Queensland (Úc) từ 1/1987 đến 12/1993:

```
1664.81 2397.53      2840.71      3547.29      3752.96
3714.74 4349.61      3566.34      5021.82      6423.48
7600.60 19756.21     2499.81      5198.24      7225.14
4806.03 5900.88      4951.34      ...
```

Đây là dữ liệu theo thời gian vì có tháng và năm. Chúng ta có thể “đọc” dữ liệu vào R với hàm scan như sau:

```
souv = scan("~/Documents/_Vietnam14/R Book (Revised)/
Data/souvenirs.txt")
```

Nhưng dữ liệu souv chưa thể phân tích được vì chỉ là một vector số mà không có yếu tố tháng và năm. Để thêm yếu tố tháng và năm, chúng ta cần dùng đến hàm ts như sau:

```
ts.souv = ts(souv, frequency=12, start=c(1987, 1))
```

Bây giờ dữ liệu ts.souv đã có một hình thức mới và có thể sử dụng cho phân tích:

```
> ts.souv
```

	Jan	Feb	Mar	Apr	May	Jun
1987	1664.81	2397.53	2840.71	3547.29	3752.96	3714.74
1988	2499.81	5198.24	7225.14	4806.03	5900.88	4951.34
1989	4717.02	5702.63	9957.58	5304.78	6492.43	6630.80
1990	5921.10	5814.58	12421.25	6369.77	7609.12	7224.75

```

1991  4826.64   6470.23   9638.77   8821.17   8722.37  10209.48
1992   7615.03   9849.69  14558.40  11587.33   9332.56  13082.09
1993  10243.24  11266.88  21826.84  17357.33  15997.79  18601.53
...

```

Ví dụ 3: Số trẻ em mới sinh ở New York. Dữ liệu dưới đây là số trẻ em mới sinh mỗi tháng ở Thành phố New York từ 1/1946 đến 12/1959 cũng là một dữ liệu theo thời gian:

```

26.663 23.598 26.931 24.740 25.806 24.364 24.477 23.901 23.175
23.227 21.672 21.870 21.439 21.089 23.709 21.669 21.752 20.761
23.479 23.824 23.105 23.110 21.759 22.073 21.937 20.035 23.590
21.672 22.222 22.123 23.950 23.504 22.238 23.142 21.059 21.573
21.548 20.000 22.424 20.615 21.761 22.874 24.104 23.748 23.262
22.907 21.519 22.025 22.604 20.894 24.677 23.673 25.320 23.583
...

```

Mặc dù dữ liệu không có cột tháng và năm, nhưng chúng ta có thể dùng hàm R để tạo ra một dữ liệu R (data frame) cho phân tích. Trước hết, đọc dữ liệu vào đối tượng `births`.

```

births = scan("~/Documents/_Vietnam14/R Book (Revised)/
Data/births.txt")

```

Sau đó, sắp xếp dữ liệu theo từng tháng, bắt đầu từ 1/1946 đến 12/1959, bằng cách dùng hàm `ts` trong R, và cho kết quả vào đối tượng `ts.births`:

```

ts.births = ts(births, frequency=12, start=c(1946, 1))

```

Trong hàm trên, chú ý lệnh `frequency=12` (một năm có 12 tháng) và `start=c(1946, 1)` tức bắt đầu từ tháng 1 năm 1946. Kiểm tra kết quả cho thấy R đã sắp xếp dữ liệu theo tháng năm:

```

> ts.births


      Jan   Feb   Mar   Apr   May   Jun   Jul   Aug   Sep
1946 26.663 23.598 26.931 24.740 25.806 24.364 24.477 23.901 23.175
1947 21.439 21.089 23.709 21.669 21.752 20.761 23.479 23.824 23.105
1948 21.937 20.035 23.590 21.672 22.222 22.123 23.950 23.504 22.238
1949 21.548 20.000 22.424 20.615 21.761 22.874 24.104 23.748 23.262
1950 22.604 20.894 24.677 23.673 25.320 23.583 24.671 24.454 24.122
...

```

22.2 Biểu đồ

Sau khi dữ liệu đã được sắp xếp và nhập thích hợp cho phân tích, bước đầu tiên là xem xét dữ liệu bằng một biểu đồ. Hàm **plot.ts** có thể giúp cho phân tích này. Nên nhớ đối tượng của **plot.ts** là dữ liệu đã được hàm **ts** nhập:

```
plot.ts(ts.births)
```



Biểu đồ số trẻ mới sinh mỗi tháng ở New York từ 1/1946 đến 12/1959


Có thể thấy từ biểu đồ này một chu kì mang tính mùa và xu hướng năm. Trong mỗi năm số trẻ mới sinh thường cao nhất vào mùa hè và giảm thấp nhất vào mùa đông. Nhưng đồng thời xu hướng chung là tính từ 1950 thì số trẻ mới sinh tăng theo năm.

Đối với dữ liệu về tuổi tử vong của các vua Anh Quốc, chúng ta có biểu đồ dưới đây:

```
kings = scan("~/Documents/_Vietnam14/R Book (Revised)/  
Data/kings.txt")
```

```
ts.kings = ts(kings)
```

```
plot.ts(ts.kings)
```




Biểu đồ mô tả tuổi tử vong của 42 vua Anh Quốc

Biểu đồ trên cho thấy, không có một chu kỳ rõ ràng, tuy nhiên có xu hướng. Sự biến chuyển của dữ liệu có thể mô tả bằng một mô hình cộng hưởng (additive model), vì độ dao động ngẫu nhiên có vẻ bất biến (độc lập) với thời gian.

Nhưng biểu đồ mô tả biến chuyển về lượng hàng lưu niệm bán ra thì có xu hướng và chu kỳ rõ ràng:


```
ts.souv = ts(souv, frequency=12, start=c(1987, 1))
plot.ts(ts.souv)
```



Biểu đồ mô tả lượng hàng lưu niệm bán ra từ 1/1987 đến 12/1993.

Biểu đồ cho thấy mô hình cộng hưởng có vẻ không thích hợp để mô tả dữ liệu này, vì có bằng chứng cho thấy có chu kì trong dữ liệu. Có lẽ chúng ta cần hoán chuyển dữ liệu sang đơn vị log để xem mô hình cộng hưởng có thể dùng để mô tả:

```
ts.souv = ts(souv, frequency=12, start=c(1987, 1))  
  
plot.ts(ts.souv)  
logsouv = log(ts.souv)  
plot.ts(logsouv)
```



Biểu đồ mô tả lượng hàng lưu niệm (đơn vị log) bán ra từ 1/1987 đến 12/1993.

Biểu đồ trên cho thấy mức độ dao động theo chu kì có vẻ độc lập với thời gian. Do đó, có lẽ chúng ta sẽ dùng đơn vị log cho các phân tích kế tiếp.

22.3 Phân tích các thành phần trong dữ liệu theo thời gian

Dãy số liệu theo thời gian có 3 thành phần (components) chính theo thuật ngữ tiếng Anh như sau: *trend*, *seasonal*, và *cyclic*. Ba thành phần này có thể giải thích như sau:

Trend (xu hướng lâu dài)

Xu hướng là chiều hướng biến đổi, tăng hay giảm, trong dữ liệu. Xu hướng không nhất thiết phải là tuyến tính.


Seasonal (theo mùa)

Biến đổi theo mùa xảy ra khi dãy số liệu chịu ảnh hưởng bởi các yếu tố mùa (như quý trong năm, tháng, hay ngày trong tuần). Biến đổi theo mùa lúc nào cũng xảy ra trong một quãng thời gian nhất định.

Cyclic (chu kì)

Biến đổi theo chu kì tồn tại khi dữ liệu thể hiện những biến chuyển (tăng và giảm) mà *không theo một thời gian cố định*. Nhiều dữ liệu theo thời gian dao động tăng giảm trong thời gian tối thiểu là 2 năm.

Nhiều người nhầm lẫn giữa biến chuyển cyclic và seasonal, nhưng thật ra sự phân biệt không quá khó khăn. Nếu dao động không xảy ra trong một thời gian cố định, đó là biến chuyển cyclic; nếu thời gian cố định (như tuần, tháng, quý) biến chuyển là seasonal. Nói chung, thời gian của biến chuyển cyclic thường dài hơn thời gian của biến chuyển seasonal. Ngoài ra, mức độ của biến chuyển cyclic cũng thường cao hơn biến chuyển seasonal.



Bốn loại dữ liệu theo thời gian

Biểu đồ phía trái dòng 1 cho thấy biến đổi theo mùa trong mỗi năm, nhưng cũng có biến đổi cyclic trong thời gian 6-10 năm. Tuy nhiên dữ liệu không biểu hiện xu hướng lâu dài. **Biểu đồ bên phải dòng 1** không biểu hiện biến chuyển theo mùa, nhưng xu hướng giảm thì rất rõ ràng. **Biểu đồ phía trái dòng 2** biểu hiện xu hướng tăng rất rõ ràng, với thành phần seasonal cũng rất rõ ràng. Tuy nhiên, không có biểu hiện cyclic. **Biểu đồ bên phải dòng 2** không có xu hướng

lâu dài, không có yếu tố seasonal, và cũng không có biến đổi cyclic. Tất cả có vẻ chỉ là ngẫu nhiên, rất khó tiên lượng.

Cần phân biệt 2 loại dữ liệu theo thời gian: loại không có yếu tố seasonal và loại có yếu tố seasonal.

22.3.1 Đối với dữ liệu không có seasonal

Đối với dữ liệu không có season (như tuổi thọ của vua Anh Quốc) dữ liệu chỉ có 2 phần: phần hệ thống (regular component) và phần phi hệ thống hay ngẫu nhiên (irregular component). Gọi dãy dữ liệu là Y , để tách hai phần này, chúng ta cần phải ước tính phần xu hướng (T_t), và phần còn lại là E_t :

$$Y_t = T_t + E_t$$

Để ước tính T của dữ liệu không có season, chúng ta có thể dùng một phương pháp *mượt hoá* (gọi là *smoothing method*). Một trong những phương pháp mượt hoá phổ biến là **simple moving average** (SMA), tôi tạm dịch là *trung bình động đơn giản*.

Trung bình động là một số trung bình của một tập hợp số liệu được tính toán *tích lũy* theo thời gian và *trong một khoảng thời gian* nhất định. Đây là một chỉ số thống kê rất có ích cho việc xác định xu hướng của một dãy số liệu theo thời gian. Ví dụ chúng ta có một dãy số liệu theo năm như sau:

2003:	4 triệu
2004:	6 triệu
2005:	5 triệu
2006:	8 triệu
2007:	9 triệu
2008:	5 triệu
2009:	4 triệu
2010:	3 triệu
2011:	7 triệu

Chúng ta có thể chọn tính trung bình động cho một khoảng thời gian. Trung bình động 3 năm có thể tính như sau:

$$(4 + 6 + 5) / 3 = 5$$

$$\text{cho 3 năm kế tiếp: } (6 + 5 + 8) / 3 = 6.3$$

$$\text{và 3 năm kế tiếp: } (5 + 8 + 9) / 3 = 7.3$$

vân vân. Tính như thế chúng ta có một dãy số mới chỉ toàn là trung bình động.

Tương tự, chúng ta cũng có thể tính trung bình động cho 5 năm thay vì 3 năm. Trung bình động 5 năm như sau:

$$(4 + 6 + 5 + 8 + 9) / 5 = 6.4$$

$$(6 + 5 + 8 + 9 + 5) / 5 = 6.6$$

$$(5 + 8 + 9 + 5 + 4) / 5 = 6.2$$

v.v.

Chúng ta có thêm 2 biến như sau:

NĂM	SỐ LIỆU	SMA=3	SMA=5
2003	4		
2004	6		
2005	5	5.0	
2006	8	6.3	
2007	9	7.3	6.4
2008	5	7.3	6.6
2009	4	6.0	6.2
2010	3	4.0	5.8
2011	7	4.7	5.6

SMA=3 là trung bình động tính trên 3 năm;

SMA=5 là trung bình động tính cho 5 năm.

Như có thể xem qua bảng số liệu trên, trung bình động với thời gian càng rộng thì xu hướng càng ổn định, xu hướng càng “mượt mà”. Tuy nhiên, trung bình động với thông số n càng dài thì phải “hi sinh” tham số và bậc tự do trong tính toán.

Trong R, để tính SMA, chúng ta có thể dùng hàm **SMA()** trong package **TTR**. Hàm TTR đòi hỏi phải có tham số về order (hay span) với n . Chẳng hạn như nếu chúng ta muốn tính SMA 5 năm thì $n = 5$.

```
kings = scan("~/Documents/Data/kings.txt")
```

```
ts.kings = ts(kings)
```


```
library(TTR)
```

```
# tính trung bình cộng cho 5 năm
```

```
king.ma = SMA(ts.kings, n=5)
```

```
# vẽ biểu đồ trung bình cộng
```


```
plot.ts(king.ma)
```



Biểu đồ tuổi thọ của vua Anh Quốc với SMA = 5

Biểu đồ trên cho thấy vẫn còn khá nhiều độ dao động ngẫu nhiên với SMA=5. Để ước tính T chính xác hơn, chúng ta có thể tăng hệ số SMA lên 8:

```
king.ma8 = SMA(ts.kings, n=8)
plot.ts(king.ma8)
```



Biểu đồ tuổi thọ của vua Anh Quốc với SMA = 8

Biểu đồ trên cho thấy với SMA=8, chúng ta có một bức tranh rõ nét hơn về xu hướng. Chúng ta thấy rằng tuổi thọ của vua Anh có vẻ giảm từ 55 tuổi đến 38 tuổi trong 20 vị vua đầu, và tăng sau đó đến 73 tuổi (vị vua thứ 40).

22.3.2 Đối với dữ liệu có yếu tố seasonal

Như đề cập trên, các dữ liệu có yếu tố seasonal, chúng ta sẽ phân tích theo mô hình $Y_t = S_t + T_t + E_t$. Chúng ta có thể dùng hàm `decompose()` có sẵn trong R cho phân tích. Quay lại ví dụ về số trẻ em mới sinh, chúng ta phân tích như sau:

```
births = scan("../births.txt")
ts.births = ts(births, frequency=12, start=c(1946, 1))
comp = decompose(ts.births)
```

Hàm `decompose()` sẽ cung cấp cho chúng ta biết 3 thành phần trong dữ liệu như sau:

Phần liên quan đến seasonal (trích kết quả tiêu biểu):

\$seasonal

	Jan	Feb	Mar	Apr	May
1946	-0.6771947	-2.0829607	0.8625232	-0.8016787	0.2516514
1947	-0.6771947	-2.0829607	0.8625232	-0.8016787	0.2516514
	Jun	Jul	Aug	Sep	Oct
1946	-0.1532556	1.4560457	1.1645938	0.6916162	0.7752444
1947	-0.1532556	1.4560457	1.1645938	0.6916162	0.7752444
	Nov	Dec			
1946	-1.1097652	-0.3768197			
1947	-1.1097652	-0.3768197			

Chú ý trong phần seasonal, yếu tố seasonal cao nhất là tháng 7 (1.46) và thấp nhất là tháng 2 (-2.08). Các kết quả này cho thấy tháng có nhiều trẻ sinh nhất là tháng 7 và thấp nhất là tháng 2.

Phần liên quan đến trend cho từng năm và tháng:

\$trend

	Jan	Feb	Mar	Apr	May	Jun	Jul
1946	NA	NA	NA	NA	NA	NA	23.98433
1947	22.35350	22.30871	22.30258	22.29479	22.29354	22.30562	22.33483
1948	22.43038	22.43667	22.38721	22.35242	22.32458	22.27458	22.23754
1949	22.06375	22.08033	22.13317	22.16604	22.17542	22.21342	22.27625
1950	23.21663	23.26967	23.33492	23.42679	23.50638	23.57017	23.63888
1951	24.00083	24.12350	24.20917	24.28208	24.35450	24.43242	24.49496
1952	24.27204	24.27300	24.28942	24.30129	24.31325	24.35175	24.40558
1953	24.78646	24.84992	24.92692	25.02362	25.16308	25.26963	25.30154
1954	25.92446	25.92317	25.92967	25.92137	25.89567	25.89458	25.92963
1955	25.64612	25.78679	25.93192	26.06388	26.16329	26.25388	26.35471
1956	27.21104	27.21900	27.20700	27.26925	27.35050	27.37983	27.39975
1957	27.44221	27.40283	27.44300	27.45717	27.44429	27.48975	27.54354
1958	27.68642	27.76067	27.75963	27.71037	27.65783	27.58125	27.49075
1959	26.96858	27.00512	27.09250	27.17263	27.26208	27.36033	NA

	Aug	Sep	Oct	Nov	Dec
1946	23.66213	23.42333	23.16112	22.86425	22.54521
1947	22.31167	22.26279	22.25796	22.27767	22.35400
1948	22.21988	22.16983	22.07721	22.01396	22.02604
1949	22.35750	22.48862	22.70992	22.98563	23.16346
1950	23.75713	23.86354	23.89533	23.87342	23.88150
1951	24.48379	24.43879	24.36829	24.29192	24.27642
1952	24.44475	24.49325	24.58517	24.70429	24.76017
1953	25.34125	25.42779	25.57588	25.73904	25.87513
1954	25.98246	26.01054	25.88617	25.67087	25.57312
1955	26.40496	26.45379	26.64933	26.95183	27.14683
1956	27.44150	27.45229	27.43354	27.44488	27.46996
1957	27.56933	27.63167	27.67804	27.62579	27.61212
1958	27.46183	27.42262	27.34175	27.25129	27.08558
1959	NA	NA	NA	NA	NA


và sau cùng là phần ngẫu nhiên (chỉ liệt kê vài kết quả)

```
$random
```

	Jan	Feb	Mar	Apr	May
1946	NA	NA	NA	NA	NA
1947	-0.237305288	0.863252404	0.543893429	0.175887019	-0.793193109
1948	0.183819712	-0.318705929	0.340268429	0.121262019	-0.354234776
1949	0.161444712	0.002627404	-0.571689904	-0.749362981	-0.666063109
1950	0.064569712	-0.292705929	0.479560096	1.047887019	1.561973558

Thay vì nhìn con số, chúng ta có thể vẽ biểu đồ các kết quả trên qua hàm plot như sau:

```
comp = decompose(ts.births)
plot(comp)
```




Biểu đồ trên phân tích phần “observed” thành 3 phần: trend, seasonal, và random. Chúng ta thấy số trẻ em mới sinh giảm trong năm 1947 và sau đó thì tăng hàng năm, nhưng trong mỗi năm số trẻ em mới sinh biến đổi theo mùa. Còn phần ngẫu nhiên thì có vẻ độc lập với thời gian.

Điều chỉnh cho ảnh hưởng của season

Một cách để “hiệu” xu hướng biến đổi là hiệu chỉnh cho yếu tố seasonal. Trong mô hình cộng hưởng, cách hiệu chỉnh đơn giản nhất là lấy hiệu số giữa giá trị quan sát và các tham số của yếu tố seasonal:

```
adj.births = ts.births-comp$seasonal  
plot(adj.births)
```



Trong biểu đồ trên, phần ảnh hưởng của mùa đã được loại bỏ, và phần còn lại chỉ phản ánh xu hướng - trend và phần ngẫu nhiên.

22.4 Tiên lượng bằng các phương pháp Exponential Smoothing

22.4.1 Phương pháp simple exponential smoothing

Nếu dữ liệu có thể mô tả bằng một mô hình cộng hưởng và không có yếu tố mùa, phương pháp *simple exponential smoothing* (SES, một số sách còn gọi là *single exponential smoothing*) là một cách tiên lượng trong một quãng thời gian ngắn. Để giải thích phương pháp này, tôi sẽ bắt đầu bằng những tiên lượng đơn giản.

Một cách “ngây thơ”, giá trị tiên lượng cho tương lai tùy thuộc vào giá trị quan sát trước đó. Gọi giá trị tương lai là Y_{t+1} và giá trị hiện tại là Y_t , phát biểu trên có nghĩa là:

$$Y_{t+1} = Y_t$$

Một cách ngây thơ khác là dùng trung bình trong quá khứ tính đến thời điểm t .

$$Y_{t+1} = \frac{1}{T} \sum_{i=1}^T Y_i$$

Nhưng phương pháp trung bình này giả định rằng tất cả các giá trị quá khứ có trọng số như nhau. Giả định này không hợp lí, vì đối với tiên đoán, các giá trị gần nhất phải có trọng số cao hơn các giá trị cũ. Do đó, phương pháp SES phát biểu rằng:

$$Y_{t+1} = \alpha Y_t + \alpha (1 - \alpha) Y_{t-1} + \alpha (1 - \alpha)^2 Y_{t-2} + \dots$$

Trong đó, α được gọi là *smoothing parameter*. Do đó, mượt mà hoá (smoothing) được kiểm soát bằng một trọng số α (cũng có thể xem là thông số) có giá trị từ 0 đến 1. Alpha bằng 0 hay gần 0 có nghĩa là trọng số cho số liệu trước đó không cao trong tiên lượng giá trị kế tiếp. Để thấy ý nghĩa đó, chúng ta thử xem qua vài giá trị trong bảng sau:

GIÁ TRỊ	Alpha= 0.2	Alpha= 0.4	Alpha= 0.6	Alpha= 0.8
Y_t	0.2	0.4	0.6	0.8
Y_{t-1}	0.16	0.24	0.24	0.16
Y_{t-2}	0.128	0.144	0.096	0.032
Y_{t-3}	0.1024	0.0864	0.0384	0.0064
Y_{t-4}	$(0.2)(0.8)^4$	$(0.4)(0.6)^4$	$(0.6)(0.4)^4$	$(0.8)(0.2)^4$
Y_{t-5}	$(0.2)(0.8)^5$	$(0.4)(0.6)^5$	$(0.6)(0.4)^5$	$(0.8)(0.2)^5$

Để minh họa cho tiên lượng bằng phương pháp SES, tôi sẽ dùng dữ liệu về lượng mưa hàng năm từ 1813 đến 1912 (của Hipel và McLeod):

```
# Đọc dữ liệu, bỏ dòng đầu
rain = scan("~/Documents/Data/rainfalls.txt", skip=1)
ts.rain = ts(rain, start=c(1813))
plot.ts(ts.rain)
```

Để tiên lượng bằng phương pháp, chúng ta dùng hàm `HoltWinters()` với tham số `beta=FALSE` và `gamma=FALSE` (tham số `beta` và `gamma` parameters được dùng cho mục đích khác).

```
forecast = HoltWinters(ts.rain, beta=F, gamma=F)
forecast
```



Hàm `HoldWinters` cho kết quả $\alpha = 0.024$ và $\text{Coefficients} = 24.678$. Vì α gần bằng 0, các giá trị tiên lượng dựa vào các giá trị gần nhất không có trọng số cao. Hàm `HoldWinters` cho ra kết quả tiên lượng trong một biến / đối tượng có tên là **fitted**. Chúng ta có thể xem qua giá trị tiên lượng bằng bảng số liệu và biểu đồ:

```
forecast$fitted
plot(ts.rain); plot(forecast)
```

sẽ cho ra kết quả (trích):

```
> forecast$fitted
Time Series:
Start = 1814
End = 1912
Frequency = 1
```

	xhat	level
1814	23.56000	23.56000
1815	23.62054	23.62054
1816	23.57808	23.57808
1817	23.76290	23.76290
...		
1910	24.57541	24.57541
1911	24.59433	24.59433
1912	24.59905	24.59905



Biểu đồ cho thấy giá trị gốc và tiên lượng (đường màu đỏ) của lượng mưa ở London từ năm 1814 đến 1912. Cũng như mô hình hồi qui tuyến tính, chúng ta cũng có thể tính toán các chỉ số phản ánh độ chính xác như tổng bình phương sai số (sum of squared errors) bằng cách trích SSE từ đối tượng forecast:

```
forecast$SSE
```

Như đề cập trên, hàm HoltWinters() chỉ tiên lượng trong khoảng thời gian của dữ liệu gốc. Nhưng trong thực tế, chúng ta muốn tiên lượng trong tương lai. Để tiên lượng giá trị tương lai, chúng ta có thể dùng hàm forecast. HoltWinters() trong package chuyên dụng forecast. Chẳng hạn như chúng ta muốn tiên lượng lượng mưa trong 5 năm tới, chúng ta dùng hàm sau đây:


```
library(forecast)
forecast2 = forecast.HoltWinters(forecast, h=5)

> forecast2
```

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
1913	24.67819	19.17493	30.18145	16.26169	33.09470
1914	24.67819	19.17333	30.18305	16.25924	33.09715
1915	24.67819	19.17173	30.18465	16.25679	33.09960
1916	24.67819	19.17013	30.18625	16.25434	33.10204
1917	24.67819	19.16853	30.18785	16.25190	33.10449

Hàm HoltWinters cung cấp giá trị tiên lượng và khoảng tin cậy 80%, 95%. Chẳng hạn như lượng mưa cho năm 1917 được dự đoán là 24.68 inches, với khoảng tin cậy 95% từ 16.25 đến 33.10. Một cách dễ nhìn hơn là dùng biểu đồ:

```
plot.forecast(forecast2)
```




Biểu đồ trên vẽ các giá trị tiên lượng bằng màu xanh, với khoảng tin cậy 80% và 95% trong vùng màu xám.

22.4.2 Tiên lượng bằng phương pháp Holt Exponential Smoothing

Một phương pháp khác có ứng dụng cho các dữ liệu không có yếu tố mùa là phương pháp Holt Exponential Smoothing (HES). Phương pháp HES ứng dụng cho *tiên lượng ngắn hạn* khi dữ liệu có xu hướng tăng hoặc giảm (nhưng không có yếu tố mùa).

Phương pháp HES được hình thành từ 2 thông số smoothing là alpha và beta, có giá trị từ 0 đến 1. Alpha là trọng số của giá trị tại thời điểm hiện tại. Beta là độ dốc (slope) cho phần trend ngay tại thời điểm hiện tại. Một ví dụ ứng dụng của phương pháp HES là dữ liệu về đường kính của đường viên váy phụ nữ đo lường từ 1866 đến 1911.

```
skirts = scan("~/Documents/Data/skirts.txt", skip=5)
ts.skirts = ts(skirts, start=c(1866))
plot.ts(ts.skirts)
```




Chúng ta thấy rằng đường kính váy tăng từ 1866 đến 1880 (tăng khoảng 600), và sau đó thì giảm đến 1911 (giảm ~520). Để tiên lượng, chúng ta cần phải dùng hàm `HoltWinters()` để phân tích dữ liệu.

```
forecast1 = HoltWinters(ts.skirts, gamma=F)
forecast1
```


Cho ra thông số $\alpha = 0.84$ và $\beta = 1$. Hai thông số này cho chúng ta biết giá trị hiện hành có trọng số khá cao hay rất cao trong việc tiên lượng giá trị tương lai. Điều này khá nhất quán với biểu đồ dưới đây phản ánh giá trị quan sát và giá trị tiên lượng rất nhất quán nhau:

```
plot(forecast1)
```



Cũng như phương pháp SES, với phương pháp HES, chúng ta cũng có thể tiên lượng cho một tương lai ngắn hạn bằng hàm `forecast.HoltWinters()` package chuyên dụng `forecast`. Chẳng hạn như tiên đoán cho 10 năm:

```
forecast1 = HoltWinters(ts.skirts, gamma=F)
forecast2 = forecast.HoltWinters(forecast1, h=10)
plot.forecast(forecast2)
```



Trong biểu đồ trên, đường màu xanh thể hiện giá trị tiên lượng, cùng khoảng tin cậy 95% và 80% (vùng màu xanh và màu xám).

22.4.3 Tiên lượng bằng phương pháp Holt-Winters Exponential Smoothing


Nếu dữ liệu có thể mô tả bằng một mô hình cộng hưởng, nhưng có yếu tố mùa, phương pháp Holt-Winters Exponential Smoothing có thể dùng cho tiên lượng ngắn hạn. Phương pháp này dùng 3 thông số smoothing (α , β và γ) để thể hiện dữ liệu. Thông số alpha là trọng số của giá trị hiện tại; thông số beta thể hiện độ dốc của giá trị hiện tại; và thông số gamma thể hiện mùa - seasonality. Dĩ nhiên, tất cả các thông số α , β và γ đều có giá trị giữa 0 và 1.

Để minh họa cho phương pháp Holt-Winters Exponential Smoothing, chúng ta quay lại với ví dụ về lượng hàng lưu niệm bán ra từ một cửa hàng ở Queensland. Chú ý chúng ta dùng đơn vị log.

```
souv = scan("~/Documents/Data/souvenirs.txt")
ts.souv = ts(souv, frequency=12, start=c(1987, 1))
log.souv = log(ts.souv)
forecast1 = HoltWinters(log.souv)
```


Chúng ta có hệ số $\alpha = 0.413$, $\beta = 0$, và $\gamma = 0.956$. Giá trị của thông số alpha (0.41) tương đối thấp, cho thấy giá trị hiện tại phụ thuộc vào các giá trị gần đây và một số giá trị trong quá khứ khá xa. Thông số beta = 0 cho thấy độ dốc của trend không có "cập nhật hoá" trong thời gian qua. Thông số gamma = 0.956 rất cao, cho thấy ảnh hưởng của yếu tố mùa tại thời điểm hiện tại phụ thuộc vào các giá trị gần nhất. Chúng ta có thể vẽ biểu đồ để biết giá trị tiên lượng và thực tế rất gần nhau, chứng tỏ mô hình tiên lượng rất tốt.

```
plot(forecast1)
```



Chúng ta cũng có thể tiên lượng cho tương lai 5 năm (tức 60 tháng):

```
forecast1 = HoltWinters(log.souv)
forecast2 = forecast.HoltWinters(forecast1, h=60)
plot.forecast(forecast2)
```



Như thường lệ, hàm `plot.forecast` vẽ giá trị tiên lượng bằng màu xanh, kèm theo khoảng tin cậy 80% và 95% trong vùng màu xám nhạt và xám đậm.

22.5 Mô hình ARIMA

Thật ra, phải nói là “các mô hình ARIMA” mới đúng, vì đó là tập hợp một số mô hình phân tích và tiên lượng cho dữ liệu theo thời gian. Các phương pháp tôi vừa mô tả trên đây (như Simple Exponential Smoothing, Holt Exponential Smoothing, Holt-Winters Exponential Smoothing) là những *phương pháp tiên lượng* mà không dựa vào những giả định về mối tương quan giữa các giá trị liên tiếp nhau trong dãy số liệu (còn gọi là **autocorrelation**, có lẽ tạm dịch là tương quan liên hoàn). Tuy nhiên, nếu chúng ta muốn tiên lượng khoảng tin cậy bằng các phương pháp exponential smoothing thì giả định là sai số (error) của các giá trị tiên lượng không liên quan nhau và tuân theo luật phân bố chuẩn với trung bình 0 và phương sai bất biến.

Mặc dù các phương pháp exponential smoothing không đặt giả định về tương quan liên hoàn, trong một số trường hợp, giá trị tiên lượng sẽ chính xác hơn nếu hiệu chỉnh cho hệ số tương quan. Các mô hình “Autoregressive

Integrated Moving Average” hay ARIMA là những mô hình thống kê dùng để mô hình hoá phần ngẫu nhiên của một dãy số liệu theo thời gian. Trong các mô hình ARIMA, hệ số tương quan liên hoàn được điều chỉnh.

22.5.1 Khái niệm sai phân (differencing)

Dữ liệu ổn định và dữ liệu không ổn định

Các mô hình ARIMA được ứng dụng thường xuyên cho các dãy dữ liệu theo thời gian ổn định (thuật ngữ tiếng Anh là *stationary time series*). Trong thống kê, dữ liệu theo thời gian ổn định (sẽ gọi tắt là **dữ liệu ổn định**) có nghĩa là dữ liệu mà các chỉ số thống kê như trung bình, phương sai, hệ số tương quan liên hoàn, v.v.. đều không thay đổi theo thời gian.


Ngược lại, khi các chỉ số thống kê, nhất là trung bình và phương sai, có xu hướng biến chuyển theo thời gian, thì chúng ta có một **dữ liệu bất ổn định** -- *non-stationary time series*. Với dữ liệu bất ổn định, chúng ta phải bắt đầu bằng cách tính *sai phân* (difference) dữ liệu cho đến khi nó trở thành ổn định.

Sai phân bậc 1 của một dãy số liệu theo thời gian là hiệu số của số liệu tại thời điểm t và số liệu của một thời điểm $t-1$. Nếu Y_t là giá trị tại thời điểm t , và Y_{t-1} tại thời điểm $t-1$, thì sai phân tại thời điểm t chính là $Y_t - Y_{t-1}$. Sai phân này có khi còn gọi là *first difference*.

Nếu sai phân bậc 1 của Y ổn định dữ liệu và hoàn toàn ngẫu nhiên (tức không có autocorrelation), thì Y còn được mô tả bằng mô hình *bước đi ngẫu nhiên* - tức *random walk model*.


Nếu sai phân bậc 1 của Y ổn định nhưng không ngẫu nhiên (tức là giá trị tại thời điểm t có liên quan với giá trị trước) thì cần phải có một **mô hình ARIMA** để mô tả dữ liệu.

Nếu chúng ta phải tính sai phân dữ liệu d lần (hay bậc sai phân bậc d) để có được dữ liệu ổn định, thì chúng ta có mô hình ARIMA(p, d, q); trong đó, d là bậc thứ tự [order] của sai phân. Trong R, có hàm **diff()** với tham số **differences = d** có thể dùng để tính sai phân. Chẳng hạn như đối với dữ liệu về đường kính của vảy từ 1866 đến 1911 là dữ liệu không ổn định vì trung bình biến chuyển theo thời gian (xem biểu đồ dưới đây):




Chúng ta có thể tính sai phân cho dữ liệu trên:

```
skirts = scan("~/Documents/Data/skirts.txt", skip=5)
ts.skirts = ts(skirts, start=c(1866))
# tính sai phân
dif.skirts = diff(ts.skirts, differences=1)
plot.ts(dif.skirts)
```




Kết quả cho thấy dữ liệu có vẻ không ổn định vì trung bình thay đổi theo thời gian. Chúng ta thử sai phân bậc 2:

```
dif.skirts2 = diff(ts.skirts, differences=2)
plot.ts(dif.skirts2)
```


Biểu đồ trên cho thấy sai phân bậc 2 đã làm cho dữ liệu ổn định (không có xu hướng tăng/giảm theo thời gian). Phương sai cũng có vẻ ổn định. Như vậy, sai phân bậc 2 ($d = 2$) có vẻ thích hợp cho dữ liệu.

Do đó, mô hình ARIMA bây giờ là $ARIMA(p, 2, q)$. Vấn đề kế tiếp là xác định tham số p và q . Quay lại ví dụ về tuổi thọ của các vị vua Anh Quốc, chúng ta thấy dữ liệu không phải thuộc loại ổn định.



Bây giờ, chúng ta tính sai phân bậc 1 cho dữ liệu:

```
kings = scan("~/Documents/Data/kings.txt")
ts.kings = ts(kings)
dif.kings = diff(ts.kings, difference=1)
plot.ts(dif.kings)
```



Biểu đồ trên cho thấy dữ liệu đã ổn định với sai phân bậc 1. Mô hình ARIMA(p, 1, q) có lẽ thích hợp cho dữ liệu về tuổi thọ của các vị vua Anh Quốc.

Hai ví dụ trên cho thấy khi tính sai phân, chúng ta loại bỏ phần trend của dữ liệu theo thời gian. Phần còn lại chính là phần ngẫu nhiên hay irregular hay random. Bây giờ chúng ta sẽ xem xét đến hệ số tương quan liên hoàn xem có thể giúp gì cho chúng ta mô hình hoá dữ liệu.

22.5.2 Chọn mô hình ARIMA

Mô hình ARIMA(p, d, q) có ít nhất 3 thông số. Chúng ta đã thấy cách chọn/xác định thông số d . Nhưng thông số p và q có thể xác định qua phân tích biểu đồ tương quan liên hoàn (correlogram) và biểu đồ tương quan liên hoàn từng phần (partial correlogram) của dữ liệu ổn định.

Khái niệm **autocorrelation – tương quan liên hoàn** có thể giải thích ngắn gọn như sau. Gọi $Y_1, Y_2, Y_3, \dots, Y_N$ là một dãy số liệu theo thời gian được ghi nhận ở thời điểm $t_1, t_2, t_3, \dots, t_N$. Autocorrelation được định nghĩa là:

$$r_k = \frac{\sum_{i=1}^{N-k} (Y_i - \bar{Y})(Y_{i+k} - \bar{Y})}{\sum_{i=1}^N (Y_i - \bar{Y})^2}$$

Như vậy, autocorrelation chính là một hệ số tương quan. Nhưng thay vì tương quan giữa 2 biến X và Y , thì autocorrelation là tương quan giữa Y_i và Y_{i+k} . Autocorrelation bậc 1 (tức $k=1$) thường được sử dụng để xác định hiện tượng phi ngẫu nhiên (non-randomness). Trong R có hàm **acf()** và **pccf()** có thể dùng để tính toán hệ số autocorrelation và hệ số autocorrelation từng phần.


Chúng ta dùng dữ liệu về tuổi thọ của các vua Anh Quốc làm ví dụ ước tính autocorrelation và autocorrelation từng phần, và qua đó xác định thông số p và q cho mô hình ARIMA.

```
kings = scan("~/Documents/Data/kings.txt")
ts.kings = ts(kings)
dif.kings = diff(ts.kings, difference=1)
acf(dif.kings, lag.max=20, plot=F)
acf(dif.kings, lag.max=20)
```

Chúng ta sẽ có kết quả như sau:

```
> acf(dif.kings, lag.max=20, plot=F)
Autocorrelations of series 'dif.kings', by lag
0      1      2      3      4      5      6      7      8
1.000 -0.360 -0.162 -0.050  0.227 -0.042 -0.181  0.095  0.064
 9     10     11     12     13     14     15     16     17
-0.116 -0.071  0.206 -0.017 -0.212  0.130  0.114 -0.009 -0.192
18     19     20
0.072  0.113 -0.093
```

hay thể hiện qua biểu đồ correlogram:




Chúng ta thấy hệ số autocorrelation ở sai phân bậc 1 (-0.360) quá ngưỡng ý nghĩa thống kê. Ngưỡng ý nghĩa thống kê là hai đường đứt đoạn màu xanh trong biểu đồ. Tuy nhiên, hệ số tương quan của các bậc khác thì đều 0, vì nằm trong vùng không có ý nghĩa thống kê.

Tương tự, chúng ta xem xét hệ số autocorrelation từng phần bằng hàm `pacf()`:

```
pacf(dif.kings, lag.max=20, plot=F)
pacf(dif.kings, lag.max=20)

> pacf(dif.kings, lag.max=20, plot=F)
Partial autocorrelations of series 'dif.kings', by lag
      1      2      3      4      5      6      7      8      9     10
-0.360 -0.335 -0.321  0.005  0.025 -0.144 -0.022 -0.007 -0.143 -0.167
     11     12     13     14     15     16     17     18     19     20
  0.065  0.034 -0.161  0.036  0.066  0.081 -0.005 -0.027 -0.006 -0.037
```



Biểu đồ và kết quả trên cho thấy hệ số autocorrelation từng phần ở bậc (lags hay sai phân) 1, 2 và 3 vượt qua ngưỡng ý nghĩa thống kê và âm (lag 1: -0.360, lag 2: -0.335, lag 3: -0.321). Tuy nhiên, hệ số này giảm dần và gần như bằng 0 sau lag 3.

Qua phân tích autocorrelation và autocorrelation từng phần như trên, chúng ta có thể xác định 2 thông số p và q cho mô hình ARMA (autoregressive moving average) cho dữ liệu theo thời gian với sai phân bậc 1:

- Mô hình ARMA(3,0), tức là mô hình autoregressive với $p=3$ có vẻ là tối ưu, vì autocorrelogram từng phần bằng 0 sau lag 3.
- Mô hình ARMA(0,1), tức là mô hình moving average với $q=1$, vì autocorrelogram bằng 0 sau lag 1.

Ở đây, chúng ta cần dùng *nguyên lý tiết kiệm* (Principle of Parsimony) để quyết định mô hình nào là tốt nhất. Nói cách khác, chúng ta muốn tìm mô hình có ít thông số nhất nhưng mô tả dữ liệu tốt nhất. Mô hình ARMA(3, 0) có 3 thông số, mô hình ARMA(0, 1) có 1 thông số, và mô hình chung ARMA(p , q) có ít nhất là 2 thông số. Do đó, mô hình ARMA(0,1) trong trường hợp này là mô hình tốt nhất.

Mô hình Moving Average (MA model)

Mô hình MA chủ yếu quan tâm đến white noise (Z_t) chứ không phải Y_t . Mô hình MA bậc q , viết tắt là MA(q), có thể phát biểu như sau:

$$Y_t = Z_t + \theta_1 Z_{t-1} + \theta_2 Z_{t-2} + \theta_3 Z_{t-3} + \dots + \theta_q Z_{t-q}$$

Trong đó, $\theta_1, \theta_2, \theta_3, \dots, \theta_q$ là thông số của mô hình. Mô hình này có q sai phân (lag), và Z_t là white noise.

Mô hình ARMA(0, 1) thực chất là một mô hình moving average – trung bình động bậc 1. Nói cách khác, đó là **mô hình MA(1)**. Mô hình này có thể viết như sau:

$$Y_t - \mu = Z_t - (\theta \times Z_{t-1})$$

trong đó, Y_t là một dãy số liệu ổn định và chúng ta nghiên cứu sai phân bậc 1; μ là trung bình Y_t , Z_t là yếu tố ngẫu nhiên với trung bình 0 và phương sai bất biến (Z_t còn gọi là “white noise”); và θ là thông số cần ước tính.

Mô hình MA (moving average) thường được sử dụng để mô hình dữ liệu theo thời gian với đặc điểm là các số liệu phụ thuộc nhau trong một khoảng thời gian ngắn. Trong thực tế, mô hình MA có thể dùng để mô tả phần ngẫu nhiên của tuổi thọ của các vua, vì chúng ta kì vọng rằng tuổi thọ của một vị vua có thể có ảnh hưởng đến tuổi thọ của vị vua kế tiếp hay vài vị vua tiếp theo, nhưng khó có thể ảnh hưởng đến các vua sau một thời gian dài.

Tìm thông số cho mô hình ARIMA bằng hàm `auto.arima()`

Các phân tích trên đây để tìm thông số cho mô hình $ARIMA(p, d, q)$ có thể nói là mang tính thủ công. Trong thực tế, chúng ta có thể sử dụng hàm `auto.arima()` trong package chuyên dụng **forecast** để tìm các thông số từ dữ liệu gốc. Để “kiểm tra” hàm `auto.arima()`, chúng ta thử mô phỏng một dãy dữ liệu theo thời gian với mô hình $ARIMA(1, 0, 1)$, với thông số $p = 0.3$ và $q = 0.6$. Mô phỏng có thể dùng hàm `arima.sim` có sẵn trong R:

```
test.data = arima.sim(model=list(ar=0.3, ma=0.6),
n=1000, n.start=200)
```

Hàm trên mô phỏng 1000 giá trị theo mô hình $AR(0.3)$ và $MA(0.6)$. Lệnh `n.start=200` có nghĩa là giá trị mô phỏng chỉ lấy từ 201 trở lên để đảm bảo ổn định của mô phỏng.

Bây giờ chúng ta thử dùng hàm `auto.arima()` để tìm mô hình tốt nhất:

```
library(forecast)
```

```
auto.arima(test.data)
```

Kết quả cho thấy:

```
> auto.arima(test.data)
```

```
Series: test.data
```

```
ARIMA(1,0,1) with zero mean
```

```
Coefficients:
```

```
ar1      ma1
```

```
0.3641  0.5797
```

```
s.e.  0.0377  0.0330
```

Kết quả đề nghị mô hình $ARIMA(1, 0, 1)$, tức là đúng với mô hình chúng ta mô phỏng. Thông số là $AR(0.36)$ gần bằng với giá trị thật 0.30, và $MA(0.58)$ gần với giá trị thật là 0.60. Dĩ nhiên giá trị mô phỏng không thể nào chính xác với giá trị thật, nhưng kết quả của hàm `auto.arima()` rõ ràng là đề nghị mô hình hợp lý.

Bây giờ, chúng ta quay lại với dữ liệu thực tế để dùng `auto.arima()` tìm thông số cho dữ liệu về tuổi thọ của vua:

```
kings = scan("~/Documents/Data/kings.txt")
library(forecast)
auto.arima(kings)
```

Với kết quả:

```
> auto.arima(kings)
Series: kings
ARIMA(0,1,1) with drift
Coefficients:
          ma1      drift
      -0.7463   0.3882
s.e.    0.1294   0.6603
```

Kết quả trên cho thấy mô hình thích hợp là ARIMA(0, 1, 1). Nói cách khác, thông số của mô hình là $p=0$, $d=1$, $q=1$. Mô hình này nhất quán với phân tích thủ công mà chúng ta đã thực hiện.

Mô hình autoregression (AR model)


Ý tưởng của mô hình autoregressive (AR) là giá trị quan sát hiện tại phụ thuộc vào các giá trị trước đó. Gọi Z_t là một white noise. Nếu chúng ta mô hình Z_t bằng một phương trình bậc 2 như sau:

$$Y_t = Y_{t-1} - 0.9Y_{t-2} + Z_t$$

Phương trình này phát biểu rằng giá trị của thời điểm hiện tại phụ thuộc vào (a) giá trị của thời điểm trước hiện nay, và (b) giá trị của thời điểm trước đó. Đây là mô hình autoregressive (AR).

Ví dụ: Khẩu trang che mặt chống bụi núi lửa ở Bắc bán cầu. Dữ liệu sau đây bao gồm chỉ số về khẩu trang chống bụi được đo lường từ 1500 đến 1969 tại vùng Bắc bán cầu (dữ liệu của Hipel và Mcleod, 1994). Chúng ta đọc dữ liệu vào R và hoán chuyển sang dữ liệu theo thời gian với hàm `ts` như sau:

```
vc = scan("~/Documents/Data/vulcano.txt", skip=1)
ts.vc = ts(vc, start=c(1500))
plot.ts(ts.vc)
```



Biểu đồ trên cho thấy những dao động ngẫu nhiên của số liệu có vẻ bất biến theo thời gian. Do đó, một mô hình cộng hưởng có vẻ thích hợp cho việc mô tả dữ liệu. Ngoài ra, biểu đồ trên cũng cho thấy phương sai độc lập với thời gian. Do đó, chúng ta không cần phải tính sai phân cho dữ liệu để dùng mô hình ARIMA, nhưng có thể áp dụng mô hình ARIMA trực tiếp vào dữ liệu gốc (tức $d = 0$). Chúng ta tìm các thông số bằng hàm `auto.arima()` như sau:

```
> auto.arima(vc)
Series: vc
ARIMA(1,0,2) with non-zero mean

Coefficients:
          ar1          ma1          ma2  intercept
          0.4723      0.2694      0.1279          57.5178
s.e.      0.0936      0.0969      0.0752          8.4883
```

Kết quả trên “đề nghị” mô hình ARIMA(1, 0, 2). Mô hình có 3 thông số. Tuy nhiên, nếu chúng ta dùng tiêu chuẩn BIC (Bayesian Information Criterion) thì mô hình có lẽ đơn giản hơn:

```
> auto.arima(vc, ic="bic")
Series: vc
ARIMA(2,0,0) with non-zero mean

Coefficients:
          ar1          ar2  intercept
          0.7533      -0.1268          57.5274
s.e.      0.0457      0.0458          8.5958
```


Với tiêu chuẩn BIC, chúng ta có mô hình ARMA(2, 0). Mô hình này có 2 thông số, và so với các mô hình khác, đây là mô hình tối ưu. Đây là **mô hình autoregressive** bậc 2, hay AR(2). Mô hình này phát biểu rằng

$$Y_t - \mu = \beta_1(Y_{t-1} - \mu) + \beta_2(Y_{t-2} - \mu) + Z_t$$

Trong đó Y_t là số liệu tại thời điểm t , μ là số trung bình của dãy số liệu, β_1 và β_2 là thông số cần tìm, và Z_t là yếu tố ngẫu nhiên (white noise) với trung bình 0 và phương sai bất biến.

Model AR (autoregressive) thường được sử dụng để mô tả dãy số liệu theo thời gian mà sự tương quan giữa các số liệu nối tiếp nhau *mang tính lâu dài*. Mô hình này thích hợp cho những trường hợp như số liệu về bụi núi lửa vì chúng ta kì vọng rằng bụi núi lửa của một năm còn ảnh hưởng đến nhiều năm sau, bởi vì bụi không thể nào biến mất một cách nhanh chóng.

Nếu mô hình ARMA(2, 0), tức $p=2$, $q=0$ được dùng để mô tả dữ liệu bụi núi lửa, thì điều này có nghĩa là chúng ta có mô hình ARIMA(2, 0, 0), tức $p=2$, $d=0$, và $q=0$.

22.5.3 Tiên lượng dùng mô hình ARIMA

Sau khi xác định mô hình tốt nhất, bước kế tiếp là ước tính thông số và dùng thông số để làm một mô hình tiên lượng các số liệu tương lai. Trong R có hàm `arima()` dùng để ước tính thông số của mô hình ARIMA.

Chúng ta dùng số liệu về tuổi lúc tử vong của các vua Anh Quốc làm ví dụ cho mô hình ARIMA. Nhớ rằng, chúng ta đã có mô hình “tối ưu” cho dữ liệu là ARIMA(0, 1, 1). Trong R, chúng ta dùng lệnh `order=c(p, d, q)`:

```
kings = scan("~/Documents/Data/kings.txt")
ts.kings = ts(kings)
arima1 = arima(ts.kings, order=c(0, 1, 1))
```

Với kết quả như sau:

```
> arima1
Series: ts.kings
ARIMA(0,1,1)
```

```
Coefficients:
          ma1
        -0.7218
s.e.      0.1208
```

```
sigma^2 estimated as 230.4:  log likelihood=-170.06
```

```
AIC=344.13   AICc=344.44   BIC=347.56
```

Như đề cập trên, nếu chúng ta áp dụng mô hình ARIMA(0, 1, 1), thì điều đó cũng tương đương với áp dụng mô hình ARMA(0, 1) vào dữ liệu sai phân bậc 1. Mô hình ARMA(0, 1) có thể viết như sau:

$$Y_t - \mu = Z_t - \theta Z_{t-1}$$

Trong kết quả phân tích trên, $\theta = -0.7218$.

Chúng ta cũng có thể tiên lượng bằng cách dùng hàm forecast.


Arima() trong package forecast:

```
library(forecast)
forecast1 = forecast.Arima(arima1, h=5)
forecast1
plot.forecast(forecast1)
```

Kết quả trình bày cho 5 năm tới với khoảng tin cậy 80% và 95%.

```
> forecast1
```

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
43	67.75063	48.29647	87.20479	37.99806	97.50319
44	67.75063	47.55748	87.94377	36.86788	98.63338
45	67.75063	46.84460	88.65665	35.77762	99.72363
46	67.75063	46.15524	89.34601	34.72333	100.77792
47	67.75063	45.48722	90.01404	33.70168	101.79958



Tuổi thọ của vua thứ 42 là 56 tuổi. Mô hình ARIMA tiên lượng rằng vị vua 43 sẽ thọ 67.8 tuổi.

Tiên lượng dữ liệu bụi núi lửa. Quay trở lại ví dụ về bụi núi lửa, chúng ta đã xác định mô hình tối ưu là ARIMA(2, 0, 0). Để ước tính thông số mô hình này, chúng ta dùng hàm `arima`:

```
vc = scan("~/Documents/Data/vulcano.txt", skip=1)
ts.vc = ts(vc, start=c(1500))
arimal = arima(ts.vc, order=c(2,0,0))
arimal
```

Với kết quả:

```
> arimal
Series: ts.vc
ARIMA(2,0,0) with non-zero mean
Coefficients:
            ar1            ar2    intercept
            0.7533    -0.1268         57.5274
s.e.    0.0457    0.0458         8.5958
sigma^2 estimated as 4870:  log likelihood=-2662.54
AIC=5333.09    AICc=5333.17    BIC=5349.7
```

Như đề cập trên, mô hình ARIMA(2,0,0) cũng có thể viết là:

$$Y_t - \mu = \beta_1(Y_{t-1} - \mu) + \beta_2(Y_{t-2} - \mu) + Z_t$$


Kết quả trên cho thấy ước số của $\beta_1 = 0.753$ và $\beta_2 = -0.127$. Bây giờ, chúng ta có thể tiên lượng cho 31 năm sau bằng hàm `forecast.Arima()`:

```
forecast1 = forecast.Arima(arimal, h=31)
forecast1
plot.forecast(forecast1)


> forecast1
      Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95
1970      21.48131 -67.94860 110.9112 -115.2899 158.2526
1971      37.66419 -74.30305 149.6314 -133.5749 208.9033
1972      47.13261 -71.57070 165.8359 -134.4084 228.6737
1973      52.21432 -68.35951 172.7881 -132.1874 236.6161
```

1974	54.84241	-66.22681	175.9116	-130.3170	240.0018
1975	56.17814	-65.01872	177.3750	-129.1765	241.5327
1976	56.85128	-64.37798	178.0805	-128.5529	242.2554
1977	57.18907	-64.04834	178.4265	-128.2276	242.6057
1978	57.35822	-63.88124	178.5977	-128.0615	242.7780
1979	57.44283	-63.79714	178.6828	-127.9777	242.8634
...					
1998	57.52739	-63.71275	178.7675	-127.8934	242.9482
1999	57.52739	-63.71275	178.7675	-127.8934	242.9482
2000	57.52739	-63.71275	178.7675	-127.8934	242.9482

Forecasts from ARIMA(2,0,0) with non-zero mean



Forecasts from ARIMA(2,0,0) with non-zero mean



Tóm lại, qua chương này, các bạn đã làm quen với một số khái niệm và phương pháp cơ bản thường hay dùng trong phân tích dữ liệu theo thời gian. Một số phương pháp tuy nói là “cơ bản” nhưng khá phức tạp nếu mô tả bằng ngôn ngữ toán. Do đó, tôi cố gắng không trình bày các công thức toán, mà thay vào đó là ý tưởng và cách dùng R để ước tính các thông số của mô hình AR, MA, và ARIMA. Tôi hi vọng rằng sau khi đọc và hiểu hết chương này, các bạn có thể thực hiện những phân tích dữ liệu theo thời gian và có thể diễn giải kết quả một cách thuyết phục.

Chú thích

Sách về phân tích dữ liệu theo thời gian dùng R rất phong phú. Chương này được mô phỏng theo và dùng dữ liệu từ cuốn “*Forecasting: principles and practice*” của R. Hyndman và G. Athanasopoulos (Otexts, 2012; Amazon.com). Ngoài ra, cuốn “*Times Series Analysis and Its Applications (with R examples)*” của Robert Shumway và David Stoffer (Nhà xuất bản Springer) cũng rất có ích và dễ hiểu.

23

Phụ lục 1 Hàm R dùng cho phân tích

Đối với các bạn mới làm quen với R, có lẽ vấn đề nổi cộm là lúng túng, không nhớ hàm và lệnh. Tôi hiểu khó khăn đó. Dưới đây là một bảng tổng hợp các hàm cần thiết cho đọc dữ liệu, biên tập dữ liệu, phân tích mô tả, và mô hình thống kê. Tôi sắp xếp theo thứ tự của chương sách. Mô hình sắp xếp hàm là việc làm và tên hàm, một số nơi tôi cho ví dụ cụ thể. Gần như tất cả các hàm chính yếu trong sách đều được tóm lược trong bảng này. Bạn đọc có thể dùng bảng này như là một tài liệu tham khảo khi cần biết hàm R nào để phân tích dữ liệu.

Môi trường vận hành

PHÂN TÍCH / VIỆC	HÀM R
Cho biết directory hiện hành là gì	<code>getwd()</code>
Chuyển directory vận hành về c:\works	<code>setwd(c:/works)</code>
Đổi chiều rộng của sổ R thành 100 characters	<code>options(width=100)</code>
Đổi số thành 3 số thập phân (thay vì kiểu 1.2E-04)	<code>options(scipen=3)</code>
Cho biết các thông số về môi trường của R	<code>options()</code>
Liệt kê các đối tượng (objects) trong memory	<code>ls()</code>
Tìm kiếm	<code>search()</code>
Cộng, trừ, nhân, chia, lũy thừa	<code>+ - * / ^</code>
Chia số nguyên	<code>%/%</code>
Số dư từ chia 2 số nguyên	<code>%%</code>

Kí hiệu logic	
Bằng	==
Không bằng	!=
Nhỏ / lớn hơn	<, >
Nhỏ hoặc bằng, lớn hoặc bằng	<=, >=
Có phải là số missing value	is.na(x)
và (AND)	&
hoặc (OR)	
Không là (NOT)	!
Ma trận	
Số đầu tiên của biến số x	x[1]
Năm số đầu tiên của biến số x	x[1:5]
Chọn x sao cho y nhỏ hơn hoặc bằng 30	x[y<=30]
Chọn x sao cho sex bằng male	x[sex=="male"]

Đọc dữ liệu

PHÂN TÍCH / VIỆC	HÀM R
Đọc dữ liệu từ file dạng csv	read.csv()
Đọc dữ liệu từ file dạng text/ascii	read.table()
Đọc / nhập số liệu dạng tab delimited	read.delim()
Đọc từ SAS	library(foreign); read.ssd()
Đọc từ SPSS	library(foreign); read.spss()
Đọc từ Stata	library(foreign); read.dta()
Tạo data frame	dat=data. frame(x1,x2,x3)

Mô phỏng

PHÂN TÍCH / VIỆC	HÀM R
Tạo dãy số -4, -3.5, -3.0, ..., 3.0	seq(-4, 3, 0.5)
Tạo dãy số 1, 2, 3, ..., 10	1:10
Nhập số 5, 7, 8, 1 vào biến x	x = c(5, 7, 8, 1)
Lặp lại số "1" 5 lần	rep(1, 5)
Lặp "A" 4 lần	rep("A", 4)
Yếu tố 3 bậc, lặp lại 2 lần, tổng cộng 12 số	gl(3, 2, 12)
Mô phỏng	
Phân bố chuẩn (normal distribution) 1000 đối tượng, với trung bình = 0 và độ lệch chuẩn = 1	rnorm(n=1000, mean=0, sd=1)
Phân bố mũ (exponential distribution)	rexp(n, rate=1)
Phân bố gamma	rgamma(n, shape, scale=1)
Phân bố Poisson	rpois(n, lambda)
Phân bố Weibull	rweibull(n, shape, scale=1)
Phân bố Cauchy	rcauchy(n, location=0, scale=1)
Phân bố beta	rbeta(n, shape1, shape2)
Phân bố t	rt(n, df)
Phân bố Khi bình phương	rchisq(n, df)
Phân bố nhị phân (binomial)	rbinom(n, size, prob)
Phân bố geometric	rgeom(n, prob)
Phân bố hypergeometric	rhyper(nn, m, n, k)
Phân phối log normal	rlnorm(n, meanlog=0, sdlog=1)
Phân phối logistic	rlogis(n, location=0, scale=1)
Phân phối negative binomial	rnbinom(n, size, prob)
Phân phối uniform	runif(n, min=0, max=1)

Biên tập dữ liệu

PHÂN TÍCH / VIỆC	Hàm R
Tạo biến mới (\$)	<pre>dat=data.frame(x1,x2); dat\$x3 = dat\$x1 + dat\$x2</pre>
Mã hoá dữ liệu	<pre>dat\$sex[gender=="male"] <- 1; dat\$sex[gender=="female"] <- 2</pre>
Hoán chuyển dữ liệu	<pre>as.numeric(), as.character(), as.vector(), as.matrix(), as.data.frame</pre>
Data.frame như là ma trận	<pre>dat[,1] dat[,2:3] dat[2,] dat[3:8,] dat[1:5, 2:3]</pre>
Subset dữ liệu	<pre>dat2 = subset(dat, id<=5)</pre>
Sort dữ liệu	<pre>id = c(1:5) name = c("A", "B", "C", "D", "E") x = c(12, 45, 67, 32, 26) dat = data.frame(id, name, x) new.dat = dat[order(x),] new.dat = dat[-order(dat\$x),]</pre>
Merge dữ liệu	<pre>dat = merge(dat1, dat2, by="id"); dat = merge(dat1, dat2, by="id", all.x=T, all.y=T)</pre>
Chuyển từ cột sang dòng	<pre>id=c(1:4) sex=c("M", "F", "M", "F") group=c(1,1,2,2) day1=c(15,16,21,31) day2=c(17,15,23,35) day3=c(19,20,19,33) dat=data.frame(id,sex,group,day1,day2,day3) require(reshape2) dat1 = melt(dat, id=c("id", "sex", "group"), measure.vars=c("day1", "day2", "day3"))</pre>
Chuyển từ dòng sang cột	<pre>require(reshape) dat2 = cast(dat1, id+sex+group ~ variable)</pre>

Biểu đồ cơ bản trong R

PHÂN TÍCH	HÀM R
Biểu đồ phân bố (histogram)	hist(x, breaks=20, col="blue", border="white") # Thêm density lines(density(na.omit(x)), col="red", lwd=2)
Biểu đồ hộp (box plot)	boxplot(hdl, notch=T, col="blue") # Biểu đồ cho theo nhóm sex boxplot(x ~ sex, col="blue", notch=T, names=c("Men", "Women"))
Biểu đồ tương quan (scatter plot)	plot(y ~ x, pch=16) # dùng package car scatterplot(y ~ x, pch=16, smooth=F, col="blue", lwd=2) # Biểu đồ cho theo nhóm group scatterplot(y ~ x group, pch=c(16, 14), smooth=F, col=c("blue", "red"), lwd=c(1,2))
Biểu đồ tương quan đa biến (package psych)	library(psych); vars = cbind(age, bmi, whr, hdl, ldl, insulin, ir); pairs.panels(vars)
Phân chia cửa sổ	par(mfrow=c(rows, cols))

Biểu đồ dùng package chuyên dụng ggplot2

PHÂN TÍCH	HÀM R
Biểu đồ phân bố (histogram)	qplot(x) + geom_histogram(col="white", fill="blue") # Thêm density
Biểu đồ phân bố có thêm đường density	p = ggplot(data=pisa, aes(MATH)); p + geom_histogram(binwidth=20, aes(y=.. density..), col="white", fill="blue", lwd=0.5) + geom_density() + labs(x="MATH SCORE", y="Frequency")
Biểu đồ phân bố cho nhiều nhóm; mỗi nhóm một box riêng	qplot(MATH, col=AREA, geom="histogram", facets=~AREA)
Biểu đồ phân bố cho nhiều nhóm; mỗi nhóm một box riêng; hai biến phân nhóm	p = ggplot(data=pisa, aes(MATH)) p + geom_histogram(binwidth=20, aes(y=.. density..), col="white", fill="blue", lwd=0.5) + geom_density() + facet_grid(REGION ~ AREA)

Biểu đồ phân bố cho nhiều nhóm; thêm đường biểu diễn và density	<code>qplot(MATH, geom="density", fill=AREA, alpha=I(0.5)) + opts(legend.position="top")</code>
Biểu đồ tương quan (xy) phân theo nhóm	<code>qplot(x=READING, y=MATH, col=AREA) + stat_smooth(method="lm") + opts(legend.position="top")</code>
Biểu đồ xy cho từng đối tượng; vẽ chồng lên nhau	<code>p = ggplot(data=long, aes(x=visit, y=L1L4, group=id, colour = factor(id)));</code> <code>p + geom_line() + opts(legend.text=theme_text(size=5))</code>
Biểu đồ xy cho từng đối tượng; mỗi đối tượng một box	<code>p = ggplot(data=long, aes(x=visit, y=L1L4))</code> <code>p + geom_point() + geom_smooth(method=lm) + facet_wrap(~id)</code>

Phân tích mô tả

PHÂN TÍCH	HÀM R
Trung bình; phương sai; độ lệch chuẩn; trung vị; giá trị thấp nhất; giá trị cao nhất; range; số đối tượng	<code>mean(x); var(x); sd(x); median(x); min(x); max(x); range(x); length(x)</code>
Tính bách phân vị 2.5, 50, 97.5%	<code>quantile(median, probs=c(0.025, 0.975))</code>
Tóm tắt dữ liệu	<code>summary(dataset)</code>
Tóm tắt dữ liệu cho nhiều biến hay dataset dùng describe (trong psych)	<code>library(psych);</code> <code>summary(dataset, skew=F, range=F)</code>
Tóm tắt dữ liệu cho nhiều biến hay dataset; theo nhóm	<code>library(psych);</code> <code>describeBy(dataset, skew=F, range=F)</code>
Tóm tắt bằng hàm tabular (trong tables); biến phân nhóm	<code>tabular(REGION ~ 1);</code> <code>tabular(REGION~1*(n=1 + Percent("col")));</code> <code>tabular(REGION ~ AREA*(n=1 + Percent("row")));</code> <code>tabular(REGION ~ AREA*(n=1 + Percent("col")));</code> <code>tabular(REGION*AREA ~ TYPE)</code>
Tóm tắt bằng hàm CrossTable (trong gmodels); biến phân nhóm	<code>CrossTable(REGION, TYPE, prop.c=T, prop.r=T, prop.t=F, prop.chisq=F, chisq=T)</code>
Tóm tắt bằng hàm tabular (trong tables); biến phân nhóm	<code>tabular(REGION ~ MATH*(n=1+mean+sd));</code> <code>tabular(REGION*TYPE ~ MATH*(n=1+mean+sd));</code> <code>tabular(REGION*TYPE ~ (MATH + READING) * (n=1+mean+sd))</code>

Kiểm định xem biến x có tuân theo luật phân bố chuẩn	<code>shapiro.test(x)</code>
Kiểm định t xem trung bình mẫu bằng trung bình quần thể (mu)	<code>t.test(x, mu=30)</code>
Kiểm định t hai nhóm độc lập (unpaired t-test)	<code>t.test(x ~ group);</code> hoặc <code>t.test (group1, group2)</code>
Kiểm định t hai nhóm không độc lập (paired t-test)	<code>t.test(x ~ group, paired=T);</code> hoặc <code>t.test (group1, group2, paired=T)</code>
Kiểm định phương sai hai nhóm	<code>var.test(x ~ group)</code>
Kiểm định Wilcoxon cho 2 nhóm độc lập	<code>wilcox.test(x ~ group)</code>
Kiểm định Wilcoxon cho 2 nhóm không độc lập	<code>wilcox.test(group1, group2, paired=TRUE)</code>
Kiểm định nhị phân cho một tỉ lệ (binomial test)	# kiểm định xem tần số x xảy ra trong số n có bằng 50% <code>prop.test(x, n, 0.50)</code>
So sánh 2 tỉ lệ; kiểm định nhị phân	<code>fracture = c(7, 20)</code> <code>total = c(100, 110)</code> <code>prop.test(fracture, total)</code>
Kiểm định Khi bình phương (χ^2 test) 2 nhóm	<code>freq = table(sex, ethnicity);</code> <code>prop.test(freq)</code>
Kiểm định Khi bình phương (χ^2 test) nhiều nhóm	<code>chisq.test(sex, ethnicity)</code>
Kiểm định chính xác Fisher (Fisher's exact test)	<code>fisher.test(sex, ethnicity)</code>
Khoảng tin cậy 95% cho một tỉ lệ	<code>library(binom);</code> <code>x = c(3, 5, 7);</code> <code>n = rep(10, length(x));</code> <code>binom.confint(x, n, conf.level=0.95, methods="all")</code>
Khoảng tin cậy 95% cho một tỉ lệ gần 100% hay gần 0 (Phương pháp Cai & DasGupta 2002)	<code>n=40; x=39; alpha=0.05;</code> <code>qbeta(c(alpha/2, 1-alpha/2), x+0.5, n-x+0.5)</code>
Khoảng tin cậy 95% chính xác cho 2 tỉ lệ	<code>require("ExactCIdiff");</code> # <code>binormCI(n1,n2,x1,x2,conf.level,Citype)</code> <code>binormCI(10,15,2,4, conf.level=0.95,Citype="Two.sided")</code>

Mô hình hồi qui tuyến tính

PHÂN TÍCH	HÀM R
Hệ số tương quan Pearson (coefficient of correlation) giữa x và y	<code>cor(x, y);</code> <code>cor.test(x, y)</code>
Hệ số tương quan Spearman	<code>cor.test(x, y, method="spearman")</code>
Hệ số tương quan Kendall	<code>cor.test(x, y, method="kendall")</code>
Mô hình hồi qui tuyến tính đơn giản $y = a + bx$	<code>m = lm(y ~ x);</code> <code>summary(m);</code> <code>anova(m)</code>
Mô hình hồi qui tuyến tính đa biến $y = a + b_1x_1 + b_2x_2 + b_3x_3 + \dots$	<code>m = lm(y ~ x1 + x2 + x3 + ...);</code> <code>summary(m);</code> <code>anova(m)</code>
Mô hình hồi qui đa thức $y = a + b_1x^1 + b_2x^2 + \dots + b_px^p$	# đa thức bậc 2 <code>m = lm(y ~ poly(x, 2));</code> # đa thức bậc k <code>m = lm(y ~ poly(x, k));</code>
Tìm mô hình "tối ưu" bằng tiêu chuẩn AIC	<code>reg = lm(y ~ x1+x2+x3+x4+x5+x6+x7, data=REGdata);</code> <code>reg = lm(y ~ ., data=REGdata);</code> <code>step(reg, direction="both")</code>
Tìm mô hình "tối ưu" bằng tiêu chuẩn BIC (Bayesian Model Average)	<code>library(BMA);</code> <code>xvars = REGdata[, -1];</code> <code>yvar = REGdata[, 1];</code> <code>bma = bicreg(xvars, y, strict=FALSE, OR=20)</code> <code>imageplot.bma(bma)</code>

Phân tích phương sai

PHÂN TÍCH	HÀM R
Mô hình phân tích phương sai đơn giản hay ANOVA: y và x (x là factor)	<code>m = lm(y ~ x);</code> <code>m = aov(y ~ x);</code> <code>summary(x);</code> <code>anova(m)</code>
So sánh giữa các nhóm (post-hoc comparison) từ ANOVA, phương pháp Bonferroni	<code>pairwise.t.test(galactose, group, p.adj="bonferroni")</code>
So sánh giữa các nhóm (post-hoc comparison) từ ANOVA, phương pháp Tukey	<code>m = aov(y ~ x)</code> <code>TukeyHSD(m)</code>

Phân tích phương sai phi tham số (Kruskal test)	<code>kruskal.test(y ~ x)</code>
Phân tích phương sai với nhiều factor g1, g2, g3.	<code>m = aov(y ~ g1 + g2 + g3)</code> <code>TukeyHSD(m)</code> <code>plot(TukeyHSD(m), ordered=TRUE)</code>
Phân tích phương sai giai thừa (factorial experiment)	<code>m = aov(y ~ factor1 + factor2 + factor3);</code> <code>anova(m);</code> <code>plot(TukeyHSD(m), ordered=T)</code>
Phân tích phương sai thí nghiệm giao chéo (cross-over experiment)	<code>m = lm(y ~ treat + seq + period);</code> <code>anova(m);</code> <code>TukeyHSD(aov(y ~ treat+seq+period+id))</code>
Phân tích hiệp biến (analysis of covariance); x là biến liên tục	<code>m = lm(y ~ x + factor)</code> <code># có interaction</code> <code>m = lm(y ~ x + factor + factor:x)</code>

Mô hình hồi qui logistic

PHÂN TÍCH	HÀM R
Mô hình hồi qui logistic: biến y là nhị phân, biến x có thể là nhị phân hay liên tục	<code>m = glm(y ~ x, family="binomial");</code> <code>summary(m)</code>
Tính toán giá trị tiên lượng; vẽ biểu đồ	<code>predict(m, type="response");</code> <code>plot(x, fitted(glm(y ~ x, family="binomial")))</code>
Mô hình hồi qui logistic đa biến với 3 biến x1, x2, x3	<code>m = glm(y ~ x1 + x2 + x3, family="binomial");</code> <code>summary(m)</code>
Chọn mô hình "tối ưu" bằng phương pháp Bayesian Model Average	<code>library(BMA);</code> <code>xvars = cbind(x1,x2,x3,x4,x5);</code> <code>bma = bic.glm(xvars, y, strict=F, OR=20,glm.</code> <code>family="binomial");</code> <code>imageplot.bma(bma)</code>
Mô hình hồi qui Poisson	<code>age=c(19.5,29.5,39.5,49.5,59.5,69.5,79.5);</code> <code>cases = c(1, 16, 30, 71, 102, 130, 133);</code> <code>pop = c(172675, 123065, 96216, 92051, 72159,</code> <code>54722, 32185);</code> <code>dat = data.frame(age, cases, pop)</code> <code>library(MASS)</code> <code>m = glm(cases ~ age + offset(log(pop)),</code> <code>family=poisson,data=dat)</code> <code>summary(m)</code>
Mô hình hồi qui Binomial	<code>library(MASS)</code> <code>m = glm.nb(y ~ x1 + x2 + x3)</code> <code># chú ý: y là biến phụ thuộc, x1, x2, x3 là biến</code> <code>tiên lượng summary(m)</code>

Mô hình hồi qui Cox và phân tích sống còn

PHÂN TÍCH	HÀM R
Phương pháp Kaplan-Meier	<pre>library(survival); # status=1 là có biến cố, 0 là censored survtime = Surv(weeks, status==1); kp = survfit(Surv(weeks, status==1)~1); plot(kp)</pre>
Phương pháp Kaplan-Meier, so sánh 2 nhóm	<pre>bygroup = survfit(Surv(time, status==1)~group); summary(bygroup); plot(bygroup)</pre>
Mô hình Cox đơn biến	<pre>m = coxph(Surv(time, status==1) ~ group); summary(m)</pre>
Mô hình Cox đa biến, với biến tiên lượng x1, x2	<pre>m = coxph(Surv(time, status==1) ~ group+x1+x2); summary(m)</pre>
Tìm mô hình Cox "tối ưu" bằng phương pháp AIC	<pre>cox = coxph(Surv(y, status) ~ ., data=dat); summary(cox); search = step(cox, direction="both"); summary(search)</pre>
Tìm mô hình Cox "tối ưu" bằng phương pháp Bayesian Model Average	<pre>library(BMA); bma = bic.surv(xvars, time, death); summary(bma); imageplot.bma(bma)</pre>

Phân tích đa biến (multivariate analysis)

PHÂN TÍCH	HÀM R
Phân tích thành phần (principal component analysis)	<pre>pca = princomp(~factor1 + factor2, data=temp); summary(pca); loadings(pca)</pre>
Phân tích cụm (cluster analysis): đo lường khoảng cách	<pre>dat = read.table(text=" x1 x2 4 8 6 6 10 11 11 8 17 5 19 3 20 11 21 2 ", header=T) distance = dist(dat)</pre>

Phân tích cụm (cluster analysis): phân tích	<pre>library(cluster); hc.average = hclust(dist, method = "average"); plot(hc.average, hang = -1, main = "average")</pre>
Phân tích cụm (cluster analysis): xác định số cluster	<pre>library(NbClust); teeth = read.table(teeth.txt", header=T) teeth1 = as.numeric(as.matrix(teeth[, -1])) NbClust(teeth1, method = "average", index = "all")</pre>

Mô hình mixed effects

PHÂN TÍCH	HÀM R
Biểu đồ xyplot cho từng cá nhân: y là biến phân tích và time là thời gian, id là mã cá nhân	<pre>library(rms); library(lattice); library(lme4); xyplot(y ~ time id, type=c("p","r"), as.table=time)</pre>
Biểu đồ interaction cho từng cá nhân: y là biến phân tích và time là thời gian	<pre>fit = by(y, id, function(data) fitted.values(lm(y ~ time, data=data)))); fit = unlist(fit); names(fit) = NULL; interaction.plot(time, id, fit)</pre>
Mô hình unconditional growth: $y_i = a_i + b_iT + e_i;$ $a_i = A + u;$ $b_i = B + v;$ $y_i = (A + u) + (B + v)T + e_i;$ $y_i = (A + BT) + (u + vT + e_i)$	<pre>library(lme4) fit = lmer(y ~ 1 + time + (1 + time id), data=glucose, REML=0) summary(fit)</pre>
Mô hình conditional growth: $a_i = A_0 + A_1 \times treatment + u;$ $b_i = B_0 + B_1 \times treatment + v;$ $y_i = (A_0 + A_1 \times treatment + B_0T + B_1 \times treatment \times T) + (u + vT + e_i)$	<pre>fit = lmer(y ~ 1 + treatment + time + time:treatment + (1+time id), data=glucose, REML=0) summary(fit)</pre>

Phân tích tổng hợp

PHÂN TÍCH	HÀM R
Phân tích biến nhị phân, 2 nhóm: chuẩn bị dữ liệu	<pre>Study = 1:13 N1 = số bệnh nhân nhóm 1 D1 = số biến cố nhóm 1 N0 = số bệnh nhân nhóm 2 D0 = số biến cố nhóm 2 S1 = N1-D1 # số không biến cố nhóm 1 S0 = N0-D0 # số không biến cố nhóm 2 bb = data.frame(Study,N1,D1,S1,N0,D0,S0)</pre>
Phân tích biến nhị phân, 2 nhóm: tính effect size	<pre>library(metafor) es = escalc(measure = "RR", ai=D1, bi=S1, ci=D0, di=S0, data=bb, append=T)</pre>
Phân tích biến nhị phân, 2 nhóm: random effects model	<pre>re = rma(yi, vi, data = es); summary(re); plot(re); forest(re, attransf=exp)</pre>
Phân tích biến liên tục, 2 nhóm: chuẩn bị dữ liệu (n=số đối tượng, m=trung binh, sd=độ lệch chuẩn)	<pre>n1 = c(155,31,75,18,8,57,34,110,60) m1 = c(55,27,64,66,14,19,52,21,30) sd1 = c(47,7,17,20,8,7,45,16,27) n2 = c(156,32,71,18,13,52,33,183,52) m2 = c(75,29,119,137,18,18,41,31,23) sd2 = c(64,4,29,48,11,4,34,27,20) los = data.frame(n1,m1,sd1,n2,m2,sd2)</pre>
Phân tích biến liên tục, 2 nhóm: tính effect size	<pre>library(metafor) es = escalc(measure="MD", n1i=n1, m1i=m1, sd1i=sd1, n2i=n2, m2i=m2, sd2i=sd2, data=los, append=T)</pre>
Phân tích biến liên tục, 2 nhóm: random effects model	<pre>re = rma(yi, vi, data=es, method="FE") plot(re) forest(re)</pre>

Phân tích bootstrap

PHÂN TÍCH	HÀM R
Lấy mẫu ngẫu nhiên	<pre>x = c(1, 2, 3, 4, 5, 6, 7, 8, 9, 10) sample(x, 5, replace=T) sample(x, 5, replace=F)</pre>
Khoảng tin cậy 95% cho trung vị	<pre>x = c(0.05,0.15,0.35,0.25, ...); n = length(pain); B=1000; median = numeric(B); for (i in 1:B) { bs.sample = sample(x, n, replace=T) median[i] = median(bs.sample) } quantile(median, probs=c(0.025, 0.975)) hist(median, col="blue", border="white", main="")</pre>
So sánh 2 số trung vị	<pre>control = c(52,104,146, ...); treatment = c(94, 197, 16, ...); B=1000; con = rep(NA, B); trt = rep(NA, B); for (i in 1:B) { con[i] = median(sample(control, replace=T)) trt[i] = median(sample(treatment, replace=T)) dif[i] = trt[i]-con[i] } quantile(dif, c(0.025, 0.5, 0.975))</pre>
So sánh 2 tỉ lệ	<pre>n = c(11037, 11034); disease = c(104, 189); aspirin = c(rep(1, disease[1]), rep(0, n[1]-disease[1])); control = c(rep(1, disease[2]), rep(0, n[2]-disease[2])); B = 10000; bs1 = rep(NA, B); bs2 = rep(NA, B); for (i in 1:B) { resample1 = sample(aspirin, n[1], replace=T) dis1 = sum(resample1) resample2 = sample(control, n[2], replace=T) dis2 = sum(resample2) bs1[i] = dis1/n[1] bs2[i] = dis2/n[2] } RR = bs1/bs2; quantile(RR, c(0.025, 0.50, 0.975))</pre>

So sánh 2 tỉ lệ, phương pháp Bayes	<pre> x = 11; n1 = 20; alpha1 = 1; beta1 = 1; y = 5; n2 = 20; alpha2 = 1; beta2 = 1; p1 = rbeta(10000, x + alpha1, n1 - x + beta1); p2 = rbeta(10000, y + alpha2, n2 - y + beta2); rd = p2 - p1; plot(density(rd)); quantile(rd, c(.025, 0.5, 0.975)) </pre>
------------------------------------	--

Ước tính cỡ mẫu

PHÂN TÍCH	HÀM R
Ước tính cỡ mẫu (n) cho một tỉ lệ	<pre> alpha=0.05; z = qnorm(0.05/2) p=0.10; e = 0.01 n = (z/e)^2*p*(1-p) # Dùng package epicalc library(epicalc); n = n.for.survey(p=0.10, delta=0.01, alpha=0.05) </pre>
Ước tính n cho một số trung bình	<pre> alpha=0.05; z = qnorm(0.05/2) sigma=12; e = 2.5 n = (z/e*sigma)^2 ; n </pre>
Cỡ mẫu cho nghiên cứu so sánh 2 tỉ lệ	<pre> library(epicalc); n = n.for.2p(p1=0.75, p2=0.90, power=0.9, alpha=0.05, ratio=1); n </pre>
Cỡ mẫu cho nghiên cứu so sánh 2 số trung bình	<pre> library(epicalc); n = n.for.2means(mu1=0.80, mu2=0.84, sd1=0.12, sd2=0.12, power=0.9, alpha=0.05, ratio=1); n </pre>
Cỡ mẫu cho nghiên cứu so sánh 2 survival curves	<pre> library(epiR); epi.studysize(treat=0.60, control=0.50, n=NA, sigma=NA, power=0.80, r=1, conf.level=0.95, sided.test=2, method = "survival") </pre>
Cỡ mẫu cho nghiên cứu bệnh chứng	<pre> library(epiR); epi.studysize(treat = 2/100, control = 1/100, n = NA, sigma = 0.30, power = 0.90, r = 1, conf.level = 0.95, sided.test = 2, method = "case.control") </pre>
Cỡ mẫu cho nghiên cứu đoàn hệ	<pre> library(epiR); smoke=1.4*(5*413)/100000 nonsmoke=(5*413)/100000 epi.studysize(treat=smoke, control=nonsmoke, n=NA, sigma=NA, power=0.90, r=1, conf.level=0.95, sided.test=1, method="cohort.count") </pre>

Phân tích số liệu dãy thời gian (time series)

PHÂN TÍCH	HÀM R
Sắp xếp dữ liệu bằng hàm ts	<pre>births = scan("~/Documents/births.txt"); ts.births = ts(births, frequency=12, start=c(1946, 1))</pre>
Vẽ biểu đồ time series	<pre>plot.ts(ts.births)</pre>
Trung bình động (moving average) với bậc k	<pre>library(TTR); SMA(ts.births, n=5)</pre>
Phân tích trend, season, và random: dữ liệu không có season	<pre>ma5 = SMA(ts.births, n=5) plot.ts(ma5)</pre>
Phân tích trend, season, và random: dữ liệu có season	<pre>comp = decompose(ts.births); comp; plot(comp)</pre>
Điều chỉnh cho season	<pre>adj.births = ts.births-comp\$seasonal; plot(adj.births)</pre>
Tiên lượng bằng phương pháp simple exponential smoothing	<pre>library(forecast); forecast = HoltWinters(ts.births, beta=F, gamma=F); forecast; plot(ts.births); plot(forecast)</pre>
Tiên lượng bằng phương pháp Holt exponential smoothing	<pre>forecast1 = HoltWinters(ts.births, gamma=F); forecast1; plot(forecast1)</pre>
Tiên lượng bằng phương pháp Holt-Winters smoothing	<pre>forecast1 = HoltWinters(ts.births); forecast1; plot(forecast1); forecast2 = forecast.HoltWinters(forecast1, h=60) plot.forecast(forecast2)</pre>
Mô hình ARIMA: sai phân (differencing), differences=k	<pre>skirts = scan("~/Documents/skirts.txt", skip=5); ts.skirts = ts(skirts, start=c(1866)); # tính sai phân dif.skirts = diff(ts.skirts, differences=1); plot.ts(dif.skirts)</pre>
Autocorrelation và partial autocorrelation	<pre>acf(dif.kings, lag.max=20, plot=F); acf(dif.kings, lag.max=20); pacf(dif.kings, lag.max=20, plot=F); pacf(dif.kings, lag.max=20)</pre>
Mô hình MA	<pre>kings = scan("~/Documents/kings.txt") library(forecast); auto.arima(kings)</pre>

Mô hình RA	<pre>vc = scan("~/Documents/vulcano.txt") ts.vc = ts(vc, start=c(1500)); plot.ts(ts.vc); auto.arima(vc); auto.arima(vc, ic="bic")</pre>
Mô hình ARIMA(p, d, q)	<pre>arimal = arima(ts.kings, order=c(0, 1, 1)); arimal</pre>
Tiên lượng bằng mô hình ARIMA(p, d, q)	<pre>library(forecast); forecast1 = forecast.Arima(arimal, h=5); forecast1; plot.forecast(forecast1)</pre>

WinBUGS

Bước 1: Viết mô hình

```
MODEL {

# prior information
p1 ~ dbeta(0.5, 0.5)
p2 ~ dbeta(0.5, 0.5)

# data or likelihood
x1 ~ dbin(p1, n1)
x2 ~ dbin(p2, n2)

# effect size
diff = p1-p2
rr = p1/p2
or = (p1/(1-p1)) / (p2/(1-p2))
logOR = log(or)
ppos = step(OR - 1)
}

DATA list(x1=3, n1=18, x2=2, n2=23)
```

Bước 2: Kiểm tra ngữ pháp

Model → Specification → Specification Tool:

Highlight MODEL, nhấn check model

Bước 3: Nhập dữ liệu

Highlight list. Specification Tool → Load data

Bước 4: Compile

Specification Tool → Compile

Bước 5: Initial value

Specification Tool → gen inits

Bước 6: Mô tả thông số (parameter)

Inference → sample → Sample monitor tool

node trong Sample Monitor Tool và gõ tên parameter

Bước 7: Mô phỏng (generating simulated values)

Model → Update → Update Tool (from 5000, refresh 100)

Bước 8: Xem xét kết quả thông tin hậu định (posterior information)

Sample Monitor Tool → beg

Chọn thông số (trường hợp này là p) từ field node

Bước 9: Chẩn đoán (diagnosis)

Sample Monitor Tool và nhấn chuột vào nút history.

Lập trình và hàm với R

R được phát triển sao cho người sử dụng có thể phát triển những hàm thích hợp cho mục đích phân tích và tính toán của mình. Thật vậy, như đã đề cập trong phần đầu của sách, có thể xem R là một ngôn ngữ thống kê, và chúng ta có thể sử dụng ngôn ngữ để giải quyết các vấn đề không thường thấy trong sách giáo khoa. Phần này chỉ trình bày một vài hàm đơn giản để bạn đọc có thể hiểu cách vận hành của R và hi vọng giúp bạn đọc tự phát triển các hàm sau đó.

Hàm (hay có khi còn gọi là “macro” trong các phần mềm khác) thực chất là tập hợp một số lệnh được lưu trữ dưới một cái tên. Ở mức độ đơn giản nhất, hàm là “tổc kị” cho một nhóm lệnh.

Ví dụ 1: Trong các lệnh sau đây, chúng ta tạo hai dữ liệu (data1 và data2). Mỗi dữ liệu có hai cột số liệu được tạo ra bằng mô phỏng từ phân phối chuẩn. Sau đó, vẽ biểu đồ cho hai dữ liệu với ghi chú.

```

data1 = cbind(rnorm(100,1), rnorm(100,0))
data2 = cbind(rnorm(100,-1), rnorm(100,0))
xr = range(rbind(data1,data2)[,1])
yr = range(rbind(data1,data2)[,2])
plot(data1, xlim=xr, ylim=yr, col=1, xlab= " " , ylab= " " )
par(new=T)
plot(data2, xlim=xr, ylim=yr, col=2, xlab= " " , ylab= " " )
title(main= "My simulated data" , xlab= "Weight" , ylab= "Yield ")
legend(-3.0, -1.5, c( "Big " , "Small " ), col=1:2, pch=1)

```

Một cách để nhớ tất cả các lệnh này là lưu trữ chúng trong một text file chẳng hạn. Mỗi lần muốn sử dụng, chúng ta chỉ đơn giản cắt và dán các lệnh này vào R. Một cách khác tốt hơn là tạo ra một hàm gồm các lệnh trên để có thể sử dụng nhiều lần.

Mỗi hàm R phải có tên. Tất cả các lệnh được chứa trong khu vực được giới hạn bằng hai kí hiệu { và }. Kí hiệu { cho biết tất cả các lệnh sau đó là nằm trong hàm; và kí hiệu } cho biết chấm dứt hàm. Trong ví dụ trên, chúng ta gọi hàm là `plotfigure`:

```

plotfigure <- function()
{
  data1 = cbind(rnorm(100,1), rnorm(100,0))
  data2 = cbind(rnorm(100,-1), rnorm(100,0))
  xr = range(rbind(data1,data2)[,1])
  yr = range(rbind(data1,data2)[,2])
  plot(data1, xlim=xr, ylim=yr, col=1, xlab= " " , ylab= " ")
  par(new=T)
  plot(data2, xlim=xr, ylim=yr, col=2, xlab= " " , ylab= " ")
  title(main= "My simulated data " , xlab= "Weight " ,
        ylab= "Yield " )
  legend(-3.0, -1.5, c( "Big " , "Small " ), col=1:2, pch=1)
}

```


Sau khi đã cho vào R, chúng ta chỉ đơn giản gọi hàm nhiều lần như sau:

```

> plotfigure()
> plotfigure()

```

và kết quả sẽ như sau:



Trong hàm `plotfigure` trên, chúng ta mô phỏng 100 số liệu từ phân phối chuẩn. Và cứ mỗi lần ứng dụng, hàm chỉ tạo ra 100 số liệu, chúng ta không thay đổi được (ngoại trừ phải thay đổi từ lúc biên tập, hay lập hàm). Nói cách khác, hàm trên không có thông số.

Khía cạnh tiện lợi của hàm là chúng ta có thể làm cho thông số thay đổi theo ý muốn của người sử dụng. Chẳng hạn như chúng ta muốn thay đổi số liệu mô phỏng và trung bình từ luật phân phối chuẩn, chúng ta chỉ cần cho hai con số này là hai thông số (parameters) để người sử dụng có thể thay đổi. Tạm gọi đó là thông số `n`, `mean1`, và `mean2`, thì hàm sẽ như sau:

```
plotfigure <- function(n, mean1, mean2)

{
  data1 = cbind(rnorm(n,mean1), rnorm(n,0))
  data2 = cbind(rnorm(n,mean2), rnorm(n,0))
  xr = range(rbind(data1,data2)[,1])
  yr = range(rbind(data1,data2)[,2])
  plot(data1, xlim=xr, ylim=yr, col=1, xlab="", ylab="")
  par(new=T)
```




```
plot(data2, xlim=xr, ylim=yr, col=2, xlab="", ylab="")
title(main="My simulated data", xlab="Weight",
      ylab="Yield")
legend(-3.0, -1.5, c("Big", "Small"), col=1:2, pch=1)
}
```

Khi ứng dụng hàm, chúng ta chỉ đơn giản thay đổi `n` và `mean`. Trong hai lệnh sau đây, chúng ta đầu tiên vẽ một biểu đồ tán xạ với 200 số liệu, và số trung bình -2 và 2. Trong lệnh hai, chúng ta nâng số liệu lên 200, nhưng trung bình vẫn như lần mô phỏng trước:

```
> plotfigure(200, 2, -2)
> plotfigure(500, 2, -2)
```

Và kết quả sẽ khác trên:



Ví dụ 2: Chúng ta muốn viết một hàm để cộng hai số. Tất nhiên R có khả năng làm “việc” này, nhưng vì lí do minh họa, chúng ta sẽ giả thiết đơn giản như thế. Gọi hàm đó là `add`. Hai thông số `a` và `b` là “arguments”. Cách viết như sau:

```
add <- function(a, b)
{
  sum = a+b
  ans <- "Answer = "
  cat(ans, sum, "\n")
}
```

Như đã thấy, bước đầu tiên, chúng ta cho tên hàm là `add` và định nghĩa thông số `a` và `b`. Một hàm phải được mở đầu bằng kí hiệu `{` và chấm dứt bằng `}`. `sum` là một biến số cộng `a` và `b`. `ans <- "Answer = "` định nghĩa trả lời (có thể không cần). `cat(ans, sum, "\n")` có chức năng thu thập số liệu và trình bày kết quả cho người sử dụng hàm, trong đó `"\n"` có nghĩa là sau khi trình bày, cho người sử dụng một prompt khác. Bạn đọc có thể dán các lệnh trên vào R và thử cho lệnh:

```
> add(3, 9)
Answer = 12

> add(sqrt(5), exp(10))
Answer = 22028.7
```

Ví dụ 3: Hàm sau đây tiến hành nhiều tính toán hơn hàm trong ví dụ 1. Nếu chúng ta có một biến số gồm n phần tử $x_1, x_2, x_3, \dots, x_n$ tuân theo luật phân phối chuẩn với trung bình μ và phương sai σ^2 . Viết theo kí hiệu toán:

$$x_i \sim N(\mu, \sigma^2)$$

Nếu chúng ta có thông tin trước cho biết μ có luật phân phối chuẩn với trung bình θ và phương sai τ^2 , hay:

$$\mu \sim N(\theta, \tau^2)$$

Qua định lí Bayes, chúng ta có thể ước tính trung bình:

$$\mu_p = \frac{\frac{\theta}{\tau^2} + \frac{\bar{nx}}{\sigma^2}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}$$

và phương sai

$$\sigma_p^2 = \left(\frac{1}{\tau^2} + \frac{n}{\sigma^2} \right)^{-1}$$

Trong đó, $\bar{x}$ là số trung bình của mẫu n . μ_p và σ_p^2 được gọi là “posterior”. Chúng ta có thể viết một hàm bằng R để tính hai số này như sau. Gọi tên hàm là `bayes`.

```
bayes <- function(x, prior.mean, prior.var)
{
  n <- length(x)
  sample.mean = mean(x)
  sample.var = var(x)
```

```

numerator = (prior.mean/prior.var) + (n*sample.mean/
sample.var)
denominator = 1/prior.var + n/sample.var
posterior.mean = numerator/denominator
posterior.var = 1/denominator
a = "Posterior mean = "
b = "Posterior variance = "
cat("Sample size = ", n, "\n")
cat("Sample mean = ", sample.mean, "\n")
cat("Sample var = ", sample.var, "\n")
cat("Prior mean = ", prior.mean, "\n")
cat("Prior var = ", prior.var, "\n")
cat(a, posterior.mean, "\n")
cat(b, posterior.var, "\n")
}

```

Ví dụ 4: Mật độ chất khoáng trong xương (bone mineral density - bmd) trong một quần thể thường phân phối theo luật phân phối chuẩn, với giá trị trung bình khoảng 1.0 g/cm^2 và phương sai 0.0144 g/cm^2 . Giả dụ chúng ta đo mật độ xương của một nhóm bệnh nhân như sau: 1.0, 1.5, 2.1, 1.7, 1.8, 0.9, 0.7. Chúng ta muốn biết giá trị trung bình và phương sai của mẫu này sau khi “điều chỉnh” cho trung bình và phương sai đã biết trước. Trước hết, chúng ta gọi nhóm số liệu này là bmd:

```
> bmd = c(1.0, 1.5, 2.1, 1.7, 1.8, 0.9, 0.7)
```

và sau đó “gọi” hàm bayes như sau:

```

> bayes(bmd, 1.0, 0.0144)
Sample size = 7
Sample mean = 1.385714
Sample var = 0.2747619
Prior mean = 1
Prior var = 0.0144
Posterior mean = 1.103525
Posterior variance = 0.01053507

```

Trên đây chỉ là một vài hàng giới thiệu cách lập trình và viết hàm bằng ngôn ngữ R. Trong thực tế, tất cả các hàm như survival, BMA, meta, metafor, rms, Hmisc, v.v. đều được phát triển bằng ngôn ngữ R. Bạn đọc có thể tham khảo tài liệu “Introduction to R” của W. Venables và B. Ripley (phần cuối của sách) để biết thêm chi tiết kĩ thuật.

Phụ lục 2

Thuật ngữ dùng trong sách

TIẾNG ANH	TIẾNG VIỆT
95% confidence interval	Khoảng tin cậy 95%
Akaike Information criterion (AIC)	Tiêu chuẩn thông tin Akaike
Analysis of covariance	Phân tích hiệp biến
Analysis of variance (ANOVA)	Phân tích phương sai
Bar chart	Biểu đồ thanh
Binomial distribution	Phân phối nhị phân
Box plot	Biểu đồ hộp
Categorical variable	Biến thứ bậc
Clock chart	Biểu đồ đồng hồ
Coefficient of correlation	Hệ số tương quan
Coefficient of determination	Hệ số xác định bội
Coefficient of heterogeneity	Hệ số bất đồng nhất
Combination	Tổ hợp
Continuous variable	Biến liên tục
Correlation	Tương quan

Covariance	Hợp biến
Cross-over experiment	Thí nghiệm giao chéo
Cumulative probability distribution	Hàm phân phối tích lũy
Degree of freedom	Bậc tự do
Determinant	Định thức
Discrete variable	Biến rời rạc
Dot chart	Biểu đồ điểm
Estimate	Ước số
Estimator	Hàm ước lượng thống kê
Factorial analysis of variance	Phân tích phương sai cho thí nghiệm giai thừa
Fixed effects	Ảnh hưởng bất biến
Frequency	Tần số
Function	Hàm
Heterogeneity	Bất đồng nhất
Histogram	Biểu đồ tần số
Homogeneity	Đồng nhất
Hypothesis test	Kiểm định giả thiết
Inverse matrix	Ma trận nghịch đảo
Latin square experiment	Thí nghiệm hình vuông Latin
Least squares method	Phương pháp bình phương nhỏ nhất
Linear Logistic regression analysis	Phân tích hồi qui tuyến tính logistic
Linear regression analysis	Phân tích hồi qui tuyến tính
Matrix	Ma trận
Maximum likelihood method	Phương pháp hợp lí cực đại
Mean	Số trung bình
Median	Số trung vị

Meta-analysis	Phân tích tổng hợp
Missing value	Giá trị không
Model	Mô hình
Multiple linear regression analysis	Phân tích hồi qui tuyến tính đa biến
Normal distribution	Phân phối chuẩn
Object	Đối tượng
Outlier	Giá trị ngoại vi
Parameter	Thông số, tham số
Permutation	Hoán vị
Pie chart	Biểu đồ hình tròn
Poisson distribution	Phân phối Poisson
Polynomial regression	Hồi qui đa thức
Probability	Xác suất
Probability density distribution	Hàm mật độ xác suất
P-value	Trị số P
Quantile	Hàm định bậc
Random effects	Ảnh hưởng ngẫu nhiên
Random variable	Biến ngẫu nhiên
Relative risk	Tỉ số nguy cơ tương đối
Repeated measure experiment	Thí nghiệm tái đo lường
Residual	Phần dư
Residual mean square	Trung bình bình phương phần dư
Residual sum of squares	Tổng bình phương phần dư
Scalar matrix	Ma trận vô hướng
Scatter plot	Biểu đồ tán xạ
Significance	Có ý nghĩa thống kê

Simulation	Mô phỏng
Standard deviation	Độ lệch chuẩn
Standard error	Sai số chuẩn
Standardized normal distribution	Phân phối chuẩn chuẩn hóa
Survival analysis	Phân tích biến cố
Transposed matrix	Ma trận chuyển vị
Variable	Biến (biến số)
Variance	Phương sai
Weight	Trọng số
Weighted mean	Trung bình trọng số

25

Đôi lời bạt cùng bạn đọc (và tài liệu tham khảo)

Qua 22 chương sách và 2 phụ lục, bạn đọc đã đi cùng tác giả một hành trình khá dài trong phân tích thống kê và biểu đồ. Trước khi “chia tay” bạn đọc, tác giả cũng muốn có đôi lời tạm biệt.

Qua kinh nghiệm giảng dạy và nghiên cứu cá nhân cho thấy phần lớn sinh viên khi tiếp cận với khoa học thống kê lần đầu chẳng mấy gì hào hứng, nếu không nói là khó khăn, vì sách giáo khoa soạn cho môn học này rất xa rời thực tế, với những ví dụ không có trong đời thường. Những khái niệm trừu tượng, những công thức rắc rối, những phép tính phức tạp và rườm rà làm cho người học cảm thấy khó khăn và từ đó cảm thấy thiếu hứng thú theo đuổi môn học. Thật vậy, có khi đọc sách giáo khoa, các bài báo nghiên cứu khoa học, chúng ta bắt gặp những phương pháp hay và những mô hình thích hợp cho nghiên cứu của chính mình, nhưng không biết làm sao tính toán các mô hình đó. Trong cuốn sách này, tác giả muốn cung cấp cho bạn đọc một phương tiện phân tích thực tế để lấp đi cái khoảng trống phương pháp và kiến thức mà có lẽ bạn đọc còn thiếu.


Học phải đi đôi với hành. Cách học về phương pháp hay nhất, theo tôi, là... bắt chước. R cung cấp cho bạn đọc cách học mô phỏng đó rất tiện lợi. Trong khi đọc những chương sách này cùng với những ví dụ, bạn đọc có thể gõ những lệnh vào máy tính và xem kết quả có nhất quán với những gì mình đọc hay không. Sau khi đã biết được cách sử dụng một hàm hay một lệnh nào đó, bạn đọc có thể thêm vào (hay bớt ra) những thông số của hàm để xem kết quả. Chỉ có học như thế thì bạn đọc mới nắm vững được các khái niệm và cách sử dụng R.

Chúng ta học từ sai sót. Qua cuốn sách này, tác giả muốn bạn đọc đi một quãng đường khá... gập ghềnh, tức là bạn đọc phải tương tác với máy tính bằng những lệnh của R. Trong quá trình tương tác đó, có thể một số lệnh sẽ không chạy, vì gõ sai tên biến số hay sai chính tả, vì không để ý đến kí tự viết hoa và viết thường, vì số liệu không đầy đủ hay sai sót, v.v... Tất cả những lần sai sót đó sẽ giúp cho bạn đọc rút ra kinh nghiệm và trở nên thành thạo hơn. Đó là cách học mà người Anh hay gọi là “trial and error”, học từ sai lầm và thử nghiệm.

Tinn-R

Một công trình phân tích số liệu cần nhiều lệnh và hàm R. Tuy nhiên, vì tính tương tác mà bạn đọc theo dõi, các lệnh này sẽ biến mất khi ngưng R. Vấn đề đặt ra là có cách nào lưu trữ các lệnh này trong một hồ sơ để sau này sử dụng lại. Phần mềm cực kì có ích cho mục đích này là Tinn-R (cũng có thể tải xuống và cài đặt vào máy hoàn toàn miễn phí). Website để tải Tinn-R và tài liệu sử dụng là: <http://www.sciviews.org/Tinn-R>.

Tinn-R thực chất là một editor cho R (và nhiều phần mềm khác). Tinn-R cho phép chúng ta lưu trữ tất cả các lệnh cho một công trình phân tích trong một hồ sơ. Với Tinn-R, chúng ta có sẵn một chỉ dẫn trực tuyến về cách sử dụng các lệnh hay hàm trong R. Trong khi lệnh gõ sai “văn phạm” R, Tinn-R sẽ báo ngay và đề nghị cách sửa! Giao diện Tinn-R có thể giống như sau:




Chẳng hạn như trong giao diện trên, khi chúng ta gõ `read.table()` thì một chỉ dẫn ngay phía dưới hiện ra, với tất cả thông số của hàm `read.table`. Với Tinn-R chúng ta ít khi phạm phải những sai sót nhỏ trong khi chạy R. Sau khi đã xong một số lệnh, chúng ta có thể dùng chuột để tô đậm (highlight) những lệnh cần chạy và gửi sang R. Chú ý chúng ta không cần phải rời Tinn-R trong khi R chạy.

Đến đây, có lẽ bạn đọc sẽ hỏi: có cách nào sử dụng R dễ dàng hơn mà không cần phải gõ các lệnh? Câu trả lời là ... có. Tại sao tôi không giới thiệu trước, ngay từ chương đầu? Tại vì, tôi muốn bạn đọc đi con đường khó trước khi đi con đường dễ, nên đến bây giờ mới nói đến một phần mềm phụ khác có khả năng giúp cho bạn đọc sử dụng R một cách nhanh chóng hơn, dễ dàng hơn, và tiện lợi hơn bằng chuột thay vì bằng bàn phím.

Rcmdr

Phần mềm để “tự động hóa” R có tên là Rcmdr (viết tắt từ R commander). Trong thực tế, Rcmdr là một package mà bạn đọc có thể tải từ website chính thức của R (<http://cran.au.r-project.org/src/contrib/Descriptions/Rcmdr.html>) hay website của tác giả của Rcmdr sau đây: <http://socserv.socsci.mcmaster.ca/jfox/Misc/Rcmdr>. Chú ý, Rcmdr vận hành tốt khi có những package sau đây trong máy: `relimp`, `multcomp`, `lmtest`, `effects`, `car`, và `abind`. Nếu chưa có những package này, bạn đọc nên tải chúng về máy. Tài liệu chỉ dẫn Rcmdr cũng có thể tải từ website <http://cran.R-project.org/doc/packages/Rcmdr.pdf>.

Khi đã tải Rcmdr xuống và cài đặt vào máy tính, bạn đọc chỉ đơn giản lệnh: `library(Rcmdr)`, và một giao diện như dưới đây sẽ xuất hiện. Với phần “menu” (như File, Edit, Data, Statistics, Graphs, Models, Distribution, Tool, Help) bạn đọc có thể tự mình khám phá cách vận hành của Rcmdr bằng chuột.




Về nội dung cuốn sách ở lần xuất bản thứ nhất này, tác giả không có ý định bàn về những mô hình phân tích đa biến (multivariate analysis model) như phân tích yếu tố (factor analysis), phân tích tập hợp (cluster analysis), phân tích tương quan đa biến (correspondence analysis), phân tích phương sai đa biến (multivariate analysis of variance), v.v... vì đây là những phương pháp tương đối cao cấp, đòi hỏi người sử dụng phải thông thạo không những về lý thuyết thống kê, mà còn phải hiểu rất rõ những phương pháp phân tích căn bản như trình bày trong sách này. Tuy nhiên, bạn đọc có nhu cầu cho các phương pháp phân tích này cũng có thể tìm hiểu trong trang web của R để biết thêm các package chuyên dụng cho phân tích đa biến.

RStudio

Sau cùng, tôi muốn giới thiệu RStudio như là một add-on rất tốt cho R. Trong thực tế, RStudio là một phần mềm đứng riêng, hiểu theo nghĩa, khi khởi động RStudio thì không cần khởi động R, và tất cả các hàm, các lệnh R đều có thể thực hiện trong RStudio.

Về giao diện, RStudio có 4 cửa sổ chính: cửa sổ dành cho viết hàm, cửa sổ quản lý các biến và dataframe, cửa sổ kết quả, và cửa sổ để lưu trữ các biểu đồ (xem hình dưới đây).



RStudio có thể tải về (miễn phí) từ website dưới đây. Dĩ nhiên, đối với máy tính cá nhân, chúng ta chọn “Desktop”:

<http://www.rstudio.com/products/RStudio>

Tài liệu tham khảo

- Hiện nay, thư viện sách về R còn tương đối khiêm tốn so với thư viện cho các phần mềm thương mại như SAS và SPSS. Tuy nhiên, trong thời đại tiến bộ phi thường về thông tin internet và toàn cầu hóa như hiện nay, sách in và sách xuất bản trên website không còn có những khác nhau bao xa. Phần lớn chỉ dẫn về cách sử dụng R có thể tìm thấy rải rác đây đó trên các website từ các trường đại học và website cá nhân trên khắp thế giới. Phần này chỉ liệt kê một số sách mà bạn đọc nếu cần tham khảo thêm có thể tìm đọc. Trong quá trình viết cuốn sách mà bạn đọc đang cầm trên tay, tác giả cũng tham khảo một số sách và trang web sẽ liệt kê sau đây với vài lời nhận xét cá nhân.
- Tài liệu tham khảo chính về R là bài báo của hai người sáng tạo ra R: Ihaka R, Gentleman R. R: A language for data analysis and graphics. *Journal of Computational and Graphical Statistics* 1996; 5:299-314.

Sách tham khảo về R

- **“Data Analysis and Graphics Using R - An Example Approach”** (Nhà xuất bản Cambridge University Press, 2003) của John Maindonald nay đã xuất bản lần thứ 2 với thêm một tác giả mới John Braun. Đây là cuốn sách rất có ích cho những ai muốn tìm hiểu và học về R. Năm chương đầu của sách viết cho bạn đọc chưa từng biết về R, còn các chương sau thì viết cho các bạn đọc đã biết cách sử dụng R thành thạo.
- **“Introductory Statistics With R”** (Nhà xuất bản Springer, 2004) của Peter Dalgaard là một cuốn sách loại căn bản cho R nhằm vào bạn đọc chưa biết gì về R. Sách tương đối ngắn (chỉ khoảng 200 trang) nhưng giá khá đắt!
- **“Linear Models with R”** (Nhà xuất bản Chapman & Hall/CRC, 2004) của Julian Faraway. Sách hiện có thể tải xuống miễn phí từ internet tại website sau đây: <http://www.stat.lsa.umich.edu/~faraway/book/prs.pdf> hay <http://cran.r-project.org/doc/contrib/Faraway-PRA.pdf>. Tài liệu dài 213 trang.
- **“R Graphics (Computer Science and Data Analysis)”** (Nhà xuất bản Chapman & Hall/CRC, 2005) của Paul Murrell. Đây là cuốn sách chuyên về phân tích biểu đồ bằng R. Sách có rất nhiều mã để bạn đọc có thể tự thiết kế các biểu đồ phức tạp và... màu mè.
- **“Modern Applied Statistics with S-Plus”** (Nhà xuất bản Springer, 4th Edition, 2003) của W. N. Venables và B. D. Ripley được viết cho ngôn ngữ S-Plus nhưng tất cả các lệnh và mã trong sách này đều có thể áp dụng cho R mà không cần thay đổi (S-Plus là tiền thân của R, nhưng S-Plus là một phần mềm thương mại, còn R thì hoàn toàn miễn phí!). Có thể nói đây là cuốn sách tham khảo cho tất cả những ai muốn phát triển thêm về R. Hai tác giả cũng là những chuyên gia có thẩm quyền về ngôn ngữ R. Sách dành cho bạn đọc với trình độ cao về máy tính và thống kê học.

Các website quan trọng hay có ích về R

- Rất nhiều tài liệu tham khảo có thể tải từ website chính thức của R sau đây: <http://cran.R-project.org/other-docs.html>

Trong đó có một số tài liệu quan trọng như **“An Introduction to R”** của W. N. Venables và B. D. Ripley.

Địa chỉ internet: <http://cran.r-project.org/doc/manuals/R-intro.pdf>.

- Vài tài liệu hướng dẫn cách sử dụng R có thể tải (miễn phí) và tham khảo như sau:

“R for Beginners” (57 trang) của Emmanuel Paradis. Tài liệu được soạn cho bạn đọc mới làm quen với R.

Địa chỉ internet: http://cran.r-project.org/doc/contrib/Paradis-rdebuts_en.pdf.

“Using R for Data Analysis and Graphics: Introduction, Code and Commentary” (35 trang) của John Maindonald là một tóm lược các lệnh và hàm căn bản của R cho phân tích số liệu và biểu đồ. Chủ đề của tài liệu này rất gần với cuốn sách mà bạn đang đọc.

Địa chỉ internet: <http://cran.r-project.org/doc/contrib/usingR.pdf>

“Statistical Analysis with R - a quick start” (46 trang) của Oleg Nenadic và Walter Zucchini. Tài liệu hướng dẫn cách ứng dụng R cho phân tích thống kê và biểu đồ.

Địa chỉ internet: http://www.statock.wiso.uni-goettingen.de/mitarbeiter/ogi/pub/r_workshop.pdf

“A Brief Guide to R for Beginners in Econometrics” (31 trang) của M. Arai. Tài liệu chủ yếu soạn cho giới phân tích thống kê kinh tế.

Địa chỉ internet: http://people.su.se/~ma/R_intro

“Notes on the use of R for psychology experiments and questionnaires” (39 trang) của Jonathan Baron và Yuelin Li. Web: <http://www.psych.upenn.edu/~baron/rpsych/rpsych.html>. Tài liệu được soạn cho giới nghiên cứu tâm lý học và xã hội học. Có ví dụ về log-linear model và một số mô hình phân tích phương sai trong tâm lý học.

Địa chỉ internet: <http://www.psych.upenn.edu/~baron/rpsych/rpsych.html>

StatsRus gồm một sưu tập về các mẹo để sử dụng R hữu hiệu hơn (dài khoảng 80 trang). Địa chỉ internet: <http://lark.cc.ukans.edu/pauljohn/R/statsRus.html>

- Một tài liệu **“Hướng dẫn sử dụng R cho phân tích số liệu và biểu đồ”** (khoảng 110 trang - thường xuyên cập nhật hóa) do chính tác giả viết bằng tiếng Việt. Thực chất là tóm lược một số chương chính của cuốn sách này.

http://cran.r-project.org/doc/contrib/Intro_to_R_Vietnamese.pdf

- Sau cùng, tôi muốn giới thiệu đến các bạn đọc loạt bài giảng video về R và phân tích dữ liệu trên youtube. Cho đến nay, số bài giảng đã lên đến 30, đi từ đơn giản giới thiệu R , cách đọc dữ liệu, đến phân tích hồi qui tuyến tính. Các bạn có thể tải toàn bộ bài giảng về máy tính để theo dõi cùng với cuốn sách này. Địa chỉ là:

<https://www.youtube.com/user/drnguyenvtuan/videos>

26

Vài hàng về tác giả

Tác giả là một nhà nghiên cứu cao cấp (Principal Fellow) và đứng đầu một laboratory chuyên nghiên cứu về di truyền và dịch tễ học loãng xương của Viện Nghiên cứu Y khoa Garvan (Australia). Ông còn là Giáo sư y khoa của Đại học New South Wales (Australia). Mới đây, tác giả được bổ nhiệm chức danh Giáo sư xuất sắc (Distinguished Professor) của Đại học Công nghệ Sydney (Australia). Ông là một nhà nghiên cứu nổi tiếng trên thế giới về loãng xương, và một trong những kết quả nghiên cứu của ông được phát triển thành một mô hình tiên lượng gãy xương “Garvan Fracture Risk Calculator” (www.fractureriskcalculator.com) được các bác sĩ khắp thế giới sử dụng trong lâm sàng. Ở Việt Nam, tác giả là giám đốc chương trình nghiên cứu về cơ và xương tại Trường Đại học Tôn Đức Thắng (bmr.tdt.edu.vn), và giáo sư thỉnh giảng của Trường Đại học Nguyễn Tất Thành, Thành phố Hồ Chí Minh.

Tác giả là tiến sĩ thống kê học và tiến sĩ y khoa. Ông là tác giả của trên 200 công trình nghiên cứu khoa học được công bố trên nhiều tạp san nổi tiếng trên thế giới như *Nature*, *Science*, *Nature Genetics*, *JAMA*, *Lancet*, *New England Journal of Medicine*, v.v. Những nghiên cứu của tác giả có tác động lớn, với hơn 15000 trích dẫn, và chỉ số H của tác giả là 65. Tác giả còn là chuyên gia bình duyệt cho trên 20 tạp san khoa học khắp thế giới, và duyệt đơn tài trợ nhiều cơ quan tài trợ của Mỹ, Âu châu, Á châu.

Ở Việt Nam, tác giả đã từng giảng dạy về thống kê học, phương pháp nghiên cứu khoa học, và y học thực chứng ở Việt Nam trong suốt 15 năm qua

cho hơn một ngàn học viên trên khắp cả nước. Ông cũng đã xuất bản 12 cuốn sách ở Việt Nam. Sách của ông viết về y khoa, giáo dục, khoa học và nghiên cứu khoa học. Tác giả từng nhận bằng khen của Bộ trưởng Bộ Ngoại giao Việt Nam năm 2004, giải thưởng “*Vinh danh Nước Việt*” năm 2005, Giải thưởng Sách Hay 2013 cho cuốn “Đi vào nghiên cứu khoa học” (Nhà xuất bản Tổng hợp Thành phố Hồ Chí Minh, 2012), một số giải thưởng của Ủy ban nhân dân Thành phố Hồ Chí Minh, Hội Y học Thành phố Hồ Chí Minh v.v..

Mục lục

Lời nói đầu

1. Giới thiệu ngôn ngữ R.....	9
2. Nhập dữ liệu	19
3. Biên tập dữ liệu	27
4. Dùng R cho các phép tính đơn giản và ma trận	35
5. Tính toán xác suất và mô phỏng (simulation)	47
6. Kiểm định thống kê và kiểm định giả thuyết	77
7. Văn phạm biểu đồ trong R	89
8. Phân tích dữ liệu bằng biểu đồ	107
9. Phân tích thống kê mô tả	127
10. Phân tích hồi qui tuyến tính	157
11. Phân tích phương sai (Analysis of variance).....	189
12. Phân tích hồi qui logistic.....	237
13. Phân tích sống còn (event history hay survival analysis)	261
14. Phân tích đa biến	283
15. Mô hình ảnh hưởng hỗn hợp (mixed-effects model)	307
16. Phân tích tổng hợp	325
17. Phương pháp Bootstrap	355
18. Phương pháp Bayes.....	369
19. Hướng dẫn sử dụng WinBUGS.....	393
20. Thiết kế thí nghiệm (Design of experiments)	409
21. Ước tính cỡ mẫu	425
22. Phân tích số liệu dãy thời gian (Time Series Analysis)	447
23. Phụ lục 1: Hàm R dùng cho phân tích	483
24. Phụ lục 2: Thuật ngữ dùng trong sách.....	505
25. Đôi lời bạt cùng bạn đọc (và tài liệu tham khảo).....	509
26. Vài hàng về tác giả	517

PHÂN TÍCH DỮ LIỆU VỚI



Nguyễn Văn Tuấn

Chịu trách nhiệm xuất bản

Giám đốc - Tổng Biên tập

NGUYỄN THỊ THANH HƯƠNG

Biên tập : **CAO BÁ ĐỊNH**

NGUYỄN NGỌC THÀNH

Sửa bản in : **CAO THỊ BÍCH THÚY**

Trình bày : **GIAO CHINH**

Bìa : **NGUYỄN ĐÌNH NGUYỄN**

NGUYỄN UYÊN

NHÀ XUẤT BẢN TỔNG HỢP THÀNH PHỐ HỒ CHÍ MINH

62 Nguyễn Thị Minh Khai, Quận 1, Thành phố Hồ Chí Minh

ĐT: (08) 38 296 764 - 38 256 713 - 38 247 225

Fax: 84.8.38222726 - Email: tonghop@nxbhcm.com.vn

Sách online: www.nxbhcm.com.vn - Ebook: www.sachweb.vn

NHÀ SÁCH TỔNG HỢP 1

62 Nguyễn Thị Minh Khai, Quận 1, Thành phố Hồ Chí Minh ♦ **ĐT: 38 256 804**

NHÀ SÁCH TỔNG HỢP 2

86 - 88 Nguyễn Tất Thành, Quận 4, Thành phố Hồ Chí Minh ♦ **ĐT: 39 433 868**

In số lượng 1.000 cuốn. Khổ 18 x 25 cm

Tại: Công ty Cổ phần in Khuyến học phía Nam - 128/7/7 Trần Quốc Thảo, Quận 3, TP. Hồ Chí Minh

XNĐKXB số: 42-2015/CXBIPH/29-282/THTPHCM cấp ngày 09/01/2015

QĐXB số: 51/QĐ-THTPHCM-2015 ngày 16/01/2015

ISBN: 978 - 604 - 58 - 2831 - 1

In xong và nộp lưu chiểu quý I năm 2015

Tác giả là Tiến sĩ Thống kê học và Tiến sĩ Y khoa. Ông là tác giả của trên 200 công trình nghiên cứu khoa học được công bố trên nhiều tập san nổi tiếng thế giới như: Nature, Science, Nature Genetics, JAMA, Lancet, New England Journal of Medicine, v.v.. Những nghiên cứu của tác giả có tác động lớn trong nghiên cứu khoa học, với hơn 15.000 trích dẫn, và chỉ số H của tác giả là 65. Ông còn là chuyên gia bình duyệt cho trên 20 tập san khoa học khắp thế giới, và duyệt đơn tài trợ của nhiều cơ quan tài trợ tại Mỹ, châu Âu, châu Á.

Ở Việt Nam, tác giả đã từng giảng dạy về Thống kê học, Phương pháp nghiên cứu khoa học và Y học thực chứng trong suốt 15 năm qua cho hơn một ngàn học viên trên khắp đất nước. Ông cũng đã xuất bản 12 cuốn sách ở Việt Nam. Sách của ông viết về y khoa, giáo dục, khoa học và nghiên cứu khoa học. Tác giả từng nhận bằng khen của Bộ trưởng Bộ Ngoại giao Việt Nam năm 2004, giải thưởng "Vinh danh nước Việt" năm 2005, Giải thưởng Sách Hay 2013, một số bằng khen của Ủy ban nhân dân Thành phố Hồ Chí Minh, Hội Y học Thành phố Hồ Chí Minh v.v..

Phân tích dữ liệu với



Phân tích dữ liệu bằng các phương pháp thống kê học là một kỹ năng rất cần thiết cho tất cả các lĩnh vực khoa học và xã hội. Phân tích dữ liệu là một quy trình khám phá trong khoa học. Trong thời đại “big data” (dữ liệu lớn) phân tích dữ liệu đang dần trở thành một khoa học: khoa học dữ liệu hay data science. Đây là một khoa học mới và đầy hào hứng mà các bạn có thể “dấn thân”. Do đó, dù muốn hay không thì tất cả các nhà chuyên môn, nhà khoa học cần phải làm quen hay ít ra là có kiến thức về phương pháp và mô hình phân tích dữ liệu.

Cuốn sách bạn đang cầm trên tay là một nỗ lực nhằm giới thiệu các phương pháp phân tích và mô hình thống kê phổ biến. Các phương pháp và mô hình bao gồm hồi qui tuyến tính, hồi qui logistic, phân tích tổng hợp (meta-analysis), mô hình phân tích sống còn (survival analysis), phương pháp phân tích chuỗi dữ liệu theo thời gian (time series data), phương pháp Bayes, phương pháp bootstrap, v.v.. Với một nội dung khá rộng như thế, cuốn sách này sẽ giúp ích cho các nhà nghiên cứu, giảng viên cao đẳng và đại học, sinh viên, hay bất cứ ai muốn học về thống kê và phương pháp phân tích dữ liệu.

Ngôn ngữ được sử dụng trong sách là R. Có nhiều lý do R được chọn làm ngôn ngữ để thực hiện các phương pháp trên, kể cả sự miễn phí và năng lực khoa học. Không giống như các phần mềm thương mại khác đều tốn khá nhiều tiền, R hoàn toàn miễn phí. Bất cứ ai ở bất cứ nơi nào trên thế giới có truy cập mạng internet đều có thể tải R về máy tính, tốn vài phút cài đặt, và bắt đầu sử dụng. Trước đây, chỉ có một thiểu số nhà nghiên cứu trên thế giới (chủ yếu là ở các nước tiên tiến) mới có điều kiện sử dụng các phần mềm thống kê, nhưng từ ngày có R thì bất cứ ai trên thế giới cũng đều có điều kiện áp dụng những phương pháp phân tích tinh vi nhất và hiện đại nhất cho nghiên cứu khoa học và phân tích dữ liệu. Do đó, sự ra đời của R đã làm một cuộc cách mạng thống kê ở qui mô toàn cầu. R còn “dân chủ hóa” việc tiếp cận các phương pháp phân tích dữ liệu tiên tiến nhất trên thế giới.



PHÂN TÍCH DỮ LIỆU VỚI R

ISBN 978-6-04-582831-1



9 786045 828311

Giá: 250.000 đ

www.sachweb.vn

