





Nhà Máy Xử Lý Dữ Liệu Thời Gian Thực

Xây dựng Hệ thống SOC & Phân tích Dữ liệu lớn với Kafka và Spark

Cơ sở lý thuyết: Big Data 5V và Công nghệ cốt lõi (Kafka & Spark)

Big Data 5V



Apache Kafka



- Xử lý luồng dữ liệu phân tán
- Thông lượng cao, độ trễ thấp
- Khả năng mở rộng linh hoạt
- Bền bỉ, chịu lỗi tốt

Apache Spark




- Tính toán trên bộ nhớ (In-Memory)
- Xử lý dữ liệu lớn nhanh chóng
- Thư viện đa dạng (SQL, MLlib, GraphX)
- Xử lý theo lô và theo luồng (Micro-batching)

Khởi nguồn ý tưởng & Mục tiêu cốt lõi

01

Khả năng chịu tải (Throughput)

Làm sao để tiếp nhận >9,000 requests/phút mà không mất mát dữ liệu?



02

Độ trễ phân tích (Latency)


Có thể rút ngắn thời gian phát hiện từ hàng giờ xuống chỉ còn vài giây?



03


Ngưỡng phát hiện (Thresholding)

Cơ chế nào để phân biệt chính xác đợt tấn công Brute Force với lỗi người dùng thông thường?




Giải pháp đơn giản hóa: Xử lý theo Lô vs. Xử lý theo Luồng

Hệ thống cũ	Giải pháp Đề xuất
Xử lý theo Lô (Tích lũy theo giờ/ngày)	Xử lý theo Luồng (Tính toán tức thời Data In-Motion)
Ghi xuống Ổ cứng (Disk I/O)	Tính toán trực tiếp trên RAM (In-Memory)
Dễ nghẽn cổ chai, sập hệ thống	Có trạm đệm hấp thụ lực (Kafka Buffer)
Độ trễ (Latency): Tính bằng phút/giờ	Độ trễ (Latency): Tính bằng giây (Micro-batching)



- **Kiến trúc Tách rời (Decoupled):** Trạm trung chuyển Apache Kafka đóng vai trò như “Hồ chứa” (Reservoir) hấp thụ toàn bộ lưu lượng thô. Cụm Spark (RAM Generator) hoạt động hoàn toàn độc lập phía sau để kéo dữ liệu về xử lý mà không làm ảnh hưởng đến máy chủ web gốc.
- **Phân luồng Dữ liệu:** Thuật toán tự động nhận diện và rẽ nhánh luồng dữ liệu. Các IP tấn công (Threat) bị cô lập tức thời (Security), trong khi 70% luồng dữ liệu sạch được tái sử dụng để đẩy về Bảng điều khiển phân tích kinh doanh (BI).

Thuật toán Nhận diện: Cửa sổ Thời gian & Ngưỡng lỗi



1. Khung thời gian (Sliding Window)

Cắt thời gian thực thành các đoạn ngắn (VD: 1 phút) để giám sát cục bộ.

2. Gom nhóm (Aggregation)


Nhóm toàn bộ nhật ký theo từng Địa chỉ IP nguồn.

3. Đối sánh luật (Rule Matching)

Đếm tổng số mã lỗi HTTP 401 (Brute Force) hoặc 404 (Scanning).

Trượt qua ranh giới ngưỡng -> Kích hoạt cô lập IP tức thời.

Cấu trúc Ảo hóa Toàn phần (Dockerized Pipeline)




Giả lập dữ liệu: Kịch bản Python trộn lẫn lưu lượng User thật và Botnet.

Tính độc lập: Từng vi dịch vụ (ZooKeeper, Kafka Broker, Spark Master/Worker) chạy trong các container tách biệt, loại bỏ xung đột tài nguyên.


Trạm 1: Sinh dữ liệu & Phân loại “Dòng chảy”

× — ↗ × Lưu lượng Hợp lệ Trễ 0.05 - 0.5s <pre>{ "ip": "192.168.1.45", "url": "/home", "method": "GET", "status": 200, "time": "2026-03-19 10:05:22" }</pre>	× — ↗ × Mạng Máy tính ma Trễ 0.005 - 0.05s (Tốc độ cực nhanh) <pre>{ "ip": "10.0.0.99", "url": "/login", "method": "POST", "status": 401, "time": "2026-03-19 10:05:22" }</pre>
---	---

Trạm 2: Trạm trung chuyển Kafka & Khả năng Chịu tải



Cơ chế Bất đồng bộ (Async): Cho phép kích bản đẩy hàng ngàn bản ghi/giây mà không bị nghẽn (Block).



Phân vùng (Partitions = 3): Luồng dữ liệu được chia nhỏ thành 3 luồng song song, tối ưu hóa sức mạnh đa nhân.



Kiểm soát áp lực (Backpressure): Đảm bảo luồng cung ứng không làm sập cụm Spark phân tích phía sau.

Trạm 3: Spark ETL & Cơ chế Chia lô nhỏ (Micro-batching)



Spark bóc tách lược đồ
JSON -> Gom thành
Khung dữ liệu
(DataFrame).

```
26/01/18 18:17:17 INFO NettyBlockTransferService: Server created on a7783867269f136257
26/01/18 18:17:17 INFO BlockManager: Using org.apache.spark.storage.BandwidthReclamationPolicy for block replication policy
26/01/18 18:17:17 INFO BlockManagerMaster: Registering BlockManager BlockManagerId(driver, e7783867269f, 36267, None)
26/01/18 18:17:17 INFO BlockManagerMasterEndpoint: Registering BlockManager e7783867269f:36267 on 474.4 MB for BlockManagerId(driver, e7783867269f, 36267, None)
26/01/18 18:17:17 INFO BlockManagerMaster: Registered BlockManager BlockManagerId(driver, e7783867269f, 36267, None)
26/01/18 18:17:17 INFO BlockManager: Initialized BlockManager: BlockManagerId(driver, e7783867269f, 36267, None)
[329] OS ghi tệp tin dữ liệu vào Data Lake...
[328] OS ghi tệp tin dữ liệu vào Data Lake...
[323] OS ghi tệp tin dữ liệu vào Data Lake...
[322] OS ghi tệp tin dữ liệu vào Data Lake...
[323] OS ghi tệp tin dữ liệu vào Data Lake...
[328] OS ghi tệp tin dữ liệu vào Data Lake...
[325] OS ghi tệp tin dữ liệu vào Data Lake...
[326] OS ghi tệp tin dữ liệu vào Data Lake...
[327] OS ghi tệp tin dữ liệu vào Data Lake...
[328] OS ghi tệp tin dữ liệu vào Data Lake...
[328] OS ghi tệp tin dữ liệu vào Data Lake...
[328] OS ghi tệp tin dữ liệu vào Data Lake...
[328] OS ghi tệp tin dữ liệu vào Data Lake...
[322] OS ghi tệp tin dữ liệu vào Data Lake...
[322] OS ghi tệp tin dữ liệu vào Data Lake...
[322] OS ghi tệp tin dữ liệu vào Data Lake...
[333] OS ghi tệp tin dữ liệu vào Data Lake...
[330] OS ghi tệp tin dữ liệu vào Data Lake...
[327] OS ghi tệp tin dữ liệu vào Data Lake...
[330] OS ghi tệp tin dữ liệu vào Data Lake...
[323] OS ghi tệp tin dữ liệu vào Data Lake...
[340] OS ghi tệp tin dữ liệu vào Data Lake...
[341] OS ghi tệp tin dữ liệu vào Data Lake...
[342] OS ghi tệp tin dữ liệu vào Data Lake...
[342] OS ghi tệp tin dữ liệu vào Data Lake...
[343] OS ghi tệp tin dữ liệu vào Data Lake...
[343] OS ghi tệp tin dữ liệu vào Data Lake...
[346] OS ghi tệp tin dữ liệu vào Data Lake...
[347] OS ghi tệp tin dữ liệu vào Data Lake...
[348] OS ghi tệp tin dữ liệu vào Data Lake...
[349] OS ghi tệp tin dữ liệu vào Data Lake...
```



Thay vì ghi từng dòng, hệ thống sử dụng Trigger gom toàn bộ sự kiện mỗi **3 giây** thành một Lô (Batch) đẩy xuống Data Lake. Cân bằng hoàn hảo giữa Tốc độ và Tài nguyên.

Kết quả Thực nghiệm: Sức chịu tải của Kiến trúc

Thông lượng tải



9,120 Requests / 60 giây (~152 req/s).

Tỷ lệ thất thoát

0% (Hệ thống luân chuyển nguyên vẹn 100% JSON thô).

Độ trễ (Latency)

~3 Giây (Đạt tiêu chuẩn thời gian thực).



Biểu đồ xác nhận cuộc tấn công: Lỗi 401 (18.4%) và 404 (18.5%) tăng vọt đồng thời với lưu lượng đột biến.

SOC Dashboard: Truy vết & Cô lập Mối đe dọa

Cảnh báo Lỗi 401:

9 IP

Cảnh báo Lỗi 404:

5 IP

Tổng IP Bị Chặn:

21 IP


 DANH SÁCH ĐỊA CHỈ IP VI PHẠM BẢO MẬT

	Địa Chỉ IP	Số Lượt Vi Phạm		Địa Chỉ IP	Số Lượt Vi Phạm
1	141.180.155.247	290	1	180.189.142.218	322
2	29.69.163.226				295
3	76.209.20.221				266
4	5.247.75.218	253	4	126.76.246.124	282
5	90.3.128.178	252	5	115.48.199.180	254
6	113.127.120.5	247	6	142.91.117.56	213


Có những địa chỉ IP thực hiện gần 300 lượt truy cập lỗi chỉ trong chớp nhoáng nhằm vào /login và /wp-login.php.

Hệ thống nhận diện và tự động bóc tách thành công máy tính ma ra khỏi lưu lượng người dùng thật.

Trí tuệ Doanh nghiệp (BI): "Biến Dữ liệu rác thành Tài sản"



Kiến trúc tách rời (Decoupled) cho phép bóc tách IP độc hại, tái sử dụng luồng log hợp lệ cho nghiệp vụ mà không cần quét lại cơ sở dữ liệu chính.




Tỷ lệ chuyển đổi (CVR) chính xác đạt 10.38%.

Đánh giá Kiến trúc & Giới hạn Thực tế

Thành quả


Khắc phục triệt để điểm mù độ trễ của cơ sở dữ liệu quan hệ/truyền thống.

Hoạt động đa nhiệm (Security + BI) xuất sắc.




Giới hạn 1 - Single Node

Cấu hình 1 máy trạm hiện tại giới hạn ở mức vài ngàn req/s. Cần nâng cấp lên Multi-node Cluster cho quy mô Enterprise.




Giới hạn 2 - Ngưỡng Tĩnh

Thuật toán (Threshold-based) dễ bị qua mặt bởi các đợt tấn công 'Low and Slow'.



Giới hạn 3 - Data Lake CSV

File CSV thiếu tính năng Schema Evolution. Cần nâng cấp lên Parquet/ElasticSearch.



Tổng kết: Lá chắn An ninh & Kim chỉ nam Nghiệp vụ

- Ứng dụng thành công Kafka & Spark vào bài toán thực tiễn, làm chủ công nghệ dữ liệu đang bay (Data In-Motion).
- Rút ngắn thời gian phản ứng sự cố xuống mức 3 giây, bảo vệ tài nguyên máy chủ.

Bảng tổng kết hiệu năng thực nghiệm

Tiêu chí	Kết quả
Thông lượng (Throughput)	152 req/s
Độ trễ phản ứng (Latency)	3s
Tỷ lệ chuyển đổi chính xác (CVR)	10.38%

“Chuyển hóa tệp nhật ký thụ động thành một cỗ máy phân tích chủ động, bảo vệ hệ thống nền tảng đồng thời thúc đẩy chiến lược kinh doanh.”

Kết thúc báo cáo Đồ án môn học. Xin cảm ơn thầy và các bạn.